

YAPAY ZEKA VE MAKİNE ÖĞRENMESİ

KURS NOTLARI

Kaan ASLAN

C VE SİSTEM PROGRAMCILARI DERNEĞİ

Son Güncelleme Tarihi: 28/07/2022

Bu kurs notları Kaan ASLAN tarafından hazırlanmıştır. Kaynak belirtilmek koşuluyla her türlü alıntı yapılabılır.

GİRİŞ

Bu bölümünde "yapay zeka (artificial intelligence) ve makine öğrenmesi (machine learning)" konusuna bir giriş yapılmaktadır.

Yapay Zeka (Artificial Intelligence) Nedir?

Zeka kapsamı, işlevleri ve yol açtığı sonuçları bakımından karmaşık bir olgudur. Zekanın ne olduğu konusunda psikologlar ve nörobilimciler arasında tam bir fikir birliği bulunmamaktadır. Çeşitli kuramcılar ve araştırmacılar tarafından zekanın çeşitli tanımları yapılmıştır. Bu kuramcılar ve araştırmacıların bazıları yaptıkları tanımdan hareketle zekayı ölçmek için çeşitli araçlar da geliştirmeye çalışmışlardır.

Charles Spearman zekayı "g" ve "s" biçiminde iki yeteneğin birleşimi olarak tanımlamıştır. Spearman'a göre "g" faktörü akıl yürütme ve problem çözmeyle ilgili olan "genel zekayı" belirtir. "s" faktörü ise müzik, sanat, iş yaşamı gibi özel alanlara yönelik "spesifik zekayı" belirtir. İnsanlar "zeka" denildiğinde daha çok genel zekayı kastetmektedirler.

Howard Gardner tarafından kuramsal hale getirilen "çoklu zeka (multiple intelligence)" zeka teorisinde Gardner zekayı "sözel/dilbilimsel (verbal/linguistic), müzikal (musical), mantıksal/matematiksel (logical/mathematical), görsel uzamsal (visual/spatial), kinestetik (kinesthetic), kişilerarası (interpersonal), içsel (intrapersonal)" olmak üzere başlangıçta yedi türe ayırmıştır. Sonra bu yedi türe "doğasal (naturalistic), varoluşsal (existentialist)" biçiminde iki tür daha ekleyerek dokuzu çıkarmıştır.

Robert Sternberg'e göre ise "analitik (analytical), pratik (practical) ve yaratıcı (creative)" olmak üzere üç tür zeka vardır. Analitik zeka problemi parçalara ayırma, analiz etme ve çözme ile ilgili yetileri içermektedir. Bu yetiler aslında zeka testlerinin ölçmeye çalıştığı yetilerdir. Pratik zeka yaşamı sürdürmek için gerekli olan pratik becerilerle ilgilidir. Yaratıcı zeka ise yeni yöntemler bulmak, problemleri farklı biçimlerde çözebilmek, yenilikler yapabilmekle ilgili yetilerdir.

Catell-Horn-Carroll (CHC) Teorisi diye isimlendirilen çok katmanlı zeka teorisi üzerinde en çok durulan zeka teorisidir. (Raymond Catell aslında Spearman'ın John Horn ise Catell'in öğrencisidir.) Catell zekayı "kristalize zeka (crystalized intelligence)" ve "akıcı zeka (fluid intelligence)" biçiminde ikiye ayırmıştır. Kristalize zeka öğrenilmiş ve oturmuş bilgi ve becerilerle ilgili iken akıcı zeka problem çözme ve yeni durumlara uyum sağlama becerileriyle ilgilidir. John Horn

ise Catell'in bu iki tür zekasını genişletecek ona görsel işitsel yetileri, belleğe erişimle ilgili yetileri, tepki zamanlarına ilişkin yetileri, niceliksel işlemlere yönelik yetileri ve okuma yazma becerilerini de eklemiştir. Nihayet John Carroll zeka ile ilgili 460 yeteneği faktör analizine sokarak üç katmanlı bir zeka teorisi oluşturmuştur. CHC teorisi Stanford Binet ve Wechsler zeka testlerinin ileri sürümlerinin benimsediği zeka anlayışıdır.

Yapay zeka ise -ismi üzerinde- insan zekası ile ilgili bilişsel süreçlerin makineler tarafından sağlanmasına yönelik süreçleri belirtmektedir. Yapay zeka terimi ilk kez 1955 yılında John McCarthy tarafından uydurulmuştur. Doğal zekada olduğu gibi yapay zekanın da farklı kişiler tarafından pek çok tanımı yapılmaktadır. Ancak bu terim genel olarak "insana özgü nitelikler olduğu varsayılan akıl yürütme, anlam çıkartma, genelleme ve geçmiş deneyimlerden öğrenme gibi yüksek zihinsel süreçlerin makineler tarafından gerçekleştirilmesi" biçiminde tanımlanabilir. Yapay zekanın diğer bazı tanımları şunlardır:

- Yapay zeka insan zekasına ilişkin "öğrenme", "akıl yürütme", "kendini düzeltme" gibi süreçlerin makineler tarafından simüle edilmesidir.
- Yapay zeka zeki makineler yaratma amacında olan bilgisayar bilimlerinin bir alt alanıdır.
- Bilgisayarların insanlar gibi davranışmasını sağlamayı hedefleyen bilgisayar bilimlerinin bir alt dalıdır.

Yapay zekanın simüle etmeye çalıştığı bilişsel süreçlerin bazlarının şunlar olduğuna dikkat ediniz:

- Bir şeyin nasıl yapılacağını bilme (knowledge)
- Akıl yürütme (reasoning)
- Problem çözme (problem solving)
- Algılama (perception)
- Öğrenme (learning)
- Planlama (planning)
- Doğal dili anlama ve konuşma
- Uzmanlık gerektiren alanlarda karar verme

Yapay Zeka Çalışmalarının Kısa Tarihi

Yapay zeka ile ilgili düşünceler ve görüşler antik çağ'a kadar götürülebilir. Ancak modern yapay zeka çalışmalarının 1950'li yıllarda başladığı söylenebilir. Şüphesiz yapay zeka alanındaki gelişmeleri de aslında başka alanlardaki gelişmeler tetiklemiştir. Örneğin bugün kullandığımız elektronik bilgisayarlar olmasaydı yapay zeka bugünkü durumuna gelemeyecekti. İşte aslında pek çok bilimsel ve teknolojik gelişmeler belli bir noktaya gelmiş ve yapay zeka dediğimiz bu alan 1950'lerde ortaya çıkmaya başlamıştır.

Yapay zeka çalışmalarının ortayamasına yol açan önemli gelişmeler şunlar olmuştur:

- **Mantıktaki Gelişmeler:** Bertrand Russell ve Alfred North Whitehead tarafından 1913 yılında yazılmış olan "Principia Mathematica" adlı üç cilt kitabı "bicimsel mantıkta (formal logic)" devrim niteliğinde etki yapmıştır.
- **Matematikteki Gelişmeler:** 1930'larda Alonzo Church "Lambda Calculus" denilen bicimsel sistemi geliştirmiştir ve özyinelemeli fonksiyonel notasyonla hesaplanabilirliği araştırmış ve sorgulamıştır. Yine 1930'larda Kurt Gödel "bicimsel sistemler (formal systems)" üzerindeki çalışmalarıyla teorik bilgisayar bilimlerinin öncülüğünü yapmıştır.
- **Turing Makineleri:** Alan Turing'in henüz elektronik bilgisayarlar gerçekleştirilmeden 1930'lu yılların ortalarında (ilk kez 1936) tasarladığı teorik bilgisayar yapısı olan "Turing Makineleri" bilgisayar bilimlerinin ve yapay zeka kavramının ortaya çıkışında etkili olmuştur. (Turing makinelerinin çeşitli modelleri vardır. Bugün hala Turing makineleri

algoritmalar dünyasında algoritma analizinde ve algoritmik karmaşıklıkta teorik bir karşılaştırma aracı olarak kullanılmaktadır.)

- **Elektronik Bilgisayarların Ortaya Çıkması:** 1940'lı yıllarda ilk elektronik bilgisayarlar gerçekleştirilmeye başlanmıştır. Bilgisayarlar yapay zeka çalışmalarının gerçekleştirilmesinde en önemli araçlar durumundadır.

Yapay Zeka (Artificial Intelligence) terimi ilk kez John McCarthy tarafından 1955 yılında uydurulmuştur. John McCarthy, Marvin Minsky, Nathan Rochester ve Claude Shannon tarafından 1956 yılında Dartmouth College'de bir konferans organize edilmiştir. Bu konferans yapay zeka kavramının ortaya çıkışını bakımından çok önemlidir. Bu konferans yapay zekanın doğumu olarak kabul edilmektedir. Yapay zeka terimi de bu konferansta katılımcılar tarafından kabul görmüştür. John McCarthy aynı zamanda dünyanın ilk programlama dillerinden biri olan Lisp'i de 1958 yılında tasarlamıştır. Lisp hala yapay zeka çalışmalarında kullanılmaktadır.

Yapay zeka çalışmalarının "yaz dönemleri" ve "kış dönemleri" olmuştur. Buradaki "yaz dönemleri" konuya ilginin arttığı, finansman sıkıntısının azaldığı, çeşitli kurumların yapay zeka çalışmaları için fonlar ayırdığı dönemleri belirtmektedir. "Kış dönemleri" ise yaz döneminin tersine konuya ilginin azaldığı, finansman sıkıntısının arttığı, kurumların yapay zeka çalışmaları için fonlarını geri çektiği dönemleri belirtmektedir.

1956-1974 yapay zekanın altın yılları olmuştur. Bu yıllar arasında çeşitli algoritmik yöntemler geliştirilmiş ve pek çok uygulama üzerinde çalışılmıştır. Örneğin arama (search) yöntemleri uygulanmış ve arama uzayı (search space) sezgisel (heuristic) yöntemlerle daraltılmaya çalışılmıştır. Yine bu yıllarda doğal dili anlamaya yönelik ilk çalışmalar gerçekleştirilmiştir. Bu ilk çalışmalarдан elde edilen çeşitli başarılar yapay zeka alanında iyimser bir hava estirmiştir. Örneğin:

- 1958 yılında Simon ve Newell "10 yıl içinde dünya satranç şampiyonunun bir bilgisayar olacağını" iddia etmişlerdir. (Halbuki bu durum 90'lı yılların ikinci yarısında gerçekleşmeye başlamıştır.)

- 1970 yılında Minsky 3 yıldan 8 yıla kadar makinelerin ortalama bir insan zekasına sahip olabileceği iddia etmiştir.

1974-1980 yılları arasında yapay zeka alanında kış dönemine girilmiştir. Daha önce yapılan tahminlerin çok iyimser olduğu görülmüş bu da biraz hayal kırıklığına yol açmıştır. Bu yıllarda yapay sinir ağları çalışmaları büyük ölçüde durmuştur. Yeni projeler için finans elde edilmesi zorlaşmıştır.

1980'li yıllarla birlikte yapay zeka çalışmalarında yine yükseliş başlamıştır. 80'li yıllarda en çok yükselişe geçen yapay zeka alanı "uzman sistemler" olmuştur. Japonya bu tür projelere önemli finans ayırmaya başlamıştır. Ayrıca Hopfield ve Rumelhart'in çalışmaları da "yapay sinir ağlarına" yeni bir soluk getirmiştir.

1987-1993 yılları arasında yine yapay zeka çalışmaları kış dönemine girmiştir. Konuya ilgi azalmış ve çeşitli projeler için finans kaynakları da kendilerini geri çekmiştir.

1993 yılından itibaren yapay zeka alanı yine canlanmaya başlamıştır. Bilgisayarların güçlenmesi, Internet teknolojisinin gelişmesi, mobil aygıtların gittikçe yaygınlaşması sonucunda veri analizinin önemi artmış ve bu da yapay zeka çalışmalarına yeni bir boyut getirmiştir. 1990'lı yılların ortalarından itibaren veri işlemeye yeni bir dönem başlamıştır. Veri madenciliği bir alan olarak kendini kabul ettirmiştir. Özellikle 2011 yılından başlayarak büyük veri (big data) analizleri iyice yaygınlaşmış, yapay sinir ağlarının bir çeşidi olan derin öğrenme (deep learning) çalışmaları hızlanmış, IOT uygulamaları da yapay zekanın önemini hepten artırmıştır.

Yapay Zekanın Alt Alanları

Yapay zeka aslında pek çok alt konuya ayrılabilen bir alandır. Yapay zekanın önemli alt alanları şunlardır:

- Makine Öğrenmesi
- Yapay Sinir Ağları ve Derin Öğrenme
- Robotik Sistemlerin Tasarımı ve Gerçekleştirilmesi
- Bulanık Sistemler (Fuzzy Logic Systems)
- Evrimsel Yöntemler (Genetic Algoritmalar, Differential Evolution, Neuroevolution vs.)
- Üst Sezgisel (Meta Heuristic) Yöntemler (Karınca Kolonisi, Particle Swarm Optimization)
- Olasılıksal (Probabilistic) Yöntemler (Bayesian Network, Hidden Markov Model, Kalman Filter vs.)
- Uzman Sistemler (Expert Systems)

Yapay Zekanın Uygulama Alanları

Yapay zekanın tipik uygulama alanları şunlardır:

- Yapay Yaratıcılık Faaliyetleri (Artificial Creativity)
- Planlama ve Çizelgeleme Faaliyetleri
- Akıl Yürütme (Reasoning) Faaliyetleri
- Otomatik Hedef Belirlemesi (Automatic Target Recognition)
- Yüz Tanıma (Face Recognition)
- Konuşma Tanıma (Speech Recognition)
- Konuşanı Tanıma (Speaker Recognition)
- Bilgisayarlı Görü (Computer Vision)
- Görüntü İşleme (Image Processing)
- OCR (Optical Character Recognition), Zeki Karakter Tanıma (Intelligent Character Recognition) ve Zeki Sözcük Tanıma (Intelligent Word Recognition)
- Nesne Tanıma (Object Recognition)
- El Yazısı Tanıma (Handwriting Recognition)
- Hastalığa Tanı Koyma Sistemleri (Diagnosis Systems)
- Uzman Sistemler (Expert Systems)
- Karar Destek Sistemleri (Decision Support Systems)
- Klinik Karar Destek Sistemleri (Clinical Decision Support Systems)
- Zeka Oyunlarını Oynaması (Satranç, Go, vs.)
- Veri Madenciliği (Data Mining)
- Yazı Madenciliği (Text Mining)
- Süreç Madenciliği (Process Mining)
- E-Posta Spam Filtreleri (Spam Filtering)
- Etkinlik Belirleme (Activity Recognition)
- Otomatik Resim Yorumlama (Automatic Image Annotation)
- İlişkili Olanları Bulma (Relationship Extraction)
- Referans Çözümlemesi (Coreference Resolution)
- Doğal Dili Anlama (Natural Language Understanding)
- Makine Çevirisi (Machine Translation)
- Semantic Web (Semantic Web)
- Soru Yanıtlama Sistemleri (Question Answering Systems)
- Görüntü Tanıma (Image Recognition)
- Robotlar (Robotics)
- Sesli Konuşmayı Yazıyla Çevirme (Text to Speech)
- Yazılıyı Sesli Konuşmaya Çevirme (Speech to Text)
- Sanal Gerçeklik Sistemleri (Virtual Reality Systems)

Yapay zekanın yukarıdaki uygulama alanlarından bazıları zaman içerisinde bazı kesimler tarafından artık yapay zekanın bir konusu olarak görülmemeye başlamıştır. Örneğin OCR işlemleri eskiden her kesim tarafından bir yapay

zeka faaliyeti olarak görüldü. Ancak zamanla OCR işlemleri o kadar bilindik ve rutin bir hale geldi ki artık bu işlemler geniş bir kesim tarafından bir yapay zeka faaliyeti olarak ele alınmıyor. Benzer biçimde satrançta bir büyük ustayı yenecek bir programın yazılması eskiden bir yapay zeka faaliyeti olarak görülmüşken artık bu faaliyet de bazı kesimler tarafından bir yapay zeka faaliyeti olarak ele alınmamaktadır. İşte zaman içerisinde yapay zeka olarak görülen bir süreci makineler algoritmik olarak başardıkça onun yapay zeka alanından çıkartılması gibi bir durum oluşmaya başlamıştır. Eskiden yapay zeka faaliyeti olarak adlandırılan bazı faaliyetlerin yapay zeka kapsamından çıkarılmasına "Yapay Zeka Etkisi (AI Effect)" denilmektedir. Günümüzde de yapay zeka faaliyeti olarak ele aldığımız bazı faaliyetlerin zamanla yapay zeka faaliyeti olmaktan çıkabileceğine de dikkatinizi çekmek istiyoruz.

Makine Öğrenmesi Nedir?

Aslında makine öğrenmesinin ne olduğundan önce öğrenmenin ne olduğunu ele almak gereklidir. Psikolojide öğrenme "davranışta görelî biçimde kalıcı değişiklikler oluşturan süreçler" biçiminde tanımlanmaktadır. Bu tanımdaki davranış (behavior) klasik davranışçılara göre "gözlemlenebilen devinimleri" kapsamaktadır. Ancak daha sonra "radikal davranışçılar" bu davranış tanımını zihinsel süreçleri de kapsayacak biçimde genişletmiştir.

Psikolojide öğrenme kabaca dört bölümde ele alınmaktadır.

1) Klasik Koşullanma (Classical Conditioning): Organizmada doğal bir tepki oluşturan uyaranlara "koşulsuz uyaranlar (unconditioned stimuli)", koşulsuz uyararlara karşı organizmanın verdiği tepkilere de "koşulsuz tepkiler (unconditioned responses)" denilmektedir. Örneğin "gök gürültüsü" koşulsuz uyarana, gök gürültüsüne karşı verilen tepki de koşulsuz tepkiye örnek verilebilir. İşte klasik koşullanmada başlangıçta organizmada bir tepkiye yol açmayan "nötr bir uyaran (neutral stimulus)" koşulsuz bir uyaranla (unconditioned stimulus) zamansal bakımdan eşleştirildiğinde artık bu nötr uyaran organizmada koşulsuz uyaranın oluşturduğu tepkiye benzer bir tepki oluşturmaya başlamaktadır. Nötr uyaranın zamanla koşulsuz uyaranla benzer tepkilere yol açması durumunda artık bu nötr uyarana "koşullu uyaran (conditioned stimulus)", organizmanın da bu koşullu uyarana verdiği tepkiye "koşullu tepki (conditioned response)" denilmektedir. Bu süreci şekilsel olarak aşağıdaki gibi ifade edebiliriz:

Koşulsuz Uyaran	--->	Koşulsuz Tepki	(Doğal Durum)
Nötr Uyaran	--->	Koşulsuz Uyaran	(Klasik Koşullanma Süreci)
Nötr Uyaran	--->	Koşulsuz Uyaran	(Klasik Koşullanma Süreci)
...	--->	...	(Klasik Koşullanma Süreci)

Nötr uyaran artık koşullu uyarana haline gelmiştir.

Koşullu Uyaran	--->	Koşullu Tepki	(Öğrenilmiş Yeni Durum)
----------------	------	---------------	-------------------------

Klasik koşullanma sürecinin gerçekleşmesi için önce nötr uyaranın sonra koşullu uyaranın zamansal bakımdan peş peşe uygulanması gerekmektedir. Burada iki uyaran arasındaki zaman uzarsa (örneğin 5 saniyeden büyük olursa) organizmanın onları ilişkilendirmesi güçleşmektedir. Pek çok çalışma 0.5 saniye civarındaki bir zaman aralığının klasik koşullanma için ideal bir zaman aralığı olduğunu göstermektedir.

Klasik koşullanma ilk kez Ivan Pavlov tarafından fark edilmiş ve tanımlanmıştır. Pavlov'un köpek deneyi klasik koşullanmaya tipik bir örnektir. Bu deneyde Pavlov köpeğe yemek gösterdiğinde (koşulsuz uyaran) köpek salya salgılamaktadır. Yemeği görünce köpeğin salya salgılaması doğal olan koşulsuz bir tepkidir. Daha sonra Pavlov köpeğe bir metronom sesinden (nötr uyaran) sonra yemeği göstermiş ve bu işlemi bir süre tekrarlamıştır. Bu süreç sonunda artık köpek yalnızca metronom sesini duyduğunda (artık nötr uyaran koşullu uyarana haline gelmiştir) salgı salyalar hale gelmiştir. Köpeğin metronom sesini duyduğunda salgı salgılaması daha önce yapmadığı koşullu bir tepkidir.

Klasik koşullanma süreci pek çok hayvan üzerinde denenmiştir. Hayvanların çok büyük çoğunluğu klasik koşullanma ile öğrenebilmektedir. Birinci kuşak davranışçılar pek çok davranışın nedenini klasik koşullanmayla açıklamışlardır.

Gerekten de fobilerin çoğunda klasik koşullanmanın etkili olduğu görülmektedir. Özellikle olumsuz birtakım sonuçlar doğuran uyaranlar çok kısa süre içerisinde klasik koşullanmaya yol açabilmektedir. Örneğin karanlık bir sokakta saldırıyla uğrayan bir kişi yeniden karanlık bir sokağa girdiğinde klasik koşullanma etkisiyle yeniden saldırıyla uğrayacağı hissine kapılabilmektedir.

2) Edimsel Koşullanma (Operant Conditioning): Edimsel koşullanma en önemli öğrenme yollarından biridir. Pek çok süreç edimsel koşullanma ile öğrenilmektedir. Klasik koşullanmada önce uyaran sonra tepki gelmektedir. Halbuki edimsel koşullanmada önce tepki sonra uyaran gelir. Organizma bir faaliyyette bulunur. Bunun sonucunda hoşa giden bir durum (buna ödül de denilmektedir) oluşursa bu davranış tekrarlanır ve böylece öğrenme gerçekleşir. Yani özetle organizmada hoşa giden sonuçlar doğuran davranışlar tekrarlanma eğilimindedir.

Edimsel koşullanma bir süreç olarak ilk kez Edward Thorndike tarafından fark edilmiştir. Thorndike "puzzle box" ismini verdiği bir kafes düzeneği ile yaptığı deneylerden "organizmada olumlu sonuçlar doğuran tepkilerin tekrarlanması eğiliminde olduğu" sonucunu çıkarmıştır ve bu durumu "etki yasası (law of effect)" terimiyle ifade etmiştir. Her ne kadar edimsel koşullanmayı gerçek anlamda ilk kez Thorndike fark ettiyse de bunu genişleterek kuramsal bir öğrenme modeli haline getiren asıl kişi B.F. Skinner olmuştur. Bu konuda kullanılan terminoloji de büyük ölçüde Skinner tarafından oluşturulmuştur.

Edimsel koşullanmada ödül oluşturan uyaranlara "pekiştireç (reinforcer)" denilmektedir. Davranış ne kadar pekiştirilirse o kadar iyi öğrenilmektedir. Pekiştireçler "pozitif" ve "negatif" olmak üzere ikiye ayrılırlar. Pozitif pekiştireçler doğrudan organizmanın hoşuna gidecek uyaranlardır. Negatif pekiştireçler ise organizmanın içinde bulunduğu hoş olmayan durumu ortadan kaldırarak dolaylı ödül oluşturan uyaranlardır. Edimsel koşullanma için bazı örnekler söyle verilebilir:

- Ödevini yapan öğrenciye öğretmenin ödül vermesi ödev yapma davranışını artırmaktadır (pozitif pekiştireç).
- Maddenin bunaltısı (anxiety) ortadan kaldırması kişiyi madde kullanımına teşvik etmektedir (negatif pekiştireç).
- Arabada emniyet kemeri bağlı değilken rahatsız edici bir ses çıkmaktadır. Bu sesi ortadan kaldırmak için sürücü ve yolcular emniyet kemeri bağlarlar (negatif pekiştireç).
- Ağlayan çocuğun isteklerini ebeveynin karşılaması istekleri karşılanmayan çocukta ağlama davranışını artırıbmektedir (pozitif pekiştireç).

Bugün psikolojide edimsel koşullanma davranışı değiştirmede ve şekillendirmede en önemli araçlardan biri olarak kabul edilmektedir.

3) Sosyal Bilişsel Öğrenme (Social Cognitive Learning): Bu yönteme "taklit yoluyla öğrenme" ya da model alarak öğrenme" de denilmektedir. Biz başkalarını taklit ederek de davranışlarımızı değiştirebilmekteyiz. Sosyal bilişsel öğrenme büyük ölçüde Albert Bandura tarafından kuramsal hale getirilmiştir. Aslında sosyal bilişsel öğrenmede de bir bakıma pekiştirmeler söz konusudur. Ancak bu pekiştirmeler doğrudan değil dolaylı (vicarious) biçimde olmaktadır. Sosyal bilişsel öğrenmede birtakım bilişsel süreçlerin de devreye girdiğine dikkat ediniz. Çünkü bu süreçte kişinin başkalarının yaptığı davranışları izleme, izlediklerini bellekte saklama ve onlardan sonuçlar çıkartma gibi süreçler de işin içine karışmaktadır.

4) Bilişsel Öğrenme (Cognitive Learning): Biliş (cognition) organizmanın bilgi işlem faaliyetlerini anlatan bir terimdir. Biliş denildiğinde düşünme, bellek, dikkat, bilinç, akıl yürütme gibi faaliyetler anlaşılmaktadır. Araştırmacılar hiç pekiştireç olmadan öğrenmenin hayvanlarda da insanlarda da mümkün olduğunu göstermişlerdir. Yani biz klasik koşullanma, edimsel koşullanma ve sosyal öğrenme süreçleri olmadan yalnızca bilişsel etkinliklerle de öğrenebilmektediriz.

Halk arasında öğrenme denildiğinde genellikle sürecin davranışsal boyutu göz ardı edilmekte yalnızca bilişsel tarafi değerlendirilmektedir. Halbuki her türlü öğrenmede açık ya da örtük görelî bir biçimde kalıcı bir davranışın ortaya çıkması beklenir. Ancak "davranış (behavior)" sözcüğünün tanımı konusunda da tam bir anlaşma bulunmamaktadır.

Yukarıda da belirttiğimiz gibi ilk davranışçılar yalnızca gözlemlenebilen süreçleri davranış olarak tanımlarken radikal davranışçılar zihinsel süreçleri de davranış tanımının içine katmaktadır.

O halde makine öğrenmesi (machine learning) nedir? Aslında psikolojideki öğrenme kavramı makine öğrenmesinde de geçerlidir. Biz makinenin (makine demekle donanımı ve yazılımı kastediyoruz) bir biçimde davranışını arzu edilen yönde değiştirmesini isteriz. Yani makinenin davranışını bizim istediğimiz yönde ve istediğimiz hedefleri gerçekleştirmeye anlamında değiştirmelidir. İşte makine öğrenmesi kabaca geçmiş bilgilerden ve deneyimlerden faydalı birtakım sonuçlar (davranışlar) ortaya çıkartan algoritmalar ve yöntemler topluluğudur. Makine öğrenmesinde üç bileşen vardır: Deneyim, Görev ve Performans. Deneyim canlılarda olduğu gibi makine öğrenmesinde de en önemli öğelerdir. Makine öğrenmesinde deneyim birtakım verilerin analiz edilmesini ve onlardan bir kestirim ya da faydalı sonuçlar çıkartılması sürecidir. Görev makinenin yapmasını istediğimiz şeydir. Görevler düşük bir deneyimle düşük bir performansa gerçekleştirilebilirler. Deneyim arttıkça görevin yerine getirilme performansı da artabilir. İşte makine öğrenmesi temelde bunu hedeflemektedir. O halde makine öğrenmesinde bir veri grubu incelenir, analiz edilir, bundan sonuçlar çıkarılır, sonra hedeflenen görev yerine getirilmeye çalışılır. Bu görevin yerine getirilmesi de gitgide iyileştirilir. Bu süreç çeşitli algoritmalarla ve yöntemlerle değişik biçimlerde ve yaklaşımalarla yürütülmektedir.

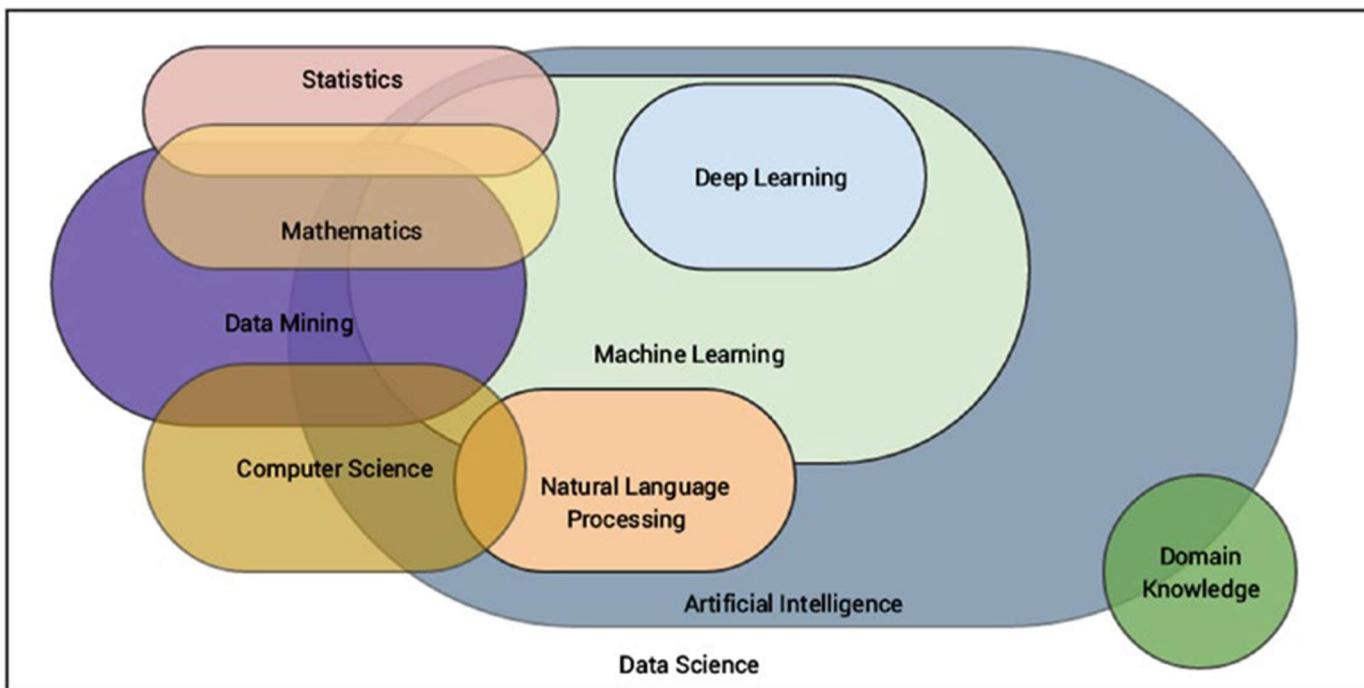
Makine öğrenmesi genel olarak üç bölümde ele alıp incelenmektedir:

- 1) Denetimli Öğrenme (Supervised Learning)
- 2) Denetimsiz Öğrenme (Unsupervised Learning)
- 3) Pekiştirmeli Öğrenme (Reinforcement Learning)

Denetimli (supervised) öğrenmede makineye (yani algoritmaya) biz daha önce gerçekleşmiş olan olayları ve sonuçları girdi olarak veririz. Makine bu olaylarla sonuçlar arasında bağlantı kurar. Daha sonra biz yeni bir olayı makineye verdığımızda onun sonucunu makineden kestirmesini isteriz. Denetimsiz öğrenmede biz makineye yalnızca olayları veririz. Makine bunların arasındaki benzerliklerden ve farklılıklardan hareketle bizim istediğimiz sonuçları çıkartmaya çalışır. Örneğin biz makineye resimler verip bunların elma mı armut mu olduğunu söyleyelim. Ve bunu çok miktarda yapalım. Sonra ona bir elma resmi verdığımızda o daha önceki deneyimlerden hareketle bunun elma olduğu sonucunu çıkartabilecektir. İşte bu denetimli öğrenmeye bir örnektir. Şimdi biz makineye elma ve armut resimlerini verelim ama bunların ne olduğunu ona söylemeyeelim. Ondan bu resimleri ortak özelliklerine göre iki gruba ayırmamasını isteyelim. Bu da denetimsiz öğrenmeye örnektir. Pekiştirmeli öğrenmede ise tıpkı edimsel koşullanmada olduğu gibi hedefe yaklaşan durumlar ödüllendirilerek makinenin öğrenmesi sağlanmaktadır.

Yapay Zeka ve Makine Öğrenmesinin Diğer Disiplinlerle İlgisi

Yapay zeka alanın diğer pek çok disiplinle yakın ilgisi vardır. Aşağıdaki şekilde bu ilgi betimlenmektedir.



Alıntı Notu: Görsel "Practical Machine Learning with Python (APress)" kitabından alınmıştır.

İstatistik: İstatistik temelde iki bölüme ayrılmaktadır:

- Betimsel istatistik (descriptive statistics)
- Sonuç çıkartıcı istatistik (inferential statistics)

Betimsel istatistik verilerin gruplanması, özetlenmesi, karakteristiklerinin betimlenmesi ve gösterilmesi ile ilgilidir. Yani betimleyici istatistik zaten var olan durumu betimlemektedir. Sonuç çıkartıcı istatistik ise kestirim yapmakla ilgilidir. Makine öğrenmesi istatistiğin kestirimsel yöntemlerini açıkça kullanmaktadır. Örneğin regresyon analizi, kümeleme analizi, karar ağaçları, faktör analizi vs. gibi pek çok makine öğrenmesi yöntemi aslında istatistiğin bir konusu olarak ortaya çıkmıştır. Ancak bu istatistiksel yöntemler makine öğrenmesi temelinde genişletilmiş ve dinamik bir biçimde dönüştürülmüştür.

Veri Madenciliği (Data Mining): Veri madenciliği verilerin içerisindeki çeşitli faydalı bilgilerin bulunması, onların çekilerek elde edilmesi işlemleriyle ilgilenmektedir. Şüphesiz bu süreç istatistiksel birtakım bilgilerin yanı sıra yazılımsal uygulamaları da bünyesinde barındırmaktadır.

Bilgisayar Bilimleri (Computer Science): Bilgi işlem ve programlama etkinlikleriyle ilgili geniş kapsamlı bir bilim dalıdır. Bilgisayar bilimlerindeki teknikler ve yöntemler kullanılmadan makine öğrenmesi uygulamaları gerçekleştirilememektedir.

İlgili Konudaki Özel Bilgiler: Şüphesiz her türlü algoritmik yöntem için bir biçimde hedeflenen konuda belli bir bilgi birikiminin var olması gereklidir. Örneğin ne kadar iyi programlama ve istatistik bilirseniz bilin görüntüselleştermek için bir görüntünün (resmin) nasıl bir organizasyona sahip olduğunu bilmeniz gereklidir. Ya da örneğin hiç muhasebe bilmeyen iyi bir programcının bir muhasebe programı yazabilmesini bekleyebilir miyiz?

Makine Öğrenmesi Uygulamaları İçin Kullanılan Programlama Dilleri

Veri bilimi (data science) ve makine öğrenmesi uygulamaları için pek çok dil kullanılabilmektedir. Bu bağlamda ilk akla gelen dil şüphesiz Python'dur. Ancak C++, Java, C# gibi popüler programlama dilleri de bu amaçla gittikçe daha fazla kullanılır hale gelmektedir. Python programlama dili son on yıldır bir atak yaparak dünyanın en popüler ilk üç dili arasına girmiştir. Python dilinin özellikle veri bilimi ve makine öğrenmesi konusunda popüleritesinin neden bu kadar arttığını ilişkin görüşlerimiz şöyledir:

- Son yıllarda veri işleme ve verilerden kestirim yapma gereksiniminin gittikçe artmıştır ve Python dili de veri analizi için iyi bir araç olarak düşünülmektedir.
- Veri bilimi ve makine öğrenmesi için Python dilinden kullanılabilecek pek çok kütüphane vardır. (Bu konudaki kütüphaneler diğer dillerden -şimdilik- daha fazladır.)
- Python nispeten basit bir dildir. Bu basitlik ana hatları veri analizi olan konularda uygulamacılara kolaylıklar sunmaktadır. Bu nedenle Python diğer disiplinlerden gelip de veri analizi ve makine öğrenmesi uygulaması yapmak isteyenler için nispeten daha kolay bir araç durumundadır.
- Python genel amaçlı bir programlama dili olmasının yanı sıra aynı zamanda matematiksel alana da yakın bir programlama dilidir. Yani Python'un matematiksel alana yönelik ifade gücü (expressivity) popüler diğer programlama dillerinden daha yüksektir.
- Python dilinin çeşitli prestijli üniversitelerde "programlamaya giriş (introduction to programming)" gibi derslerde kullanılmaya başlanmış olması onun popüleritesini artırmıştır. Ayrıca Python özellikle 3'lü versiyonlarla birlikte dikkate değer biçimde iyileştirilmiştir.
- Python dilinin veri analizi için diğer dillere göre daha erken yola çıktığı söylenebilir. Bu alanda algoritma geliştiren araştırmacılar algoritmalarını daha çok Python kullanarak gerçekleştirmiştir.

Pekiyi Python dilinin veri analizi ve makine öğrenmesi konusunda hangi dezavantajları vardır? Bu dezavantajları da şöyle sıralayabiliriz:

- Python nispeten yavaş bir dildir. Bu yavaşlık büyük ölçüde Python dilinin dinamik tür sistemine sahip olmasından, Python programlarının yorumlayıcı yoluyla çalıştırılmasından ve dilin seviyesinin yüksek olmasından kaynaklanmaktadır. Her ne kadar veri analizi ve makine öğrenmesinde kullanılan kütüphaneler (NumPy, Pandas, SciPy, Keras gibi) asıl olarak C programlama dili ile yazılmış olsalar da bu C rutinlerinin Python'dan çağrılması ve diğer birtakım işlemler yavaşlığa yol açmaktadır.
- Python yüksek seviyeli bir dil olduğu için dilin olanakları ince birtakım işlemlerin yapılabilmesine olanak sağlamamaktadır.

Pekiyi Python genel olarak yavaş bir dilse bu durum veri analizi ve makine öğrenmesi uygulamalarında bir sorun oluşturur mı? Bizim yanıtımız "bazı durumlarda" olacaktır.

<Diğer Alternatifler Hakkında Daha Fazla Bilgi>

Veri Bilimi (Data Science) Nedir?

Bilgisayar teknolojisinin gelişmesine paralel olarak veri toplama ve depolama olanaklarının artmasıyla birlikte veri analizinde yeni bir dönemin başladığı söylenebilir. Özellikle 2000'li yıllarda itibaren insanlık eskiden olduğundan çok daha fazla miktarda veriyle karşılaşmıştır. Bu bakımından insanlığının bir veri bombardımanına maruz kaldığı söylenebilir. İşte "veri bilimi (data science)" 2000'li yılların başlarında böyle bir bağlamda kullanılmaya başlanmış bir terimdir. Veri biliminin tanımı konusunda tam bir fikir birliği bulunmamaktadır. Ancak veri bilimi "verilerden birtakım faydalı bilgilerin ve içgörülerin (insights) elde edilmesine yönelik çalışmaların yapıldığı" bir alan olarak tanımlanabilir. Veri bilimi ile uğraşan uygulamacılara "veri bilimcisi (data scientist)" denilmektedir. (Bu bağlamda veri bilimcisinin bir bilim insanı gibi ele alınmadığını vurgulamak istiyoruz.)

Aslında veri bilimi istatistik biliminin uygulamalı ve dinamik bir alt alanı gibi de düşünülebilir. Bazı bilim adamlarına göre "veri bilimi" terimi gereksiz uydurulmuş bir terimdir ve aslında bu alan "uygulamalı istatistikten" başka bir şey değildir. Ancak ne olursa olsun son 30 senedir verilerin ele alınma biçimi, verilerin işlenmesi ve bunlardan faydalı birtakım sonuçların çıkarılması için yapılan işlemler de klasik istatistiksel çalışma ile örtüşmemektedir. Veri bilimi

terimi -bazı çevreler tarafından eleştiriliyor olsa da- kendini kabul ettirmiş ve yaygınlık kazanmış bir terim gibi görülmektedir.

İstatistik ile veri bilimi arasındaki farklılıklarını birkaç cümleyle şöyle özetleyebiliriz: Veri bilimi klasik istatistikten farklı olarak disiplinler arası bir niteliğe sahiptir. Veri bilimi yazılımı çok daha yoğun kullanmaktadır. Veri bilimi örneklemelerden ziyade çok daha büyük verilerle uğraşma eğilimindedir. İstatistiksel çalışmalar daha çok hipotezleri doğrulamaya odaklanırken veri bilimi daha çok faydalı hipotezler oluşturmaya odaklanmıştır.

İSTATİSTİĞE İLİŞKİN BAZI TEMEL BİLGİLER

Yapay zeka ve özellikle de makine öğrenmesi ile ilgili çalışmalar yapacak kişilerin belli düzeyde istatistiksel bilgilere sahip olması gerekmektedir. Şüphesiz istatistik pek çok alt alanı olan geniş bir bilim dalıdır. Bu nedenle istatistiksel konulara ilişkin pek çok ayrıntı vardır. Biz bu bölümde temel bilgiler vermekle yetineceğiz. Çeşitli ayrıntılar ilgili konuların anlatıldığı bölümde gereğinde açıklanacaktır. (Örneğin "kümeleme analizi (cluster analysis)" aslında istatistikte çok uzun süredir incelenen bir konudur. Ancak son yıllarda makine öğrenmesi bağlamında konunun önemi çok daha fazla artmış ve bu bağlamda pek çok algoritmik yöntem geliştirilmiştir. Dolayısıyla örneğin kümeleme analizi çok değişkenli istatistiğin bir konusu olduğu halde biz bu tekninin ayrıntılarını "denetimsiz öğrenme (unsupervised learning)" içerisinde ele alacağız.)

İstatistiksel Ölçek Türleri

İstatistikte ölçülen ya da ölçülmüş olan değerlerin sınıflarına genel olarak "ölçek (scale)" denilmektedir. Pek çok kişi ölçeklerin yalnızca sayısal olduğunu sanmaktadır. Halbuki ölçekler başka biçimlerde de karşımıza çıkabilmektedir. İstatistikte ölçekler tipik olarak dört sınıfa ayrılmaktadır:

Kategorik (Nominal) Ölçekler: Bu ölçeklerde söz konusu kümenin elemanları kategorik olgulardır. Örneğin cinsiyet, renk, coğrafi bölge gibi. Bu ölçekteki ölçülen ya da ifade edilen değerlerin sayısal karşılıkları yoktur. Örneğin "kadınlarla erkekler arasında sigara içme miktarı arasında anlamlı bir fark olup olmadığını" anlamak için gerçekleştirilen bir araştırmada ölçülmesi istenen değişkenlerden "cinsiyet" kategorik (nominal) bir ölçüye ilişkindir. Benzer biçimde kişilerin renk tercihleriyle ilgili bir araştırmada renkler (siyah, beyaz, kırmızı gibi) kategorik bir ölçekle ifade edilirler.

Sırasal (Ordinal) Ölçekler: Bu ölçeklerdeki değerler de birer kategori belirtmekle birlikte bu kategoriler arasında büyüklik-küçüklik ilişkisi söz konusudur. Örneğin eğitim durumu için kategorik değerler "ilköğretim", "lise", "üniversite" olabilir ve bunlar arasında sıra ilişkisi vardır. Bu nedenle "eğitim durumu" bir sıralı ölçek belirtmektedir.

Aralıklı (Interval) Ölçekler: Aralıklı ölçekler sayısal bilgi içerirler. Bu tür ölçeklerde iki puan arasındaki fark aynı miktar uzaklığı ya da yakınlığı ifade eder. Örneğin bir testte 20 puan alan 10 puan alandan beli miktarda daha iyidir. 30 puan alan da 20 puan alandan aynı miktar kadar daha iyidir. Bu tür ölçeklerde mutlak sıfır noktası yoktur. Başka bir deyişle bu tür ölçeklerde "sıfır" yokluğu ya da mevcut olmamayı belirtmemektedir. Alınan puanlar her zaman belli bir göreli orijine göre anlamlıdır. Örneğin aslında sınavlardan alınan puanlar böyle bir ölçek türündedir. Sınavdan sıfır alınabilir. Ancak bu sıfır o kişinin o konu hakkında hiçbir şey bilmediği anlamına gelmez. Yani mutlak sıfır değildir. Ya da örneğin ısı belirten "derece (celcius)" bir aralıklı ölçüği belirtmektedir. 50 derece ile 40 derece arasındaki ısı farkı 40 derece ile 30 derece arasındaki fark kadardır ancak sıfır derece isının olmadığı anlamına gelmez.

Oransal (Ratio) Ölçekler: Bu ölçekler de sayısal bilgi içerirler. Oransal ölçekler aralık ölçeklerin tüm özelliklerine sahiptirler. Ancak ek olarak oransal ölçeklerde mutlak bir sıfır noktası da vardır. Dolayısıyla puanlar arasındaki oranlar mutlak olarak anlamlıdır. Örneğin uzunluk, kütle gibi temel fiziksel özellikler oransal ölçek türlerindendir. Bir nesnenin uzunluğunun sıfır olması onun uzunluğunun olmadığı, kütlesinin sıfır olması da onun kütlesinin olmadığı anlamına gelmektedir.

Provides:	Nominal	Ordinal	Interval	Ratio
The "order" of values is known		✓	✓	✓
"Counts," aka "Frequency of Distribution"	✓	✓	✓	✓
Mode	✓	✓	✓	✓
Median		✓	✓	✓
Mean			✓	✓
Can quantify the difference between each value			✓	✓
Can add or subtract values			✓	✓
Can multiple and divide values				✓
Has "true zero"				✓

Summary of data types and scale measures

Akıntı Notu: Görsel <https://www.mymarketresearchmethods.com/wp-content/uploads/2016/05/summary-of-data-types-and-scales.png> adresinden alınmıştır.

Aritmetik Ortalama, Medyan, Mod, Standart Sapma ve Varyans Kavramları

Betimsel istatistikte bir grup veri için çeşitli ortalama hesaplama yöntemleri kullanılabilir. Bu yöntemlere "merkezi eğilim ölçütleri (measures of central tendency)" denilmektedir. En çok kullanılan merkezi eğilim ölçüsü aritmetik ortalamadır. Aritmetik ortalama değerlerin toplamının değer sayısına bölünmesiyle elde edilmektedir:

$$\bar{X} = \frac{\sum_{i=1}^n X_i}{N} = \frac{X_1 + X_2 + X_3 + \dots + X_n}{N}$$

Artimetik ortalamanın $O(n)$ karmaşıklıkta hesaplanabildiğine dikkat ediniz. Aritmetik ortalama için Python'da statistics modülü içerisindeki mean fonksiyonu bulundurulmuştur. mean fonksiyonu dolaşılabilir herhangi bir nesneyi parametre olarak alabilmektedir. Örneğin:

In [13]: `import statistics`

In [14]: `a = [3, 6, 2, 8, 5]`

In [15]: `statistics.mean(a)`

Out[15]: 4.8

Ancak NumPy içerisindeki mean fonksiyonu daha fazla olanaklılara sahiptir. Örneğin:

In [16]: `import numpy as np`

In [17]: `a = np.array([3, 6, 2, 8, 5])`

In [18]: `np.mean(a)`

Out[18]: 4.8

mean fonksiyonunda eğer axis parametresi girilmezse NumPy dizisindeki bütün elemanların ortalaması hesaplanmaktadır. Ancak axis=0 parametresi ile sütun temelinde, axis=1 parametresi ile satır temelinde ortalamalar elde edilebilmektedir. Örneğin:

```
In [19]: a = np.array([[1, 2, 3], [4, 5, 6], [7, 8, 9]])
```

```
In [20]: np.mean(a)
```

```
Out[20]: 5.0
```

```
In [21]: np.mean(a, axis=0)
```

```
Out[21]: array([4., 5., 6.])
```

```
In [22]: np.mean(a, axis=1)
```

```
Out[22]: array([2., 5., 8.])
```

Pandas kütüphanesinde aritmetik ortalama için Series ve DataFrame sınıflarının mean metotları kullanılmaktadır. Örneğin:

```
In [26]: df = pd.DataFrame([[1, 2, 3], [4, 5, 6], [7, 8, 9]])
```

```
In [27]: df.mean()
```

```
Out[27]:
```

```
0    4.0  
1    5.0  
2    6.0
```

```
dtype: float64
```

```
In [28]: df.mean(axis=1)
```

```
Out[28]:
```

```
0    2.0  
1    5.0  
2    8.0
```

```
dtype: float64
```

DataFrame sınıfında da axis parametresinin olduğuna dikkat ediniz. Burada axis belirtilmezse default durum axis=0 biçimindedir. Yani sütunsal işlem yapılmaktadır.

Aritmetik ortalama ancak sıralı (ordinal) ya da oransal (ratio) ölçekler için kullanılabilir. Aritmetik ortalamaların üç değerlerden çok etkilenebileceğine dikkat ediniz. Bu nedenle bazı durumlarda merkezi eğilim ölçüsü olarak aritmetik ortalama yerine medyan değeri de tercih edilebilmektedir. Medyan küçükten büyüğe sıraya dizilmiş değerlerin ortasında bulunan değere denilmektedir. Eleman sayısı çift ise medyan değeri ortadaki iki elemanın toplamının yarısı ile hesaplanmaktadır.

Medyan işlemi için Python standart kütüphanesinde median fonksiyonu bulundurulmuştur. Bu fonksiyon herhangi bir dolaşılabılır (iterable) nesneyi parametre olarak alabilmektedir. Örneğin:

```
In [29]: a = [1, 5, 9, 2, 7]
```

```
In [30]: statistics.median(a)
```

```
Out[30]: 5
```

```
In [31]: a = [1, 5, 9, 2, 7, 10]
```

```
In [32]: statistics.median(a)
```

```
Out[32]: 6.0
```

NumPy kütüphanesinde de medyan işlemi için median isimli fonksiyon bulunmaktadır. Fonksiyonda axis belirtilmezse medyan hesabı dizideki tüm değerler dikkate alınarak yapılır. Yine axis=0 parametresi ile sütun temelinde, axis=1 parametresi ile de satır temelinde medyan hesabı yapılabilmektedir. Örneğin:

```
In [35]: a = np.array([[1, 5, 9, 4], [3, 8, 4, 7], [4, 9, 3, 8]])
```

```
In [36]: np.median(a)
```

```
Out[36]: 4.5
```

```
In [37]: np.median(a, axis=0)
```

```
Out[37]: array([3., 8., 4., 7.])
```

```
In [38]: np.median(a, axis=1)
```

```
Out[38]: array([4.5, 5.5, 6. ])
```

Medyan işlemi Pandas kütüphanesinde de Series ve DataFrame sınıflarının median metotları ile yapılmaktadır. Örneğin:

```
In [41]: df = pd.DataFrame([[1, 5, 9, 4], [3, 8, 4, 7], [4, 9, 3, 8]])
```

```
In [42]: df.median()
```

```
Out[42]:
```

```
0    3.0  
1    8.0  
2    4.0  
3    7.0  
dtype: float64
```

```
In [43]: df.median(axis=1)
```

```
Out[43]:
```

```
0    4.5  
1    5.5  
2    6.0  
dtype: float64
```

Pekiyi merkezi eğilim ölçüsü olarak aritmetik ortalama ile medyan arasında nasıl bir farklılık vardır? Aritmetik ortalamada tüm değerlerin işlemde etkili olduğuna ancak medyanda etkili olmadığına dikkat ediniz. Dağılım içerisindeki en büyük değeri daha da büyütsek bunun medyan hesabına bir etkisi olabilir mi? Ayrıca aritmetik ortalamanın üç değerlerden çok etkilenebildiğini ancak medyanın etkilenmediğini de belirtmek istiyoruz. Medyan işlemi sıraya dizme gerektirdiği için algoritma ancak $O(n \log n)$ karmaşıklıkta gerçekleştirilebilmektedir. Halbuki aritmetik ortalama $O(n)$ karmaşıklıkta hesaplanabilmektedir. Medyanın da sıralı, aralıklı ve oransal ölçekteki bilgilere uyarlanabileceğine dikkat ediniz.

Bir dağılımin modu en çok yinelenen değeri belirtir. Mod özellikle kategorik ve sıralı ölçeklerde ortalamanın yerini tutan bir işlem olarak kullanılmaktadır. Mod işlemi özel durumlarda $O(n)$ karmaşıklıkta genel olarak ise $O(n \log n)$ karmaşıklıkta yapılmaktadır. (Mod işlemi hash tabloları kullanılarak büyük dizilerde $O(n)$ karmaşıklıkta yapılmaktadır. Ancak hash tablolarının da $O(n)$ karmaşıklıkta bir ek alana gereksinim duyacağına dikkat ediniz. Klasik yöntem diziyi $O(n \log n)$ karmaşıklıkta sıraya dizip aynı değerdeki yan yana elemanların sayısına bilmaktır.)

Mod değeri Python standart kütüphanesindeki statistics modülü içerisindeki mode fonksiyonuyla elde edilebilmektedir. Örneğin:

```
In [4]: a = [3, 5, 7, 3, 8, 150, 4, 7, 1, 7]
```

```
In [5]: statistics.mode(a)
```

```
Out[5]: 7
```

mode fonksiyonu yine herhangi bir dolaşılabilir nesneyi parametre olarak alabilmektedir. Eğer dolaşılabilir nesne içerisinde en çok yinelenen değerler birden fazla ise mode fonksiyonu bunlardan ilk karşılaştığı değeri bize vermektedir. Eşit sayıda tüm yinelenen mod değerlerini elde etmek için multimode fonksiyonu bulundurulmuştur. Örneğin:

```
In [6]: a = [1, 2, 2, 1, 3, 3, 6, 8, 6]
```

```
In [7]: statistics.multimode(a)
```

```
Out[7]: [1, 2, 3, 6]
```

NumPy kütüphanesinde mode işlemi için hazır bir fonksiyon bulunmamaktadır. Ancak SciPy kütüphanesindeki stats modülünde mode fonksiyonu vardır. Bu fonksiyon axis parametresi de alarak mode işlemi yapar. Fonksiyon ModeResult türünden bir sınıf nesnesine geri dönmektedir. Sınıfın mode özniteliği mod değerlerini, count özniteliği ise onların sayılarını vermektedir. Örneğin:

```
import numpy as np
import scipy.stats

a = np.random.randint(0, 10, (10, 10))
print(a)

mr = scipy.stats.mode(a, axis=0)
print()
print(mr.mode)
print(mr.count)
```

Programdan şöyle bir çıktı elde edilmiştir:

```
[[0 0 8 7 0 3 5 9 4 6]
 [4 4 9 0 3 5 0 2 7 3]
 [6 1 7 1 4 4 4 9 4 0]
 [5 4 3 6 7 5 2 7 6 0]
 [6 6 7 5 7 1 7 3 7 1]
 [1 3 5 2 4 4 5 7 7 4]
 [2 3 9 3 8 0 6 9 3 7]
 [9 0 5 5 3 1 6 5 4 1]
 [3 2 2 7 0 8 1 5 0 1]
 [2 0 4 1 1 6 7 7 3 2]]

[[2 0 5 1 0 1 5 7 4 1]]
[[2 3 2 2 2 2 3 3 3]]
```

Eksen içerisinde birden fazla aynı değer varsa mod olarak fonksiyon en küçük değeri vermektedir. Örneğin:

```
import numpy as np
import scipy.stats

a = np.random.choice(['A', 'B', 'C', 'D', 'E'], (10, 10))
mr = scipy.stats.mode(a)
print(a)
print()
print(mr.mode)
print(mr.count)
```

Şöyledir bir çıktı elde edilmiştir:

```
[['D', 'E', 'E', 'E', 'B', 'E', 'C', 'B', 'E', 'A']
 ['B', 'E', 'B', 'E', 'B', 'D', 'A', 'E', 'B', 'B']
 ['D', 'D', 'E', 'D', 'D', 'C', 'D', 'B', 'D', 'A']
 ['E', 'C', 'E', 'E', 'A', 'E', 'A', 'E', 'A', 'C']
 ['C', 'A', 'D', 'B', 'A', 'E', 'A', 'B', 'E', 'E']
 ['D', 'D', 'B', 'D', 'C', 'E', 'A', 'A', 'D', 'C']
 ['E', 'B', 'C', 'D', 'E', 'C', 'D', 'C', 'B', 'C']
 ['D', 'D', 'B', 'D', 'C', 'A', 'B', 'C', 'B', 'D']
 ['A', 'A', 'D', 'D', 'A', 'D', 'B', 'E', 'E', 'E']
 ['D', 'E', 'B', 'A', 'E', 'E', 'C', 'E', 'B', 'B']]
[[['D', 'D', 'B', 'D', 'A', 'E', 'A', 'E', 'B', 'C']]
 [[5, 3, 4, 5, 3, 5, 4, 4, 4, 3]]]
```

Aritmetik ortalama, medyan ve mod değerlerine "merkezi eğilim ölçütleri (measures of central tendency)" denilmektedir. Bu değerler dağılımın merkezine yönelik bilgileri bize verir. Bunların dışında ayrıca değerlerin merkezden ne kadar uzaklıkta konumlandığı da önemli bir bilgidir. Bu bilgiyi veren değerlere ise "merkezi yayılım ölçütleri (measures of dispersion)" denilmektedir. Örneğin bir ülkede kişi başına düşen milli gelir ortalamasının 10000 dolar olduğunu varsayıyalım. Bu ortalama herkesin eline yılda 10000 dolar geçtiği anlamına gelmez değil mi? Bu ülkede gelirler birbirlerine yakın da olabilir gelir dağılımında büyük bir adaletsizlik de olabilir.

Merkezi yayılım ölçütleri "ortalamadan ortalama uzaklığını hesap etme" temeline dayanmaktadır. Ancak bu hesabı yaparken dikkat etmek gereklidir. Örneğin eğer değerleri ortalamadan çıkartıp toplamlarının ortalamasını alırsak 0 elde ederiz. Bu da bize bir bilgi vermez. Örneğin:

```
In [8]: a = np.array([1, 0, 4, 3, 3, 8, 2, 5, 1, 2, 7, 7, 3, 2, 7, 8, 2, 1, 0])
```

```
In [9]: np.mean(np.mean(a) - a)
```

```
Out[9]: 1.7763568394002506e-16
```

Sonuç 0'a çok yakındır. Yuvarlama hatasından dolayı 0 olamamıştır. Şimdi akılınızda mutlak değer almak gelebilir. Örneğin:

```
In [12]: a = np.array([1, 0, 4, 3, 3, 8, 2, 5, 1, 2, 7, 7, 3, 2, 7, 8, 2, 1, 0])
```

```
In [13]: np.mean(np.abs(np.mean(a) - a))
```

```
Out[13]: 2.1850000000000005
```

Gördüğünüz gibi ortalamaya yakınlık konusunda daha iyi bir ölçü elde etmiş olduk. Ancak ortalama mutlak değer yöntemi de aslında ortalamaya uzaklık hesabı için çok iyi bir yöntem değildir. Özellikle normal dağılımda bu yöntem bizi amacımızdan saptırabilir. Ayrıca ortalama mutlak değeri aynı olan birden fazla dağılım söz konusu olduğunda bunların aralarındaki farklılıklar da bu yöntemde iyi açığa çıkartılamamaktadır. İşte bu nedenle merkezi yayılım ölçüsü olarak genellikle "standart sapma (standard deviation)" kullanılmaktadır. Standart sapmada kare alma işlemi değerleri daha fazla farklılaştırılmaktadır.

Bir dağılımın standart sapması değerlerin ortalamadan farklarının karelerinin ortalamasının karekökü alınarak hesaplanır. Değerlerin sayısı N olmak üzere ortalama alınırken anakütle için N değerine örneklem için N - 1 değerine bölüm kullanılmaktadır:

$$\sigma = \sqrt{\frac{\sum(X_i - \bar{X})^2}{N}}$$

Anakütle standart sapmasının sigma simbolüyle gösterildiğine dikkat ediniz. Bir anakütleden çekilen örnek söz konusuysa bölme işlemi N'e değil N - 1'e yapılmaktadır:

$$s = \sqrt{\frac{\sum(X_i - \bar{X})^2}{N - 1}}$$

Örnek için N - 1 değerine bölmeye "Bessel düzeltmesi (Bessel's correction)" denilmektedir. Bessel düzeltmesinin anlamı üzerinde burada durmayacağız. Bunun için Internet'te pek çok kaynak bulabilirsiniz. Düzeltmedeki N - 1 değerine "serbestlik derecesi (degrees of freedom)" de denilmektedir. Şimdi standart sapma için basit bir fonksiyon yazalım:

```
import numpy as np

def stdev(a):
    return np.sqrt(np.sum((a - np.mean(a)) ** 2) / len(a))
```

Tabii aslında Python statistics modülündeki pstdev (buradaki p "population" sözcüğünden geliyor) fonksiyonu anakütle için standart sapma hesabı yapmaktadır. Eğer örneklem standart sapması hesaplanacaksa (yani N - 1 değerine bölme isteniyorsa) bu durumda stdev fonksiyonu kullanılmalıdır. pstdev ve stdev fonksiyonlarına argüman olarak dolaşılabilir nesneler verilebilmektedir. Örneğin:

```
In [18]: statistics.pstdev(a)
Out[18]: 1.4142135623730951
```

```
In [19]: statistics.stdev(a)
Out[19]: 1.5811388300841898
```

NumPy kütüphanesindeki std fonksiyonu axis parametresi de alarak standart sapmayı hesaplamaktadır. Fonksiyonun ddof (delta degrees of freedom) parametresi "N - bölünecek değeri" belirtir. Bu parametrenin default değeri 0'dır. Yani bölüm N değerine (anakütle standart sapması) yapılmaktadır. Örneğin:

```
In [2]: a = np.random.randint(0, 100, (10, 10))
```

```
In [3]: a
Out[3]:
array([[57, 86, 54, 2, 53, 33, 78, 65, 89, 6],
       [96, 2, 24, 25, 42, 57, 70, 36, 63, 56],
       [93, 20, 61, 88, 18, 90, 8, 81, 90, 67],
       [6, 1, 5, 7, 27, 45, 72, 4, 19, 57],
       [76, 96, 97, 81, 81, 69, 51, 48, 34, 90],
       [35, 2, 28, 31, 17, 3, 65, 5, 60, 97],
       [20, 95, 46, 13, 18, 59, 45, 35, 97, 50],
       [3, 28, 92, 53, 23, 82, 1, 30, 71, 64],
       [31, 19, 7, 75, 26, 24, 24, 44, 27, 71],
       [74, 54, 98, 74, 43, 78, 41, 71, 74, 28]])
```

```
In [4]: np.std(a, axis=1)
Out[4]:
array([28.94149271, 25.59472602, 31.94745686, 24.02103245, 20.42571908,
       29.60760038, 27.9742739 , 30.62041802, 21.02284472, 20.16060515])
```

Pandas kütüphanesinde Series ve DataFrame sınıflarının da std metotları vardır. Bu metodların ddof parametrelerinin default değeri 1'dir (yani bu metodlar default durumda örnek standart sapmasını hesaplamaktadır). Örneğin:

```
In [6]: s = pd.Series([1, 2, 3, 4, 5])
```

```
In [7]: s.std()
Out[7]: 1.5811388300841898
```

```
In [8]: df = pd.DataFrame(np.random.randint(0, 100, (10, 10)))
```

```
In [9]: df
```

```
Out[9]:
```

```
   0   1   2   3   4   5   6   7   8   9  
0  54  40  4   9  48  92  2   92  48  66  
1  31  1   71  91  70  32  39  64  54  52  
2  97  32  91  32  55  73  61  32  56  20  
3  12  54  51  59  12  17  28  93  12  97  
4  28  25  92  8   37  95  19  59  99  36  
5  32  32  73  12  56  94  42  25  64  55  
6  96  49  56  90  48  24  30  35  26  55  
7  75  87  14  6   15  68  34  32  98  37  
8  70  43  20  35  0   34  78  2   9   65  
9  69  98  20  41  85  20  59  91  54  13
```

```
In [10]: df.std()
```

```
Out[10]:
```

```
0    29.684264  
1    28.598563  
2    32.757696  
3    32.400446  
4    26.841924  
5    32.630763  
6    22.134940  
7    32.163644  
8    30.973107  
9    24.441313  
dtype: float64
```

```
In [11]: df.std(axis=1)
```

```
Out[11]:
```

```
0    33.009258  
1    25.695871  
2    26.316239  
3    32.725288  
4    34.107021  
5    24.676800  
6    25.057489  
7    32.850503  
8    28.383094  
9    31.034031  
dtype: float64
```

Standart sapmanın karesine varyans denilmektedir. Varyans işlemi Python standart kütüphanelerindeki statistics modülündeki pvariance ve variance fonksiyonlarıyla, NumPy kütüphanesindeki var fonksiyonuyla, Pandas kütüphanelerindeki Series ve DataFrame sınıflarının var metotlarıyla yapılabilmektedir. Örneğin:

```

In [16]: a = np.array([1, 2, 3, 4, 5])
In [17]: statistics.pvariance(a)
Out[17]: 2
In [18]: np.var(a)
Out[18]: 2.0
In [19]: s = pd.Series(a)
In [20]: s.var()
Out[20]: 2.5
In [21]: b = np.random.randint(0, 10, (10, 10))
In [22]: df = pd.DataFrame(b)
In [23]: df.var()
Out[23]:
0    7.211111
1    5.788889
2   10.488889
3    9.655556
4    7.377778
5   14.266667
6    9.066667
7   10.044444
8    8.622222
9    7.155556
dtype: float64
In [27]: np.var(b, axis=0, ddof=1)
Out[27]:
array([ 7.21111111,  5.78888889, 10.48888889,  9.65555556,  7.37777778,
       14.26666667,  9.06666667, 10.04444444,  8.62222222,  7.15555556])

```

Olasılık Kavramı

Bir olsunun gerçekleşme bekentisini anlatan olaslığın pek çok tanımı yapılmaktadır. Bir paranın atılması durumunda tura gelme olaslığının 0.5 (%50) olduğunu biliriz. Ancak bir parayı 10 kez attığımızda 5 kere tura geleceğinin bir garantisini yoktur. O halde neden paranın atılması tura gelme olasılığı 0.5'tir? İşte olaslığın en yaygın kullanılan tanımlarından biri "göreli sıklık (relative frequency)" tanımıdır. Paranın atılması gibi bir rassal olay n defa yinelendiğinde ve bu n sayısı artırıldığında "tura gelme sayısı / n " değeri gittikçe 0.5'e yakınsayacaktır. Para 1000000 kere atıldığından yine yazı ile tura gelme sayısı aynı olmaz. Ancak tura gelme oranı gitgide 0.5'e yakınsar. O halde biz bir paranın atılması durumunda tura gelme olaslığının 0.5 olması demekle aslında bir limit durumunu kastetmiş olmaktadır.

Aşağıda 0 ile 1 arasında rastgele sayı üretecek yazı-tura atan örnek bir fonksiyon görüyorsunuz:

```

import random

def head_tail(n):
    head = 0
    for _ in range(n):
        head += random.randint(0, 1)      # tail = 0, head = 1
    return head / n

```

Fonksiyonun parametresi paranın kaç kere atılacağını belirtmektedir. Şimdi çeşitli denemeler yapalım:

```
In [46]: head_tail(1)
```

```
Out[46]: 1.0
```

```
In [47]: head_tail(10)
```

```
Out[47]: 0.5
```

```
In [48]: head_tail(100)
```

```
Out[48]: 0.45
```

```
In [49]: head_tail(1000)
```

```
Out[49]: 0.492
```

```
In [50]: head_tail(10_000)
```

```
Out[50]: 0.4931
```

```
In [51]: head_tail(100_000)
```

```
Out[51]: 0.50024
```

```
In [52]: head_tail(1000_000)
```

```
Out[52]: 0.499425
```

```
In [53]: head_tail(10_000_000)
```

```
Out[53]: 0.4999111
```

```
In [54]: head_tail(100_000_000)
```

```
Out[54]: 0.50006924
```

Gördüğünüz gibi para atım sayısı arttıkça tura gelme olasılığı da 0.5'e yakınsamaktadır. Bu olguya istatistikte "büyük sayılar yasası (law of large numbers)" da denilmektedir.

Rassal Deneyler, Örnek Uzayı ve Rassal Olaylar

Sonucu önceden kesin olarak belirlenemeyen deneylere "rassal deneyler (random experiments)" denilmektedir. Örneğin bir paranın ya da bir zarın atılması birer rassal deneydir. Rassal deneyler sonucunda olusabilecek tüm sonuçlara "örnek uzayı (sample space)" denilmektedir. Örneğin bir paranın atılması ile ilgili örnek uzay $S = \{Y, T\}$ bir zarın atılması ile ilgili örnek uzay ise $S = \{1, 2, 3, 4, 5, 6\}$ biçimindedir.

Örnek uzayın her bir alt kümeye "olay (event)" denilmektedir. Örneğin bir zarın atılması durumunda bazı olaylar şunlar olabilir:

$E1 = \{1, 3\}$

$E2 = \{4, 5, 6\}$

$E3 = \{2\}$

Örnek uzaydaki tek elemanlı oylara ise "basit olaylar (simple events)" denir. Yani basit olaylar örnek uzayıın elemanlarıdır. Örneğin zarın atılmasındaki basit olaylar şunlardır:

$E1 = \{1\}$

$E2 = \{2\}$

$E3 = \{3\}$

$E4 = \{4\}$

$E5 = \{5\}$

$E6 = \{6\}$

E rassal olayının olasılığı $s(E) / s(S)$ biçiminde ifade edilir. Bu aksiyom büyük sayılar yasasına göre anlamlı ve aynı zamanda da sezgisel olarak da kabul edilebilir bir aksiyomdur. Örneğin bir zar atımı için E olayı $E = \{3, 4\}$ olsun. Bu

durumda zar atıldığında 3 ya da 4 gelme olasılığı $P(E) = \frac{1}{3}$ olacaktır. $P(S) = 1$ olduğuna ve $P(\emptyset) = 0$ olduğuna dikkat ediniz. Dolayısıyla E olayının olasılığı aynı zamanda $P(E) = 1 - P(E')$ biçimindedir.

Rassal Değişkenler (Random Variables)

Rassal olaylar birer küme belirttiği için matematiksel işlemlere uygun değildir. Bu nedenle kümeler yerine sayısal değerlerin kullanılabilmesi için rassal değişken kavramından faydalılmaktadır. Bir rassal değişken örnek uzayının her bir elemanını (yani bir basit olayını) bir gerçek sayıya eşleyen bir fonksiyondur. Örneğin:

$$X: S \rightarrow R$$

Burada X rassal değişkeni (yani fonksiyonu) S örnek uzayındaki her bir elemanı bir gerçek sayıya eşlemektedir. Rassal değişkenler genellikle anlatımlarda sözcüklerle ifade edilseler de aslında fonksiyon belirtirler. Örneğin X rassal değişkeni için biz "bir topluluktaki kişilerin boy uzunlukları" diyebiliriz. Bu durumda aslında o toplulukta kişiler vardır. Bu kişiler örnek uzayı oluşturmaktadır. X rassal değişkeni de oradaki bireyleri onların boy uzunluklarıyla eşleyen bir fonksiyondur. Örneğin Y rassal değişkeni için de biz "sözcüklerin karakter uzunlukları" diyebiliriz. Bu durumda örnek uzay tüm sözcüklerden oluşmaktadır. Y rassal değişkeni de bu sözcükleri onların karakter uzunluklarına eşleyen bir fonksiyon durumundadır. Rassal değişkenler sayesinde artık kümeler yerine sayılarla konuşabildiğimize dikkat ediniz. Burada verdigimiz örneklerde de gördüğünüz gibi genellikle rassal değişkenler X, Y, Z gibi büyük harflerle temsil edilmektedir.

Örnek uzaydaki her olayın bir olasılığı olduğuna göre bir rassal değişkenin belli bir değeri almasının da bir olasılığı vardır. $X: S \rightarrow R$ olmak üzere $P(X = N)$ olasılığının eşdeğeri şöyledir:

$$P(X = N) = P(\{w \in S \mid X(w) = N\})$$

Bu eşitlik şu anlama gelmektedir: X rassal değişkeninin N değerini alma olasılığı S kümesindeki X fonksiyonunu N değerine eşleyen elemanların oluşturduğu olayın olasılığına eşittir. Yani örneğin X rassal değişkeni iki zarın atılması durumunda üste gelen değerlerin toplamını belirtiyor olsun. Bu durumda $P(X = 7)$ aslında $P(\{(1, 6), (2, 5), (3, 4), (4, 3), (5, 2), (6, 1)\})$ ile aynı anlamdadır. Bundan sonra biz de kümelerle konuşmak yerine rassal değişkenlerle konuşmayı tercih edeceğiz. Yani bizim için X rassal değişkeninin N değerine eşit olması aslında X fonksiyonuyla N'e eşlenen kümeyi belirtecektir.

Bir rassal değişkenin olasılığını matematiksel biçimde göstermek için normal parantezler de küme parantezleri de kullanılabilmektedir. Örneğin X rassal değişkeninin N'e eşit olma olasılığı $P(X = N)$ biçiminde de $P\{X = N\}$ biçiminde de gösterilebilmektedir. Bu iki gösterim arasında bir fark yoktur. (Aslında $P\{X = N\}$ gösterimi $P(\{X = N\})$ gösteriminin kısa yazımı olarak kullanılmaktadır.) Biz kursumuzda her iki gösterim biçimini de kullanacağız.

Kesikli ve Sürekli Rassal Değişkenler

Eğer bir rassal değişken belli bir aralıkta tüm gerçek değerleri değil de yalnızca bazı değerleri alabiliyorsa bu tür rassal değişkenlere "kesikli (discrete) rassal değişkenler" denilmektedir. Örneğin iki zar atıldığında üste gelen sayıların toplamını belirten X rassal değişkeni $[2, 12]$ aralığında yalnızca belirli değerleri alabilmektedir, bu rassal değişken $[2, 12]$ aralığında tüm gerçek sayı değerlerini alamamaktadır.

Eğer rassal değişken belli bir aralıkta tüm gerçek sayı değerlerini alabiliyorsa bu tür rassal değişkenlere de "sürekli (contiguous) rassal değişkenler" denilmektedir. K rassal değişkeni bir topluluktaki kişilerin kilolarını belirtiyor olsun. Bu K rassal değişkeni sürekli bir rassal değişkendir. Çünkü bir kişinin kilosu belli aralıkta tüm gerçek sayı değerlerini alabilmektedir. (Yani örneğin kişinin kilosu 76.234567 olabileceği gibi 83.2323728765 de olabilir.)

Kesikli rassal değişkenlerin olasılık değerlerinin hesaplanması nokta temelli olarak ve tamsayı işlemleriyle yapılabilmektedir. Fakat sürekli rassal değişkenlerin olasılıklarının hesaplanması ancak aralık temelli ve gerçek sayılar kullanılarak yapılabilir ki bu aralık temelli hesaplama da akla integral hesabı getirmektedir. Örneğin topluluktan rastgele seçilen kişinin kilosunu belirten K rassal değişkeninin 72 olma olasılığı aslında sıfırdır. Çünkü kişinin kilosu sonsuz sayıda değerden biri olabilir. Oysa 72 sayısı gerçek sayı doğrusunda yalnızca tek bir nokta belirtmektedir (sayı

/ sonsuz'un 0 olduğuna dikkat ediniz. Örneğin kişinin kilosu 72.000000000000001 olabilir, 71.99999999999999 olabilir ama tam 72 olmayı bilir.) O halde sürekli rassal değişkenlerin olasılıklarını biz ancak aralık temelli olarak ve bir integral hesapla bulabiliyoruz. Bu örneğimizde K rassal değişkeninin 72 olma olasılığı 0'dır, ancak 71 ile 73 arasında olma olasılığı sıfır değildir. Tabii integral hesap için bir fonksiyona gereksinimiz olacaktır. Integral hesap yapmakta kullandığımız bu tür fonksiyonlara "olasılık yoğunluk fonksiyonları (probability density functions)" denilmektedir.

Sürekli Rassal Değişkenlerin Olasılık Yoğunluk Fonksiyonları

Sürekli rassal değişkenler için olasılık yoğunluk fonksiyonları (probability density functions) sürekli rassal değişkenlerin belli aralıktaki olasılıklarını integral hesabı ile bulmak için kullanılan fonksiyonlardır. Aşağıdaki fonksiyonu inceleyiniz:

$$f(x) = \lim_{\Delta x \rightarrow 0} \frac{P(x \leq X \leq x + \Delta x)}{\Delta x}$$

Burada f fonksiyonu x ve $x + \Delta x$ arasında değer alabilen ve her noktada türevlenebilen bir fonksiyon olsun. Bu f fonksiyonu aşağıdaki özellikleri sağlıyorsa ona olasılık yoğunluk fonksiyonu denilmektedir:

1) $f(x) \geq 0$

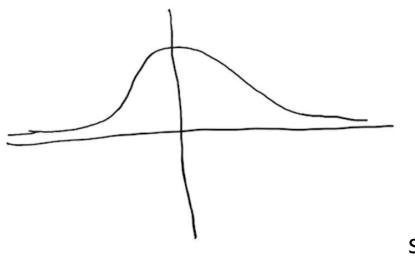
2) $\int_{-\infty}^{\infty} f(x) dx = 1$

3) $P(x_1 < X \leq x_2) = \int_{x_1}^{x_2} f(x) dx = F(x_2) - F(x_1)$

4) $F(x_0) = P(X \leq x_0) = \int_{-\infty}^{x_0} f(x) dx$

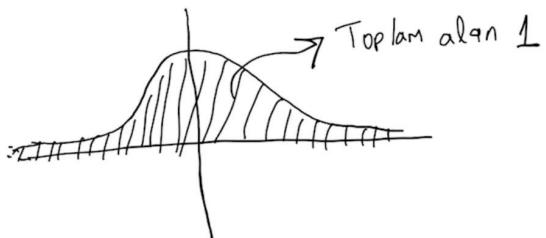
Alıntı Notu: Buradaki tanım için avys.omu.edu.tr adresindeki içerikten faydalanyılmıştır. Ancak tanımda bazı düzeltmeler ve değişiklikler yapılmıştır.

Birinci özellik olasılık yoğunluk fonksiyonlarının her zaman 0 ya da 0'dan büyük bir değer vermesi gerektiğini belirtir. Başka bir deyişle bu fonksiyonların grafikleri X ekseninin üzerinde kalmaktadır. İkinci özellik eksi sonsuzdan artı sonsuza kadar olasılık yoğunluk fonksiyonlarının eğri altında kalan alanının 1 olması gerektiğini belirtmektedir. Hiçbir olasılığın 1'den büyük ve 0'dan küçük olamayacağına dikkat ediniz. Üçüncü özellik bir rassal değişkenin belli bir aralıktaki olasılığının, olasılık yoğunluk fonksiyonun o aralıktaki integrali ile hesaplanabileceğini belirtmektedir. Yani başka bir deyişle bir rassal değişkenin belli bir aralıktaki olasılığı o rassal değişkene ilişkin olasılık yoğunluk fonksiyonun o aralıktaki eğri altında kalan alanına (integraline) eşittir. Dördüncü özellik X rassal değişkeninin x gibi bir değerden küçük olma olasılığının o rassal değişkenin olasılık yoğunluk fonksiyonun x değerinin solundaki eğri altında kalan alanına (integraline) eşit olduğunu belirtmektedir. Aşağıda bir olasılık yoğunluk fonksiyonun bu özellikler bakımından değerlendirilmesini görüyorsunuz:

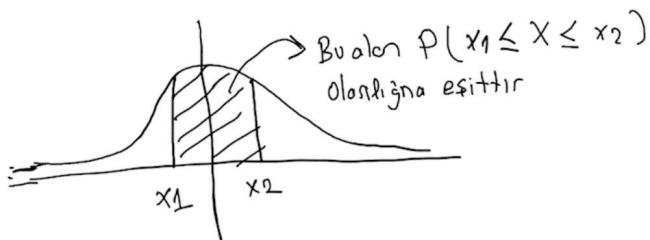


- Buradaki f fonksiyonunun X ekseninin üzerinde kaldığını görüyorsunuz (1. Özellik).

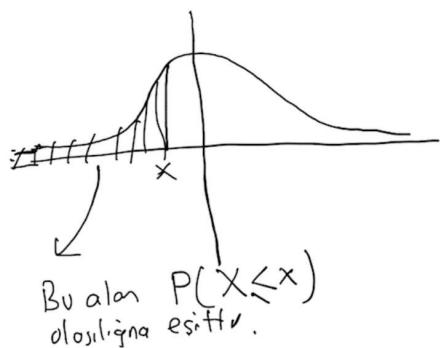
- Eğri altında kalan toplam alan 1'dir (2. Özellik):



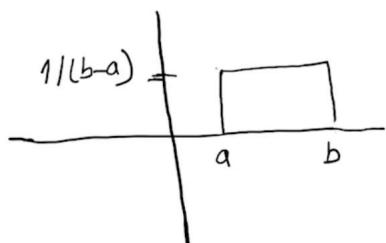
- X rassal değişkeninin x_1 ile x_2 arasında olma olasılığı $X=x_1$ ve $X=x_2$ doğruları ile belirlenen alana eşittir (3. Özellik):



X rassal değişkenin x'ten küçük olma olasılığı $X = x$ doğrusunun solundaki tüm toplam alan kadardır (4. Özellik):



Aşağıdaki fonksiyona bakınız:



Burada ilgili fonksiyon bir olasılık yoğunluk fonksiyonudur. Toplam eğri altında kalan alanın 1 olduğunu dikkat ediniz. Bu durumda c değeri a ve b arasında olmak üzere $P(X \leq c)$ olasılığı $(c - a) / (b - a)$ biçimindedir.

Çok Karşılaşılan Bazı Sürekli Dağılımlar

Yukarıda da belirttiğimiz gibi sürekli rassal değişkenlerle olasılık hesabı yapabilmemiz için o rassal değişkene ilişkin bir olasılık yoğunluk fonksiyonunu biliyor olmamız gereklidir. Örneğin X rassal değişkenimiz şöyle olsun:

X : İnsanların kilosu

Burada aslında örnek uzayı tüm insanlardır. (Kurs notlarının yazıldığı sırada dünyada 8 milyar civarı insan olduğu tahmin edilmektedir.) O halde X rassal değişkeni tüm insanları tek tek onların kilolarına eşleyen bir fonksiyondur. Burada kilonun sürekli bir rassal değişken olduğuna dikkat ediniz. Şimdi bizim rastgele seçilen bir kişinin 60 ile 80 arasında bir kiloya sahip olma olasılığını bulmamız için bu rassal değişkene ilişkin olasılık yoğunluk fonksiyonunu

biliyor olmamız gereklidir. İşte her ne kadar sonsuz sayıda olasılık yoğunluk fonksiyonu söz konusu olabilirse de belli olguların olasılık yoğunluk fonksiyonlarının belli bir kalıba uygun olduğu görülmüştür. Genellikle uygulamalarda anakütlenin olasılık yoğunluk fonksiyonunun (buna anakütle dağılımı da denilmektedir) bu kalıplardan biri içerisinde girdiği varsayılmaktadır. Örneğin doğada pek çok olguya ilişkin sürekli rassal değişkenlerin "normal dağılım" denilen dağılıma uyduğu ve bunların olasılık yoğunluk fonksiyonlarının Gauss fonksiyonuna benzettiği görülmektedir.

Pekiyi bir rassal değişkenin olasılık yoğunluk fonksiyonunun ne olacağına nasıl karar verilmektedir? Bunun en pratik yöntemlerinden biri histogram çizip eğrinin neye benzettiğine bakmak olabilir. Eğer eğri bildiğimiz bir dağılıma benzeyiyorsa biz elimizdeki bilgilerle onun olasılık yoğunluk fonksiyonunu kolaylıkla belirleyebiliriz. Pekiyi eğer elimizdeki histogram bildiğimiz hiçbir dağılımin şecline benzemiyorsa bu durumda ne yapabilirim? İşte bu durumda birikimli dağılım fonksiyonundan hareketle rassal değişkenin olasılık yoğunluk fonksiyonu çıkarılabilmektedir. Bunun için aşağıdaki makaleyi inceleyebilirsiniz:

<https://online.stat.psu.edu/stat414/lesson/22/22.1>

Yukarıda da belirttiğimiz gibi sürekli bir rassal değişkenin olasılık yoğunluk fonksiyonuna kısaca o rassal değişkenin dağılımı da denilmektedir. İşte biz de bu bölümde doğada doğrudan ya da dolaylı olarak çok karşılaştığımız bazı olasılık dağılımlarını (yani olasılık yoğunluk fonksiyonlarını) açıklayacağız.

Normal Dağılım

Şüphesiz normal dağılım doğada en çok karşılaşılan sürekli dağılımdır. Bu dağılıma Gauss dağılımı da denilmektedir. Gerçekten boy, kilo, zeka gibi pek çok özellik normal dağılıma eğilimindedir. Normal dağılımin doğada neden bu kadar çok karşılaşıldığının önemli bir nedeni de merkezi limit teoremdir (central limit theorem). Bu teoreme göre bir ana kütleden çekilen örnek ortalamaları normal dağılıma eğilimindedir.

Normal dağılıma ilişkin olasılık yoğunluk fonksiyonu şöyledir:

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Fonksiyonda μ ve σ biçiminde iki parametrenin olduğunu görüyoruz. μ dağılımin ortalamasını, σ ise standart sapmasını belirtmektedir. Gauss fonksiyonundaki μ eğrinin orta noktasının X eksenindeki yeri üzerinde, σ ise eğrinin genişliği üzerinde etkili olmaktadır. $\mu = 0$ ve $\sigma = 1$ olan normal dağılıma "standart normal dağılım" denilmektedir. μ ve σ değerleri farklı olan normal dağılımlar standart normal dağılıma dönüştürülebilmektedir.

Şimdi Gauss eğrisini çizdiren bir fonksiyon yazalım:

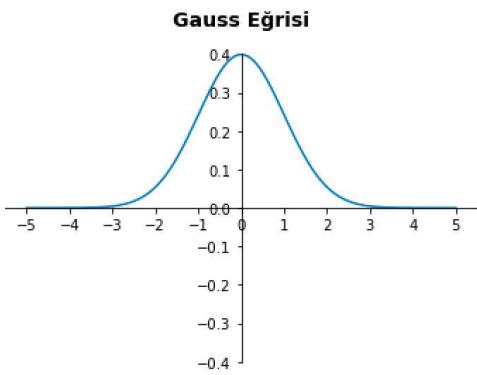
```
import numpy as np
import matplotlib.pyplot as plt

def draw_gauss(mu = 0, sigma = 1):
    x = np.linspace(-5, 5, 1000)
    y = 1 / np.sqrt(2 * np.pi * sigma ** 2) * np.e ** (-((x - mu) ** 2) / (2 * sigma ** 2))

    axis = plt.gca()
    axis.set_title('Gauss Eğrisi', fontsize=14, fontweight='bold', pad=20)
    axis.set_ylim([-0.4, 0.4])
    axis.set_xticks(range(-5, 6))
    axis.spines['left'].set_position('center')
    axis.spines['bottom'].set_position('center')
    axis.spines['top'].set_color(None)
    axis.spines['right'].set_color(None)

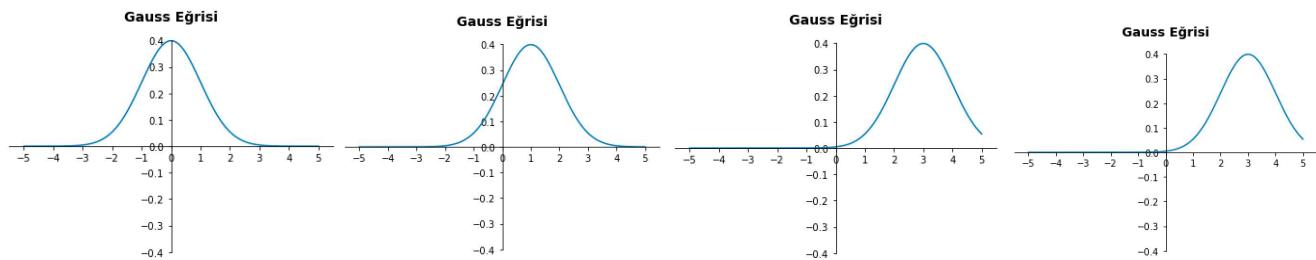
    plt.plot(x, y)
    plt.show()
```

```
draw_gauss()
```



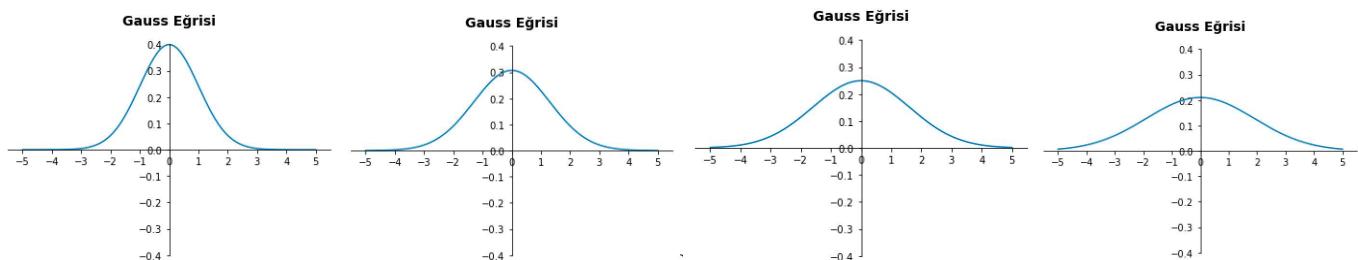
Şimdi çeşitli mü değerleri için birden fazla grafik çizelim:

```
draw_gauss(mu=0)  
draw_gauss(mu=1)  
draw_gauss(mu=2)  
draw_gauss(mu=3)
```



Şimdi de mu değerini sabit tutup sigma (standart sapma) değerini değiştirelim:

```
draw_gauss(sigma=1)  
draw_gauss(sigma=1.3)  
draw_gauss(sigma=1.6)  
draw_gauss(sigma=1.9)
```



Gördüğünüz gibi dağılımin standart sapma değeri değiştirildiğinde Gauss eğrisi şişmanlamaktadır. Standart sapmanın ortalamadan uzaklığı ilişkin bir değer belirttiğine dikkat ediniz. Yukarıdaki draw_gauss fonksiyonunu daha parametrik bir biçimde de yazabiliriz:

```
import numpy as np  
import matplotlib.pyplot as plt  
  
def draw_gauss(mu = 0, sigma = 1, axispos = None):  
    if axispos == None:  
        axispos = mu  
    x = np.linspace(axispos - 5 * sigma, axispos + 5 * sigma , 1000)  
    y = 1 / np.sqrt(2 * np.pi * sigma ** 2) * np.e ** (- (x - mu) ** 2 / (2 * sigma ** 2))
```

```

axis = plt.gca()
axis.set_title('Gauss Eğrisi', fontsize=14, fontweight='bold', pad=20)
axis.set_ylim([-0.4 / sigma, 0.4 / sigma])
axis.set_xticks(np.arange(int(mu - 5 * sigma), int(mu + 5 * sigma + sigma), sigma))
axis.spines['left'].set_position('center')
axis.spines['bottom'].set_position('center')
axis.spines['top'].set_color(None)
axis.spines['right'].set_color(None)

plt.plot(x, y)
plt.show()

draw_gauss(mu=100, sigma=2, axispos=100)

```

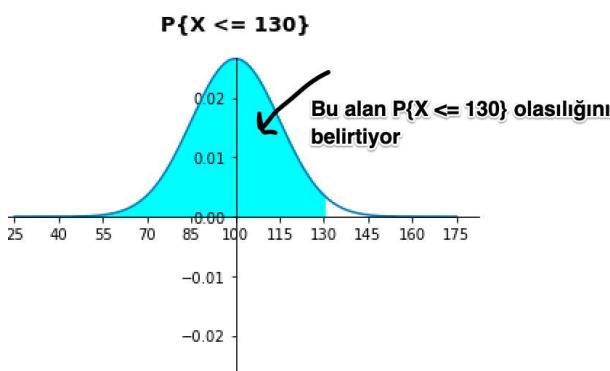
Fonksiyonun axispos parametresi Y eksenin çizileceği yeri belirtmektedir.

Bizim bir Python programcısı olarak normal dağılımla ilgili dört önemli işlemi yapabiliyor olmamız gereklidir:

1) Belli bir X değeri için (standart normal dağılımdaki X değerlerine Z değerleri de denilmektedir) eğri altında kalan alanı bulmak. Belli bir değerden küçük olan eğri altında kalan alanı veren fonksiyona "kümülatif dağılım fonksiyonu (cumulative distribution function)" denilmektedir. Kümülatif dağılım fonksiyonunu şöyle ifade edebiliriz:

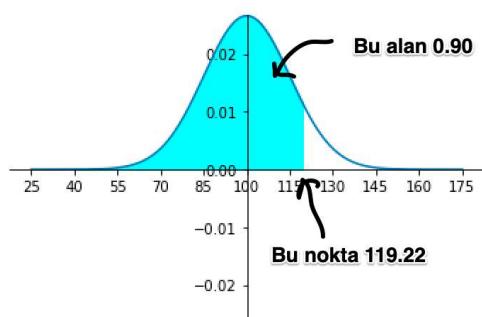
$$F(x) = P\{X \leq x\}$$

Örneğin ortalaması 100, standart sapması 15 olan bir normal dağılımda X'in 130'dan küçük olma olasılığı aslında F(130) değeridir.

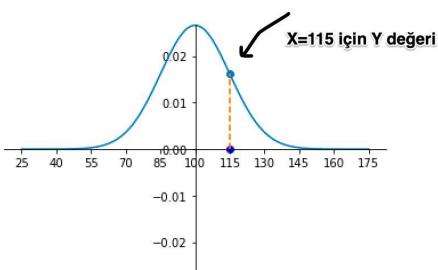


F kümülatif olasılık fonksiyonunu belirtmek üzere $P\{x_1 < X < x_2\}$ olasılığının $F(x_2) - F(x_1)$ olasılığı ile aynı olduğuna dikkat ediniz. Ayrıca X sürekli bir rassal değişken olmak üzere $X = x$ olma olasılığı 0 olduğuna göre $P\{X \leq x\}$ gösterimi ile $P\{X < x\}$ gösterimi arasında bir fark olmadığını da dikkatinizi çekmek istiyoruz. (Sürekli rassal değişkenlerin noktalı olasılıklarının 0 olduğunu anımsayınız.)

2) Kümülatif dağılım değerine karşı gelen X değerini bulmak. Bu işlem önceki işlemin tersidir. Örneğin ortalaması 100 standart sapması 15 olan bir normal dağılımda eğri altında kalan alanın 0.90 olduğu X değerinin bulunması istenebilir.



- 3) Üçüncü önemli işlem belli bir X değeri için Gauss fonksiyonundaki Y değerinin elde edilmesidir. Örneğin ortalaması 100 standart sapması 15 olan Gauss fonksiyonunda $X = 115$ 'e karşılık gelen Y değeri bulunmak istenebilir.



- 4) Normal dağılıma uygun rastgele sayıların elde edilmesi. Örneğin ortalaması 100, standart sapması 15 olan normal dağılıma ilişkin 1000 tane rastgele X değeri elde etmek isteyebiliriz.

Normal dağılıma ilişkin işlemler Python standart kütüphanesindeki `NormalDist` sınıfı ile yapılmaktadır. Bu sınıf nesnesi yaratılırken sınıfın `__init__` metodunda dağılımın ortalaması ve standart sapması girilir:

```
class statistics.NormalDist(mu=0.0, sigma=1.0)
```

Sınıfın `cdf` (cumulative distribution function) birikimli olasılık değerini bize verir. Örneğin ortalaması 100 standart sapması 15 olan normal dağılımda $P\{X \leq 130\}$ değeri şöyle edilir:

```
In [13]: import statistics
```

```
In [14]: nd = statistics.NormalDist(100, 15)
```

```
In [15]: nd.cdf(130)
```

```
Out[15]: 0.9772498680518209
```

Bu işlemin tersi (yani birikimli olasılığı belli değere eşit olan X değeri) `inv_cdf` metoduyla elde edilmektedir. Örneğin aynı dağılım için 0.95 birikimli olasılığa karşı gelen X değerini bulalım:

```
In [17]: nd.inv_cdf(0.95)
```

```
Out[17]: 124.67280440427207
```

Normal dağılımın olasılık yoğunluk fonksiyonu sınıfın `pdf` metoduyla temsil edilmiştir. Örneğin $X = 100$ için Y değeri şöyle elde edilebilir:

```
In [18]: nd.pdf(100)
```

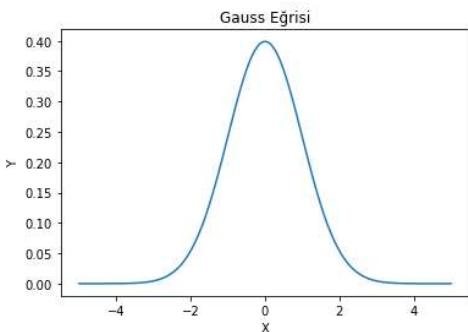
```
Out[18]: 0.02659615202676218
```

Bu metot yoluyla Gauss eğrisini şöyle çizdirebiliriz:

```
import statistics
import matplotlib.pyplot as plt

nd = statistics.NormalDist()
x = [i * 0.001 for i in range(-5000, 5000)]
y = [nd.pdf(i) for i in x]

plt.title('Gauss Eğrisi')
plt.xlabel('X')
plt.ylabel('Y')
plt.plot(x, y)
plt.show()
```



Normal dağılıma ilişkin X rassal değerleri NormalDist sınıfının samples metodu ile elde edilebilir. Metot üretilecek rassal sayı miktarını argüman olarak alır, rassal sayılarından oluşan float bir listeye geri döner. Örneğin ortalaması 0, standart sapması 1 olan normal dağılıma ilişkin 10 tane X değeri elde edelim:

```
In [8]: nd.samples(10)
Out[8]:
[2.2430953695646756,
 1.2268571624167866,
 -0.724013324379113,
 0.024421452476078475,
 1.3844039121150333,
 -0.30039474167071156,
 0.3358960004859962,
 0.1357332312337312,
 1.7497659974133424,
 0.9205748388940354]
```

Normal dağılıma ilişkin rassal sayıların elde edilmesi için çeşitli yöntemler önerilmektedir. Ancak en basit yöntem 0 ile 1 arasında rasgele sayı üretip inv_cdf metodu ile buna karşı gelen X değerini elde etmektedir. Örneğin:

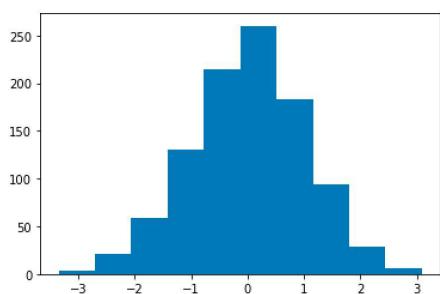
```
In [9]: import random
```

```
In [10]: nd.inv_cdf(random.random())
Out[10]: -0.7182396147616845
```

Şimdi de normal dağılıma ilişkin rassal sayılar elde edip histogramını çizelim:

```
import statistics
import matplotlib.pyplot as plt

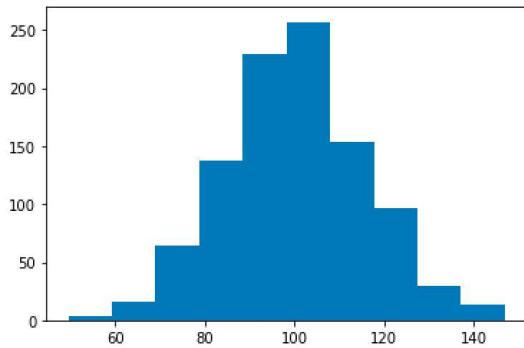
nd = statistics.NormalDist()
vals = nd.samples(1000)
plt.hist(vals)
plt.show()
```



Python standart kütüphanesindeki random modülünde bulunan gauss fonksiyonu da normal dağılmış rassal sayı üretmektedir. Örneğin:

```
import random
import matplotlib.pyplot as plt
```

```
vals = [random.gauss(100, 15) for _ in range(1000)]
plt.hist(vals)
plt.show()
```



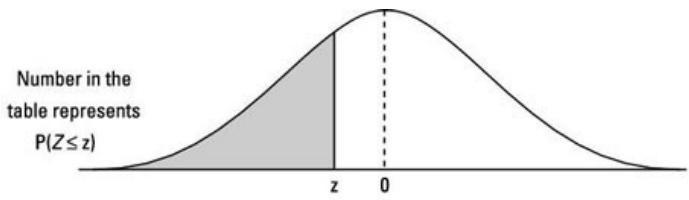
Aynı modülde thread güvenli olan ancak biraz daha yavaş çalışma potansiyelinde olan randomvariate isimli bir fonksiyon da bulunmaktadır. Benzer biçimde numpy.random modülündeki normal isimli fonksiyon da normal dağılmış rastgele sayılar üretebilmektedir.

In [14]: np.random.normal(100, 15, (5, 5))

Out[14]:

```
array([[136.98876845,  91.53984056, 102.17566605, 116.12829323,
       115.4082498 ],
       [ 98.64699431, 101.85886721, 91.26849034, 71.3181747 ,
       112.85576916],
       [103.83548818,  84.62959357,  99.00314067, 123.32854279,
       92.02323565],
       [ 77.37713894,  79.77778321, 104.35880328,  92.44849229,
       81.36674797],
       [ 89.26058084, 105.95081198, 104.37975346, 101.53852492,
       106.91590956]])
```

Bilgisayarların istatistikte bu kadar yoğun kullanılmadığı zamanlarda normal dağılıma ilişkin bu tür işlemler elle yapıliyordu. Bunun için ortalaması 0, standart sapması 1 olan standart normal dağılım için Z tabloları oluşturulmuştur. Bu tablolar belli bir Z değeri için (standart normal dağılımda X değeri yerine Z değeri denildiğini anımsayınız) birikimli olasılıkları göstermektedir. Aşağıda örnek bir Z tablosu görüyorsunuz:



z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
-3.6	.0002	.0002	.0001	.0001	.0001	.0001	.0001	.0001	.0001	.0001
-3.5	.0002	.0002	.0002	.0002	.0002	.0002	.0002	.0002	.0002	.0002
-3.4	.0003	.0003	.0003	.0003	.0003	.0003	.0003	.0003	.0003	.0002
-3.3	.0005	.0005	.0005	.0004	.0004	.0004	.0004	.0004	.0004	.0003
-3.2	.0007	.0007	.0006	.0006	.0006	.0006	.0006	.0005	.0005	.0005
-3.1	.0010	.0009	.0009	.0009	.0008	.0008	.0008	.0008	.0007	.0007
-3.0	.0013	.0013	.0013	.0012	.0012	.0011	.0011	.0011	.0010	.0010
-2.9	.0019	.0018	.0018	.0017	.0016	.0016	.0015	.0015	.0014	.0014
-2.8	.0026	.0025	.0024	.0023	.0023	.0022	.0021	.0021	.0020	.0019
-2.7	.0035	.0034	.0033	.0032	.0031	.0030	.0029	.0028	.0027	.0026
-2.6	.0047	.0045	.0044	.0043	.0041	.0040	.0039	.0038	.0037	.0036
-2.5	.0062	.0060	.0059	.0057	.0055	.0054	.0052	.0051	.0049	.0048
-2.4	.0082	.0080	.0078	.0075	.0073	.0071	.0069	.0068	.0066	.0064
-2.3	.0107	.0104	.0102	.0099	.0096	.0094	.0091	.0089	.0087	.0084
-2.2	.0139	.0136	.0132	.0129	.0125	.0122	.0119	.0116	.0113	.0110
-2.1	.0179	.0174	.0170	.0166	.0162	.0158	.0154	.0150	.0146	.0143
-2.0	.0228	.0222	.0217	.0212	.0207	.0202	.0197	.0192	.0188	.0183
-1.9	.0287	.0281	.0274	.0268	.0262	.0256	.0250	.0244	.0239	.0233
-1.8	.0359	.0351	.0344	.0336	.0329	.0322	.0314	.0307	.0301	.0294
-1.7	.0446	.0436	.0427	.0418	.0409	.0401	.0392	.0384	.0375	.0367
-1.6	.0548	.0537	.0526	.0516	.0505	.0495	.0485	.0475	.0465	.0455
-1.5	.0668	.0655	.0643	.0630	.0618	.0606	.0594	.0582	.0571	.0559
-1.4	.0808	.0793	.0778	.0764	.0749	.0735	.0721	.0708	.0694	.0681
-1.3	.0968	.0951	.0934	.0918	.0901	.0885	.0869	.0853	.0838	.0823
-1.2	.1151	.1131	.1112	.1093	.1075	.1056	.1038	.1020	.1003	.0985
-1.1	.1357	.1335	.1314	.1292	.1271	.1251	.1230	.1210	.1190	.1170
-1.0	.1587	.1562	.1539	.1515	.1492	.1469	.1446	.1423	.1401	.1379
-0.9	.1841	.1814	.1788	.1762	.1736	.1711	.1685	.1660	.1635	.1611
-0.8	.2119	.2090	.2061	.2033	.2005	.1977	.1949	.1922	.1894	.1867
-0.7	.2420	.2389	.2358	.2327	.2296	.2266	.2236	.2206	.2177	.2148
-0.6	.2743	.2709	.2676	.2643	.2611	.2578	.2546	.2514	.2483	.2451
-0.5	.3085	.3050	.3015	.2981	.2946	.2912	.2877	.2843	.2810	.2776
-0.4	.3446	.3409	.3372	.3336	.3300	.3264	.3228	.3192	.3156	.3121
-0.3	.3821	.3783	.3745	.3707	.3669	.3632	.3594	.3557	.3520	.3483
-0.2	.4207	.4168	.4129	.4090	.4052	.4013	.3974	.3936	.3897	.3859
-0.1	.4602	.4562	.4522	.4483	.4443	.4404	.4364	.4325	.4286	.4247
-0.0	.5000	.4960	.4920	.4880	.4840	.4801	.4761	.4721	.4681	.4641

Alıntı Notu: Görüel <https://www.dummies.com/education/math/statistics/how-to-use-the-z-table/> adresinden alınmıştır.

Burada ilgili satır ile sütunun birleşimi Z değerini, onların kesimlerinde bulunan değerler ise birikimli olasılık değerlerini belirtmektedir. Tabloda yalnızca normal dağılımın sol yarımlarının bulunduğuuna dikkat ediniz. Eğrinin iki yarısı simetrik olduğuna göre sağ yarısı için birikimli değerler de kolaylıkla elde edilebilmektedir. Yukarıdaki Z tablosunun benzerini çeken basit bir Python programını söyle yazabiliriz:

```
import statistics

def disp_ztable():
    nd = statistics.NormalDist()

    print('-' * 76)
    print(' z' + 6 * ' ', end='')
    for i in range(10):
        f = i * 0.01
```

```

    print(f'{f:<7.2f}', end=' ')
print()
print('-' * 76)

z = -3.6
while z <= 0.05:
    print(f'{-0.0:<8.1f}' if z > 0 else f'{z:<8.1f}', end='')

    for i in range(10):
        f = i * 0.01
        cd = nd.cdf(z - f)
        print(f'{cd:<8.4f}'[1:], end=' ')
    print()
    z += 0.1

```

z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
-3.6	.0002	.0002	.0001	.0001	.0001	.0001	.0001	.0001	.0001	.0001
-3.5	.0002	.0002	.0002	.0002	.0002	.0002	.0002	.0002	.0002	.0002
-3.4	.0003	.0003	.0003	.0003	.0003	.0003	.0003	.0003	.0003	.0002
-3.3	.0005	.0005	.0005	.0004	.0004	.0004	.0004	.0004	.0004	.0003
-3.2	.0007	.0007	.0006	.0006	.0006	.0006	.0006	.0005	.0005	.0005
-3.1	.0010	.0009	.0009	.0008	.0008	.0008	.0008	.0007	.0007	.0007
-3.0	.0013	.0013	.0012	.0012	.0011	.0011	.0011	.0010	.0010	.0010
-2.9	.0019	.0018	.0018	.0017	.0016	.0016	.0015	.0015	.0014	.0014
-2.8	.0026	.0025	.0024	.0023	.0023	.0022	.0021	.0021	.0020	.0019
-2.7	.0035	.0034	.0033	.0032	.0031	.0030	.0029	.0028	.0027	.0026
-2.6	.0047	.0045	.0044	.0043	.0041	.0040	.0039	.0038	.0037	.0036
-2.5	.0062	.0060	.0059	.0057	.0055	.0054	.0052	.0051	.0049	.0048
-2.4	.0082	.0080	.0078	.0075	.0073	.0071	.0069	.0068	.0066	.0064
-2.3	.0107	.0104	.0102	.0099	.0096	.0094	.0091	.0089	.0087	.0084
-2.2	.0139	.0136	.0132	.0129	.0125	.0122	.0119	.0116	.0113	.0110
-2.1	.0179	.0174	.0170	.0166	.0162	.0158	.0154	.0150	.0146	.0143
-2.0	.0228	.0222	.0217	.0212	.0207	.0202	.0197	.0192	.0188	.0183
-1.9	.0287	.0281	.0274	.0268	.0262	.0256	.0250	.0244	.0239	.0233
-1.8	.0359	.0351	.0344	.0336	.0329	.0322	.0314	.0307	.0301	.0294
-1.7	.0446	.0436	.0427	.0418	.0409	.0401	.0392	.0384	.0375	.0367
-1.6	.0548	.0537	.0526	.0516	.0505	.0495	.0485	.0475	.0465	.0455
-1.5	.0668	.0655	.0643	.0630	.0618	.0606	.0594	.0582	.0571	.0559
-1.4	.0808	.0793	.0778	.0764	.0749	.0735	.0721	.0708	.0694	.0681
-1.3	.0968	.0951	.0934	.0918	.0901	.0885	.0869	.0853	.0838	.0823
-1.2	.1151	.1131	.1112	.1093	.1075	.1056	.1038	.1020	.1003	.0985
-1.1	.1357	.1335	.1314	.1292	.1271	.1251	.1230	.1210	.1190	.1170
-1.0	.1587	.1562	.1539	.1515	.1492	.1469	.1446	.1423	.1401	.1379
-0.9	.1841	.1814	.1788	.1762	.1736	.1711	.1685	.1660	.1635	.1611
-0.8	.2119	.2090	.2061	.2033	.2005	.1977	.1949	.1922	.1894	.1867
-0.7	.2420	.2389	.2358	.2327	.2296	.2266	.2236	.2206	.2177	.2148
-0.6	.2743	.2709	.2676	.2643	.2611	.2578	.2546	.2514	.2483	.2451
-0.5	.3085	.3050	.3015	.2981	.2946	.2912	.2877	.2843	.2810	.2776
-0.4	.3446	.3409	.3372	.3336	.3300	.3264	.3228	.3192	.3156	.3121
-0.3	.3821	.3783	.3745	.3707	.3669	.3632	.3594	.3557	.3520	.3483
-0.2	.4207	.4168	.4129	.4090	.4052	.4013	.3974	.3936	.3897	.3859
-0.1	.4602	.4562	.4522	.4483	.4443	.4404	.4364	.4325	.4286	.4247
-0.0	.5000	.4960	.4920	.4880	.4840	.4801	.4761	.4721	.4681	.4641

Bu tür kodlarda yuvarlama hatalarına dikkat ediniz. Python'da yuvarlama hatalarına maruz kalmadan noktalı sayılar üzerinde işlem yapmak için tasarılanmış decimal isimli standart bir modülün olduğunu anımsatmak istiyoruz. Ancak bu modüldeki Decimal türü NumPy ya da Pandas kütüphanelerinde kullanılamamaktadır.

Belli bir ortalama ve standart sapmaya ilişkin normal dağılımdaki X değerini standart normal dağılımdaki Z değerine dönüştürmek için (yani ortalaması 0, standart sapması 1 olan normal dağılımdaki X değerine dönüştürmek için) aşağıdaki işlem uygulanır:

$$Z = \frac{X - \mu}{\sigma}$$

Örneğin ortalaması 100 standart sapması 15 olan bir normal dağılımdaki $X = 125$ değerinin standart normal dağılımdaki karşılığı şöyle hesaplanmaktadır:

$$Z = \frac{125 - 100}{15} = 1.666$$

Python 3.9 ile birlikte NormalDist sınıfına bu dönüşümü yapan zscore isimli bir metot da eklenmiştir. Örneğin:

```
In [4]: nd = statistics.NormalDist(100, 15)
```

```
In [5]: nd.zscore(125)
```

```
Out[5]: 1.6666666666666667
```

Eski bilgisayarların bu kadar yoğun kullanılmadığı zamanlarda belli bir ortalamaya ve standart sapmaya sahip normal dağılımlar üzerindeki işlemler standart normal dağılıma dönüştürülerek yapıyordu. Z tablolarının standart normal dağılıma yönelik oluşturulduğuna dikkat ediniz.

Şimdi şöyle bir soruyu çözelim: Rastgele seçilen bir kişinin ortalaması 100 standart sapması 15 olan WAIS (Wechsler Adult Intelligence Scale) testinden 130 ile 140 puan alma olasılığı nedir? Bu soruda sorulmak istenen şey aslında $P\{130 < X \leq 140\}$ yani $F(140) - F(130)$ olasılığıdır. NormalDist sınıfını kullanarak bu olasılığı şöyle hesaplayabiliriz:

```
In [4]: nd = statistics.NormalDist(100, 15)
```

```
In [5]: nd.cdf(140) - nd.cdf(130)
```

```
Out[5]: 0.018919751380589434
```

Şimdi aynı işlemi yukarıda vermiş olduğumuz Z tablosunu kullanarak elle yapmaya çalışalım. Önce ortalaması 100 standart sapması 15 olan normal dağılımdaki 130 ve 140 değerlerini standart normal dağılım değerlerine dönüştürelim:

$$Z_{140} = \frac{140 - 100}{15} = 2.66$$

$$Z_{130} = \frac{130 - 100}{15} = 2$$

Şimdi Z tablosuna bakarak 2.66 ve 2 değerleri için kümülatif olasılıkları bulalım. 2.66 değerini 2.67 olarak yuvarlayacağız:

$$F(2.66) = 1 - 0.0038 = 0.9962$$

$$F(2) = 1 - 0.0228 = 0.9772$$

$$F(2.66) - F(2) = 0.19$$

Aradaki küçük fark Z tablosunun duyarlılığından ve yapılan yuvarlamadan kaynaklanmaktadır.

NumPy ve Pandas kütüphanelerinde normal dağılım üzerinde işlem yapan fonksiyonlar ya da sınıflar bulunmamaktadır. Ancak normal dağılıma ilişkin işlemler SciPy kütüphanesindeki stats modülünde bulunan norm isimli "singleton" sınıf nesnesi ile de yapılmaktadır. SciPy kütüphanesi NumPy kütüphanesi kullanılarak gerçekleştirildiği için bir grup veri üzerinde vektörel işlemler yapılabilmektedir. norm nesnesinin ilişkin olduğu sınıfın cdf isimli metodu birikimli olasılık değerini elde etmekte kullanılmaktadır. Metodun birinci parametresi birikimli olasılığı hesaplanacak değerlerin bulunduğu dolaşılabilir nesneyi alır. İkinci ve üçüncü parametreler normal dağılımin ortalama ve standart sapmasını belirtmektedir. Örneğin:

```
from scipy.stats import norm

result = norm.cdf([100, 130, 120], 100, 15)
print(result)
```

Şöyledir bir çıktı elde edilmiştir:

```
[0.5      0.97724987 0.90878878]
```

Bu işlemin tersi yani birikimli olasılığa karşı gelen X değerleri ilgili sınıfın ppf (percent point function) metodıyla elde edilmektedir:

```
from scipy.stats import norm

result = norm.ppf([0.5, 0.3, 0.05], 100, 15)
print(result)
```

Şöyledir bir çıktı elde edilmiştir:

```
[100.      92.13399231  75.3271956 ]
```

Belli X değerleri için Gauss eğrisindeki Y değerlerinin elde edilmesi ilgili sınıfın pdf isimli metodıyla yapılmaktadır. Örneğin:

```
from scipy.stats import norm

result = norm.pdf([100, 120, 130], 100, 15)
print(result)
```

Bu işlemenin sonucu aşağıdaki gibi bir çıktı elde edilmiştir:

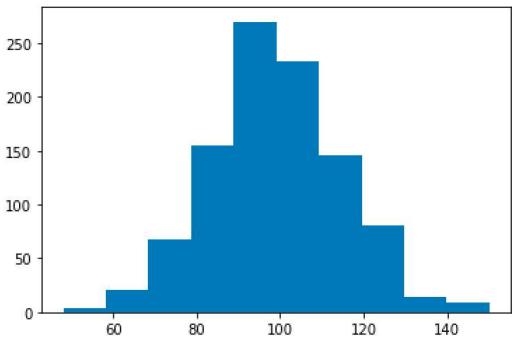
```
[0.02659615 0.010934  0.0035994 ]
```

Normal dağılıma ilişkin rastgele sayı elde edebilmek için ise ilgili sınıfın rvs metodunu kullanılmaktadır. Örneğin:

```
from scipy.stats import norm
import matplotlib.pyplot as plt

result = norm.rvs(100, 15, 1000)
plt.hist(result)
plt.show()
```

Elde edilen histogram şöyledir:



rvs fonksiyonun üçüncü parametresi bir demet olarak da girilebilmektedir. Bu durumda çok boyutlu normal dağılmış rassal sayılar da üretilebilmektedir.

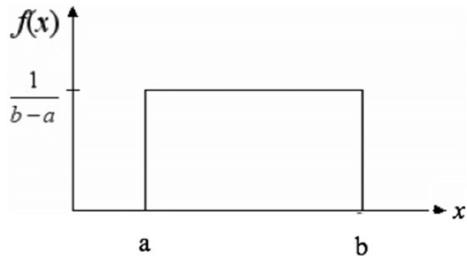
Sürekli Düzgün Dağılım (Continuous Uniform Distribution)

Düzgün dağılım herkesin aşina olduğu bir dağılımdır. Düzgün dağılımın olasılık yoğunluk fonksiyonu şöyledir:

$$f(x) = \begin{cases} \frac{1}{b-a} & \text{for } a \leq x \leq b, \\ 0 & \text{for } x < a \text{ or } x > b \end{cases}$$

Akıntı Notu: Görsel https://en.wikipedia.org/wiki/Continuous_uniform_distribution adresinden alınmıştır.

Olasılık yoğunluk fonksiyonun grafiği de şöyledir:



Akıntı Notu: Görsel <https://www.researchgate.net/publication/332236648/figure/fig8/AS:865450120445954@1583350796843/Continuous-uniform-distribution-Source-14.ppm> adresinden elde edilmiştir.

Bu grafikte dikdörtgenin içerisindeki alanın 1 olması gereğine dikkat ediniz. Bu dikörtgensel alanda aynı genişlikteki aralığın olasılığı aynı olacaktır.

Düzgün dağılımla işlemler `scipy.stats` kütüphanesindeki `uniform` isimli "singleton" nesne ile yapılabilmektedir. Nesnenin kullanımı norm nesnesiyle benzerdir. Örneğin:

```
from scipy.stats import uniform
import matplotlib.pyplot as plt

result = uniform.cdf([50, 60, 70], 0, 100)
print(result)

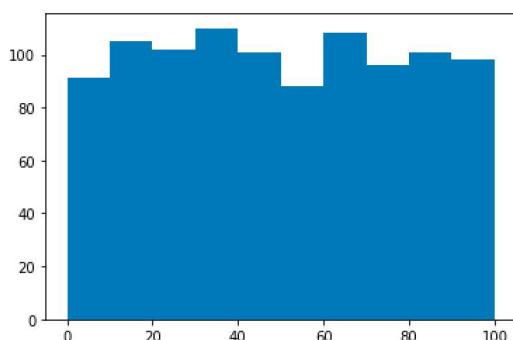
result = uniform.ppf([0.3, 0.5, 0.7], 0, 100)
print(result)

result = uniform.pdf([0.3, 0.5, 0.7], 0, 100)
print(result)

result = uniform.rvs(0, 100, 1000)
plt.hist(result)
plt.show()
```

Şöyledir bir çıktı elde edilmiştir:

```
[0.5 0.6 0.7]
[30. 50. 70.]
[0.01 0.01 0.01]
```



t Dağılımı (Student's t Distribution)

Özellikle hipotez testlerinde karşımıza çıkan diğer bir dağılım da t dağılımıdır. Dağılım William. S. Gosset tarafından 1908 yılında geliştirilmiştir. Gosset çalıştığı Guinness Biracılık şirketinin izin vermemesi nedeniyle makalesini "Student (Öğrenci)" takma adıyla yayımladığı için dağılım bu isimle de anılmaktadır. Gosset'in orijinal makalesini aşağıdaki bağlantıdan inceleyebilirsiniz:

http://seismo.berkeley.edu/~kirchner/eps_120/Odds_n_ends/Students_original_paper.pdf

t dağılımı normal dağılıma benzerdir. Dağılımin olasılık yoğunluk fonksiyonunu -biraz karışık olduğu gereklisiyle- burada vermeyeceğiz. Ancak t dağılımı normal dağılıma göre daha düz, daha az yüksek ancak daha geniş bir görünümdedir. Örneklem miktarı büyüdükçe t dağılımı standart normal dağılıma benzemektedir. t dağılımindaki değerlere (yani X değerlerine) t değerleri denilmektedir. (Standart normal dağılımdaki X değerlerine Z değerleri dendiğini anımsayınız.) t dağılıminin şekli "serbestlik derecesi (degrees of freedom)" denilen bir değere bağlıdır. Serbestlik derecesi örneklem büyüklüğünün bir eksigidir. Yani n örneklem büyüklüğü olmak üzere serbestlik derecesi şöyle hesaplanmaktadır:

$$df = n - 1$$

t dağılıminin ortalaması standart normal dağılımda olduğu gibi 0'dır. Ancak standart sapması 1 değildir. 1'den biraz daha fazladır. t dağılıminin standart sapması şöyle hesaplanır:

$$\sigma = \sqrt{\frac{df}{df - 2}}$$

Standart sapmanın 1'den büyük olması standart normal dağılıma göre eğrinin daha geniş (yani daha şişman) olmasına yol açmaktadır. Bu eşitlikte serbestlik derecesi olan df arttıkça standart sapmanın 1'e yaklaşmasına dikkat ediniz.

Python standart kütüphanesinde t dağılımı ile ilgili işlem yapan bir fonksiyon ya da sınıf yoktur. Numpy kütüphanesinde t dağılımına uygun rastgele sayı üretene standard_t fonksiyonu dışında başka bir fonksiyon ya da sınıf bulunmamaktadır. Ancak SciPy kütüphanesinde stats modülü içerisinde t dağılımı ile işlem yapan t isimli bir singleton nesne bulunmaktadır. t nesnesinin kullanımı norm ve uniform nesnelerine benzemektedir. t nesnesinin ilişkin olduğu sınıfın cdf metodu birikimli olasılığı hesaplar. ppf fonksiyonu yine ters işlemi yapmaktadır. pdf fonksiyonu ise X değerleri için olasılık yoğunluk fonksiyonun Y değerini vermektedir. Bu fonksiyonların hepsinin birinci parametreleri hesaplanacak değerleri, ikinci parametreleri serbestlik derecesini, üçüncü ve dördüncü parametreleri ise ortalama ve standart sapma değerlerini almaktadır. Örneğin:

```
from scipy.stats import t
from scipy.stats import norm

p = t.cdf([0, 1, 2], 10)
print(p)

p = norm.cdf([0, 1, 2])
print(p)
```

Programdan şöyle bir çıktı elde edilmiştir:

```
[0.5      0.82955343 0.96330598]
[0.5      0.84134475 0.97724987]
```

Buradan da gördüğünüz gibi t dağılımı biraz daha şişman ve standart sapması biraz daha büyük olduğu için kümülatif değerler de standart normal dağılım değerlerinden biraz daha küçüktür. Şimdi 10 serbestlik derecesi için t dağılımini ve standart normal dağılımı çizerek aynı eksende gösterelim:

```

import numpy as np
from scipy.stats import norm, t
import matplotlib.pyplot as plt

fig = plt.gcf()
fig.set_size_inches(10, 8)
x = np.linspace(-5, 5, 1000)
y_norm = norm.pdf(x)
y_t = t.pdf(x, 5)

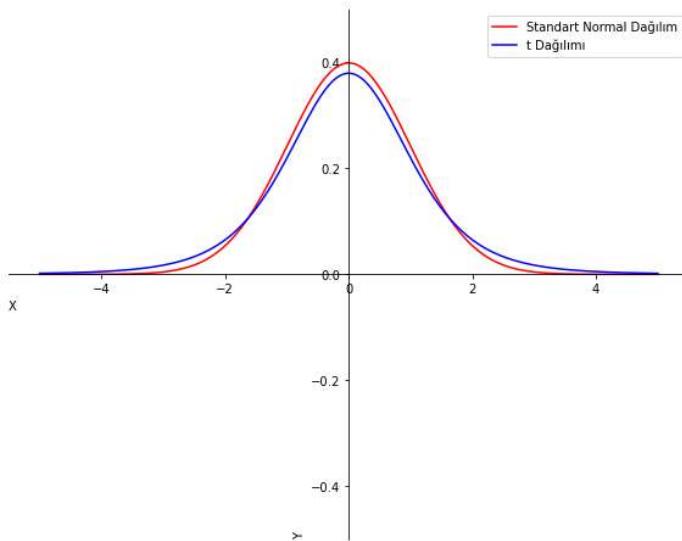
axis = plt.gca()
axis.spines['left'].set_position('center')
axis.spines['bottom'].set_position('center')
axis.spines['top'].set_color(None)
axis.spines['right'].set_color(None)
axis.set_xlim([-0.5, 0.5])

plt.plot(x, y_norm, color='red')
plt.plot(x,y_t, color='blue')
plt.xlabel('X', loc='left')
plt.ylabel('Y', loc='bottom')
plt.legend(['Standart Normal Dağılım', 't Dağılımı'])

plt.show()

```

Aşağıdaki gibi bir grafik elde edilmiştir:



Şimdi de çeşitli serbestlik dereceleri için t dağılımının eğrilerini çizelim:

```

import numpy as np
from scipy.stats import t
import matplotlib.pyplot as plt

plt.title('Değişik Serbestlik Dereceleri İçin t Dağılımı Grafiği', fontsize=14, pad=22,
fontweight='bold')
fig = plt.gcf()
fig.set_size_inches(15, 12)
x = np.linspace(-5, 5, 1000)

axis = plt.gca()
axis.spines['left'].set_position('center')
axis.spines['bottom'].set_position('center')
axis.spines['top'].set_color(None)
axis.spines['right'].set_color(None)

```

```

axis.set_ylim([-0.5, 0.5])

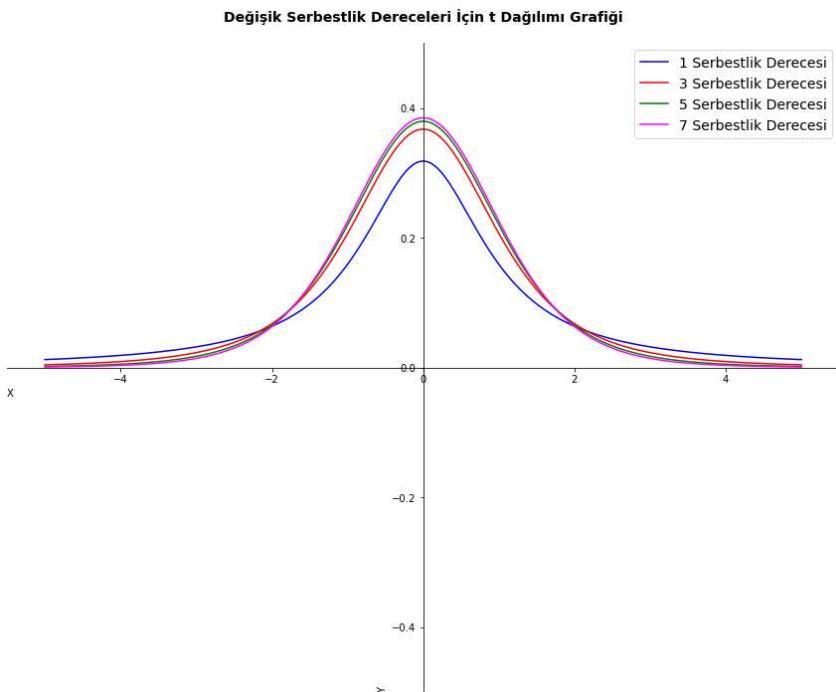
dist_info = [(1, 'blue'), (3, 'red'), (5, 'green'), (7, 'magenta')]

for df, c in dist_info:
    y = t.pdf(x, df)
    plt.plot(x, y, color=c)

plt.xlabel('X', loc='left')
plt.ylabel('Y', loc='bottom')
plt.legend([f'{t[0]} Serbestlik Derecesi' for t in dist_info], fontsize=14)

plt.show()

```



t dağılımı 30 serbestlik derecesi ve sonrasında artık standart normal dağılıma çok benzemektedir. Uygulamada t dağılımı anakütle standart sapmasının bilinmediği ve örneklem miktarının küçük olduğu (tipik olarak 30'dan küçük olduğu) durumlarda örnekten hareketle anakütle parametrelerinin tahmin edilmesinde kullanılmaktadır.

Diger Sürekli Dağılımlar

İstatistikte çeşitli olguların olasılıklarını modellemek için ya da çeşitli konularda dolaylı olarak kullanılan pek çok sürekli dağılım vardır. Bu dağılımların büyük çoğunluğu için SciPy kütüphanesinde stats modülü içerisinde hazır nesneler bulunmaktadır. Temel işlemler yine ilgili sınıfların benzer metotlarıyla yapılmaktadır. SciPy kütüphanesindeki dağılım nesnelerinin listesini aşağıdaki bağlantıdan inceleyebilirsiniz:

<https://docs.scipy.org/doc/scipy/reference/stats.html>

Merkezi Limit Teoremi (Central Limit Theorem)

Şüphesiz sonuç çıkarıcı istatistiğin (inferential statistics) en önemli teoremi merkezi limit teoremidir. Bu teorem normal dağılımin bizim için neden bu kadar önemli olduğunu da göstermektedir. Teorem uzun süredir bilinmiyor olmasına karşın bu isimle ilk kez George Pólya tarafından 1920 yılında kullanılmıştır. Merkezi limit teoreminin biçimsel ifadesi biraz karmaşık bir görünümdedir. Biz burada sözel anlatımı üzerinde duracağız.

Bu teoreme göre bir anakütleden elde edilen örnek ortalamaları normal dağılma eğilimindedir. Eğer anakütle normal dağılmışsa küçük örneklerin ortalamaları da normal dağılır. Ancak anakütle normal dağılmamışsa örnek

ortalamalarının normal dağılması için örneklerin belli bir büyülüklükte (tipik olarak ≥ 30) olması gerekmektedir. Yine bu teoreme göre örnek ortalamalarının ortalaması ana kütle ortalamasına eşittir. Örnek ortalamalarının standart sapması ise anakütle standart sapmanın örneklem büyülüğünün kareköküne bölümüne eşittir. Teoremin bu kısmını matematiksel olarak şöyle ifade edebiliriz:

$$\mu_{\bar{x}} = \mu$$

$$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$$

Buradaki n örneklem büyülüğünü belirtmektedir. n değeri örneklem büyülüğünü, N ise anakütle büyülüğünü belirtmek üzere,

$\frac{n}{N} > 0.05$ ise yani örneklem büyülüğünün anakütle büyülüğüne oranı %5'ten büyük ise örneklem standart sapması şöyle olur:

$$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}} \sqrt{\frac{N-n}{N-1}}$$

Burada $\sqrt{\frac{N-n}{N-1}}$ oranına düzeltme faktörü denilmektedir.

Teoremdeki örneklem dağılımının standart sapmasına "standart hata (standard error)" da denilmektedir. Normal dağılımda standart sapma küçüldüğünde Gauss eğrisinin ortalama etrafında toplanarak inceldiğini anımsayınız. Bu nedenle örneklem dağılımının standart sapması ne kadar düşükse örnektен hareketle anakütle parametreleri daha iyi tahmin edilebilmektedir. Örneklem dağılımının standart sapmasının örneklem büyülüüğü ile ilişkili olduğuna da dikkat ediniz. Örneklem dağılımına ilişkin örneklem ne kadar büyütürse standart hata o kadar azalmaktadır.

Terminoloji İlişkin Not: Biz burada "örnek (sample)" terimi ile "örneklem (sampling)" terimlerini farklı anımlarda kullanacağız. Bir anakütlenden seçilen belli bir büyülükteki tek bir alt küme için "örnek" terimini ancak anakütlenden çekilen belli bir büyülükteki tüm alt kümeler için "örneklem" terimini tercih edeceğiz.

Şimdi merkezi limit teoremini deneme yoluyla doğrulamaya çalışalım. Önce anakütle normal dağılmış olsun ve küçük bir örnek grubu üzerinde çalışalım. Bunun için anakütleyi temsil eden 1000 tane normal dağılmış rastgele sayı üreteceğiz. Sonra bu rastgele sayılardan örneğin 5'lik ($n < 30$) rastgele 1_000_000 örnek çekip onların ortalamalarına ilişkin histogram çizeceğiz. (Şüphesiz 1000 elemanlı bir kümenin 5'li tüm alt kümelerini ele alamayız. $C(1000, 5)$ çok büyük bir değerdir. Biz 5'li rastgele 1_000_000 değer çekmekle yetineceğiz. Bunun bir hata kaynağı oluşturacağı muhakkaktır.

```
import numpy as np
import matplotlib.pyplot as plt

NPOPULATION = 1000
NSAMPLES = 1_000_000
SAMPLE_SIZE = 5

population = np.random.normal(0, 1, NPOPULATION)
samples = np.random.choice(population, (NSAMPLES, SAMPLE_SIZE))
smeans = np.mean(samples, axis=1)

plt.hist(smeans)
plt.show()

smeans_mean = np.mean(smeans)
population_mean = np.mean(population)
population_std = np.std(population)
smeans_std = np.std(smeans)
```

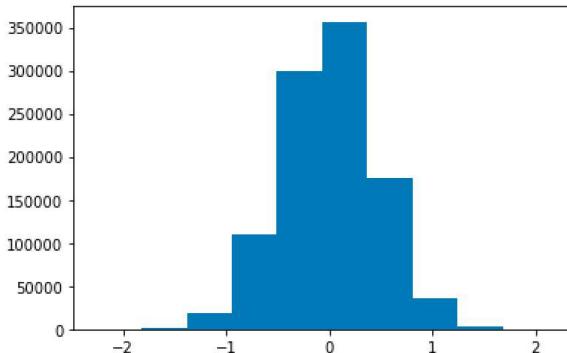
```

sigma_slash_sqrt_n = population_std / np.sqrt(SAMPLE_SIZE)

print(f'Örneklem ortalamalarının ortalaması: {smeans_mean}')
print(f'Anakütle ortalaması: {population_mean}')
print(f'Anakütle standart sapması: {population_std}')
print(f'Örneklem ortalamalarının standart sapması: {smeans_std}')
print(f'sigma / sqrt(n) değeri: {sigma_slash_sqrt_n}')

```

Programın çalıştırılması sonucunda şöyle bir çıktı elde edilmiştir:



```

Örneklem ortalamalarının ortalaması: 0.006341131037852003
Anakütle ortalaması: 0.006536944315343625
Anakütle standart sapması: 1.0182981841666945
Örneklem ortalamalarının standart sapması: 0.4561456393309987
sigma / sqrt(n) değeri: 0.45539679223226576

```

Bu çıktıdan da gördüğünüz gibi örnek ortalamalarının histogramı Gauss eğrisine benzemektedir. Örneklem ortalaması ile anakütle ortalaması arasındaki ve örneklem standart sapması ile anakütləndən hareketlə edilən standart sapma arasındaki küçük fark alınan örneklerin toplam sayısının (1_000_000) az olmasından ve yuvarlama hatalarından kaynaklanmaktadır.

Şimdi aynı denemeyi anakütlənin normal dağılmadığı durum için yineleyelim. Bu kez anakütle düzgün dağılmış olsun ve örneklem büyülüğünü 50 ($n \geq 30$) olarak seçelim. Yine anakütle büyülüğü 10_000 olsun:

```

import numpy as np
import matplotlib.pyplot as plt

NPOPULATION = 10_000
NSAMPLES = 1_000_000
SAMPLE_SIZE = 50

population = np.random.uniform(0, 1, NPOPULATION)
samples = np.random.choice(population, (NSAMPLES, SAMPLE_SIZE))
smeans = np.mean(samples, axis=1)

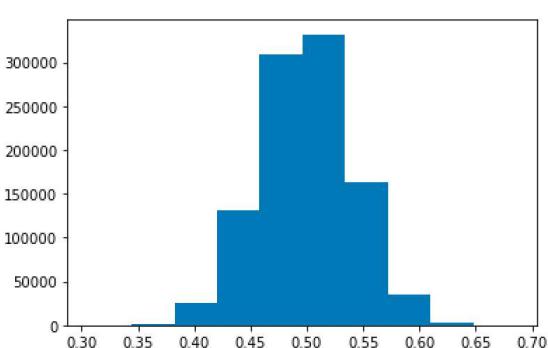
plt.hist(smeans)
plt.show()

smeans_mean = np.mean(smeans)
population_mean = np.mean(population)
population_std = np.std(population)
smeans_std = np.std(smeans)
sigma_slash_sqrt_n = population_std / np.sqrt(SAMPLE_SIZE)

print(f'Örneklem ortalamalarının ortalaması: {smeans_mean}')
print(f'Anakütle ortalaması: {population_mean}')
print(f'Anakütle standart sapması: {population_std}')
print(f'Örneklem ortalamalarının standart sapması: {smeans_std}')
print(f'sigma / sqrt(n) değeri: {sigma_slash_sqrt_n}')

```

Programın çalıştırılması sonucunda elde edilen çıktı şöyledir:



Örneklem ortalamalarının ortalaması: 0.4995729042905874

Anakütle ortalaması: 0.4995699925304928

Anakütle standart sapması: 0.29005119517418737

Örneklem ortalamalarının standart sapması: 0.04108047000586231

σ / \sqrt{n} değeri: 0.041019433399786136

Gördüğünüz gibi anakütlenin normal dağılmadığı ve örneklem büyülüğünün ≥ 30 olduğu durum için de merkezi limit teoremi deneyel olarak doğrulanıyor.

Merkezi limit teoreminin biçimsel (formal) ispatını burada yapmayacağız. Bunun için başka kaynaklara başvurmalısınız.

Normalliğin Test Edilmesi

Parametrik istatistiksel yöntemlerde anakütle ve/veya örneklem dağılımının normal olduğu varsayımları bulunmaktadır. Bu nedenle örneklem dağılımının normal olup olmadığına belli bir örneğe dayalı olarak test edilmesi gereklidir. Aslında normallik testi gözle üstünkörü yapılabılır. Bunun için belli sayıda rastgele değerden oluşan bir örnek için histogram çizilip şeşlin Gauss eğrisine benzeyip benzemediğine bakılabilir.

Normallik testi için çeşitli istatistiksel hipotez testleri geliştirilmiştir. Bunların bazı bakımlardan birbirlerine üstünlükleri ve zayıflıkları vardır. Burada biz konunun ayrıntılarına girmeyeceğiz. Normallik testlerinden birisi Kolmogorov-Smirnov testidir (test ünlü Sovyet matematikçi ve istatistikçi Andrey Kolmogorov ve Nikolai Smirnov tarafından geliştirildiği için bu isimle anılmaktadır). Bu test SciPy kütüphanesindeki stats modülü içerisinde bulunan kstest fonksiyonuyla uygulanabilmektedir.

```
scipy.stats.kstest(rvs, cdf, args=(), N=20, alternative='two-sided', mode='auto')
```

Kolmogorov-Smirnov testi parametrik olmayan istatistiksel bir hipotez testidir. kstest fonksiyonu birinci parametresiyle verilen değerlerin ikinci parametresiyle belirtilen dağılıma uygunluğunu test etmektedir. Eğer kstest fonksiyonun ikinci parametresi 'norm' olarak girilirse bu durumda normal dağılıma uygunluk testi yapılır. Testin H_0 hipotezi söz konusu değerlerin normal dağılmış bir anakütleden geldiği, H_1 hipotezi ise söz konusu değerlerin normal dağılmış bir anakütleden gelmediği biçimindedir. Test işleminden sonra p değeri belirlenen kritik değerden (örneğin 0.05) küçükse H_0 hipotezi reddedilir edilir, H_1 hipotezi kabul edilir. Bu durumda değerler normal dağılıma sahip bir anakütleden gelmemektedir. Eğer p değeri bu kritik değerden büyükse bu durumda H_0 hipotezi kabul edilir, H_1 hipotezi reddedilir. Bu da değerlerin normal dağılmış bir anakütleden geldiği anlamına gelmektedir.

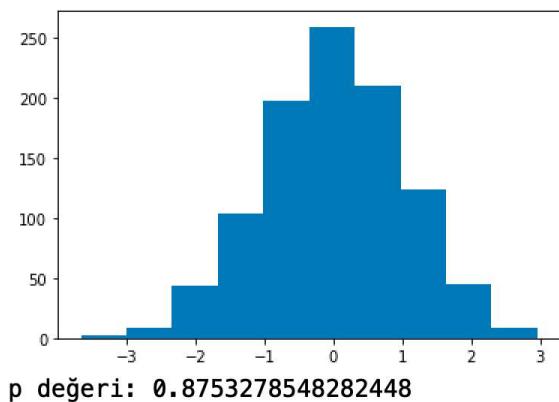
kstest fonksiyonunu KTestResult isimli bir sınıf nesnesine ("isimli demet (named tuple)" nesnesine) geri dönmektedir. Nesnenin statistic elemanı Kolmogorov-Smirnov test istatistiğini, pvalue elemanı ise p değerini vermektedir. Burada uygulamacı p değerine bakmalı eğer bu p değeri belirlediği kritik değerden (alfa) düşükse H_1 hipotezini, yüksekse H_0 hipotezini kabul etmelidir. Yani dağılımın normal olduğunu kabul edebilmemiz için bu pvalue değerinin 0.05 gibi bir kritik değerinden büyük olması gerekmektedir.

Şimdi test amaçlı 1000 tane standart normal dağılıma ilişkin rastgele sayı üretelim. Sonra bu sayılarla Kolmogorov-Smirnov testi uygulayalım:

```
from scipy.stats import kstest, norm
import matplotlib.pyplot as plt

a = norm.rvs(size=1000)
plt.hist(a)
plt.show()
tresult = kstest(a, 'norm')
print(f'p değeri: {tresult.pvalue}')
```

Programın çalıştırılması sonucunda şöyle bir çıktı elde edilmiştir:

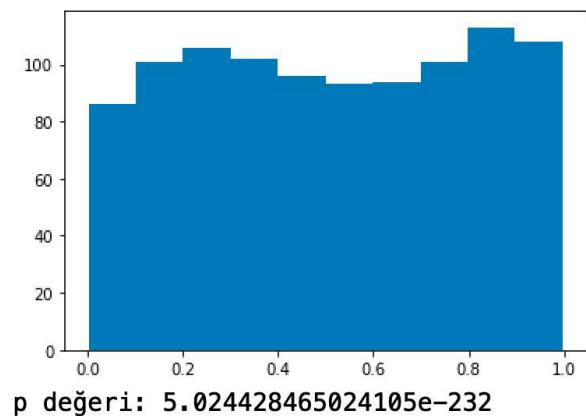


Burada p değerinin 0.05 gibi bir kritik değerden büyük olduğu görülmektedir. O halde bu verilerin normal dağıldığını ya da normal dağılmış bir anakütlede geldiğini varsayılabılır. Şimdi aynı testi düzgün dağılmış rastgele değerlerle gerçekleştirelim:

```
from scipy.stats import kstest, uniform
import matplotlib.pyplot as plt

a = uniform.rvs(size=1000)
plt.hist(a)
plt.show()
tresult = kstest(a, 'norm')
print(f'p değeri: {tresult.pvalue}')
```

Program çalıştırıldığında şöyle bir çıktı elde edilmiştir:



Göründüğü gibi p değeri 0'a çok yakındır. Bu durumda H₀ hipotezi reddedilmektedir. Yani veriler normal dağılıma uygun değildir ya da normal dağılmış bir anakütlede gelmemektedir.

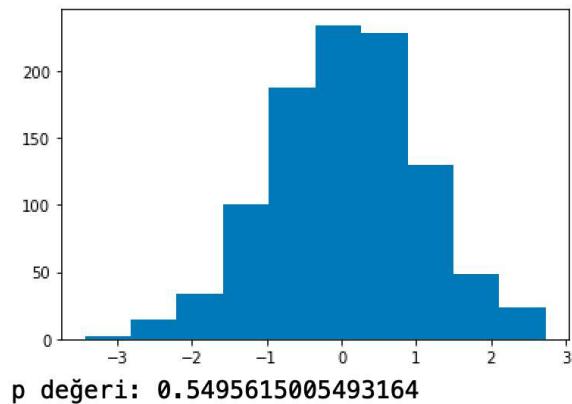
Diğer yaygın kullanılan normallik testlerinden biri de Shapiro-Wilk testidir. Burada biz bu iki testin teknik farklılıklarını üzerinde durmayacağız. Bunun için ilgili kaynaklara başvurabilirsiniz. Shapiro-Wilk testinde de H₀ hipotezi verilerin normal dağılıma ilişkin anakütledeği geldiği, H₁ hipotezi ise verilerin normal dağılıma ilişkin bir anakütledeği gelmediği biçimindedir. Karar yine test sonucunda elde edilen p değerinin kritik değerden küçük olup olmadığına göre verilmektedir.

Shapiro-Wilk testi scipy.stats modülü içerisindeki shapiro fonksiyonu kullanılmaktadır. Fonksiyon dağılım verilerini parametre olarak alır. Şimdi normal dağılmış rastgele değerlerden oluşan veri kümesi üzerinde Shapiro-Wilk testi uygulayalım:

```
from scipy.stats import shapiro, norm
import matplotlib.pyplot as plt

a = norm.rvs(size=1000)
plt.hist(a)
plt.show()
tresult = shapiro(a)
print(f'p değeri: {tresult.pvalue}')
```

Program çalıştırıldığında şöyle bir sonuç elde edilmiştir:

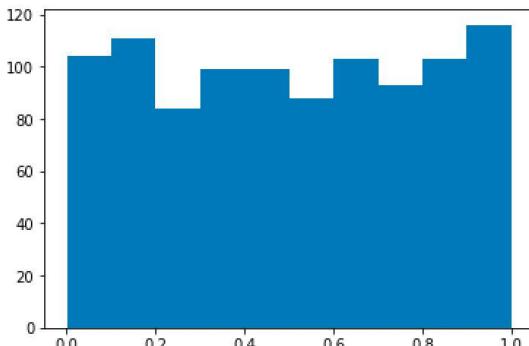


Göründüğü gibi p değeri oldukça yüksektir. Bu durumda H₀ hipotezi kabul edilir. Dolayısıyla örneklem değerleri normal dağılmış bir anakütledeği gelmektedir. Yine aynı denemeyi düzgün dağılmış bir rassal değişken için deneyelim:

```
from scipy.stats import shapiro, uniform
import matplotlib.pyplot as plt

a = uniform.rvs(size=1000)
plt.hist(a)
plt.show()
tresult = shapiro(a)
print(f'p değeri: {tresult.pvalue}')
```

Program çalıştırıldığında şöyle bir sonuç elde edilmiştir:



p değeri: 3.4066265135381214e-18

p değerinin sıfıra çok yakın olduğunu görüyorsunuz. Bu durumda H₀ hipotezi reddedilmektedir. Yani değerler normal dağılmış bir anakütleden gelmemektedir.

Örnektan Hareketle Anakütle Ortalamasının Tahmin Edilmesi ve Güven Aralıkları

Güven aralıkları (confidence intervals) bir anakütleden çekilen örneğe bağlı olarak anakütle parametrelerinin belli bir güven düzeyi (confidence level) içerisinde aralıksal olarak belirlenmesi için kullanılan istatistiksel bir yöntemdir.

Merkezi limit teoremine göre bir anakütleden çekilen örneklemelerin ortalamalarının normal dağıldığını görmüştük. O halde biz bir anakütleden rastgele bir örnek seçip onun ortalamasına bakarak anakütle ortalamasını belli bir güven düzeyinde tahmin edebiliriz.

Güven aralıklarının oluşturulması örnekleme dağılımına bakılarak yapılmaktadır. Eğer anakütle standart sapması biliniyorsa anakütleden seçilen bir örneğin ortalamasından hareketle ana kütle parametreleri tahmin edilebilir. Örneğin elimizde ortalaması 100 standart sapması 15 olan normal dağılmış 1000 adet değer olsun. Biz de bu anakütleden 10 elemanlık rastgele bir örnek seçip onun ortalamasını bulalım:

```
import numpy as np
from scipy.stats import norm
import matplotlib.pyplot as plt

POPULATION_SIZE = 1000
SAMPLE_SIZE = 10

population = norm.rvs(100, 15, POPULATION_SIZE)
population_mean = np.mean(population)
population_std = np.std(population)
sample = np.random.choice(population, SAMPLE_SIZE)
sample_mean = np.mean(sample)

print(f'Anakütle ortalaması: {population_mean}')
print(f'Anakütle standart sapması: {population_std}')
print(f'Selezion örneğin ortalaması: {sample_mean}'')
```

Programın çalıştırılmasıyla şöyle bir çıktı elde edilmiştir:

```
Anakütle ortalaması: 99.96597670217074
Anakütle standart sapması: 14.996297931176969
Seçilen örneğin ortalaması: 104.10574797536367
```

Merkezi limit teoremine göre anakütle normal dağılmışsa örnek ortalamalarının dağılımı da normaldir. Daha önce de belirttiğimiz gibi örneklem dağılımının ortalaması ve standart sapması şöyledir:

$$\mu_{\bar{x}} = \mu$$

$$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$$

O halde eğer bir anakütle standart sapmasını biliyorsak alındığımız tek bir örneğin ortalamasından hareketle anakütle ortalamasını belli bir güven düzeyinde aralıksal olarak tahmin edebiliriz. Yukarıda verdığımız örnekte anakütle standart sapmasını bildiğimizi varsayırsak örneklem dağılımının standart sapması şöyle olacaktır:

```
sampling_std = population_std / np.sqrt(SAMPLE_SIZE)
print(sampling_std)
```

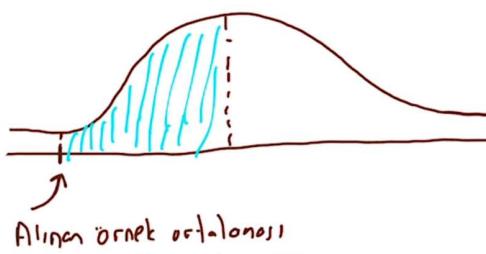
Bu işleminden şöyle bir değer elde edilmiştir:

4.742245793299021

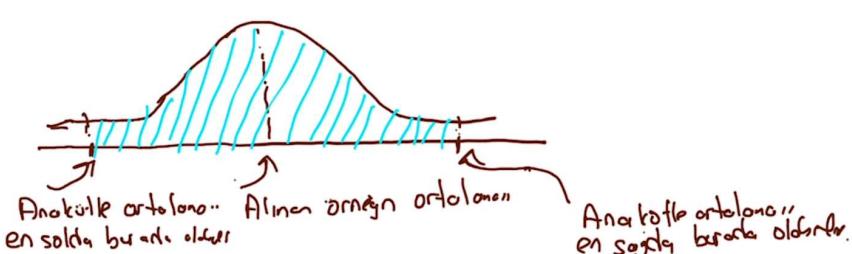
Bu durumda biz örneklem dağılımının standart sapmasını biliyoruz ancak örneklem dağılımının ortalamasını bilmiyoruz. Örneklem dağılımının ortalamasının anakütle ortalamasına eşit olması gerektiğini anımsayınız. Normal dağılım eğrisinde ortalama, egrinin X ekseniye göre konumu üzerinde etkili olmaktadır. O halde tüm bu bilgiler eşliğinde rastgele seçilen bir örnektenden hareketle anakütle ortalamasının belli bir güven düzeyinde hangi aralıklarda olabileceğini belirleyebiliriz. Örneğin rastgele seçilen bir örnektenden hareketle anakütle ortalamasının %95 güven düzeyinde hangi aralıktan olabileceğini anlamaya çalışalım. Aldığımız örnek en kötü olasılıkla anakütle ortalamasının 0.475 sağında olabilir. Aşağıdaki şekli inceleyiniz:



Yine alınan örnek en kötü olasılıkla anakütle ortalamasının 0.475 solunda olabilir:



Bu durumda anakütle ortalaması için 0.95 güven aralığı aslında alınan örnek ortalamasının solunda ve sağında 0.475 alana ilişkin X değerleridir:



Şimdi yukarıdaki örnek için 0.95 güven düzeyinde güven aralıklarını oluşturalım. Aldığımız örneğin ortalaması 104.10574797536367 idi. O halde ortalaması bu olan ve standart sapması 4.742245793299021 olan normal dağılımda 0.025 ve 0.975 birikimli olasılık değerini veren noktaları bulalım:

```

lower_bound = norm.ppf(0.025, 104.1057479753636, 4.742245793299021)
upper_bound = norm.ppf(0.975, 104.1057479753636, 4.742245793299021)

print(lower_bound, upper_bound)

```

Buradan şöyle bir çıktı elde edilmiştir:

94.81111701466094 113.40037893606626

Bu örneğimizde biz belli bir anakütleden çektiğimiz örneğe dayanarak anakütle ortalamasının %95 güven aralığında bu sınırlar içerisinde olabileceğini anlamış olduk. Aslında bunu standart normal dağılımin kullanımacağı biçimde şöyle de formülize edebiliriz:

$$\bar{x} \pm z\sigma_{\bar{x}}$$

Buradaki z değeri güven düzeyine karşı gelen X eksenindeki değerdir. $\sigma_{\bar{x}}$ ise örneklem dağılımının standart sapması olan σ / \sqrt{n} değeridir.

Şimdi standart sapması 10 olan bir anakütleden çekilen 100'lük bir örneğin ortalamasının 65 olduğunu varsayıyalım. Anakütle ortalaması 0.95 güven düzeyi içerisinde şöyle hesaplanacaktır:

```

import numpy as np
from scipy.stats import norm

lower_bound = 65 + norm.ppf(0.975) * 10 / np.sqrt(100)
upper_bound = 65 - norm.ppf(0.975) * 10 / np.sqrt(100)
print(lower_bound, upper_bound)

```

Buradan şu çıktı elde edilmiştir:

63.04003601545995 66.95996398454005

Tabii aynı işlemi şöyle de yapabilirdik:

```

lower_bound = norm.ppf(0.975, 65, 10 / np.sqrt(100))
upper_bound = norm.ppf(0.025, 65, 10 / np.sqrt(100))
print(lower_bound, upper_bound)

```

Aslında güven aralıkları için norm nesnesine ilişkin sınıfta interval isimli bir metot da bulundurulmuştur. interval metodu üç parametre almaktadır. Metodun birinci parametresi güven aralığını, ikinci parametresi ortalama değeri, üçüncü parametresi ise standart sapmayı belirtir. Fonksiyon güven aralığının düşük ve yüksek değerlerine ilişkin bir demete geri dönmektedir. Bu durumda standart sapması 10 olan bir anakütleden çekilen 65 ortalamaya sahip 100'lük bir örnekten hareketle anakütlenin ortalamasını %95 güven düzeyinde şöyle belirleyebiliriz:

```

import numpy as np
from scipy.stats import norm

ci = norm.interval(0.95, 65, 10 / np.sqrt(100))
print(ci)

```

Programın çalıştırılmasıyla şu çıktı elde edilmiştir:

(63.04003601545995, 66.95996398454005)

Merkezi limit teoremine göre eğer ana kütle normal dağılmamışsa ancak $n \geq 30$ koşulunu sağlayan örneklem dağılımlarının normal dağıldığı kabul edilmektedir. Yani örneklerimizdeki gibi anakütle ortalamasının tahmin edilmesi ve güven aralıklarının oluşturulması için şu iki koşuldan en az biri sağlanmalıdır:

1) Anakütle normal dağılmıştır ve örneklem dağılımı için $n < 30$ durumu söz konusudur.

2) Anakütle normal dağılmamıştır ve örneklem dağılımı için $n \geq 30$ durumu söz konusudur.

Pekiyi anakütle normal dağılmamışsa ve $n < 30$ ise ne olacaktır? İşte bu durumda biz yukarıda uygulandığı biçimde anakütle ortalamasını ve güven aralıklarını belirleyemeyiz. Bu durumda "parametrik olmayan" başka yöntemler kullanılabilmektedir. Ancak biz bu yöntemleri burada ele almayacağız.

Merkezi limit teoremine göre bizim anakütle ortalamasını örnekten hareketle tahmin edebilmemiz için anakütle standart sapmasını biliyor olmamız gereklidir. Pekiyi ya bunu bilmiyorsak ne yapabiliriz? Örneğin aşağıdaki gibi bir soruyu nasıl çözebiliriz?

İşte eğer anakütle standart sapması bilinmiyorsa bu durumda t dağılımı kullanılmaktadır. (Zaten William Gosset t dağılımını anakütle standart sapmasının bilinmediği durumda örneklerden anakütle parametrelerini tahmin etmeye çalışırken geliştirmiştir.) Anakütle standart sapması bilinmiyorsa alınan örneğin standart sapması sanki anakütlünün standart sapmayışı gibi ele alınmaktadır. t dağılımının bir serbestlik derecesi (degrees of freedom) parametresinin olduğunu anımsayınız. Burada serbestlik derecesi örnek büyüğünün 1 eksik değeridir. Anakütle standart sapmasının bilinmemesi durumunda da örneklem dağılımına ilişkin örneklem büyüğü önemli olmaktadır. Eğer alınan örnek büyük değilse (< 30) anakütlünün normal dağılmış olması gerekmektedir. Eğer alınan örnek yeteri kadar büyükse (≥ 30) bu durumda anakütle dağılımı normal olmak zorunda değildir.

Şimdi elimizde bir anaküyleden çekilmiş olan 35 elemandan oluşan aşağıdaki gibi bir örneklem olsun:

```
sample = np.array([101.93386212, 106.66664836, 127.72179427, 67.18904948,
    87.1273706 , 76.37932669, 87.99167058, 95.16206704,
    101.78211828, 80.71674993, 126.3793041 , 105.07860807,
    98.4475209 , 124.47749601, 82.79645255, 82.65166373,
    92.17531189, 117.31491413, 105.75232982, 94.46720598,
    100.3795159 , 94.34234528, 86.78805744, 97.79039692,
    81.77519378, 117.61282039, 109.08162784, 119.30896688,
    98.3008706 , 96.21075454, 100.52072909, 127.48794967,
    100.96706301, 104.24326515, 101.49111644])
```

Şimdi %95 güven düzeyinde anakütle ortalamasının hangi aralıklar içerisinde olabileceğini bulmaya çalışalım. Burada biz anakütle standart sapmasını bilmiyoruz. Anakütlünün normal dağılıp dağılmadığını da bilmediğimizi düşünelim. (Örnekten hareketle anakütlünün normal dağılıp dağılmadığını daha önce görmüş olduğumuz normallik testleriyle belirleyebilirsiniz.) Bu durumda anakütle ortalaması için aralık tahmini t dağılımı kullanılarak yapılmalıdır. Öncelikle bu örneğin ortalamasını ve standart sapmasını bulalım:

```
sample_mean = np.mean(sample)
sample_std = np.std(sample)
```

Örneğin standart sapmasını anakütlünün standart sapması kabul ederek örneklem dağılımının standart sapmasını bulalım:

```
sampling_std = sample_std / np.sqrt(35)
```

Örnek büyüğü 35 olduğuna göre serbestlik derecesi 34 olacaktır. Artık t dağılımından hareketle güven aralığını bulabiliriz:

```
from scipy.stats import t

lower_bound = t.ppf(0.025, 34, sample_mean, sampling_std)
upper_bound = t.ppf(0.975, 34, sample_mean, sampling_std)
print(lower_bound, upper_bound)
```

Şöyledir bir çıktı elde edilmiştir:

94.89296371821018 105.02201556521837

Tabii aynı işlemleri t nesnesine ilişkin sınıfın interval metoduyla da yapabilirdik:

```
ci = t.interval(0.95, 34, sample_mean, sampling_std)  
print(ci)
```

Güven aralıklarının daha güvenilir biçimde elde edilebilmesi için örneklem üzerinde "bootstrap" denilen yöntem tercih edilebilmektedir. "Bootstrap" yöntemi kursumuzda "ensemble" yöntemlerin ele alındığı bölümde açıklanmaktadır.

VERİ KÜMELERİNİN KULLANIMA HAZIR HALE GETİRİLMESİ

Istatistiksel veri analizi ve makine öğrenmesi uygulamalarında veriler bir biçimde toplandıktan sonra onların "veri kümeleri (datasets)" biçiminde düzenlenmesi gereklidir. Veri kümeleri satırlardan ve sütunlardan oluşmaktadır. Veri kümelerinin satırları belli bir varlığa ilişkin bilgileri, sütunları ise bu varlıkların belli özelliklerini temsil ederler.

Terminolojiye İlişkin Not: Biz kursumuzda "veri kümesi (dataset)" yerine bazen "veri tablosu (data table)" da diyeceğiz. Veri kümelerinin satırlarına da bazen "satır (row)" baze de "kayıt (record)" diyeceğiz. Veri kümelerinin sütunlarına istatistikte daha çok "özellik (feature)" denilmektedir. Ancak biz kursumuzda veri kümelerinin sütunlarına bazen "sütun (column)", baze de "özellik (feature)" diyeceğiz.

Veri kümelerini ilişkisel veritabanlarındaki veritabanı tablolarına da benzetilebilir. Örnek bir veri kümesi şöyle olabilir:

Medeni Durum	Yaş	Eğitim Durumu	Maaş
Evlı	37	Lise	3850
Bekar	40	Üniversite	7360
Evlı	28	Lise	2700
...

Burada Medeni Durum, Yaş, Eğitim Durumu ve Maaş veri kümelerinin sütunları t-yani özellikleridir. Satırlar da kayıtları oluşturmaktadır. Yukarıdaki örnekte de gördüğünüz gibi bir veri tablosunda sütunlar farklı ölçek türlerine ilişkin olabilmektedir. Örneğin yukarıdaki tabloda "Medeni Durum" sütunu kategorik (nominal), "Eğitim Durumu" sütunu sırasal (ordinal) ölçeklere ilişkindir. Ancak "Yaş" ve "Maaş" sütunları oransal (ratio) ölçüye ilişkindir.

Veri tabloları genellikle dosyalarda saklanırlar. Bunun için çeşitli dosya formatları kullanılabilir. Ancak makine öğrenmesi uygulamalarında en yaygın kullanılan dosya formatı CSV (Comma Separated Values) formatıdır. Bir CSV dosyası satırlardan oluşmaktadır. Satırlardaki elemanlar ',' karakteri ile birbirlerinden ayrılmıştır. CSV dosyalarında isteğe bağlı olarak sütunların ne anlam ifade ettiklerini belirten başlık kısımları da bulunabilmektedir. Bu başlık kısımları bizim için bazeen gerekli bazeen de gereksiz olabilir. Örneğin bu başlıklar eğer CSV dosyası Pandas kütüphanesindeki `read_csv` fonksiyonuyla okunuyorsa bu fonksiyon başlık kısmındaki DataFrame nesnesindeki sütun isimleri haline dönüştürülmemektedir. Biz de DataFrame indekslemesinde bu sütun isimlerinden faydalananabiliz. Kursumuzda veri kümeleri için ağırlıklı biçimde CSV dosyalarını kullanacağz. Yukarıdaki örnek veri tablosunun CSV dosya formatındaki görünümü aşağıdaki gibidir:

Medeni Durum,Yaş,Eğitim Durumu,Maaş
Evlı,37,Lise,3850
Bekar,40,Üniversite,7360
Evlı,28,Lise,2700
...

Alıntı Notu: Aşağıdaki gruplandırma "Data Preparation for Machine Learning - Jason Brownlee" isimli kitaptan alınmıştır ve bölüm içerisinde bu kitaptan faydalılmıştır. Okuyucunun bu kitabı baştan sona gözden geçirmesini tavsiye ediyoruz.

Verilerin kullanıma hazır hale getirilmesi süreci aslında ayrıntılı bir konudur. Bu nedenle biz kursumuzda önce genel bir açıklama yapıp sonra gerekli yerlerde gerekli yöntemleri ele alacağız. Genel olarak bir veri tablosunun kullanıma hazır hale getirilmesi için beş yöntem grubu kullanılmaktadır. Şimdi bu yöntem grupları hakkında temel bilgiler verelim.

1) Verilerin Temizlenmesi (Data Cleaning): Veriler içerisinde geçersiz olan değerler söz konusu olabilir. Geçersiz veriler bazen mevcut olmayan (nan/None) veriler biçiminde, bazen bozulmuş veriler biçiminde, bazen de yinelenen (mükerrer) veriler biçiminde karşımıza çıkabilmektedir. Veri bilimcisinin bu verileri dikkate alıp bunları ortadan kaldırmaya yönelik teknikleri uygulaması gereklidir. Örneğin bu tür durumlarda geçersiz verilerin bulunduğu satırlar ya da sütunlar tablodan tümden atılabilir ya da geçersiz değerler yerine başka değerler (tipik olarak ortalama değerler ya da mod değerleri) yerleştirilebilir. Bazen aşırı uçtaki bazı değerler de bozucu etkiler yaratmaktadır. Bu aşırı uçtaki değerlerden kurtulmak gerekebilir. Bazı veri tablolarında ise birbirile yüksek korelasyona sahip olan sütunlar da bulunabilmektedir. Bize ek bir bilgi vermeyen bu tür sütunların bazlarının atılması işlenecek verinin miktarını düşürmektedir.

2) Özelliğin Seçimi (Feature Selection): Özelliğin seçimi veri tablosundaki sütunların gerekli olanlarının alınıp gereksiz olanlarının atılması ile ilgili bir hazırlık etkinliğidir. Örneğin veri tablosunun bir sütununda kişinin ismi olabilir ve bu ismin kestirim sürecinde hiçbir etkisi olmamıştır. Bu durumda bu sütunun atılması gerekebilir. Bazen çok sayıda sütunun nispeten özensiz olanlarının atılması da uygun olabilmektedir. Uygun sütunların seçilmesi süreci sütun türlerine ve amaçlanan hedefe bağlı olarak da değişebilmektedir.

3) Verilerin Dönüşürtülmesi (Data Transformation): Verilerin dönüşürtülmesi verilerin türlerini ya da dağılımını değiştirmek için kullanılan yöntemlerdir. Makine öğrenmesinde sıralı ve kategorik veriler doğrudan kullanılamamaktadır. Bunların algoritmalarla sokulmadan önce sayısal biçimde dönüştürülmesi gereklidir. İşte sıralı ve kategorik verilerin sayısal biçimde dönüştürülmesi en çok uygulanan veri dönüştürmesi yöntemlerindendir. Veri dönüştürmesi sırasında bazen bunun tersi de yapılmaktadır. Örneğin sayısal verilerin sıralı biçimde dönüştürülmesi de gerekmektedir. Bu işleme "ayrık hale getirme (discretization transform)" denilmektedir. Kategorik verilerin sayısal biçimde dönüştürülmesinde en sık uygulanan yöntemlerden biri "one hot encoding" denilen yöntemdir. Bu yöntemde kategorik veri birden fazla sütunu olan ikili (binary) veri haline dönüştürülmemektedir. Bazen veri tablolarının sütunları arasında skala farklılıklar olabilmektedir. Bu skala farklılıklarını pek çok algoritmada bozucu etkiler yaratılmaktadır. Bunları ortadan kaldırmak için "ölçekleme (scaling)" işlemleri yapılmaktadır.

4) Özelliğin Mühendisliği (Feature Engineering): Özelliğin mühendisliği var olan sütunlardan yeni sütunlar oluşturma sürecine ilişkin yöntemlere denilmektedir. Örneğin bir sütunda varlıklarla ilişkin tarih bilgileri olabilir. Biz de bu tarih bilgilerinden hareketle o tarihlerin hafta sonu olup olmadığını belirten kategorik bir sütunu tabloya ekleyebiliriz.

5) Boyutsal Özelliğin İndirgemesi (Dimensionality Feature Reduction): Veri tablosundaki sütunlar aslında çok boyutlu uzaydaki boyutlar olarak düşünülebilir. Örneğin iki sütunlu verilerdeki satırlar iki boyutlu bir düzlemede nokta belirtirler. Boyut indirgemesi de aslında çok sayıda sütunu temsil edebilen daha az sayıda sütun oluşturulması sürecidir. Boyut indirgemesi için "temel bileşenler analizi (principal components analysis)", "tekil değer ayrıştırması (singular value decomposition)", "doğrusal ayrımlı analizi (linear discriminant analysis)" gibi yöntemler kullanılmaktadır.

Veri Tablolarının Gereksiz Sütunlardan Arındırılması

Veri tablolarının gereksiz sütunlardan arındırılması birkaç biçimde yapılmaktadır. Eğer bir CSV dosyası söz konusu ise gereksiz sütunlar daha CSV dosyasından okuma yapılmırken (örneğin NumPy kütüphanesindeki loadtxt ya da Pandas kütüphanesindeki read_csv fonksiyonlarıyla) işin başında atılabilir. Örneğin aşağıdaki gibi bir CSV dosyası olsun:

```
Adı Soyadı,Boy,Kilo,Doğum Yeri  
Ali Bulut,182,89,Eskişehir  
Erol Öner,187,82,İzmir  
Ayşe Tan,172,58,Urfâ  
Rasim Taşcan,168,92,Samsun
```

Dosyanın isminin "test.csv" olduğunu varsayıyalım. Şimdi bu veri tablosunun "Adı Soyadı" ve "Doğum Yeri" sütunlarını atmak isteyelim. loadtxt fonksiyonun usecols parameteresinin dosyadan elde edilecek satırları belirlemek için kullanıldığını anımsayınız. Bu tabloda "Boy" 1 numaralı sütunu, "Kilo" ise 2 numaralı sütunu belirtmektedir. Okuma işlemi şöyle yapılabilir:

```
import numpy as np

data = np.loadtxt('test.csv', delimiter=',', encoding='utf-8', skiprows=1, usecols=(1, 2),
dtype=np.float32)
print(data)
```

İşlemden şöyle bir çıktı elde edilmiştir:

```
[[182.  89.]
 [187.  82.]
 [172.  58.]
 [168.  92.]]
```

Tabii tablonun hepsini okuyup söz konusu iki sütunu delete fonksiyonu ile axis=1 parametresini kullanarak da silebilirdik. Ancak bu işlem daha yorucu olurdu:

```
import numpy as np

data = np.loadtxt('test.csv', delimiter=',', encoding='utf-8', skiprows=1, dtype=np.object)
data = np.delete(data, [0, 3], axis=1).astype(np.float32)
print(data)
```

Sayısal olmayan sütunları okurken dtype=object verildiğine dikkat ediniz. Bu durumda satırların hepsi string olarak elde edilmektedir. astype metodu string olan sütunların np.float32 türüne dönüştürülmesi için kullanılmıştır.

CSV dosyalarını okuyup gereksiz sütunları atmak için numpy.loadtxt fonksiyonu yerine Pandas kütüphanesindeki read_csv fonksiyonu da kullanılabilir. read_csv fonksiyonu loadtxt fonksiyonu ile benzer işlevselligi sahiptir. Ancak read_csv fonksiyonu CSV dosyalarını okuma konusunda daha yeteneklidir. Şimdi aynı işlemleri read_csv fonksiyonu ile yapalım:

```
import pandas as pd

data = pd.read_csv('test.csv', encoding='utf-8', usecols=(1, 2))
print(data)
```

Kodun çalıştırılması sonucunda şöyle bir çıktı elde edilmiştir:

```
   Boy   Kilo
0  182    89
1  187    82
2  172    58
3  168    92
```

Burada CSV dosyasındaki başlık isimlerinin sütun isimleri haline getirildiğine dikkat ediniz. Tabii aslında Pandas'ta biz yine tüm tabloyu okuduktan sonra da belli sütunları atabiliyoruz:

```
import pandas as pd

df = pd.read_csv('test.csv', encoding='utf-8')
df = df[['Boy', 'Kilo']]
print(df)
```

Burada önce tüm tabloyu okuduktan sonra dilimleme ile belli sütunları aldığıma dikkat ediniz. Elde edilen çıktı aynı olacaktır:

```
Boy Kilo
0 182   89
1 187   82
2 172   58
3 168   92
```

Şimdi de müşterilerin kredi kartı ödemelerini yapıp yapmadıkları ile ilgili bilgileri içeren "bank.csv" dosyasından bazı sütunları atalım. Bu dosyayı dosyayı <https://www.kaggle.com/janiobachmann/bank-marketing-dataset/data> adresinden indirebilirsiniz. Dosyanın çalışma dizininde bulunduğu varsayacağımız. Dosyanın genel görünümü aşağıdaki gibidir:

```
age,job,marital,education,default,balance,housing,loan,contact,day,month,duration,campaign,pdays,previous
,poutcome,deposit
59,admin.,married,secondary,no,2343,yes,no,unknown,5,may,1042,1,-1,0,unknown,yes
56,admin.,married,secondary,no,45,no,no,unknown,5,may,1467,1,-1,0,unknown,yes
41,technician,married,secondary,no,1270,yes,no,unknown,5,may,1389,1,-1,0,unknown,yes
55,services,married,secondary,no,2476,yes,no,unknown,5,may,579,1,-1,0,unknown,yes
54,admin.,married,tertiary,no,184,no,no,unknown,5,may,673,2,-1,0,unknown,yes
42,management,single,tertiary,no,0,yes,yes,unknown,5,may,562,2,-1,0,unknown,yes
56,management,married,tertiary,no
....
```

Burada örneğin 8'inci (contact) ve 15'inci (poutcome) sütunlarını atmak isteyelim. Bunun için Pandas'ın read_csv fonksiyonu NumPy'in loadtxt fonksiyonundan daha kolay bir seçenektrir:

```
import pandas as pd

df = pd.read_csv('bank.csv')
df.drop(['contact', 'poutcome'], axis=1, inplace=True)
print(df)
```

Kodun çalıştırılması sonucunda oluşan çıktıyı inceleyiniz:

```
      age      job marital education ... campaign pdays previous deposit
0      59    admin. married secondary ...        1     -1       0     yes
1      56    admin. married secondary ...        1     -1       0     yes
2      41 technician married secondary ...        1     -1       0     yes
3      55   services married secondary ...        1     -1       0     yes
4      54    admin. married tertiary ...        2     -1       0     yes
...
11157   33 blue-collar single primary ...        1     -1       0     no
11158   39   services married secondary ...        4     -1       0     no
11159   32 technician single secondary ...        2     -1       0     no
11160   43 technician married secondary ...        2    172       5     no
11161   34 technician married secondary ...        1     -1       0     no
```

Kategorik (Nominal) ve Sıralı (Ordinal) Verilerin Sayısal Biçime Dönüşürülmesi

Tipik bir veri tablosunda kişinin cinsiyeti, medeni durumu, yaşadığı ülke gibi kategorik (nominal) ve sıralı (ordinal) sütunlar bulunabilmektedir. Veri biliminde ve makine öğrenmesinde pek çok yöntem ve algoritma kategorik ve sıralı veriler üzerinde doğrudan işlem yapamamaktadır. Bu nedenle önce kategorik ve sıralı verilerin sayısal biçimde dönüştürülmeleri gereklidir. Bu nedenle kategorik ve sıralı verilerin sayısal biçimde dönüştürülmesi verileri hazır hale getirme sürecinde kullanılan en önemli veri dönüştürme (data transformation) yöntemlerinden biridir.

Kategorik (Nominal) Verilerin Sayısal Biçime Dönüştürülmesi

Kategorik verilerde her bir kategori için 0'dan itibaren farklı bir tam sayı karşılık düşürülmesi yoluna gidilebilir. Tabii buradaki değerler arasında bir sıralama ilişkisi olmadığı için bu tam sayılar büyülü küçüklük belirtmeyecek yalnızca farklı kategorileri belirtecektir. Bu tür kategorik sütunların farklı tam sayılar biçiminde sayısal olarak ifade edilmesini kolaylaştırmak için NumPy ya da Pandas kütüphanelerinde hazır bir fonksiyon ya da metot bulunmaktadır. Bu işlem en kolay olarak sklearn (Scikit-learn) kütüphanesindeki LabelEncoder sınıfı ile yapılabilir. Bu sınıf sklearn.preprocessing paketi içerisinde yer almaktadır. Dönüşürme için önce LabelEncoder sınıfı türünden bir nesne yaratılır. Örneğin:

```
from sklearn.preprocessing import LabelEncoder  
le = LabelEncoder()
```

Sonra LabelEncoder sınıfının fit isimli metodu bizden kategorik ölçekteki değerleri alır. Sınıfın transform metodu da dönüştürülecek kategorik değerleri alarak 0'dan itibaren sayısal değerlere dönüştürmektedir. LabelEncoder sınıfının classes_ isimli örnek özniteliği ile fit işlemi sırasında verilen kategorik değerler elde edilebilir. Örneğin:

```
from sklearn.preprocessing import LabelEncoder  
  
le = LabelEncoder()  
le.fit(['mavi', 'kırmızı', 'yeşil', 'beyaz'])  
data = ['mavi', 'kırmızı', 'mavi', 'yeşil', 'beyaz', 'yeşil', 'kırmızı']  
result = le.transform(data)  
  
print(data)  
print(result)  
print(le.classes_)
```

Kodun çıktısı şöyledir:

```
['mavi', 'kırmızı', 'mavi', 'yeşil', 'beyaz', 'yeşil', 'kırmızı']  
[2 1 2 3 0 3 1]  
['beyaz' 'kırmızı' 'mavi' 'yeşil']
```

Göründüğü gibi fit metodu bizden kategorik ölçek değerlerini almış, transform ise bunları dönüştürmüştür. Biz bu örnekte metotlara Python listeleri verdik. Tabii uygulamada tipik olarak bu metotlara NumPy dizileri verilmektedir. Aslında fit ve transform işlemi bir arada fit_transform metoduyla da yapılabilmektedir:

```
from sklearn.preprocessing import LabelEncoder  
  
le = LabelEncoder()  
data = ['mavi', 'kırmızı', 'mavi', 'yeşil', 'beyaz', 'yeşil', 'kırmızı']  
result = le.fit_transform(data)  
  
print(data)  
print(result)  
print(le.classes_)
```

Burada fit_tranform doğrudan dönüştürülecek verileri bizden almıştır. Metot bu verileri önce fit metoduna sonra da transform metoduna sokmaktadır. Sınıfın fit metodu aynı kategorik değerler birden fazla kez kullanılmışsa onları zaten dikkate almaz. Yukarıdaki koddan elde edilen çıktı öncekiyle aynı olacaktır:

```
['mavi', 'kırmızı', 'mavi', 'yeşil', 'beyaz', 'yeşil', 'kırmızı']  
[2 1 2 3 0 3 1]
```

```
['beyaz' 'kırmızı' 'mavi' 'yeşil']
```

Burada önemli bir noktaya dikkatinizi çekmek istiyoruz. Bu sınıf ile yapılan dönüştürmede hangi kategorik değerin hangi sayıyla ifade edileceğini biz belirleyememekteyiz. fit metodu verilen kategorik değerleri numpy.unique fonksiyonuna saptıktan sonra onlara 0'dan itibaren değerler karşılık düşürmektedir. numpy.unique fonksiyonun yinelenenleri attıktan sonra buna ek olarak sıraya dizme işlemi yaptığı da anımsayınız. Yani bu durumda aslında bizim fit ya da fit_transform metodlarına verdığımız kategoriler alfabetik olarak sıraya dizildikten sonra onlara numaralar atanmış olmaktadır. Gerçekten de yukarıdaki örnekte beyazın 0, kırmızının 1 olduğuna dikkat ediniz. Buradan LabelEncoder sınıfının eğer kategorik isimler sıralı değilse sıralı veriler için kullanılamayacağı sonucunu çıkarabiliriz.

LabelEncoder sınıfının fit ve fit_transform metodlarına aslında biz kategorik verileri yazışal biçimde vermek zorunda değiliz. Kategorik veriler zaten sayısal biçimde de bulunuyor olabilir. Örneğin kategorik verilerin şehirlerin plaka numaralarından oluştuğunu düşünelim:

```
from sklearn.preprocessing import LabelEncoder

le = LabelEncoder()
data = [34, 26, 37, 34, 6, 77, 10, 16, 35, 34, 6]
result = le.fit_transform(data)

print(data)
print(result)
print(le.classes_)
```

Kodun çıktısı şöyle olacaktır:

```
[34, 26, 37, 34, 6, 77, 10, 16, 35, 34, 6]
[4 3 6 4 0 7 1 2 5 4 0]
[ 6 10 16 26 34 35 37 77]
```

Şimdi aynı işlemi bir CSV dosyasından hareketle yapalım. Örneğimizdeki "test.csv" dosyası şöyle olsun:

```
Cinsiyet,Kilo,Boy,Şehir
Erkek,85,172,Eskişehir
Kadın,72,170,İzmir
Kadın,65,162,İstanbul
Erkek,92,183,İstanbul
Kadın,62,173,Ankara
Erkek,98,172,İzmir
```

Burada ilk ve son sütundaki kategorik verileri sayısal biçimde şöyle dönüştürebiliriz:

```
import pandas as pd
from sklearn.preprocessing import LabelEncoder

df = pd.read_csv('test.csv')
print(df)

le = LabelEncoder()
df['Cinsiyet'] = le.fit_transform(df['Cinsiyet'])
print(le.classes_)
df['Şehir'] = le.fit_transform(df['Şehir'])
print(le.classes_)
print(df)
```

```
dataset = df.to_numpy()
print(dataset)
```

Kodun çalıştırılması sonucunda şöyle bir çıktı elde edilmiştir, inceleyiniz:

```
Cinsiyet  Kilo   Boy      Şehir
0    Erkek     85  172  Eskisehir
1    Kadın     72  170       Izmir
2    Kadın     65  162  Istanbul
3    Erkek     92  183  Istanbul
4    Kadın     62  173   Ankara
5    Erkek     98  172  Izmir
['Erkek' 'Kadın']
['Ankara' 'Eskişehir' 'İstanbul' 'İzmir']
Cinsiyet  Kilo   Boy  Şehir
0          0    85  172    1
1          1    72  170    3
2          1    65  162    2
3          0    92  183    2
4          1    62  173    0
5          0    98  172    3
[[ 0  85 172  1]
 [ 1  72 170  3]
 [ 1  65 162  2]
 [ 0  92 183  2]
 [ 1  62 173  0]
 [ 0  98 172  3]]
```

LabelEncoder sınıfının fit, transform ve fit_transform metotları hem Python listeleriyle hem NumPy dizileriyle hem de Pandas'ın Series nesneleriyle çalışabilmektedir. transform ve fit_transform sonucu her zaman ndarray olarak vermektedir.

LabelEncoder sınıfının inverse_transform metodu tam tersi bir işlemi yapmaktadır. Yani bu metoda biz sayısal verileri verirsek o bize kategorik değerlerden oluşan bir NumPy dizisi verir. Tabii inverse_transform metodunu kullanmadan önce bir fit işleminin yapılmış olması gereklidir.

sklearn.preprocessing modülünde LabelEncoder sınıfıyla benzer işlemi yapan OrdinalEncoder isimli bir sınıf da vardır. OrdinalEncoder aslında LabelEncoder sınıfının birden çok sütunu aynı anda alarak işlem yapan bir biçimi gibidir. OrdinalEncoder sınıfında oluşturulan kategoriler sınıfın categories_ özniteliği ile bize bir NumPy listesi olarak verilmektedir. Örneğin:

```
from sklearn.preprocessing import OrdinalEncoder

data = [['mavi', 'erkek'], ['kırmızı', 'kadın'], ['siyah', 'kadın'], ['mavi', 'kadın'],
        ['beyaz', 'kadın'], ['yeşil', 'kadın']]

oe = OrdinalEncoder()
result = oe.fit_transform(data)
print(result)
print(oe.categories_)
```

Şimdi önceki örnekteki "test.csv" dosyasını OrdinalEncoder sınıfıyla dönüştürelim:

```
import pandas as pd
from sklearn.preprocessing import OrdinalEncoder

df = pd.read_csv('test.csv')
```

```

print(df)

oe = OrdinalEncoder()
df[['Cinsiyet', 'Şehir']] = oe.fit_transform(df[['Cinsiyet', 'Şehir']])
print(df)
dataset = df.to_numpy()
print(dataset)

```

Kodun çıktısı şöyle olacaktır:

	Cinsiyet	Kilo	Boy	Şehir
0	Erkek	85	172	Eskişehir
1	Kadın	72	170	İzmir
2	Kadın	65	162	İstanbul
3	Erkek	92	183	İstanbul
4	Kadın	62	173	Ankara
5	Erkek	98	172	İzmir

	Cinsiyet	Kilo	Boy	Şehir
0	0.0	85	172	1.0
1	1.0	72	170	3.0
2	1.0	65	162	2.0
3	0.0	92	183	2.0
4	1.0	62	173	0.0
5	0.0	98	172	3.0

[[0.	85.	172.	1.]
[1.	72.	170.	3.]
[1.	65.	162.	2.]
[0.	92.	183.	2.]
[1.	62.	173.	0.]
[0.	98.	172.	3.]]

OrdinalEncoder sınıfının fit, transform ve fit_transform metotları iki boyutlu Python listeleriyle, NumPy dizileriyle ya da Pandas'ın DataFrame nesneleriyle çalışabilmektedir. Bu metotlarla tek boyutlu bir liste, NumPy dizisi ya da Series nesnesi ile kullanılamamaktadır. transform ve fit metotları bize her zaman sayısallaştırılmış verileri NumPy dizisi olarak verdiği de dikkat ediniz.

OrdinalEncoder sınıfının da inverse_transform isimli bir metodu vardır. Bu metot çok boyutlu bir Python listesini, NumPy dizisini ya da Pandas DataFrame nesnesini parametre olarak alıp kategorik değerlere ilişkin bir NumPy dizisi vermektedir

OrdinalEncoder sınıfı da -ismi yanlış bir çağrıım uyandırsa da- aslında sıralı veriler için kullanılamaz. Çünkü burada yine LabelEncoder sınıfının yaptığı gibi numpy.unique işlemi uygulanmaktadır. Bu sınıf da alfabetik ya da sayısal olarak en küçük kategoriden başlayarak sayısal atamaları yapmaktadır.

Aslında kategorik veriler çoğu kez buradaki gibi sayısal biçimde dönüştürülmemektedir. Kategorik verilerin sayısal biçimde dönüştürülmesinde sıkılıkla "one hot encoding" denilen teknik kullanılmaktadır. İzleyen bölümde "one hot encoding" denilen tekniği ele alacağız.

One Hot Encoding Dönüşürmesi

Kategorik verilerin 0'dan itibaren tam sayılar kullanılarak sayısal biçimde dönüştürülmesi pek çok algoritma için bir sorundur. Çünkü bu biçimdeki sayıların arasında büyüklik küçüklik ilişkisi vardır ve bu büyüklik küçüklik ilişkisi pek çok algoritmada yanlış öğrenmelere yol açabilmektedir. Örneğin biz LabelEncoder ya da OrdinalEncoder sınıflarıyla üç kategorik renk değerine Blue = 0, Green = 1, Yellow = 2 değerlerini atamış olalım. Buradaki Yellow > Green > Blue gibi bir ilişkinin ya da Blue + Green = Yellow gibi bir ilişkinin bizim için bir anlamı yoktur. Ancak pek çok algoritma bu

üç renk böyle kodlandığında onların kategorik değil sıralı ölçüye sahip olduğunu sanmaktadır. İşte kategorik değerlerin sanki onlar sıralı ölçüye ilişkinmiş gibi değerlendirilmesini engellemek için "one hot encoding" denilen bir yöntem kullanılmaktadır. İngilizce "One hot" bir grup bitten yalnızca birinin 1 diğerlerinin 0 olduğunu anlatmak için kullanılan bir deyimdir.

One hot encoding dönüştürmesinde kategorik veriler ikili sistemde kategori sayısı kadar sütunla ifade edilmektedir. Bu yöntemde n kategoriden birini belirten bir veri n tane sütunla ifade edilir. Verinin ilişkin olduğu kategoriye ilişkin sütun bilgisi 1 diğer sütun bilgileri 0 yapılır. Örneğin aşağıdaki gibi bir veri tablosu söz konusu olsun:

Tepki Süresi	Renk
1.2	Kırmızı
2.3	Mavi
0.7	Kırmızı
1.2	Yeşil
3.2	Mavi

Bu tabloda Renk "Kırmızı, Yeşil ve Mavi" olabilen üç kategoriden oluşan kategorik bir ölçüye ilişkindir. Bu tablodaki Renk sütununun "one hot encoding" tekniği ile sayısallaştırılması sonucunda şöyle bir tablo elde edilir:

Tepki Süresi	Kırmızı	Yeşil	Mavi
1.2	1	0	0
2.3	0	0	1
0.7	1	0	0
1.2	0	1	0
3.2	0	0	1

Burada Renk sütunun yerine onun kategori sayısı kadar sütun eklendiğine dikkat ediniz. Renk hangi renkse yalnızca o rengin sütun değeri 1, diğer renklerin sütun değerleri 0 yapılmıştır. Bu biçimdeki bir kodlamayla renkler arasında bir sıra ilişkisinin ortadan kaldırılmaya çalışıldığına dikkat ediniz. Eğer bizim kategorik verimiz 10 tane farklı kategoriden oluşmuş olsaydı biz de 10 kategori için 10 tane sütun oluşturacaktık.

Burada özel bir duruma dikkatinizi çekmek istiyoruz. One hot encoding ikiden fazla sınıf belirten kategorik veriler için uygulanması gereken bir tekniktir. İki sınıflı kategorik veriler için one hot encoding uygulamaya hiç gerek yoktur. Örneğin veri tablosunun bir sütunu cinsiyet belirtiyor olsun. Cinsiyet ikili bir kategorik sınıf oluşturduğu için bu sütun için bizim one hot encoding uygulamamız gerekmeyecektir. Bu tür iki sınıflı kategorik alanlar tipik olarak 0 ve 1 biçiminde sayısallaştırılarak bırakılabilirler.

Şimdi de "one hot encoding" işleminin nasıl yapılacağını görelim. Scikit-learn kütüphanesindeki sklearn.preprocessing modülünde "one hot encoding" işlemini yapan OneHotEncoder isimli hazır bir sınıf vardır. Ancak bu sınıf kategorik verilerin önce sayısal biçimde dönüştürülmüş olmasını ister. Bu nedenle biz bu sınıfı kullanmadan önce kategorik verileri LabelEncoder ya da OrdinalEncoder sınıfı ile sayısal biçimde dönüştürmiş olmalıyız. OneHotEncoder sınıfı şöyle kullanılmaktadır:

1) Önce one hot encoding dönüştürmesi yapılacak değerlerin iki boyutlu bir matris biçiminde ifade edilmeleri gereklidir. Bu matrisin elemanları doğrudan yazışal etiketler de olabilir, sayısal değerler de olabilir. Ancak genellikle one hot encoding işlemi NumPy dizileri üzerinde yapıldığı için ve NumPy dizileri de ortak bir türden olduğu için programcılar yazışal kategorik alanları önce LabelEncoder ya da OrdinalEncoder sınıfları kullanılarak sayısal biçimde dönüştürürler. Örneğin yukarıda verdigimiz veri tablosunun aşağıdaki gibi bir "test.csv" dosyası içerisinde bulunduğu varsayıyalım:

Tepki Süresi, Renk
1.2, Kırmızı

2.3,Mavi
0.7,Kırmızı
1.2,Yeşil
3.2,Mavi

Şimdi bu dosyayı okuyup Renk sütununu LabelEncoder sınıfı ile sayısal biçimde dönüştürelim:

```
import numpy as np
import pandas as pd
from sklearn.preprocessing import LabelEncoder

df = pd.read_csv('test.csv')
print(df)

le = LabelEncoder()
df['Renk'] = le.fit_transform(df['Renk'])
print(df)
dataset = df.to_numpy()
print(dataset)
```

Buradan şöyle bir çıktı elde edilecektir:

```
Tepki Süresi      Renk
0            1.2  Kırmızı
1            2.3    Mavi
2            0.7  Kırmızı
3            1.2    Yeşil
4            3.2    Mavi
Tepki Süresi  Renk
0            1.2    0
1            2.3    1
2            0.7    0
3            1.2    2
4            3.2    1
[[1.2 0. ]
 [2.3 1. ]
 [0.7 0. ]
 [1.2 2. ]
 [3.2 1. ]]
```

2) sklearn.preprocessing modülü içerisindeki OneHotEncoder sınıfı türünden bir nesne yaratılır. Bu nesnenin fit_transform metoduna sayısallaştırılmış kategorik değerler parametre olarak verilir. Ancak fit_transform metodu parametre olarak iki boyutlu bir Python listesini, bir NumPy dizisini ya da Pandas'ın bir DataFrame nesnesini almaktadır. Eğer elinizde tek boyutlu bir vektör varsa onu tek bir sütundan oluşan bir matris biçimine dönüştürmeniz gereklidir. Bunun için ndarray sınıfının reshape metodundan faydalanabilirsiniz.

```
from sklearn.preprocessing import OneHotEncoder

ohe = OneHotEncoder(sparse=False)
ohe_data = ohe.fit_transform(dataset[:, 1].reshape(-1, 1))
print(ohe_data)
```

Burada fit_transform işleminde ilgili sayısallaştırılmış kategorik verilerin sütun vektörüne dönüştürüldüğüne dikkat ediniz. Bu işleminden şöyle bir çıktı elde edilmiştir:

```
[[1. 0. 0.]
 [0. 1. 0.]
 [1. 0. 0.]
```

```
[0. 0. 1.]  
[0. 1. 0.]]
```

Aslında fit_transform ile iki farklı sütun da tek hamlede one hot encoding dönüştürmesine sokulabilmektedir. fit_transform metoduna genel olarak iki boyutlu bir dizinin geçirilebildiğine dikkat ediniz. Biz bu örnekte fit_transform metoduna LabelEncoder sınıfı ile 0'dan itibaren sayısallaştırılmış sütunu parametre olarak verdik. Aslında sütunun 0'dan itibaren ardışıl numaralarla sayısallaştırılmış olması gerekmemektedir. Buradaki sayılar kategori belirttiği için herhangi değerlerde olabilmektedir. fit_transform metodunun sayısal kategorik veriler yerine yazışal kategorik veriler üzerinde de işlem yapabildiğini anımsatmak istiyoruz.

Biz aslında fit ve transform işlemlerini birlikte değil ayrı ayrı da yapabiliyoruz:

```
from sklearn.preprocessing import OneHotEncoder  
  
ohe = OneHotEncoder(sparse=False)  
ohe.fit(dataset[:, 1].reshape(-1, 1))  
ohe_data = ohe.transform(dataset[:, 1].reshape(-1, 1))  
print(ohe_data)
```

Bu işlemlerin ayrı ayrı yapılması size anlamsız gelebilir. Ancak aslında fit işleminde biz "one hot encoding" işlemi için gereken kategorileri belirtmekteyiz. transform ise gerçek dönüştürmeyi yapmaktadır. Yani örneğin biz bir kere fit işlemi yapıp çok defa transform işlemi yapabiliriz. fit_transform metodu aslında önce fit sonra transform işlemini yapmaktadır. Hem fit metodunun hem de transform metodunun iki boyutlu Python listeleriyle, NumPy dizileriyle ya da Pandas'ın DataFrame nesneleriyle çalışmasına dikkat ediniz.

3) Nihayet one hot encoding işlemi sonucunda elde edilen matrisin gerçek veri matrisine yerleştirilmesi gerekmektedir. Bunun için tabii önce gerçek veri matrisindeki sayısallaştırılmış kategorik sütun silinmelidir. İşin bu kısmını Pandas'ın DataFrame üzerinde yapabiliyoruz:

```
df.drop(['Renk'], axis=1, inplace=True)  
df[['Kırmızı', 'Yeşil', 'Mavi']] = ohe_data  
print(df)
```

Bu işlemden şöyle bir çıktı elde edilecektir

	Tepki Süresi	Kırmızı	Yeşil	Mavi
0	1.2	1.0	0.0	0.0
1	2.3	0.0	1.0	0.0
2	0.7	1.0	0.0	0.0
3	1.2	0.0	0.0	1.0
4	3.2	0.0	1.0	0.0

Ya da işin bu kısmını hiç Pandas kullanmadan NumPy dizisi üzerinde de yapabiliyoruz:

```
dataset = np.delete(dataset, 1, axis=1)  
dataset = np.append(dataset, ohe_data, axis=1)  
print(dataset)
```

Şimdi bu adımları tek bir kodla bireştirelim:

```
import pandas as pd  
from sklearn.preprocessing import LabelEncoder  
  
df = pd.read_csv('test.csv')  
print(df)
```

```

le = LabelEncoder()
df['Renk'] = le.fit_transform(df['Renk'])

from sklearn.preprocessing import OneHotEncoder

ohe = OneHotEncoder(sparse=False)
ohe_data = ohe.fit_transform(df['Renk'].to_numpy().reshape(-1, 1))
df.drop(['Renk'], axis=1, inplace=True)
df[['Kırmızı', 'Yeşil', 'Mavi']] = ohe_data
print(df)

```

Kod çalıştırıldığında şöyle bir çıktı elde edilecektir:

	Tepki Süresi	Renk
0	1.2	Kırmızı
1	2.3	Mavi
2	0.7	Kırmızı
3	1.2	Yeşil
4	3.2	Mavi

	Tepki Süresi	Kırmızı	Yeşil	Mavi
0	1.2	1.0	0.0	0.0
1	2.3	0.0	1.0	0.0
2	0.7	1.0	0.0	0.0
3	1.2	0.0	0.0	1.0
4	3.2	0.0	1.0	0.0

"One hot encoding" işlemi uygulamanın diğer bir yolu da tensorflow.keras.utils modülündeki to_categorical fonksiyonunu kullanmaktır. Bu fonksiyon 0'dan başlayan ardışılı tamsayıların bulunduğu kategorik ndarray nesnesini parametre olarak alır ve geri dönüş değeri olarak da "one hot encoding" biçiminde dönüştürülmüş ndarray matrisi verir. Biz de bu matrisi uygun sütunlarla yer değiştirebiliriz. Örneğin:

```

data = [0, 0, 2, 2, 3, 1, 2, 1, 1]

from tensorflow.keras.utils import to_categorical

ohe_data = to_categorical(data)
print(ohe_data)

```

Kodun çalıştırılması sonucunda şöyle bir çıktı elde edilmiştir:

```

[[1. 0. 0. 0.]
 [1. 0. 0. 0.]
 [0. 0. 1. 0.]
 [0. 0. 1. 0.]
 [0. 0. 0. 1.]
 [0. 1. 0. 0.]
 [0. 0. 1. 0.]
 [0. 1. 0. 0.]
 [0. 1. 0. 0.]]

```

Biz de bu işlemden elde ettiğimiz "one hot encoding" ndarray nesnesini orijinal nesnenin sütunlarıyla değiştirebiliriz. Şimdi de yukarıdaki renk içeren "test.csv" örneğini to_categorical fonksiyonuyla one hot encoding yapalım:

```

import pandas as pd
from sklearn.preprocessing import LabelEncoder
from tensorflow.keras.utils import to_categorical

df = pd.read_csv('test.csv')

```

```

le = LabelEncoder()
df['Renk'] = le.fit_transform(df['Renk'])

df[['Renk-0', 'Renk-1', 'Renk2']] = to_categorical(df['Renk'])
df.drop(['Renk'], axis=1, inplace=True)
print(df)

```

Kod çalıştırıldığında şöyle bir çıktı elde edilmiştir:

	Tepki Süresi	Renk-0	Renk-1	Renk2
0	1.2	1.0	0.0	0.0
1	2.3	0.0	1.0	0.0
2	0.7	1.0	0.0	0.0
3	1.2	0.0	0.0	1.0
4	3.2	0.0	1.0	0.0

Tabii aslında one hot encoding yapan bir fonksiyon yazmak da oldukça kolay. Örneğin:

```

def one_hot_encoder(dataset, column):
    ncategory = np.max(dataset[:, column]) + 1
    ohe = np.zeros((dataset.shape[0], int(ncategory)), dtype=np.float32)
    for index, category in enumerate(dataset[:, column]):
        ohe[index, int(category)] = 1

    dataset = np.delete(dataset, column, axis=1)
    dataset = np.hstack((dataset, ohe))

    return dataset

```

Bu fonksiyon bizden kategori sütunu sayısal hale dönüştürülmüş olan NumPy dizisini ve one hot encoding yapılacak sütun numarasını alır. Bize one hot encoding yapılmış yeni matrisi geri dönüş değeri olarak verir. Aslında bu fonksiyonu np.eye fonksiyonu ile birim matris oluşturarak da daha kolay yazabilirdik:

```

def one_hot_encoder(dataset, column):
    ncategory = int(np.max(dataset[:, column]) + 1)
    eye = np.eye(ncategory)
    ohe = eye[dataset[:, column].astype(np.int32)]

    dataset = np.delete(dataset, column, axis=1)
    dataset = np.hstack((dataset, ohe))

    return dataset

```

Örneğin:

```

import numpy as np
import pandas as pd
from sklearn.preprocessing import LabelEncoder

def one_hot_encoder(dataset, column):
    ncategory = int(np.max(dataset[:, column]) + 1)
    eye = np.eye(ncategory)
    ohe = eye[dataset[:, column].astype(np.int32)]

    dataset = np.delete(dataset, column, axis=1)
    dataset = np.hstack((dataset, ohe))

    return dataset

```

```

df = pd.read_csv('test.csv')
print(df)

le = LabelEncoder()
df['Renk'] = le.fit_transform(df['Renk'])
print(df)

dataset = one_hot_encoder(df.to_numpy(), 1)
print(dataset)

```

Kod çalıştırıldığında şöyle bir çıktı elde edilecektir:

	Tepki Süresi	Renk
0	1.2	Kırmızı
1	2.3	Mavi
2	0.7	Kırmızı
3	1.2	Yeşil
4	3.2	Mavi

	Tepki Süresi	Renk
0	1.2	0
1	2.3	1
2	0.7	0
3	1.2	2
4	3.2	1


```

[[1.2 1. 0. 0. ]
 [2.3 0. 1. 0. ]
 [0.7 1. 0. 0. ]
 [1.2 0. 0. 1. ]
 [3.2 0. 1. 0. ]]

```

One hot encoding işlem için Pandas kütüphanesindeki get_dummies fonksiyonu ile de yapabiliyoruz. Bu fonksiyon bizden kategorik değerlerin bulunduğu liste ya da Series nesnesini alır. Bize bir Pandas DataFrame nesnesi verir. Fonksiyon sayısallaştırma işlemini de kendisi yapmaktadır. Örneğin:

```

import pandas as pd

categorical_data = ['Otomobil', 'Kamyон', 'Otomobil', 'Motosiklet', 'Kamyон']

df_ohe = pd.get_dummies(categorical_data)
print(df_ohe)

ohe = df_ohe.to_numpy()
print(ohe)

```

Şöyledir bir çıktı elde edilmiş:

	Kamyон	Motosiklet	Otomobil
0	0	0	1
1	1	0	0
2	0	0	1
3	0	1	0
4	1	0	0


```

[[0 0 1]
 [1 0 0]
 [0 0 1]
 [0 1 0]
 [1 0 0]]

```

DataFrame nesnesinin sütun isimlerinin etiketlerden oluştuğuna dikkat ediniz. Fonksiyonun diğer parametreleri için dokümanlara başvurabilirsiniz.

One hot encoding dönüştürmesi kategorik veriler için iyi sonuçlar doğursa da bazı dezavantajlara sahiptir. Örneğin veri tablosundaki bir sütunun kategori sayısı çok fazla olabilir. Bu durumda one hot encoding çok fazla sütunun tabloya eklenmesine yol açar. Bu tür durumlarda one hot encoding yerine başka bir yöntem (örneğin "binary encoding") tercih edilebilir ya da one hot encoding sonrasında "boyutsal özellik indirgemesi (dimensionality feature reduction)" uygulanabilir. (Boyutsal özellik indirgemesi kursumuzda ileride ele alınmaktadır.) One hot encoding işlemi için tüm kategorilerin neler olduğunu işin başında bilinmesi gerekmektedir. Halbuki pek çok durumda toplam kategorilerin sayısı işin başında bilinmez. Bu tür durumlarda hash tabloları oluşturulabilir ve bu tablolara göre kodlama yapılabilir. Kategori sayısının çok fazla olduğu durumlarda sıkılıkla uygulanan yöntemlerden bir diğeri de "binary encoding" yöntemidir.

Binary Encoding Yöntemi

Binary Encoding yöntemi kategorik değerlerin sayısı n olmak üzere $\log_2 n$ tane sütunla ifade edilmesini sağlamaktadır. Bu yöntemde sanki toplamda n tane farklı kategorik değer k tane ($k = \log_2 n$) sütun ile ikilik sistemde kodlanmaktadır. Örneğin toplamda 64 farklı kategorik değer söz konusu olsun. Bu durumda bu kategorik değerler $\log_2 64 = 6$ tane sütun ile ikilik sistemde kodlanabilir. Örneğin:

Sütun-1	Sütun-2	Sütun-3	Sütun-4	Sütun-5	Sütun-6	Kategori
0	0	0	0	0	0	C1
0	0	0	0	0	1	C2
...
1	1	1	1	1	0	C63
1	1	1	1	1	1	C64

Binary Encoding işlemi Scikit-learn kütüphanesindeki `category_encoders` modülündeki `BinaryEncoder` sınıfı ile gerçekleştirilebilmektedir. Ancak `category_encoders` modülü `sklearn` paketleri içerisinde değildir. Onun ayrıca install edilmesi gerekmektedir:

```
pip install category_encoders
```

`BinaryEncoder` sınıfı `OneHotEncoder` sınıfında olduğu gibi kategori sayısı kadar sütun oluşturmaktadır. Bu nedenle elde edilen pek çok sütun tamamen sıfırlardan oluşabilir. `BinaryEncoder` sınıfı bizden `Pandas DataFrame` nesnesini alıp bize yine `DataFrame` de verebilmektedir. Örneğin:

```
import pandas as pd
from category_encoders.binary import BinaryEncoder

df = pd.read_csv('test.csv')
print(df)

be = BinaryEncoder()
be_df = be.fit_transform(df[ 'Renk' ])
print(be_df)
```

Kodun çalıştırılması sonucunda şöyle bir çıktı elde edilecektir:

	Tepki Süresi	Renk
0	1.2	Kırmızı
1	2.3	Mavi
2	0.7	Kırmızı

```

3      1.2    Yeşil
4      3.2    Mavi
  Renk_0  Renk_1  Renk_2
0      0      0      1
1      0      1      0
2      0      0      1
3      0      1      1
4      0      1      0

```

Şimdi DataFrame içerisindeki 'Renk' sütununu silelim, elde edilen sütunlardan sıfır olanları atalım ve iki DataFrame nesnesini birleştirelim:

```

df.drop(['Renk'], axis=1, inplace=True)
be_df = be_df.loc[:, (be_df != 0).any(axis=0)]

result_df = pd.concat([df, be_df], axis=1)
print(result_df)

```

Şöyledir bir çıktı elde edilecektir:

	Tepki Süresi	Renk_1	Renk_2
0	1.2	0	1
1	2.3	1	0
2	0.7	0	1
3	1.2	1	1
4	3.2	1	0

Sıralı (Ordinal) Verilerin Sayısal Biçime Dönüşürtlmesi

Sıralı verilerin sayısal biçimde dönüştürülmesi işlemi için yüksek seviyeli kütüphanelerde hazır bir fonksiyon ya da metot bulunmamaktadır. Bu işlem en pratik biçimde Pandas kütüphanesindeki Series ya da DataFrame sınıflarının replace metodlarıyla gerçekleştirilebilir. Örneğin aşağıdaki gibi bir "test.csv" dosyamız olsun:

```

Cinsiyet,Kilo,Boy,Eğitim
Erkek,85,172,İlkokul
Kadın,72,170,Üniversite
Kadın,65,162,Lise
Erkek,92,183,Lise
Kadın,62,173,İlkokul
Erkek,98,172,Ortaokul

```

Burada "Eğitim" sütunu sıralı ölçüye ilişkindir. Şimdi biz DataFrame sınıfının replace metodunu ile eğitim bilgilerini 0'dan itibaren artan bir sayıyla ifade etmeye çalışalım. Önce dosyayı pandas.read_csv fonksiyonu ile ilk sütunu atarak okuyalım:

```

import pandas as pd

df = pd.read_csv('test.csv', encoding='utf-8', usecols=[1, 2, 3])
print(df)

```

Elde edilen DataFrame aşağıdaki gibidir:

	Kilo	Boy	Eğitim
0	85	172	İlkokul
1	72	170	Üniversite
2	65	162	Lise
3	92	183	Lise

```

4    62  173      İlkokul
5    98  172      Ortaokul

```

Şimdi DataFrame sınıfının replace metodunu ile dönüştürmemizi yapalım:

```

replace_dict = {'Eğitim': {'İlkokul': 0, 'Ortaokul': 1, 'Lise': 2, 'Üniversite': 3}}
df.replace(replace_dict, inplace=True)
print(df)

```

Kodun çalıştırılması sonucunda öyle bir çıktı elde edilecektir:

	Kilo	Boy	Eğitim
0	85	172	0
1	72	170	3
2	65	162	2
3	92	183	2
4	62	173	0
5	98	172	1

Artık bu DataFrame nesnesini to_numpy metodu ile ndarray nesnesine dönüştürebiliriz:

```

dataset = df.to_numpy()
print(dataset)

[[ 85 172  0]
 [ 72 170  3]
 [ 65 162  2]
 [ 92 183  2]
 [ 62 173  0]
 [ 98 172  1]]

```

Aynı işlemi Series nesnesi üzerinde de -biraz daha dolaylı olarak- şöyle yapabilirdik:

```

replace_dict = {'İlkokul': 0, 'Ortaokul': 1, 'Lise': 2, 'Üniversite': 3}
df['Eğitim'] = df['Eğitim'].replace(replace_dict)

```

Bu işlemi yalnızca NumPy kullanarak yapmak daha zahmetlidir. Çünkü NumPy kütüphanesinin Pandas kütüphanesindeki gibi bir replace fonksiyonu yoktur.

```

import numpy as np

data = np.loadtxt('test.csv', delimiter=',', skiprows=1, usecols=[1, 2, 3], encoding='utf-8',
dtype=np.object)

dataset = data[:, [0, 1]].astype(np.float32)
edu = data[:, 2]

replace_dict = {'İlkokul': 0, 'Ortaokul': 1, 'Lise': 2, 'Üniversite': 3}
v = np.vectorize(replace_dict.get)
dataset = np.insert(dataset, 2, v(edu), axis=1)
print(dataset)

```

Burada önce "test.csv" dosyasını numpy.loadtxt fonksiyonu ile dtype=np.object parametresi ile okuduk. NumPy dizilerinin tek bir dtype türü olduğu için fonksiyon tüm değerleri string olarak okudu. Sonra "Kilo" ve "Boy" sütunlarını np.float32 türüne dönüştürerek dataset isimli yeni bir NumPy dizisi içerisine yerleştirdik. Nihayet "Eğitim" sütununu da numpy.vectorize fonksiyonu ile sıralı sayısal bir sütuna dönüştürerek bunu yeni bir sütun biçiminde ekledik. Yukarıdaki kod çalıştırıldığında aşağıdaki gibi bir çıktı elde edilecektir:

```
[[ 85. 172.  0.]
 [ 72. 170.  3.]
 [ 65. 162.  2.]
 [ 92. 183.  2.]
 [ 62. 173.  0.]
 [ 98. 172.  1.]]
```

Tabii NumPy içerisinde bu işlemi yapmanın başka çok çeşitli yolları da vardır. Örneğin bu işlem aslında loadtxt fonksiyonu sırasında fonksiyonun converters parametresi kullanılarak da yapılabilirdi:

```
import numpy as np

replace_dict = {'İlkokul': 0, 'Ortaokul': 1, 'Lise': 2, 'Üniversite': 3}
dataset = np.loadtxt('test.csv', delimiter=',', skiprows=1, usecols=[1, 2, 3], encoding='utf-8',
converters={1: lambda x: float(x), 2: lambda x: float(x), 3: lambda x: replace_dict[x]},
dtype=np.object)
print(dataset)
```

Tabii sizin de gördüğünüz gibi bu tür işlemleri yalnızca NumPy kütüphanesi ile yapmak yerine Pandas kütüphanesini kullanarak yapmak ve en sonunda DataFrame nesnesini ndarray nesnesine dönüştürmek daha pratik ve kolay bir yöntemdir. Biz kursumuzda bazen doğrudan NumPy kütüphanesini kullanırken bazen de Pandas kütüphanesinin sağladığı kolaylıklarını kullanacağız.

YAPAY SINİR AĞLARI

Yapay sinir ağları yapay zekanın ve makine öğrenmesinin en önemli alt alanlarından biridir. Derin öğrenme (deep learning) de bir çeşit yapay sinir ağı yöntemidir. Bu bölümde yapay sinir ağları belli düzeylerde teorik bakımdan ele alınacak ve daha çok uygulamaları üzerinde durulacaktır.

Yapay Sinir Ağlarının Tarihi

Yapay Sinir ağlarının teorisi ilk zamanlar sinir bilimle (neuroscience), psikolojiyle ve matematikle uğraşan bilim adamları tarafından geliştirilmiştir. Yapay sinir ağları ilk kez Warren McCulloch ve Walter Pitts isimli kişiler tarafından 1943 yılında ortaya atılmıştır. 1940'lı yılların sonlarına doğru Donald Hebb isimli psikolog da "Hebbian Learning" kavramıyla, 1950'li yıllarda da Frank Rosenblatt isimli araştırmacı da "Perceptron" kavramıyla alana önemli katkılarında bulunmuştur. Bu yıllar henüz elektronik bilgisayarların çok yeni olduğu yıllardır. Halbuki yapay sinir ağlarına yönelik algoritmalar için önemli bir CPU gücü gerekmektedir. Bu nedenle özellikle 1960 yıllarda bu konuda bir motivasyon eksikliği oluşmuştur. Yapay sinir ağları sonraki dönemlerde yeniden popüler olmaya başlamıştır. Derin öğrenme konusunun gündeme gelmesiyle de popüleritesi heften artmıştır.

Yapay Sinir Ağlarının Uygulama Alanları

Yapay Sinir ağlarının pek çok farklı alanda uygulaması vardır. Örneğin:

- Metinlerin sınıflandırılması ve kategorize edilmesi (text classification and categorization)
- Ses tanıma (speech recognition)
- Karakter tanıma (character recognition)
- İsimlendirilmiş Varlıkların Tanınması (Named Entity Recognition)
- Sözcük gruplarının aynı anlama gelip gelmediğinin belirlenmesi (paraphrase detection and identification)
- Metin üretimi (text generation)
- Makine çevirisi (machine translation)
- Örütü tanıma (pattern recognition)
- Yüz tanıma (face recognition)
- Finansal uygulamalar (portföy yönetimi, kredi değerlendirme, sahtecilik, gayrimenkul değerlendirme, döviz fiyatlarının tahmini vs.)
- Endüstriyel problemlerin çözümü
- Biyomedikal mühendisliğindeki bazı uygulamalar (Örneğin medikal görüntü analizi, hastalığa tanı koyma ve tedavi planı oluşturma)
- Optimizasyon problemlerinin çözümü
- Pazarlama süreçlerinde karşılaşılan problemlerin çözümü
- Ulaştırma problemlerinin çözümü

İnsanın Sinir Sistemi

Yapay sinir ağlarını matematiksel düzeyde incelemeden önce insanın sinir sistemi üzerinde de temel bazı açıklamalar yapmak faydalı olacaktır.

İnsanın sinir sistemi iki bölüme ayrılmaktadır:

- Merkezi Sinir Sistemi (Central Nervous System)
- Çevresel Sinir Sistemi (Peripheral Nervous System)

Merkezi sinir sistemi beyin ve omurilikten oluşmaktadır. Beyinden çıkan nöral iletiller omurilikten geçerek tüm vücuda yayılmaktadır. Beyin ve omuriliğin dışındaki nöral ağa çevresel sinir sistemi denilmektedir. Kaslarımız nöronlar tarafından harekete geçirilirler. Fakat bu emir çoğu kez beyin tarafından verilmektedir. Kasları harekete getiren nöronlara "motor nöronlar" denilmektedir. Merkezi sinir sistemi de kendi içerisinde "somatik sinir sistemi" ve "otonom sinir sistemi" olmak üzere ikiye ayrılır. Sinir sisteminin bilinçli bir biçimde harekete geçirilebilen kısmına

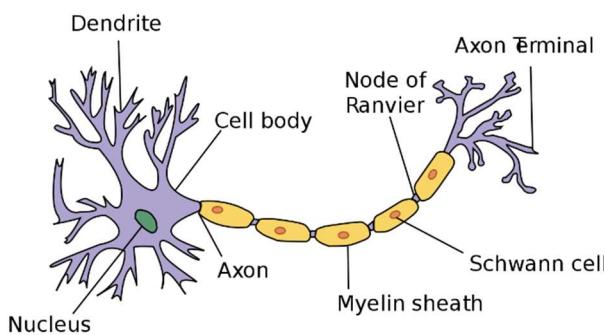
"somatik sinir sistemi", bilinçli bir biçimde harekete geçirilmeyen kısmına ise "otonom sinir sistemi" denilmektedir. Örneğin elimizin hareket ettirilmesi gibi faaliyetler bilinçli bir biçimde yapılmaktadır. Ancak örneğin kalp kaslarının kasılmaları, soluk alıp verme gibi faaliyetler bilinçli olarak gerçekleştirilemezler.

Duyumlar (sensation) bu konuda özelleşmiş nöronlar vasıtıyla gerçekleşmektedir. Fiziksel uyaranlar bu nöronları uyarır. Bu nöronlar bu iletiyi kimyasal düzeye dönüştürürler (transduction) sonra duruma göre omurilige ve oradan da beynin ilgili bölümüne iletiler. Fiziksel uyaranları alan özelleşmiş bu nöronlara "duyusal nöronlar (sensory neurons)" denilmektedir.

Felç olgusunun çeşitli nedenleri vardır. En çok karşılaşılan nedenleri beyindeki lezyonlar (beyin kanaması sonucunda ya da tümörel biçimde oluşabilirler) ya da kazalardır. Diğer nedenler arasında omurilik zedelenmeleri, fitiklar gibi sorunlar bulunmaktadır.

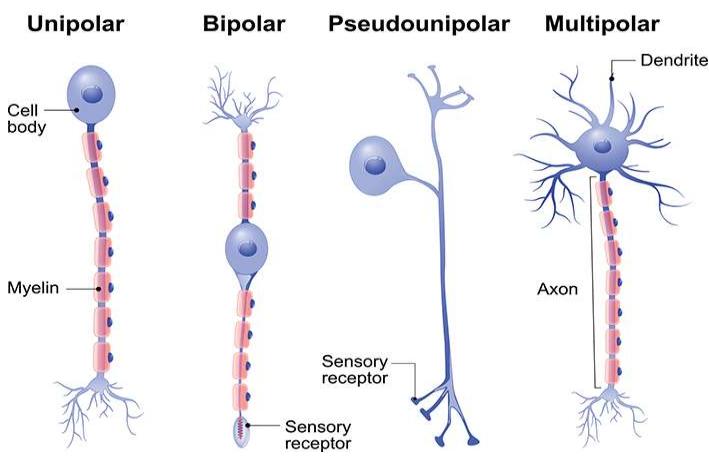
Sinir sisteminin en önemli hücreleri nöronlardır. Nöronların en fazla bulunduğu yer beyindir. Beyinde 100 milyar civarında nöron olduğu düşünülmektedir. Nöronların dışında sinir sisteminde gliya gibi nöromodülatör hücreler de bulunmaktadır.

Bir nöron hücresi tipik olarak aşağıdaki gibidir:



Alıntı Notu: Görsel <https://simple.wikipedia.org/wiki/Neuron> adresinden alınmıştır.

Nöronların da birkaç çeşidi vardır. Yukarıdaki şekilde görüldüğü tipteki nöronlara "multipolar nöronlar" denilmektedir. Bu nöronlar sinir sisteminde en fazla bulunan nöronlardır. Aşağıda diğer bazı nöron çeşitlerini görüyorsunuz:



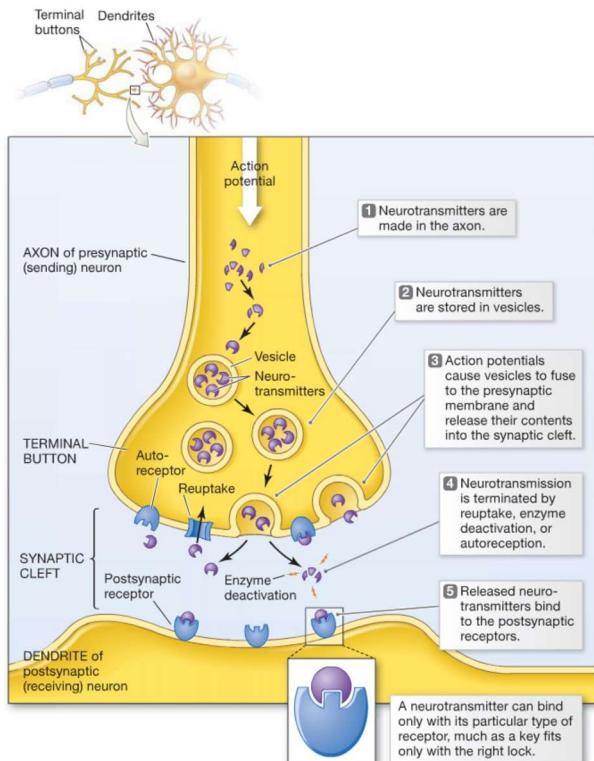
Alıntı Notu: Görsel <https://qbi.uq.edu.au/brain/brain-anatomy/types-neurons> adresinden alınmıştır.

Multipolar nöronlar bir çekirdekten, nöral iletiyi alan dendrit'lerden ve nöral iletiyi ileten aksonlardan oluşurlar. Akson denilen uzun dalın üzerinde bazı nöronlarda miyelin kılıfı (myelin sheet) bulunmaktadır. Miyelin kılıfının en önemli işlevi nöral iletiyi hızlandırmıştır. Miyelinli nöronların ileti hızı yaklaşık 80-120 m/sn, miyelinsiz nöronların ileti hızı ise yaklaşık 0.5-2 m/sn civarındadır. Beyinde hem miyelinli hem de miyelinsiz nöronlar bulunur. Miyelenli nöronlar beyaz renkte miyelinsiz olanlar ise gri renkte görüntü verdiklerinden beyinde miyelinli nöronların bulunduğu

bölgelere "beyaz madde (white matter)", miyelinsiz nöronların bulunduğu bölgelere ise "gri madde (gray matter)" denilmektedir.

Pekiyi nöral ileti kimyasal düzeyde nasıl gerçekleşmektedir? İşte bir nöronun aksonunun ucunda düğmecikler (terminal buttons) bulunmaktadır. Nöron ateşlendiğinde bu düğmeciklerden "nörotransmít" denilen moleküller zerk edilir. Nöral ileti büyük ölçüde bu nörotransmítler yoluyla gerçekleşmektedir.

Akson uçları duruma göre yüzlerce ya da binlerce başka nörona bağlı olabilmektedir. İleti genellikle (ama her zaman değil) bir nöronun aksonu ile karşı taraftaki nöronun dendriti arasında gerçekleşir. Nöral iletinin gerçekleştiği bölgeye sinaps denilmektedir. Bir sinaps tipik olarak şöyledir:



Alıntı Notu: Görsel <https://in.pinterest.com/pin/722546333950674913/> adresinden alınmıştır.

Yukarıda de belirtildiği gibi aksonların ucunda düğmecikler (axon terminal buttons) bulunmaktadır. Dendritlerde de ismine reseptör denilen küçük yarıklar (synaptic cleft) vardır. Akson uçlarındaki düğmeciklerden ismine nörotransmít denilen kimyasallar zerk edilir. Zerk edilen bu nörotransmítler dendritlerdeki reseptörler tarafından alınmaktadır. Ancak her türlü reseptör her türlü nörotransmít'i alamamaktadır. Her nörotransmít'i alan farklı reseptörler vardır.

Nörotransmítler çeşitli alt sınıflara ayrılmaktadır. En önemli nörotransmítler şunlardır:

Amino Asit Grubundan olanlar: Glutamat, GABA, Glisin

Monoamin Grubundan Olanlar: Serotonin, Histamin, Dopamin, Adrenalin, Noradrenalin. Dopamin, Adrenalin ve Noradrenaline "katakolaminler" de denilmektedir.

Peptit Grubundan Olanlar: Endorfin

Digerleri: Asetilkolin, ...

Örneğin psikoaktif maddeler ve psikotrop ilaçlar bu nörotransmítleri artırıp azaltabilmektedir. Sinapslarda nörotransmítleri artırma etkisi yaratan maddelere "agonist", azalma etkisi yaratan maddelere ise "antagonist" denilmektedir. Örneğin "dopamin antagonisti" demek "sinapslardaki dopamin seviyesini düşüren madde" demektir. Agonist ya da antagonist etki çeşitli biçimlerde oluşturulabilmektedir. Örneğin:

- Nörotransmiter üretimi artırılarak ya da azaltılarak
- Rezeptörler bloke edilerek.
- Rezeptörlerin etkinliği artırılarak (yani daha çok nörotransmiter almasını sağlayarak).

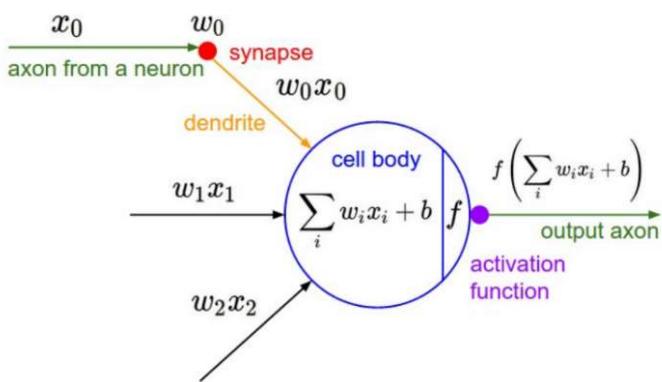
Akson uçları nörotransmiterleri zerk ettikten sonra kullanılmayanları geri almaktadır. Buna "geri alım (reuptake)" işlemi denilmektedir. İşte bazı maddeler bu geri alımı engelleyerek agonist bir etki oluşturabilmektedir. Yukarıda da belirtildiği gibi psikiyatride kullanılan psikotrop ilaçlar büyük ölçüde sinapslardaki nörotransmitterler üzerinde etkili olmaktadır. Örneğin:

- SSRI türevi antidepresanlar serotonin geri alımını engelleyerek sinapslardaki seronin miktarını artırmaktadır. Depresyonla sinapslardaki serotonin eksikliği arasında ilişki olduğu düşünülmektedir.
- Bazı trisiklik antidepresanlar ve SNRI türevi antidepresanlar sinapslardaki noradrenalin miktarını artırmaktadır.
- Şizofreni ve diğer psikotik bozuklukların tedavilerinde kullanılan antipsikotikler genellikle dopaminerjik sistemle ilgili etki gösterirler. Bazı psikotik bozuklukların nedenleri beynin bazı bölgelerindeki dopaminerjik aktivitenin fazla olmasıyla açıklanmaya çalışılmaktadır.
- Sakinleştirici (sedatif) olarak kullanılan ilaçların çoğu (örneğin benzodiazepinler) GABA isimli nörotransmitteri artırmaktadır. GABA nöral iletisi üzerinde inhibisyon etkisi yapan önemli bir nörotransmitter'dir.

Psikotrop ilaçlar deneysel yolla (hatta bazıları tesadüflerle) bulunmuştur. Maalesef neredeyse hiçbir psikotrop ilaçın çalışma mekanizması ayrıntılılarıyla ve kesin düzeyde bilinmemektedir.

Yapay Nöron Modeli

Yapay sinir ağlarındaki nöral iletişim oldukça basitleştirilerek matematiksel bir algoritmik yönteme dönüştürülmüştür. İşte yapay sinir ağları temelde bu basitleştirilmiş matematiksel nöron modeline dayanmaktadır. Nasıl gerçek bir nöronda birtakım girişler (dendritlerdeki rezeptörler) ve çıkışlar (akson'dan zerk edilen nörotransmitterler) varsa matematiksel nöron modelinde de nörona çeşitli girişler ve bir çıkış söz konusudur. Örnek bir yapay nöron aşağıdaki şekilde temsil edilebilir. Bu tek nöronluk modele aynı zamanda "perceptron" da denilmektedir.



Bu örnek nöron modelinde x 'ler (x_0, x_1, x_2) gözlenen birtakım değişkenleri temsil etmektedir. Başka bir deyişle buradaki x 'ler tipik bir istatistik veri tablosundaki sütunları temsil etmektedir. Örneğin bir apartman dairesinin o andaki piyasa değerini tahmin etmeye çalışan bir nöral ağ tasarlayacak olalım. Bu ağın girdileri (yani x değerleri) neler olabilir? Bir dairenin fiyatı neler bağlıdır? Burada kabaca şu unsurları sayabiliriz:

- Apartmanın yaşı

- Dairenin metrekare büyülüğü
- Dairenin şehir merkezine uzaklığı
- Dairenin binanın kaçinci katında olduğu
- Dairenin oda sayısı

Ya da örneğin 10 tane biyomedikal tetkik sonucuna göre kişilerin belli bir hastalığa sahip olup olmadığını anlamaya çalışan bir yapay sinir ağı modeli kurmak isteyelim. Bu modeldeki x 'ler bu 10 biyomedikal tetkik değerleri olacaktır. Bu yapay sinir ağında çıktılar girdilere bağlandıktan sonra en sonunda tek bir çıkış elde edilecektir. Bu çıkış da kişinin o hastalığa sahip olup olmadığını verecektir.

Yukarıdaki nöron modelinde bu girdi değişkenlerinin birtakım w katsayılarla çarpılıp toplandığı görülmüyor. Sonra da bu toplam bir fonksiyona sokulup bir çıktı değeri elde edilmektedir. Peki buradaki w değerleri ne anlam ifade etmektedir? w değerleri aslında eğitimli ağırlarda nihai olarak elde edilmiş bir daha değiştirilmeyecek ağırlık değerleridir. Zaten yapay sinir ağının eğitilmesi aslında girdilere göre uygun çıktıyı verebilecek w ağırlık değerlerinin tespit edilmesi sürecidir. Eğitimli yapay sinir ağılarında daha önceki verilere dayanılarak girdilerle çıktılar arasında bir ilişki kurulmaya çalışılır. Bu ilişki aslında w katsayılarının uygun biçimde belirlenmesiyle kurulmaktadır. Örneğin ev fiyatını belirleme probleminde biz yapay sinir ağına evin özelliklerini girdi olarak veririz. Yapay sinir ağı da evin fiyatını bize çıktı olarak verir. Ancak yapay sinir ağının bunu yapabilmesi için gerçek birtakım ev özellikleriyle ve fiyatlarıyla eğitilmesi gerekmektedir. İşte bu eğitim sırasında aslında yapay sinir ağındaki w katsayıları uygun biçimde ayarlanmaktadır. Eğitim bittikten sonra artık biz ağa yeni bir ev özellikleri verdigimizde bu w katsayıları ve aktivasyon fonksiyonları devreye girerek bize o evin fiyatını verecektir.

Biz yukarıda tek nöron üzerinde açıklamalar yaptık. Halbuki insanın sinir sisteminde olduğu gibi yapay sinir ağılarında da pek çok nöronun çıktıları başka nöronların girdilerine bağlanabilmektedir. İleride bu bağlantı modelleri hakkında bilgiler verilecektir.

Yapay Nöronun Python'da Bir Sınıfla Temsil Edilmesi

Yapay bir nöron basit bir sınıfta temsil edilebilir. Örneğin:

```
import numpy as np

class Neuron:
    def __init__(self, weights, activation, bias = 0):
        self.weights = weights
        self.activation = activation
        self.bias = bias

    def output(self, x):
        total = np.dot(self.weights, x)
        return self.activation(total + self.bias)

def sigmoid(x):
    return 1 / (1 + np.exp(-x))

n = Neuron([0.2, 0.3, 0.4], sigmoid)
result = n.output([2, 1, 7])
print(result)
```

Burada Neuron sınıfı bizden nesne yaratılırken ağırlık değerlerini, aktivasyon fonksiyonunu ve bias değerini istemiştir. Sınıfın output fonksiyonu da nöral işlemi yaparak bize çıktı değerini vermektedir.

Yapay Sinir Ağılarında Katmanlar

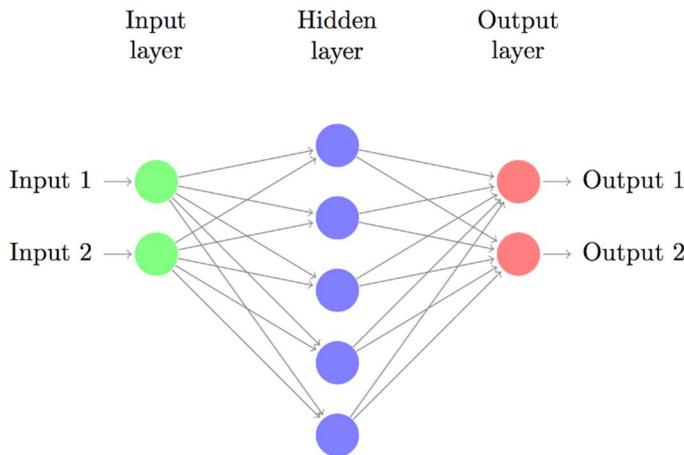
Bir yapay sinir ağında üç katman söz konusudur:

1) Girdi Katmanı (Input Layer / Visible Layer)

2) Saklı Katman (Hidden Layer)

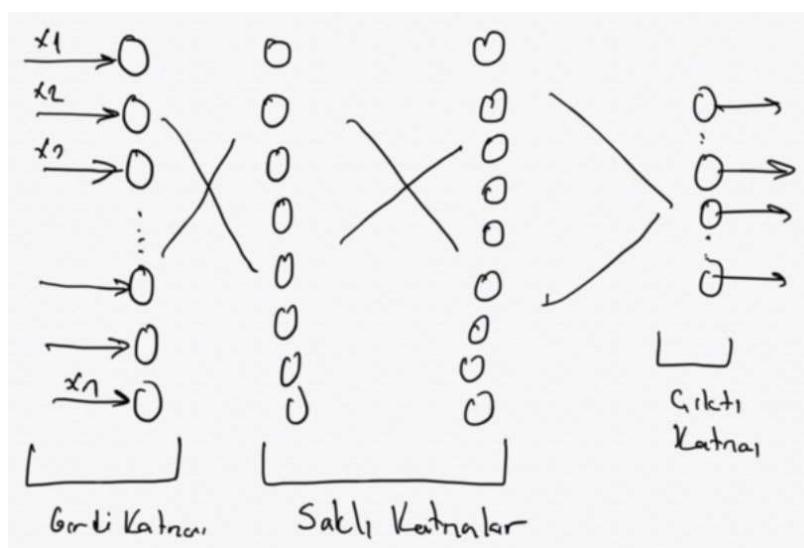
3) Çıkış Katmanı (Output Layer)

Bir yapay sinir ağında katmanlar ve katmanlardaki nöronların oluşturduğu yapıya "ağ mimarisi" denilmektedir.



Girdi katmanı dış dünyadan girdi değerlerini (yani x değerlerini) alan katmandır. Girdi katmanındaki nöronlar içerisinde bir işlem yapılmamaktadır. Her ne kadar şekillerde girdi katmanı da her bir x girişi için bir nöronla temsil ediliyorsa da aslında gerçek bir nöron işlevi yapmamaktadır. Yani girdi katmanındaki nöronların bir girişi vardır. Bu nöronların çıkış değeri de giriş değerinin aynısıdır. Örneğin bir kişinin diyabetli olup olmadığını anlayabilmek için 10 farklı biyomedikal tetkik sonuçlarını girdi olarak kullanmak isteyelim. Bu durumda ağın girdi katmanı 10 nörondan oluşacaktır. Bu 10 nöronun girdisi tamamen çıktı ile aynı olacaktır.

Basit problemler yalnızca girdi ve çıktı katmanı olan bir ağa çözülebilir. Ancak model karmaşıklıkça ara katman görevini yapan saklı katmanların kullanılması gerekmektedir. Saklı katmanlar düzey olarak bir tane, iki tane ya da ikiden çok olabilir. Örneğin:



Burada iki saklı katman bulunmaktadır. Duruma göre veri bilimcisi tarafından saklı katmanların sayısı artırılıp azaltılabilmektedir. Saklı katmanlardaki nöron sayıları girdi katmanındaki nöron sayısı ile aynı olmak zorunda değildir. Genellikle eğer girdi katmanındaki nöronların sayıları göreli olarak azsa saklı katmanlardaki nöronların sayıları

fazlalaştırılır. Eğer girdi katmanında görelî olarak çok fazla nöron varsa saklı katmanlardaki nöronların sayıları işlem yüklerini azaltmak için düşürülebilmektedir. Genel olarak saklı katmanların sayısı ikiden büyükse bu tür yapay sinir ağlarına derin yapay sinir ağları ya da özetle derin öğrenme (deep learning) ağları denilmektedir. Yani derin ağlarla normal sinir ağları arasındaki fark saklı katmanların sayısı ile ilgilidir.

Çıktı katmanı sinir ağından elde edilecek bilgiyi dış dünyaya veren katmandır. Tabii çıktı katmanındaki nöronlarda da saklı katmanlarda olduğu gibi işlemler yapılmaktadır. Ancak çıktı katmanı artık değerlerin elde edildiği son katmandır. Yani biz girdileri girdi katmanına veririz sonucu çıktı katmanından alırız. Çıktı katmanın kaç nörondan oluşacağı çıktıının ne olduğu ile ilgilidir.

Şimdi katmanlardaki olası nöron sayıları hakkında bazı şeyler söyleyelim. Girdi katmanındaki nöron sayısı kestirimde kullanılacak özelliklerin (features) sayısı kadar olmalıdır. Çıktı katmanındaki nöronların sayısı da elde edilecek kestirim sonucuya ilgilidir. Örneğin ağımız var/yok gibi, olumlu/olumsuz gibi, hasta/sağlıklı ikili bir kestirimde bulunacaksın (bu tür modellere istatistikte lojistik regresyon denilmektedir) çıktı katmanı tek bir nörondan oluşur. Örneğin ağımız bir resimdeki rakamın kaç olduğunu kestirmeye çalışıyorsa bu durumda çıktı katmanında 10 tane nöron bulunur. Yine örneğin ağımız bir evin fiyatını tahmin etmeye çalışıyorsa çıktı katmanı evin fiyatını veren tek bir nörondan oluşacaktır. O halde bilmemişimiz iki durum vardır: Ağımızda kaç tane saklı katman ve her saklı katmanda kaç tane nöron bulunmalıdır? İşte bu soruların yanılıarı deneyimle ve üzerinde çalışılan problemin nitelegine göre veri bilimcisi tarafından doğru biçimde verilmeye çalışılmaktadır. Ancak yine de bu konuda önerilen birkaç genel yönerge vardır. Saklı katmanların sayısı için şu pratik tavsiyelerde bulunulabilir.

(<https://www.heatonresearch.com/2017/06/01/hidden-layers.html>)

- Eğer problem doğrusal olarak ayırtılabilir (linearly separable) ise saklı katman kullanmaya gerek yoktur. Doğrusal olarak ayrılabilir problem hakkında kısa teorik bilgi ileride verilecektir.
- Bir saklı katman pek çok sorunun çözümü için yeterlidir. İki saklı katman çok büyük ölçüde pek çok problemin çözümü için yeterli olmaktadır.
- İkiden fazla saklı katmanı olan derin modeller karmaşık problemlerin çözümü için kullanılmaktadır. Bunlara örnekler ileride verilecektir.

Bir saklı katmandaki nöron sayısı için üstünkörü pratik tavsiyeler de şunlar olabilir:

- Saklı katmandaki nöronların sayısı girdi katmanındaki nöronların sayısının $2/3$ ile çıktı katmanındaki nöronların sayısının toplamı kadar olabilir. Örneğin girdi katmanındaki nöron sayısı 5, çıktı katmanındaki 1 olsun. Bu durumda saklı katmandaki nöron sayısı 5 olabilir.
- Saklı katmandaki nöronların sayısı girdi katmanındaki nöron sayısının iki katından fazla olmamalıdır.

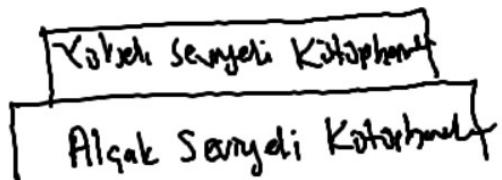
Tabii aslında saklı katmanlardaki nöron sayılarına ilişkin bu iki sezgisel yargıya bazı durumlarda uyulmamaktadır. Genellikle saklı katmanlardaki nöron sayıları deneyimle, deneme yanlışlığını yöntemleriyle belirlenmektedir. Şüphesiz bir fayda sağlanmadığı halde çok saklı katman ya da saklı katmanlarda çok nöron bulundurmasının bir anlamı yoktur. Ağ ne kadar sade olursa hem işlem yükü bakımından hem de verilerin saklanması ve iletilmesi bakımından o kadar avantaj sağlanması.

Yapay Sinir Ağlarında ve Derin Öğrenme Ağlarında Yaygın Kullanılan Kütüphaneler ve Framework'ler

Bir yapay sinir ağı mimarisinin sıfırdan programını yazmak çok zor olmasına da zaman alıcı bir süreçtir. Üstelik programcılar tarafından kendi gereksinimleri doğrultusunda yazılan bu tür kodların pek çoğu genel değildir ve genişletilememektedir. Bu konudaki diğer bir sorun ise yapay sinir ağlarındaki işlem yüküyle ilgilidir. Yapay sinir ağlarının eğitilmesi çok yoğun işlemleri gerektirebilmektedir. Bu işlemleri bir framework kullanmadan yapmak

isteyen programcı kendisini paralel programlama gibi görelî karmaşık konular içerisinde bulabilmektedir. Bu da programcının toplam iş yükünü artırmaktadır.

İşte her konuda olduğu gibi yapay sinir ağlarında da işlemleri kolaylaştırmak için birtakım kütüphanelerden ve framework'lerden faydalılmaktadır. Bu tür kütüphanelerin ve framework'lerin sayısı oldukça fazla olmakla birlikte bazıları çokça tercih edilmektedir. Bu tür kütüphaneleri ve framework'leri kabaca "aşağı seviyeli olanlar" ve yüksek seviyeli olanlar" biçiminde ikiye ayıralım. Tabii aslında yüksek seviyeli kütüphaneler ve framework'ler kendi içlerinde aşağı seviyeli kütüphanelerden faydalana bilmekte



Bazı kütüphaneler ve framework'ler yalnızca bazı dillerden kullanılabilirken bazıları farklı programlama dillerinden kullanılabilirler. Kütüphane ve framework tercihlerini bu durum da etkilemektedir.

Scikit-learn isimli kütüphane Python'da yazılmıştır ve makine öğrenmesi için kullanılan aşağı seviyeli genel bir kütüphanedir. Pek çok kütüphane kendi içerisinde Scikit-learn kütüphanesini de kullanmaktadır. Scikit-learn açık kaynak kodlu bir kütüphanedir, NumPy ve SciPy kullanılarak yazılmıştır. Ancak Scikit-learn yapay sinir ağlarına yönelik tasarlanmamıştır. Yani Scikit-learn içerisinde yapay sinir ağlarını oluşturacak modüller yoktur.

PyTorch Python ve C++'ta yazılmış olan bir yapay sinir ağı ve derin öğrenme ağı kütüphanesidir. Proje Facebook tarafından yaşama geçirilmiştir. Bu kütüphane veri bilimcileri arasında belli yoğunluklarda kullanılmaktadır. PyTorch da NumPy üzerine oturtulmuştur.

Theano aslında Python programcılar için yazılmış bir nümerik analiz kütüphanesidir. Ancak yapay sinir ağlarında ve derin öğrenmede de aşağı seviyeli bir kütüphane olarak Theano'dan faydalılmaktadır.

TensorFlow Google tarafından geliştirilmiş olan aşağı seviyeli nümerik analiz kütüphanesidir. Makine öğrenmesi, yapay sinir ağları ve derin öğrenme ağları uygulamalarında en çok tercih edilen aşağı seviyeli kütüphane durumundadır. TensorFlow Python dahil olmak üzere pek çok programlama dilinden kullanılabilirler. Bu kütüphane de Python ve C++ kullanılarak yazılmıştır.

MxNet ise başka bir aşağı seviyeli yapay sinir ağları ve derin öğrenme kütüphanesidir. Apache grubu tarafından açık kaynak kodlu olarak yazılmıştır.

Yüksek seviyeli yapay sinir ağları ve derin öğrenme kütüphanelerinin açık ara en başında Keras gelmektedir. Keras Python'da yazılmıştır ve oldukça yüksek seviyeli bir kütüphanedir. Ancak Keras arka planda birkaç alçak seviyeli kütüphanesi "backend" olarak kullanılmaktadır. (Default durumda Keras Google'in TensorFlow kütüphanesini kullanmaktadır.) Kursumuzun bu bölümünde yapay sinir ağları ve derin öğrenme uygulamalarında basitliğinden dolayı Keras kullanılacaktır. Keras kütüphanesinin dokümantasyonu <https://keras.io/> sitesinde bulunmaktadır. Keras açık kaynak kodlu bir projedir ve Google Tensorflow ekibi tarafından da desteklenmektedir.

Denetimli (Supervised) Yapay Sinir Ağları ve Veri Kümeleri

Daha önceden makine öğrenmesini ve yapay sinir ağlarını denetimli (supervised), denetimsiz (unsupervised) ve pekiştirmeli (reinforcement) olmak üzere üçe ayırmıştık. Denetimli (supervised) yapay sinir ağlarında ağıın mimarisi oluşturulduktan sonra gerçek verilerle ağıın etgitilmesi (training) gerekmektedir. Bu eğitim sırasında nöronların w katsayıları ayarlanmaktadır. İşte bu eğitim işleminde kullanılmak üzere elimizde gerçek örneklerin bulunması gereklidir.

Eğitimde kullanılan gerçek örneklem kümesine "eğitim veri kümesi (traning data set)" denilmektedir. Ağ eğitildikten sonra ağın test edilmesi için de gerçek verilerden oluşan bir veri kümesine gereksinim duyulmaktadır. Buna da "test veri kümesi (test data set)" denilmektedir. O halde bizim gerçek verileri toplayıp bu verileri "eğitim veri kümesi" ve "test veri kümesi" olmak üzere ikiye ayırmamız gereklidir. Eğitimde kullanılan veri kümescinin aynı zamanda test işleminde kullanılması yanlış bir tekniktir. Çünkü ağ eğitilirken öğrenilen şeyler test edilirken kullanılmamalıdır. (Bu durumu şuna benzetebiliriz: Öğretmen derste birtakım sorular çözüp sınavda da aynısını sorarsa bu sınav gerçek durumu kestirmekte başarısız olabilir.)

Pekiyi eğitim veri kümesi ve test veri kümesi arasındaki oran nasıl olmalıdır? Yani topladığımız verilerin yüzde kaç eğitim veri kümesi için yüzde kaç test veri kümesi için kullanılmalıdır? İşte yapay sinir ağlarında ve derin öğrenme ağlarında aslında kesin kurallar yoktur. Pek çok seçim istege bağlıdır. Örneğin uygulamalarda tipik olarak verilerin %80'i eğitim veri kümesi için %20'si ise test veri kümesi için ayrılmaktadır. Ancak veri kümescinin çok büyükse test kümescinin oranı düşürülebilir.

Yukarıda ağın eğitilmesi ve test edilmesi için verilerin bir biçimde elde edilmiş olması gerektiğini söyledik. Verilerin elde edilmesi ayrı bir süreci oluşturmaktadır. Kursumuz bu verilerin elde edilmesi süreci ile ilgili değildir. Bu nedenle biz bu kursta vereceğimiz örneklerde zaten elde edilmiş olan hazır veriler üzerinde işlemlerimizi yapacağız.

Elde edilmiş veriler "eğitim veri kümesi" ve "test veri kümesi" biçiminde ikiye ayrıldıktan sonra ayrıca bunların da "girdi veri kümesi" ve "çıkıtı veri kümesi" biçiminde ayrıştırılması gereklidir. Örneğin bir banka müşterisinin 13 özelliğine bakılarak o müşterinin 3 ay içerisinde bankayı terk edip etmeyeceğinin kestirilmeye çalışıldığını düşünelim. İşte bizim bu kestirimini yapabilmemiz için 13 özelliği olan müşterilerin bankayı 3 ay içerisinde terk edip etmediğine yönelik -bir biçimde elde edilmiş olan- bir veri tablomuzun olması gereklidir. Bu veri tablosunda girdi kümesci 13 özellikten, çıktı kümesci ise bankayı tek edip etmediğine ilişkin (örneğim 0 ya da 1) bir özellikten oluşmalıdır.

Şimdi verilerin bu biçimde ayrıştırılmasına örnek verelim. Örneğimizde "pima-indians-diabetes" isimli bir veri tablosunu kullanacağımız. "pima-indians-diabetes" veri tablosu bir kişinin 8 özelliğine bakarak onun şeker hastası olup olmadığıının kestirilmesi için hazırlanmış gerçek bir veri tablosudur. Tablodaki 8 sütunun anlamları şöyledir:

```
# 1. Number of times pregnant  
# 2. Plasma glucose concentration a 2 hours in an oral glucose tolerance test  
# 3. Diastolic blood pressure (mm Hg)  
# 4. Triceps skin fold thickness (mm)  
# 5. 2-Hour serum insulin (mu U/ml)  
# 6. Body mass index (weight in kg/(height in m)^2)  
# 7. Diabetes pedigree function  
# 8. Age (years)  
# 9. Class variable (0 or 1)
```

Bu veri tablosu <https://www.kaggle.com/uciml/pima-indians-diabetes-database> adresinden .csv dosyası biçiminde indirilebilir. Dosyanın görüntüsü şöyledir:

```
Pregnancies,Glucose,BloodPressure,SkinThickness,Insulin,BMI,DiabetesPedigreeFunction,Age,Outcome  
6,148,72,35,0,33.6,0.627,50,1  
1,85,66,29,0,26.6,0.351,31,0  
8,183,64,0,0,23.3,0.672,32,1  
1,89,66,23,94,28.1,0.167,21,0  
0,137,40,35,168,43.1,2.288,33,1  
5,116,74,0,0,25.6,0.201,30,0  
3,78,50,32,88,31,0.248,26,1  
10,115,0,0,0,35.3,0.134,29,0  
2,197,70,45,543,30.5,0.158,53,1  
8,125,96,0,0,0,0.232,54,1  
4,110,92,0,0,37.6,0.191,30,0  
10,168,74,0,0,38,0.537,34,1
```

```
10,139,80,0,0,27.1,1.441,57,0  
1,189,60,23,846,30.1,0.398,59,1  
...
```

Bu tablo gerçek veriler kullanılarak oluşturulmuştur. Tablodaki her satır farklı bir kişinin bilgisini içermektedir. Her satırın ilk 8 sütunu kişinin çeşitli özelliklerini 9'uncu son sütun ise o kişinin şeker hasası olup olmadığını belirtmektedir. Bu son sütundaki değerin 1 olması kişinin şeker hastası olduğunu, 0 olması ise kişinin şeker hastası olmadığını göstermektedir. Tabii bizim aslında bu bölümdeki amacımız yapay sinir ağlarını kullanarak yeni bir kişinin bu sekiz özelliğine bakarak onun belli güvenilirlikle şeker hastası olup olmadığını anlamaktır.

Bu veri tablosunun ayarlığını NumPy kullanarak şöyle yapılabılırız:

```
import numpy as np  
  
dataset = np.loadtxt('diabetes.csv', dtype='float32', skiprows=1, delimiter=',')  
  
dataset_x = dataset[:, :8]  
dataset_y = dataset[:, 8]  
  
tzone = int(len(dataset) * 0.80)  
  
training_dataset_x = dataset_x[:tzone, :]  
training_dataset_y = dataset_y[:tzone]  
  
test_dataset_x = dataset_x[tzone:, :]  
test_dataset_y = dataset_y[tzone:]
```

Burada önce dosya okunmuştur. Veri kümesi içerisinde kategorik bir sütunun olmadığına dikkat ediniz. Sonra veri kümesi girdi ve çıktı biçiminde (dataset_x, dataset_y) ayrılmış sonra bu kümelerde de kendi aralarında %80 noktasından eğitim ve test veri kümesi biçiminde (training_dataset_x, training_dataset_y) yeniden ayrılmıştır.

Aslında yukarıdaki manuel işlem Scikit-learn kütüphanesindeki tek bir fonksiyonla da yapılabilmektedir. Bu işlemi yapan sklearn.model_selection modülündeki train_test_split isimli fonksiyonun parametrik yapısı şöyledir:

```
sklearn.model_selection.train_test_split(*arrays, test_size=None, train_size=None,  
random_state=None, shuffle=True, stratify=None)
```

Fonksiyona biz dataset_x ve dataset_y vektörlerini ayrı parametreler biçiminde veririz. Fonksiyon da bize training_dataset_x, test_dataset_x, training_dataset_y ve test_datatset_y biçiminde dörtlü bir demet verir. Fonksiyonun test_size isimli parametresi test kümesinin yüzde kaç olacağını bizden istemektedir. Bu parametre 0 ile 1 arasında float bir değer biçiminde girilmelidir. Örneğin:

```
import numpy as np  
  
dataset = np.loadtxt('diabetes.csv', dtype='float32', skiprows=1, delimiter=',')  
  
dataset_x = dataset[:, :8]  
dataset_y = dataset[:, 8]  
  
from sklearn.model_selection import train_test_split  
  
training_dataset_x, test_dataset_x, training_dataset_y, test_datatset_y =  
train_test_split(dataset_x, dataset_y, test_size=0.2)
```

Göründüğü gibi train_test_split isimli fonksiyon bizden girdi ve çıktı matrislerini alıp onu istediğimiz oranda parçalara ayırmaktadır. Yukarıda da belirttiğimiz gibi buradaki test_size isimli argümanı test verilerinin yüzdesini belirtmektedir. Bu yüzde 0 ile 1 arasında float bir sayı biçiminde girilmelidir. Yukarıdaki örnekte test_size=0.2 girişi

eğitim veri kümesinin %80, test veri kümesinin %20 olacağı anlamına gelmektedir. Eğer fonksiyonda `test_size` parametresi belirtilmemez default olarak 0.25 alınmaktadır.

`train_test_split` fonksiyonu default durumda verilen x ve y vektörlerini karıştırıp ondan sonra eğitim ve test kümelerini ayırtırmaktadır. Eğer bunun yapılmasını istenmiyorsanız (bazen zamansal verilerde bunun yapılmasını istemeyebilirsiniz) fonksiyonun `shuffle` parametresini `False` geçmelisiniz.

Keras Kütüphanesinin Kurulması

Önceden de belirttiğimiz gibi Keras yüksek seviyeli bir yapay sinir ağı kütüphanesidir. Keras 2.3 sürümüne kadar birden fazla arkayı (backend) destekliyordu (`TensorFlow`, `Microsoft Cognitive Toolkit`, `Theano`, `PlaidML`). Ancak 2.4 sürümüyle birlikte artık Keras arkayıza olarak yalnızca `TensorFlow` kütüphanesini kullanmaktadır. Bu nedenle Keras kütüphanesi yüklenmeden önce `TensorFlow` yüklenmiş olmalıdır.



Keras yalnızca Python kullanılarak, `TensorFlow` ise C++ ve Python kullanılarak yazılmıştır. Bu iki kütüphanenin yüklenmesi pip komutlarıyla şöyle yapılabilir:

```
pip install tensorflow
pip install keras
```

Tabii yükleme işlemini Anaconda Navigator sekmelerinden ya da PyCharm menülerinden görsel olarak da yapabilirsiniz. Kurulumuzun verildiği sırada Keras'ın son sürümü 2.4.0, `TensorFlow`'un ise 2.5.0'dır. Ancak burada dikkat edilmesi gereken bir nokta şudur: Maalesef `Tensorflow` kütüphanesini ile kullanılabilcek Python sürümleri farklıdır. Eğer Python sürümünüz 3.8 ise sizin `TensorFlow` 2.2 ya da daha sonraki bir versiyonu yüklemeniz gereklidir. Eğer Python versyonunuz 3.9 ise sizin `Tensorflow` 2.5'i yüklemeniz gereklidir. Daha eski Python sürümleri için istediğiniz `TensorFlow` sürümünü yükleyebilirsiniz.

`Tensorflow` 2'li versiyonlarla birlikte Keras kütüphanesini bünyesine dahil etmiştir. Yani artık Keras kütüphanesi `Tensorflow` içerisinde `tensorflow.keras` paketi biçiminde bulunmaktadır. Ancak Keras ayrı bir kütüphane gibi de şimdilik kendini devam ettirmektedir. Fakat maalesef Keras'ın ayrı bir kütüphane biçiminde kurulumu sırasında `TensorFlow` kütüphanesi ile versiyon uyuşmazlığı yaşanabiliyor. Bu nedenle Keras'ı eğer ayrı bir kütüphane olarak kuracaksanız -kursun yapıldığı tarihte- `TensorFlow` kütüphanesinin 2.2 versiyonunu yüklemelisiniz. Ayrıca artık bu kursla birlikte Keras kütüphanesinin `Tensorflow` bünyesine katılmış biçimini kullanacağız. Halbuki önceki kurslarda ayrı bir biçimde kurulan Keras kütüphanesini kullanıyorduk.

Pekiyi bağımsız Keras kurulumu ile `Tensorflow` içerisindeki Keras kurulumu arasında bir fark var mıdır? Aslında Keras'ın ileri sürümleri de zaten `TensorFlow` içerisindeki Keras ile uyumlu hale getirilmektedir. Ancak `TensorFlow` içerisindeki Keras, `TensorFlow` kütüphanesine yönelik bazı aşağı seviyeli işlemlerinin yapılmasına da izin verdiği için bu durum Keras ile `TensorFlow` kütüphanelerini beraber kullanmak isteyen programcılar için bir avantaj oluşturabiliyor. Yukarıda da belirttiğimiz gibi biz kursumuzla birlikte artık `TensorFlow` içerisindeki Keras'ı kullanacağız.

Keras'ta Yapay Sinir Ağlarının Oluşturulması

Keras yüksek seviyeli bir kütüphanedir. Dolayısıyla işlemler yüksek seviyeli biçimde yürütülmektedir. Keras modelinde programcının kabaca ağ için şu belirlemeleri yapmış olması gereklidir:

- Aşağıdaki katmanlar
- Katmanlardaki nöronların sayısı
- Nöronların kullanacağı aktivasyon (transfer) fonksiyonları
- Eğitimde ve testte kullanılacak girdi ve çıktı veri kümeleri
- Sistemin amaçlarına yaklaşlığını ölçmek için kullanılacak "amaç fonksiyonu (loss function)"
- w değerlerinin iyileştirme yöntemini belirleyen optimizasyon algoritması

Biz burada önce Keras'ta işlem adımlarını kabaca ele alacağımız sonra ayrıntılara gireceğiz. Keras'ta işlemler tipik olarak (her zaman değil) aşağıdaki beş aşamadan geçilerek gerçekleştirilmektedir:

1) Modelin Oluşturulması: Keras'ta yapay sinir ağı bir sınıf nesnesi ile temsil edilmektedir. Bu amaçla en yaygın kullanılan sınıf Sequential isimli sınıfır. Programcı bu Sequential sınıfı türünden bir nesne yaratır. Yaratılan bu nesneye genellikle "model" denilmektedir. Örneğin:

```
from tensorflow.keras.models import Sequential
model = Sequential()
```

Keras'ta Sequential dışında başka model sınıfları da vardır. Bu sınıflar ileride ele alınacaktır.

2) Modele Katmanların Eklenmesi: Bu aşamada artık katmanları modele eklememiz gereklidir. Katman eklemeye işlemi için Sequential sınıfının add metodu kullanılmaktadır. add metodu bizden argüman olarak katman istemektedir. Keras'ta katmanı temsil eden çeşitli sınıflar vardır. Bunların en çok kullanılanı Dense isimli sınıfır. Dense katmanı (dense yoğun anlamına geliyor) bu katmandan önceki katmanın her nöronunun bu katmanın her nöronu ile bağlanacağı anlamına gelmektedir. Dense sınıfının `__init__` metodu aşağıdaki gibidir:

```
tensorflow.keras.layers.Dense(units,
    activation=None,
    use_bias=True,
    kernel_initializer='glorot_uniform',
    bias_initializer='zeros',
    kernel_regularizer=None,
    bias_regularizer=None,
    activity_regularizer=None,
    kernel_constraint=None,
    bias_constraint=None,
    **kwargs
)
```

Metodun units parametresi ilgili katmandaki nöron sayısını, activation parametresi ise o katmandaki tüm nöronların aktivasyon (transfer) fonksiyonunu belirtmektedir. Burada fonksiyon isim olarak ya da fonksiyon nesnesi olarak girilebilmektedir. Eğer buradaki fonksiyon bir fonksiyon nesnesi olarak girilecekse tensorflow.keras.Activation modülündeki fonksiyon nesneleri kullanılmalıdır. use_bias parametresi eğer True geçilirse (default durum) bu durumda bias_initializer parametresi nöronındaki "bias" değeri olarak kullanılmaktadır. bias değerinin anlamı ileride ele alınacaktır. kernel_initializer parametresi başlangıçtaki 'w' değerlerinin dağılımını belirtmektedir. Yani biz işin başında bu 'w' değerlerini rastgele biçimde belli bir dağılıma göre oluşturabiliriz. Bu parametre belirtilmeyebilir. Bu durumda w değerlerinin başlangıçtaki rastgele dağılımı "glorot_uniform" biçimde olacaktır. "glorot_uniform" dağılımı (buna "Xavier initialization" da denilmektedir) bir çeşit sürekli düzgün dağılımdır.

Biz Dense fonksiyonunda oluşturduğumuz katmanlara name parametresi yoluyla isimler de verebiliriz. Katmanlara isimler vermek bazen gerekmektedir. Eğer biz katmanlara name parametresi yoluyla isim vermemsek bu durumda Dense fonksiyonu katmanlara kendisi otomatik isimler vermektedir. Biz genel olarak örneklerimizde katmanlara isimler vereceğiz.

fit metodun diğer parametreleri şimdilik ele alınmayacağıdır. Ancak bunların da çeşitli default değerler aldığıını görürsünüz.

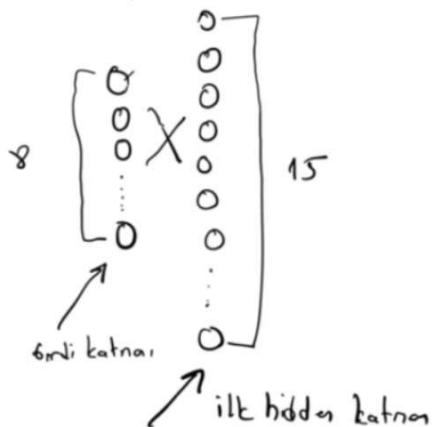
Dense fonksiyonunda input_dim isimli özel parametre (bu parametre ** parametresi yoluyla alınmaktadır) girdi katmanındaki nöron sayısını belirtmek için kullanılmaktadır. Zaten girdi katmanı normal bir katman gibi olmadığı için girdi katmanı için ayrı bir katman oluşturulmamaktadır. Yani ağa eklenen ilk katmanda input_dim girdi katmanındaki nöron sayısını (yani girdi değişkenlerinin sayısını) belirtir. Örneğin:

```
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense

model = Sequential()

model.add(Dense(15, input_dim=8, activation='relu', name='Hidden-1'))
```

Burada biz 15 nöronlu bir saklı (hidden) katman oluşturduk. Bu modelimizin ilk saklı katmanı olduğu için bu katmanda input_dim ile girdi katmanındaki nöronların sayısını da belirttik.



Aslında girdi katmanındaki nöronların sayısı input_dim parametresi yerine input_shape parametresiyle de girilebilmektedir. Bu iki parametrenin tek farkı input_dim parametresinin int bir değer alması, input_shape parametresinin ise int elemanlarından oluşan bir demet parametresi almasıdır. Bazı modellerde girdiler tek boyutlu değil çok boyutlu da olabilmektedir. Bu durumda input_dim yerine input_shape parametresinin kullanılması gerekmektedir. Bu durumda yukarıdaki Dense katmanı eşdeğer biçimde şöyle de oluşturulabilirdik:

```
model.add(Dense(15, input_shape=(8, ), activation='relu', name='Hidden-1'))
```

Burada saklı katmanın transfer fonksiyonu "relu (rectifier linear unit)" olarak alınmıştır. Pek çok problem türü için saklı katmanlarda en fazla kullanılan transfer (aktivasyon) fonksiyonu budur. Bu fonksiyon negatif x değerleri için 0, pozitif x değerleri için x değerini veren basit bir fonksiyondur:

$$f(x) = \max(0, x)$$

relu fonksiyonu aşağıdaki gibi basit bir biçimde yazılabilir:

```
def myrelu(x):
    return np.maximum(0, x)
```

Ya da örneğin şöyle de yazılabilir:

```
def myrelu(x):
    return x * (x > 0)
```

relu fonksiyonun grafiğini de şöyle çizdirebiliiz:

```
import numpy as np
import matplotlib.pyplot as plt

def relu(x):
    return np.maximum(0, x)

x = np.linspace(-10, 10, 100)
y = relu(x)

plt.title('RELU Fonksiyonunun Grafiği')
plt.plot(x, y)
plt.show()
```

Keras'ta yaygın biçimde kullanılan aktivasyon fonksiyonları tensorflow.keras.activations modülünün içerisinde hazır biçimde bulunmaktadır. Ancak bu fonksiyonlar Tensorflow kütüphanesi içerisinde kullanılacak biçimde tasarlanmışlardır. Dense sınıfının add metodunda aktivasyon fonksiyonları isim olarak değil de fonksiyon nesnesi olarak de belirtilebilmektedir:

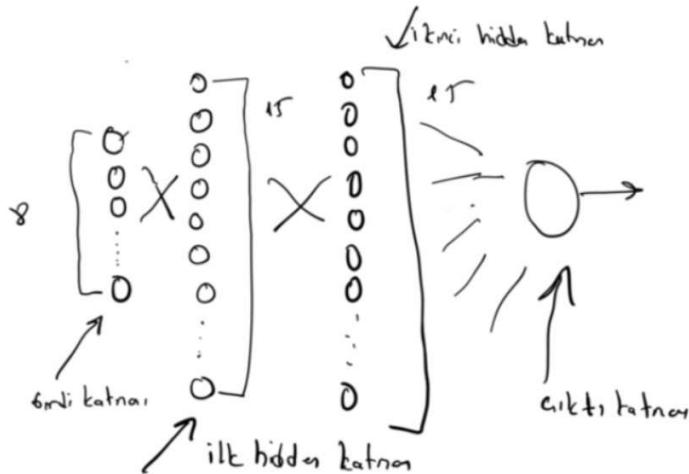
```
from tensorflow.keras.activations import relu

model.add(Dense(15, input_dim=8, activation=relu, name='Hidden-1'))
```

Şimdi ikinci saklı katmanı ve çıktı katmanını da ağa ekleyelim:

```
model.add(Dense(15, activation='relu', name='Hidden-2'))
model.add(Dense(1, activation='sigmoid', name='Output'))
```

Böylece ağımızda 4 katman oluşturmuş olduk: 1 tane girdi katmanı + 2 tane saklı katman + 1 tane çıktı katmanı.



Ağın çıktı katmanı için özel bir belirleme yapılmamaktadır. Her zaman son katman zaten çıktı katmanı olmaktadır. Dense katmanının "önceki katmandaki nöronların hepsinin bu katmandaki nöronların hepsiyle bağlantılı olacağı" anlamına geldiğine bir kez daha dikkat ediniz. Bu modelde çıktı katmanından aktivasyon fonksiyonu olarak "sigmoid" fonksiyonu kullanılmıştır. Sigmoid fonksiyonu iki sınıflı lojistik regresyon modellerinde çıktı katmanında en fazla tercih edilen aktivasyon fonksiyonudur:

$$\text{Sigmoid}(x) = \frac{1}{1 + e^x}$$

Sigmoid fonksiyonun grafiğini çizelim:

```

import numpy as np
import matplotlib.pyplot as plt

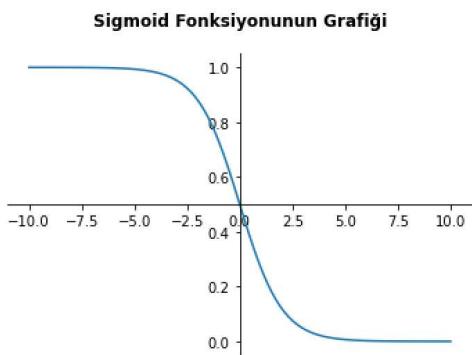
def sigmoid(x):
    return 1 / (1 + np.e ** x)

x = np.linspace(-10, 10, 100)
y = sigmoid(x)

plt.title('Sigmoid Fonksiyonunun Grafiği', weight='bold', pad=20)
axis = plt.gca()
axis.spines['left'].set_position('center')
axis.spines['bottom'].set_position('center')
axis.spines['top'].set_color(None)
axis.spines['right'].set_color(None)

plt.plot(x, y)
plt.show()

```



Şimdi "diabetes.csv" dosyasını okuyarak girdileri bu modele uygulayalım:

```

import numpy as np
from sklearn.model_selection import train_test_split

dataset = np.loadtxt('diabetes.csv', delimiter=',', skiprows=1)
dataset_x = dataset[:, :8]
dataset_y = dataset[:, 8]
training_dataset_x, test_dataset_x, training_dataset_y, test_dataset_y =
train_test_split(dataset_x, dataset_y, test_size=0.2)

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense

model = Sequential()

model.add(Dense(100, input_dim=8, activation='relu', name='Hidden-1'))
model.add(Dense(100, activation='relu', name='Hidden-2'))
model.add(Dense(1, activation='sigmoid', name='Output'))

```

Yukarıda da belirttiğimiz gibi genellikle ikili sınıflandırma (binary classification) tarzı problemlerde saklı katmanların transfer fonksiyonları "relu", çıktı katmanının transfer fonksiyonu ise "sigmoid" olarak alınmaktadır.

3) Modelin Derlenmesi: Modele katmanlar eklendikten sonra artık modelin derlenmesi gereklidir. Buradaki "derleme" terimi programlamadaki derleme anlamında kullanılmamaktadır. Bir çeşit konfigüre etmek anlamında kullanılmaktadır. Konfigüre etme işlemi Sequential sınıfının compile metodu ile yapılmaktadır. Metodun parametrik yapısı şöyledir:

```

Dense.compile(optimizer='rmsprop',
    loss=None,
    metrics=None,
    loss_weights=None,
    weighted_metrics=None,
    run_eagerly=None,
    steps_per_execution=None,
    **kwargs
)

```

compile metodundaki üç önemli parametre optimizer, loss ve metrics parametreleridir. Diğer parametrelerin daha az önemi vardır. Yapay sinir ağlarını eğitirken her eğitim işleminden (epoch) sonra gerçek değerlerle elde edilen değerler arasındaki hata farkı bir biçimde hesaplanmaktadır. İşte bu hesaplanma yöntemine "loss" fonksiyonu denilmektedir. Örneğin bir regresyon modelinde gerçekte olması gereken çıktı 172 iken ağımızın o anda bunu 182 olarak bulduğunu düşünelim. Burada bir fark söz konusudur. Normal olarak bu farkın minimize edilmesi gereklidir. İşte loss fonksiyonu bu farkı ölçmek için kullanılan fonksiyondur. İşlevinden dolayı bu fonksiyona "amaç fonksiyonu" da denilmektedir. Loss fonksiyonları problemin türüne göre seçilmektedir. Lojistik olmayan regresyon tarzı problemlerde lojistik regresyon problemlerinde kullanılabilen loss fonksiyonları farklıdır. Yapay sinir ağlarında çok kullanılan loss fonksiyonları şunlardır:

- **Mean Squared Error:** Lojistik olmayan regresyon modellerinde kullanılır. Bu tür problemlerde en fazla tercih edilen loss fonksiyonudur. Bu yöntemde olması gereken değerlerle olan değerler arasındaki farkın ortalaması bulunmaya çalışılmaktadır. Bu fark ne kadar küçükse hedefe o kadar yaklaşıldığı anlamı çıkar.

$$MSE = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

Burada Y değeri tahmin edilen değeri \hat{Y} ise gerçek değeri belirtmektedir.

- **Mean Absolute Error:** Bu da lojistik olmayan regresyon modellerinde kullanılmaktadır. Fikir MSE ile aynıdır. Yalnızca kare yerine mutlak değer işlemi uygulanmaktadır:

$$MAE = \frac{1}{n} \sum_{i=1}^n |Y_i - \hat{Y}_i|$$

Burada da yine Y değeri tahmin edilen değeri \hat{Y} ise gerçek değeri belirtmektedir.

- **Mean Absolute Percentage Error:** Lojistik olmayan regresyon modellerinde kullanılmaktadır. Aşağıdaki gibi hesaplanır:

$$MAPE = \frac{100}{n} \sum_{i=1}^n \left| \frac{Y_i - \hat{Y}_i}{\hat{Y}_i} \right|$$

- **Mean Square Logarithmic Error:** Lojistik olmayan regresyon modellerinde kullanılmaktadır.

- **Binary Cross-Entropy:** Bu "loss" fonksiyonu ikili sınıflı lojistik regresyon modellerinde en çok tercih edilen loss fonksiyonudur. Örneğin biyomedikal verilerden hareketle kişinin diyabetli olup olmadığını belirlemek için oluşturulan model iki sınıflı lojistik regresyon modelidir. Bu modelde loss fonksiyonu "binary cross-entropy" seçilebilir.

- **Categorical Cross-Entropy:** Bu loss fonksiyonu ikiden fazla sınıflı lojistik regresyon modellerinde en çok tercih edilen loss fonksiyonudur. Örneğin bir resmin üzerinde yazan rakamın belirlenmesine yönelik bir model çok sınıflı lojistik regresyon problemidir. Böyle bir modelde loss fonksiyonu "categorical cross-entropy" seçilebilir.

Yukarıdaki loss fonksiyonları compile metoduna isimsel olarak girebiliriz. Bu fonksiyonlar için kullanılabilecek isimler şunlardır:

```
'mean_squared_error' ya da 'mse'  
'mean_absolute_error' ya da 'mae'  
'mean_absolute_percentage_error' ya da 'mape'  
'mean_squared_logarithmic_error' ya da 'msle'  
'categorical_crossentropy'  
'binary_crossentropy'
```

loss fonksiyonları isimsel fonksiyon nesnesi olarak da belirtilebilir. Keras'taki tüm loss fonksiyonları tensorflow.keras.losses modülünde bulunmaktadır. Buradaki önemli fonksiyon isimleri şöyledir:

```
tensorflow.keras.losses.mean_squared_error ya da tensorflow.keras.losses.mse  
tensorflow.keras.losses.mean_absolute_error ya da tensorflow.keras.losses.mae  
tensorflow.keras.losses.mean_absolute_percentage_error ya da tensorflow.keras.losses.mape  
tensorflow.keras.losses.mean_squared_logarithmic_error ya da tensorflow.keras.losses.msle  
tensorflow.keras.losses.categorical_crossentropy  
tensorflow.keras.losses.binary_crossentropy
```

Aslında programcının kendisi de bir loss fonksiyonu ya da sınıfı yazıp onu kullanabilmektedir. Kursumuzda bu durum ele alınmayacağıdır.

compile metodunun optimizer parametresi 'w' değerlerinin iyileştirilmesi için kullanılacak algoritmayı belirtmektedir. Bu algoritma loss fonksiyonuyla karıştırılmamalıdır. Loss fonksiyonu yalnızca bizim hedefe yaklaşma miktarımızı hesaplamakta kullanılmaktadır. Bu hedefe daha iyi yaklaşmak için 'w' değerlerinin nasıl güncellenmesi gerektiği optimizasyon algoritmasıyla ilgilidir. Çok kullanılan üç optimizasyon algoritması "rmsprop (root mean square propagation)", "adam (adaptive moment estimation)" ve "sgd (stochastic gradient descent)" algoritmalarıdır. Optimizasyon algoritmaları compile metodunun optimizer parametresine aşağıdaki isimlerle yazı olarak girilebilir:

```
'rmsprop'  
'sgd'  
'adam'
```

compile metodunun optimizer parametresinin 'rmsprop' default değerini aldığına dikkat ediniz.

Optimizer algoritmaları aslında tensorflow.keras.optimizers modülündeki sınıflar tarafından gerçekleştirilmektedir. Örneğin rmsprop algoritması için RMSProp isimli sınıf, "adam" algoritması için Adam isimli sınıf, "sgd" algoritması için SGD isimli sınıf bulunmaktadır. Böylece biz optimizer parametresine algoritmanın ismini vermek yerine ilgili sınıflar türünden nesne yaratarak bu nesneleri de verebiliriz. Örneğin:

```
from tensorflow.keras.losses import msle  
from tensorflow.keras.optimizers import Adam  
  
model.compile(optimizer=Adam(), loss=msle)
```

Aslında programcının kendisi de optimzier algoritmalarına ilişkin fonksiyon ya da sınıf yazabilmektedir. Ancak kursumuzda bu konuya ayrıntı olduğu gereçesiyle ele almayacağız. Biz kursumuzda şimdilik optimizasyon algoritmalarının nasıl işlev gördüğü üzerinde durmayacağız. Bu algoritmaların nasıl çalıştığı kursumuzun ilerleyen bölümlerinde ele alınmaktadır.

compile metodundaki metrics parametresi bir liste biçiminde "metrics" denilen fonksiyonları almaktadır. "metrics" fonksiyonları da "loss" fonksiyonları gibi kestirilen değerlerle gerçek değerler arasındaki farklılığı ifade etmeye kullanılmaktadır. Ancak "loss" fonksiyonlarından eğitim sürecinde ve her batch işlemi bittiğinde (batch işleminin ne anlam ifade ettiği ilerde ele alınmaktadır) faydalananırken "metrics" fonksiyonlarından eğitim ve sınama (validation) sürecinde her epoch bittiğinde (epoch kavramından ilerde bahsedilecektir) faydalanyılmaktadır. Metrics fonksiyonları veri bilimcisine eğitim ve sınama süreçlerinde "eğitimin performansı hakkında bilgi" vermektedir. Loss

fonksiyonlarının algoritmanın işleyişi konusunda etkili olduğuna, metrics fonksiyonlarının ise yalnızca bilgi verdiğine dikkat ediniz.

Metrics fonksiyonlarını ele almadan önce eğitim sırasında sınama (validation) işlemleri üzerinde durmak istiyoruz. Modelin sınanması eğitim sırasında modelin başarısını ölçmek için yapılan bir işlemidir. Veri bilimcisi isterse eğitim veri kümesinin bir bölümünün sınama amacıyla kullanılmasını sağlayabilir. Bu durumda eğitim devam ederken aynı zamanda her epoch'tan sonra sınama veri kümesi ile sınama işlemi de yapılır. Sınama işlemini test işlemi ile karıştırmayınız. Sınama işlemi eğitim sırasında test işlemi ise eğitim bittikten sonra yapılmaktadır.

Eğitim ve sınama işlemi sırasında kullanılabilecek çeşitli metrics fonksiyonları bulunmaktadır. Bu fonksiyonlar yukarıda da belirttiğimiz gibi compile metodunun metrics parametresine bir liste biçiminde girilir. Aşağıda önemli metrics fonksiyonları hakkında kısa açıklamalar veriyoruz:

- **accuracy**: Bu metrics fonksiyonu ağıın verdiği değerin yüzde kaçının gerçek değerle aynı olduğu hesabını yapmaktadır. Örneğin eğitim için 1000 adet veri kullanılıyor olsun. Bu 1000 veri ağa sokulduğunda eğer bunların 800 tanesi gerçek değerle aynı değerde ise (tabii belli bir delta aralığı içerisinde) bu durumda accuracy değeri $800 / 1000 = 0.8$ olacaktır. accuracy fonksiyonu lojistik olmayan regresyon modellerinde sıklıkla kullanılmaktadır.
- **binary_accuracy**: accuracy fonksiyonu gibidir. Ancak burada 0 ve 1 biçiminde ikili değerlerin belli bir delta aralığında uyuşmasına bakılmaktadır.
- **binary_crossentropy**: binary_crossentropy loss fonksiyonun metrics biçimidir. Lojistik olmayan iki sınıfı regresyon problemlerinde tercih edilmektedir.
- **categorical_accuracy**: Bu fonksiyon tipik olarak iki sınıfı lojistik regresyon modellerinde kullanılmaktadır. Belli bir delta aralığı içerisinde aynı olduğuna bakmaktadır. Ancak bu fonksiyon ikiden fazla sınıfı lojistik regresyon modellerinde kullanılmaktadır.
- **mean_squared_error**: Lojistik olmayan regresyon problemlerinde metrics değeri olarak sık kullanılmaktadır. mean_squared_error loss fonksiyonu ile aynı işlemleri yapmaktadır. Lojistik olmayan regresyon modellerinde tercih edilmektedir.
- **mean_absolute_error**: Lojistik olmayan regresyon problemlerinde metrics değeri olarak sık kullanılmaktadır. mean_absolute_error loss fonksiyonu ile aynı işlemleri yapmaktadır. Lojistik olmayan regresyon modellerinde tercih edilmektedir.
- **mean_absolute_percentage_error**: mean_absolute_percentage_error loss fonksiyonu ile aynı işlemleri yapmaktadır. Lojistik olmayan regresyon modellerinde tercih edilmektedir.

metrics parametresi için kullanılacak fonksiyon isimleri de şöyledir:

```
'accuracy' ya da 'acc'  
'binary_accuracy'  
'categorical_accuracy'  
'mean_absolute_error' ya da 'mae'  
'mean_absolute_percentage_error' ya da 'mape'  
'mean_squared_error' ya da 'mse'
```

Bu durumda compile metodunun örnek bir çağrı şöyledir:

```
model.compile(optimizer='adam', loss='binary_crossentropy', metrics=['binary_accuracy'])
```

Aslında metrics fonksiyonları da tensorflow.keras.metrics modülündeki sınıflarla temsil edilmiştir.. Örneğin biz compile metodunda metrics fonksiyonlarını şöylede girebilirdik:

```
from tensorflow.keras.metrics import BinaryAccuracy
model.compile(optimizer='adam', loss='binary_crossentropy', metrics=[BinaryAccuracy()])
```

Aslında buradaki sınıflar tensorflow.keras.losses modülündeki sınıflarla aynıdır. Dolayısıyla metrics fonksiyonları ve sınıfları yerine loss fonksiyonları ve sınıfları da kullanılabilmektedir. Ancak her loss fonksiyonu ve sınıfı için bir metrics fonksiyonu ve sınıfı, her metrics fonksiyonu ve sınıfı için de bir loss fonksiyonu ve sınıfı yoktur. Örneğin binary_cross_entropy hem bir loss fonksiyonu hem de bir metrics fonksiyonudur. Ancak binary_accuracy bir metrics fonksiyonudur fakat loss fonksiyonu değildir. Bu durumda örneğin biz metrics olarak tensorflow.keras.metrics modülündeki binary_crossentropy fonksiyonu yerine tensorflow.keras.losses modülündeki binary_crossentropy fonksiyonunu kullanabilirdik. Örneğin:

```
from tensorflow.keras.losses import binary_crossentropy
model.compile(optimizer='adam', loss='binary_crossentropy', metrics=[binary_crossentropy])
```

Tabii bu durumun tersi de geçerlidir. Yani loss fonksiyonu ya da sınıfı için biz tensorflow.keras.metrics modülündeki uygun fonksiyonları ve sınıfları da kullanabiliriz.

4) Modelin Eğitilmesi: Sequential.compile metodu ile modelin konfigüre edilmesinden sonra sıra eğitim aşamasına gelmiştir. Yukarıda da belirtildiği gibi eğitim modeldeki nöronların 'w' katsayılarının uygun biçimde ayarlanması sağlanan bir süreçtir. Şüphesiz eğitim veri kümesi ne kadar büyük ve anlamlı ise, kullanılan optimizasyon algoritması ve loss fonksiyonu ne kadar uygun seçilmişse eğitimin sonucunda gerçekleşen öğrenme de o kadar tatmin edici olacaktır. Eğitim işlemi Sequential sınıfının fit isimli metoduyla yapılmaktadır. Metodun parametrik yapısı şöyledir:

```
Sequential.fit(
    x=None,
    y=None,
    batch_size=None,
    epochs=1,
    verbose='auto',
    callbacks=None,
    validation_split=0.0,
    validation_data=None,
    shuffle=True,
    class_weight=None,
    sample_weight=None,
    initial_epoch=0,
    steps_per_epoch=None,
    validation_steps=None,
    validation_batch_size=None,
    validation_freq=1,
    max_queue_size=10,
    workers=1,
    use_multiprocessing=False
)
```

Göründüğü gibi metodun çok sayıda parametresi vardır. Ancak en önemli olan parametreler ilk dört parametre olan x, y, batch_size ve epochs parametreleridir. x ve y gerçek gözlemlerdeki girdi ve çıktı değerlerine ilişkin ndarray nesneleridir.

Eğitim sırasında gözlemler teker teker iterasyona sokulup loss değeri elde edilerek optimizasyon algoritması ile 'w' değerleri güncellenebilir. Ancak bazen on binlerce hatta milyonlarca eğitim verisini böyle tek tek işleme sokmak çok zaman alabilmektedir ve üstelik de bazı nedenlerden dolayı eğitimin başarısını da düşürebilmektedir. İşte bunun için bir grup gözlem verisini (yani satırı) birlikte işleme sokup bunlardan elde edilen sonuçlardan hareketle 'w' değerlerinin güncellenmesi yoluna gidilmektedir. 'w' değerlerinin her bir gözlem verisinden (satırдан) sonra değil de bir grup gözlem verisi işleme sokulduktan sonra güncellenmesi işlemeye "batch işlemi" buradaki bir grup gözlem verisine de "batch" denilmektedir. İşte fit metodunun batch_size parametresi batch büyüğünün kaç gözlem verisinden (satırдан) oluşacağını belirtmektedir. Her batch işleminden sonra loss fonksiyonu kullanılarak tahmin edilen değerle gerçek değer arasındaki fark hesaplanır ve optimizasyon algoritması çalıştırılarak 'w' değerleri

güçellenir. Bu işleme "iterasyon" denilmektedir. Yani "iterasyon" batch_size kadar gözlemin işleme sokup bundan loss değerinin elde edilmesi ve daha sonra optimizasyon algoritması ile w değerlerinin güncellenmesi sürecini belirtmektedir.

fit metodunun epochs parametresi eğitim veri kümесinin baştan aşağı toplamda kaç kez kullanılacağını belirtmektedir. Tabii aynı veri kümесinin aynı model için birden fazla kez kullanılması sizlere tuhaf gelebilir. Ancak ne olursa olsun bu yöntemin 'w' katsayılarını iyileştirmede belli bir faydası vardır. (Aynı dersi birden fazla kez dinlerseniz daha iyi öğrenirsiniz değil mi?) Çoğu zaman epoch değerini yükselttiğimizde öğrenmenin daha başarılı olduğunu görürüz. Ancak belli bir epoch değerinden sonra artık öğrenme başarısı pek artmamaktadır. Ayrıca epoch sayısının yüksek tutulması eğitim süresinin uzamasına ve "overfit" sorununun ortayamasına da yol açabilmektedir.

Yukarıda da belirttiğimiz gibi epoch eğitim veri kümесinin toplamda baştan sona kaç kere eğitim sürecinde kullanılacağını belirtmektedir. Yine yukarıda belirttiğimiz gibi her epoch işleminden sonra sınama (validation) işlemi yapılmaktadır. Sınama işleminde kullanılan veriler fit metodu tarafından bizim ona verdığımız training_dataset_x ve training_dataset_y içerisinde alınmaktadır. İşte fit metodundaki validation_split isimli parametre bizim verdığımız verilerin yüzde kaçının sınama için kullanılacağını belirtmektedir. Metot kendi içerisinde bizim ona verdığımız training_dataset_x ve training_dataset_y vektörlerini bu oranda bölüp onun belli bir kısmını epoch işleminden sonra sınama işleminde kullanmaktadır. Programcı isterse sınama işi için veri kümесini kendisi de oluşturabilir. Yani sınama verisinin eğitim verilerinden alınması zorunlu değildir. Bunun için fit metodunun validation_data parametresi kullanılmaktadır. fit metodunda validation_split parametresinin default olarak 0 olduğunu dikkat ediniz. Bu durum eğitim sırasında epoch'lardan sonra hiç sınama yapılmayacağı anlamına gelmektedir. validation_split parametresinin girilmesi durumunda sınama verilerinin seçilmesi işin başında yapılmakta ve her epoch'ta aynı sınama verileri kullanılmaktadır. fit metodunun shuffle parametresinin default olarak True olduğunu dikkat ediniz. Bu durumda her epoch işleminde işin başında ayrılmış olan eğitim verileri kendi aralarında yeniden karıştırılmaktadır.

fit metodunun verbose parametresinin default durumda 'auto' olduğunu görüyorsunuz. Bu parametre eğitim sırasında bilgilendirme yazılarının hangi düzeyde ekrana yazdırılacağını belirtmektedir. Bu parametre aslında 0, 1 ya da 2 değerini almaktadır. 0 değeri fit işlemi sırasında ekrana hiçbir şeyin yazdırılmayacağı anlamına gelir. 1 değeri ekrana bir progress bar çıkartarak ilerlemeyi gösterir. 2 ise her epoch'ta loss ve metrik değerleri ekrana yazdırmaktadır. Parametrenin default değeri olan 'auto' duruma göre 2 değerine ya da 1 değerine karşılık gelmektedir.

fit metodu geri dönüş değeri olarak History nesnesi vermektedir. Bu nesne içerisinde biz her epoch'taki sonuç bilgilerini alabiliriz. History nesneleri izleyen bölümlerde ele alınmaktadır.

Şimdiye kadar geçtiğimiz aşamalara ilişkin örnek bir model şöyle olabilir:

```
import numpy as np
from sklearn.model_selection import train_test_split

dataset = np.loadtxt('diabetes.csv', delimiter=',', skiprows=1)
training_dataset_x, test_dataset_x, training_dataset_y, test_dataset_y =
train_test_split(dataset[:, :8], dataset[:, 8], test_size=0.2)

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense

model = Sequential()

model.add(Dense(100, input_dim=8, activation='relu', name='Hidden-1'))
model.add(Dense(100, activation='relu', name='Hidden-2'))
model.add(Dense(1, activation='sigmoid', name='Output'))

model.compile(optimizer='adam', loss='binary_crossentropy', metrics=['binary_accuracy'])
model.fit(training_dataset_x, training_dataset_y, batch_size=32, epochs=100,
validation_split=0.2)
```

Elde edilen sonuç şöyledir:

```

Epoch 1/100
16/16 [=====] - 1s 9ms/step - loss: 1.0918 - binary_accuracy: 0.5927 - val_loss:
0.7977 - val_binary_accuracy: 0.5772
Epoch 2/100
16/16 [=====] - 0s 2ms/step - loss: 0.7048 - binary_accuracy: 0.6477 - val_loss:
0.7097 - val_binary_accuracy: 0.6829
...
Epoch 99/100
16/16 [=====] - 0s 2ms/step - loss: 0.5110 - binary_accuracy: 0.7658 - val_loss:
0.6706 - val_binary_accuracy: 0.6829
Epoch 100/100
16/16 [=====] - 0s 2ms/step - loss: 0.4458 - binary_accuracy: 0.7902 - val_loss:
0.5761 - val_binary_accuracy: 0.7317

```

fit metodu her epoch'tan sonra sınıma verisi üzerinde elde ettiği başarı değerini ekrana yazdırmaktadır. Bu başarı değeri bizim metrics ile verdigimiz algoritmadan elde edilen değerdir. Programcı bu değerlere bakarak modelin başarısı hakkında bir fikir edinebilir. Duruma göre modelini değiştirmek düzeltmeye çalışabilir.

Şimdi modelimize bir tane daha saklı katman ekleyelim. Acaba modelimiz daha başarılı hale gelecek mi? Örneğin:

```

import numpy as np
from sklearn.model_selection import train_test_split

dataset = np.loadtxt('diabetes.csv', delimiter=',', skiprows=1)
training_dataset_x, test_dataset_x, training_dataset_y, test_dataset_y =
train_test_split(dataset[:, :8], dataset[:, 8], test_size=0.2)

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense

model = Sequential()

model.add(Dense(100, input_dim=8, activation='relu', name='Hidden-1'))
model.add(Dense(100, activation='relu', name='Hidden-2'))
model.add(Dense(100, activation='relu', name='Hidden-3'))
model.add(Dense(1, activation='sigmoid', name='Output'))

model.compile(optimizer='adam', loss='binary_crossentropy', metrics=['binary_accuracy'])
model.fit(training_dataset_x, training_dataset_y, batch_size=32, epochs=100,
validation_split=0.2)

```

Elde edilen sonuçlar şöyledir:

```

Epoch 1/100
16/16 [=====] - 1s 9ms/step - loss: 2.1612 - binary_accuracy: 0.5316 - val_loss:
0.7898 - val_binary_accuracy: 0.6179
Epoch 2/100
16/16 [=====] - 0s 2ms/step - loss: 1.1615 - binary_accuracy: 0.5866 - val_loss:
0.8797 - val_binary_accuracy: 0.6748
...
Epoch 99/100
16/16 [=====] - 0s 4ms/step - loss: 0.3778 - binary_accuracy: 0.8187 - val_loss:
0.6744 - val_binary_accuracy: 0.7073
Epoch 100/100
16/16 [=====] - 0s 5ms/step - loss: 0.3641 - binary_accuracy: 0.8147 - val_loss:
0.6834 - val_binary_accuracy: 0.7073

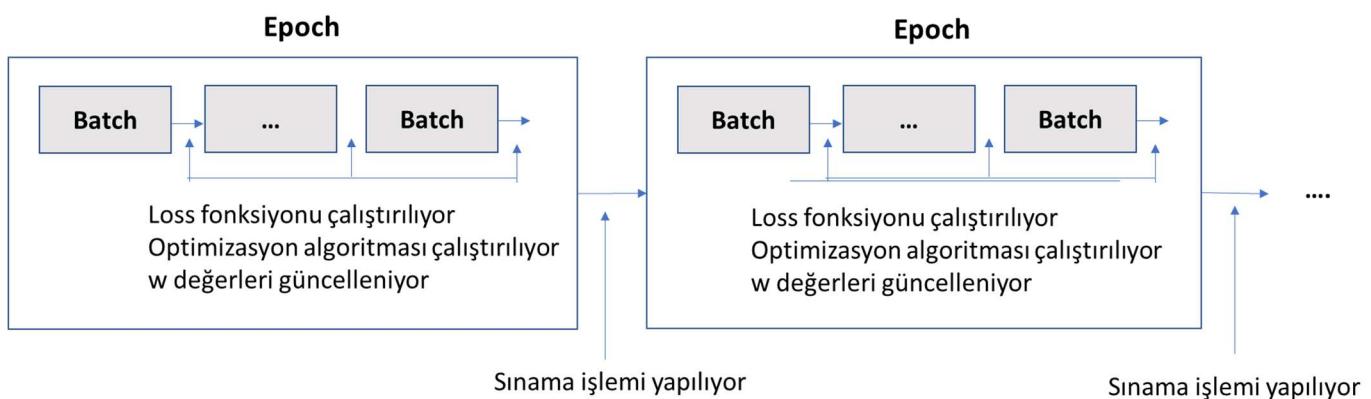
```

İşte her modelde saklı katman sayısının artırılması modeli daha başarılı hale getirmemektedir. Yukarıdaki konularda da degenildiği gibi pek çok regresyon modelinde iki saklı katman yeterli olmaktadır. Bu katmanların sayısının artırılması işlem süresini uzattığı halde başarıyı artırmayabilir. Ancak bazı tarz problemlerde çok katmanlı derin öğrenme ağları çok iyi sonuçların elde edilmesine yol açabilmektedir

Şimdi bu noktaya kadar öğrendiklerimizin bir özeti yapalım:

- Toplam veri kümesi başlangıçta eğitim ve test veri kümesi olmak üzere ikiye ayrılmaktadır. Genellikle test veri kümesi toplam veri kümescinin %20'si civarlarında seçilmektedir.
- Eğitim veri kümesi de kendi arasında ikiye ayrılmaktadır. Asıl kısım eğitimde kullanılacak kısımdır. Diğer kısım sınama amacıyla kullanılan kısımdır. Veri kümescinin sınama amacıyla kullanılan kısma "sınama veri kümesi (validation data set)" diyoruz.
- Batch eğitim verilerinin tek tek değil gruplanarak işleme sokulması anlamına gelmektedir. Batch işlemi hem bir yandan eğitim süresini kısaltırken hem de "overfit" durumunu engelleyebilmektedir. Overfit kavramı ileride ele alınacaktır.
- Epoch toplam eğitim verilerinin baştan sona kaç kere eğitimde kullanılacağını belirtmektedir.
- 'w' değerleri her batch işleminden sonra güncellenmektedir.
- Sınama işlemi ise her epoch'tan sonra yapılmaktadır.

Şimdi de son olarak eğitim süresindeki batch ve epoch kavramlarını bir şekilde özetleyelim:



5) Modelin Test Edilmesi: Şimdi artık sıra modelin test veri kümesiyle test edilmesine gelmiştir. Bu işlem Sequential sınıfının evaluate metoduyla yapılmaktadır. evaluate metodunun parametrik yapısı şöyledir:

```
Sequential.evaluate(
    x=None,
    y=None,
    batch_size=None,
    verbose=1,
    sample_weight=None,
    steps=None,
    callbacks=None,
    max_queue_size=10,
    workers=1,
    use_multiprocessing=False,
    return_dict=False,
    **kwargs
)
```

Metodun ilk iki parametresi test veri kümescinin girdi ve çıktı matrislerini almaktadır. Test süreci batch işlemleriyle tek bir epoch olarak gerçekleştirilmektedir. Metodun batch parametresi batch büyüklüğünü belirtmektedir. Metot bize test veri kümescinden elde edilen metrics değerlerini bir liste olarak vermektedir. Bu metrics değerleri compile metodunda belirtilen metrics fonksyonlarının verdiği değerlerdir. (Kullanılan metrics isimleri ayrıca Sequential sınıfının metrics_names örnek özniteligidinden elde edilebilir.) evaluate metodunun geri dönüş değeri olarak verilen listenin ilk elemanı her zaman "loss" değerine diğer elemanları da metrics ile belirtilen değerlere ilişkindir. Örneğin:

```
eval_result = model.evaluate(test_dataset_x, test_dataset_y)
print(eval_result)
```

Örnek çıktı şöyledir:

```
[0.5974747538566589, 0.6623376607894897]
```

Burada listenin ilk elemanı loss fonksiyonundan elde edilen son değerdir. İkinci elemanı ise compile işleminde belirttikimiz metrik 'binary_accuracy' metrik değeridir. Yazdırma işlemini şöyle de yapabiliyoruz:

```
for i in range(len(eval_result)):
    print(f'{model.metrics_names[i]}: {eval_result[i]}')
```

Buradan şöyle bir çıktı elde edilecektir:

```
loss: 0.5974747538566589
binary_accuracy: 0.6623376607894897
```

6) Model Üzerinde Kestirimlerin Yapılması: Model test edildikten sonra kullanıma hazır hale gelmiştir. Artık kestirimlerde kullanılabilir. Bizim zaten öğrenen modellerden beklediğimiz öğrenilmiş olanlardan hareketle yeni durumlar için modelin kestirimlerde bulunabilmesidir. Kestirim işlemi Sequential sınıfının predict isimli metoduyla yapılmaktadır. Metodun parametrik yapısı şöyledir:

```
Sequential.predict(x,
    batch_size=None,
    verbose=0,
    steps=None,
    callbacks=None,
    max_queue_size=10,
    workers=1,
    use_multiprocessing=False
)
```

Metodun birinci parametresi kestirimde bulunulacak girdi verilerini temsil etmektedir. Yani bu parametre girdi katmanındaki nöronlara uygulanacak değerleri belirtmektedir. Bu girdi verisi tek bir vektör olabileceği gibi bir grup vektör de olabilir. batch_size eğer girdi verisi birden fazlaysa yine bunların kaçarlı biçimde işleme sokulacağını belirtir. Metodun çıktısı normal olarak yapay sinir ağının çıktı katmanındaki değerdir. Tabii metoda birden fazla girdi verilirse çıktı da buna göre birden fazla değerden oluşacaktır. predict metodundaki x parametresi bir matris biçiminde organize edilmelidir. Benzer biçimde predict metodunun geri dönüş değeri de bir matris biçimindedir. Matrisin satırları girdi değerlerine sütunları ise çıktı değerlerine ilişkindir. Örneğin biz predict metoduna n tane gözlemden oluşan n satır girersek ve çıktı tek bir nörondan oluşuyorsa metot bize bize nx1'lik bir matris verecektir. Girdi matrisini şekilsel olarak şöyle gösterebiliriz:

```
X11 X12 X13 ... X1n
X21 X22 X23 ... X2n
X31 X32 X33 ... X3n
X41 X42 X43 ... X4n
X51 X52 X53 ... X5n
```

Burada 5 satırlık bilgi vardır. Her bir satır kestirim için gereken girdileri belirtir. Eğer modelin çıktısı bir tane ise çıktı matrisini de şekilsel olarak şöyle gösterebiliriz:

```
O11
O21
O31
O41
O51
```

Buradaki her satır bir girdinin tahmin edilen çıktısını belirtmektedir.

Yukarıdaki model için örnek bir kestirim şöyle yapılabilir:

```
output = model.predict(x)
print(output)
if output[0, 0] > 0.5:
    print('diyabetli')
else:
    print('diyabetsiz')
```

Burada biz kişinin 8 biyomedikal özelliğini girdi olarak kullanıp bir çıktı elde ettik. Elde ettiğimiz çıktıının görünümü şöyledir:

```
[[0.8509829]]
diyabetli
```

Buradaki 0. 0.8509829 değeri ağıımızın çıktı katmanındaki değerdir. Bu değer sigmoid fonksiyonun elde edildiğini anımsayınız. Halbuki biz bu işlemden ikili (binary) bir değer elde etmek istiyorduk. İşte bu durumda elde ettiğimiz bu değeri bir eşik fonksiyonuna sokmamız gereklidir. Tabii tipik eşik fonksiyonu 0.5'ten büyük değerleri 1 olarak 0.5'ten düşük değerleri 0 olarak veren fonksiyondur.

Yukarıda da belirttiğimiz gibi predict işleminin teker teker yapılması gereklidir. Biz predict metodunda bir matris de verebiliriz. Örneğin:

```
x = np.array([[1, 1, 48, 20, 0, 24.7, 0.90, 22],
              [1, 2, 48, 30, 0, 24.7, 0.92, 22],
              [2, 3, 48, 30, 0, 24.7, 0.94, 22]])

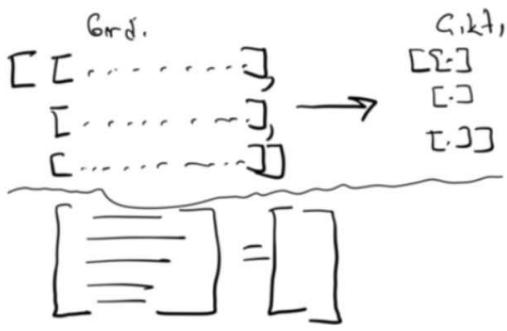
output = model.predict(x)
print(output)

for i in range(len(output)):
    if output[i, 0] > 0.5:
        print('diyabetli')
    else:
        print('diyabetsiz')
```

Bu koddan şöyle bir çıktı elde edilmiştir:

```
[0.6931946873664856, 0.701298713684082]
[[0.80758095]
 [0.36790228]
 [0.48114637]]
diyabetli
diyabetsiz
diyabetsiz
```

Burada predict metoduna üç satırlı bir matris argüman olarak verilmiştir. Yani biz tek hamlede üç farklı gözlem sonucunu tahmin etmek istemekteyiz. O halde predict metodu da bize üç elemanlı bir sütun matrisi verecektir. Bu durumu şekilsel olarak aşağıdaki gibi gösterebiliriz.



Pekiyi predict metodundaki batch_size parametresinin anlamı nedir? Anımsanacağı gibi fit işleminde batch_size bir grup satırın tek bir satırı gibi işleme sokulması anlamına geliyordu. Yani fit işleminde 'w' değerlerinin güncellenmesi her satırda değil her batch_size kadar satırda bir yapılmaktadır. Ancak predict metodundaki batch_size farklı bir anlamdadır. Bu metottaki batch_size predict işlemini aynı anda kaçarlı gruplar halinde yapılacağını belirtmektedir. Yani buradaki batch_size değerinin predict sonucu üzerinde hiçbir etkisi yoktur. Başka bir deyişle biz buraki batch_size değerini 32 versek de (default durum) 1 versek de tamamen aynı sonucu elde ederiz. O halde bu parametrenin ne faydası vardır? Bu parametre içsel olarak Keras'in predict işlemini hızlı yapması konusunda faydalı olabilmektedir.

Keras'ta Kullanılan Veri Kümeleri ve Algoritmalarla İlişkin Kavramların Özeti

Temel olarak bir sinir ağı eğitilirken üç veri kümesi söz konusudur: Eğitim Veri Kümesi (Training Data Set), Sınamma Veri Kümesi (Validation Data Set) ve Test Veri Kümesi (Test Data Set). Bunların oranları uygulamadan uygulamaya değişebilse de genellikle test veri kümesi eğitim veri kümesinin %20'si, sınamma veri kümesi de eğitim veri kümesinin %20'si olarak alınmaktadır. Eğitim veri kümesi -ismi üzerinde- eğitim sürecinde kullanılan veri kümesidir. Sınamma veri kümesi ise eğitim sürecinde her epoch işleminden sonrasında yapılrken kullanılmaktadır. (Sınamma veri kümesinin her batch size'dan sonra değil her epoch'tan sonra uygulandığına dikkat ediniz.) Test veri kümesi tüm eğitim bittikten sonra model test edilirken test için kullanılan veri kümesidir. Pekiyi bu durumda sınamma veri kümesi ile test veri kümesi arasında ya da sınamma işlemi ile test işlemi arasında ne fark vardır? Sınamma veri kümesi her epoch işleminden sonra uygulandığı için modelin epoch işlemlerine göre davranışları gözlenebilmektedir. Halbuki test veri kümesi tüm model eğitildikten sonra performans ölçütlerini belirlemek için kullanılır.

Model eğitilirken her batch size kadar eğitim veri kümesi bir araya getirilerek eğitimde kullanılır. Yani eğitim işlemi birer birer değil çanak çanak (batch batch) yapılmaktadır. Loss fonksiyonunun hesaplanması ve 'w' katsayılarının optimizasyon algoritmasına göre güncellenmesi her batch işleminden sonra yapılmaktadır. Aslında Keras'ta her batch işleminde de callback mekanizmasıyla araya girmek mümkündür

Loss fonksiyonu 'w' değerlerinin güncellenmesi için bir amaç fonksiyonu olarak kullanılmaktadır. Optimizasyon algoritması ise loss fonksiyonuna bakılarak 'w' değerlerinin nasıl güncelleneceğini belirleyen algoritmadır. Yani başka bir deyişle "optimizasyon algoritması loss fonksiyonunu minimize etmek için 'w' değerlerinin nasıl değiştirileceğini belirten algoritmadır."

Pekiyi metrik fonksiyonlar ne anlama gelmektedir? Metrik değerler sınamma süreci ile ilgilidir. Genellikle metrik fonksiyonlar loss fonksiyonuyla aynı olabilir. Ancak eğitimde birden fazla metrik fonksiyon da kullanılabilmektedir. Pekiyi loss fonksiyonu ile metrik fonksiyonları arasında ne fark vardır? İşte loss fonksiyonu optimizasyon algoritmasını uygulamak için bir hedef belirtirken metrik fonksiyonları ise doğrulama işlemi sonucunda bir performs belirtmektedir.

Batch İşleminin Anlamı

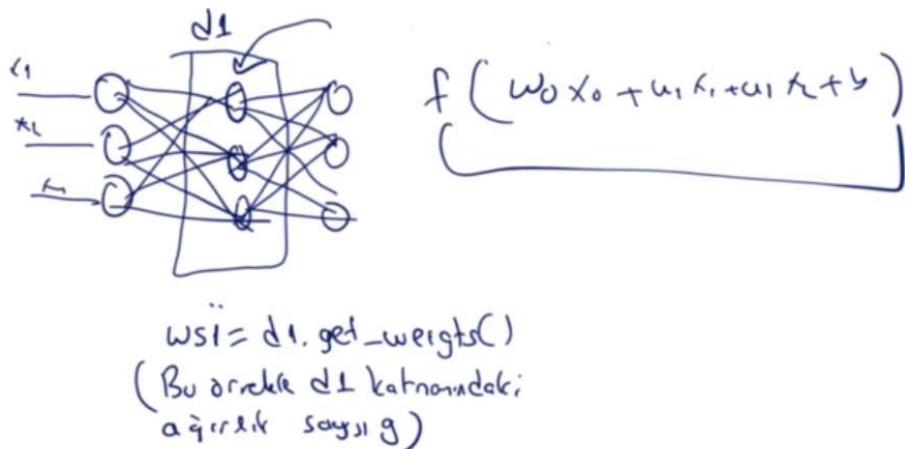
Eğitim ve test sırasında girdi kümelerinin birer birer değil bir grup olarak işleme sokulduğunu belirtmiştik. Bu grubun büyüklüğünə "batch size" denilmektedir. Pekiyi girdilerin teker teker eğitime sokulmayıp grup grub sokulmasının anlamı nedir? Batch işleminin genel olarak bir hızlandırma sağladığını söyleyebilir. Batch işleminin yapılış biçimini kullanılan optimizasyon ve loss fonksiyonuna göre değişimle birlikte tipik uygulanışı şöyledir: Biz batch büyüğünü (batch size) 32 kabul edelim. Bu durumda tipik olarak 32'lik bir kümenin elemanları (bu elemanlara

"örnek (sample)" da denilmektedir) tek tek ve ayrı ayrı ağa sokulup buradan bir loss değeri hesaplanır. Sonra bu loss değerinin batch için ortalaması alınır (örneğimizde bu değer 32'ye bölünecektir.) Bu ortalama değer tek bir değer olarak optimizasyon algoritmasına verilmektedir. Böylece 'w' değerlerini güncellenmesi birer birer değil batch-batch yapılır. 'w' değerlerinin böyle batch batch hesaplanması genel olarak hesaplamayı hızlandırmaktadır. Batch işlemleri aynı zamanda overfit olgusuna karşı bir direnç de oluşturabilmektedir. Overfit olgusu sonraki bölümlerde ele alınmaktadır.

Tabii batch içerisindeki bir grup veri aslında Python'da bir hamlede işleme sokulur. Yani bunun için bir döngü gerekmemektedir. Zaten NumPy kütüphanesi bu işlemi yapmaktadır. Pekiyi biz her ne kadar NumPy'da iki vektörü tek hamlede işleme sokabiliyor olsak da arka planda NumPy bu işlemi işlemciye bir döngü içerisinde sıralı olarak mı yaptırmaktadır? İşte NumPy arka planda C'de yazılmış bir kütüphanedir. İşlemcilerin vektörel işlem yapma yeteneğini de kullanmaktadır. (Örneğin Intel işlemcileri ve ARM işlemcileri böyle vektörel işlemler yapabilmektedir.)

Keras Modelindeki Nöron Ağırlıklarının (W Değerlerinin) Elde Edilmesi ve Yüklenmesi

Keras'ta eğitim sonrasında nöronlarda oluşan ağırlık değerlerini almak isteyebiliriz. Keras model olarak bu bilgileri katman nesnesi ile ilişkilendirmiştir. Dolayısıyla bu bilgiler eğitim sonrasında katman nesnelerinden elde edilebilmektedir. İşte Dense sınıfının (ve diğer katman sınıflarının) get_weights ve set_weights metotları bu ağırlıkların alınması ve yüklenmesi için kullanılmaktadır. Tabii her katman kendi ağırlık değerlerini bize verecektir.



Bir katmandaki nöron ağırlıkları o katmandaki nöronlardan çıkan değil o katmandaki nöronlara giren ağırlık değerleridir.

Mademki nöron ağırlıkları katman nesnelerinin içerisindeidir o halde bizim katmanlardaki nöronların wğırlıklarını elde edebilmemiz için yaratmış olduğumuz katman nesnelerine erişebilmemiz gereklidir. Halbuki biz yukarıda Dense katman nesnelerini yaratır yaratmaz hemen Sequential sınıfının add metodıyla modele ekledik. Yani katman nesnelerini bir değişkende tutmadık. Yukarıdaki örneğin ilgili kısmını anımsayınız:

```
model = Sequential()
model.add(Dense(100, input_dim=8, activation='relu', name='Hidden-1'))
model.add(Dense(100, activation='relu', name='Hidden-2'))
model.add(Dense(1, activation='sigmoid', name='Output'))
...
```

Katman nesnelerini elde edebilmenin bir yolu add metodunu uygulamadan önce onları değişkenlerde saklamak olabilir. Örneğin:

```
model = Sequential()
d1 = Dense(100, input_dim=8, activation='relu', name='Hidden-1')
model.add(d1)
d2 = Dense(100, activation='relu', name='Hidden-2')
model.add(d2)
```

```

d3 = Dense(1, activation='sigmoid', name='Output')
model.add(d3)
...
wd1 = d1.get_weights()
wd2 = d2.get_weights()
wd3 = d3.get_weights()

```

Aslında bu yönteme gerek yoktur. Çünkü Sequential sınıfının zaten layers isimli örnek özniteligi bize katman nesnelerini bir liste biçiminde vermektedir. Bu durumda örneğin biz modelimizin katmanlarına ilişkin ağırlık değerlerini şöyle elde edebiliriz:

```

wd1 = model.layers[0].get_weights()
wd2 = model.layers[1].get_weights()
wd3 = model.layers[2].get_weights()

```

`get_weights` metodu bize duruma göre iki elemanlı ya da tek elemanlı bir NumPy dizi listesi vermektedir. Şöyledi ki: Eğer katman yaratılırken `Dense` fonksiyonunda `bias=False` değeri geçilirse ilgili katmandaki nöronlarda bias değerleri kullanılmayacaktır. Bu durumda `get_weights` metodu da yalnızca ağırlık matrisinden oluşan bir elemanlı liste verecektir. Eğer katman yaratılırken `Dense` fonksiyonunda `bias=True` değeri geçilirse (default durum zaten böyledir) artık `get_weights` fonksiyonu iki elemanlı bir listeye geri dönecektir. Bu durumda listenin ilk elemanı ağırlık matrisinden diğer elemanı bias değerlerinden oluşacaktır. Anımsanacağı gibi bias değeri her nöron için oluşturulan bir değerdir. Dolayısıyla örneğin eğer katmanımızda 100 nöron varsa 100 tane bias değeri olacaktır. Bu bias değerlerinin ne işe yaradığı ileride ele alınacaktır. Ancak bu bias değerleri de eğitilmiş modelin bir parçasını oluşturmaktadır.

`get_weights` metodlarının verdiği ağırlık değerleri önceki katmanın çıkışlarının ilgili katmanın girişlerine bağlılığı ağırlık değerleridir. Örneğin `get_weights` metodunun çağrıldığı katmanda 100 nöron olsun. Önceki katmanda da 8 nöron olsun. Bu durumda `get_weights` bize 8×100 'luk bir ağırlık matrisi verecektir. Bu matrisin satırları önceki katman nöronlarına sütunları ise ilgili katmanın nöronlarına ilişkindir.

Yukarıdaki örnek modeldeki `d1` katmanından (birinci saklı katmandan) elde edilen ağırlık değerlerine ilişkin `wd1` dizisinin eleman türlerine ve uzunluklarına dikkat ediniz:

```
In [93]: wd1[0].shape
Out[93]: (8, 100)
```

```
In [94]: wd1[1].shape
Out[94]: (100,)
```

```
In [95]: type(wd1)
Out[95]: list
```

```
In [96]: len(wd1)
Out[96]: 2
```

```
In [97]: type(wd1[0])
Out[97]: numpy.ndarray
```

```
In [98]: wd1[0].shape
Out[98]: (8, 100)
```

```
In [99]: type(wd1[1])
Out[99]: numpy.ndarray
```

```
In [100]: wd1[1].shape
Out[100]: (100,)
```

Listenin 0'inci indeksli elemanı o katmandaki nöronların ağırlıklarını vermektedir. Bu katmanda 8 girdi nöronu dense bir biçimde katmandaki 100 nörona bağlandığına göre toplamda her biri 8 elemandan oluşan 100 ağırlık değer

olacaktır. Yine bu katmandaki bias değerlerinin nöron sayısı olan 100 tane olduğuna dikkat ediniz. Pekiyi şimdî de modelin ikinci saklı katmanına ilişkin ağırlık değerlerinin kaçar tane olduğuna bakalım. İkinci saklı katmandaki nöronun her birine toplam 100 nöron girecektir. Bu durumda ikinci saklı katmandaki ağırlık değerleri (100, 100) biçiminde bir matris ile ifade edilecektir. Bu matrisin 10000 elemanı olduğuna dikkat ediniz. Bu katmandaki toplam bias değerleri 100 tane (katmandaki nöron sayısı) olacaktır:

```
In [110]: wd2[0].shape  
Out[110]: (100, 100)
```

```
In [111]: wd2[1].shape  
Out[111]: (100, )
```

Şimdî de çıktı katmanındaki ağırlık değerlerinin hangi sayıda olması gerektîgine bakalım. Çıktı katmanının nöron sayısı 1 tanedir. Önceki katmandaki 100 nöron bu katmandaki bu tek nörona girdi yapılmıştır. O halde çıktı katmanındaki ağırlık matrisinin (100, 1) olması gerekir. Çıktı katmanı tek nörondan oluştugu göre toplamda tek bir bias değeri vardır:

```
In [116]: wd3[0].shape  
Out[116]: (100, 1)
```

```
In [117]: wd3[1].shape  
Out[117]: (1, )
```

set_weights metodu da benzer biçimde ağırlık değerlerini ilgili katmana yüklemek için kullanılmaktadır. Yani örneğin aşağıdaki gibi biz katmandaki ağırlık değerlerini get_weights metodu ile alıp set_weights metodu ile yükleyebiliriz:

```
wd1 = model.layers[0].get_weights()  
...  
model.layers[0].set_weights(wd1)
```

set_weights metodunun da iki elemanlı uygun uzunluklarda indeksli dolaşılabilir nesne aldığına dikkat ediniz.

Keras Modelinin Özet Bilgisinin Görüntülenmesi

Bir Keras modeli oluşturulduktan sonra model sınıflarının summary isimli metotları bize model hakkında özet bilgiler vermektedir. Örneğin aşağıdaki gibi bir model söz konusu olsun:

```
import numpy as np  
  
from tensorflow.keras import Sequential  
from tensorflow.keras.layers import Dense  
from sklearn.model_selection import train_test_split  
  
dataset = np.loadtxt('diabetes.csv', skiprows=1, delimiter=',')  
dataset_x = dataset[:, :-1]  
dataset_y = dataset[:, -1]  
training_dataset_x, test_dataset_x, training_dataset_y, test_dataset_y =  
train_test_split(dataset_x, dataset_y,  
test_size=0.20)  
  
model = Sequential()  
model.add(Dense(100, input_dim=8, activation='relu', name='Hidden-1'))  
model.add(Dense(100, activation='relu', name='Hidden-2'))  
model.add(Dense(1, activation='sigmoid', name='Output'))  
  
model.summary()
```

Elde edilen summary bilgisi şöyledir:

Layer (type)	Output Shape	Param #
Hidden-1 (Dense)	(None, 100)	900
Hidden-2 (Dense)	(None, 100)	10100
Output (Dense)	(None, 1)	101
<hr/>		
Total params: 11,101		
Trainable params: 11,101		
Non-trainable params: 0		

Burada birinci sütunda katmanın ismini görüyorsunuz. İkinci sütunda ilgili katmanın çıkışındaki nöron miktarları belirtilmektedir. Nihayet son sütunda her katmandaki tahmin edilecek parametre sayılarını görmektesiniz. Birinci katmandaki parametre sayısının $8 * 100 + 100 = 900$, ikinci katmandaki parametre sayısının $100 * 100 + 100 = 10100$ ve üçüncü katmandaki parametre sayısının ise $100 * 1 + 1 = 101$ olduğuna dikkat ediniz.

Oluşturulan Modelin ve Modeldeki Tüm Ağırlık Değerlerinin Bir Dosyada Saklanması ve Geri Yüklenmesi

Bir modeli eğittikten sonra bilgisayarı kapadığımızda tüm eğitim bilgileri kaybolacaktır. İşte onun başka zaman kullanılabilmesi için bir dosyada saklanması gerekebilmektedir. Keras bu işlemler için HDF (Hierarchical Data Format) dosya formatını kullanmaktadır. Sequential sınıfının save isimli metodu bizden .h5 ya da .hdf5 uzantılı HDF dosyasının yol ifadesini alır; model bilgilerini, ağırlık ve bias değerlerini bu dosyaya save eder. Örneğin:

```
model.save('diabetes.h5')
```

Artı biz tüm modeli her şeyle bir dosya içerisinde saklamış olduk. Onu geri almak için tensorflow.keras.models modülündeki load_model fonksiyonu kullanılmaktadır. Bu fonksiyon da benzer biçimde HDF dosyasının yol ifadesini argüman olarak alır. Tüm modeli ağırlık ve bias değerleriyle yeniden yükler, yeni bir model nesnesi yaratarak bize onu verir. Örneğin:

```
from tensorflow.keras.models import load_model
model = load_model('diabetes.h5')
```

Şimdi yukarıdaki örneği save edip tekrar yükleyerek predict işlemi yapalım:

```
# keras-model-save.py
import numpy as np
from tensorflow.keras import Sequential
from tensorflow.keras.layers import Dense
from sklearn.model_selection import train_test_split

dataset = np.loadtxt('diabetes.csv', skiprows=1, delimiter=',')
dataset_x = dataset[:, :-1]
dataset_y = dataset[:, -1]
training_dataset_x, test_dataset_x, training_dataset_y, test_dataset_y =
train_test_split(dataset_x, dataset_y,
test_size=0.20)

model = Sequential()
model.add(Dense(100, input_dim=8, activation='relu', name='Hidden-1'))
model.add(Dense(100, activation='relu', name='Hidden-2'))
model.add(Dense(1, activation='sigmoid', name='Output'))

model.compile(optimizer='adam', loss='binary_crossentropy', metrics=['binary_accuracy'])
```

```

model.fit(training_dataset_x, training_dataset_y, batch_size=32, epochs=200,
validation_split=0.2)
result = model.evaluate(test_dataset_x, test_dataset_y)

for i in range(len(result)):
    print('{} = {}'.format(model.metrics_names[i], result[i]))

model.save('diabetes.h5')

# keras-model-Load.py

import numpy as np
from tensorflow.keras.models import load_model

model = load_model('diabetes.h5')

predict_x = np.array([[5.0, 73.0, 60.0, 0., 0., 29.8, 0.368, 25.0],
[6.0, 43.0, 70.0, 0., 0., 29.8, 0.368, 25.0],
[6.0, 73.0, 70.0, 0., 0., 39.8, 0.668, 25.0]])

predict_result = model.predict(predict_x)

for i in range(len(predict_result)):
    if result[i, 0] < 0.5:
        print('Şeker hastası değil')
    else:
        print('Şeker hastası')

```

Bazen programcı yalnızca ağırlık değerlerini (tabii bias değerleri de dahil olmak üzere) saklayıp geri yüklemek isteyebilir. Bu işlem Sequential sınıfının save_weights ve load_weights metodlarıyla yapılmaktadır. Örneğin:

```

ws = model.save_weights('diabtes_weights.h5')
...
model.load_weights('diabtes_weights.h5')

```

Tabii bu durumda biz bu ağırlık değerlerini kullanabilmek için modeli yeniden oluşturmalıyız. Çünkü save_weights model bilgilerini saklamamaktadır. Yalnızca modeldeki tüm nöronların ağırlık değerlerini saklamaktadır.

İstenirse load işlemi yapılırken yalnızca aynı isimli katmanların ağırlıkları da yüklenebilmektedir. Şöyledi ki: Dense fonksiyonunda name isimli parametre yoluyla katmanlara tek olan (unique) isimler verebilmekteyiz. İşte Sequential sınıfının load_weights isimli metodunun da by_name isimli bool değer alan bir parametresi vardır. Bu parametre default durumda False biçimdedir. Eğer bu parametre True yapılrsa bu durumda diskte saklanmış olan modeldeki katman isimleriyle hali hazırda çalışmakta olan model nesnesindeki katmanların isimleri karşılaştırılır. Aynı isimli olan katmandaki ağırlık ve bias değerleri yüklenir. Örneğin:

```
model.load_weights('diabtes_weights.h5', by_name=True)
```

Burada diskte 'x' ve 'y' isimli iki katman olsun. Şu andaki model nesnesinde de bu isimli iki katmanın bulunduğu varsayılmıştır. Artık load_weights metodu yalnızca bu katmanların ağırlık ve bias değerlerini mevcut modeldeki kilerin üzerine yükleyecektir.

Bir modeli diske save ettikten sonra onu tekrar yükleyerek eğitime devam edebiliriz. Yani eğitimin (fit metodunun) yalnızca bir kez aynı zaman dilimi içerisinde yapılması gerekmemektedir.

Yapay Sinir Ağlarını Kullanarak Kestirim Yapmak İçin Aşamalar

Aslında yapay sinir ağları bir regresyon modeli oluşturmaktadır. Yani biz yapay sinir ağının eğitilmesi sonucunda $y = f(x)$ gibi bir fonksiyon elde ederiz. Sonra bu fonksiyona x değerini verdığımızda fonksiyon da bize kestirilen y

değerini verir. Tabiiyapay sinir ağlarının dışında istatistikte de regresyon amacıyla kullanılan çok sayıda istatistiksel yöntem vardır. Bu yöntemler ileride ele alınacaktır. Ancak yapay sinir ağları çok sayıda özelliğin (feature) olduğu ve özellikler arasında karmaşık etkileşimlerin bulunduğu durumlarda diğer yöntemlere göre çok daha iyi sonuçlar vermektedir.

Yapay sinir ağlarının kullanılması için tipik aşamalar şunlardır:

1) Hedefin Belirlenmesi Süreci: Önce bizim yapay sinir ağını neden oluşturmak istediğimizi biliyor olmamız gereklidir. Yani bizim ağı oluşturmaktaki amacımız nedir? Biz ağı kullanarak neyi kestirmeye çalışmak istemektedir. Örneğin bir dershanedeki öğrenciler arasında üniversite sınavında belli bir puanın yukarısında puan elde edebilecek kişileri önceden tespit etmek isteyelim. Bu öğrencilere özel bazı olanakların sunulması söz konusu olabilir ve kurum da bu olanakları sunacağı öğrencileri mümkün olduğu kadar önce tespit etmek isteyebilir. Ya da örneğin bir kurumun çeşitli mağazaları olabilir ve yönetim belli bir mağazadaki dönemsel ciroyu tahmin etmek isteyebilir. Bunun sonucu olarak kurum bazı politikaları daha uygun belirleyebilecektir.

Amaç kabaca tespit edildikten sonra bunun daha ayrıntılı ve operasyonel hale getirilmesi gerekmektedir. Yani kaba bir amaçtan ziyade giridisi çıktıısı belli değerlerle temsil edilen bir amaç haline dönüştürülmelidir.

2) Kestirimle İlgili Olabilecek Özelliklerin (Features) Belirlenmesi Süreci: Veri bilimcisinin kestirimde bulunacağı olguya etkileyen etmenleri (features) bir biçimde tespit etmiş olması gerekmektedir. Biz bunu önceki bölümlerde "özellik seçimi (feature selection)" başlığı altında kısaca ele almıştık. Kestirimle ilgili olabilecek özelliklerin neler olabileceğinin belirlenmesi sürecin önemli adımlarından biridir. Eğer özellikler yanlış ya da yetersiz seçilirse öğrenme bizim istediğimiz ölçüde olamayacaktır. Örneğin bir taşıtin kilometre başına yaktığı yakıtın tahmin edilmesinde rol oynayan özelliklerin bazıları şunlar olabilir:

- Aracın motor hacmi
- Aracın ağırlığı
- Aracın benzinle mi motorinle mi gazla mı çalıştığı
- Aracın yaşı

Biz şimdi burada aracın motor hacmini bir özellik olarak ağımlıza dahil etmezsek ağımlıza ne kadar doğru kestirimlerde bulunabilir ki?

Örneğin bir öğrencinin başarısına etki eden faktörler neler olabilir?

- Öğrencinin zeka düzeyi
- Öğrencinin derslere devam oranı
- Öğrencinin geçmişteki not ortalaması
- Öğrencinin ailesinin ekonomik durumu
- Öğrencinin ailesinin eğitim düzeyi
- Öğrencideki sağlık problemleri
- Ailedeki sağlık problemleri
- Öğrencinin sınıf dışında toplam günlük ortalama çalışma zamanı
- Öğrencinin daha önce nereden geldiği
- Öğrencinin hobilerine ayırdığı zaman
- Öğrencinin anne babasının ayrı olup olmadığı
- Öğrencinin okul ile evi arasındaki uzaklık

Bir eczanenin curosunu etkileyebilecek özellikler de şunlar olabilir:

- Eczanenin önünden günlük ortalama geçen insan sayısı
- Eczanenin bulunduğu bölge (kategorik)
- Eczanenin yakınlarında bir ya da birden fazla sağlık kurumunun olup olmadığı bilgisi
- Eczanenin hangi kurumlarla anlaşmalı olup olmadığı
- Eczanenin yakınındaki eczane sayısı

- Eczanenin güzellik ürünü satıp satmadığı (kategorik)
- Eczanenin takviye ürünler satıp satmadığı (kategorik)
- Eczanenin büyülüğu

Bu özellikler belirlendikten sonra onların mümkün olduğu kadar operasyonel hale getirilmeleri gereklidir. Operasyonel demek bir özelliği ölçülebilir bir biçimde ifade etmek demektir. Örneğin bir mağazanın albenisi operasyonel bir özellik değildir. Ancak bunu likert tarzı bir ölcükle operasyonel hale getirebiliriz.

Burada önemli bir noktayı vurgulamak istiyoruz. Özelliklerin belirlenmesi uzmanlık gerektiren bir alandır. Eğer veri bilimcisi konu ile ilgili uzman bilgisine sahip değilse bu aşamada mutlaka uzmanlardan yardım olması gerekebilir. Biz uzmanı olmadığıımız konulardaki özellikleri isabetli bir biçimde belirleyemeyebiliriz.

3) Eğitim İçin Verilerin Toplanması Süreci: Veri bilimcisinin eğitimde kullanacağı geçmiş birtakım verileri ve bunlara karşı gelen gerçek değerleri (training dataset_x ve training dataset_y) bir biçimde elde etmiş olması gerekmektedir. Biz kursumuzda genellikle zaten elde edilmiş olan hazır veriler üzerinde çalışacağız. İyi de bu veriler kimler tarafından ve nasıl elde edilmiş? İşte veriler değişik kaynaklardan elde edilmiş olabilirler. Örneğin bazı veriler zaten elde edilmiş ve veritabanlarında bulunuyor olabilir. Bazı veriler birtakım kurumlardaki (örneğin Türkiye İstatistik Kurumu gibi) veritabanlarından elde edilebilir. Bazen verileri biz anketler yoluyla elde etmek zorunda kalabilirmiz. Bazı veriler ise sensörler yoluyla otomatik bir biçimde elde ediliyor olabilir. Özellikle son 20 yıldır sensörler yoluyla verilerin elde edilmesi konusunda çok ilerlemeler kaydedilmiştir. IOT uygulamalarının yaygınlaşmasıyla otomatik veri elde etme çok yaygınlaşmıştır. Örneğin biz belli bir kavşakta hangi günün hangi saatinde ne kadar aracın bulunuyor olabileceğini tahmin etmeye çalışalım. Burada verileri kavşağa yerlestireceğimiz sensörler yoluyla elde edebiliriz. (Artık dünyada adaptif kavşak yönetim sistemlerinde bu tür sensörler yaygın olarak kullanılmaktadır.)

4) Verilerin Kullanıma Hazır Hale Getirilmesi Süreci: Veriler toplandıktan sonra bunların önişleme sokulması gerekebilmektedir. Biz daha önce bu konuda özet bilgiler vermişizdir. Önişlem sırasında geçersiz verilerin atılması ya da düzeltilmesi, kategorik verilerin sayısallaştırılması, gereksiz ve yüksek korelasyonlu sütunların atılması en çok uygulanan yöntemlerdendir.

5) Yapay Sinir Ağı Modelinin Kurulması Süreci: Artık sıra sinir ağı yapay modelinin kurulmasına gelmiştir. Ağımızın mimarisi nasıl olacaktır? Ağımızda kaç saklı katman bulunacaktır? Katmanlardaki aktivasyon fonksiyonları, ağ için kullanılacak loss fonksiyonu ve optimizasyon fonksiyonu nasıl olacaktır? Bu aşamada bu belirlemeler yapılmalıdır.

6) Modelin Eğitilmesi ve Test Edilmesi Süreci: Bundan sonra model gerçek verilerle eğitilir ve test edilir. Artık elimizde kestirimde kullanılabilecek ve başarısı hakkında fikrimiz olan bir model vardır.

7) Kestirimde Bulunma Süreci: Artık ağımız hazır olduğuna göre istediğimiz zaman kestirimde bulunabiliriz.

Keras Modelinde Callback Mekanızması

Keras kütüphanesinde bazı işlemlerde programcının bilgilendirilmesi için "callback" denilen bir mekanizma bulunmaktadır. Bu mekanizma sayesinde fit, evaluate ve predict metodları işlemlerini yaparken programcının belirlediği kodları çalıştırılabilir. fit, evaluate ve predict metodlarının callbacs isimli parametreleri vardır. Bu parametreye callback görevini yapacak bir fonksiyon ya da sınıf nesnesi (callable bir nesne) yerleştirilir. Bazı callback sınıfları zaten hazır durumdadır. Bu nedenle programcının kendi callback sınıflarını yazması genellikle gerekmemektedir. Ancak programcı isterse kendi callback sınıflarını da yazabilir. Biz burada önce hazır birkaç callback sınıfını ele alacağımız sonra da callback sınıflarının nasıl yazılabileceği hakkında bir örnek vereceğiz. Diğer callback sınıfları için Keras dokümanlarına başvurulabilir. Keras'taki tüm callback sınıfları tensorflow.keras.callbacks modülündeki Callback isimli sınıfından türetilmiş durumdadır.

History isimli callback sınıfı kayıt işlemi yapmaktadır. Yani örneğin fit metodu çalışırken bu callback sınıfı bizim için bazı kayıtlar tutar. fit metodunun çalışması bittikten sonra biz bu kayıtları alıp kullanabiliriz. Aslında fit metodunun callbacks parametresine biz History callback sınıfı nesnesini geçirmek zorunda değiliz. fit metodu zaten her zaman bu kaydı yaparak bize bu History nesnesini geri dönüş değeri olarak vermektedir. Biz de yapılan kayıtları fit metodunun geri dönüş değerinden alarak kullanabiliriz. Örneğin:

```
hist = model.fit(training_set_x, training_set_y, batch_size=30, epochs=100)
```

History nesnesinin history isimli örnek özniteliği dict türündendir. Bu sözlük nesnesinin anahtarları "elde edilecek bilginin isimlerini", değerleri de her epoch için ilgili değerleri bize vermektedir. history örnek özniteliği ile biz verilen sözlükte her zaman 'loss' isimli bir anahtar bulunmaktadır. Bu sözlüğün diğer anahtarları ise bizim fit metodunda metrics'te verdığımız metrik isimleridir. Örneğin yukarıdaki model şöyle konfigüre edilmiş olsun:

```
model.compile(optimizer='adam', loss='binary_crossentropy', metrics=['binary_accuracy'])
```

Bu durumda history nesnesinin keys metodu bize üç anahtar verecektir:

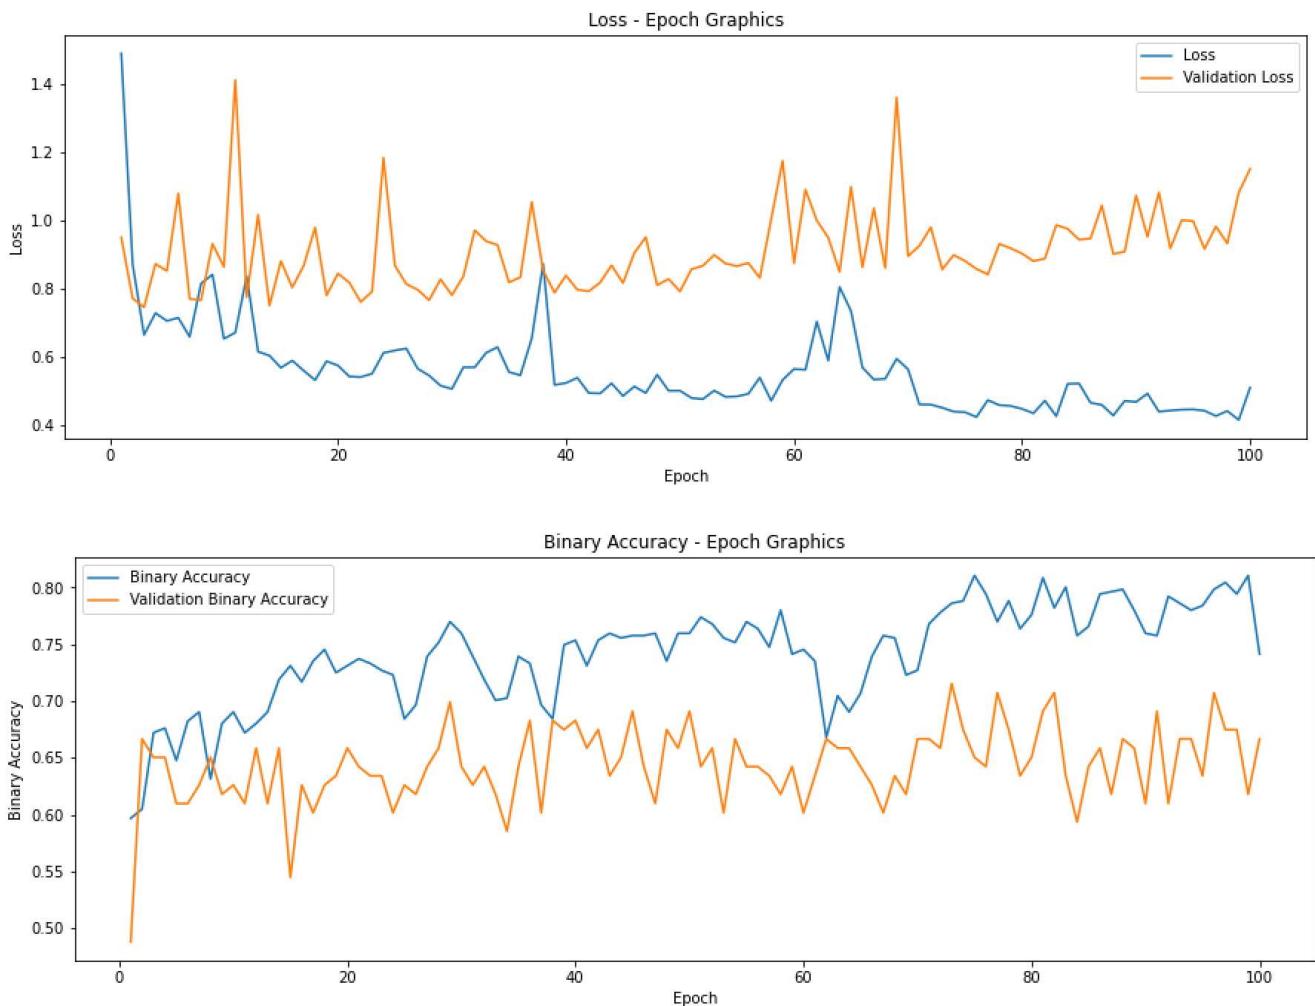
```
In [38]: hist.history.keys()
Out[38]: dict_keys(['loss', 'binary_accuracy', 'val_loss', 'val_binary_accuracy'])
```

Burada başı "val_" ile başlayan "val_xxx" biçimindeki anahtarlar epoch sonrasında sınıma işlemlerinden elde edilen değerleri, başı "val_" ile başlamayan anahtarlar ise doğrudan eğitim veri kümesine ilişkin değerleri belirtmektedir. Bu anahtarları biz sözlüğe verdığımızda sözlük bize her epoch sonrasında ilgili değeri bir liste biçiminde vermektedir. Örneğin burada 100 epoch uygulandığına göre bu dizinin elemanları 100'lük olacaktır. Bu durumda biz fit işleminde her epoch'tan elde edilen metrik değerlerinin grafiğini şöyle çizdirebiliriz:

```
import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Loss - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.plot(range(1, len(hist.history['loss']) + 1), hist.history['loss'])
plt.plot(range(1, len(hist.history['val_loss']) + 1), hist.history['val_loss'])
plt.legend(['Loss', 'Validation Loss'])
plt.show()

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Binary Accuracy - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Binary Accuracy')
plt.plot(range(1, len(hist.history['binary_accuracy']) + 1), hist.history['binary_accuracy'])
plt.plot(range(1, len(hist.history['val_binary_accuracy']) + 1),
hist.history['val_binary_accuracy'])
plt.legend(['Binary Accuracy', 'Validation Binary Accuracy'])
plt.show()
```



Pekiyi history bilgilerine neden gereksinim duyabiliyoruz? İşte modeli eğitirken en uygun epoch değerini belirlemeye bu grafiklerden faydalananabiliriz. Çünkü grafikler çizildiğinde belli epoch değerlerinden sonra anomaliler gözle görülebilmektedir. Aynı zamanda hangi epoch değerinden sonra artık epoch'u artırmanın bir fayda sağlamadığı da görülebilmektedir. Aynı zamanda yukarıdaki grafikler bize epoch kaynaklı overfit durumu hakkında da bilgi verebilmektedir. Örneğin epoch değerini 100'den 1000'e çıkartarak grafikleri yeniden oluşturalım:

```

import numpy as np
from tensorflow.keras import Sequential
from tensorflow.keras.layers import Dense
from sklearn.model_selection import train_test_split

dataset = np.loadtxt('diabetes.csv', skiprows=1, delimiter=',')
dataset_x = dataset[:, :-1]
dataset_y = dataset[:, -1]
training_dataset_x, test_dataset_x, training_dataset_y, test_dataset_y =
train_test_split(dataset_x, dataset_y,
test_size=0.20)

model = Sequential()
model.add(Dense(100, input_dim=8, activation='relu', name='Hidden-1'))
model.add(Dense(100, activation='relu', name='Hidden-2'))
model.add(Dense(1, activation='sigmoid', name='Output'))

model.compile(optimizer='adam', loss='binary_crossentropy', metrics=['binary_accuracy'])

hist = model.fit(training_dataset_x, training_dataset_y, batch_size=32, epochs=1000,
validation_split=0.2)

import matplotlib.pyplot as plt

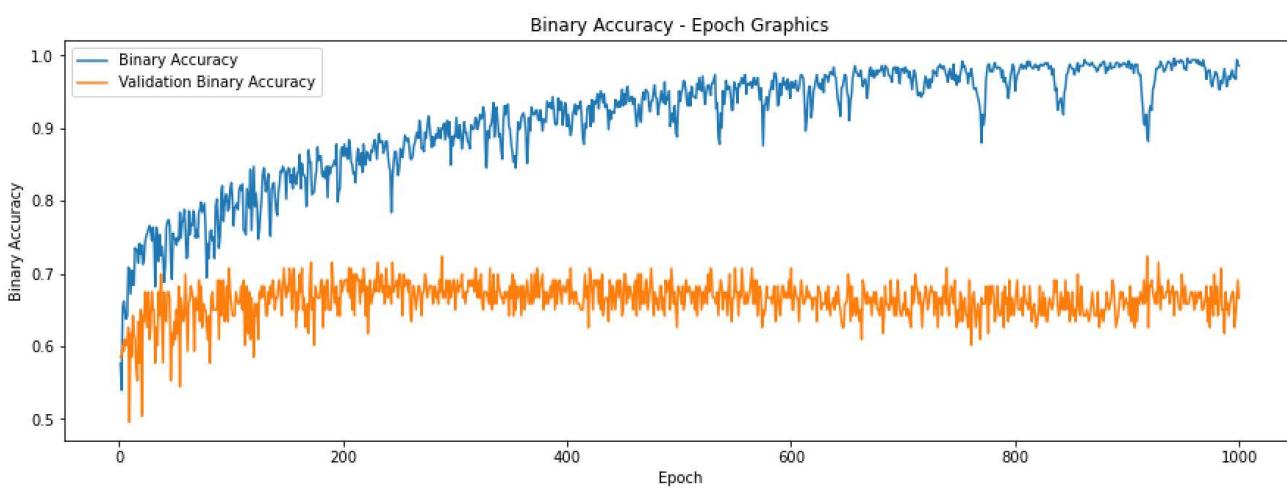
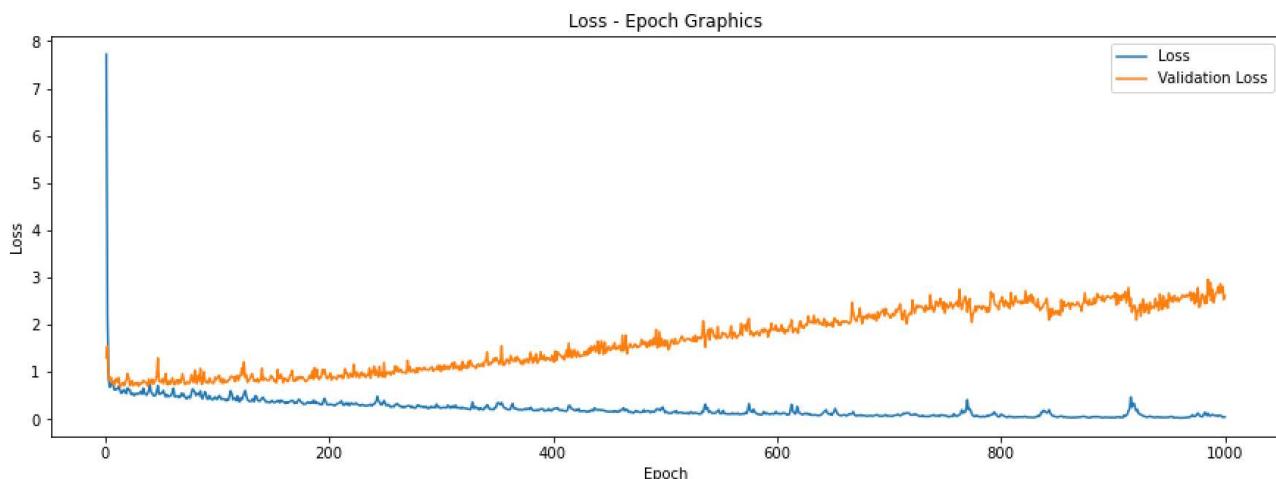
```

```

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Loss - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.plot(range(1, len(hist.history['loss']) + 1), hist.history['loss'])
plt.plot(range(1, len(hist.history['val_loss']) + 1), hist.history['val_loss'])
plt.legend(['Loss', 'Validation Loss'])
plt.show()

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Binary Accuracy - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Binary Accuracy')
plt.plot(range(1, len(hist.history['binary_accuracy']) + 1), hist.history['binary_accuracy'])
plt.plot(range(1, len(hist.history['val_binary_accuracy']) + 1),
hist.history['val_binary_accuracy'])
plt.legend(['Binary Accuracy', 'Validation Binary Accuracy'])
plt.show()

```



Gördüğünüz gibi 100 civarında bir epoch'tan sonra eğitim verilerinin verdiği metrik değerleriyle sınama verilerinin verdiği metrik değerler birbirinden kopmaya başlamıştır. Bu olguya "overfit" denilmektedir. Overfit olgusu ileride ayrı bir başlıkta ele alınacaktır.

CSVLogger isimli callback sınıfı tipki History gibi epoch temelinde kayıt yapmaktadır. Ancak history'den farklı olarak bu kaydı bir CSV dosyasına yazar. Örneğin:

```

csv_callback = CSVLogger('diabetes.csv')
h = model.fit(training_set_x, training_set_y, batch_size=30, epochs=500,
 callbacks=[csv_callback])

```

Metotlardaki callbacks parametresinin bir liste olduğuna dikkat ediniz. Yani biz bu metotlara birden fazla callback nesnesi geçirebiliriz.

Diğer çok kullanılan hazır callback sınıflarından biri de LambdaCallback sınıfıdır. Bu callback nesnesi aslında çeşitli olaylarda bizim ona verdiğimiz fonksiyonları çağrılmaktadır. LambdaCallback sınıfının `__init__` metodu şöyledir:

```

tf.keras.callbacks.LambdaCallback(
    on_epoch_begin=None,
    on_epoch_end=None,
    on_batch_begin=None,
    on_batch_end=None,
    on_train_begin=None,
    on_train_end=None,
    **kwargs
)

```

Metodun parametreleri olayları anlatmaktadır. Biz bu her parametreye bir fonksiyon girebiliriz. Bu fonksiyonların parametreleri de vardır. Parametreleri şunlardır:

Fonksiyon	Parametreler
on_epoch_begin	epoch ve logs
on_epoch_end	epoch ve logs
on_batch_begin	batch ve logs
on_batch_end	batch ve logs
on_train_begin	logs
on_train_end	logs

Buradaki epoch ve batch parametreleri epoch ve batch numaralarını vermektedir. logs parametresi ise bir sözlük biçimindedir. Tıpkı history nesnesinde olduğu gibi bize loss ve metrik değerleri bize verir. logs parametresinin verdiği loss ve metrik değerler on_xxx_begin fonksiyonlarında batch ya da epoch başlangıcındaki değerler, on_xxx_end fonksiyonlarında ise batch ya da epoch sonundaki değerlerdir.

Programcı kendisi de (custom) callback sınıfı yazabilir. Bunun için sınıfını tensorflow.keras.callbacks.Callback sınıfından türetmesi gereklidir. İşte aşağıdaki metodlar sınıfta yazılırsa ilgili işlemde bu metodlar devreye girecektir:

```

on_epoch_begin
on_epoch_end
on_batch_begin
on_batch_end
on_train_begin
on_train_end

```

Örneğin:

```

from tensorflow.keras.callbacks import Callback

class MyCallback(Callback):
    def on_epoch_begin(self, epoch, logs):
        print('epoch {} begins...'.format(epoch))

    def on_epoch_end(self, epoch, logs):
        print('epoch {} ends...'.format(epoch))

```

```

my_callback = MyCallback()
hist = model.fit(training_dataset_x, training_dataset_y, batch_size=32, epochs=10,
validation_split=0.2, callbacks=[my_callback])
result = model.evaluate(test_dataset_x, test_dataset_y)

```

Genel olarak buradaki metodların parametrik yapıları tensorflow.keras.callbacks. Callback sınıfında aşağıdaki biçimde belirtilmiştir. Programcının metodlarını yazarken bu parametrik yapılara uyması gereklidir:

```

class Callback(object):
    def __init__(self):
        self.validation_data = None
        self.model = None

    def set_params(self, params):
        self.params = params

    def set_model(self, model):
        self.model = model

    def on_epoch_begin(self, epoch, logs=None):
        pass

    def on_epoch_end(self, epoch, logs=None):
        pass

    def on_batch_begin(self, batch, logs=None):
        pass

    def on_batch_end(self, batch, logs=None):
        pass

    def on_train_begin(self, logs=None):
        pass

    def on_train_end(self, logs=None):
        pass

```

Metotlardaki batch parametresi o andaki batch uzuluğunu, epoch parametresi ise o andaki epoch numarasını belirtmektedir. logs parametresi ise yine metrik değerlerinin bulunduğu biz sözlük nesnesidir.

Verilerin Kullanıma Hazır Hale Getirilmesi Sürecinde Özellik Ölçeklendirmesi (Feature Scaling)

Biz daha önce verilerin kullanıma hazır hale getirilmesi sürecini çeşitli alt başlıklar halinde gruplandırmıştık. İşte bu alt başlıklardan "veri dönüştürmesi (data transformation)" grubundaki önemli bir teknik de "özellik ölçeklendirmesi (feature scaling)" denen tekniktir. Eğer bir veri tablosundaki sütunlarda bulunan değerlerin mertebeleleri birbirinden çok farklı ise yapay sinir ağlarının bu durumlarda başarısı düşmektedir. Verilerin farklı mertebelere sahip olması aynı zamanda "geç yakınsama" sorunları da oluşturmaktadır. Örneğin bir evin fiyatının tahmin edilmesi örneğinde sütunların birinde evin kira geliri 1000'li mertebede iken diğer bir sütunda bulunan evin yaşı çok küçük bir mertebededir.

Özellik ölçeklendirmesinin neden gerektiği sezgisel olarak da anlaşılabilir. Bir nörona giren değerlerin ağırlıklarla çarpılarak toplandığını biliyorsunuz. Bu durumda yüksek mertebedeki değerler düşük mertebedeki değerlerin etkisini azaltabilecektir değil mi? Tabii özellik ölçeklendirmesi yalnızca yapay sinir ağlarında değil makine öğrenmesinin diğer bazı konularında da uygulanan bir tekniktir. Ancak "rassal ormanlar (random forest)", "karar ağaçları (decision trees)" gibi bazı makine öğrenmesi yöntemlerinde özellik ölçeklendirmesine gerek duyulmamaktadır.

Standart Ölçekleme (Standard Scaling): Bu yöntemde sütunun ortalaması ve standart sapması bulunur. Sonra sütundaki her değer ortalamadan çıkartılıp standart sapmaya bölünerek yeniden sütuna yazılır.

$$yeni \bar{x} = \frac{\bar{x} - \bar{x}}{\sigma_x}$$

Anımsayacağınız gibi aslında bu işlem farklı ortalama ve standart sapmaya ilişkin normal dağılım değerlerinin standart normal dağılım değerlerine (ortalaması 0, standart sapması 1 olan normal değerlerine) dönüştürülmesi için de kullanıldığını biliyorsunuz. Bu nedenle bu yönteme "özelliklerin standart hale getirilmesi (feature standardization)" de denilmektedir.

Bu işlemi aşağıdaki matris için NumPy'da yapalım:

```
import numpy as np

def standard_scale(dataset):
    for col in range(dataset.shape[1]):
       冷data = dataset[:, col]
        dataset[:, col] = (冷data - np.mean(冷data)) / np.std(冷data)
```

Şimdi aşağıdaki yazdığımız fonksiyonu test edelim. Aşağıdaki gibi bir "test.csv" dosyası bulunuyor olsun:

```
1,10,13400
2,12,14200
4,4,15000
2,6,12000
4,6,11700
8,9,14200
3,1,34444
```

Test işlemini şöyle yapabiliriz:

```
dataset = np.loadtxt('test.csv', delimiter=',')
standard_scale(dataset)
print(dataset)
```

Sonuç da şöyle olacaktır:

```
[[ -1.14096529  0.90267093 -0.40588721]
 [ -0.67115606  1.47709789 -0.29838776]
 [  0.26846242 -0.82060994 -0.19088831]
 [ -0.67115606 -0.24618298 -0.59401125]
 [  0.26846242 -0.24618298 -0.63432354]
 [  2.14769938  0.61545745 -0.29838776]
 [ -0.20134682 -1.68225038  2.42188583]]
```

Bu işlem aslında daha pratik bir biçimde sklearn.preprocessing modülündeki StandardScaler sınıfıyla yapılabilmektedir. Bu sınıf türünden bir nesne yaratıp fit_transform işlemi ile dönüştürmeyi yapabiliriz.

```
from sklearn.preprocessing import StandardScaler

ss = StandardScaler()
scaled_dataset = ss.fit_transform(dataset)
print(scaled_dataset)
```

Bu işlemden de aynı çıktı elde edilmiştir:

```
[[ -1.14096529  0.90267093 -0.40588721]
 [ -0.67115606  1.47709789 -0.29838776]
 [  0.26846242 -0.82060994 -0.19088831]
 [ -0.67115606 -0.24618298 -0.59401125]
 [  0.26846242 -0.24618298 -0.63432354]
 [  2.14769938  0.61545745 -0.29838776]
 [ -0.20134682 -1.68225038  2.42188583]]
```

Aslında bu işlemleri tek adımda fit_transform ile yapmak yerine önce fit sonra transform biçiminde iki adımda da yapabiliirdik. Örneğin:

```
import numpy as np
from sklearn.preprocessing import StandardScaler

ss = StandardScaler()
ss.fit(dataset)
scaled_dataset = ss.transform(dataset)
print(scaled_dataset)
```

Burada fit metodu önce veri tablosundaki sütunların ortalamalarını ve standart sapmalarını heaplayarak sınıfın mean_ ve scale_ isimli örnek özniteliklerinde saklamakta transform metodu da bu değerlerden hareketle standart ölçeklendirmeyi yapmaktadır.

Standart ölçeklendirme sütunların normal dağılıma uyduğu durumlarda uygulanması tavsiye edilen bir tekniktir. Sütunların bu biçimde standart hale getirilmesi sonucunda değerlerin belli bir aralıktaki ölçeklendirilmemiğine ancak büyük ölçüde 0 değerinin etrafında kümelendirildiğine dikkat ediniz.

Ölçeklendirme yaparken dikkat edilmesi gereken önemli bir nokta aynı ölçeklendirmenin test veri kümesi için de yapılması gerekliliğidir. Ancak test veri kümesinin ölçeklendirilmesi kendi arasında değil eğitim veri kümesindeki değerlerden hareketle yapılmalıdır. Bu nedenle uygulamada fit ile transform işlemini ayırmak, fit işlemini eğitim veri kümesi için bir kez yapıp transform işlemini hem eğitim veri kümesi için hem de test veri kümesi için yapmak daha uygun bir yöntemdir. Şimdi standart ölçeklendirmeyi bu biçimde "diabetes.csv" dosyası üzerinde yapalım:

```
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler

dataset = np.loadtxt('diabetes.csv', skiprows=1, delimiter=',')
dataset_x = dataset[:, :-1]
dataset_y = dataset[:, -1]
training_dataset_x, test_dataset_x, training_dataset_y, test_dataset_y =
train_test_split(dataset_x, dataset_y, test_size=0.2)

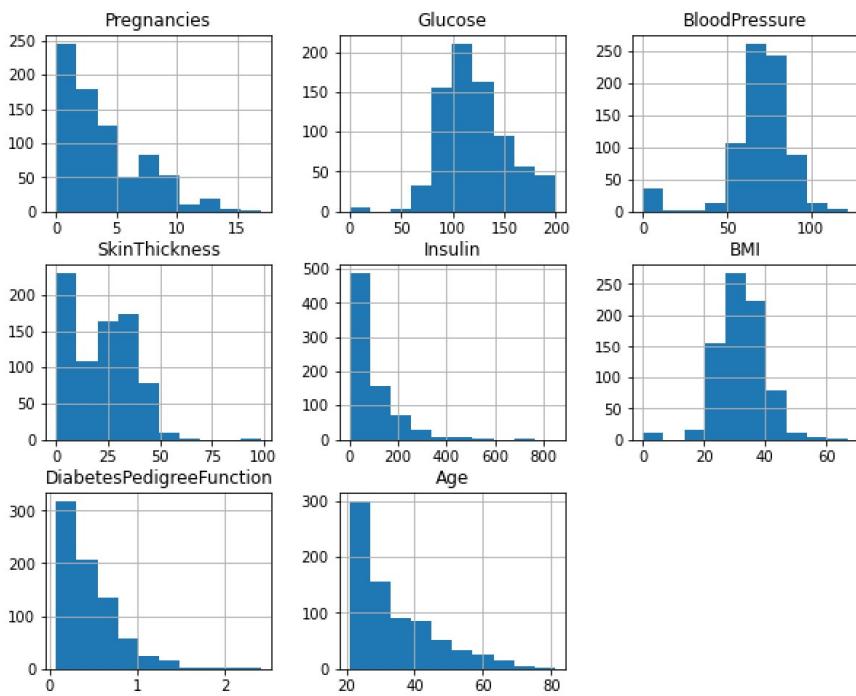
ss = StandardScaler()
ss.fit(training_dataset_x)
training_dataset_x = ss.transform(training_dataset_x)
test_dataset_x = ss.transform(test_dataset_x)
```

Biz burada yalnızca test amaçlı olarak "diabetes.csv" üzerinde standart ölçeklendirme yaptık. Yukarıda da belirttiğimiz gibi standart ölçeklendirme sütun verilerinin normal dağıldığı durumlarda tercih edilmesi gereken bir tekniktir. Dolayısıyla "diabetes.csv" sütunlarının normal dağıldığını bilmedikten sonra bu tekniği kullanmamamız gereklidir. Peki acaba bu sütunlardaki verile gerçekten normal dağılıyor mu, histogram çizerek bakalım. Bu histogramları DataFrame sınıfının hist metodunu kullanarak çok daha kolay çizebiliriz:

```
import pandas as pd

df = pd.read_csv('diabetes.csv')
df.iloc[:, :-1].hist(figsize=(10, 8))
```

Elde edilen histogramlar şöyledir:



Burada sütunların bazlarının normal dağılıma benzедiğini ancak bazlarının ise benzemediğini görüyorsunuz. Normal dağılmayan sütunların bulunduğu veri tablolarında standart ölçeklendirme yapmak uygun değildir. Ölçeklendirmede diğer önemli bir nokta da eğer veriler ölçeklendirme ile oluşturulmuşsa predict işlemi yapılırken predict metoduna geçirilecek değerlerin de aynı ortalama ve standart sapma değerleriyle ölçeklendirmeye sokulması gerektidir. Örneğin:

```
predict_result = model.predict(ss.transform(predict_data))
```

Burada ss daha önce eğitim verileriyle fit ya da fit_transform yapılmış StandardScaler nesnesini belirtmektedir.

Min-Max Ölçeklendirmesi: Bu ölçeklendirmede sütunun en küçük ve en büyük elemanları bulunur. Bu elemanlara göre ölçeklendirme yapılır:

$$\text{Yeni } x = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

Buradan elde edilen değerler her zaman $[0, 1]$ arasında olacaktır. Min-Max ölçeklemesini yapan fonksiyonu şöyle yazabiliriz:

```
import numpy as np

def minmax_scale(dataset):
    maxcol = np.max(dataset, axis=0)
    mincol = np.min(dataset, axis=0)
    diff = maxcol - mincol
    for col in range(dataset.shape[1]):
        dataset[:, col] = (dataset[:, col] - mincol[col]) / diff[col]

dataset = np.loadtxt('test.csv', delimiter=',')
minmax_scale(dataset)
print(dataset)
```

Kodun çalıştırılması sonucunda şöyle bir çıktı elde edilmiştir:

```
[[0.          0.81818182 0.07474499]
 [0.14285714 1.          0.1099191 ]
 [0.42857143 0.27272727 0.14509321]
 [0.14285714 0.45454545 0.01319029]
 [0.42857143 0.45454545 0.          ]
 [1.          0.72727273 0.1099191 ]
 [0.28571429 0.          1.          ]]
```

sklearn.preprocessing modülündeki MinMaxScaler sınıfı bu işlemi otomatik olarak yapmaktadır. Sınıfın kullanımı tamamen StandardScaler sınıfında olduğu gibidir. Önce MinMaxScaler sınıfı türünden bir nesne yaratılır. Ondan sonra sınıfın fit ve transform metotları çağrılır. Yine istenirse bu iki işlem fit_transform metodu ile tek hamlede de yapılabilmektedir. Örneğin:

```
import numpy as np

from tensorflow.keras import Sequential
from tensorflow.keras.layers import Dense
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import MinMaxScaler

dataset = np.loadtxt('diabetes.csv', skiprows=1, delimiter=',')
dataset_x = dataset[:, :-1]
dataset_y = dataset[:, -1]
training_dataset_x, test_dataset_x, training_dataset_y, test_dataset_y =
train_test_split(dataset_x, dataset_y,
test_size=0.20)

mms = MinMaxScaler()
mms.fit(training_dataset_x)
training_dataset_x = mms.transform(training_dataset_x)
test_dataset_x = mms.transform(test_dataset_x)

model = Sequential()
model.add(Dense(100, input_dim=8, activation='relu', name='Hidden-1'))
model.add(Dense(100, activation='relu', name='Hidden-2'))
model.add(Dense(1, activation='sigmoid', name='Output'))

model.compile(optimizer='adam', loss='binary_crossentropy', metrics=['binary_accuracy'])

hist = model.fit(training_dataset_x, training_dataset_y, batch_size=32, epochs=100,
validation_split=0.2)

import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Loss - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.plot(range(1, len(hist.history['loss']) + 1), hist.history['loss'])
plt.plot(range(1, len(hist.history['val_loss']) + 1), hist.history['val_loss'])
plt.legend(['Loss', 'Validation Loss'])
plt.show()

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Binary Accuracy - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Binary Accuracy')
plt.plot(range(1, len(hist.history['binary_accuracy']) + 1), hist.history['binary_accuracy'])
plt.plot(range(1, len(hist.history['val_binary_accuracy']) + 1),
```

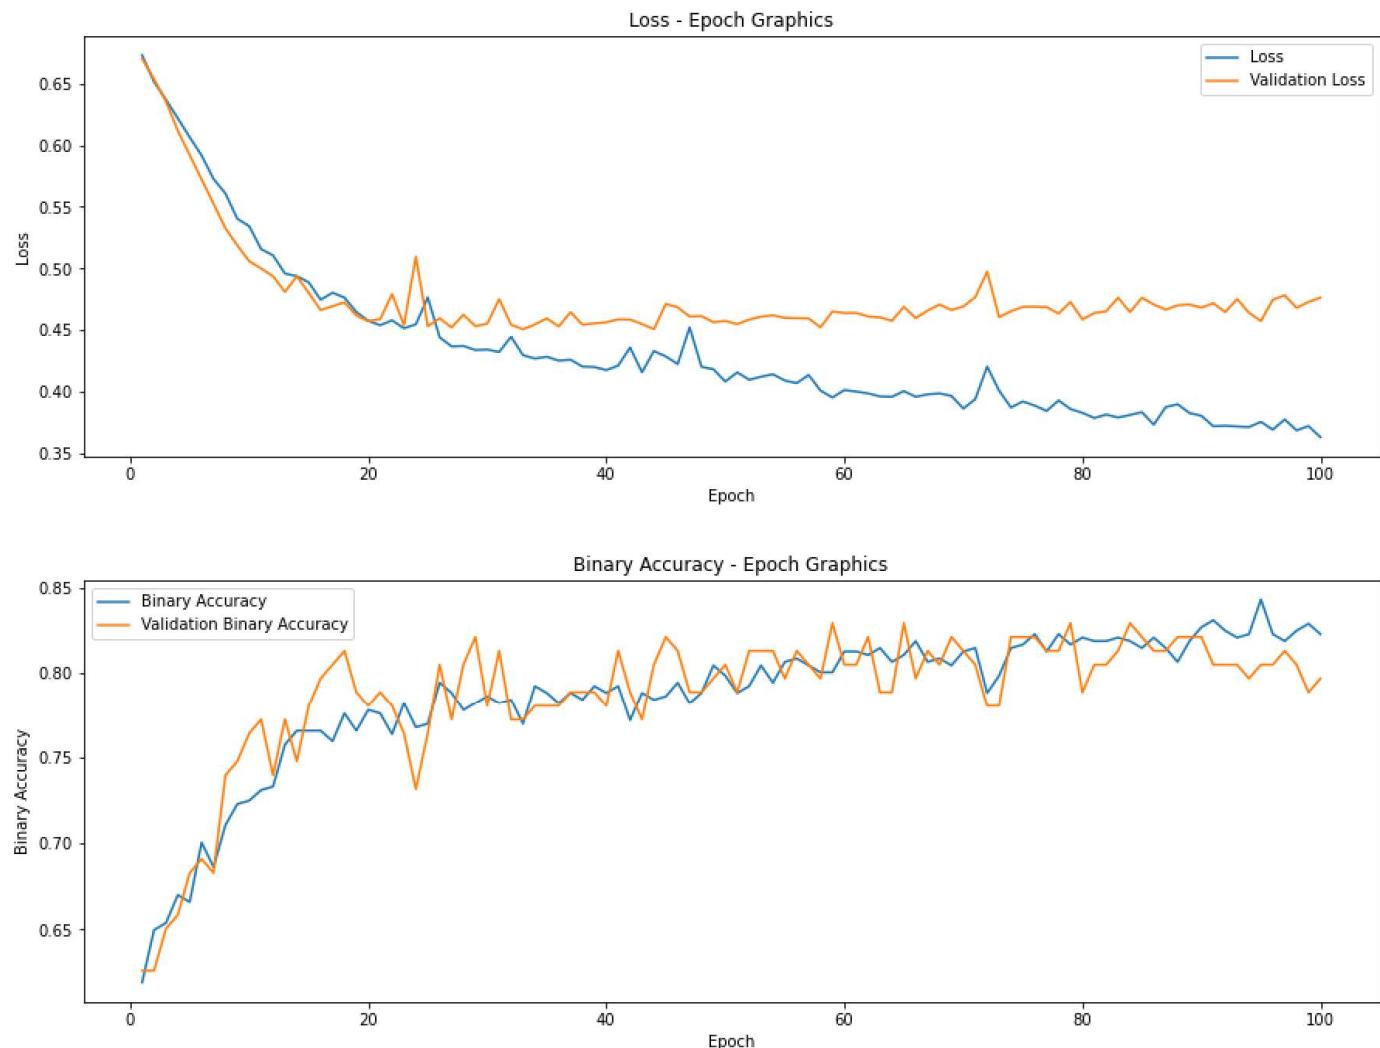
```

hist.history['val_binary_accuracy'])
plt.legend(['Binary Accuracy', 'Validation Binary Accuracy'])
plt.show()

eval_result = model.evaluate(test_dataset_x, test_dataset_y)
for i in range(len(eval_result)):
    print(f'{model.metrics_names[i]}: {eval_result[i]}')

```

Elde edilen çıktılar şöyledir:



```

loss: 0.4925406277179718
binary_accuracy: 0.7922077775001526

```

Buradan elde ettiğimiz değerleri Min-Max ölçeklemesi yapılmadan elde edilen değerlerle kıyaslayalım. Ölçekleme yapmadan elde ettiğimiz değerler şöyledi:

```

loss: 0.5974747538566589
binary_accuracy: 0.6623376607894897]

```

Gördüğünüz gibi Min-Max ölçeklemesi modeli %13 civarında iyileştirmiştir.

Mutlak Max Ölçeklendirmesi (Absolute Max Scaling): Bu ölçeklendirmede sütundaki değerler sütunun en büyük değerinin mutlak değerine bölünerek dönüştürülmektedir:

$$\text{Yeni } x = \frac{x}{|\max(x)|}$$

Bu işlem sonucunda değerlerin [min, 1] aralığında ölçeklendirildiğine dikkat ediniz. Eğer tüm değerler pozitif ise bu ölçeklendirme Min-Max Ölçeklendirmesine benzemektedir. Mutlak Max Ölçeklendirmesi `sklearn.preprocessing.MaxAbsScaler` sınıfıyla temsil edilmiştir. Sınıfın kullanılması benzer birimdir. Örneğin en son örnekte kullandığımız "test.csv" dosyasındaki sütunları mutlak max Ölçeklendirmesiyle ölçeklendirelim:

```
import numpy as np
from sklearn.preprocessing import MaxAbsScaler

dataset = np.loadtxt('test.csv', delimiter=',')
mas = MaxAbsScaler()
scaled_dataset = mas.fit_transform(dataset)
print(dataset)
print()
print(scaled_dataset)
```

Kodun çıktısı şöyle olacaktır:

```
[[1.0000e+00 1.0000e+01 1.3400e+04]
[2.0000e+00 1.2000e+01 1.4200e+04]
[4.0000e+00 4.0000e+00 1.5000e+04]
[2.0000e+00 6.0000e+00 1.2000e+04]
[4.0000e+00 6.0000e+00 1.1700e+04]
[8.0000e+00 9.0000e+00 1.4200e+04]
[3.0000e+00 1.0000e+00 3.4444e+04]]

[[0.125      0.83333333 0.38903728]
[0.25       1.          0.41226338]
[0.5        0.33333333 0.43548949]
[0.25       0.5         0.34839159]
[0.5        0.5         0.3396818 ]
[1.          0.75        0.41226338]
[0.375      0.08333333 1.          ]]
```

Yukarıda da belirttiğimiz gibi eğer sütun verileri normal dağılırsa standart Ölçeklendirme daha uygun olmaktadır. Böyle bir normalilik söz konusu değilse ve sütundaki verilerin en büyük değeri önceden biliniyorsa Min-Max Ölçeklendirmesini kullanmak uygun olur. Biz de kursumuzda hep bu iki Ölçeklendirmeyi kullanacağız.

Yapay Sinir Ağlarının Eğitilmesinde "Overfitting" ve "Underfitting" Olgusu

Yapay sinir ağlarının eğitilmesinde çok karşılaşılan iki terim "overfitting" ve "underfitting" terimleridir. "Overfitting" kabaca modelin "eğitim veri kümesinde iyi performans gösterdiği halde sınıma ve test veri kümelerinde düşük bir performans göstermesi" anlamına gelmektedir. Yani eğitim sırasında model bir şeyi öğrenmiş olabilir ancak öğrendiği şey bizim arzu ettiğimiz şey olmayı bilmez. (Örneğin derste çözülen soruların aynısını çözebilir ama derste çözülmeyen sorularda aynı başarıyı gösteremeyen bir öğrenci düşünün. Bu öğrenciye derste çözülen sorular sorulursa o çok başarılı olacaktır. Ancak aynı konuya ilgili derste çözülmeyen sorular sorulduğunda başarısı düşecektir. Bu durumda öğrencinin konuyu iyi bir biçimde öğrendiğini söyleyebilir miyiz?) Overfitting olusunu sinyal-gürültü (singal-noise) teorisiyle de açıklayabiliriz. Eğitim verilerimizde öğrenilmesi gereken kalıplar "sinyallerdir" ancak bu sinyallerin arasında "gürültüler" de vardır. Eğer modelimiz sinyalleri değil de gürültülerini öğrenme eğilimindeyse overfitting oluşmaktadır.

Pekiyi overfitting oluşturan kaynaklar nelerdir? İşte overfitting çeşitli nedenlerden dolayı oluşabilmektedir. Bazı overfitting durumları modelin doğru bir biçimde oluşturulamamasından kaynaklanırken bazı overfitting durumları ise eğitim verilerinin uygun biçimde oluşturulamamasından kaynaklanmaktadır.

Örneğin modelin çok fazla parametreye sahip olması overfitting sorununa yol açabilmektedir. Bu durumda model parametrelerinin (yani 'w' değerlerinin) toplam sayısının çeşitli tekniklerle düşürülmesi gerekebilir. Modelin eğitilmesi sırasında fazla epoch uygulamak diğer önemli overfitting nedenlerindendir. Eğer overfitting epoch temelli

olarak ortaya çıkıysa veri bilimcisinin eğitimi uygun bir epoch'ta kesmesi gerekir. Keras kütüphanesi belli koşullarda eğitimin sonlandırılmasına (early stopping) izin vermektedir.

Eğitim veri kümesinin uygun seçilmiş olmaması da overfitting sorununa yol açabilmektedir. Eğitim veri kümesi yanlış (bias) bir biçimde seçilmiş olabilir. Bu durumda eğitim sırasında ağ öğrenmesi gerekenleri değil başka şeyleri öğreniyor olabilir. Yanlılık dışında eğitim veri kümesinin değişkenliğinin (variance) düşük olması da bir "overfitting" kaynağını oluşturabilmektedir. Çünkü düşük değişkenlik (low variance) ana kütlenin iyi bir biçimde temsil edilememesi anlamına gelmektedir.

Pekiyi "overfit" durumunu nasıl anlarız? İşte eğitim sırasında eğitim verilerinin verdiği metrik değerler iyileşirken bu iyileşme sınama verilerinde gözükmüyorsa yani eğitim verilerinin kendisinden elde edilen başarı sınama sırasında ortaya çıkmıyorsa bu durumda bir "overfitting" şüphesi akla gelmelidir. Bu nedenle eğitim sırasında eğitim kümesinden elde edilen metrik değerlerle sınama kümesinden elde edilen metrik değerlerin belli bir uyumda olup olmadığından bir biçimde kontrol edilmesi gerekmektedir. Bu kontrolün gözle yapılması kolaydır. Biz Keras'ta eğitim sırasında fit metodunun verdiği history nesnesinden hareketle eğitim verileri ve sınama verileri için elde edilen metrik değerlerin grafiğini birlikte çizebiliriz. Grafikteki ayışmayı bu yolla görebiliriz.

Overfitting olsusunun tersine "underfitting" denilmektedir. Underfitting olsusu da yine modelin yanlış oluşturulmasından ve eğitim veri kümesindeki sorunlardan kaynaklanıyor olabilir. Örneğin özelliklerin (yani tablo sütunlarının) yanlış ve eksik seçilmesi, modeldeki nöronların sayısının azlığı, yanlış optimizasyon algoritmalarının ve loss fonksiyonlarının kullanılması modelin yanlış oluşturulduğuna ilişkin akla gelen en önemli unsurlardır. Öte yandan nasıl düşük varyans overfitting durumuna yol açıysa yüksek varyans da underfitting durumuna yol açabilmektedir. Eğitim veri kümesindeki yüksek varyanstan dolayı metrik değerler bir türlü iyileşemeyebilir. Eğitim veri kümesinin azlığı, eğitim verilerinin yüksek bir entropide olması da önemli underfitting kaynaklarındanandır. Underfitting olsusunu yine sinyal-gürültü teorisiyle açıklayabiliriz. Eğer gürültü sinyalden çok daha fazla ise bu durumda sinyal bir türlü elde edilemeyecektir.

Regresyon Kavramı ve Regresyon Modellerinin Sınıflandırılması

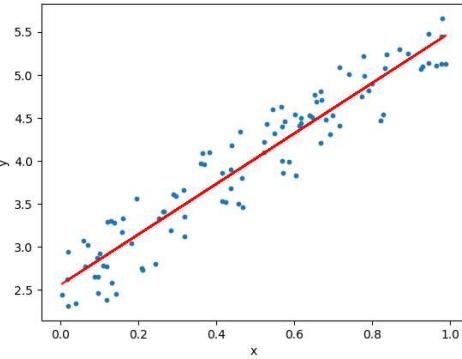
Girdi ile çıktı arasında ilişki kurma sürecine istatistikte "regresyon" denilmektedir. Girdiyle çıktı arasındaki ilişki bir fonksiyonla ifade edilebildiğine göre regresyon sürecini de biz aslında girdi ile çıktı arasındaki ilişkiyi belirten uygun bir fonksiyonun bulunması süreci olarak ele alabiliriz. Matematiksel biçimde açıklarsak regresyon aslında $y = f(x)$ biçiminde bir f fonksiyonun bulunması sürecidir. (Burada x ve y birer vektör olarak düşünülmelidir. Yani x bir tane değil x_0, x_1, \dots, x_n biçiminde n tane olabileceği gibi y de bir tane değil y_0, y_1, \dots, y_m biçiminde m tane olabilir.)

Pekiyi girdi ile çıktı arasında ilişki kurmanın amacı ne olabilir? Şüphesiz en önemli amaç kestirimde bulunmaktır. Örneğin elimizde birtakım geçmiş veriler vardır. Biz de gelecekteki durumun ne olabileceğiyle ilgili karar vermek isteyebiliriz. Bu durumda gelecekteki verileri regresyon sonucunda bulduğumuz f fonksiyonuna girdi yaparak sonucu elde ederiz. Biz kursumuzda girdiler yoluyla çıktıların tahmin edilmesine yönelik problemlere "regresyon problemleri" diyeceğiz.

Regresyon problemlerinin çözümü için değişik yöntemler kullanılmaktadır. İstatistiksel regresyon analizi makine öğrenmesinin popüler hale gelmesinden çok önceleri uygulanan ve oldukça bilinen bir teknikler topluluğudur. Ancak makine öğrenmesinde istatistiksel regresyon analizinin dışında kullanılan başka özel teknikler de bulunmaktadır. Örneğin yapay sinir ağları da aslında bir regresyon sürecidir ve regresyon problemlerinde kestirim amacıyla kullanılmaktadır.

Regresyon modelleri ve problemleri istatistikte çeşitli biçimlerde sınıflandırılabilmektedir. Maalesef herkesin hemfikir olduğu bir sınıflandırma biçimi yoktur. Biz burada regresyon modellerini tipik olarak bazı alt başlıklarla sınıflandıracağız. Regresyon sonucunda elde edilecek fonksiyonun genel yapısına göre regresyon modelleri tipik olarak aşağıdaki gibi sınıflandırılmaktadır:

- Doğrusal Regresyon (Linear Regression): Girdi çıktı arasındaki ilişkinin doğrusal olduğu kabulüyle yapılan regresyon sürecine denilmektedir. Yani doğrusal regresyonla girdi ile çıktı arasında doğrusal bir fonksiyon bulunmaya çalışılır. Örneğin:



Burada düzlemede çeşitli noktaları ortalayan bir doğru elde edilmiştir. Bu doğru aslında noktaların doğruya uzaklıklarının en küçük olduğu doğrudur ve istatistikte bu doğrunun elde edilmesi yöntemine "en küçük kareler" yöntemi denilmektedir. İstatistiksel doğrusal regresyon kursumuzda ileride ele alınmaktadır.

Doğrusal regresyonda girdi (yani bağımsız değişken) bir tane ve çıktı da (bağımlı değişken) bir tane ise buna "basit doğrusal regresyon" denilmektedir. Tabii gerçek yaşama ilişkin problemlerde genellikle girdi bir tane olmaz. Örneğin bizim kullandığımız veri tablolarındaki özellikler (sütunlar) girdileri oluştururlar. Böylece regresyon modelinde çok sayıda girdi söz konusu olur. İşte eğer doğrusal regresyonda girdiler (yani bağımsız değişkenler) birden fazla ise buna "çoklu doğrusal regresyon (multiple linear regression)" denilmektedir. Doğrusallığın değişken sayısı ile ilgili olmadığına değişkenlerin dereceleri ile ilgili olduğuna dikkat ediniz. Örneğin n tane değişken içeren doğrusal bir fonksiyonun genel biçimini söylemek:

$$f(x) = a_1x_1 + a_2x_2 + a_3x_3 + \dots + a_nx_n + b$$

Biz bu doğrusal fonksiyonu vektörel biçimde şöyle de ifade edebiliriz:

$$f(X) = AX$$

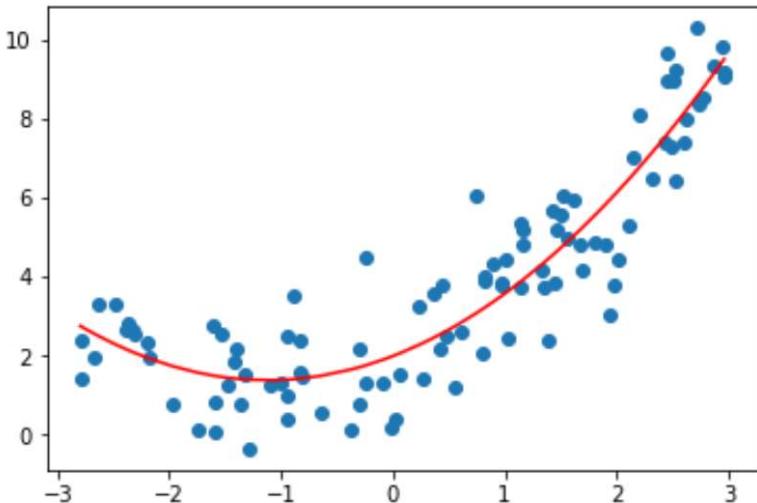
Burada A bir satır vektörünü X ise bir sütun vektörünü belirtmektedir. Aslında AX işleminin bir "dot product" oluşturduğuna dikkat ediniz.

İki boyutlu düzlemede tek değişkenli doğrulara biz çok aşınıyoruz. Burada eksenlerden biri bağımsız değişkeni diğer ise bağımlı değişkeni belirtir. Eğer bağımsız değişken iki tane ise doğru denklemi de bir doğru değil bir düzlem belirtir hale gelir. Düzlem de üç boyutlu uzayda bir doğru gibi düşünülmeliidir. O halde n boyutlu uzayın $n - 1$ değişkenle ifade edilebilen bir düzlemi vardır. Burada anlatmak istediğimiz şey doğrusallığın genel prensiplerinin değişmediğidir. İki boyutlu uzaydaki tek değişkenli doğrusallıkla n boyutlu uzaydaki $n - 1$ boyutlu doğrusallık aynı prensiplere sahiptir.

- **Polinomsal Regresyon (Polynomial Regression):** Verilerin grafiğini çizdiğimizde ilişkinin doğrusal olup olmadığı hemen gözle görülebilmektedir. Bağımsız değişkenlerin herhangi birinin üssü 1'den büyükse bu tür regresyon modellerine polinomsal regresyon modelleri denilmektedir. Başka bir deyişle polinomsal regresyon aşağıdaki gibi bir polinomsal fonksiyonun bulunması sürecidir:

$$f(x) = a_0x^0 + a_1x^1 + a_2x^2 + a_nx^n$$

Polinomsal regresyona aşağıdaki gibi bir örnek verebiliriz:



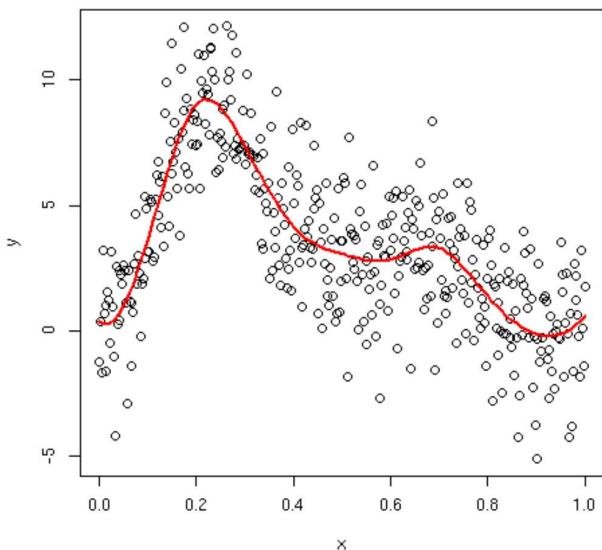
Alıntı Notu: GörSEL <https://developpaper.com/polynomial-regression-and-model-generalization-in-machine-learning/> adresinden alınmıştır.

Burada söz konusu noktalardan bir doğru değil bir polinom geçirilmiştir. Aslında polinomsal regresyon eğer katsayılarla değişkenler yer değiştirirse doğrusal regresyona benzemektedir:

$$f(x) = x^0 a_0 + x^1 a_1 + x^2 a_2 + x^n a_n$$

Polinomsal regresyon kursumuzun ilerleyen bölümlerinde ayrı bir başlık halinde ele alınacaktır.

- **Doğrusal Olmayan Regresyon (Nonlinear Regression):** Her ne kadar polinomlar doğrusal fonksiyonlar değilse de katsayılarla değişkenler yer değiştirdiğinde doğrusal gibi ele alınabilemektedir. İstatistikte doğrusal olmayan regresyon denildiğinde katsayılarla değişkenler değiştirildiğinde yine doğrusal olmayan fonksiyonların elde edildiği regresyonlar anlaşılmaktadır. Bu tür fonksiyonalar genel olarak üstel ifadeler, logaritmik ifadeler, pay ve paydasında bağımsız değişkenlerin bulunduğu oransal ifadeler içermektedir.



Alıntı Notu: GörSEL <https://stackoverflow.com/questions/15837763/b-spline-confusion> adresinden alınmıştır.

Aslında doğrusal olmayan regresyonları da elde edilmek istenen fonksiyonlara göre logaritmik regresyon, üstel regresyon gibi alt sınıflara ayırmak mümkündür.

Lojistik Regresyon (Logistic/Logit Regression): Bağımlı değişkenin sürekli bir değer almadığı, kategorik değer aldığı durumlarda uygulanan regresyonlara lojistik regresyon ya da logit regresyonu denilmektedir. Lojistik regresyon terimi tipik olarak çıktıının 0 ya da 1 gibi ikili değerlere sahip olduğu durumlar için kullanılmaktadır. (Örneğin çıktı "evli mi bekar mı", "hasta mı sağlıklı mı", "film iyi mi kötü mü" gibi iki seçenekten biri olabilmektedir.) Ancak zamanla bu

terim genişletilmiştir. Çıktının ikiden fazla kategoriye ayrıldığı durumlar için de "çok sınıflı lojistik regresyon (multinomial logistic regression)" terimi kullanılmaktadır. Ayrıca "sıralı lojistik regresyon (ordinal logistic regression)" denilen bir lojistik regresyon modelinde girdi ve çıktılar kategorik değil sıralı ölçeklere ilişkin olabilmektedir.

Regresyonlar bağımlı ve bağımsız değişken sayılarına göre de sınıflandırılmaktadır:

- **Basit Regresyon (Simple Regression):** Bağımsız değişken sayısı bir tane ise buyle regresyonlara basit regresyonlar denilmektedir.

- **Çoklu Regresyon (multiple regression):** Bağımsız değişken sayısının (yani girdilerin) birden fazla olduğu fakat bağımlı değişken sayısının (yani çıktıının) bir tane olduğu regresyon modelleri için kullanılan bir terimdir. Örneğin bir otomobilin 8 özelliğinden onun yakıt harcamasının tahmin edilmek istediği regresyon modeli çoklu regresyon modelidir. Ya da örneğin "diabeteses.csv"örneğinde olduğu gibi kişinin 8 biyomedikal bilgisinden hareketle kişinin şeker hastası olup olmadığına tahmin edilmesi için oluşturulan model de çoklu lojistik regresyon modelidir.

- **Çok Değişkenli Regresyon (Multivariate Regression):** Eğer regresyon modelinde bağımlı değişkenin sayısı birden fazlaysa (yani çıktıı birden fazlaysa) buna da "çok değişkenli (multivariate)" regresyon denilmektedir. Örneğin öğrencinin bazı girdi bilgileri olsun (bağımsız değişkenler) biz de onun sınavda alacağı notu ve ortalama kaç saat uyuduğunu tahmin etmek isteyelim. Burada tahmin etmek istediğimiz şey birden fazladır. Şüphesiz çok değişkenli regresyonlarda çıktıılar birbirlerinden bağımsız ve teker teker olarak da ele alınabilirler. O zaman iki farklı çoklu regresyondan söz ederdim. Fakat çok değişkenli regresyonlarda aynı anda birden fazla çıktıının değişiminin belirlenmesi hedeflenmektedir. Yani örneğin 15 tane biyomedikal tetkike bakarak biz bir kişinin "diabetli olup olmadığını", "kalp hastası olup olmadığını", "hipertansiyonunun olup olmadığını" ayrı ayrı çoklu lojistik regresyonla anlamaya çalışabilirim. Ancak bu üç hastalık birbirlerini de etkiliyor olabilir. O halde bu üç hastalığın birlikte değerlendirilmesi gereklidir. İşte bu durum çok değişkenli lojistik regresyon olarak modellenebilir.

Yapay Sinir Ağları ve Derin Ağlarla Regresyon Modelleri ile İstatistiksel Regresyon Modellerinin Karşılaştırılması

Yukarıda da belirttiğimiz gibi aslında regresyon modellerini çözmek için değişik teknikler kullanılabilmektedir. Kursumuzun ilerleyen zamanlarında regresyon problemlerinin başka tekniklerle çözümü üzerinde de durulacaktır. Pekiyi yapay sinir ağları ve derin ağlar klasik istatistiksel regresyon analizine göre hangi durumlarda avantaj sağlamaaktadır? Bu durumları söyle ifade edebiliriz:

- Bağımsız değişken sayısının (girdi sayılarının) fazla olduğu durumlarda (örneğin 25'ten fazla olduğu durumlarda)
- Bağımsız değişkenler arasında korelasyonların olduğu durumlarda
- Bağımsız değişkenler arasında karmaşık ilişkilerin olduğu durumlarda
- Bağımsız değişkenlerle bağımlı değişkenler arasında doğrusal olmayan ilişkilerin bulunduğu durumlarda
- Bağımsız değişkenlerin bazlarının kategorik, bazlarının sürekli olduğu durumlarda
- Bağımlı değişken sayısının fazla olduğu ve onların arasında da ilişkilerin bulunduğu

Bu tür durumlarda istatistiksel regresyon analizleri genellikle sinir ağ modellerine göre hem daha düşük performans göstermekte hem daha fazla bilgisayar zamanı almaktır.

Tabii aslında klasik istatistiksel regresyon analizi modellerinin yapay sinir ağları ve derin ağlardan daha yüksek performans göstermesi de söz konusu olabilmektedir. Özellikle girdi ile çıktı arasındaki ilişkilerin çok belirgin olduğu durumlarda istatistiksel regresyon analizi tercih edilebilmektedir. Yine benzer biçimde elde çok veri olduğu durumda yapay sinir ağlarının eğitilmesi bir sorun oluşturabilmektedir. Bu durumlarda istatistiksel regresyonlar yapay sinir ağlarına tercih edilebilmektedir.

Yapay Sinir Ağları ile Oluşturulan Regresyon Modellerinde Önemli Parametrelerin Belirlenmesi

Yapay sinir ağlarında ve derin ağlarda regresyon modeli oluşturulurken genellikle bazı sezgisel yöntemler izlenmektedir. Tabii daha önceden de bahsedildiği gibi aslında veri biliminde genel yaklaşım her zaman o andaki modele ve amaca özgü olarak değişimektedir. Ancak yine de çeşitli problem grupları için kaba bazı model belirlemeler söz konusu olabilmektedir. Bunları birkaç maddede ele almak istiyoruz:

- Regresyon modelinde genellikle saklı katmanlar için "relu", çıktı katmanı için regresyon modeli eğer ikili lojistik ise "sigmoid", çok sınıflı lojistik ise softmax, lojistik değilse "linear" aktivasyon fonksiyonları tercih edilmektedir. (Linear aktivasyon fonksiyonu girdinin hiçbir işleme sokulmadan çıktı olarak verildiği fonksiyondur. Dense katmanındaki default aktivasyonunun "linear" olduğunu anımsayınız.)
- Modeldeki optimizer algoritması için genellikle "rmsprop", "adam" ve "sgd (stochastic_gradient_descent)" seçilmektedir.
- Modelin loss fonksiyonu için genellikle ikili lojistik regresyon modelleri için "binary_crossentropy", çok sınıflı regresyon modelleri için "categorical_crossentropy" ve lojistik olmayan regresyon modelleri için de "mse (mean_squared_error)" tercih edilmektedir.
- Validation işlemi için kullanılacak metrikler de genellikle jöistik ikili regresyon modelleri için "binary_accuracy", çok sınıflı lojistik regresyon modelleri için "categorical_accuracy", lojistik olmayan regresyon modelleri için ise "mae (mean_absolute_error)" seçilmektedir.

Regresyon modelleri için özel durumlar haricinde mimari konusunda da genellikle şunlar uygulanmaktadır:

- Model katmanları Dense (yani tüm nöron çıktılarının diğerlerine bağlılığı) biçimde oluşturulur. Ancak özel durumlarda ileride de göreceğiniz gibi başka mimariler de kullanılabilir.
- Katmandaki nöron sayıları 100-200 gibi orta değerde tutulmaktadır.
- Önce tek saklı katman denenir, eğer performans düşük kalırsa katman sayısı ikiye, üçe, dörde ve duruma göre daha yüksek derecelere çıkartılır.
- Fazla miktarda katmanla hala iyileşme sağlanamıyorsa katmanlardaki nöron sayıları artırılır.
- Hala yeterli bir performans elde edilmiyorsa bu durumda mimarı, seçilen özelliklerden (sütunlardan) ya da eğitim için kullanılan verilerden şüphe edilmelidir.

Yapay Sinir Ağlarıyla Lojistik Olmayan Regresyon Örneği: Otomobillerin Mil Başına Yaktıkları Yakıtı Tahmin Etme

Şimdi lojistik olmayan regresyon problemlerinde çok kullanılan klasikleşmiş bir örnek üzerinde duracağız. Örnek verileri 70'li yılların sonlarına doğru toplanmıştır. Dolayısıyla değerler o yıllara özgüdür. Şimdi aşama aşama örneği gerçekleştirmeye çalışalım.

1) Önce modelimizde kullanacağımız veri kümesini aşağıdaki bağlantıdan indirebilirsiniz:

<https://archive.ics.uci.edu/ml/datasets/auto+mpg>

Bu bağlantıdan "auto-mpg.data" ve "auto-mpg.names" isimli dosyalar indirilebilir. Gerçek veri dosyası "auto-mpg.data" dosyasıdır. "auto-mpg.names" dosyasına açıklama bilgileri vardır. Veri kümesinde toplam 8 sütun vardır. Bu 8 sütun sırasıyla şunlardır oluşturmaktadır:

Aracın Mil başına yaktığı yakıtın galon miktarı (1 galon 3.78 litredir)
 Aracın Silindir Sayısı
 Aracın Motor Hacmi
 Aracın Beygir Gücü
 Aracın Ağırlığı
 Aracın 100 km/h ya çıkışma süresi (ivmelenmesi)
 Aracın Orijini (Kategorik 1: USA, 2: Europe, 3: Japan)
 Aracın Markası

Sütunlar dosyada birbirlerinden SPACE karakterleriyle ayrılmıştır. Ancak Markadan önce bir tane TAB karakteri bulunmaktadır. Verilerin örnek görünümü şöyledir:

1	18.0	8	307.0	130.0	3504.	12.0	70	1	"chevrolet chevelle malibu"
2	15.0	8	350.0	165.0	3693.	11.5	70	1	"buick skylark 320"
3	18.0	8	318.0	150.0	3436.	11.0	70	1	"plymouth satellite"
4	16.0	8	304.0	150.0	3433.	12.0	70	1	"amc rebel sst"
5	17.0	8	302.0	140.0	3449.	10.5	70	1	"ford torino"
6	15.0	8	429.0	198.0	4341.	10.0	70	1	"ford galaxie 500"
7	14.0	8	454.0	220.0	4354.	9.0	70	1	"chevrolet impala"
8	14.0	8	440.0	215.0	4312.	8.5	70	1	"plymouth fury iii"
9	14.0	8	455.0	225.0	4425.	10.0	70	1	"pontiac catalina"
10	15.0	8	390.0	190.0	3850.	8.5	70	1	"amc ambassador dpl"
11	15.0	8	383.0	170.0	3563.	10.0	70	1	"dodge challenger se"
12	14.0	8	340.0	160.0	3609.	8.0	70	1	"plymouth 'cuda 340"
13	15.0	8	400.0	150.0	3761.	9.5	70	1	"chevrolet monte carlo"
14	14.0	8	455.0	225.0	3086.	10.0	70	1	"buick estate wagon (sw)"
15	24.0	4	113.0	95.00	2372.	15.0	70	3	"toyota corona mark ii"
16	22.0	6	198.0	95.00	2833.	15.5	70	1	"plymouth duster"
17	18.0	6	199.0	97.00	2774.	15.5	70	1	"amc hornet"
18	21.0	6	200.0	85.00	2587.	16.0	70	1	"ford maverick"
19	27.0	4	97.00	88.00	2130.	14.5	70	3	"datsun pl510"
20	26.0	4	97.00	46.00	1835.	20.5	70	2	"volkswagen 1131 deluxe sedan"
21	25.0	4	110.0	87.00	2672.	17.5	70	2	"peugeot 504"
22	24.0	4	107.0	90.00	2430.	14.5	70	2	"audi 100 ls"
23	25.0	4	104.0	95.00	2375.	17.5	70	2	"saab 99e"
24	26.0	4	121.0	113.0	2234.	12.5	70	2	"bmw 2002"
25	21.0	6	199.0	90.00	2648.	15.0	70	1	"amc gremlin"
26	10.0	8	360.0	215.0	4615.	14.0	70	1	"ford f250"
27	10.0	8	307.0	200.0	4376.	15.0	70	1	"chevy c20"
28	11.0	8	318.0	210.0	4382.	13.5	70	1	"dodge d200"
29	9.0	8	304.0	193.0	4732.	18.5	70	1	"hi 1200d"
30	27.0	4	97.00	88.00	2130.	14.5	71	3	"datsun pl510"
31	28.0	4	140.0	90.00	2264.	15.5	71	1	"chevrolet vega 2300"
32	25.0	4	113.0	95.00	2228.	14.0	71	3	"toyota corona"
33	25.0	4	98.00	?	2046.	19.0	71	1	"ford pinto"

Son sütundaki otomobil markalarının bizim için bir önemi yoktur. Dolayısıyla son sütunu tamamen atabiliyoruz. Ayrıca dosya incelediğinde 3'üncü indeksli sütunda (bu sütun araçların beygir güçlerinden oluşmaktadır) '?' karakterlerinin olduğu görülmektedir. Bu '?' karakterleri ilgili aracın beygir gücünün bilinmediği anlamına gelir. Örneğimizde bu satırları tamamen atabiliyoruz. Şimdi dosyayı okuyup bu hazırlık işlemlerini yapalım:

```
import numpy as np

dataset = np.loadtxt('auto-mpg.data', usecols=range(8), dtype='object')
dataset = dataset[dataset[:, 3] != '?', :].astype('float32')
```

Artık elimizde '?' lerinden arındırılmış ve float32 formatına dönüştürülmüş bir ndarray nesnesi vardır. Şimdi x ve y veri kümelerini ayırtıralım. Çıktıların ilk sütunda olduğuna dikkat ediniz:

```
dataset_x = dataset[:, 1:]
dataset_y = dataset[:, 0]
```

Şimdi bizim arabanın orijinini belirten kategorik sütun için one hot encoding dönüştürmesi yapmamız gereklidir. Bu işlemi şöyle yapılabiliyoruz:

```
ohe = OneHotEncoder(sparse=False)
ohe_data = ohe.fit_transform(dataset_x[:, 6].reshape(-1, 1))
dataset_x = np.delete(dataset_x, 6, axis=1)
dataset_x = np.append(dataset_x, ohe_data, axis=1)
```

Şimdi de veri kümemizdeki sütunların mertebeleri arasında ciddi farklar olduğu için "özellik ölçeklendirmesi (feature scaling)" yapalım:

```
from sklearn.preprocessing import MinMaxScaler

mms = MinMaxScaler()
mms.fit(dataset_x)
dataset_x = mms.transform(dataset_x)
```

Şimdi veri kümemizi eğitim ve test amacıyla ikiye ayıralım:

```

from sklearn.model_selection import train_test_split

training_dataset_x, test_dataset_x, training_dataset_y, test_dataset_y =
train_test_split(dataset_x, dataset_y, test_size=0.20)

```

Artık modeli kurabiliyoruz. Modelimizde iki saklı katman olsun. Saklı katmanlar için aktivasyon fonksiyonlarını "relu" çıktı katmanı için de "linear" alabiliyoruz. Optimizer algoritması olarak aslında yukarıda belirttiğimiz "sgd", "adam" ya da "rmsprop" algoritmalarından herhangi birini seçebiliyoruz. Örneğimizde biz "rmsprop" kullanacağımız. Lojistik olmayan regresyon modellerinde loss fonksiyonunun genellikle "mse" ve metrik değerinin de "mae" olarak seçildiğini biliyoruz:

```

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense

model = Sequential()
model.add(Dense(100, input_dim=training_dataset_x.shape[1], activation='relu', name='Hidden-1'))
model.add(Dense(100, activation='relu', name='Hidden-2'))
model.add(Dense(1, activation='linear', name='Output'))

model.compile('rmsprop', loss='mse', metrics=['mae'])

```

Modelimizin özet bilgilerini de yazdırıralım:

```
model.summary()
```

Şöyledir bir çıktı elde edilmiş:

Model: "Auto-MPG"

Layer (type)	Output Shape	Param #
<hr/>		
Hidden-1 (Dense)	(None, 100)	1000
<hr/>		
Hidden-2 (Dense)	(None, 100)	10100
<hr/>		
Output (Dense)	(None, 1)	101
<hr/>		
Total params: 11,201		
Trainable params: 11,201		
Non-trainable params: 0		

Artık modelimizi eğitebiliriz:

```
hist = model.fit(training_dataset_x, training_dataset_y, batch_size=32, epochs=200)
```

Eğitimden elde ettiğimiz history bilgilerine dayanarak epoch temelinde loss değerinin ve 'mae' metrik değerinin grafiklerini çizelim:

```

import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Loss - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.plot(range(1, len(hist.history['loss']) + 1), hist.history['loss'])
plt.plot(range(1, len(hist.history['val_loss']) + 1), hist.history['val_loss'])

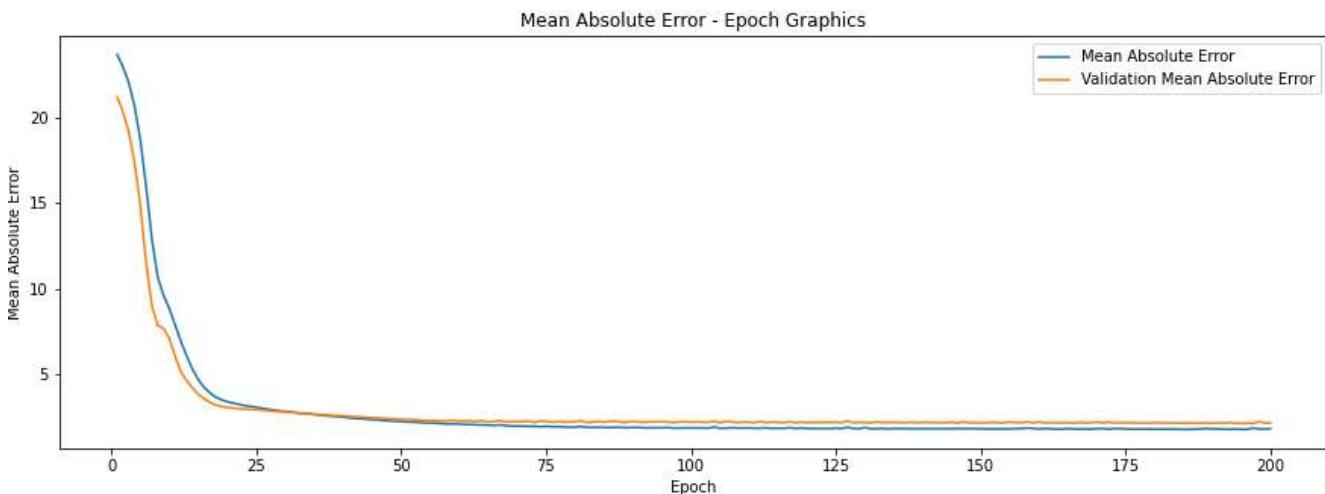
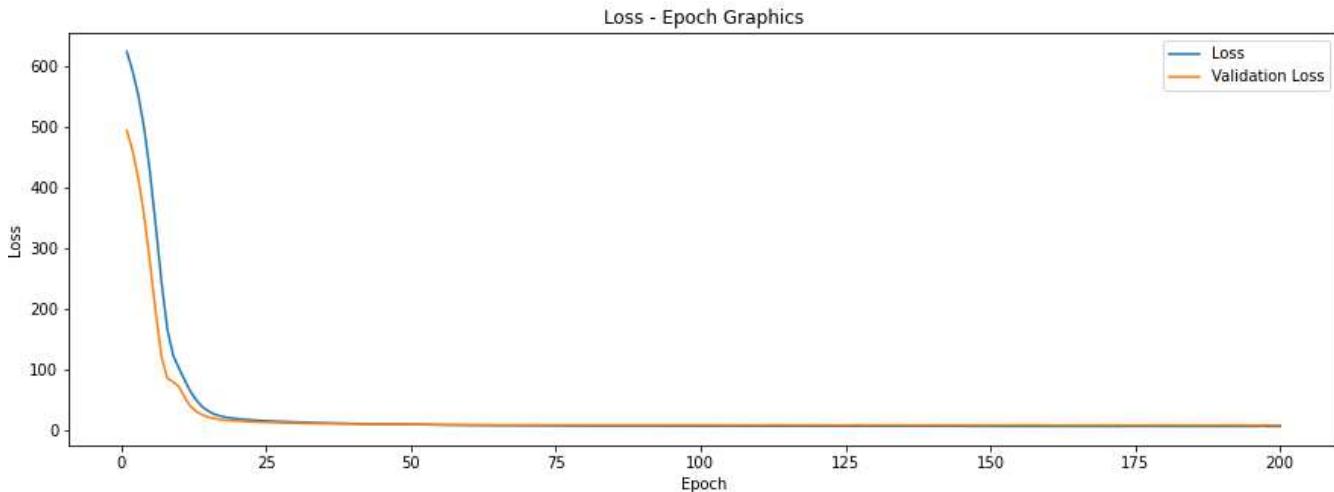
```

```

plt.legend(['Loss', 'Validation Loss'])
plt.show()

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Mean Absolute Error - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Mean Absolute Error')
plt.plot(range(1, len(hist.history['mae']) + 1), hist.history['mae'])
plt.plot(range(1, len(hist.history['val_mae']) + 1), hist.history['val_mae'])
plt.legend(['Mean Absolute Error', 'Validation Mean Absolute Error'])
plt.show()

```



Grafiklerden eğitim veri kümesi ile elde edilen metrik değerlerin sınama veri kümesi ile elde edilenlerle benzer olduğunu görüyorsunuz. Bu durum bir overfitting sorununun olmadığını gösteriyor. Biz eğitimde 200 epoch kullandık. Ancak aslında 75 epoch civarından sonra performansta bir artma olmamaktadır. Eğitimin 75 epoch civarında kesilmesi uygun olacaktır.

Şimdi modelin testini yapalım:

```

test_result = model.evaluate(test_dataset_x, test_dataset_y)
for i in range(len(test_result)):
    print(f'{model.metrics_names[i]} --> {test_result[i]}')

```

Şöyledir bir çıktı elde edilmiş:

```

loss --> 8.037224769592285
mae --> 2.179290771484375

```

Mean Absolute Error değerinin 2.179 olduğunu görüyorsunuz. Bu değer gerçek değerle tahmin edilen değer arasındaki ortalama sapmayı belirtmektedir. Yani biz bir kestirim yaptığımızda gerçek değerle ortalama 2.179 kadar bir sapma ile karşılaşacağız.

Şimdi de predict işlemi yapalım:

```
predict_data = np.array([[4., 113., 95., 2228., 14., 71, 0, 0, 1]], dtype='float32')
predict_data = mms.transform(predict_data)
predict_result = model.predict(predict_data)
print(predict_result)
```

Predict işlemi yapılrken de kategorik verilerin yine one hot encoding dönüştürmesiyle kullanıldığına ve predict verilerinin yine aynı MinMaxScaler nesnesiyle normalize edildiğine dikkat ediniz. Buradan şu sonuç elde edilmiştir:

```
[[22.448292]]
```

Yukarıdaki örneğin tüm kodunu bütün olarak da vermek istiyoruz. Denemeleri bu koddan faydalananarak yapabilirsiniz:

```
import numpy as np

dataset = np.loadtxt('auto-mpg.data', usecols=range(8), dtype='object')
dataset = dataset[dataset[:, 3] != '?', :].astype('float32')

dataset_x = dataset[:, 1:]
dataset_y = dataset[:, 0]

from sklearn.preprocessing import OneHotEncoder, MinMaxScaler

ohe = OneHotEncoder(sparse=False)
ohe_data = ohe.fit_transform(dataset_x[:, 6].reshape(-1, 1))
dataset_x = np.delete(dataset_x, 6, axis=1)
dataset_x = np.append(dataset_x, ohe_data, axis=1)

from sklearn.model_selection import train_test_split

training_dataset_x, test_dataset_x, training_dataset_y, test_dataset_y =
train_test_split(dataset_x, dataset_y, test_size=0.2)

mms = MinMaxScaler()
mms.fit(dataset_x)

training_dataset_x = mms.transform(training_dataset_x)
test_dataset_x = mms.transform(test_dataset_x)

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense

model = Sequential(name='Auto-MPG')
model.add(Dense(100, activation='relu', input_dim=dataset_x.shape[1], name='Hidden-1'))
model.add(Dense(100, activation='relu', name='Hidden-2'))
model.add(Dense(1, activation='linear', name='Output'))

model.summary()

model.compile(optimizer='adam', loss='mse', metrics=['mae'])
hist = model.fit(training_dataset_x, training_dataset_y, batch_size=32, epochs=75,
validation_split=0.2)

import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches((15, 5))
```

```

plt.title('Loss - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.plot(range(1, len(hist.history['loss']) + 1), hist.history['loss'])
plt.plot(range(1, len(hist.history['val_loss']) + 1), hist.history['val_loss'])
plt.legend(['Loss', 'Validation Loss'])
plt.show()

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Mean Absolute Error - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Mean Absolute Error')
plt.plot(range(1, len(hist.history['mae']) + 1), hist.history['mae'])
plt.plot(range(1, len(hist.history['val_mae']) + 1), hist.history['val_mae'])
plt.legend(['Mean Absolute Error', 'Validation Mean Absolute Error'])
plt.show()

test_result = model.evaluate(test_dataset_x, test_dataset_y)
for i in range(len(test_result)):
    print(f'{model.metrics_names[i]} --> {test_result[i]}')

predict_data = np.array([[4., 113., 95., 2228., 14., 71, 0, 0, 1]], dtype='float32')
predict_data = mms.transform(predict_data)
predict_result = model.predict(predict_data)
print(predict_result)

```

Tabii uygulamada kestirim için değerler kullanıcı arayüzünden, varitabanlarından ya da CSV dosyalarından da alınabilir. Örneğin kestirilecek değerler "predict-data.csv" isimli bir dosyada aşağıdaki gibi bulunuyor olsun:

```

8,307,130,3504,12,70,1
8,350,165,3693,11.5,70,1
8,318,150,3436,11,70,1
8,304,150,3433,12,70,1
8,302,140,3449,10.5,70,2

```

Biz predict işlemini verileri bu dosyadan okuyarak da şöyle yapabiliyoruz:

```

predict_data = np.loadtxt('predict-data.csv', delimiter=',', dtype=np.float32)
ohe = OneHotEncoder(categories=[[1, 2, 3]], sparse=False)
ohe_data = ohe.fit_transform(predict_data[:, 6].reshape(-1, 1))
predict_data = np.delete(predict_data, 6, axis=1)
predict_data = np.append(predict_data, ohe_data, axis=1)
predict_data = mms.transform(predict_data)
predict_result = model.predict(predict_data)
print(predict_result)

```

Şöyledir bir çıktı elde edilmiştir:

```

[[15.033615]
[14.265699]
[14.969746]
[15.133997]
[15.067176]]

```

Yukarıdaki işlemde OneHotEncoder nesnesi yaratılırken categories parametresine kategorik değerler girilmiştir. Eğer bu yapılmazsa fit_transform metodu kendine verilen verilerdeki kategori sayısı kadar sütun oluşturmaktadır. Biz categories parametresinde üç kategori belirttiğimiz için fit_transform artık üç sütun oluşturacaktır.

Şimdi model bilgilerini saklamak isteyelim. Bunun için model sınıflarının save metodlarının kullanıldığını anımsayıınız:

```
model.save('autompg.h5')
```

Geri yükleme işleminin de nasıl yapıldığını biliyorsunuz:

```
from tensorflow.keras.models import load_model
model = load_model('autompg.h5')
```

Ancak burada bir noktaya dikkatinizi çekmek istiyoruz. Modeli yükledikten sonra predict işlemi yapmadan önce bizim yine "özellik ölçeklendirmesi (feature scaling)" yapmamız gereklidir. Halbuki bunun için oluşturmuş olduğumuz MinMaxScaler nesnesini biz herhangi biçimde diskte saklamadık. Pekiyi bunun için ne yapabilirim? İşte -"Python Uygulamaları" kursunda da ele aldığımız gibi- aslında sınıf nesnelerini içlerindeki verilerle diske bir dosya içerisinde saklayabiliriz. Bu işleme nesne yönelimli dillerde "nesnelerin seri hale getirilmesi (object serialization)" denilmektedir. Python'da nesnelerin seri hale getirilmesi için pickle isimli bir modül bulunmaktadır. Bu modüldeki dump fonksiyonu nesneyi saklamak için load fonksiyonu da geri almak için kullanılmaktadır. Örneğin:

```
import pickle
with open('mms.dat', 'wb') as f:
    pickle.dump(mms, f)
```

Şimdi de "mms.dat" dosyasında saklamış olduğumuz nesne bilgilerini diskten geri yükleyerek predict işlemi yapalım:

```
import numpy as np
from tensorflow.keras.models import load_model
import pickle
model = load_model('autompg.h5')
with open('mms.dat', 'rb') as f:
    mms = pickle.load(f)
predict_data = np.array([[4., 113., 95., 2228., 14., 71, 0, 0, 1]], dtype='float32')
predict_data = ss.transform(predict_data)
predict_result = model.predict(predict_data)
print(predict_result)
```

Lojistik Olmayan Regresyon Modeli İçin "Boston Housing Prices" Örneği

Şimdi de lojistik olmayan regresyon için başka bir örnek üzerinde çalışacağımız Boston Housing Prices veri kümesi Boston'da 70'li yılların sonlarına doğru ev fiyatlarının tahmin edilmesi için toplanmış verilerden oluşmaktadır. Veri kümesi <https://www.kaggle.com/vikrishnan/boston-house-prices> adresinden indirilebilir. Dosyanın genel görünümü şöyledir:

0.00632	18.00	2.310	0	0.5380	6.5750	65.20	4.0900	1	296.0	15.30	396.90	4.98	24.00
0.02731	0.00	7.070	0	0.4690	6.4210	78.90	4.9671	2	242.0	17.80	396.90	9.14	21.60
0.02729	0.00	7.070	0	0.4690	7.1850	61.10	4.9671	2	242.0	17.80	392.83	4.03	34.70
0.03237	0.00	2.180	0	0.4580	6.9980	45.80	6.0622	3	222.0	18.70	394.63	2.94	33.40
0.06905	0.00	2.180	0	0.4580	7.1470	54.20	6.0622	3	222.0	18.70	396.90	5.33	36.20
0.02985	0.00	2.180	0	0.4580	6.4300	58.70	6.0622	3	222.0	18.70	394.12	5.21	28.70
0.08829	12.50	7.870	0	0.5240	6.0120	66.60	5.5605	5	311.0	15.20	395.60	12.43	22.90
0.14455	12.50	7.870	0	0.5240	6.1720	96.10	5.9505	5	311.0	15.20	396.90	19.15	27.10
0.21124	12.50	7.870	0	0.5240	5.6310	100.00	6.0821	5	311.0	15.20	386.63	29.93	16.50
0.17004	12.50	7.870	0	0.5240	6.0040	85.90	6.5921	5	311.0	15.20	386.71	17.10	18.90
0.22489	12.50	7.870	0	0.5240	6.3770	94.30	6.3467	5	311.0	15.20	392.52	20.45	15.00
0.11747	12.50	7.870	0	0.5240	6.0090	82.90	6.2267	5	311.0	15.20	396.90	13.27	18.90
0.09378	12.50	7.870	0	0.5240	5.8890	39.00	5.4509	5	311.0	15.20	390.50	15.71	21.70
0.62976	0.00	8.140	0	0.5380	5.9490	61.80	4.7075	4	307.0	21.00	396.90	8.26	20.40
0.63796	0.00	8.140	0	0.5380	6.0960	84.50	4.4619	4	307.0	21.00	380.02	10.26	18.20
0.62739	0.00	8.140	0	0.5380	5.8340	56.50	4.4986	4	307.0	21.00	395.62	8.47	19.90
1.05393	0.00	8.140	0	0.5380	5.9350	29.30	4.4986	4	307.0	21.00	386.85	6.58	23.10
0.78420	0.00	8.140	0	0.5380	5.9900	81.70	4.2579	4	307.0	21.00	386.75	14.67	17.50

Dosyada sütunların boşluk karakterleriyle birbirlerinden ayırdığını görüyorsunuz. Dosyanın son sütunu evin 1000 dolar cinsinden fiyatını belirtmektedir. Biz burada diğer sütun özelliklerinin neler olduğu üzerinde durmayacağımız. Ancak yukarıda verdigimiz "Kaggle" bağlantısından sütun özelliklerinin anlamlarını öğrenebilirsiniz. Biz yukarıdaki bağlantı yoluyla veri kümesi dosyasının "housing.csv" ismiyle çalışma dizini içerisinde indirdiğini varsayacağımız.

Dosyayı aşağıdaki gibi yükleyip eğitim ve test veri kümelerini ayırtılabiliriz:

```
import numpy as np

dataset = np.loadtxt('housing.csv')
dataset_x = dataset[:, :-1]
dataset_y = dataset[:, -1]

from sklearn.model_selection import train_test_split
training_dataset_x, test_dataset_x, training_dataset_y, test_dataset_y =
train_test_split(dataset_x, dataset_y, test_size=0.20)
```

Aslında bu veri kümesi test amacıyla makine öğrenmesi öğrencileri tarafından çok kullanıldığı için tensorflow.keras.datasets.boston_housing modülünde de hazır bir biçimde bulundurulmuştur. Modülün load_data fonksiyonu verileri bize ikili demetten oluşan ikili demet biçiminde vermektedir. Biz de aşağıdaki gibi verileri kullanıma hazır hale getirebiliriz:

```
from tensorflow.keras.datasets import boston_housing

(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) =
boston_housing.load_data()
```

Veriler incelendiğinde bir özellik ölçeklendirmesi yapılması gerektiği görülmektedir. Veri kümesinin 3'üncü indeksli sütunu aslında 0 ve 1 değerlerinden oluşan kategorik bir sütundur. İkili kategoriler için one hot encoding işleminin gereklidğini anımsayınız. O halde bu veri kümesi için örnek modeli şöyle oluşturabiliriz.

```
from tensorflow.keras.datasets import boston_housing

(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) =
boston_housing.load_data()

from sklearn.preprocessing import MinMaxScaler

mms = MinMaxScaler()
```

```

mms.fit(training_dataset_x)
training_dataset_x = mms.transform(training_dataset_x)
test_dataset_x = mms.transform(test_dataset_x)

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense

model = Sequential()
model.add(Dense(100, input_dim=training_dataset_x.shape[1], activation='relu', name='Hidden-1'))
model.add(Dense(100, activation='relu', name='Hidden-2'))
model.add(Dense(1, activation='linear', name='Output'))

model.compile('rmsprop', loss='mse', metrics=['mae'])
hist = model.fit(training_dataset_x, training_dataset_y, epochs=300, validation_split=0.2,
batch_size=32)

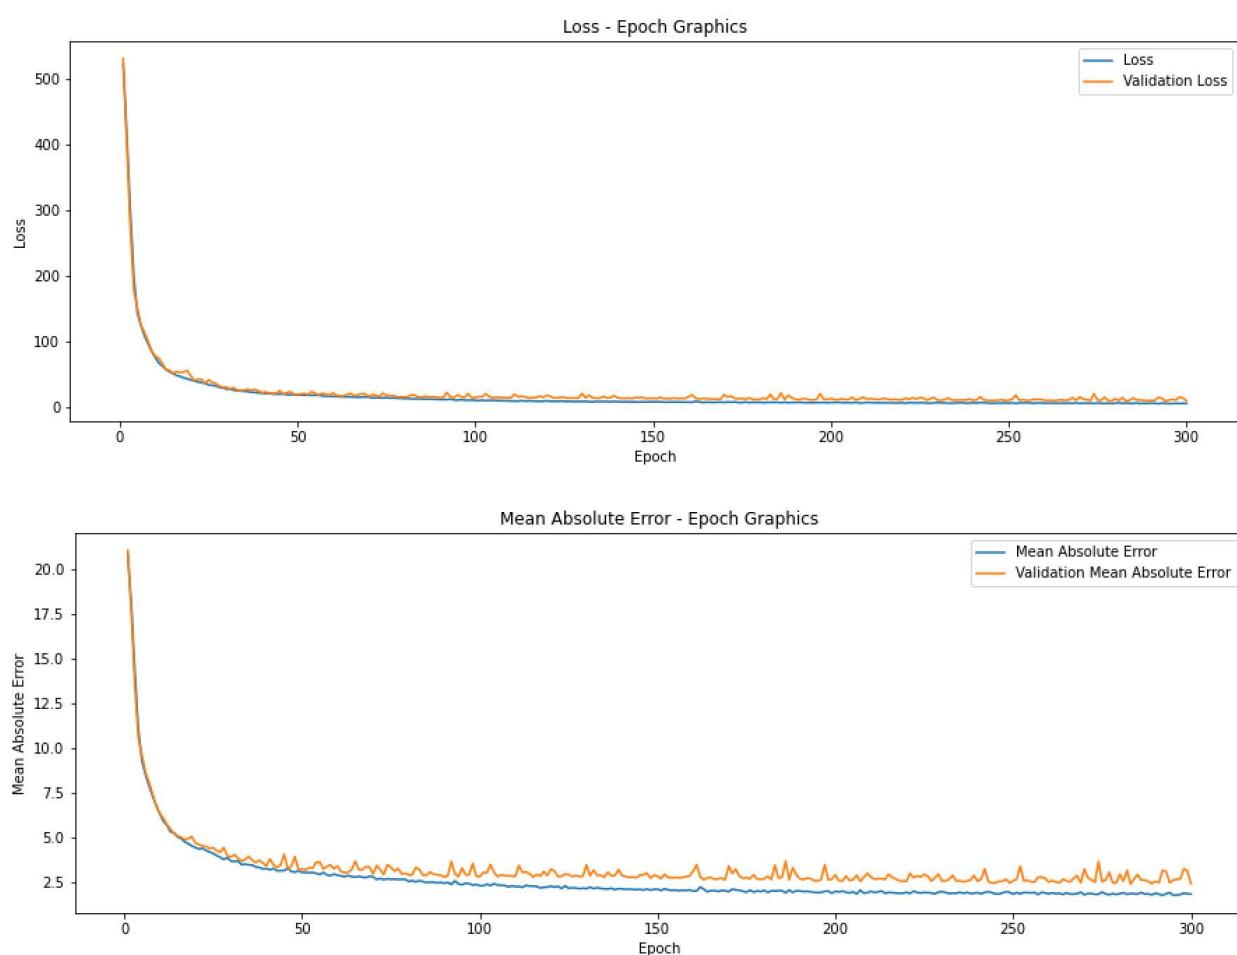
import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Loss - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.plot(range(1, len(hist.history['loss']) + 1), hist.history['loss'])
plt.plot(range(1, len(hist.history['val_loss']) + 1), hist.history['val_loss'])
plt.legend(['Loss', 'Validation Loss'])
plt.show()

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Mean Absolute Error - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Mean Absolute Error')
plt.plot(range(1, len(hist.history['mae']) + 1), hist.history['mae'])
plt.plot(range(1, len(hist.history['val_mae']) + 1), hist.history['val_mae'])
plt.legend(['Mean Absolute Error', 'Validation Mean Absolute Error'])
plt.show()

```

Burada 300 epoch uyguladık. Eğitim sırasındaki loss ve metrik grafiklerine bakalım:



Grafiklerden herhangi bir overfitting şüphesinin olmadığı görülmektedir. Ayrıca epoch işleminin 100 civarından sonra performansın pek değişmediğini görüyoruz. Artık modeli test edebiliriz:

```
eval_result = model.evaluate(test_dataset_x, test_dataset_y)
for i in range(len(eval_result)):
    print(f'{model.metrics_names[i]}: {eval_result[i]}')
```

Şöyledir bir çıktı elde edilmiş:

```
loss: 18.788570404052734
mae: 2.841968059539795
```

Hedeften ortalama sapmanın 2.84 civarında olduğunu görüyoruz. Şimdi de bir kestirim yapalım:

```
import numpy as np

predict_data = np.array([[18.0846, 0, 18.1, 0, 0.679, 6.434, 100, 1.8347, 24, 666, 20.2, 27.25,
29.05]])
predict_data = mms.transform(predict_data)
predict_result = model.predict(predict_data)
print(predict_result)
```

Şöyledir bir çıktı elde edilmiş:

```
[[9.333602]]
```

Yapay Sinir Ağlarında Çok Değişkenli (Multivariate) Regresyon Modelleri

Aslında sinir ağlarında tek değişkenli regresyon modelleri ile çok değişkenli (multivariate) regresyon modelleri arasında mimari olarak ve parametre belirleme bağlamında önemli bir fark yoktur. Yalnızca çok değişkenli modellerde çıktı katmanındaki nöronların sayısı bağımlı değişken sayısına kadar olmaktadır. Örneğin biz ev fiyatını tahmininde evin fiyatının yanı sıra kirasını da tahmin etmek isteyebiliriz. Tek yapacağımız şey çıktı katmanındaki nöron sayısını 1 yerine 2 yapmak olacaktır. Tabii eğitim ve test veri kümelerinde bu iki değerin bulunuyor olması gereklidir. Lojistik regresyon modelleri için "çok değişkenli (multivariate)" terimi yerine "çok etiketli (multilabel)" terimi daha çok tercih edilmektedir.

Yapay Sinir Ağlarında Lojistik Regresyon Modelleri

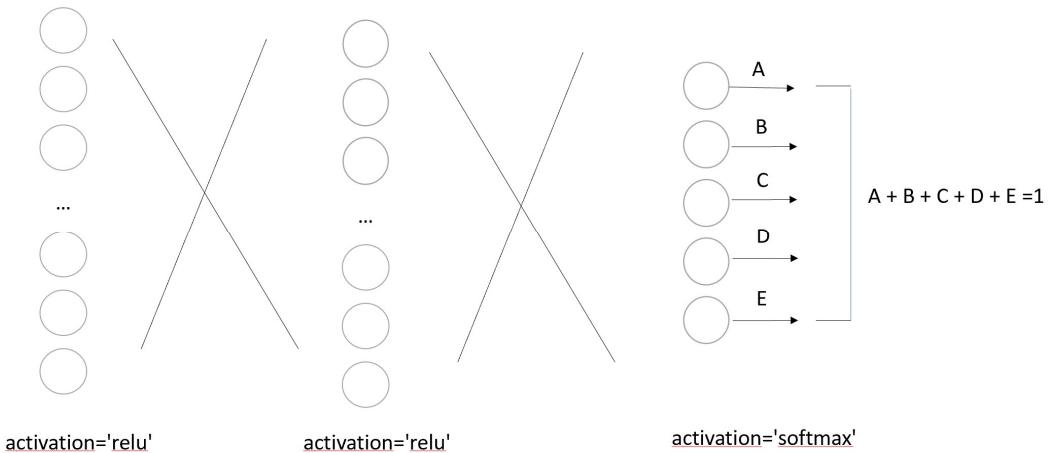
Daha önceden de belirttiğimiz gibi istatistikte sınıflandırma için "lojistik regresyon" terimi de kullanılmaktadır. Lojistik regresyon problemleri kendi aralarında "etiket (label)" ve "sınıf (class)" sayılarına göre grupperliliktedir. Etiket çıktıdaki değişken sayısını belirtmektedir. Örneğin modelin çıktısı "kişinin eğitim durumu" ve "obez olup olmadığına" ilişkin olsun. Burada iki tane etiket vardır. Tabii etiketler de kendi aralarında iki sınıfı ya da daha fazla sınıfı sahip olabilirler. Örneğin eğitim durumu beş sınıfı, obez olup olmama iki sınıfı temsil edilebilir. Bu durumda lojistik regresyon modellerini üç gruba ayıralım:

- 1) Tek etiketli iki sınıfı lojistik regresyon modelleri
- 2) Tek etiketli çok sınıfı Lojistik regresyon modelleri
- 3) Çok etiketli çok sınıfı lojistik regresyon modelleri

Şimdi bu modeller üzerinde biraz daha duralım.

1) Tek Etiketli-İkili (Single-Label Binary) Lojistik Regresyon Modelleri: Bu modeller tipik lojistik regresyon modelleridir. Daha önce yapmış olduğumuz diyabet modeli buna tipik bir örnektir. Bu modellerde yapay sinir ağının çıktı katmanında tek bir nöron bulunur. Bu nöronun çıktı değeri "doğru-yanlış", "var-yok", "hasta sağlam" gibi ikili bir değerdir. Daha önce de belirttiğimiz gibi tek etiketli ikili sınıflandırma modellerinde genellikle saklı katmanlardaki aktivasyon fonksiyonları "relu" olarak, çıktı katmanındaki aktivasyon fonksiyonu ise "sigmoid" olarak alınmaktadır. Anımsanacağı gibi sigmoid fonksiyonu 0 ile 1 arasında "S" şekli biçiminde bir değer vermektedir. Bu durumda çıktı katmanındaki nöronun çıkış değerinin "var-yok", "hasta-sağlıklı", "doğru-yanlış" gibi yorumlanması bu değerin 0.5 gibi bir eşik değerinden büyük ya da küçük olup olmamasına bakılarak yapılır. Daha önce de belirttiğimiz gibi tek etiketli ikili modellerdeki optimizasyon algoritması "adam" "sgd" ya da "rmsprop" "seçilebilir. loss fonksiyonu genellikle "binary_crossentropy" alınmaktadır. Metrik değerler için ise en çok tercih edilen "binary_accuracy" fonksiyonudur. Bu tür modellerde veri kümelerinde sütunlar arttıkça saklı katmanların ve saklı katmanlardaki sayılarının artırılması tavsiye edilmektedir. Bu tür modellerin denemelerine iki saklı katmanla başlayabilirsiniz. Duruma göre saklı katmanların sayılarını artırabilirsiniz. Saklı katmanlardaki nöron sayıları girdi katmanındaki nöron sayılarının iki katı biçiminde alınabilir. Duruma göre bu nöronlar artırılabilir. Yukarıdaki "diabetes.csv" örneğinde katmanlardaki nöron sayılarını 100 tutmuştur. Aslında bu modelde katmanlardaki nöron sayılarını 16 gibi bir değerde tutmak sonucu çok fazla etkilemeyecektir.

2) Tek Etiketli-Çok Sınıflı (Single-Label Multi-Class) Lojistik Regresyon Modelleri: Bu modellerin çıktıları kategoriktir fakat ikiden fazla sınıfından oluşmaktadır. Örneğin sinir ağı kişinin eğitim durumunu "ilkokul", "ortaokul", "lise", "üniversite" biçiminde tahmin etmek için oluşturulmuş olabilir. Ya da örneğin sinir ağı resmini aldığı meyvenin "elma", mı "armut" mu, "kayısı" mı olduğunu belirlemek için oluşturulmuş olabilir. Bu tür modellerde çıktı katmanındaki nöron sayısı toplam sınıf sayısı kadar olur. Örneğin modelimiz girdiyi A, B, C, D, E biçiminde sınıflandırıracak olsun. Bu modeldeki çıktı katmanındaki nöronlarının sayısı 5 olacaktır. Bu tür modellerde saklı katmanlar için yine genellikle "relu" aktivasyon fonksiyonu kullanılmaktadır. Ancak çıktı katmanındaki aktivasyon fonksiyonu "softmax" alınır. Softmax aktivasyon fonksiyonu çıktı nöronlarının (yani sınıfların) toplam olasılıklarının 1 değerini verdiği bir aktivasyon fonksiyonudur. Başka bir deyişle önceki örnekte çıktı katmanındaki her kategoriyi belirten nöronların çıkış değerleri toplamı 1 olacaktır.



Cıktı katmanındaki nöronların toplam değeri 1 olduğuna göre hangi sınıfın seçildiği nasıl anlaşılacaktır? İşte çok sınıflı bu tür modellerde hangi çıktı nöronunun değeri daha yüksekse o sınıfı seçtiği varsayılabılır. NumPy'da bir ndarray içerisindeki değerlerin en büyüğünün max fonksiyonuyla en büyük elemanın indeksinin ise maxarg fonksiyonuyla elde edildiğini anımsayınız. Örneğin çıktı katmanındaki nöron değerlerinin $A = 0.3$, $B = 0.2$, $C = 0.1$, $D = 0.35$ ve $E = 0.05$ biçiminde olduğunu ve "output" isimli NumPy dizisi içerisinde bulunduğu varsayıalım:

```
In [8]: output
Out[8]: array([0.3 , 0.2 , 0.1 , 0.35, 0.05])

In [9]: np.sum(output)
Out[9]: 1.0

In [10]: np.max(output)
Out[10]: 0.35

In [11]: np.argmax(output)
Out[11]: 3
```

Burada np.argmax fonksiyonu ile üçüncü indeksli nöronun en yüksek değerde olduğu bulunmuştur.

Çok sınıflı modellerde en uygun loss fonksiyonu "categorical_crossentropy"dir. Optimizasyon algoritması için yine "adam", "sgd" ya da "rmsprop" kullanılabilir. Tek etiketli çok sınıflı modeller için metrik fonksiyonu da genellikle "categorical_accuracy" seçilmektedir.

Çok sınıflı modellerde deneme yine iki saklı katmanla başlatılabilir. Ancak sınıf sayısı çok fazlaysa saklı katmanların sayısını artırmak gerekebilir. Fazla sınıflı modellerin yüksek miktarda verilerle eğitilmesi önerilmektedir.

3) Çok Etiketli (Multi-Label) Lojistik Regresyon Modelleri: Çok etiketli modeller bağımlı değişkenin birden fazla olduğu modellerdir. Yukarıda da belirttiğimiz gibi istatistikte bu tür modellere "çok değişkenli (multivariate)" modeller de denilmektedir. Çok etiketli modellerdeki her bir değişken (yani etiket) iki ya da daha fazla sınıfından oluşabilmektedir. Örneğin biz bir sinir ağı ile çeşitli biyomedikal tetkik değerlerinden hareketle hem kişinin şeker hastası olup olmadığını hem de kalp hastalıklarına yatkınlık derecesini tahmin etmek isteyebiliriz. Kişiňin şeker hastası olup olmadığı iki sınıflı bir çıktı oluştururken, kalp hastalıklarına yatkınlık derecesi üç sınıflı bir çıktı oluşturabilir.

Aşağıdaki tabloda hangi lojistik regresyon modellerinde hangi parametrik değerlerin seçileceği özet olarak belirtilmiştir:

Sınıflandırma Model	Optimizasyon Algoritması	Loss Fonksiyonu	Saklı Katman Aktivasyon Fonksiyonları	Cıktı Katmanı Aktivasyon Fonksiyonu
Tek Etiketli-İki	'rmsprop', 'adam',	'binary_crossentropy'	'relu'	'sigmoid'

Sınıflı Modeller	'sgd'			
Tek Etiketli- Çok Sınıflı Modeller	'rmsprop', 'adam', 'sgd'	'categorical_crossentropy'	'relu'	'softmax'
Çok Etiketli Modeller	'rmsprop', 'adam', 'sgd'	İki Sınıflı Çıktılar İçin 'binary_crossentropy', Çok Sınıflı Çıktılar İçin 'categorical_crossentropy'	'relu'	İki Sınıflı Çıktılar İçin 'sigmoid', Çok Sınıflı Çıktılar İçin 'softmax'

Pekiyi birden fazla sınıfın içerisinde girebilen sınıflandırma modelleri için ne yapılabilir? Örneğin bir müzik parçasının türünü sınıflandırmak isteyelim. Parçanın türü "pop", "rock", "jazz", "slow", "rap", "new wave" gibi kategorilerin birden fazlasına sahip olabilsin. Bu nasıl bir sınıflandırma modelidir? Bu model aslında çok etiketli bir model olarak düşünülebilir. Yani aslında burada toplamda 6 etiket vardır. Bu 6 etiket "var", "yok" biçiminde iki sınıf içermektedir. O halde bu model için 6 çıktıya sahip olan bir ağ oluşturulabilir. Bu 6 çıktılarının hepsi de "sigmoid" aktivasyon fonksiyonuna sahip olabilir. Diğer bir seçenek de problemi tek etiketli çok sınıflı olarak modellemektir. Bu durumda çıktı katmanında yine 6 nöron bulunur fakat çıktı katmanın aktivasyon fonksiyonu "softmax" alınır. Böylece en yüksek oranlı çıktıları veren birden fazla sınıf alınabilir. Veri analistleri daha bu tür durumlarda çok etiketli iki sınıflı model oluşturmayı tercih etmektedir.

İki Sınıflı Lojistik Regresyon Modeli İçin IMDB Örneği

Daha önce tek etiketli iki sınıflı lojistik regresyon modeli için "diabetes" örneğini vermiştık. O örnekte 8 biyomedikal tetkik sonucuna göre kişinin şeker hastası olup olmadığını tahmin etmeye çalışıyorduk. Şimdi de IMDB isimli tek etiketli iki sınıflı başka bir örnek üzerinde çalışacağız.

IMDB veri kümesi filmlerlarındaki yorumlardan oluşmaktadır. Her yorum "olumlu (pozitif)" ya da "olumsuz (negative)" biçimde değerlendirilmektedir. Biz burada içeriye bakarak bir yorumun olumlu mu yoksa olumsuz mu olduğunu tahmin edecek bir model üzerinde çalışacağız. IMDB veri kümesi CSV dosyası olarak <https://www.kaggle.com/lakshmi25npathi/imdb-dataset-of-50k-movie-reviews> adresinden indirilebilir. Bu CSV dosyası iki sütundan oluşmaktadır. Birinci sütunda yorum yazısı ikinci sütunda yorumun olumlu mu olumsuz mu olduğunu belirten "positive" ya da "negative" yazısı vardır. Yorum yazısı iki tırnak içerisinde alınmıştır. Dosyanın görünümü şöyledir:

```
review,sentiment
"One of the other reviewers has mentioned that after watching just 1 Oz episode you'll be hooked. They are right, as this is exactly what happened with me.<br>"A wonderful little production. <br /><br />The filming technique is very unassuming- very old-time-BBC fashion and gives a comforting, and sometimes discomfort. I thought this was a wonderful way to spend time on a too hot summer weekend, sitting in the air conditioned theater and watching a light-hearted comedy. The plot is simple: Basically there's a family where a little boy (Jake) thinks there's a zombie in his closet & his parents are fighting all the time.<br /><br />This movie is simple and sweet. Petter Mattei's ""Love in the Time of Money"" is a visually stunning film to watch. Mr. Mattei offers us a vivid portrait about human relations. This is a movie that I can watch over and over again. Probably my all-time favorite movie, a story of selflessness, sacrifice and dedication to a noble cause, but it's not preachy or boring. It just never gets old. I sure would like to see a resurrection of a updated Seabunt series with the tech they have today it would bring back the kid excitement in me.I grew up on this movie. This show was an amazing, fresh & innovative idea in the 70's when it first aired. The first 7 or 8 years were brilliant, but things dropped off after that. By the way, I'm a huge fan of the show. Encouraged by the positive comments about this film on here I was looking forward to watching this film. Bad mistake. I've seen 950+ films and this is truly one of the best. If you like original gut wrenching laughter you will like this movie. If you are young or old then you will love this movie, hell even my mom liked it.<br /><br />Phil the Alien is one of those quirky films where the humour is based around the oddness of everything rather than actual punchlines.<br /><br />At first it was a bit of a let down, but then I started to appreciate it more. I recall the scariest scene was the big bird eating men dangling helplessly from parachutes right out of the sky. So im not a big fan of Boll's work but then again not many are. I enjoyed his movie Postal (maybe its the only one). Boll apparently bought the rights to use Facebook's logo in his movie. The cast played Shakespeare.<br /><br />Shakespeare lost.<br /><br />I appreciate that this is trying to bring Shakespeare to the masses, but why ruin something that is so good? This is a fantastic movie of three prisoners who become famous. One of the actors is george clooney and I'm not a fan but this roll is not bad. Another good thing about this movie is the way it is shot. Kind of drawn in by the erotic scenes, only to realize this was one of the most amateurish and unbelievable bits of film I've ever seen. Sort of like a high school project that failed. Some films just simply should not be remade. This is one of them. In and of itself it is not a bad film. But it fails to capture the flavor and the terror of the original. This movie made it into one of my top 10 most awful movies. Horrible. <br /><br />There wasn't a continuous minute where there wasn't a fight with one monster or another. I remember this film, it was the first film i had watched at the cinema the picture was dark in places i was very nervous it was back in 74/75 my Dad took me my to the cinema. An awful film! It must have been up against some real stinkers to be nominated for the Golden Globe. They've taken the story of the first famous female Renaissance painter and turned it into a movie. After the success of Die Hard and it's sequels it's no surprise really that in the 1990s, a glut of 'Die Hard on a Plane' movies cashed in on the wrong guy, we saw a lot of them. I had the terrible misfortune of having to view this ""b-movie"" in it's entirety.<br /><br />All I have to say is--- save your time and money!!! This has got to be one of the worst movies I have ever seen. What an absolutely stunning movie, if you have 2.5 hrs to kill, watch it, you won't regret it, it's too much fun! Rajnikanth carries the movie on his shoulders. First of all, let's get a few things straight here: a) I AM an anime fan- always has been as a matter of fact (I used to watch Speed Racer all the time in Primary School). This was the worst movie I saw at Worldfest and it also received the least amount of applause afterwards! I can only think it is receiving such recognition because it is an exotic masterpiece. The Karen Carpenter Story shows a little more about singer Karen Carpenter's complex life. Though it fails in giving accurate facts, and details.<br /><br />Conclusion: The Cell"" is an exotic masterpiece. a dazzling trip into not only the vast mind of a serial killer. but also into one of a very talented director. This is a movie that I will never forget.
```

Yazı içerisinde satır başı için HTML
 kullanıldığına dikkat ediniz. Burada her satırda tek bir yorum ve sonuç olduğu için ve yorum yazısı da uzun olduğu için sonuç kısmı görülemiyor. Şimdi sözcük sarmalamayı (word wrap) etkin hale getirip görüntüyü bir kez daha verelim:

review,sentiment
"One of the other reviewers has mentioned that after watching just 1 Oz episode you'll be hooked. They are right, as this is exactly what happened with me.
>
The first thing that struck me about Oz was its brutality and unflinching scenes of violence, which set in right from the word GO. Trust me, this is not a show for the faint hearted or timid. This show pulls no punches with regards to drugs, sex or violence. Its is hardcore, in the classic use of the word.
>
It is called OZ as that is the nickname given to the Oswald Maximum Security State Penitentiary. It focuses mainly on Emerald City, an experimental section of the prison where all the cells have glass fronts and face inwards, so privacy is not high on the agenda. Em City is home to many..Aryans, Muslims, gangstas, Latinos, Christians, Italians, Irish and more....so scuffles, death stares, dodgy dealings and shady agreements are never far away.
>
I would say the main appeal of the show is due to the fact that it goes where other shows wouldn't dare. Forget pretty pictures painted for mainstream audiences, forget charm, forget romance..OZ doesn't mess around. The first episode I ever saw struck me as so nasty it was surreal, I couldn't say I was ready for it, but as I watched more, I developed a taste for Oz, and got accustomed to the high levels of graphic violence. Not just violence, but injustice (crooked guards who'll be sold out for a nickel, inmates who'll kill on order and get away with it, well mannered, middle class inmates being turned into prison bitches due to their lack of street skills or prison experience) Watching Oz, you may become comfortable with what is uncomfortable viewing...thats if you can get in touch with your darker side.",positive

"A wonderful little production.

The filming technique is very unassuming- very old-time-BBC fashion and gives a comforting, and sometimes discomforting, sense of realism to the entire piece.

The actors are extremely well chosen- Michael Sheen not only ""has got all the polaris"" but he has all the voices down pat too! You can truly see the seamless editing guided by the references to Williams' diary entries, not only is it well worth the watching but it is a terrifically written and performed piece. A masterful production about one of the great master's of comedy and his life.

The realism really comes home with the little things: the fantasy of the guard which, rather than use the traditional 'dream' techniques remains solid then disappears. It plays on our knowledge and our senses, particularly with the scenes concerning Orton and Halliwell and the sets (particularly of their flat with Halliwell's murals decorating every surface) are terribly well done.",positive

"I thought this was a wonderful way to spend time on a too hot summer weekend, sitting in the air conditioned theater and watching a light-hearted comedy. The plot is simplistic, but the dialogue is witty and the characters are likable (even the well bread suspected serial killer). While some may be disappointed when they realize this is not Match Point 2: Risk Addiction, I thought it was proof that Woody Allen is still fully in control of the style many of us have grown to love.

This was the most I'd laughed at one of Woody's comedies in years (dare I say a decade?). While I've never been impressed with Scarlet Johanson, in this she managed to tone down her ""sexy"" image and jumped right into a average, but spirited young woman.

This may not be the crown jewel of his career, but it was wittier than ""Devil Wears Prada"" and more interesting than ""Superman"" a great comedy to go see with friends.",positive

"Basically there's a family where a little boy (Jake) thinks there's a zombie in his closet & his parents are fighting all the time.

This movie is slower than a soap opera... and suddenly, Jake decides to become Rambo and kill the zombie.

OK, first of all when you're going to make a film you must Decide if its a thriller or a drama! As a drama the movie is watchable. Parents are divorcing & arguing like in real life. And then we have Jake with his closet which totally ruins all the film! I expected to see a BOOGYMAN similar movie, and instead i watched a drama with some meaningless thriller spots.

3 out of 10 just for the well playing parents & descent dialogs. As for the shots with Jake: just ignore them.",negative

"Petter Mattei's ""Love in the Time of Money"" is a visually stunning film to watch. Mr. Mattei offers us a vivid portrait about human relations. This is a movie that seems to be telling us what money, power and success do to people in the different situations we encounter.

This being a variation on the Arthur Schnitzler's play about the same theme, the director transfers the action to the present time New York where all these different characters meet and connect. Each one is connected in one way. or another to the next person. but no one seems to know the previous point of contact. Stylishv. the film has a

Tırnaklanmış içeriğin numpy.load.txt fonksiyonu ile okunması biraz zahmetlidir. Bu tür dosyaların okunması pandas.read_csv fonksiyonu ile çok daha kolay yapılabilir:

```
import pandas as pd

df = pd.read_csv('imdb.csv')
```

Bildiğiniz gibi yapay sinir ağları tamamen sayısal düzeydeki verilerle işlemler yapmaktadır. O halde bizim yorumdaki sözcükleri bir biçimde sayılarla ifade etmemiz gereklidir. Bunun bir yolu yorumlardaki tüm sözcükleri, anahtarlar sözcüklerden değerler de onların indeks numaralarından oluşan bir sözlükte tutmak olabilir. Bunu sağlamak için veri kümesindeki tüm yorumlardaki tüm sözcükler bir sözlüğe yerleştirilebilir. Sözlükteki her sözcüğe bir indeks numarası karşı getirilebilir. Bir yorum da böylece sözcüklerden değil indeks numaralarından oluşturulmuş olur. Şimdi önce DataFrame nesnesi içerisindeki tüm yazıları sözcüklere ayırip bir yeniden DataFrame içerisinde yerlestirelim. Bu sırada da tüm sözcükleri tek olacak biçimde bir kümeye toplayalım. Bunu yapmanın çok yolu olabilir. Ancak biz dosyayı bir kez okumak için read_csv fonksiyonunda okuma sırasında dönüştürme yapmayı tercih edeceğiz:

```
import numpy as np
import re

class WordConverter:
    def __init__(self):
        self.word_set = set()

    def __call__(self, text):
        words = re.findall("[a-zA-Z0-9'-]+", text.lower())
        self.word_set.update(words)

        return np.array(words)

    def get_word_dict(self):
        return {word: index for index, word in enumerate(wc.word_set)}

import pandas as pd

wc = WordConverter()
df = pd.read_csv('imdb.csv', converters={0: wc})
word_dict = wc.get_word_dict()
```

Bu işlemden sonra df içerisinde artık ilk sütunda küçük harfe dönüştürülmüş biçimde yazılarından oluşan bir NumPy dizisi elde edilecektir. DataFrame nesnesinin ilk satırını aşağıda görüyorsunuz:

```
In [77]: df.iloc[0]
Out[77]:
review      [one, of, the, other, reviewers, has, mentione...
sentiment                           positive
Name: 0, dtype: object
```

WordConverter sınıfının get_word_dict isimli metodunun tüm yorumlardaki tüm sözcükleri içeren bir sözlük nesnesi verdiğine dikkat ediniz. word_dict sözlüğünden 20 eleman yazdırıralım:

```
In [47]: dict(itertools.islice(word_dict.items(), 20))
Out[47]:
{'stewert': 0,
 'theatre-style': 1,
 'metabolismic': 2,
 'blaring': 3,
 'right-and-good': 4,
 'ralph-bernadette': 5,
 'ferrero': 6,
 'heterosexuals': 7,
 'reinvents': 8,
 "fargo)": 9,
 'secondtime': 10,
 'post-atomic': 11,
 'bulletins': 12,
 'retains': 13,
 "'gahden)": 14,
 "allows)": 15,
 'hedge-hog-thing': 16,
 'levels': 17,
 'pined': 18,
 'goire': 19}
```

Şimdi de word_dict sözlüğünün uzunluğuna bakalım:

```
In [51]: len(word_dict)
Out[51]: 156840
```

Şimdi de tüm yazıları indeks numaralarıyla ifade edelim:

```
for i in range(len(df)):
    df.iloc[i, 0] = np.array([word_dict[word] for word in df.iloc[i, 0]])
```

DataFrame nesnesinin ilk satırına bakınız:

```
In [59]: df.iloc[0]
Out[59]:
review      [126434, 128794, 29339, 17370, 57739, 8688, 76...
sentiment                           positive
Name: 0, dtype: object
```

Göründüğü gibi artık yapılan yorum yazı olmaktan çıkmış bir sayı dizisi haline dönüştürülmüştür. Böyle bir sayı dizisini yazıya dönüştürmek isterseniz yukarıda oluşturmuş olduğumuz word_dict sözlüğünü kullanamazsınız. Bu sözlüğü anahtar değer bağlamında ters çevirmek gerekir:

```
rev_word_dict = {index: word for word, index in word_dict.items()}
```

Şimdi artık yeniden yorumu yazışal biçimde dönüştürebiliriz. Örneğin ilk yorumu yazışal biçimde dönüştürmek isteyelim:

```
text = ' '.join([rev_word_dict[index] for index in df.iloc[0, 0]])
print(text)
```

Şöyledir bir çıktı elde edilmiş:

one of the other reviewers has mentioned that after watching just 1 oz episode you'll be hooked they are right as this is exactly what happened with me br br the first thing that struck me about oz was its brutality and unflinching scenes of violence which set in right from the word go trust me this is not a show for the faint hearted or timid this show pulls no punches with regards to drugs sex or violence its is hardcore in the classic use of the word br br it is called oz as that is the nickname given to the oswald maximum security state penitentiary it focuses mainly ...

Ancak burada önemli bir sorun üzerinde durmak istiyoruz. Bu örnekte her yorumdaki sözcük sayıları farklıdır. İnsanlar yorumlarını değişik uzunlukta yapabilmektedir. Bu ise yapay sinir ağı modeline uygun değildir. Çünkü yapay sinir ağlarının çalışması için her satırın eşit sayıda sütun bilgisine (yani girdiye) sahip olması gereklidir. Peki bu durum IMDB örneğinde nasıl sağlanabilir? İşte bunun iki yolu olabilir: Birincisi yorumlardaki sözcük sayılarını eşit hale getirmektir (kısa olanları atıp uzun olanları kırmak). İkincisi de tüm yorumlardaki tüm sözcükleri temel olarak eşit uzunlukta bir bool vektör oluşturmaktır. Yorumlardaki yazıları kırmak iyi bir fikir değildir. Çünkü bu durumda yorumlar anlamsızlaşabilir ya da yorumlar yanlış anlaşılabilir. Tüm yorumları eşit uzunlukta bool vektörlerle ifade etmek daha iyi bir çözümdür. Bool vektör yönteminde her yorum için tüm yorumlardaki tüm sözcüklerin sayısı kadar bool bir vektör oluşturulur. Yorum içerisinde geçen sözcükler 1 ile geçmeyen sözcükler 0 ile kodlanır. Örneğin bir yorumda 100 sözcük bulunuyor olsun. Yorumlardaki tüm sözcük sayısının da 156840 olduğunu biliyoruz. Bu durumda biz her yorum için 156840'luk bir bool vektör oluştururuz. Bu 156840'luk bool vektördeki 100 elemanı 1 diğerlerini 0 yaparız. 1 olan vektör elemanları yorumda geçen sözcüklere karşı gelen indeksteki elemanlardır. Biz burada bu yöntemizi izleyeceğiz. Yorumların bu biçimde bool bir vektörle ifade edilmesi aynı zamanda sözcüklerin sıra numaralarının sıralı ölçüye ilişkinmiş gibi değerlendirilmesine de engel olacaktır. Yani bu işlem bir çeşit "binary encoding" dönüştürmesi anlamına da gelmektedir. Şimdi yukarıdaki DataFrame nesnesini bu biçimde dönüştürecek bir fonksiyon yazalım:

```
def vectorize(iterable, colsizes):
    result = np.zeros((len(iterable), colsizes), dtype=np.int8)
    for index, vals in enumerate(iterable):
        result[index, vals] = 1

    return result
```

Fonksiyon sözcüklerin indeks numaralarından oluşan dolaşılabilir nesneyi ve toplam sözcük sayısını parametre olarak alıp hedeflenen bool matrise geri dönmektedir. Fonksiyonun içerisinde önce içi 0'larla doldurulmuş hedef matris oluşturulmuş, sonra bunun ilgili elemanları 1 yapılmıştır. NumPy'da indeksleme işleminde birden fazla indeks değeri belirtilebildiğini biliyorsunuz. Şimdi yukarıdaki veri kümelerini bu biçimde bool bir matrise dönüştürelim:

```
dataset = df['review'].to_list()
dataset_x = vectorize(dataset, len(word_dict))
```

Buradan elde edilen dataset_x matrisinin toplam yorum sayısı kadar satıldan, toplam sözcük sayısı kadar sütundan oluştuğuna dikkat ediniz. Matrisin her elemanı 1 byte olduğuna göre bu matris çok büyük bir yer kaplamaktadır. Görünümü aşağıdaki gibidir:

```
In [62]: dataset_x
Out[62]:
array([[0, 0, 0, ..., 0, 0, 0],
       [0, 0, 0, ..., 0, 0, 0],
       [0, 0, 0, ..., 0, 0, 0],
       ...,
       [0, 0, 0, ..., 0, 0, 0],
       [0, 0, 0, ..., 0, 0, 0],
       [0, 0, 0, ..., 0, 0, 0]], dtype=int8)
```

```
In [63]: dataset_x.shape
Out[63]: (50000, 156840)
```

```
In [64]: np.sum(dataset_x[0])
Out[64]: 189
```

Yukarıdaki örnekte matrisin ilk satırında yalnızca 189 değerin 1, geri kalanlarının 0 olduğunu görüyorsunuz. Bu ilk yorumun 189 farklı sözcükten oluştuğu anlamına gelmektedir:

```
In [66]: len(np.unique(df.iloc[0, 0]))
Out[66]: 189
```

Artık eğitimin sonuçlarını da ayrı bir vektörde toplayabiliyoruz:

```
df.iloc[df.iloc[:, 1] == 'positive', 1] = 1
df.iloc[df.iloc[:, 1] == 'negative', 1] = 0
dataset_y = df.iloc[:, 1].to_numpy(dtype=np.int8)
```

Artık modelimizi kurabiliyoruz. Modelimiz ikş sınıfı bir lojistik regresyon modelidir. Biz daha önce "diabetes" örneğinde bu biçimde bir model üzerinde çalıştık. Modelimizi yine iki katmanlı olarak tasarlayacağız:

```
from tensorflow.keras import Sequential
from tensorflow.keras.layers import Dense
from sklearn.model_selection import train_test_split

training_dataset_x, test_dataset_x, training_dataset_y, test_dataset_y =
train_test_split(dataset_x, dataset_y,
test_size=0.20)

model = Sequential(name='IMDB')
model.add(Dense(100, input_dim=training_dataset_x.shape[1], activation='relu', name='Hidden-1'))
model.add(Dense(100, activation='relu', name='Hidden-2'))
model.add(Dense(1, activation='sigmoid', name='Output'))
model.compile(optimizer='adam', loss='binary_crossentropy', metrics=['binary_accuracy'])
hist = model.fit(training_dataset_x, training_dataset_y, batch_size=64, epochs=5,
validation_split=0.2)

import matplotlib.pyplot as plt

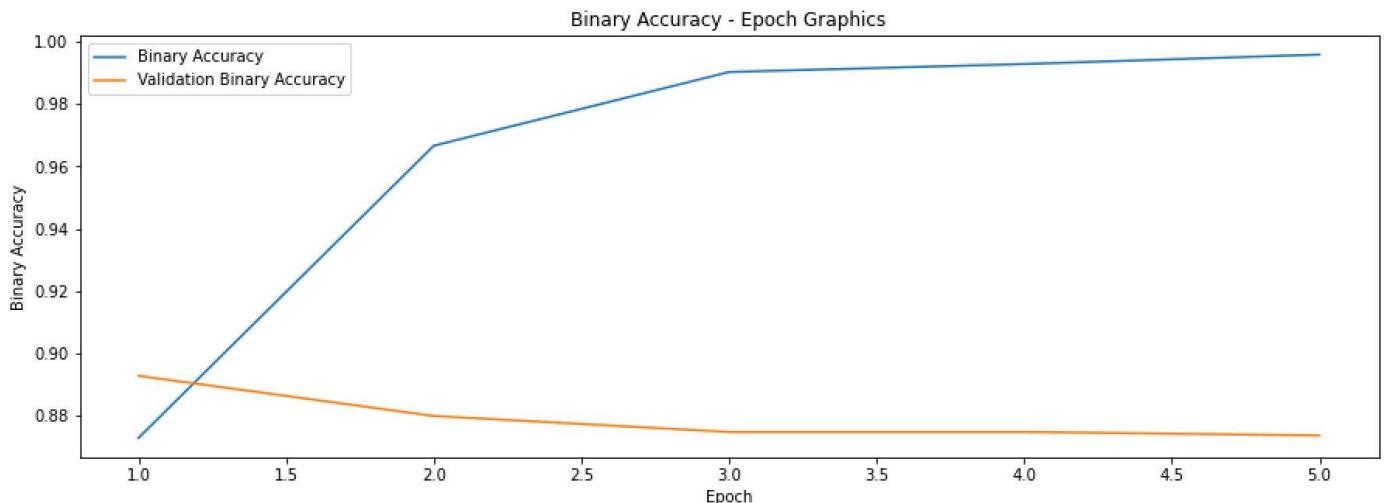
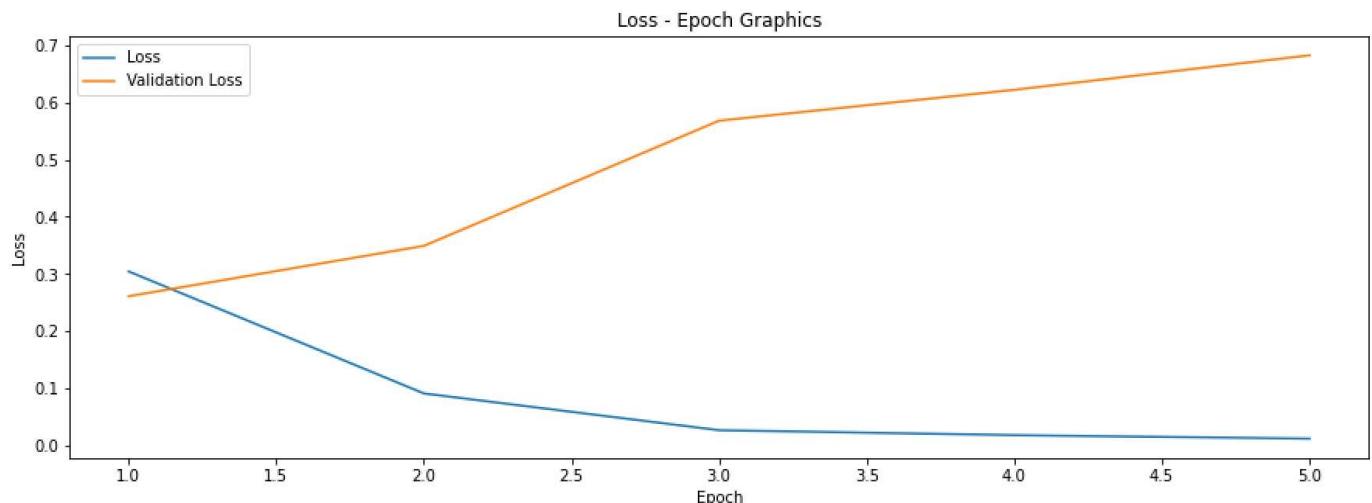
figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Loss - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.plot(range(1, len(hist.history['loss']) + 1), hist.history['loss'])
plt.plot(range(1, len(hist.history['val_loss']) + 1), hist.history['val_loss'])
plt.legend(['Loss', 'Validation Loss'])
plt.show()
```

```

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Binary Accuracy - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Binary Accuracy')
plt.plot(range(1, len(hist.history['binary_accuracy']) + 1), hist.history['binary_accuracy'])
plt.plot(range(1, len(hist.history['val_binary_accuracy']) + 1),
hist.history['val_binary_accuracy'])
plt.legend(['Binary Accuracy', 'Validation Binary Accuracy'])
plt.show()

```

Loss ve metrik grafikleri şöyle elde edilmiştir:



Burada birinci epoch'tan sonra overfit durumunun olduğunu görüyoruz. Bu durumda eğitim 1 epoch'ta kesilebilir. Burada eğitim veri kğmelerinin oldukça büyük olduğuna dikkatinizi çekmek istiyoruz:

In [69]: `training_dataset_x.shape`
Out[69]: `(40000, 156840)`

In [70]: `training_dataset_y.shape`
Out[70]: `(40000,)`

Şimdi de test işlemini yapalım:

```

eval_result = model.evaluate(test_dataset_x, test_dataset_y)
for i in range(len(eval_result)):
    print(f'{model.metrics_names[i]}: {eval_result[i]}')

```

Şöyledir bir çıktı elde edilmiştir:

```
loss: 0.6228826642036438
binary_accuracy: 0.883899986743927
```

%88.3 lük bir başarının elde edildiğini görüyorsunuz. Şimdi tüm kodu bir bütün olarak yeniden verelim. Ancak eğitimde 1 epoch kullanacağımız için metrik grafiklerini koddan çıkartıyoruz:

```
import numpy as np
import re

class WordConverter:
    def __init__(self):
        self.word_set = set()

    def __call__(self, text):
        words = re.findall("[a-zA-Z0-9'-]+", text.lower())
        self.word_set.update(words)

        return np.array(words)

    def get_word_dict(self):
        return {word: index for index, word in enumerate(wc.word_set)}

import pandas as pd

wc = WordConverter()
df = pd.read_csv('imdb.csv', converters={0: wc})
word_dict = wc.get_word_dict()

for i in range(len(df)):
    df.iloc[i, 0] = np.array([word_dict[word] for word in df.iloc[i, 0]])

def vectorize(iterable, colszie):
    result = np.zeros(len(iterable), colszie, dtype=np.int8)
    for index, vals in enumerate(iterable):
        result[index, vals] = 1

    return result

dataset = df['review'].to_list()
dataset_x = vectorize(dataset, len(word_dict))

df.iloc[df.iloc[:, 1] == 'positive', 1] = 1
df.iloc[df.iloc[:, 1] == 'negative', 1] = 0
dataset_y = df.iloc[:, 1].to_numpy(dtype=np.int8)

from tensorflow.keras import Sequential
from tensorflow.keras.layers import Dense
from sklearn.model_selection import train_test_split

training_dataset_x, test_dataset_x, training_dataset_y, test_dataset_y =
train_test_split(dataset_x, dataset_y,
test_size=0.20)

model = Sequential(name='IMDB')
model.add(Dense(100, input_dim=training_dataset_x.shape[1], activation='relu', name='Hidden-1'))
model.add(Dense(100, activation='relu', name='Hidden-2'))
model.add(Dense(1, activation='sigmoid', name='Output'))
model.compile(optimizer='adam', loss='binary_crossentropy', metrics=['binary_accuracy'])
hist = model.fit(training_dataset_x, training_dataset_y, batch_size=64, epochs=1,
```

```

validation_split=0.2)

eval_result = model.evaluate(test_dataset_x, test_dataset_y)
for i in range(len(eval_result)):
    print(f'{model.metrics_names[i]}: {eval_result[i]}')

```

Şimdi de kurulan model üzerinde kestirim yapalım. Kötü bir yorum oluşturalım:

```

predict_text = "A bad production. It's a bad movie."

```

Oluşturduğumuz bu yorumu ağımıza sokmadan önce eğitimde kullandığımız biçimde dönüştürmemiz gerekiyor. Yorum yazısını sözcüklerine ayırıp bool bir vektöre dönüştüren küçük bir fonksiyon yazabiliriz:

```

def prepare_review(predict_text):
    predict_words = re.findall("[a-zA-Z0-9'-]+", predict_text.lower())
    result = np.zeros(len(predict_words), dtype=np.int8)
    for i in range(len(predict_words)):
        result[i] = word_dict[predict_words[i]]

    return vectorize([result], len(word_dict))

```

Fonksiyonun global word_dict değişkenini kullandığına dikkat ediniz. Genel olarak fonksiyonların böyle global değişkenleri kullanması iyi bir teknik değildir. Ancak biz burada programın organizasyonundan ziyade modelin oluşturulması ve kullanılması üzerine odaklıyoruz. Şimdi kestirimimizi yapalım:

```

predict_data = prepare_review(predict_text)
predict_result = model.predict(predict_data)

if predict_result[0, 0] > 0.5:
    print(f'Olumlu Yorum: {predict_result[0, 0]}')
else:
    print(f'Olumsuz Yorum: {predict_result[0, 0]}')

```

Şöyledir bir çıktı elde edilmiştir:

```

Olumsuz Yorum: 0.41155344247817993

```

Şimdi birkaç değişik yorum için kestirimde bulunalım:

```

predict_texts = ["A nice film. But some parts are bad", "Neither a good nor a bad movie. Some parts are exaggerated.", "it's a nice film. I recommend you to watch the movie"]

for text in predict_texts:
    predict_data = prepare_review(text)
    predict_result = model.predict(predict_data)

    if predict_result[0, 0] > 0.5:
        print(f'Olumlu Yorum: {predict_result[0, 0]}')
    else:
        print(f'Olumsuz Yorum: {predict_result[0, 0]}')

```

Şöyledir bir sonuç elde edilmiştir:

```

Olumsuz Yorum: 0.15564844012260437
Olumsuz Yorum: 0.16812017560005188
Olumlu Yorum: 0.9306429624557495

```

Bu örnekte öğrenme sürecinde sözcüklerin hangi bağlamda kullanıldıklarının bir öneminin olmadığına dikkatinizi çekmek istiyoruz. Yani örneğin aslında yorumlardaki sözcüklerin yerleri değiştirilse de bunun eğitim üzerinde bir etkisi olmayacağıdır. Çünkü modelimizde sözcüklerin nerede olduğunu bir önemi yoktur. Yalnızca onların bir arada

aynı yazı içerisinde bulunuyor olmalarının önemi vardır. Tabii sözcüklerin bağımsal etkilerinin göz ardı edilmesi aslında öğrenme sürecini olumsuz etkileyebilecek bir süreç olarak değerlendirilebilir. İleride bağımsal etkinin nasıl oluşturulacağına yönelik modeller ele alınacaktır.

Aslında Keras'ta IMDB veri kümesi hazır bir biçimde tensorflow.keras.datasets paketi içerisindeki imdb modülünde bulunmaktadır. Veri kümesi modülün load_data fonksiyonu ile yüklenmektedir. load_data fonksiyonunun num_words isimli parametresi en çok kullanılan n tane sözcüğü yorumlarda bulunduracak biçimde veri kümelerini bize vermektedir. (Yani örneğin biz num_word değerini 10000 yaptığımızda tüm yorumların içerisindeki tüm farklı sözcüklerin sayısı 10000 tane olmaktadır.) Örneğin:

```
from tensorflow.keras.datasets import imdb

VOCAB_SIZE = 10000

(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) =
imdb.load_data(num_words=VOCAB_SIZE)
```

Burada training_dataset_x ve test_dataset_x birer ndarray nesnesidir. Ancak bu ndarray nesnesi list nesnelerinden oluşmaktadır. Örneğin:

```
In [4]: training_dataset_x
Out[4]:
array([list([1, 14, 22, 16, 43, 530, 973, 1622, 1385, 65, 458, 4468, 66, 3941, 4, 173, 36, 256, 5, 25,
100, 43, 838, 112, 50, 670, 2, 9, 35, 480, 284, 5, 150, 4, 172, 112, 167, 2, 336, 385, 39, 4, 172,
4536, 1111, 17, 546, 38, 13, 447, 4, 192, 50, 16, 6, 147, 2025, 19, 14, 22, 4, 1920, 4613, 469, 4, 22,
71, 87, 12, 16, 43, 530, 38, 76, 15, 13, 1247, 4, 22, 17, 515, 17, 12, 16, 626, 18, 2, 5, 62, 386, 12,
8, 316, 8, 106, 5, 4, 2223, 5244, 16, 480, 66, 3785, 33, 4, 130, 12, 16, 38, 619, 5, 25, 124, 51, 36,
135, 48, 25, 1415, 33, 6, 22, 12, 215, 28, 77, 52, 5, 14, 407, 16, 82, 2, 8, 4, 107, 117, 5952, 15,
256, 4, 2, 7, 3766, 5, 723, 36, 71, 43, 530, 476, 26, 400, 317, 46, 7, 4, 2, 1029, 13, 104, 88, 4,
381, 15, 297, 98, 32, 2071, 56, 26, 141, 6, 194, 7486, 18, 4, 226, 22, 21, 134, 476, 26, 480, 5, 144,
30, 5535, 18, 51, 36, 28, 224, 92, 25, 104, 4, 226, 65, 16, 38, 1334, 88, 12, 16, 283, 5, 16, 4472,
113, 103, 32, 15, 16, 5345, 19, 178, 32]),

      list([1, 194, 1153, 194, 8255, 78, 228, 5, 6, 1463, 4369, 5012, 134, 26, 4, 715, 8, 118, 1634,
14, 394, 20, 13, 119, 954, 189, 102, 5, 207, 110, 3103, 21, 14, 69, 188, 8, 30, 23, 7, 4, 249, 126,
93, 4, 114, 9, 2300, 1523, 5, 647, 4, 116, 9, 35, 8163, 4, 229, 9, 340, 1322, 4, 118, 9, 4, 130, 4901,
19, 4, 1002, 5, 89, 29, 952, 46, 37, 4, 455, 9, 45, 43, 38, 1543, 1905, 398, 4, 1649, 26, 6853, 5,
163, 11, 3215, 2, 4, 1153, 9, 194, 775, 7, 8255, 2, 349, 2637, 148, 605, 2, 8003, 15, 123, 125, 68, 2,
6853, 15, 349, 165, 4362, 98, 5, 4, 228, 9, 43, 2, 1157, 15, 299, 120, 5, 120, 174, 11, 220, 175, 136,
50, 9, 4373, 228, 8255, 5, 2, 656, 245, 2350, 5, 4, 9837, 131, 152, 491, 18, 2, 32, 7464, 1212, 14, 9,
6, 371, 78, 22, 625, 64, 1382, 9, 8, 168, 145, 23, 4, 1690, 15, 16, 4, 1355, 5, 28, 6, 52, 154, 462,
33, 89, 78, 285, 16, 145, 95]),

      list([1, 14, 47, 8, 30, 31, 7, 4, 249, 108, 7, 4, 5974, 54, 61, 369, 13, 71, 149, 14, 22, 112,
4, 2401, 311, 12, 16, 3711, 33, 75, 43, 1829, 296, 4, 86, 320, 35, 534, 19, 263, 4821, 1301, 4, 1873,
```

Modülün get_word_index isimli bir fonksiyonu bize sözcüklere karşı gelen indeks numaralarını bir sözlük olarak vermektedir:

```
word_dict = imdb.get_word_index()
```

get_word_index bize tüm yorumlarda kullanılan sözcük ve indeksleri vermektedir. Bu sözlük nesnesinde anahtarlar sözcüğün kendisi, değerler ise onların numaralarını belirtmektedir. Yani biz sözcüğü verdigimizde onun numarasını hızlı bir biçimde elde ederiz. Bunun tersini yine bir sözlük içlemi ile elde edebiliriz:

```
rev_word_dict = {index: word for word, index in word_dict.items()}
```

Keras imdb ve reuters gibi sözcük içeren veri kümelerindeki sözcük numaralarını hep 3 fazla almıştır. Yani örneğin bir yorumdaki 5 numaralı sözcük aslında $5 - 3 = 2$ numaralı sözcüktür. Yorumlardaki sözcükleri oluşturan sayıların ilk üçü (0, 1, 2) ayrılmıştır (rezerve edilmişdir). Bu durumda biz ilk yorumu şu biçimde sözcüklere dökebiliriz:

```
def print_review(review):
    text = ' '.join([rev_word_dict[index - 3] for index in review if index > 2])
    print(text)
```

Örneğin:

```
print_review(training_dataset_x[0])
```

Şöyledir:

this film was just brilliant casting location scenery story direction everyone's really suited the part they played and you could just imagine being there robert is an amazing actor and now the same being director father came from the same scottish island as myself so i loved the fact there was a real connection with this film the witty remarks throughout the film were great it was just brilliant so much that i bought the film as soon as it was released for and would recommend it to everyone to watch and the fly fishing was amazing really cried at the end it was so sad and you know what they say if you cry at a film it must have been good and this definitely was also to the two little boy's that played the of norman and paul they were just brilliant children are often left out of the list i think because the stars that play them all grown up are such a big profile for the whole film but these children are amazing and should be praised for what they have done don't you think the whole story was so lovely because it was true and was someone's life after all that was shared with us all

Yine önceki örnekteki gibi girdi katmanındaki nöronları sabit uzunluklu bool türden bir vektörle söyle ifade edebiliriz:

```
def vectorize(iterable, colsizes):
    result = np.zeros((len(iterable), colsizes), dtype=np.int8)
    for index, vals in enumerate(iterable):
        result[index, vals] = 1

    return result

training_dataset_x = vectorize(training_dataset_x, VOCAB_SIZE)
test_dataset_x = vectorize(test_dataset_x, VOCAB_SIZE)
```

Modelimizi de aynı biçimde oluşturabiliriz:

```
from tensorflow.keras import Sequential
from tensorflow.keras.layers import Dense

model = Sequential(name='IMDB')
model.add(Dense(100, input_dim=training_dataset_x.shape[1], activation='relu', name='Hidden-1'))
model.add(Dense(100, activation='relu', name='Hidden-2'))
model.add(Dense(1, activation='sigmoid', name='Output'))
model.compile(optimizer='adam', loss='binary_crossentropy', metrics=['binary_accuracy'])
hist = model.fit(training_dataset_x, training_dataset_y, batch_size=64, epochs=5,
validation_split=0.2)
```

Loss ve metrik grafiklerini de çizelim:

```
import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Loss - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.plot(range(1, len(hist.history['loss']) + 1), hist.history['loss'])
plt.plot(range(1, len(hist.history['val_loss']) + 1), hist.history['val_loss'])
plt.legend(['Loss', 'Validation Loss'])
plt.show()

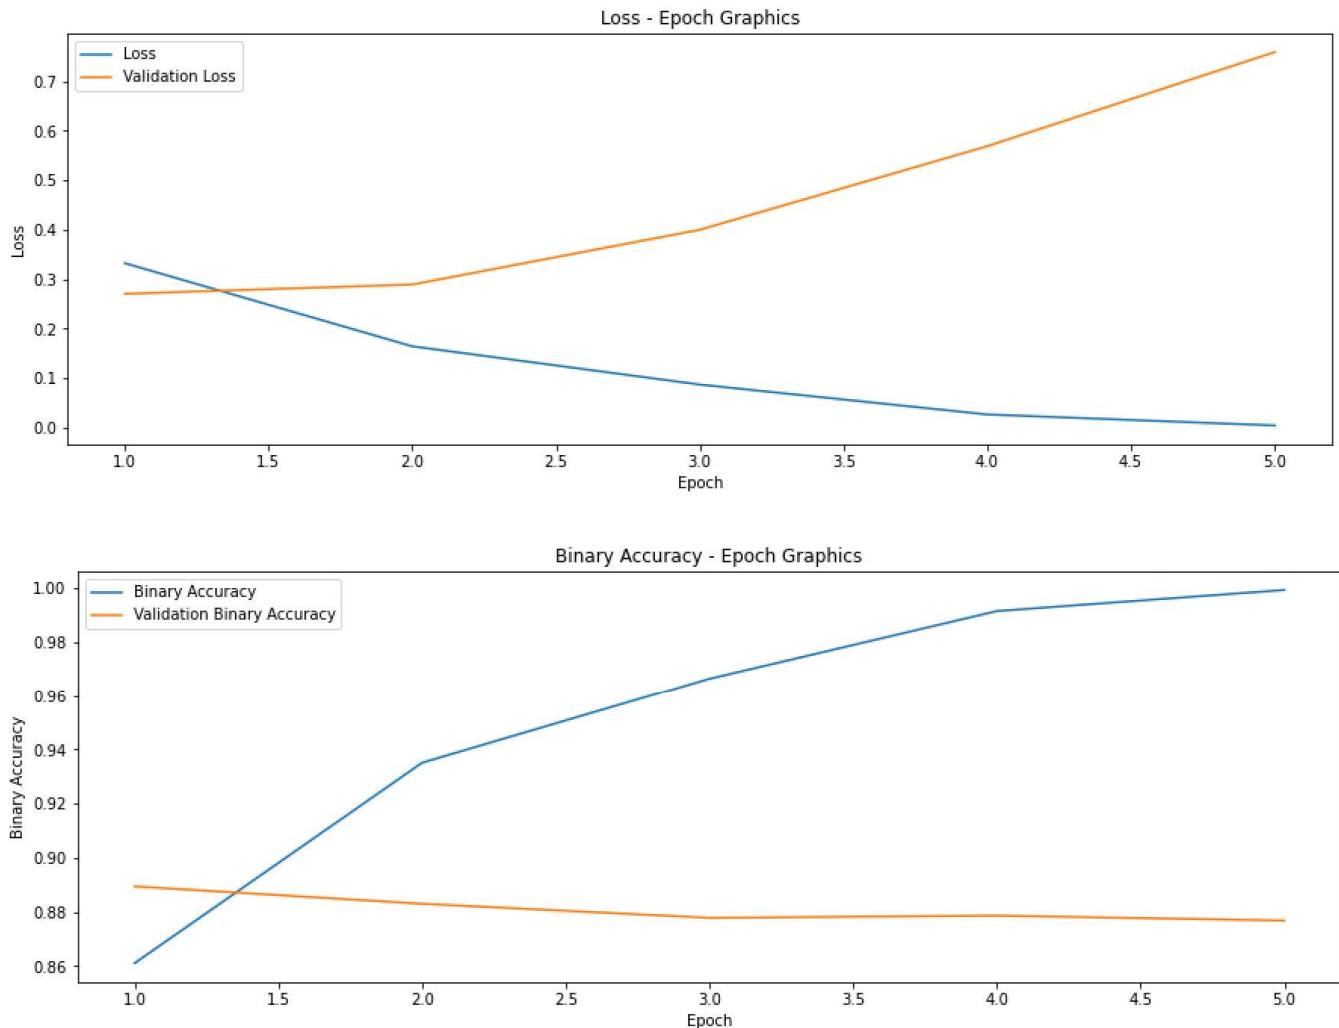
figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Binary Accuracy - Epoch Graphics')
plt.xlabel('Epoch')
```

```

plt.ylabel('Binary Accuracy')
plt.plot(range(1, len(hist.history['binary_accuracy']) + 1), hist.history['binary_accuracy'])
plt.plot(range(1, len(hist.history['val_binary_accuracy']) + 1),
hist.history['val_binary_accuracy'])
plt.legend(['Binary Accuracy', 'Validation Binary Accuracy'])
plt.show()

```

Aşağıdaki grafikler elde edilmiştir:



Burada yine 1 epoch'tan sonra overfit sorunu oluşmaya başlamıştır. Bu durumda eğitim 1 epoch'tan sonra sonlandırılabilir. Şimdi de modelimizi test edelim:

```

eval_result = model.evaluate(test_dataset_x, test_dataset_y)
for i in range(len(eval_result)):
    print(f'{model.metrics_names[i]}: {eval_result[i]}')

```

Şöyledir bir sonuç elde edilmiştir:

```

loss: 0.7935787439346313
binary_accuracy: 0.864359974861145

```

Bu sonuç modelin %86.4'lük bir başarısı olduğunu göstermektedir. Yine tüm kodu bir bütün olarak vermek istiyoruz. Eğitimde tek bir epoch kullanacağımız için metrik grafikleri koddan kaldırıyoruz:

```

import numpy as np
from tensorflow.keras.datasets import imdb

VOCAB_SIZE = 10000

```

```

(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) =
imdb.load_data(num_words=VOCAB_SIZE)

word_dict = imdb.get_word_index()
rev_word_dict = {index: word for word, index in word_dict.items()}

def vectorize(iterable, colsizes):
    result = np.zeros((len(iterable), colsizes), dtype=np.int8)
    for index, vals in enumerate(iterable):
        result[index, vals] = 1

    return result

training_dataset_x = vectorize(training_dataset_x, VOCAB_SIZE)
test_dataset_x = vectorize(test_dataset_x, VOCAB_SIZE)

from tensorflow.keras import Sequential
from tensorflow.keras.layers import Dense

model = Sequential(name='IMDB')
model.add(Dense(100, input_dim=training_dataset_x.shape[1], activation='relu', name='Hidden-1'))
model.add(Dense(100, activation='relu', name='Hidden-2'))
model.add(Dense(1, activation='sigmoid', name='Output'))
model.compile(optimizer='adam', loss='binary_crossentropy', metrics=['binary_accuracy'])
hist = model.fit(training_dataset_x, training_dataset_y, batch_size=64, epochs=1,
validation_split=0.2)

eval_result = model.evaluate(test_dataset_x, test_dataset_y)
for i in range(len(eval_result)):
    print(f'{model.metrics_names[i]}: {eval_result[i]}')

```

Şimdi de kurulan model üzerinde kestirim yapalım:

```

predict_texts = ["A nice film. But some parts are bad", "Neither a good nor a bad movie. Some
parts are exaggerated.", "it's a nice film. I recommend you to watch the movie"]

import re

def prepare_review(predict_text):
    predict_words = re.findall("[a-zA-Z0-9'-]+", predict_text.lower())
    result = np.zeros(len(predict_words), dtype=np.int8)
    for i in range(len(predict_words)):
        result[i] = word_dict[predict_words[i]] + 3

    return vectorize([result], VOCAB_SIZE)

for text in predict_texts:
    predict_data = prepare_review(text)
    predict_result = model.predict(predict_data)

    if predict_result[0, 0] > 0.5:
        print(f'Olumlu Yorum: {predict_result[0, 0]}')
    else:
        print(f'Olumsuz Yorum: {predict_result[0, 0]}'')

```

Şöyledir bir sonuç elde edilmişdir:

```

Olumsuz Yorum: 0.2089349627494812
Olumsuz Yorum: 0.14014840126037598
Olumlu Yorum: 0.7686631679534912

```

Tek Etiketli Çok Sınıflı Lojistik Regresyon Modeli İçin "Reuters" Örneği

Reuters bir yazı verildiğinde yazının konusunu 46 değişik konu arasından belirleyebilme çalışması için kullanılan popüler bir veri kümeleridir. Keras bu reuters veri kümelerini tensorflow.keras.datasets modülü içerisinde barındırmaktadır. Reuters verileri 11228 adet haber yazısını içermektedir. Bu haber yazıları 46 değişik kategoriye ayrılmıştır. Ancak maalesef Keras'ın resmi dokümanlarında bu 46 Reuters kategorisinin neler olduğu belirtilmemiştir. Bu 46 kategori başka kaynaklarda şöyle listelenmiştir:

```
category_list = ['cocoa', 'grain', 'veg-oil', 'earn', 'acq', 'wheat', 'copper', 'housing', 'money-supply', 'coffee', 'sugar', 'trade', 'reserves', 'ship', 'cotton', 'carcass', 'crude', 'nat-gas', 'cpi', 'money-fx', 'interest', 'gnp', 'meal-feed', 'alum', 'oilseed', 'gold', 'tin', 'strategic-metal', 'livestock', 'retail', 'ipi', 'iron-steel', 'rubber', 'heat', 'jobs', 'lei', 'bop', 'zinc', 'orange', 'pet-chem', 'dlr', 'gas', 'silver', 'wpi', 'hog', 'lead']
```

Aslında Keras'ın reuters verileri tamamen IMDB verileri gibi organize edilmiştir. Yani yazılar yine sözcük indeksleri ile ifade edilmiş durumdadır. Bu nedenle Reuters verilerini kullanma hazır hale getirirken IMDB örneğindekine benzer işlemleri yapacağız:

```
import numpy as np
from tensorflow.keras.datasets import reuters

VOCAB_SIZE = 10000

(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) = reuters.load_data(num_words=VOCAB_SIZE)

category_list = ['cocoa', 'grain', 'veg-oil', 'earn', 'acq', 'wheat', 'copper', 'housing', 'money-supply', 'coffee', 'sugar', 'trade', 'reserves', 'ship', 'cotton', 'carcass', 'crude', 'nat-gas', 'cpi', 'money-fx', 'interest', 'gnp', 'meal-feed', 'alum', 'oilseed', 'gold', 'tin', 'strategic-metal', 'livestock', 'retail', 'ipi', 'iron-steel', 'rubber', 'heat', 'jobs', 'lei', 'bop', 'zinc', 'orange', 'pet-chem', 'dlr', 'gas', 'silver', 'wpi', 'hog', 'lead']

word_dict = reuters.get_word_index()
rev_word_dict = {value: key for key, value in word_dict.items()}
```

Yorum yazısını ekrana yazdırın fonksiyonu da şöyle yazabiliriz:

```
def print_review(review):
    for index in review:
        if index > 2:
            print(rev_word_dict[index - 3], end=' ')
```



```
print_review(training_dataset_x[0])
```

IMDB örneğinde yaptığımız gibi yine veri kümelerini bool vektöre dönüştürebiliriz:

```
def vectorize(iterable, colsizes):
    result = np.zeros(len(iterable), colsizes), dtype=np.int8)
    for index, vals in enumerate(iterable):
        result[index, vals] = 1

    return result
```



```
training_dataset_x = vectorize(training_dataset_x, VOCAB_SIZE)
test_dataset_x = vectorize(test_dataset_x, VOCAB_SIZE)
```

Burada çıktıının da aslında 46 değerli kategorik bir özellik olduğuna dikkat ediniz. Biz şimdije kadar hep girdi kümesi üzerinde one hot encoding uygulamıştık. Ancak çıktı kümesi de iki sınıfından fazlaysa çıktı kümesi üzerinde de one hot encoding uygulamamız gereklidir. Yukarıda yazdığımız vectorize fonksiyonu aslında one hot encoding işlemini de yapabilmektedir.

```
training_dataset_y = vectorize(training_dataset_y, 46)
test_dataset_y = vectorize(test_dataset_y, 46)
```

Artık ağı modelimizi oluşturabiliriz. Ağıımızda yine iki saklı katman bulunabilir. Ancak çıktı sınıflarının sayısı fazlalaştıkça katmanlardaki nöron sayılarının artırılması doğru olacaktır. Benzer biçimde kategori sayısı arttıkça ağı derinleştirmek de sonucun kalitesini artırabilmektedir. Ağıımızdaki saklı katmanların aktivasyon fonksiyonlarını yine "relu" biçiminde alacağız. İkiden fazla sınıf içeren lojistik regresyon modellerinde çıktı katmanındaki aktivasyon fonksiyonunun "softmax" alınması gereğini belirtmiştık. (Anımsanacağı gibi çıktı katmanın aktivasyon fonksiyonun "softmax" olması tüm çıktı nöronlarının toplam değerlerinin 1 olmasını sağlamaktadır.) Böylece biz bu değerlerin en büyüğünü temel alarak sonucu kestirebileceğiz. Model için loss fonksiyonu "categorical_crossentropy" olarak, optimizasyon algoritmasını da yine "rmsprop" olarak alacağız ve metrik değerler için de yine "categorical_accuracy" kullanacağız.

Şimdi modelimizi oluşturalım:

```
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense

model = Sequential(name='Reuters')
model.add(Dense(100, input_dim=VOCAB_SIZE, activation='relu', name='Hidden-1'))
model.add(Dense(100, activation='relu', name='Hidden-2'))
model.add(Dense(46, activation='softmax', name='Output'))

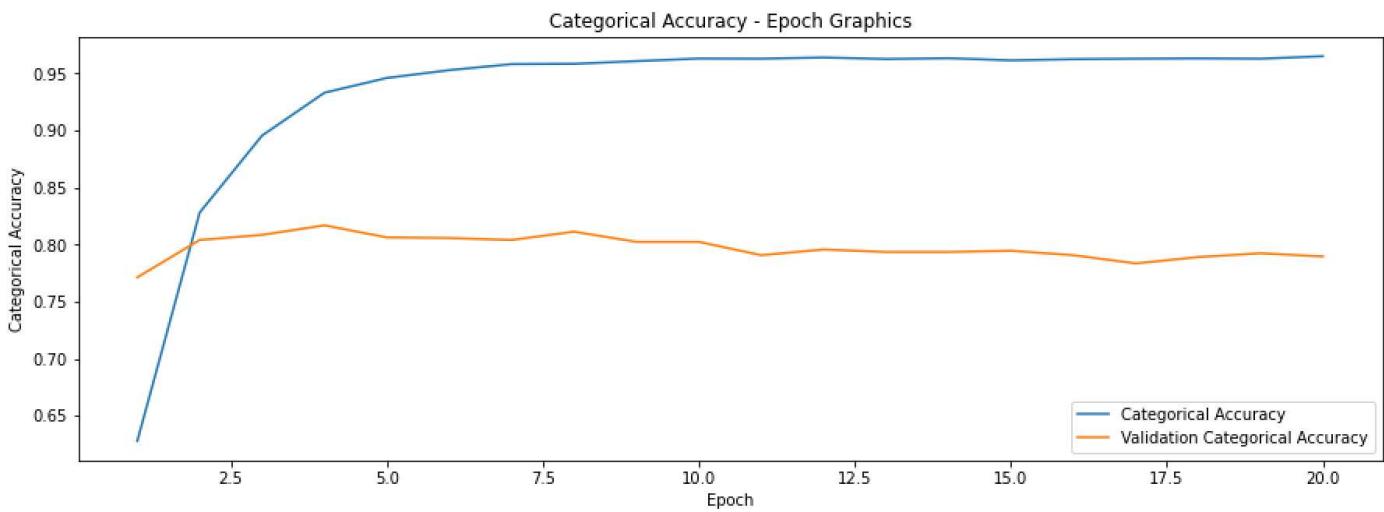
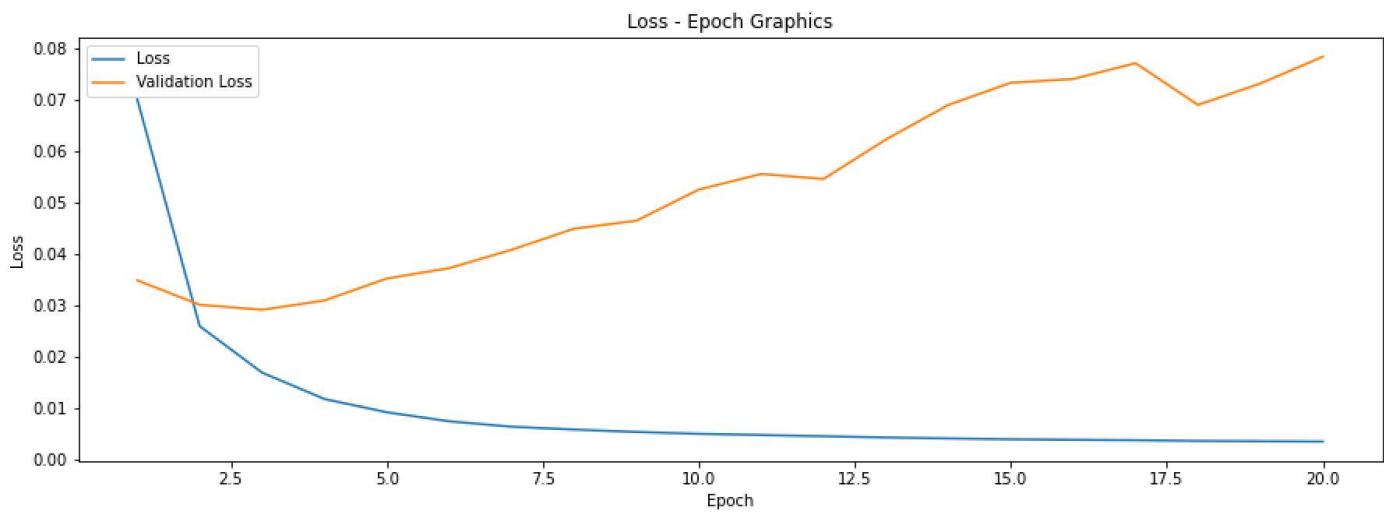
model.compile('rmsprop', loss='categorical_crossentropy', metrics=[ 'categorical_accuracy'])
hist = model.fit(training_dataset_x, training_dataset_y, epochs=20, batch_size=32,
validation_split=0.2)
```

Grafiklerimizi çizelim:

```
import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Loss - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.plot(range(1, len(hist.history['loss']) + 1), hist.history['loss'])
plt.plot(range(1, len(hist.history['val_loss']) + 1), hist.history['val_loss'])
plt.legend(['Loss', 'Validation Loss'])
plt.show()

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Categorical Accuracy - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Categorical Accuracy')
plt.plot(range(1, len(hist.history['categorical_accuracy']) + 1),
hist.history['categorical_accuracy'])
plt.plot(range(1, len(hist.history['val_categorical_accuracy']) + 1),
hist.history['val_categorical_accuracy'])
plt.legend(['Categorical Accuracy', 'Validation Categorical Accuracy'])
plt.show()
```



Burada 2'inci epoch'tan sonra overfit durumu gözlemlenmektedir. Bu epoch kaynaklı overfit nedeniyle epoch sayısı 2 ile sınırlı tutulabilir. Modelimizi test edelim:

```
eval_result = model.evaluate(test_dataset_x, test_dataset_y)
for i in range(len(eval_result)):
    print(f'{model.metrics_names[i]}: {eval_result[i]}'')
```

Şöyledir bir sonuç elde edilmiş:

```
loss: 0.08465898036956787
categorical_accuracy: 0.7822796106338501
```

Şimdi modeli 2 epoch ile eğitip de kestirim işlemini yapalım:

```
text = '''said as a result of its december acquisition of space co it expects earnings per
share in 1987 of 1 15 to 1 30 dlrs per share up from 70 cts in 1986 the company said pretax net
should rise to nine to 10 mln dlrs from six mln dlrs in 1986 and rental operation revenues to
19 to 22 mln dlrs from 12 5 mln dlrs it said cash flow per share this year should be 2 50 to
three dlrs reuter 3'''

import re

def prepare_review(predict_text):
    predict_words = re.findall("[a-zA-Z'-]+", predict_text.lower())
    result = np.zeros(len(predict_words), dtype=np.int8)
    for i in range(len(predict_words)):
        result[i] = word_dict[predict_words[i]] + 3
```

```

    return vectorize([result], VOCAB_SIZE)

predict_data = prepare_review(text)
predict_result = model.predict(predict_data)

category = np.argmax(predict_result)
print('category = {}, category name = {}'.format(category, category_list[category]))

```

Kestirim işleminin sonucunda şu çıktı elde edilmiştir:

```
category = 3, category name = earn
```

Burada biz predict işlemi sonucunda biz 46 elemanlı bir ndarray nesnesi elde etmiş olduk. Bu nesnedeki tüm değerlerin toplamı softmax fonksiyonu nedeniyle 1 olacaktır. Biz de hangi kategorinin seçildiğini en yüksek değere bakarak belirleyebiliriz. NumPy'nin argmax fonksiyonunun bir ndarray içerisindeki değerlerin en büyüğünün indeksini verdiğini anımsayınız.

Aşağıda örneğin tüm kodlarını yeniden veriyoruz:

```

import numpy as np
from tensorflow.keras.datasets import reuters

VOCAB_SIZE = 10000

(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) =
reuters.load_data(num_words=VOCAB_SIZE)

category_list = ['cocoa', 'grain', 'veg-oil', 'earn', 'acq', 'wheat', 'copper', 'housing',
'money-supply', 'coffee', 'sugar', 'trade', 'reserves', 'ship', 'cotton', 'carcass', 'crude',
'nat-gas', 'cpi', 'money-fx', 'interest', 'gnp', 'meal-feed', 'alum', 'oilseed', 'gold', 'tin',
'strategic-metal', 'livestock', 'retail', 'ipi', 'iron-teel', 'rubber', 'heat', 'jobs', 'lei',
'bop', 'zinc', 'orange', 'pet-chem', 'dlr', 'gas', 'silver', 'wpi', 'hog', 'lead']

word_dict = reuters.get_word_index()
rev_word_dict = {value: key for key, value in word_dict.items()}

def vectorize(iterable, colsizes):
    result = np.zeros((len(iterable), colsizes), dtype=np.int8)
    for index, vals in enumerate(iterable):
        result[index, vals] = 1

    return result

training_dataset_x = vectorize(training_dataset_x, VOCAB_SIZE)
test_dataset_x = vectorize(test_dataset_x, VOCAB_SIZE)

training_dataset_y = vectorize(training_dataset_y, 46)
test_dataset_y = vectorize(test_dataset_y, 46)

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense

model = Sequential(name='Reuters')
model.add(Dense(100, input_dim=VOCAB_SIZE, activation='relu', name='Hidden-1'))
model.add(Dense(100, activation='relu', name='Hidden-2'))
model.add(Dense(46, activation='softmax', name='Output'))

model.compile('rmsprop', loss='categorical_crossentropy', metrics=['categorical_accuracy'])
hist = model.fit(training_dataset_x, training_dataset_y, epochs=2, batch_size=32,
validation_split=0.2)

```

```

import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Loss - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.plot(range(1, len(hist.history['loss']) + 1), hist.history['loss'])
plt.plot(range(1, len(hist.history['val_loss']) + 1), hist.history['val_loss'])
plt.legend(['Loss', 'Validation Loss'])
plt.show()

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Categorical Accuracy - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Categorical Accuracy')
plt.plot(range(1, len(hist.history['categorical_accuracy']) + 1),
hist.history['categorical_accuracy'])
plt.plot(range(1, len(hist.history['val_categorical_accuracy']) + 1),
hist.history['val_categorical_accuracy'])
plt.legend(['Categorical Accuracy', 'Validation Categorical Accuracy'])
plt.show()

eval_result = model.evaluate(test_dataset_x, test_dataset_y)
for i in range(len(eval_result)):
    print(f'{model.metrics_names[i]}: {eval_result[i]}')


text = '''said as a result of its december acquisition of space co it expects earnings per
share in 1987 of 1 15 to 1 30 dlr per share up from 70 cts in 1986 the company said pretax net
should rise to nine to 10 mln dlr from six mln dlr in 1986 and rental operation revenues to
19 to 22 mln dlr from 12 5 mln dlr it said cash flow per share this year should be 2 50 to
three dlr reuter 3'''


import re

predict_words = re.findall("[a-zA-Z'-]+", text)

def prepare_review(predict_text):
    predict_words = re.findall('\w+', predict_text.lower())
    result = np.zeros(len(predict_words), dtype=np.int8)
    for i in range(len(predict_words)):
        result[i] = word_dict[predict_words[i]] + 3

    return vectorize([result], VOCAB_SIZE)

predict_data = prepare_review(text)
predict_result = model.predict(predict_data)

category = np.argmax(predict_result)
print('category = {}, category name = {}'.format(category, category_list[category]))

```

Keras Modelinin Parçalı Verilerle Eğitilmesi ve Test Edilmesi

Yapay sinir ağı modellerinde yüksek miktarda verilerle eğitimlerin yapılması gerekmektedir. Bu tür durumlarda verilerin hepsinin önce bellekte oluşturulması sonra eğitim işleminde kullanılması kapasite sorunlarına yol açabilmektedir. Örneğin biz yukarıdaki örneklerin hepsinde önce training_dataset_ ve training_dataset_y verilerini hazırlayıp fit metoduna verdik. Peki de eğitimde kullanılacak bu x ve y verileri belleğe sığmayacak ölçüde büyükse ne olacaktır? Şüphesiz çözümlerden biri bilgisayarınızı değiştirmek ya da bulut sistemlerinden faydalanan mak olabilir. Ancak bu tür yöntemler genellikle ölçeklenebilir (scalable) bir çözüm oluşturamazlar.

Yukarıda vermiş olduğumuz ilk IMDB örneğine bakalım. O örnekte eğitime sokulacak training_dataset_x dizisi 40000x156840 elemanlı, training_dataset_y dizisi ise 40000x1 elemanlı idi. Bu dizilerin her bir elemanı 1 byte yer kapladığına göre kabaca bu dizilerin bellekte kapladığı toplam alan 6 GB civarında olacaktır. Ayrıca IMDB ve Reuters örneklerindeki training_dataset_x matrislerinin aslında çok büyük oranda 0'lardan oluştuğuna da dikkat ediniz. Büyük bölümü 0'lardan oluşan matrlisler veri yapıları dünyasında "seyrek matrisler (sparse matrixes)" denilmektedir.

İşte Keras'ta çok büyük miktarda verilerle eğitimler yapılırken eğitim verileri tek parçada değil de batch işlemleri sırasında parça parça da oluşturulabilmektedir. Eğitim verilerinin parçalar halinde oluşturulması "üretici fonksiyonlar (generators)" yoluya ya da "Sequence" nesneleri yoluyla yapılmaktadır. Eskiden bu biçimde eğitim için model sınıflarının fit_generator isimli metodları kullanılıyordu. Ancak Keras'in yeni versiyonlarında fit_generator metodu "deprecated" hale getirilmiştir ve parçalı eğitim işlemlerinin de yine fit metoduyla yapılması sağlanmıştır.

Eğer fit metodunun birinci parametresinde training_dataset_x verileri yerine bir üretici fonksiyon nesni girilirse eğitim sırasında her batch işlemi için üretici fonksiyondan next fonksiyonu ile bir demet biçiminde x ve y değerleri elde edilip batch işlemi bu değerlerle yürütülmektedir. Bu durumda bir epoch işleminin kaç batch işleminden olusacağı fit metodunun steps_per_epoch parametresiyle ayarlanmaktadır. Aşağıda rastgele veriler kullanılarak bu mekanizmayla eğitimin yapıldığı bir örnek görüyorsunuz:

```
import numpy as np
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense

def data_generator():
    while True:
        training_dataset_x = np.random.rand(32, 10)
        training_dataset_y = np.random.randint(0, 2, 32)

        yield training_dataset_x, training_dataset_y

model = Sequential()
model.add(Dense(100, input_dim=10, activation='relu', name='Hidden-1'))
model.add(Dense(100, activation='relu', name='Hidden-2'))
model.add(Dense(1, activation='softmax', name='Output'))

model.compile('rmsprop', loss='binary_crossentropy', metrics=['binary_accuracy'])
hist = model.fit(data_generator(), epochs=1, steps_per_epoch=10)
```

Bu örnekte fit metoduna üretici fonksiyon parametre olarak geçirilmiştir. fit metodu da her bir batch işleminde üretici fonksiyonu next fonksiyonuyla bir kez çalıştırıp yield deyi̇miyle verilen x ve y verisini eğitimde kullanacaktır. Örneğimizde steps_per_epoch parametresi 10 olarak geçilmiştir. Bu 10 değeri 1 epoch işleminin 10 batch işleminden olusacağını belirtmektedir. Parçalı eğitim sırasında fit metodunun batch_size parametresinin fonksiyon tarafından dikkate alınmadığını da belirtmek istiyoruz. Yukarıdaki üretici fonksiyonun sonsuz döngü içerisinde olduğu dikkatinizi çekmiştir. Üretici fonksiyonun işletilmesi next işlemi ile yapıldığından bu durum bir soruna yol açmayacaktır. Normal olarak üretici fonksiyon içerisinde en azından epochs * steps_for_epoch kadar yield işleminin yapılması gerektigine dikkat ediniz.

Eğitim sırasında her epoch'tan sonra sınama işlemeye sokulacak sınama verileri de fit metodunun validation_data parametresiyle her epoch için parçalı biçimde oluşturulabilmektedir. Eğer validation_data parametresi bir üretici fonksiyon biçiminde girilirse her epoch işleminin sonunda next fonksiyonu yoluyla bu üretici fonksiyonda yield deyi̇mi ile elde edilen değerler sınama verisi olarak kullanılacaktır. fit metodunun validation_steps parametresi bir epoch için toplamda kaç kere next işlemi ile veri toplanacağını belirtir. Bu parametrenin default değerinin None olduğunu dikkat ediniz. Bu durumda veri toplama işlemi üretici fonksiyon bitene kadar yapılır ki bu da yalnızca 1 epoch için anlamlı olabilir. Örneğin:

```
import numpy as np
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense
```

```

def data_generator():
    for i in range(10):
        training_dataset_x = np.random.rand(32, 10)
        training_dataset_y = np.random.randint(0, 2, 32)

        yield training_dataset_x, training_dataset_y

def validation_generator():
    for i in range(10):
        validation_dataset_x = np.random.rand(32, 10)
        validation_dataset_y = np.random.randint(0, 2, 32)

        yield validation_dataset_x, validation_dataset_y

model = Sequential()
model.add(Dense(100, input_dim=10, activation='relu', name='Hidden-1'))
model.add(Dense(100, activation='relu', name='Hidden-2'))
model.add(Dense(1, activation='softmax', name='Output'))

model.compile('rmsprop', loss='binary_crossentropy', metrics=['binary_accuracy'])
hist = model.fit(data_generator(), epochs=1, steps_per_epoch=10,
validation_data=validation_generator(), validation_steps=10)

```

Burada validation_generator isimli üretici fonksiyon içerisinde rastgele değerlerle 10 ayrı yield işlemi yapılmıştır. Bu yield işlemlerinin sonunda elde edilen toplam veri sınaması verisi olarak kullanılacaktır. Modelin test edilmesi sırasında evaluate metodunda da aynı biçimde veriler parçalı olarak üretici fonksiyonlar yoluyla girilebilmektedir.

Şimdi "imdb.csv" örneği üzerinde üretici fonksiyon yoluyla verilerin elde edilmesine ilişkin bir örnek verelim. Örneğimizde "imdb.csv" dosyası tek hamlede pandas.read_csv fonksiyonu ile DataFrame nesnesi olarak okuyacağız. Sonra bu DataFrame nesnesi üzerindeki verileri eğitim, sınaması ve test sırasında üretici fonksiyon yardımıyla elde edeceğiz:

```

import numpy as np
import pandas as pd
import re

BATCH_SIZE = 64
EPOCHS = 5

class WordConverter:
    def __init__(self):
        self.word_set = set()

    def __call__(self, review):
        words = re.findall("[a-zA-Z0-9']+", review.lower())
        self.word_set.update(words)

        return np.array(words)

    def get_word_dict(self):
        return {word: index for index, word in enumerate(self.word_set)}

wc = WordConverter()
df = pd.read_csv('imdb.csv', converters={0: wc})
word_dict = wc.get_word_dict()
rev_word_dict = {index: word for word, index in word_dict.items()}

for i in range(len(df)):
    df.iloc[i, 0] = np.array([word_dict[word] for word in df.iloc[i, 0]])

"""
text = ' '.join([rev_word_dict[index] for index in df.iloc[0, 0]])

```

```

print(text)
"""

test_zone = int(len(df) * 0.8)
validation_zone = int(test_zone * 0.8)

df_training_dataset = df.iloc[:validation_zone]
df_validation_dataset = df.iloc[validation_zone:test_zone]
df_test_dataset = df.iloc[test_zone:]

df.iloc[df.iloc[:, 1] == 'positive', 1] = 1
df.iloc[df.iloc[:, 1] == 'negative', 1] = 0

def vectorize(iterable, colszie):
    result = np.zeros((len(iterable), colszie), dtype=np.int8)
    for index, values in enumerate(iterable):
        result[index, values] = 1

    return result

def data_generator(df, epochs, batch_size):
    for _ in range(epochs):
        for i in range(0, len(df) // batch_size):
            start = i * batch_size
            stop = (i + 1) * batch_size
            dataset_x = vectorize(df.iloc[start:stop, 0], len(word_dict))
            dataset_y = df.iloc[start:stop, 1].to_numpy(dtype=np.int8)

            yield dataset_x, dataset_y

training_spe = len(df_training_dataset) // BATCH_SIZE
validation_spe = len(df_validation_dataset) // BATCH_SIZE
test_spe = len(df_test_dataset) // BATCH_SIZE

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense

model = Sequential(name='IMDB')
model.add(Dense(100, activation='relu', input_dim=len(word_dict), name='Hidden-1'))
model.add(Dense(100, activation='relu', name='Hidden-2'))
model.add(Dense(1, activation='sigmoid', name='Output'))
model.compile(optimizer='rmsprop', loss='binary_crossentropy', metrics=['binary_accuracy'])
hist = model.fit(data_generator(df_training_dataset, EPOCHS, BATCH_SIZE), epochs=EPOCHS,
steps_per_epoch=training_spe,
validation_data=data_generator(df_validation_dataset, EPOCHS, BATCH_SIZE),
validation_steps=validation_spe)

import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Loss - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.plot(range(1, len(hist.history['loss']) + 1), hist.history['loss'])
plt.plot(range(1, len(hist.history['val_loss']) + 1), hist.history['val_loss'])
plt.legend(['Loss', 'Validation Loss'])
plt.show()

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Binary Accuracy - Epoch Graphics')
plt.xlabel('Epoch')

```

```

plt.ylabel('Binary Accuracy')
plt.plot(range(1, len(hist.history['binary_accuracy']) + 1), hist.history['binary_accuracy'])
plt.plot(range(1, len(hist.history['val_binary_accuracy']) + 1),
hist.history['val_binary_accuracy']))
plt.legend(['Binary Accuracy', 'Validation Binary Accuracy'])
plt.show()

eval_result = model.evaluate(data_generator(df_test_dataset, 1, BATCH_SIZE))
for i in range(len(eval_result)):
    print(f'{model.metrics_names[i]} --> {eval_result[i]}')

predict_text = 'the movie was not good. There are many flaws. Players are act badly'
predict_words = re.findall("[a-zA-Z0-9]+", predict_text.lower())
predict_numbers = [word_dict[pw] for pw in predict_words]
predict_data = vectorize([predict_numbers], len(word_dict))
predict_result = model.predict(predict_data)

if predict_result[0][0] > 0.5:
    print('OLUMLU')
else:
    print('OLUMSUZ')

```

Burada dosyadan elde edilen DataFrame nesnesi önce %80'i eğitim %20'si test olmak üzere iki parçaya ayrılmıştır. Sonra da eğitim veri kümelerinin de %20'si sınıma amacıyla ayırtılmıştır. Böylece df_training_datset, df_validation_dataset ve df_test_dataset olmak üzere üç ayrı DataFrame nesnesi elde edilmiştir. data_generator isimli üretici fonksiyon DataFrame nesnesini (df) ve oluşturulacak parçaların büyüklüğünü (batch_size) parametre olarak alıp her defasında yield deyimi ile parça büyülüğu kadar veriyi oluşturup dışarıya vermektedir. Örneğimizdeki fit metodunun kullanımına dikkat ediniz:

```

hist = model.fit(data_generator(df_training_dataset, EPOCHS, BATCH_SIZE), epochs=EPOCHS,
steps_per_epoch=training_spe,
validation_data=data_generator(df_validation_dataset, EPOCHS, BATCH_SIZE),
validation_steps=validation_spe)

```

Burada biz eğitim için ve sınıma için üretici fonksiyonlardan faydalandık. Üretici fonksiyonun yield deyimi eğitim sırasında her epoch için steps_per_epoch kadar çağrılabilecek ve yield deyiminden elde edilen değerler de batch işleminde kullanılacaktır. Yukarıda belirttiğimiz gibi sınıma verileri her epoch için epoch sonunda toplanmaktadır. Örneğimizde sınıma verilerinin her epoch için 64'erli bir biçimde oluşturulduğuna dikkat ediniz. data_generator üretici fonksiyonunun nasıl yazıldığına dikkat ediniz:

```

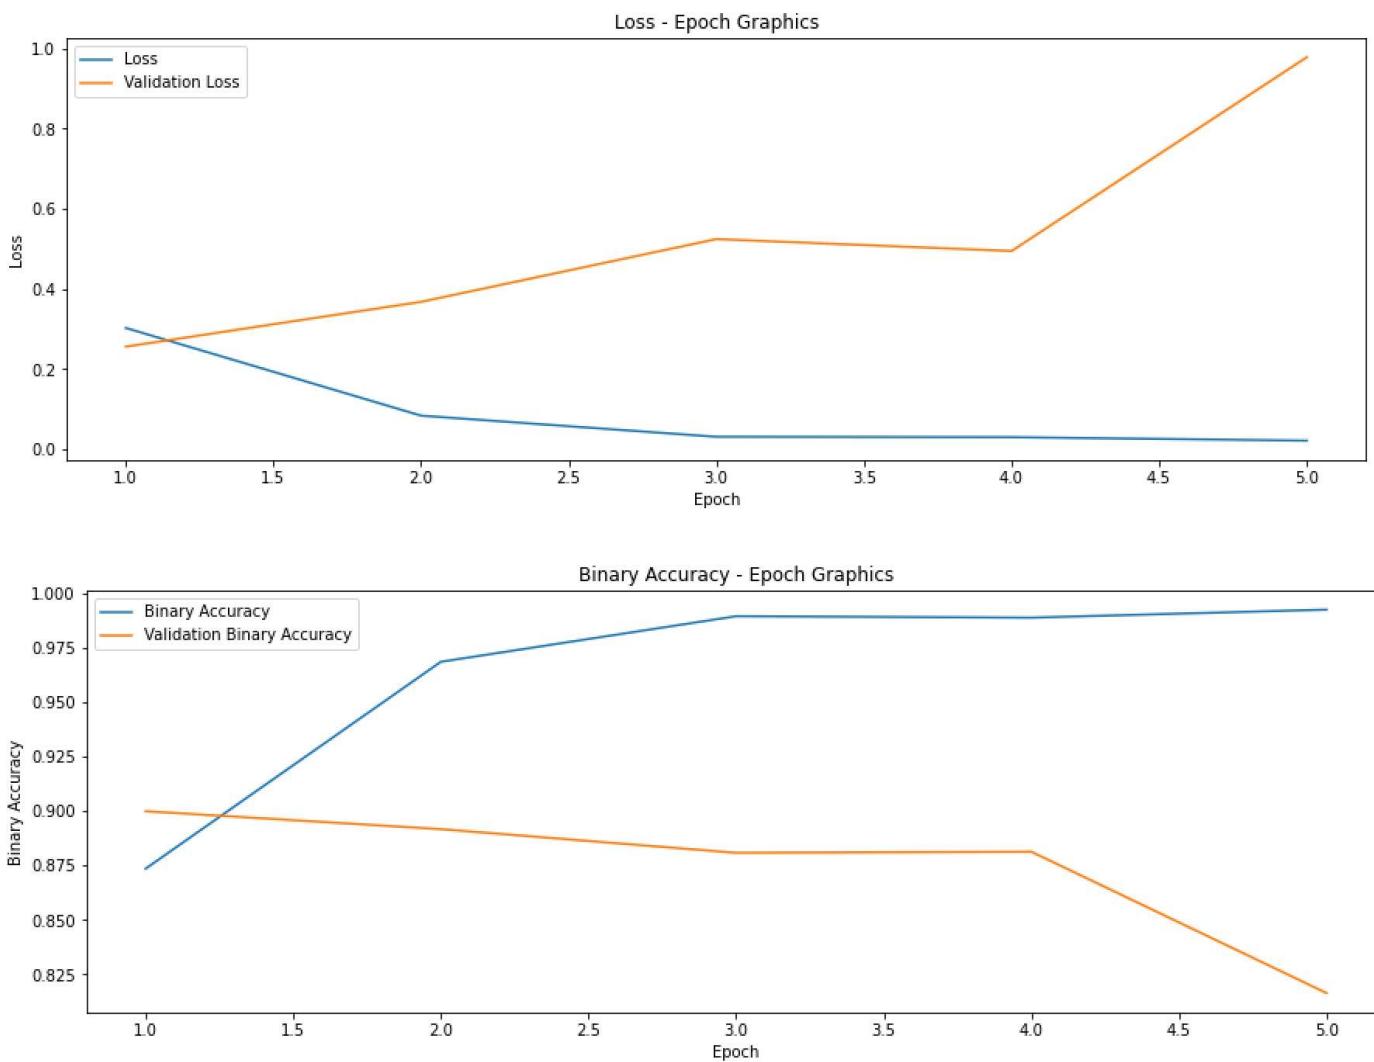
def data_generator(df, epochs, batch_size):
    for _ in range(epochs):
        for i in range(0, len(df) // batch_size):
            start = i * batch_size
            stop = (i + 1) * batch_size
            dataset_x = vectorize(df.iloc[start:stop, 0], len(word_dict))
            dataset_y = df.iloc[start:stop, 1].to_numpy(dtype=np.int8)

            yield dataset_x, dataset_y

```

Fonksiyonun birinci parametresi (df) DataFrame nesnesini ikinci parametresi (epochs) toplam epoch sayısını, üçüncü parametresi (batch_size) ise her batch işlemi için geri döndürülecek veri kümelerinin uzunluğunu (başka bir deyişle her batch işleminin ne kadar veri üzerinde gerçekleştirileceğini) belirtmektedir. Fonksiyon içerisinde iç içe döngülerle gereken sayıda yield işlemi uygulanmıştır. Burada bool vektörün bütünsel olarak oluşturulmadığına her batch işlem sırasında o anda oluşturulduğuna dikkat ediniz.

Yukarıdaki koddan elde edilen sonuçlar şunlardır:



Yine burada uygun epoch sayısının 1 olduğuna dikkat ediniz. Test işleminden şu sonuç elde edilmiştir:

```
loss: 0.9493581056594849
binary_accuracy: 0.8200120329856873
```

Keras'ta parçalı işlemle sınıflar yoluyla da yapılabilmektedir. Bunun için tensorflow.keras.utils.Sequence sınıfından bir sınıf türetilecek sınıf için `__getitem__` ve `__len__` metotları yazılır. `__len__` metodu bir epoch'un kaç batch işleminden oluşacağını belirlemek amacıyla kullanılmaktadır. Bir epoch `__len__` metodundan döndürülen sayıda batch işleminden oluşturulmaktadır. `__getitem__` metodu ise her batch işleminde fit metodu tarafından çağrılr. `__getitem__` metodunun bir index parametresi bulunmaktadır. Bu index parametresi epoch içerisindeki kaçinci batch verilerinin elde edileceğini belirtmektedir. Programcı `__getitem__` metodundan batch işleminde kullanılacak parçalı x ve y değerlerinden oluşan bir demet geri döndürmelidir. Sınıfın `on_epoch_end` metodu her epoch bittiğinde çağrılmaktadır. Programcılar tipik olarak epoch bittiğinde eğitim veri kümесinin karıştırılmasını bu metot içerisinde yaparlar.

Şimdi yukarıda üretici fonksiyonla yaptığımız "imdb.csv" örneğini şidi sınıf yoluyla gerçekleştirelim:

```
import numpy as np
import pandas as pd
import re

BATCH_SIZE = 64
EPOCHS = 5

class WordConverter:
    def __init__(self):
```

```

self.word_set = set()

def __call__(self, review):
    words = re.findall("[a-zA-Z0-9']+", review.lower())
    self.word_set.update(words)

    return np.array(words)

def get_word_dict(self):
    return {word: index for index, word in enumerate(self.word_set)}

wc = WordConverter()
df = pd.read_csv('imdb.csv', converters={0: wc})
word_dict = wc.get_word_dict()
rev_word_dict = {index: word for word, index in word_dict.items()}

for i in range(len(df)):
    df.iloc[i, 0] = np.array([word_dict[word] for word in df.iloc[i, 0]]))

"""
text = ' '.join([rev_word_dict[index] for index in df.iloc[0, 0]])
print(text)
"""

test_zone = int(len(df) * 0.8)
validation_zone = int(test_zone * 0.8)

df_training_dataset = df.iloc[:validation_zone]
df_validation_dataset = df.iloc[validation_zone:test_zone]
df_test_dataset = df.iloc[test_zone:]

df.iloc[df.iloc[:, 1] == 'positive', 1] = 1
df.iloc[df.iloc[:, 1] == 'negative', 1] = 0

def vectorize(iterable, colszie):
    result = np.zeros((len(iterable), colszie), dtype=np.int8)
    for index, values in enumerate(iterable):
        result[index, values] = 1

    return result

from tensorflow.keras.utils import Sequence

class DataGenerator(Sequence):
    def __init__(self, df, batch_size):
        self.df = df
        self.batch_size = batch_size
        self.indices = np.arange(len(self.df)) // self.batch_size, dtype=np.int32

    def __len__(self):
        return len(self.df) // self.batch_size

    def __getitem__(self, index):
        start = self.indices[index] * self.batch_size
        stop = (self.indices[index] + 1) * self.batch_size

        dataset_x = vectorize(self.df.iloc[start:stop, 0], len(word_dict))
        dataset_y = self.df.iloc[start:stop, 1].to_numpy().astype(np.int8)

        return dataset_x, dataset_y

    def on_epoch_end(self):

```

```

np.random.shuffle(self.indices)

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense

model = Sequential(name='IMDB')
model.add(Dense(100, activation='relu', input_dim=len(word_dict), name='Hidden-1'))
model.add(Dense(100, activation='relu', name='Hidden-2'))
model.add(Dense(1, activation='sigmoid', name='Output'))
model.compile(optimizer='rmsprop', loss='binary_crossentropy', metrics=['binary_accuracy'])
hist = model.fit(DataGenerator(df_training_dataset, BATCH_SIZE),
                  validation_data=DataGenerator(df_validation_dataset, BATCH_SIZE),
epoch=EPOCHS)

import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Loss - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.plot(range(1, len(hist.history['loss']) + 1), hist.history['loss'])
plt.plot(range(1, len(hist.history['val_loss']) + 1), hist.history['val_loss'])
plt.legend(['Loss', 'Validation Loss'])
plt.show()

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Binary Accuracy - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Binary Accuracy')
plt.plot(range(1, len(hist.history['binary_accuracy']) + 1), hist.history['binary_accuracy'])
plt.plot(range(1, len(hist.history['val_binary_accuracy']) + 1),
hist.history['val_binary_accuracy'])
plt.legend(['Binary Accuracy', 'Validation Binary Accuracy'])
plt.show()

eval_result = model.evaluate(DataGenerator(df_test_dataset, BATCH_SIZE))
for i in range(len(eval_result)):
    print(f'{model.metrics_names[i]} --> {eval_result[i]}')

predict_text = 'the movie was not good. There are many flaws. Players are act badly'
predict_words = re.findall("[a-zA-Z0-9]+", predict_text.lower())
predict_numbers = [word_dict[pw] for pw in predict_words]
predict_data = vectorize([predict_numbers], len(word_dict))
predict_result = model.predict(predict_data)

if predict_result[0][0] > 0.5:
    print('OLUMLU')
else:
    print('OLUMSUZ')

```

Burada parçalı veri DataGenerator sınıfının `__getitem__` metodu tarafından oluşturulmaktadır. Bu mettotta index parametresinden hareketle verilerin batch_size kadar kısımları çekilerek geri döndürülmüştür. `__len__` metodunda bir epoch'taki batch sayısının geri döndürüldüğünü görüyorsunuz. Sınıfın `on_epoch_end` metodunda eğitim ve sınıma verileri karıştırılmıştır. Karıştırma işleminin dolaylı bir biçimde asıl veriler yoluyla değil indisler yoluyla yapıldığına dikkat ediniz. Sınıfta indices isimli bir NumPy dizisi biçiminde bir örnek özniteliği bulundurulmuştur. Bu dizi `on_epoch_end` metodunda karıştırılmış ve batch verilerinin indeksleri bu diziden çekilerek kullanılmıştır.

Seyrek Matrislerle İşlemler

Elemanlarının önemli bir bölümü 0 olan küçük bölümü 0'dan farklı değerlere sahip olan matrislere seyrek matris (sparse matrix) denilmektedir. Örneğin IMDB ve Reuters örneklerinde biz yazıları her biri tüm sözcük sayılarının uzunluğu kadar sütuna sahip olan bool vektörler biçiminde kodladık. Bu biçimde elde ettiğimiz x verilerine ilişkin matrislerin çok büyük çoğunluğu 0 olan elemanlardan oluşmaktadır. Örneğin yukarıdaki "imdb.csv" dosyasından hareketle oluşturarak bool vektöre dönüştürüdüğümüz dataset_x matrisindeki 0'ların oranına bakınız:

```
In [135]: dataset_x.shape  
Out[135]: (50000, 121589)
```

```
In [136]: np.sum(dataset_x) / dataset_x.size  
Out[136]: 0.001156351808140539
```

```
In [137]: 1 - np.sum(dataset_x) / dataset_x.size  
Out[137]: 0.9988436481918594
```

Bu matriste elemanların kabaca %99.88'i 0'lardan oluşmaktadır. İşte bu biçimde elemanlarının büyük çoğunluğu 0'lardan oluşan matrislerin daha az yer kaplayacak biçimde temsil edilmeleri için bazı veri yapıları kullanılmaktadır.

SciPy kütüphanesinde seyrek matrisler üzerinde işlem yapabilen hazır birtakım sınıflar vardır. Ancak NumPy ya da Keras kütüphanelerinde seyrek matris işlemleri için özel sınıflar ya da fonksiyonlar bulundurulmamıştır. Biz burada önce bu veri yapıları üzerinde kısaca duracağız sonra da SciPy kütüphanesindeki seyrek matris sınıflarını gözden geçireceğiz.

Seyrek matrislerin az yer kaplayacak biçimde temsil edilmesinde kullanılan veri yapılarından birine "DOK (Dictionary of Keys)" yöntemi denilmektedir. Bu yöntemde seyrek matris bir sözlük nesnesiyle temsil edilir. Sıfır olmayan elemanların satır ve sütun numaraları sözlüğün anahtarı o elemanların matristeki değerleri de anahtarlarla karşı gelen değerler olur. Örneğin aşağıdaki gibi bir seyrek matris olsun:

```
0  0  10  0  5  
0  2  0  0  0  
0  0  0  20  0  
4  0  0  0  0
```

Bu matris şöyle bir sözlükle saklanabilir:

```
dok_dict = {(0, 2): 10, (0, 4): 5, (1, 1): 2, (2, 3): 20, (3, 0): 4}
```

DOK matris aşağıdakine benzer bir sınıfta temsil edilebilir:

```
import numpy as np

class DokMatrix:  
    def __init__(self, shape):  
        if not isinstance(shape, tuple) or len(shape) != 2:  
            raise IndexError('shape must be 2 length tuple')  
        self.rowsize, self.colsize = shape  
        self.dict = {}  
  
    def __getitem__(self, index):  
        if not isinstance(index, tuple) or len(index) != 2:  
            raise IndexError('index must be two dimentional')  
  
        if index[0] >= self.rowsize or index[1] >= self.colsize:  
            raise IndexError('index out of range')  
  
        return self.dict.get(index, 0)  
  
    def __setitem__(self, index, value):  
        if not isinstance(index, tuple) or len(index) != 2:  
            raise IndexError('index must be two dimentional')
```

```

        raise IndexError('index must be two dimensional')

    if index[0] >= self.rowsize or index[1] >= self.colsize:
        raise IndexError('index out of range')

    self.dict[index] = value

def todense(self, dtype=np.float64):
    result = np.zeros((self.rowsize, self.colsize), dtype=dtype)
    for index, value in self.dict.items():
        result[index] = value

    return result

dm = DokMatrix((10, 10))

dm[3, 4] = 10
dm[5, 6] = 20
dm[1, 2] = 20

a = dm.todense()
print(a)

```

SciPy'da DOK matris veri yapısı `scipy.sparse` modülündeki `dok_matrix` isimli bir sınıfla temsil edilmiştir. Bu sınıf mevcut bir NumPy dizisinden seyrek matris yaratıldığı gibi boş bir seyrek matris de yaratılmaktadır. `dok_matrix` yoluyla seyrek matris yaratıldıktan sonra onun istediğimiz bir elemanına değer atayabiliriz ya da onun istediğimiz bir elemanın değerini alabiliriz. Matris üzerinde dilimleme gibi işlemler de yapılabiliriz. Bu işlemlerden yine `dok_matrix` nesneleri elde edilmektedir. Seyrek matrisler üzerinde temel aritmetik işlemler de yapılabilmektedir. Bir seyrek matris istenirse ilgili sınıfların `todense` ya da `toarray` metodlarıyla iki boyutlu NumPy dizilerine dönüştürülebilmektedir.

Örneğin:

```

from scipy.sparse import dok_matrix

dm = dok_matrix((10, 10))

dm[0, 3] = 10
dm[1, 6] = 20
dm[7, 9] = 30
dm[3, 4] = 40
dm[5, 1] = 50

print(dm, end='\n\n')

dm2 = dm[1:4, 3:7]
print(dm2, end='\n\n')

dm3 = dm * 2
print(dm3, end='\n\n')

a = dm.toarray()
print(a)

```

Buradan şöyle bir çıktı elde edilmiştir:

```

(0, 3)      10.0
(1, 6)      20.0
(7, 9)      30.0
(3, 4)      40.0
(5, 1)      50.0

(0, 3)      20.0
(2, 1)      40.0

```

```

(0, 3)      20.0
(1, 6)      40.0
(7, 9)      60.0
(3, 4)      80.0
(5, 1)     100.0

[[ 0.  0.  0. 10.  0.  0.  0.  0.  0.]
 [ 0.  0.  0.  0.  0. 20.  0.  0.  0.]
 [ 0.  0.  0.  0.  0.  0.  0.  0.  0.]
 [ 0.  0.  0.  40.  0.  0.  0.  0.  0.]
 [ 0.  0.  0.  0.  0.  0.  0.  0.  0.]
 [ 0. 50.  0.  0.  0.  0.  0.  0.  0.]
 [ 0.  0.  0.  0.  0.  0.  0.  0.  0.]
 [ 0.  0.  0.  0.  0.  0.  0.  0. 30.]
 [ 0.  0.  0.  0.  0.  0.  0.  0.  0.]
 [ 0.  0.  0.  0.  0.  0.  0.  0.  0.]]
```

Seyrek matrisleri temsil etmek için kullanılan diğer bir veri yapısı LIL (List of List) biçiminde isimlendirilmektedir. Bu veri yapısında satırlara ilişkin iki paralel liste dizisi tutulur. Dizilerin bir tanesinde satırlardaki değerler, diğerinde ise bu değerlere ilişkin sütun numaraları bulunmaktadır. Yine seyrek matrisimiz şöyle olsun:

```

0  0   10   0   5
0  2   0    0   0
0  0   0   20   0
4  0   0    0   0
```

Bu matris LIL formatı ile şöyle saklanabilir:

```

rows = [[10, 5], [1], [20], [4]]
cols = [[2, 3], [1], [3], [0]]
```

Burada rows listesinde satırlardaki değerler, cols listesinde de onların sırasıyla sütun indeksleri bulunmaktadır. Bu veri yapısında genellikle satırlardaki sütun indeksleri sıralı bir biçimde tutulmaktadır. Bu sayede satırdaki elemanlara ikili arama (binary search) yoluyla erişilebilmektedir.

LIL matrisler SciPy kütüphanesinde scipy.sparse modülündeki lil_matrix sınıfıyla temsil edilmiştir. Sınıfın genel kullanımı dok_matrix sınıfında olduğu gibidir. Örneğin:

```

from scipy.sparse import lil_matrix

lil = lil_matrix((10, 10))

lil[0, 3] = 10
lil[1, 6] = 20
lil[7, 9] = 30
lil[3, 4] = 40
lil[5, 1] = 50

print(lil, end='\n\n')

lil2 = lil[1:4, 3:7]
print(lil2, end='\n\n')

lil3 = lil * 2
print(lil3, end='\n\n')

a = lil.toarray()
print(a)
```

CSR (Compressed Sparse Row) ve CSC (Compress Sparce Column) diğer iki önemli seyrek matris veri yapısıdır. CSR formatında seyrek matris üç dizi ile ifade edilmektedir. Dizilerden biri satır temelinde sıfır olmayan elemanların değerlerini, ikincisi bu elemanların sütun numaralarını ve üçüncüsü de her satırdaki elemanların birinci dizideki başlangıç ve bitiş indeks numaralarını tutmaktadır. Aşağıdaki gibi bir seyrek matris olsun:

```
0  0  10  0  5  7  12  0
0  2  5  0  0  0  7  6
0  7  0  20  0  9  0  0
4  0  2  0  3  0  8  0
```

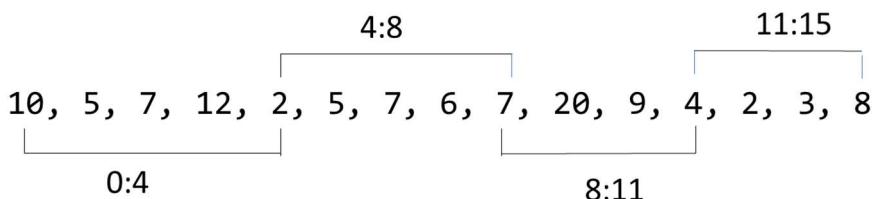
Bu matris CSR formatında aşağıdaki gibi üç dizi (liste) ile ifade edilir:

```
data = [10, 5, 7, 12, 2, 5, 7, 6, 7, 20, 9, 4, 2, 3, 8]
indices = [2, 4, 5, 6, 1, 2, 6, 7, 1, 3, 5, 0, 2, 4, 6]
indptr = [0, 4, 8, 11, 11, 15]
```

Buradaki data ve indices paralel iki dizidir. data dizisi satır temelli soldan sağa 0 olmayan elemanları, indices ise bu elemanların sütun indekslerini tutmaktadır. indptr belli satırdaki elemanların data listesindeki dilimlerini göstermektedir. Yani yukarıdaki örnekte 10 değeri 2'inci sütunda, 5 değeri 4'üncü sütunda, 7 değeri ise 5'inci sütundadır. Ancak bunların hangi satırlarda olduğu bilinmemektedir. İşte indptr aslında bu elemanların hangi satırda olduğuna ilişkin dilimlemelerden oluşmaktadır:

```
(0, 4) --> 0'inci satırdaki elemanlar
(4, 8) --> 1'inci satırdaki elemanlar
(8, 11) --> 2'inci satırdaki elemanlar
(11, 15) --> 3'üncü satırdaki elemanlar
```

indptr ile data listeleri arasındaki ilişkiyi şekilsel olarak da şöyle gösterebiliriz:



CSR matrlslere yeni bir eleman atanması DOK ve LIL matrlslere kıyasla daha fazla zaman gerektirmektedir. Böyle bir işlemde uyarı alırsanız şaşırmayınız. Ancak CSR matrlsler etkin biçimde birbirleriyle aritmetik işlemlere sokulabilmektedir. csr_matrix sınıfının data örnek özniteligi 0 olmayan matrls elemanlarını, indices örnek özniteligi bu elemanların sütun numaralarını ve indptr örnek özniteligi ise satır dilimlemelerini bize NumPy dizisi olarak vermektedir. Örneğin:

```
import numpy as np
from scipy.sparse import csr_matrix

a = np.array([[0, 0, 10, 0, 5, 7, 12, 0],
              [0, 2, 5, 0, 0, 0, 7, 6],
              [0, 7, 0, 20, 0, 9, 0, 0],
              [0, 0, 0, 0, 0, 0, 0, 0],
              [4, 0, 2, 0, 3, 0, 8, 0]])

csr = csr_matrix(a, dtype=np.int32)
print(csr.toarray(), end='\n\n')
print(csr.data, end='\n\n')
print(csr.indices, end='\n\n')
print(csr.indptr, end='\n\n')
```

```
csr2 = csr * 2
print(csr2.toarray())
```

Şöyledir bir çıktı elde edilmiştir:

```
[[ 0  0 10  0  5  7 12  0]
 [ 0  2  5  0  0  0  7  6]
 [ 0  7  0 20  0  9  0  0]
 [ 0  0  0  0  0  0  0  0]
 [ 4  0  2  0  3  0  8  0]]]

[10  5  7 12  2  5  7  6  7 20  9  4  2  3  8]

[2 4 5 6 1 2 6 7 1 3 5 0 2 4 6]

[ 0  4  8 11 11 15]

[[ 0  0 20  0 10 14 24  0]
 [ 0  4 10  0  0  0 14 12]
 [ 0 14  0 40  0 18  0  0]
 [ 0  0  0  0  0  0  0  0]
 [ 8  0  4  0  6  0 16  0]]
```

csr_matrix sınıfının çeşitli işlemler yapan pek çok metodu vardır. Bunları SciPy dokümanlarından inceleyebilirsiniz.

CSC matrisleri depolama biçimini olarak CSR matrisleri gibidir. Ancak eleman yerleri satır temelli değil sütun temelli olarak tutulmaktadır. CSC matris için de benzer örneği verebiliriz:

```
import numpy as np
from scipy.sparse import csc_matrix

a = np.array([[0, 0, 10, 0, 5, 7, 12, 0],
              [0, 2, 5, 0, 0, 0, 7, 6],
              [0, 7, 0, 20, 0, 9, 0, 0],
              [0, 0, 0, 0, 0, 0, 0, 0],
              [4, 0, 2, 0, 3, 0, 8, 0]])

csc = csc_matrix(a, dtype=np.int32)
print(csc.toarray(), end='\n\n')
print(csc.data, end='\n\n')
print(csc.indices, end='\n\n')
print(csc.indptr, end='\n\n')
csr2 = csr * 2
print(csr2.toarray())
```

Şöyledir bir çıktı elde edilmiştir:

```
[[ 0  0 10  0  5  7 12  0]
 [ 0  2  5  0  0  0  7  6]
 [ 0  7  0 20  0  9  0  0]
 [ 0  0  0  0  0  0  0  0]
 [ 4  0  2  0  3  0  8  0]]]

[ 4  2  7 10  5  2 20  5  3  7  9 12  7  8  6]

[4 1 2 0 1 4 2 0 4 0 2 0 1 4 1]

[ 0  1  3  6  7  9 11 14 15]

[[ 0  0 20  0 10 14 24  0]
 [ 0  4 10  0  0  0 14 12]
 [ 0 14  0 40  0 18  0  0]]
```

```
[ 0  0  0  0  0  0  0  0]
[ 8  0  4  0  6  0 16  0]]
```

Pekiyi burada ele aldığımız SciPy seyrek matris sınıflarının hangileri hangi durumlarda tercih edilmelidir? Bunları birkaç maddede özetleyebiliriz:

- DOK matrislerde elemanlara okuma ya da yazma amaçlı erişim hızlı bir biçimde gerçekleştirilmektedir. Ancak DOK matrisler matris işlemlerinde çok etkin değildir. DOK matrisler dilimleme de etkin değildir.
- LIL matrisler de okuma amaçlı eleman erişimlerinde ve satırsal dilimlemelerde hızlıdır. Ancak sütunsal dilimlemelerde ve matris işlemlerinde yavaşırlar. 0 olan elemanlara yazma amaçlı erişimlerde çok hızlı olmasalar da nispeten hızlıdır. Bu matrislerin matris işlemleri için CSR ve CSC formatlarına dönüştürülmesi uygundur ve bu dönüştürme hızlıdır.
- CSR matrisler satırsal dilimlemelerde CSC matrisler ise sütunsal dilimlemelerde hızlıdır. Ancak CSR sütunsal, CSC de satırsal dilimlemelerde yavaştır. Her iki matris de matris işlemlerinde hızlıdır. Bu matrislerde elemanların değerlerini değiştirmek (özellikle 0 olan elemanların) yavaştır.

SciPy kütüphanesinde burada ele aldığımızın dışında da başka seyrek matris sınıfları bulunmaktadır. Bu sınıfları SciPy dokümanlarından inceleyebilirsiniz.

Şimdi de bir seyrek matris uygulaması yapalım. Uygulamamızda yine "imdb.csv" verilerini kullanacağız. Önce bu dosyayı yine pandas.read_csv fonksiyonuyla bir DataFrame olarak okuyacağız. Sonra bu DataFrame nesnesini seyrek matris olarak okuyup seyrek matrisi parçalı biçimde bool vektöre dönüştüreceğiz:

```
import numpy as np
import pandas as pd
import re

BATCH_SIZE = 64
EPOCHS = 5

class WordConverter:
    def __init__(self):
        self.word_set = set()

    def __call__(self, review):
        words = re.findall("[a-zA-Z0-9]+", review.lower())
        self.word_set.update(words)

        return np.array(words)

    def get_word_dict(self):
        return {word: index for index, word in enumerate(self.word_set)}

wc = WordConverter()
df = pd.read_csv('imdb.csv', converters={0: wc})
word_dict = wc.get_word_dict()
rev_word_dict = {index: word for word, index in word_dict.items()}

for i in range(len(df)):
    df.iloc[i, 0] = np.array([word_dict[word] for word in df.iloc[i, 0]])

"""
text = ' '.join([rev_word_dict[index] for index in df.iloc[0, 0]])
print(text)
"""

test_zone = int(len(df) * 0.8)
validation_zone = int(test_zone * 0.8)
```

```

df_training_dataset = df.iloc[:validation_zone]
df_validation_dataset = df.iloc[validation_zone:test_zone]
df_test_dataset = df.iloc[test_zone:]

df.iloc[df.iloc[:, 1] == 'positive', 1] = 1
df.iloc[df.iloc[:, 1] == 'negative', 1] = 0

from scipy.sparse import lil_matrix

def vectorize(iterable, colszie):
    result = lil_matrix((len(iterable), colszie), dtype=np.int8)
    for index, values in enumerate(iterable):
        result[index, values] = 1

    return result

sparse_training_dataset_x = vectorize(df_training_dataset.iloc[:, 0], len(word_dict))
training_dataset_y = df_training_dataset.iloc[:, 1].values.astype(np.int8)

sparse_validation_dataset_x = vectorize(df_validation_dataset.iloc[:, 0], len(word_dict))
validation_dataset_y = df_validation_dataset.iloc[:, 1].values.astype(np.int8)

sparse_test_dataset_x = vectorize(df_test_dataset.iloc[:, 0], len(word_dict))
test_dataset_y = df_test_dataset.iloc[:, 1].values.astype(np.int8)

from tensorflow.keras.utils import Sequence

class DataGenerator(Sequence):
    def __init__(self, sparse_dataset_x, dataset_y, batch_size):
        self.sparse_dataset_x = sparse_dataset_x
        self.dataset_y = dataset_y
        self.batch_size = batch_size
        self.indices = np.arange(len(self))

    def __len__(self):
        return len(self.dataset_y) // self.batch_size

    def __getitem__(self, index):
        start = self.indices[index] * self.batch_size
        stop = (self.indices[index] + 1) * self.batch_size

        return self.sparse_dataset_x[start:stop, :].toarray(), self.dataset_y[start:stop]

    def on_epoch_end(self):
        np.random.shuffle(self.indices)

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense

model = Sequential(name='IMDB')
model.add(Dense(100, activation='relu', input_dim=len(word_dict), name='Hidden-1'))
model.add(Dense(100, activation='relu', name='Hidden-2'))
model.add(Dense(1, activation='sigmoid', name='Output'))
model.compile(optimizer='rmsprop', loss='binary_crossentropy', metrics=['binary_accuracy'])
hist = model.fit(DataGenerator(sparse_training_dataset_x, training_dataset_y, BATCH_SIZE),
                  validation_data=DataGenerator(sparse_validation_dataset_x, validation_dataset_y, BATCH_SIZE),
                  epochs=EPOCHS)

import matplotlib.pyplot as plt

figure = plt.gcf()

```

```

figure.set_size_inches((15, 5))
plt.title('Loss - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.plot(range(1, len(hist.history['loss']) + 1), hist.history['loss'])
plt.plot(range(1, len(hist.history['val_loss']) + 1), hist.history['val_loss'])
plt.legend(['Loss', 'Validation Loss'])
plt.show()

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Binary Accuracy - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Binary Accuracy')
plt.plot(range(1, len(hist.history['binary_accuracy']) + 1), hist.history['binary_accuracy'])
plt.plot(range(1, len(hist.history['val_binary_accuracy']) + 1),
hist.history['val_binary_accuracy'])
plt.legend(['Binary Accuracy', 'Validation Binary Accuracy'])
plt.show()

eval_result = model.evaluate(DataGenerator(sparse_test_dataset_x, test_dataset_y, BATCH_SIZE))
for i in range(len(eval_result)):
    print(f'{model.metrics_names[i]} --> {eval_result[i]}')

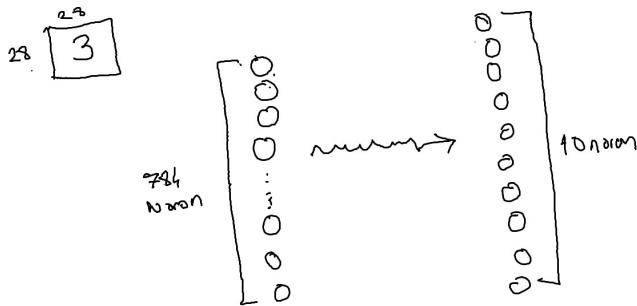
predict_text = 'the movie was not good. There are many flaws. Players are act badly'
predict_words = re.findall("[a-zA-Z0-9]+", predict_text.lower())
predict_numbers = [word_dict[pw] for pw in predict_words]
predict_data = vectorize([predict_numbers], len(word_dict))
predict_result = model.predict(predict_data)

if predict_result[0][0] > 0.5:
    print('OLUMLU')
else:
    print('OLUMSUZ')

```

Tek Etiketli Çok Sınıflı Lojistik Regresyon Modeli İçin "MNIST (Modified National Institute of Standards and Technology)" Örneği

MNIST makine öğrenmesinde deneme ve eğitim amacıyla en çok kullanılan veritabanlarından biridir. MNIST'in çok değişik veri kümeleri vardır. Bu veri kümelerinden biri Keras içerisinde de bulundurulmuştur. keras.mnist modülünde her biri 28x28'lik bir "gri tonlamalı (grayscale)" bitmap'ten oluşan pek çok resim bulunmaktadır. Bu resimlerde 0'dan 9'a kadar sayıların elle çizilmiş şekilleri vardır. Dolayısıyla modelin girdi katmanı $28 * 28 = 784$ nörondan çıktı katmanı da 10 nörondan oluşmaktadır.



Bir resim bilindiği gibi pixel'lerden oluşmaktadır. Her pixel'in de renk bileşenleri vardır. Pixel'le rin renk bileşenleri için en çok kullanılan format RGB (Red, Green, Blue) formatıdır. Bu formatta renk bileşenleri her biri 1 byte'tan oluşan Kırmızı (Red), Yeşil (Green) ve Maviniñ (Blue) tonal değerleriyle ifade edilmektedir. Pek çok görüntü birimi de aslında kendi içerisinde renkleri zaten bu renklerin tonal bileşimleriyle oluşturmaktadır. Bir byte ile ifade edilecek sayılar toplam 256 tane olduğuna göre 1 byte'lık RGB formatında her pixel $256 * 256 * 256 = 2^{24}$ renkten biri ile renklendirilebilmektedir. Aslında modern grafik kartlarında her pixel için bir byte da transparanlık (alpha channel)

bilgisi tutulmaktadır. Transparanlık arkadaki görüntünün görülebilirliği üzerinde etkili olmaktadır. Bu transparanlık 255 ise arka plan tam saydamsız, 0 ise tam saydam anlamına gelir.

Gri tonlamalı resim aslında grinin tonlarından oluşan resimdir. Gri tonlamalı resimlerde her bir pixel RGB ile değil tek bir değerle ifade edilir. Yani gri tonlamalı resim aslında $R = G = B$ pixel renklerinden oluşan resimdir. Böylece gri tonlamalı resimde her pixel üç byte'la değil bir byte'la kodlanabilmektedir. Gri tonlamalı resimleri siyah-beyaz (monochrome) resimlerle karıştırılmayınız. Siyah-beyaz (buradaki siyah ve beyaz başka renkler de olabilir) bir resimde her pixel 1 bit ile ifade edilmektedir. Ancak siyah-beyaz resimlerin çoğu insanlar tarafından anlamsız bir görüntü biçiminde algılanmaktadır. Siyah tonlamalı resimler insanlar tarafından çok daha iyi algılanmaktadır.

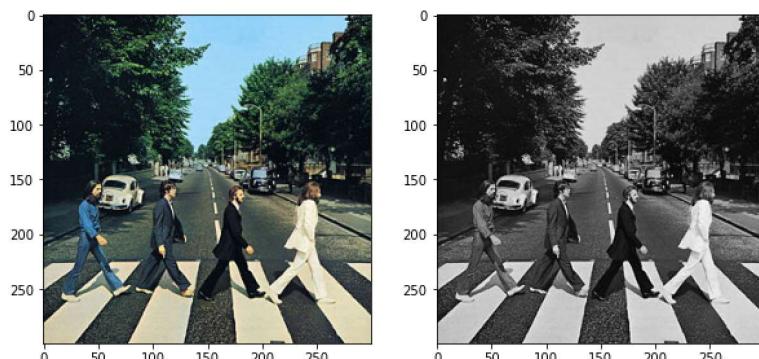
Peki normal RGB bir resim gri tonlamalı biçimde dönüştürülebilir mi? Yanıt evet. Bunun için kullanılan iki temel teknik vardır. Birinci teknikte her pixel'in RGB değerlerinin ortalaması alınır. Ancak bu yöntem bazı resimlerde çok tatmin edici sonuçlar vermemektedir. Bu yöntem için şöyle bir örnek verebiliriz:

```
import numpy as np
import matplotlib.pyplot as plt

img_data = plt.imread('AbbeyRoad.jpg')
gray_img_data = np.mean(img_data, axis=2)

figure = plt.gcf()
figure.set_size_inches((10, 10))
plt.subplot(1, 2, 1)
plt.imshow(img_data)
plt.subplot(1, 2, 2)
plt.imshow(gray_img_data, cmap='gray')
plt.show()
```

Elde edilen görüntüleri karşılaştırınız:



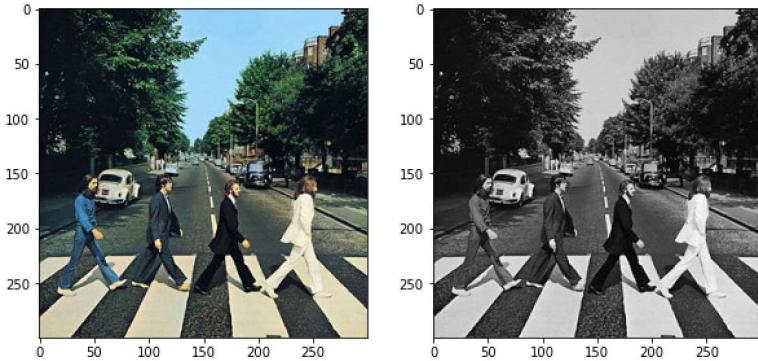
Diger yöntemde pixel'in RGB değerleri önce özel değerlerle çarpılıp sonra onların ortalamaları alınmaktadır. Uygulamada genellikle bu ağırlıklı ortalama yöntemi tercih edilmektedir. Yukarıdaki örneği bu yöntemle söyle uygulayabiliriz:

```
import numpy as np
import matplotlib.pyplot as plt

img_data = plt.imread('AbbeyRoad.jpg')
gray_img_data = np.average(img_data, weights=[0.3, 0.59, 0.11], axis=2)

figure = plt.gcf()
figure.set_size_inches((10, 10))
plt.subplot(1, 2, 1)
plt.imshow(img_data)
plt.subplot(1, 2, 2)
plt.imshow(gray_img_data, cmap='gray')
plt.show()
```

Burada R, B için ağırlık değerleri sırasıyla 0.3, 0.59, 0.11 alınmıştır. Elde edilen görüntü benzerdir:



MNIST örneğimizde işe önce veri kümesini yüklemekle başlayalım:

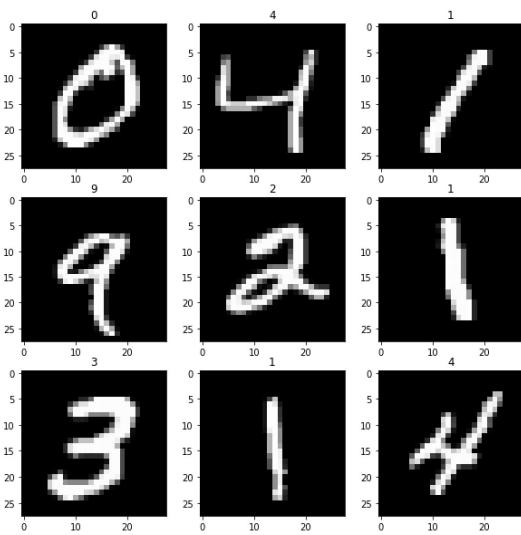
```
from tensorflow.keras.datasets import mnist  
(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) = mnist.load_data()
```

Buradaki training_dataset_x her biri 28X28'lik matristen oluşan 60000'luk bir NumPy dizisidir. Yani bu dizi 60000X28X28 boyutundadır. Benzer biçimde test_dataset_x de her biri 28X28'lik matristen oluşan 10000'luk bir ndarray dizisidir. Tabii bu dizilerin elemanları gri tonlamalı pixel belirttiğine göre 0 ile 255 arasında olmak zorundadır. training_dataset_y ve test_dataset_y dizileri ise tek boyutlu ndarray nesneleridir. Bu dizilerin her elemanı 0'dan 9'a kadar kategorik bir değer belirtmektedir. Bu değerin örneğin 3 olması demek oradaki 28x28 gri tonlamalı resmin üzerindeki çizimin 3 çizimi olması demektir.

Şimdi biz matplotlib.pyplot kullanarak buradaki birkaç resmi çizdirelim:

```
import matplotlib.pyplot as plt  
  
figure = plt.gcf()  
figure.set_size_inches(10, 10)  
for i in range(1, 10):  
    plt.subplot(3, 3, i)  
    axis = plt.gca()  
    axis.set_title(str(training_dataset_y[i]))  
    plt.imshow(training_dataset_x[i], cmap='gray')  
  
plt.show()
```

Çizim işleminden şöyle bir görüntü elde edilmiştir:



28x28'lik üç boyutlu resim matrisini yapay sinir ağına girdi yapmak için iki boyutlu hale getirelim:

```
training_dataset_x = training_dataset_x.reshape(-1, 28 * 28)
test_dataset_x = test_dataset_x.reshape(-1, 28 * 28)
```

Şimdi de `training_dataset_y` ve `test_dataset_y` verilerini düzenleyelim. Bizim ağımızın çıktı katmanında 10 tane nöron olacağına göre biz de ağıımızı eğitirken çıktı için 10 değer bulundurmalıyız. Anımsanacağı gibi çok sınıflı sınıflandırma problemlerinde çıktı katmanındaki aktivasyon fonksiyonları "softmax" alınıyordu. Bu "softmax" fonksiyonu çıktı nöronlarının toplam değerini 1'de tutuyordu. Ayrıca modelin çıktısı kategorik bir veri olduğuna göre eğitimden önce bu çıktı verilerini de one hot encoding biçiminde kodlamamız gereklidir. One hot encoding için önceki örneklerde genellikle `sklearn.preprocessing` modülündeki `OneHotEncoder` sınıfını kullanmıştık. Burada bir değişiklik yaparak işlemi sizleri alıstırmak için Keras'taki `to_categorical` fonksiyonu ile yapalım:

```
from tensorflow.keras.utils import to_categorical

training_dataset_y = to_categorical(training_dataset_y)
test_dataset_y = to_categorical(test_dataset_y)
```

Şimdi verilerimizi normalize edelim. Bunun için MinMax ölçeklendirmesi yöntemini kullanabiliriz:

```
training_dataset_x = training_dataset_x / 255
test_dataset_x = test_dataset_x / 255
```

Burada en düşük pixel değeri 0 ve en büyük pixel değeri 255 olduğu için MinMax ölçeklendirmesini pixel değerlerini doğrudan 255'e bölgerek yaptığımiza dikkat ediniz.

Şimdi modelimizi oluşturalım:

```
from tensorflow.keras.utils import to_categorical

training_dataset_y = to_categorical(training_dataset_y)
test_dataset_y = to_categorical(test_dataset_y)

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense

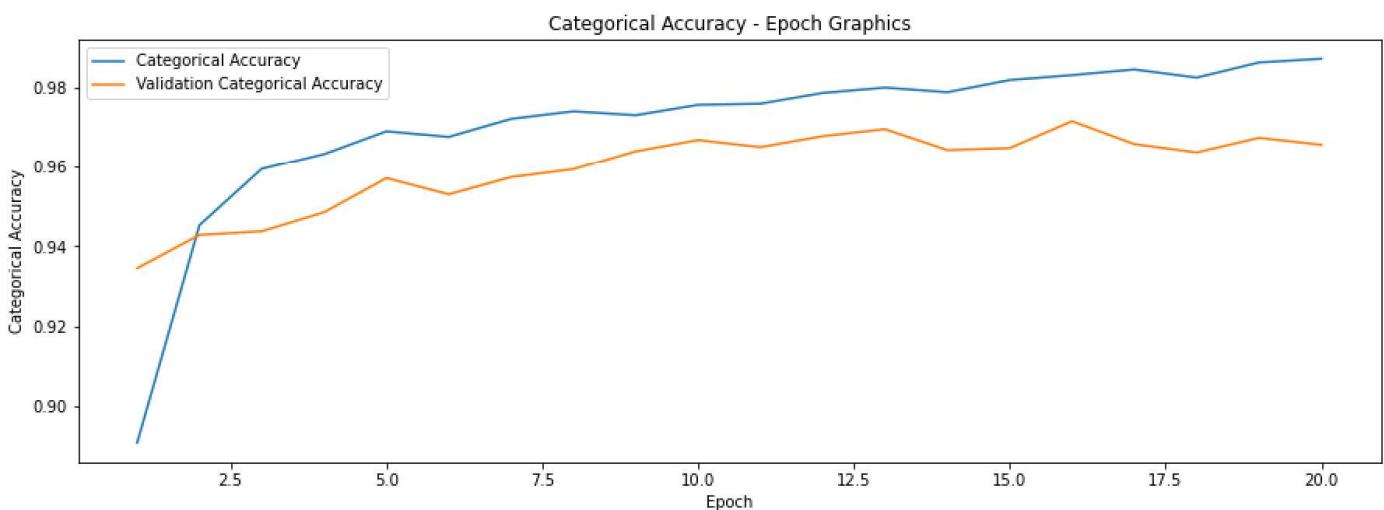
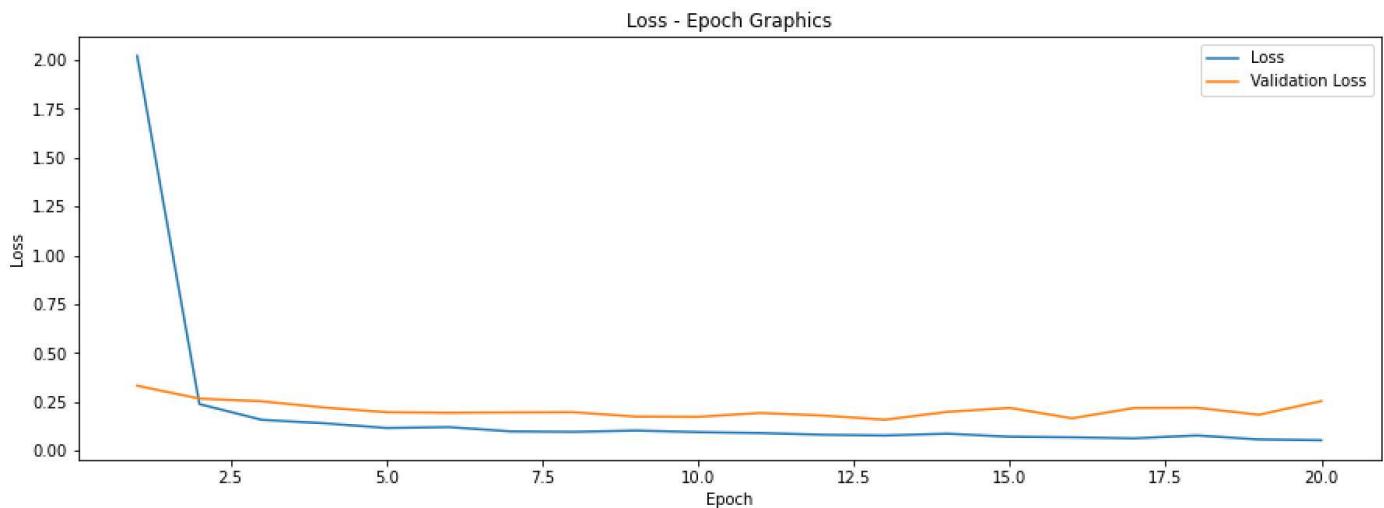
model = Sequential()
model.add(Dense(512, input_dim=28 * 28, activation='relu', name='Hidden-1'))
model.add(Dense(256, activation='relu', name='Hidden-2'))
model.add(Dense(10, activation='softmax', name='Output'))

model.compile('adam', loss='categorical_crossentropy', metrics=['categorical_accuracy'])
```

```
hist = model.fit(training_dataset_x, training_dataset_y, epochs=20, batch_size=64,  
validation_split=0.2)
```

Şimdi de grafiklerimizi çizelim:

```
import matplotlib.pyplot as plt  
  
figure = plt.gcf()  
figure.set_size_inches((15, 5))  
plt.title('Loss - Epoch Graphics')  
plt.xlabel('Epoch')  
plt.ylabel('Loss')  
plt.plot(range(1, len(hist.history['loss']) + 1), hist.history['loss'])  
plt.plot(range(1, len(hist.history['val_loss']) + 1), hist.history['val_loss'])  
plt.legend(['Loss', 'Validation Loss'])  
plt.show()  
  
figure = plt.gcf()  
figure.set_size_inches((15, 5))  
plt.title('Categorical Accuracy - Epoch Graphics')  
plt.xlabel('Epoch')  
plt.ylabel('Categorical Accuracy')  
plt.plot(range(1, len(hist.history['categorical_accuracy']) + 1),  
hist.history['categorical_accuracy'])  
plt.plot(range(1, len(hist.history['val_categorical_accuracy']) + 1),  
hist.history['val_categorical_accuracy'])  
plt.legend(['Categorical Accuracy', 'Validation Categorical Accuracy'])  
plt.show()
```



Bu grafiklere göre epoch sayısı arttıkça düşük düzeyli bir "overfit" şüphesi belirmektedir. Bu nedenle epoch sayısı 10 civarında tutulabilir.

Şimdi de modelimiz test edelim:

```
eval_result = model.evaluate(test_dataset_x, test_dataset_y)
for i in range(len(eval_result)):
    print(f'{model.metrics_names[i]} --> {eval_result[i]}')
```

Şu değerler elde edilmiştir:

```
loss --> 0.20867395401000977
categorical_accuracy --> 0.9699000120162964
```

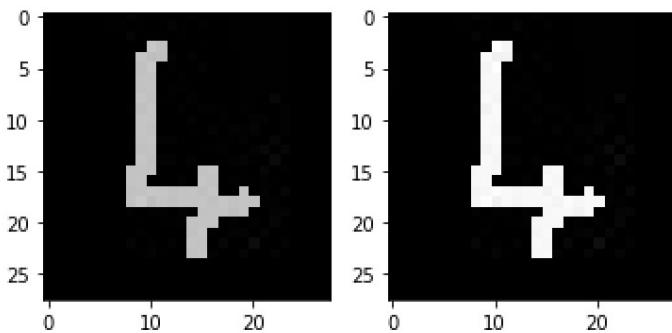
Buradaki categorical_accuracy değerine bakıldığında bu modelin %96.9 olasılıkla girilen rakamı doğru tanadığını söyleyebiliriz. Daha yüksek bir veri kümlesi üzerinde eğitim yapıldığında bu değer artacaktır.

Şimdi de predict işlemi yapmak isteyelim. Biz bu işlemi gerçek bir şekil üzerinde yapalım. Bunun için Paint gibi bir programda elle bir rakam çizip onu BMP ya da PNG formatında kaydedebiliriz. Sonra pyplot.imread kullanarak onun içerisindeki pixel verilerini okuyup gri tonlamalı hale dönüştürebiliriz.

```
import numpy as np

img_data = plt.imread('test.jpg')
gray_img_data = np.average(img_data, weights=[0.3, 0.59, 0.11], axis=2)
plt.subplot(1, 2, 1)
plt.imshow(img_data)
plt.subplot(1, 2, 2)
plt.imshow(gray_img_data, cmap='gray')
plt.show()
```

Biz bu örnekte şekli zaten siyah beyaz çizdiğimiz için asıl resimle gri tonlamalı resim arasında önemli farklar bulunmamaktadır:



Şimdi predict işlemi yapalım:

```
gray_img_data = gray_img_data / 255
gray_img_data = gray_img_data.reshape((1, 28 * 28))
predict_result = model.predict(gray_img_data)
number = np.argmax(predict_result[0])
print(number)
```

Şu sonuç elde edilmiştir:

4

Aşağıda MNIST örneğinin tüm kodunu veriyoruz. Buradaki "test.jpg" resmi Paint ile 28x28 boyutunda oluşturulmuştur:

```
from tensorflow.keras.datasets import mnist

(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) = mnist.load_data()

import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches(10, 10)
for i in range(1, 10):
    plt.subplot(3, 3, i)
    axis = plt.gca()
    axis.set_title(str(training_dataset_y[i]))
    plt.imshow(training_dataset_x[i], cmap='gray')

plt.show()

training_dataset_x = training_dataset_x / 255
test_dataset_x = test_dataset_x / 255

training_dataset_x = training_dataset_x.reshape(-1, 28 * 28)
test_dataset_x = test_dataset_x.reshape(-1, 28 * 28)

from tensorflow.keras.utils import to_categorical

training_dataset_y = to_categorical(training_dataset_y)
test_dataset_y = to_categorical(test_dataset_y)

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense

model = Sequential()
model.add(Dense(512, input_dim=28 * 28, activation='relu', name='Hidden-1'))
model.add(Dense(256, activation='relu', name='Hidden-2'))
model.add(Dense(10, activation='softmax', name='Output'))

model.compile('adam', loss='categorical_crossentropy', metrics=['categorical_accuracy'])
hist = model.fit(training_dataset_x, training_dataset_y, epochs=10, batch_size=64,
validation_split=0.2)

eval_result = model.evaluate(test_dataset_x, test_dataset_y)
for i in range(len(eval_result)):
    print(f'{model.metrics_names[i]} --> {eval_result[i]}')

import numpy as np

img_data = plt.imread('test.jpg')
gray_img_data = np.average(img_data, weights=[0.3, 0.59, 0.11], axis=2)
plt.subplot(1, 2, 1)
plt.imshow(img_data)
plt.subplot(1, 2, 2)
plt.imshow(gray_img_data, cmap='gray')
plt.show()

gray_img_data = gray_img_data / 255
gray_img_data = gray_img_data.reshape((1, 28 * 28))
predict_result = model.predict(gray_img_data)
number = np.argmax(predict_result[0])

print(number)
```

Keras içerisinde bulunan MNIST veri kümesi aslında CSV dosyası olarak da çeşitli yerlerden indirilebilir. Örneğin bunun için <https://www.kaggle.com/oddrationale/mnist-in-csv> adresini kullanabilirsiniz. Buradan "mnist_train.csv" ve "mnist_test.csv" dosyalarını elde edeceksiniz. Bu dosyalardan hareketle yukarıdaki örneği aşağıdaki gibi oluşturabilirsiniz:

```
import numpy as np

training_dataset = np.loadtxt('mnist_train.csv', delimiter=',', skiprows=1, dtype=np.uint8)

training_dataset_x = training_dataset[:, 1:]
training_dataset_y = training_dataset[:, 0]

test_dataset = np.loadtxt('mnist_test.csv', delimiter=',', skiprows=1, dtype=np.uint8)

test_dataset_x = test_dataset[:, 1:]
test_dataset_y = test_dataset[:, 0]

import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches(10, 10)
for i in range(1, 10):
    plt.subplot(3, 3, i)
    axis = plt.gca()
    axis.set_title(str(training_dataset_y[i]))
    plt.imshow(training_dataset_x[i].reshape(28, 28), cmap='gray')

plt.show()

training_dataset_x = training_dataset_x / 255
test_dataset_x = test_dataset_x / 255

from tensorflow.keras.utils import to_categorical

training_dataset_y = to_categorical(training_dataset_y)
test_dataset_y = to_categorical(test_dataset_y)

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense

model = Sequential(name='MNIST')
model.add(Dense(256, input_dim=training_dataset_x.shape[1], activation='relu', name='Hidden-1'))
model.add(Dense(128, activation='relu', name='Hidden-2'))
model.add(Dense(10, activation='softmax', name='Output'))
model.compile(optimizer='rmsprop', loss='categorical_crossentropy',
metrics=['categorical_accuracy'])
hist = model.fit(training_dataset_x, training_dataset_y, batch_size=32, epochs=20,
validation_split=0.2)

import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Loss - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.plot(range(1, len(hist.history['loss']) + 1), hist.history['loss'])
plt.plot(range(1, len(hist.history['val_loss']) + 1), hist.history['val_loss'])
plt.legend(['Loss', 'Validation Loss'])
plt.show()

figure = plt.gcf()
```

```

figure.set_size_inches((15, 5))
plt.title('Categorical Accuracy - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Categorical Accuracy')
plt.plot(range(1, len(hist.history['categorical_accuracy']) + 1),
hist.history['categorical_accuracy'])
plt.plot(range(1, len(hist.history['val_categorical_accuracy']) + 1),
hist.history['val_categorical_accuracy']))
plt.legend(['Categorical Accuracy', 'Validation Categorical Accuracy'])
plt.show()

eval_result = model.evaluate(test_dataset_x, test_dataset_y)
for i in range(len(eval_result)):
    print(f'{model.metrics_names[i]} ---> {eval_result[i]}')

```

Evrişimsel Sinir Ağları (Convolutional Neural Networks)

Sayısal sinyal işleme (digital signal processing) alanında evrişim (convolution) işlemleri ile çokça karşılaşılmaktadır. Yapay sinir ağlarında evrişim işlemi başta görsel veriler olmak üzere işitsel (audio) ve hareketsel (video) verilerine uygulanan bir tekniktir. Evrişimin görüntü verilerine uygulanması en yaygın kullanım biçimidir. Evrişim işlemi sayesinde görüntü yerel ögelere duyarlı hale getirilebilmektedir.

Evrişim işlemi evrişime sokulacak görüntü matrisinin filtre matrisi ya da "kernel" denilen küçük bir matrisle kaydırılmış biçimde işleme sokulmasıyla gerçekleştirilmektedir. Evrişim işlemi gri tonlu görüntü verileri üzerinde tipik olarak şöyle yürütülmektedir: Evrişime sokulacak orijinal görüntünün yanı sıra evrişim işleminde kullanılacak birfiltreleme (kernel) matrisi oluşturulur. Sonra bufiltreleme matrisi görüntünün üzerine bindirilerek işleme sokulur. Her işlem sonucunda tek bir değer elde edilmektedir. Sonra bufiltreleme matrisi sağa ve aşağıya kaydırılarak işlemler devam ettirilir. Filtreleme matrisi ile görüntünün ilgili kısmı üzerinde yapılan işlem genellikle "dot product" biçimindedir. Yanifiltreleme matrisindeki elemanlar asıl resmin çakıştırıldığı yerdeki elemanlarla çarpılarak toplanır ve bu toplamdan bir değer elde edilir. Örneğin asıl remin gri tonlu pixel'leri şöyle olsun:

```

a11 a12 a13 a14 a15 a16
a21 a22 a23 a24 a25 a26
a31 a32 a33 a34 a35 a36
a41 a42 a43 a44 a45 a46
a51 a52 a53 a54 a55 a56
a61 a62 a63 a64 a65 a66

```

Seçtiğimizfiltreleme matrisi de aşağıdaki gibi 3x3'lük olsun:

```

b11 b12 b13
b21 b22 b23
b31 b32 b33

```

Şimdi bufiltreleme matrisi asıl görüntü matrisinin sol-üst köşesine oturularak "dot-product" işlemi yapılır:

```

c11 = b11 * a11 + b12 * a12 + b13 * a13 + b21 * a21 + b22 * a22 + b23 * a23 + b31 * a31 + b32 * a32 + b33 * a33

```

Burada elde edilen değer evrişim işlemlerinin sonunda elde edilecek görüntü matrisinin c₁₁ elemanını oluşturacaktır. Sonra bufiltreleme matrisi asıl görüntü matrisi üzerinde sağa ve aşağıya kaydırılarak aynı işlemler yinelenir. Örneğinfiltreleme matrisini 1 sağa kaydırılmış olalım:

```

c12 = b11 * a12 + b12 * a12 + b13 * a14 + b21 * a22 + b22 * a23 + b23 * a24 + b31 * a32 + b32 * a34 + b33 * a34

```

Burada elde edilen değer görüntü matrisinin c₁₂'inci elemanı olacaktır. Bu işlemde böyle devam edildiğinde evrişilmiş hedef matrisin 4x4'lük olacağına dikkat ediniz. Bir yukarıdaki örnekte görüntü matrisini vefiltre matrisini 3X3'lük kare

matris olarak almış olsak da aslında görüntü matrisi ve filtre matrisi kare matris olmak zorunda değildir. Bu durumda evrişilmiş hedef matrisin boyutu için şu ifadeleri yazılabiliriz:

Evrişilmiş matrisin satır uzunluğu = Görüntü matrisinin satır uzunluğu - filtre matrisinin satır uzunluğu + 1

Evrişilmiş matrisin sütun uzunluğu = Görüntü matrisinin sütun uzunluğu - filtre matrisinin sütun uzunluğu + 1

Filtre matrisi gerhangi bir boyutta olabiliyorsa da genel olarak filtre matrisinin tek sayılı (3x3, 5x5, 7x7 gibi) bir kare matris olarak alındığını da belirtmek istiyoruz.

Filtre matrisini ana matris ile çalıştığımızda filtre matrisinin orta noktası için hedef matrisin hücresinin elde edildiğine dikkat ediniz. Bu nedenle evrişim işleminden daha küçük bir görüntü matrisi elde edilmektedir. Eğer evrişilmiş hedef matrisin görüntü matrisi ile aynı büyüklükte olması isteniyorsa görüntü matrisinin filtreleme matrisinin satır ve sütun uzunluğuna dayalı olarak iki taraftan uzatılması gereklidir. Bu uzatma işlemi çeşitli biçimlerde yapılmaktadır. Örneğin sol sütunun soluna, sağ sütunun sağına, üst satırın yukarısına, alt satırın aşağısına içi sıfırlarla dolu sütunlar ve satırlar eklenerek asıl şekil evrişim amaçlı büyütülebilir. Ya da sıfır eklemek yerine son satır ya da sütunlar çoğaltılmaktadır. Bu işleme genel olarak İngilizce "padding" denilmektedir.

Evrişim işleminde kaydırma birer birer yapılmak zorunda değildir. Bu kaydırma değerine İngilizce "stride" denilmektedir. Stride değerinin 1 olması kaydırmanın birer birer yapılabacağı anlamına gelir. Eğer stride değeri yükseltilirse evrişilmiş matris küçülecektir. Aynı zamanda resimdeki yerel ilişkilerin uzaklıği da artırılmış olacaktır.

Aşağıda gri tonlamalı bir resim üzerinde evrişim işlemi yapan örnek bir Python programı verilmektedir:

```
import numpy as np

def conv(image, filter):
    image_height = image.shape[0]
    image_width = image.shape[1]

    filter_height = filter.shape[0]
    filter_width = filter.shape[1]

    conv_height = image_height - filter_height + 1
    conv_width = image_width - filter_width + 1

    conv_image = np.zeros((conv_height, conv_width))

    for row in range(conv_height):
        for col in range(conv_width):
            for i in range(filter_height):
                for j in range(filter_width):
                    conv_image[row, col] += image[row + i, col + j] * filter[i, j]

    conv_image[conv_image > 255] = 255
    conv_image[conv_image < 0] = 0

    return conv_image
```

Görüntü işleme uygulamalarında evrişim işlemi resmi filtrelemek için sık kullanılmaktadır. Bu bağlamda çeşitli filtre matrisleri resimleri farklı biçimlerde filtre etmek için kullanılmaktadır. Örneğin bir resmi iki farklı filtreye sokup evrişim işlemi yapalım:

```
import matplotlib.pyplot as plt
from matplotlib.image import imread

img_data = imread('AbbeyRoad.jpg')
gray_img_data = np.average(img_data, weights=[0.3, 0.59, 0.11], axis=2)
```

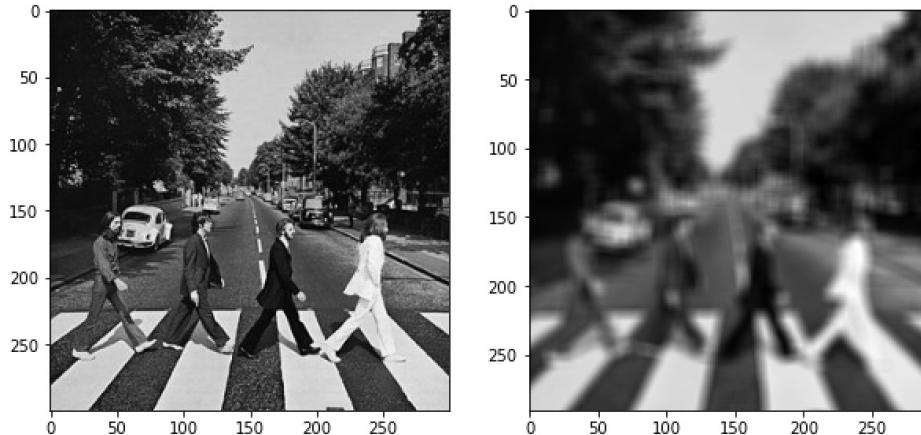
```

blur_filter = np.full((10, 10), 1 / 100)
img_conv = conv(gray_img_data, blur_filter)

figure = plt.gcf()
figure.set_size_inches((10, 10))
plt.subplot(1, 2, 1)
plt.imshow(gray_img_data, cmap='gray')
plt.subplot(1, 2, 2)
plt.imshow(img_conv, cmap='gray')
plt.show()

```

Bu filtrelemeden şu görüntüler elde edilmiştir:



Şimdi de başka bir filtre deneyelim:

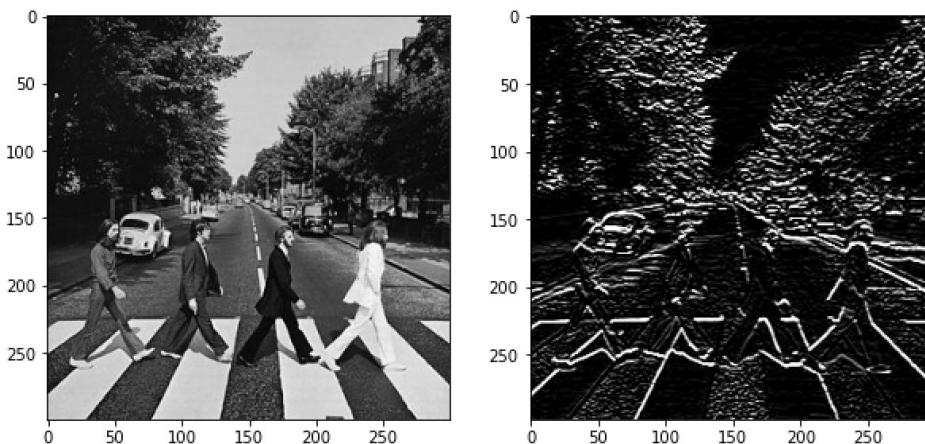
```

sobel_filter = np.array([[-1, -2, -1], [0, 0, 0], [1, 2, 1]])
img_conv = conv(gray_img_data, sobel_filter)

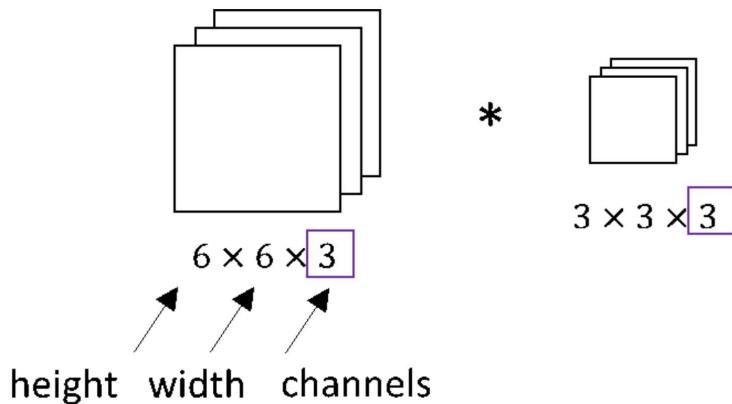
figure = plt.gcf()
figure.set_size_inches((10, 10))
plt.subplot(1, 2, 1)
plt.imshow(gray_img_data, cmap='gray')
plt.subplot(1, 2, 2)
plt.imshow(img_conv, cmap='gray')
plt.show()

```

Buradan da şu görüntüler elde edilmiştir:



Evrışim işlemi gri tonlamalı resimler yerine renkli RGB'li resimler üzerinde de yapılabilmektedir. Gri tonlamalı resimlerdeki NXN'lik filtreleme matrisleri renkli resimlerde NXNX3 biçiminde üç katmanlı olmaktadır. Örneğin gri tonlamalı resimlerdeki 3x3 boyutundaki filtreleme matrisleri renkli resimlerde 3X3X3 boyutunda olur. Bu matrisin her elemanı sırasıyla R, G ve B bileşenleri için kullanılacak 3X3'lük filtreleme matrislerini belirtir. Renkli resimlerde evrişim işlemi sinir ağları için genellikle iki biçimde yapılmaktadır. Birincisinde dot product işleminde sanki üç ayrı resim varmış gibi her renk bileşeni farklı bir filtre matrisiyle dot product işlemeye sokulur, buradan hedef pixel'i belirten 3 değer elde edilir. Örneğin:



Alıntı Notu: Görsel <http://datahacker.rs/convolution-rgb-image/> sitesinden alınmıştır.

İkincisinde yukarıdaki işlemleri yapılır. Yani her renk bileşeni ile farklı bir filtre matrisi dot product işlemeye sokulur ancak buradan elde edilen 3 değer toplanarak teke indirilir. Yani bu yöntemde hedef resim RGB olmaktan çıkarılıp gri tonlamalı hale getirilir. Keras renkli resimler üzerinde evrişimi bu ikinci biçimde olduğu gibi yapmaktadır.

Pekiyi evrişim işlemi yapay sinir ağlarına nasıl uygulanmaktadır? Görüntü işlemede kişi belli filtreleri belirleyerek bunu resme uygulamaktadır. Halbuki yapay sinir ağlarında filtreleme matrisinin kendisini sinir ağı bulmaktadır. Yani işlemler tersten yapılmaktadır. Biz evrişim işlemini yaptığımızı varsayıarak bir ağ modeli oluştururuz. Sonra ağımızı eğitiriz. Bu eğitime göre ağ kendisi bir filtreleme matrisini oluşturmuş olur. Çünkü yapay sinir ağlarında biz aslında neyin filtreleneceğini bilmemekteyiz. Halbuki klasik görüntü işlemede görüntüyü işleyen kişinin bunu bir biçimde bildiği varsayılmaktadır. Yapay sinir ağlarında evrişim işleminde kullanılacak filtreleme matrisindeki değerlerin de ağırlık ve bias değerleri gibi tahmin edilecek değişken sayısına ekleneceğine dikkat ediniz.

Evrısimsel sinir ağlarında evrişim katmanlarında yapılan şey aslında her nöronu birbirine bağlamak (dense bağlantısı) yerine bazı nöronları birbirine bağlamaktır. Böylece biz her filtreleme matrisi ile evrişim işlemi yaptığımızda buradaki dot-product aslında nöron bağlantıları anlamına gelmektedir. Örneğin şeklimiz yine 6X6'lık olsun ve biz de yine 3x3'lük bir filtre kullanacak olalım:

```

x11 x12 x13 x14 x15 x16
x21 x22 x23 x24 x25 x26
x31 x32 x33 x34 x35 x36
x41 x42 x43 x44 x45 x46
x51 x52 x53 x54 x55 x56
x61 x62 x63 x64 x65 x66

```

```

w11 w12 w13
w21 w22 w23
w31 w32 w33

```

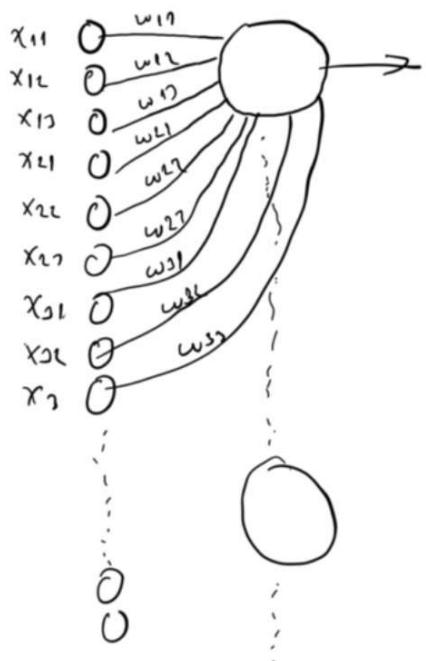
Buradaki filtreleme işlemine dikkatlice bakalım. Örneğin sol-üst köşe hedef matris pixel'i için yapılacak dot-product işlemi şöyledir:

```

x11 * w11 + x12 * w12 + x13 * w13 + x21 * w21 + x22 * w22 + x23 * w23 + x31 * w31 + x32 * w32 +
x33 * w33

```

Bu işlem aslında bir nöron giriş toplam işlemi ile aynıdır. Örneğin:



Burada görüldüğü gibi aslında katmandaki nöron bağlantısı filtreleme matrisi ile asıl resmin ilgili kısımlarının dot-product yapılması ile eşdeğerdir. Başka bir deyişle aslında evrişim işlemi bir katman görevi yapar. Evrişim işlemini yapan katmana yapay sinir ağlarında "evrişim katmanı (convolution layer)" denilmektedir. Ancak bu evrişim katmanında bazı girdi nöronları bazı ağırlıklarla işleme girmektedir.

Pekiyyi yapay sinir ağlarındaki evrişim katmanlarındaki nöron sayıları ve tahmin edilecek parametre sayıları nasıl olacaktır? Evrişim katmanındaki nöron sayısı evrişim sonucunda elde edilecek görüntünün pixel sayısı kadar olacaktır. Çünkü evrişim sırasında filtre matrisini sağa ve aşağıya her kaydırduğumda aslında evrişim katmanında yeni bir nöron oluşturmuş gibi oluruz. Daha önce de belirttiğimiz gibi biz padding durumuna göre hedef görüntü matrisini asıl matrisle aynı boyutta ya da ondan daha küçük bir boyutta elde edebilmekteyiz. Yukarıdaki son örneğimizde ana resim 6x6 boyutunda filtre matrisi de 3x3 boyutundaydı. Bu durumda hedef görüntü matrisi padding yapılmışsa 6x6 boyutunda, padding yapılmamışsa 4x4 boyutunda olacaktır. Dolayısıyla evrişim katmanında da padding yapılmışsa 36 nöron, padding yapılmamışsa 16 nöron bulunacaktır. Öte yandan evrişim katmanında tahmin edilecek parametre sayısı filtre matrisindeki eleman sayısından 1 fazla olacaktır. Çünkü biz filtre matrisini sağa ve aşağı kaydırduğumda aslında filtre matrisindeki hep aynı değerlerle evrişim yapmış olmaktadır. Dolayısıyla yukarıdaki örnekte 3x3'lük filtre matrisi için padding yapılsın ya da yapılmamasın filtre matrisi nedeniyle tahmin edilecek parametre sayısı 9 olacaktır. Evrişim katmanında oluşan nöronların hepsinin bias değeri aynıdır. Yani nasıl her nöronda tahmin edilecek parametreler aslında aynıysa her nörondaki bias değeri de aynıdır. Bu nedenle evrişim katmanındaki toplam parametre sayısı filtre matrisinin eleman sayısından 1 fazla olmaktadır. (Nöronlarda bias değerlerinin kullanılıp kullanılmayacağıının da aslında katman sınıflarındaki `use_bias` parametresiyle ayarlandığını anımsayınız. Bu parametrenin default değeri True biçimindedir.)

Pekiyyi tek bir filtreleme işlemi şeklin daha iyi anlaşılmırması için yeterli olmakta mıdır? Genellikle hayır. Çünkü tek bir filtreleme şekli ancak bazı yönleriyle filtreleyemektedir. Filtreleme sayısını atrırırsa (örneğin 32 gibi) şekil başka yönlerden de tanınabilecektir. Dolayısıyla evrişimsel sinir ağlarında evrişim katmanı genellikle tek bir filtre için değil birden fazla filtre için oluşturulmaktadır. Pekiyyi yukarıdaki 6x6'lık resme 32 tane filtre yerleştirirsek evrişimin katmanın parametrik yapısı nasıl olur? Bu durumda evrişim katmanındaki nöron sayısı padding yapılmışsa $36 * 32$ tane, padding yapılmamışsa $16 * 32$ tane olacaktır. Nöronlardaki toplam tahmin edilecek parametre sayısı da $9 * 32 + 32$ tane olacaktır.

Evrişimsel ağlarda evrişim katmanında yine dot-product sonucunun bir aktivasyon fonksiyonuna sokulmaktadır. Evrişim katmanları için de genellikle diğer saklı katmanlarda olduğu gibi "relu" aktivasyon fonksiyonu tercih edilmektedir.

Pekiyi evrişimsel sinir ağlarında evrişim katmanlarının sayısı birden fazla olabilir mi? İşte bir tane evrişimsel katman resimdeki küçük yerelikleri tanıyalıbmaktedir. Halbuki evrişimsel katmanların çıktılarını başka evrişimsel katmanlara bağladığımızda (yanifiltrelemenin üzerine yenidenfiltreleme uyguladığımızda) resmin tanınabildiği yerel bölgeyi büyütmiş oluruz. Uygulamada veri bilimcisi genellikle evrişimsel katmanlardaki nöron sayılarını ikiye katlayarak birden fazla katman oluşturmaktadır. (Yani ilk katman 32, sonrası 64, 128 biçiminde.)

Ayrıca görüntü tanımaya ilişkin ağlarda yalnızca evrişimsel katmanların kullanılması da uygun değildir. Çünkü bu durumda resmin bütününe ilişkin global özellikler gözden kaçırılmış olur. Bu nedenle bu tür ağların mimarilerinde genellikle önce birkaç evrişimsel katman daha sonra bir ya da birden fazla dense katman kullanılmaktadır. Böylece hem yerel öğeler hem de global özellikler ağa tarafından tanınabilmektedir.

Aslında evrişim işlemi tek boyutlu veriler üzerinde de uygulanabilmektedir. Tabii bu durumdafiltreleme matrisi de matris değil tek boyutlu bir dizi olacaktır. Örneğin evrişim işlemine sokacağımız dizi şöyle olsun:

2 3 5 1 4 6

Kullanacağımız filtre dizisi de şöyledir:

1 2 3

Bu filtre dizisini aynı biçimde asıl dizi üzerinde kaydırarak dot product işlemi yaparsak şöyledir:

23 15 19 27

Keras'ta Evrişimsel Sinir Ağlarının Oluşturulması

Keras yüksek seviyeli bir kütüphane olduğu için evrişim işlemi de yüksek seviyeli bir biçimde gerçekleştirilmektedir. Programcı yalnızca filtre matrislerinin boyutunu, sayısını, padding yapılmış yapılmayacağı ve stride değerini belirtmektedir. Tabii aslında bu değerlerin bazıları default argüman almış durumdadır. Evrişim işlemi tek boyutlu, iki boyutlu ya da üç boyutlu olarak da yapılabilmektedir. Biz burada iki boyutlu evrişim işlemi üzerinde duracağız.

Keras'ta iki boyutlu evrişim işlemleri için Conv2D sınıfı kullanılmaktadır. Yani tipki Dense nesnesi gibi programcı Conv2D nesnelerini yaratarak modeline ekler. Conv2D sınıfının `__init__` metodunun parametrik yapısı şöyledir:

```
tf.keras.layers.Conv2D(  
    filters,  
    kernel_size,  
    strides=(1, 1),  
    padding='valid',  
    data_format=None,  
    dilation_rate=(1, 1),  
    groups=1,  
    activation=None,  
    use_bias=True,  
    kernel_initializer='glorot_uniform',  
    bias_initializer='zeros',  
    kernel_regularizer=None,  
    bias_regularizer=None,  
    activity_regularizer=None,  
    kernel_constraint=None,  
    bias_constraint=None,  
    **kwargs  
)
```

Fonksiyonun birinci parametresi kullanılacak filtre sayısını belirtmektedir. İkinci parametre filtre matrisinin boyutlarını belirtir. Bu parametre demet olarak girilmelidir. Fonksiyonun stride parametresi stride miktarını yatay ve düşey olarak bir demet biçiminde alır. Bu parametrenin default değerinin (1, 1) olduğuna dikkat ediniz. padding parametresi ya 'valid' değerini alabilir ya da 'same' değerini alabilir. Bu parametrede 'valid' değeri padding

yapılmayacağını, 'same' değeri ise ise padding yapılacağını belirtmektedir. Ayrıca fonksiyonda bir input_shape parametresinin olduğunu da görürsünüz. Bu parametre girdi katmanının boyutunu belirlemekte kullanılmaktadır. Girdi katmanı Conv2D katmanında matrisel biçimde üç boyutlu olarak girilmelidir. Bu üç boyutun birinci ve ikinci boyutları resmin genişliğini, üçüncü boyut ise resmin kanal sayısını (yani resimdeki pixel'lerin kaç rengin bileşimi ile ifade edildiğini) belirtmektedir. Örneğin gri tonlamalı MNIST resimleri için input_shape = (28, 28, 1) biçiminde olmalıdır.

Conv2D katmanından elde edilen çıktı üç boyutlu olmaktadır. Bu nedenle iki Conv2D katmanı birbirine bağlanabilir. Dense katmanının tek boyutlu girdi beklediğini anımsayınız. Bu nedenle Conv2D katmanının çıktısı Dense katmana bağlanacaksa üç boyutlu çıktının tek boyuta dönüştürülmesi gereklidir. Bu dönüştürme Flatten isimli katmanla yapılmaktadır. Flatten sınıfının __init__ metodunun parametrik yapısı şöyledir:

```
tf.keras.layers.Flatten(  
    data_format=None,  
    **kwargs  
)
```

Metot tipik olarak parametresiz kullanılmaktadır. Flatten katmanı çok boyutlu girdiyi tek boyuta dönüştürmekten başka bir şey yapmaz. Yani bir çeşit adaptör katman görevindedir.

Şimdi öğrendiklerimizden hareketle MNIST örneğinin evrişimsel modelini oluşturmaya çalışalım. Önce modeli yükleyelim:

```
from tensorflow.keras.datasets import mnist  
  
(training_set_x, training_set_y), (test_set_x, test_set_y) = mnist.load_data()
```

Burada training_dataset_x (60000, 28, 28) boyutundadır. Conv2D katman nesnesini kullanabilmemiz için bizim bu matrisi (60000, 28, 28, 1) haline getirmemiz gereklidir. Çünkü Conv2D katmanı üç boyutlu bir matrisi girdi olarak istemektedir. Aynı işlemi test_dataset_x için de yapmalıyız:

```
training_dataset_x = training_dataset_x.reshape(-1, 28, 28, 1)  
test_dataset_x = test_dataset_x.reshape(-1, 28, 28, 1)
```

Şimdi Min-Max ölçeklendirmesini yapalım:

```
training_dataset_x = training_dataset_x / 255  
test_dataset_x = test_dataset_x / 255
```

Şimdi de kategorik y verileri üzerinde one hot encoding işlemini uygulayalım:

```
from tensorflow.keras.utils import to_categorical  
  
training_dataset_y = to_categorical(training_dataset_y)  
test_dataset_y = to_categorical(test_dataset_y)
```

Artık modelimizi oluşturabiliriz:

```
from tensorflow.keras.models import Sequential  
from tensorflow.keras.layers import Conv2D, Dense, Flatten  
  
model = Sequential()  
model.add(Conv2D(32, kernel_size=(3, 3), padding='same', input_shape=(28, 28, 1),  
activation='relu', name='Convolution-1'))  
model.add(Conv2D(64, kernel_size=(3, 3), padding='same', activation='relu', name='Convolution-  
2'))  
model.add(Flatten(name='Flatten'))  
model.add(Dense(128, activation='relu', name='Hidden-1'))  
model.add(Dense(128, activation='relu', name='Hidden-2'))
```

```
model.add(Dense(10, activation='softmax', name='Output'))  
model.summary()
```

Buradan elde edilen özet şöyledir:

Layer (type)	Output Shape	Param #
Convolution-1 (Conv2D)	(None, 28, 28, 32)	320
Convolution-2 (Conv2D)	(None, 28, 28, 64)	18496
Flatten (Flatten)	(None, 50176)	0
Hidden-1 (Dense)	(None, 128)	6422656
Hidden-2 (Dense)	(None, 128)	16512
Output (Dense)	(None, 10)	1290

Total params: 6,459,274
Trainable params: 6,459,274
Non-trainable params: 0

Pekiyi buradaki parametre değerleri nereden geliyor? Birinci evrişimsel katmanda 3×3 'lük bir filtre matrisi kullandık. Bu katmandaki nöronların hepsi için ortak bir bias değeri de olacağına göre bu katmanda tahmin edilecek parametre sayısı $32 * 9 + 32 = 320$ tane olacaktır. Evrişimsel katmandaki padding parametresinin 'same' biçiminde girildiğine dikkat ediniz. Bu durumda bu katmanın çıkışında $(28, 28, 1)$ boyutlarına sahip 32 nöron bulunacaktır. O halde ikinci evrişimsel katmanın girdisi $(28, 28, 32)$ biçiminde bir matris olacaktır. İkinci katmanda 3×3 'lük 64 filtre matrisinin kullanıldığını görüyorsunuz. Birinci katmanın çıkışında 28×28 'lik toplam 32 resim vardır. Bu resimlerden her biri farklı bir filtre matrisiyle işleme sokulacağına göre ve bu katmanda da 64 filtre kullanılacağına göre bu katmanda tahmin edilecek parametre sayısı $64 * 32 * 9 + 64 = 18496$ olacaktır. Pekiyi ikinci evrişim katmanının çıkışında kaç nöron vardır? Bu katmanın girişinde 28×28 'lik resimlerden 32 tane bulunmaktadır. Ancak evrişim katmanlarının girdilerinin hepsine aynı filtreler uygulanmaktadır. Dolayısıyla aslında bu 32 resmin hepsine aynı filtreler uygulanacaktır. Bu ikinci katmanda 64 tane filtre olduğuna göre bu katmanın çıkışında toplam $28 * 28 * 64 = 50176$ nöron bulunur. İkinci evrişim katmanından sonra Flatten katmanı ile bu katmandaki nöronların tek boyutlu hale getirildiğini görüyorsunuz. Bundan sonra modelde 128 nöronluğ bir Dense katman kullanılmıştır. Böylece bu Dense katmanda tahmin edilecek parametrelerin sayısı da $50176 * 128 + 128 = 6422656$ olur. İlk Dense katmanın çıktısında 128 nöronun bulunduğuna dikkat ediniz. Bu durumda ikinci Dense katmanda tahmin edilecek parametrelerin sayısı $128 * 128 + 128 = 16512$ tanedir. İkinci Dense katmanın çıktısında yine 128 nöron olduğuna göre ve bu 128 nöron çıktı katmanındaki nöronlarla dense bağlılığına göre çıktı katmanında tahmin edilecek parametrelerin sayısı $128 * 10 + 10 = 1290$ 'dır.

Şimdi modelimizi eğitelim:

```
model.compile(optimizer='adam', loss='categorical_crossentropy',  
metrics=['categorical_accuracy'])  
hist = model.fit(training_dataset_x, training_dataset_y, epochs=10, batch_size=64,  
validation_split=0.2)
```

Epoch grafiklerini çizdirelim:

```
import matplotlib.pyplot as plt  
  
figure = plt.gcf()  
figure.set_size_inches((15, 5))  
plt.title('Loss - Epoch Graphics')  
plt.xlabel('Epoch')  
plt.ylabel('Loss')  
plt.plot(range(1, len(hist.history['loss']) + 1), hist.history['loss'])  
plt.plot(range(1, len(hist.history['val_loss']) + 1), hist.history['val_loss'])
```

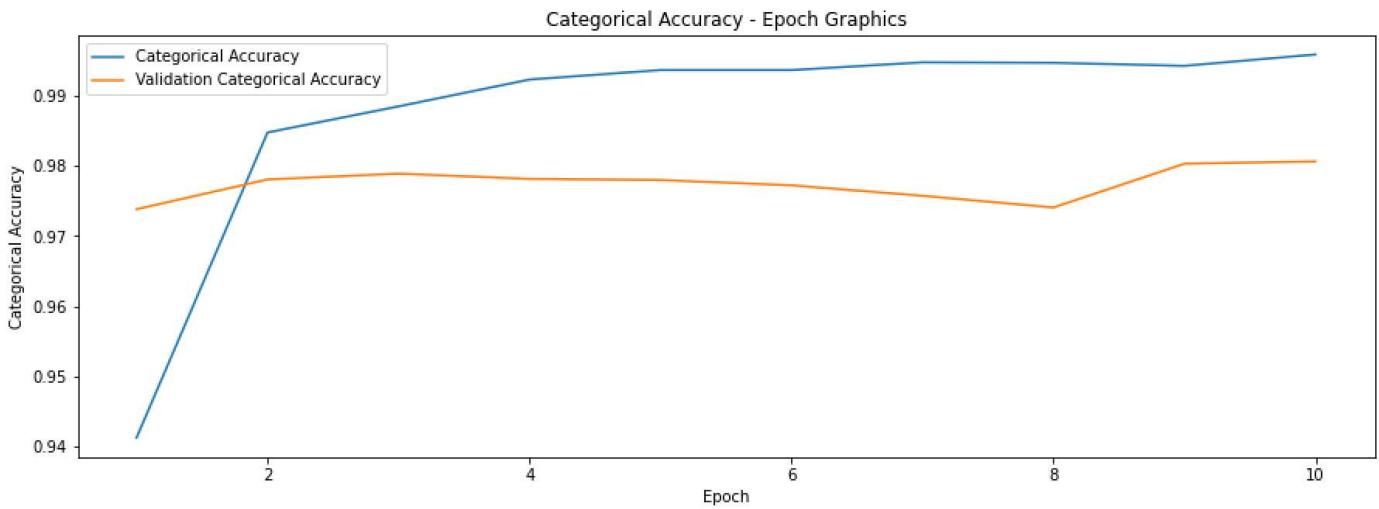
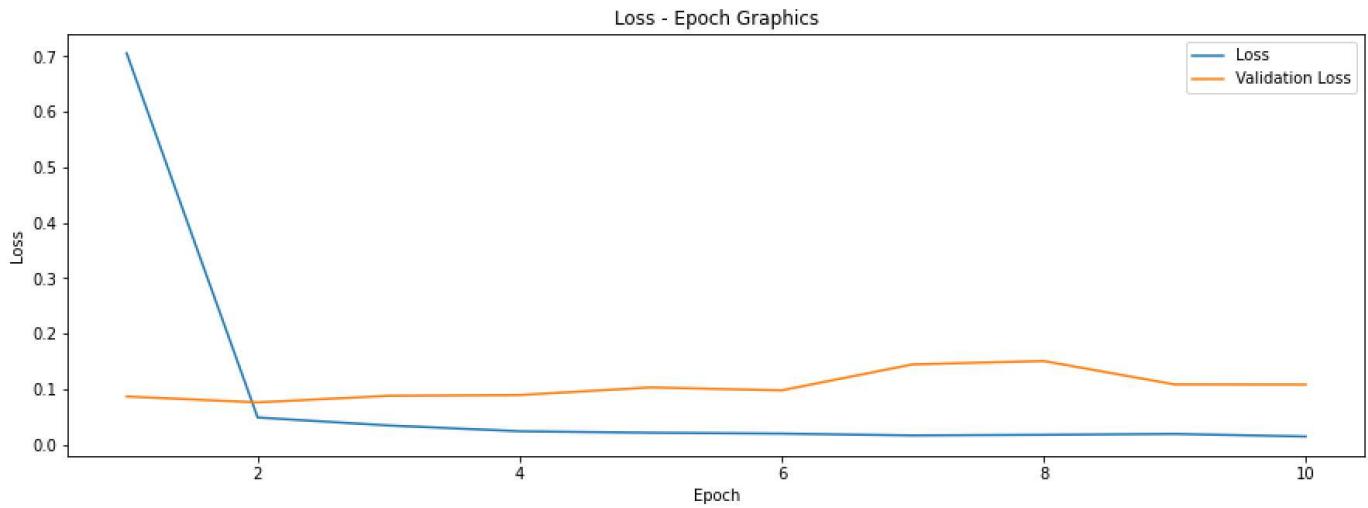
```

plt.legend(['Loss', 'Validation Loss'])
plt.show()

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Categorical Accuracy - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Categorical Accuracy')
plt.plot(range(1, len(hist.history['categorical_accuracy']) + 1),
hist.history['categorical_accuracy'])
plt.plot(range(1, len(hist.history['val_categorical_accuracy']) + 1),
hist.history['val_categorical_accuracy'])
plt.legend(['Categorical Accuracy', 'Validation Categorical Accuracy'])
plt.show()

```

Epoch-Accuracy grafiğini de çizelim:



Grafiklerden eğitim için 2 epoch işleminin yeterli olduğu görülmektedir. Modelimizi bu haliyle test edelim:

```

eval_result = model.evaluate(test_dataset_x, test_dataset_y)
for i in range(len(eval_result)):
    print(f'{model.metrics_names[i]} --> {eval_result[i]}')

```

Şu sonuçlar elde edilmiştir:

```

loss --> 0.11871606111526489
categorical_accuracy --> 0.9775999784469604

```

Yukarıdaki örneğin kaynak kodlarını bütün halinde şöyle verebiliriz:

```
from tensorflow.keras.datasets import mnist

(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) = mnist.load_data()

training_dataset_x = training_dataset_x.reshape(-1, 28, 28, 1)
test_dataset_x = test_dataset_x.reshape(-1, 28, 28, 1)

from tensorflow.keras.utils import to_categorical

training_dataset_y = to_categorical(training_dataset_y)
test_dataset_y = to_categorical(test_dataset_y)

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Conv2D, Dense, Flatten

model = Sequential()
model.add(Conv2D(32, kernel_size=(3, 3), padding='same', input_shape=(28, 28, 1),
activation='relu', name='Convolution-1'))
model.add(Conv2D(64, kernel_size=(3, 3), padding='same', activation='relu', name='Convolution-2'))
model.add(Flatten(name='Flatten'))
model.add(Dense(128, activation='relu', name='Hidden-1'))
model.add(Dense(128, activation='relu', name='Hidden-2'))
model.add(Dense(10, activation='softmax', name='Output'))

model.summary()

model.compile(optimizer='adam', loss='categorical_crossentropy',
metrics=['categorical_accuracy'])
hist = model.fit(training_dataset_x, training_dataset_y, epochs=10, batch_size=64,
validation_split=0.2)

import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Loss - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.plot(range(1, len(hist.history['loss']) + 1), hist.history['loss'])
plt.plot(range(1, len(hist.history['val_loss']) + 1), hist.history['val_loss'])
plt.legend(['Loss', 'Validation Loss'])
plt.show()

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Categorical Accuracy - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Categorical Accuracy')
plt.plot(range(1, len(hist.history['categorical_accuracy']) + 1),
hist.history['categorical_accuracy'])
plt.plot(range(1, len(hist.history['val_categorical_accuracy']) + 1),
hist.history['val_categorical_accuracy'])
plt.legend(['Categorical Accuracy', 'Validation Categorical Accuracy'])
plt.show()

eval_result = model.evaluate(test_dataset_x, test_dataset_y)
for i in range(len(eval_result)):
    print(f'{model.metrics_names[i]} --> {eval_result[i]}')
```

Evrişim işlemi tek boyutlu veriler üzerinde de yapılabilmektedir. Tabii bu durumda evrişime sokulacak olan veri ve evrişimde kullanılacak filtre de tek boyutlu olur. Örneğin evrişime sokulacak vektör şöyle olsun:

```
[4, 6, 2, 8, 5, 3, 9]
```

Filtre vektörünün de şöyle olduğunu varsayıyalım:

```
[1, 2, 3]
```

Bu durumda padding yapılmadığı durumda stride=1 için evrişimden elde edilecek vektör de şöyle olacaktır:

```
[22, 34, 33, 27, 40]
```

Evrişim işlemi zamansal (temporal) veriler üzerinde de uygulanabilmektedir. Burada zamansallık söz konusu değerler arasında öncelik sonralık ilişkisinin olması anlamına gelmektedir. Örneğin yazılardaki sözcükler, videolardaki görüntüyü oluşturan frame'ler, EEG, EKG verileri zamansal verilere örnek olarak verilebilir.

Keras'ta parçalı (zamansal) vektörler üzerinde evrişim işlemi yapmak için de Conv1D isimli bir katman sınıfı bulundurulmuştur. Conv1D sınıfının `__init__` metodunun parametrik yapısı şöyledir:

```
tensorflow.keras.layers.Conv1D(  
    filters,  
    kernel_size,  
    strides=1,  
    padding='valid',  
    data_format='channels_last',  
    dilation_rate=1,  
    groups=1,  
    activation=None,  
    use_bias=True,  
    kernel_initializer='glorot_uniform',  
    bias_initializer='zeros',  
    kernel_regularizer=None,  
    bias_regularizer=None,  
    activity_regularizer=None,  
    kernel_constraint=None,  
    bias_constraint=None,  
    **kwargs  
)
```

Metodun birinci parametresi kullanılacak toplam filtre sayısını, ikinci parametresi ise filtre genişliğini belirtmektedir. stride parametresi filtrenin kaydırma miktarını belirlemekte kullanılır. Yine padding parametresi 'valid' ya da 'same' biçiminde girilebilmektedir.

Conv1D katmanının girdisinin matrisin olması gereklidir. Ancak evrişim Conv2D katmanında olduğu gibi yapılmaz. Matrisin satır ve sütunları üzerinde yapılmaktadır. Bu nedenle Conv1D katmanı tipik olarak parçalı (zamansal) girdiler üzerinde uygulanmaktadır. Şimdi Conv1D katmanının yaptığı evrişim işlemini açıklayalım.

Conv1D katmanı için zamansal bir verinin 20 satır ve 10 sütundan oluştuğunu varsayıyalım. Verilerin her satırı yazındaki bir sözcük, videodaki bir frame gibi zamansal bir girdiyi temsil ediyor olsun. Bu verinin görünümü aşağıdakine benzer olacaktır:

```
[[116, 103, 32, 110, 78, 145, 250, 41, 8, 13],  
 [ 59, 61, 225, 25, 73, 224, 43, 46, 180, 208],  
 [232, 66, 76, 243, 233, 98, 191, 249, 209, 101],  
 [156, 190, 77, 58, 161, 246, 54, 250, 52, 105],  
 [ 13, 226, 25, 82, 74, 165, 181, 104, 17, 203],  
 [124, 241, 42, 163, 230, 97, 157, 13, 155, 207],
```

```
[ 96,  45, 137, 134, 189, 238, 132,  34, 162, 176],  
.....  
[235, 197, 185,  49, 164,   6, 229, 232,    8, 162],  
[ 11, 192, 110,  73, 132, 130,  92, 234,  58, 198],  
[174,  21, 213, 178, 237, 159, 226, 165, 220]])
```

Buradaki satırlar aslında zamansal verileri temsil etmektedir. Dolayısıyla aslında ardışık satırlar veride peşi sıra gelen değerlere ilişkiiidir. O halde padding kullanılmayan evrişim işleminde satırlar üçer üçer işleme sokulacaktır. Yani ilk evrişimde ilk üç satır işleme sokulur:

```
[116, 103,  32, 110,  78, 145, 250,  41,   8,  13]  
[ 59,  61, 225,  25,  73, 224,  43,  46, 180, 208]  
[232,  66,  76, 243, 233,  98, 191, 249, 209, 101]
```

Sonra strides = 1 olduğuna göre 1 satır kaydırılarak sonraki 3 satır işleme sokulur:

```
[ 59,  61, 225,  25,  73, 224,  43,  46, 180, 208],  
[232,  66,  76, 243, 233,  98, 191, 249, 209, 101],  
[156, 190,  77,  58, 161, 246,  54, 250,  52, 105],
```

Bu işlem böyle devam ettirilir. Burada evrişime sokulacak verilerin 3x10'luk bir matris olduğunu görüyorsunuz. Uygulamada bu matrisin her bir elemanı ayrı bir değerle dot product yapılmaktadır. Yani her ne kadar filtre uzunluğu 3 biçiminde belirtiliyorsa da aslında filtre 3X10'luk gibi düşünülmeliidir.

Şimdi Keras'ta filtre genişliğinin 3, strides değerinin 1 olduğu padding yapılmış Conv1D katmanını kullanarak özet bilgileri görüntüleyelim. Model aşağıdaki gibi oluşturulmuş olsun:

```
from tensorflow.keras.models import Sequential  
from tensorflow.keras.layers import Conv1D  
  
model = Sequential(name='Conv1D-Test')  
model.add(Conv1D(1, 3, padding='same', activation='relu', input_shape=(100, 10),  
name='Conv1D'))  
model.summary()
```

Şöyledir bir summary çıktısı elde edilmişdir:

Model: "Conv1D-Test"

Layer (type)	Output Shape	Param #
Conv1D (Conv1D)	(None, 100, 1)	31
<hr/>		
Total params: 31		
Trainable params: 31		
Non-trainable params: 0		

Burada 100 satırlık her bir satırı 10 sütundan oluşan zamansal veriler söz konusudur. Bu durumda kullanılacak filtrenin eleman sayısı aslında $3 * 10 = 30$ tanedir. Dolayısıyla bias değerini debuna eklersek bu katmanda tahmin edilecek parametre sayısı 31 olacaktır. Şimdi aşağıdaki modele bakınız:

```
from tensorflow.keras.models import Sequential  
from tensorflow.keras.layers import Conv1D, Flatten, Dense  
  
model = Sequential(name='Conv1D-Test')  
model.add(Conv1D(1, 3, padding='same', activation='relu', input_shape=(100, 10),  
name='Conv1D'))  
model.add(Flatten(name='Flatten'))
```

```

model.add(Dense(128, activation='relu', name='Dense'))
model.add(Dense(1, activation='sigmoid', name='Output'))

model.summary()

```

Buradan şu summary bilgileri elde edilmiştir:

Model: "Conv1D-Test"

Layer (type)	Output Shape	Param #
<hr/>		
Conv1D (Conv1D)	(None, 100, 1)	31
Flatten (Flatten)	(None, 100)	0
Dense (Dense)	(None, 128)	12928
Output (Dense)	(None, 1)	129
<hr/>		
Total params: 13,088		
Trainable params: 13,088		
Non-trainable params: 0		

Burada yine aynı Conv1D katmanı kullanılmıştır. Pekiyi Conv1D katmanın çıktılarında kaç nöron vardır? İşte aslında her 3'lü kaydırma bir nöronla temsil edildiğine göre ve padding='same' alındığına göre katmanın çıktılarında 100 nöron bulunmaktadır. Ancak Conv1D katmanın çıktısının tek boyutlu değil matrisel olduğuna da dikkat ediniz. Bu durumda biz Conv1D katmanın çıktısını Dense bir katmana doğrudan bağlayamayız. Önce bir Flatten işlemini yapmamız gereklidir.

Conv1D katmanında tahmin edilecek parametre sayısının filtre genişliği ile zamansal girdilerin sütun uzunlıklarından bir fazla olduğuna dikkat ediniz. Katmanın çıktı nöronlarının sayısı da eğer padding='same' yapılmışsa zamansal verilerdeki satır sayısı kadardır.

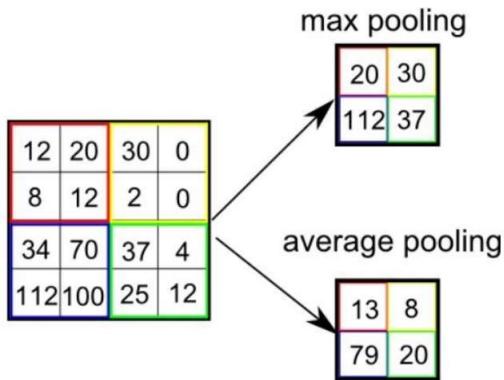
Evrışimsel Sinir Ağlarında Nöron Sayılarının Azaltılması (Downsampling)

Yukarıda da belirttiğimiz gibi evrişimsel ağlar özellikle görüntü tanımda çok kullanılmaktadır. Görüntü verileri de büyük olma eğilimindedir. (Her ne kadar MNIST görselleri 28x28'lik gri tonlamalı olsa da aslında gerçek yaşam uygulamalarında çoğu görsel daha yüksek çözünürlükte ve RGB biçimindedir.) Örneğin önceki bölümdeki MNIST modelinde oluşturduğumuz evrişimsel ağda 6 milyonun üzerinde ağırlık değerleri tahmin edilmeye çalışılmaktadır. Modelde çok nöronun olmasının şu dezavantajları söz konusudur:

- Modelin eğitilmesi fazla zaman alır.
- Model verilerinin saklanması sırasında daha fazla disk alanına gereksinim duyulur.
- Modeldeki parametre sayılarının artması da "overfitting" kaynağı olabilmektedir.

İşte bu nedenlerden dolayı modeldeki nöron sayılarını azaltmak isteyebiliriz. Bunun için ilk akla gelen yöntem evrişimsel katmalardaki stride değerinin yükseltilmesidir. (Biz yukarıdaki örnekte default stride değerini 1 almıştık.) Ancak stride yönteminden daha etkin olduğu düşünülen "pooling" isimli bir yöntem vardır. Pooling yöntemi genellikle 2x2'lik bir matrisle ve stride = 2 olarak uygulanmaktadır.

Pooling işlemleri iki temel yöntemle yapılmaktadır: Max-Pooling ve Average-Pooling. Max-Pooling yönteminde pooling büyülüğu kadarki (örneğin 2x2) matristeki en büyük eleman bulunur ve pooling büyülüüğündeki tüm değerler bu en büyük elemanla temsil edilir. Average-Pooling yönteminde ise pooling büyülüğu kadarki elemanların ortalaması alınarak pooling büyülüüğündeki elemanlar bu ortalama değerle temsil edilmektedir. Max-Pooling yöntemi Average-Pooling yöntemine göre daha yaygın kullanılmaktadır. Örneğin:



Aıntı Notu: Görüel <https://medium.com/pursuitnotes/day-41-deep-learning-6-cnn-2-d38b355bd0ba> adresinden alınmıştır.

İki boyutlu matrisler üzerinde Max-Pooling ve Average-Pooling işlemleri için tensorflow.keras.layers modülünde MaxPooling2D ve AveragePooling2D isimli iki katman sınıfı bulunmaktadır. Bu sınıfların `__init__` metodlarının parametrik yapısı şöyledir:

```
tf.keras.layers.MaxPool2D(
    pool_size=(2, 2),
    strides=None,
    padding='valid',
    data_format=None,
    **kwargs
)

tf.keras.layers.AveragePooling2D(
    pool_size=(2, 2),
    strides=None,
    padding='valid',
    data_format=None,
    **kwargs
)
```

Metotların `pool_size` parametreleri pooling işleminde kullanılacak matrisin büyülüüğünü belirtmektedir. Bu parametrenin default değerinin (2, 2) olduğunu görürorsunuz. `stride` parametreleri kaydırma değerlerini belirtmektedir. Buradaki `None` değeri default `stride` değerinin 2 olduğu anlamına gelmektedir. `padding` parametresi yine padding yapılmış yapılmayacağı belirtir. Bu parametrededeki 'valid' değeri padding yapılmayacağı, 'same' değeri padding yapılacak anlamına gelmektedir.

Evrişimsel sinir ağlarında pooling katmanları tipik olarak evrişim katmanlarından hemen sonra bulundurulmaktadır. O halde tipik bir evrişimsel sinir ağı modeli şöyle oluşturulmaktadır:



Şimdi yukarıdaki evrişimsel MNIST modelini pooling katmanlarını ekleyerek yeniden oluşturalım:

```
from tensorflow.keras.datasets import mnist

(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) = mnist.load_data()

training_dataset_x = training_dataset_x.reshape(-1, 28, 28, 1)
test_dataset_x = test_dataset_x.reshape(-1, 28, 28, 1)

from tensorflow.keras.utils import to_categorical

training_dataset_y = to_categorical(training_dataset_y)
test_dataset_y = to_categorical(test_dataset_y)
```

```

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Conv2D, MaxPooling2D, Dense, Flatten

model = Sequential()
model.add(Conv2D(32, kernel_size=(3, 3), padding='same', input_shape=(28, 28, 1),
activation='relu', name='Convolution-1'))
model.add(MaxPooling2D(name='MaxPooling2D-1'))
model.add(Conv2D(64, kernel_size=(3, 3), padding='same', activation='relu', name='Convolution-2'))
model.add(MaxPooling2D(name='MaxPooling2D-2'))
model.add(Flatten(name='Flatten'))
model.add(Dense(128, activation='relu', name='Hidden-1'))
model.add(Dense(128, activation='relu', name='Hidden-2'))
model.add(Dense(10, activation='softmax', name='Output'))

model.summary()

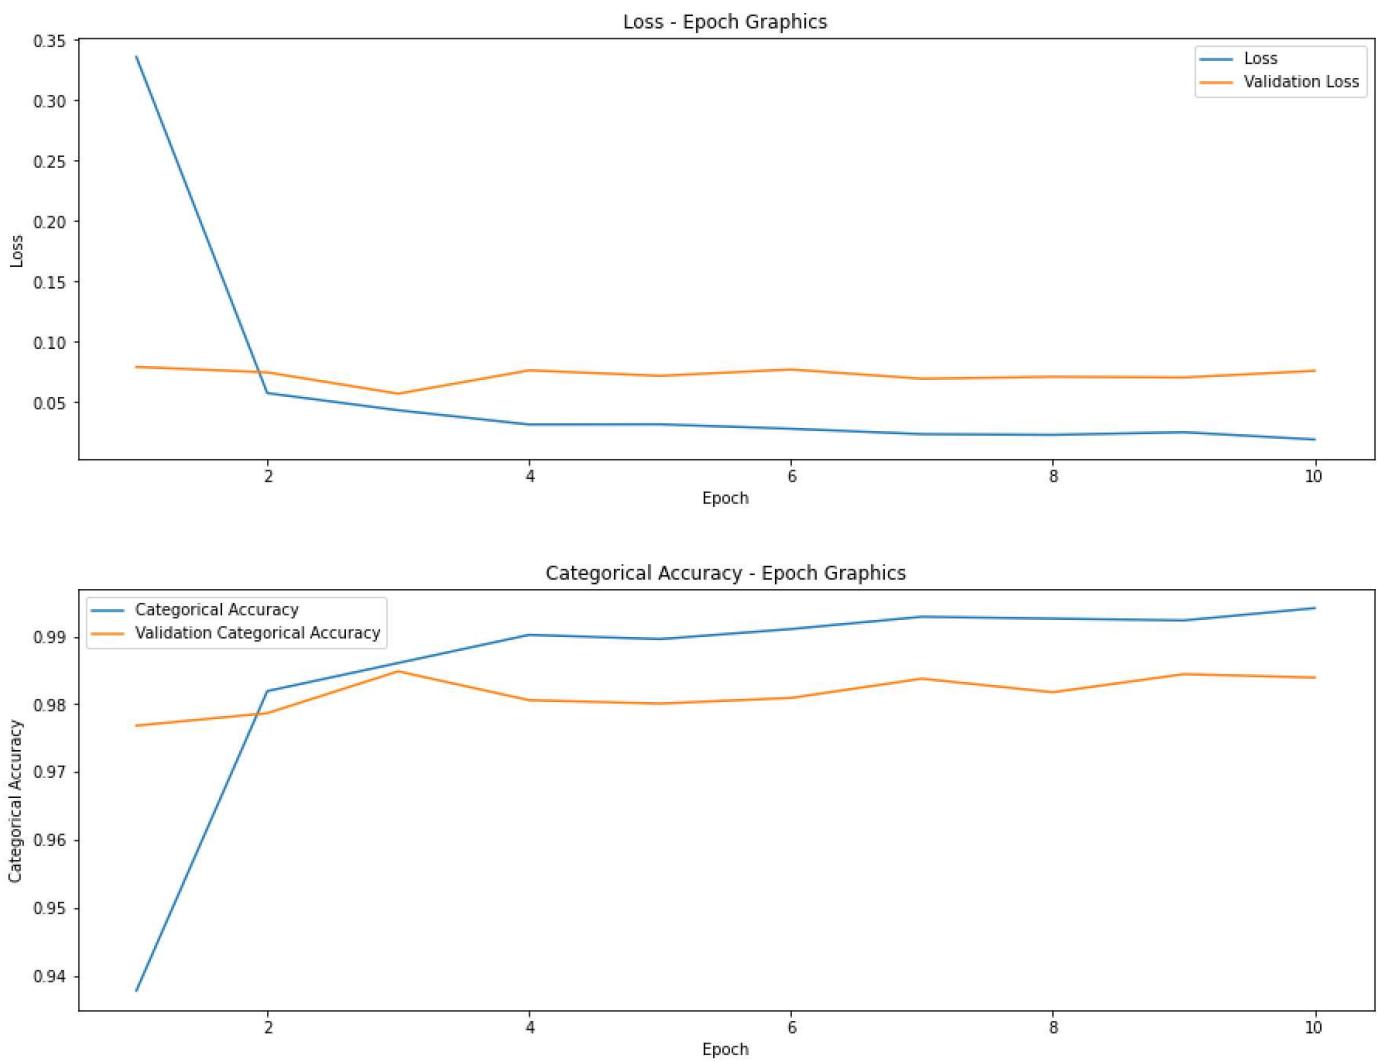
```

summary fonksiyonundan elde edilen çıktı şöyledir:

Layer (type)	Output Shape	Param #
<hr/>		
Convolution-1 (Conv2D)	(None, 28, 28, 32)	320
<hr/>		
MaxPooling2D-1 (MaxPooling2D)	(None, 14, 14, 32)	0
<hr/>		
Convolution-2 (Conv2D)	(None, 14, 14, 64)	18496
<hr/>		
MaxPooling2D-2 (MaxPooling2D)	(None, 7, 7, 64)	0
<hr/>		
Flatten (Flatten)	(None, 3136)	0
<hr/>		
Hidden-1 (Dense)	(None, 128)	401536
<hr/>		
Hidden-2 (Dense)	(None, 128)	16512
<hr/>		
Output (Dense)	(None, 10)	1290
<hr/>		
Total params: 438,154		
Trainable params: 438,154		
Non-trainable params: 0		

Bu özet bilgiden evrişim işlemi sonucunda elde edilen 28x28'luk matrislerin önce 14x14'e sonra da 7x7'ye indirgendiğini görüyorsunuz. Pooling işlemlerinden sonra modelin 6 milyon civarındaki parametre sayısı 400 bin civarına düşürülmüştür.

Şimdi modeli 10 epoch kullanarak eğitelim ve epoch grafiklerine bakalım:



Grafiklere göre eğitim 3 epoch'ta sonlandırılabilir. Şimdi modelimiz test edelim:

```
loss --> 0.0667557567358017
categorical_accuracy --> 0.984499990940094
```

Göründüğü gibi pooling işlemlerinden sonra hem model parametreleri azaltılmış hem de model biraz daha iyileştirilmiştir. Aşağıda örneğin tüm kodlarını yine bütünsel olarak veriyoruz:

```
from tensorflow.keras.datasets import mnist

(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) = mnist.load_data()

training_dataset_x = training_dataset_x.reshape(-1, 28, 28, 1)
test_dataset_x = test_dataset_x.reshape(-1, 28, 28, 1)

from tensorflow.keras.utils import to_categorical

training_dataset_y = to_categorical(training_dataset_y)
test_dataset_y = to_categorical(test_dataset_y)

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Conv2D, MaxPooling2D, Dense, Flatten

model = Sequential()
model.add(
    Conv2D(32, kernel_size=(3, 3), padding='same', input_shape=(28, 28, 1), activation='relu',
    name='Convolution-1'))
model.add(MaxPooling2D(name='MaxPooling2D-1'))
```

```

model.add(Conv2D(64, kernel_size=(3, 3), padding='same', activation='relu', name='Convolution-2'))
model.add(MaxPooling2D(name='MaxPooling2D-2'))
model.add(Flatten(name='Flatten'))
model.add(Dense(128, activation='relu', name='Hidden-1'))
model.add(Dense(128, activation='relu', name='Hidden-2'))
model.add(Dense(10, activation='softmax', name='Output'))

model.summary()

model.compile(optimizer='adam', loss='categorical_crossentropy',
metrics=['categorical_accuracy'])
hist = model.fit(training_dataset_x, training_dataset_y, epochs=10, batch_size=64,
validation_split=0.2)

import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Loss - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.plot(range(1, len(hist.history['loss']) + 1), hist.history['loss'])
plt.plot(range(1, len(hist.history['val_loss']) + 1), hist.history['val_loss'])
plt.legend(['Loss', 'Validation Loss'])
plt.show()

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Categorical Accuracy - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Categorical Accuracy')
plt.plot(range(1, len(hist.history['categorical_accuracy']) + 1),
hist.history['categorical_accuracy'])
plt.plot(range(1, len(hist.history['val_categorical_accuracy']) + 1),
hist.history['val_categorical_accuracy'])
plt.legend(['Categorical Accuracy', 'Validation Categorical Accuracy'])
plt.show()

eval_result = model.evaluate(test_dataset_x, test_dataset_y)
for i in range(len(eval_result)):
    print(f'{model.metrics_names[i]} --> {eval_result[i]}')

```

Pooling işlemleri iki boyutlu görüntü verilerinin dışında tek boyutlu veriler üzerinde de uygulanabilmektedir. Tabii bu durumda pooling büyülüğu iki boyutlu bir matris yerine tek boyutlu bir değer olacaktır. Örneğin aşağıdaki gibi tek boyutlu 10 elemanlı bir vektör söz konusu olsun:

1, 4, 6, 3, 2, 9, 4, 6, 10, 3

Bu vektör üzerinde MaxPooling1D işlemini strides=2 için yaptığımda 5 elemanlı şı vektörü elde ederiz:

4, 6, 9, 6, 10

Keras'ta tek boyutlu pooling işlemleri için MaxPooling1D ve AveragePooling1D sınıfları bulundurulmuştur. Bu sınıfların __init__ metodlarının parametrik yapısı aşağıdaki gibidir:

```

tensorflow.keras.layers.MaxPooling1D(
    pool_size=2,
    strides=None,
    padding='valid',
    data_format='channels_last',

```

```

        **kwargs
    )

tensorflow.keras.layers.AveragePooling1D(
    pool_size=2,
    strides=None,
    padding='valid',
    data_format='channels_last',
    **kwargs
)

```

Metotların birinci parametreleri kullanılacak pool genişliğini belirlemekte kullanılmaktadır. Bu parametrenin default değerinin 2 olduğunu görüyorsunuz. Metotların strides parametreleri kaydırma miktarını belirtmektedir. None değer kaydırmanın pool genişliği kadar yapılacağını belirtir. padding parametreleri yine 'valid' ya da 'same' değerini alabilmektedir.

Renkli Resimlerin Sınıflandırılmasına İlişkin CIFAR-10 Örneği

CIFAR-10 Keras'in içerisinde de var olan eğitimde yaygın kullanılan bir görsel veri kümelerinden biridir. CIFAR-10 içerisinde 60000 tane her biri 32X32 boyutlarında bitmap resimler vardır. Bu resimlerdeki her pixel 3 byte olup Red, Green, Blue tonal bileşenlerini içermektedir. CIFAR-10 çok sınıfı regresyon problemleri için hazırlanmış bir veri kümeleridir. Burdaki her resim 10 sınıf içerisinde birine ilişkindir. Cifar-10'un 100 sınıf içeren CIFAR-100 biçiminde başka bir uyarlaması da bulunmaktadır.

CIFAR-10 içerisinde resimlerin ilişkin olabileceği sınıflar şunlardır:

```
class_names = ['airplane', 'automobile', 'bird', 'cat', 'deer', 'dog', 'frog', 'horse', 'ship', 'truck']
```

Şimdi CIFAR-10 için adım adım evrişimsel sinir ağı modelini oluşturalım. Önce veri kümесini yükleyelim:

```
from tensorflow.keras.datasets import cifar10

(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) =
cifar10.load_data()

class_names = ['airplane', 'automobile', 'bird', 'cat', 'deer', 'dog', 'frog', 'horse', 'ship', 'truck']
```

Okuduğumuz verilerin boyutsal özelliklerini yazdıralım:

```
print(f'training_dataset_x.shape: {training_dataset_x.shape}')
print(f'training_dataset_y.shape: {training_dataset_y.shape}')
print(f'test_dataset_x.shape: {test_dataset_x.shape}')
print(f'test_dataset_y.shape: {test_dataset_y.shape}')
```

Elde edilen çıktı şöyledir:

```
training_dataset_x.shape: (50000, 32, 32, 3)
training_dataset_y.shape: (50000, 1)
test_dataset_x.shape: (10000, 32, 32, 3)
test_dataset_y.shape: (10000, 1)
```

Sınıflar yine 0'dan 9'a kadar bir tamsayı ile ifade edilmiştir. Şimdi ilk 9 resmi deneme amaçlı çizdirelim:

```
import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches(10, 10)
for i in range(1, 10):
```

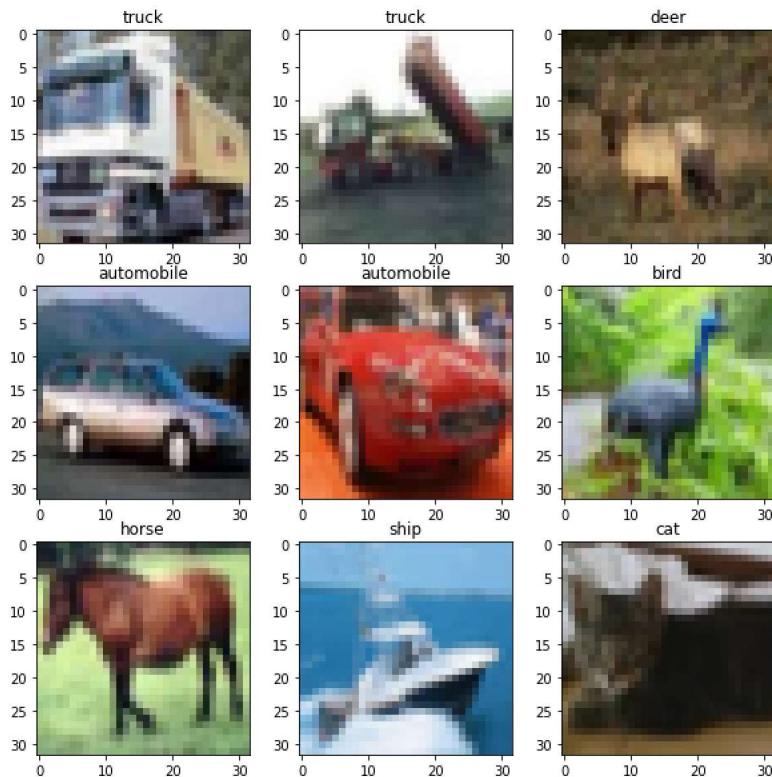
```

plt.subplot(3, 3, i)
axis = plt.gca()
axis.set_title(class_names[training_dataset_y[i, 0]])
plt.imshow(training_dataset_x[i], cmap='gray')

plt.show()

```

Elde edilen görüntü şöyledir:



Şimdi x verilerini Min-Max ölçeklendirmesine sokalım:

Min-max ölçeklendirmesini uygulayalım:

```

training_dataset_x = training_dataset_x / 255
test_dataset_x = test_dataset_x / 255

```

Şimdi training_dataset_y ve test_dataset_y değerleri üzerinde one hot encoding işlemi yapalım:

```

from tensorflow.keras.utils import to_categorical

training_dataset_y = to_categorical(training_dataset_y)
test_dataset_y = to_categorical(test_dataset_y)

```

Artık modelimizi oluşturabiliriz:

```

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Conv2D, Dense, Flatten, MaxPooling2D

model = Sequential()
model.add(Conv2D(32, kernel_size=(3, 3), input_shape=(32, 32, 3), activation='relu',
name='Convolution-1'))
model.add(MaxPooling2D(name='MaxPooling-1'))
model.add(Conv2D(64, kernel_size=(3, 3), activation='relu', name='Convolution-2'))
model.add(MaxPooling2D(name='MaxPooling-2'))
model.add(Flatten(name='Flatten'))
model.add(Dense(128, activation='relu', name='Hidden-1'))

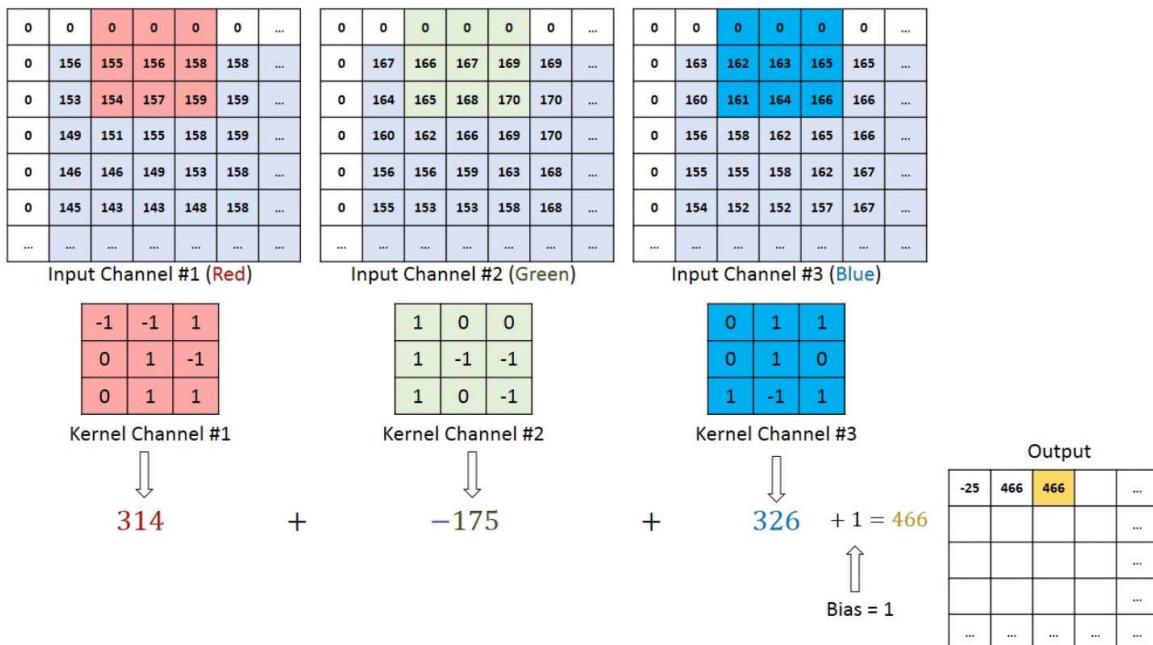
```

```
model.add(Dense(10, activation='softmax', name='Output'))  
model.summary()
```

Buradan elde edilen özet bilgiler şöyledir:

Layer (type)	Output Shape	Param #
<hr/>		
Convolution-1 (Conv2D)	(None, 32, 32, 32)	896
<hr/>		
Pooling-1 (MaxPooling2D)	(None, 16, 16, 32)	0
<hr/>		
Convolution-2 (Conv2D)	(None, 16, 16, 64)	18496
<hr/>		
Pooling-2 (MaxPooling2D)	(None, 8, 8, 64)	0
<hr/>		
Flatten (Flatten)	(None, 4096)	0
<hr/>		
Hidden-1 (Dense)	(None, 128)	524416
<hr/>		
Hidden-2 (Dense)	(None, 128)	16512
<hr/>		
Output (Dense)	(None, 10)	1290
<hr/>		
Total params: 561,610		
Trainable params: 561,610		
Non-trainable params: 0		

Öncelikle önce Keras'in Conv2D katmanının RGB resimler üzerinde nasıl evrişim işlemi uyguladığı hakkında bir açıklama yapmak istiyoruz. Keras RGB resimlerin her bir kanalı için ayrı filtreler kullanmakla birlikte bu ayrı filtrelerden elde ettiği dot product değerlerini toplayıp tek bir değer elde etmektedir. Yapılan işlemi aşağıdaki şekilde özetleyebiliriz:



Alıntı Notu: Görsel <https://stackoverflow.com/questions/43306323/keras-conv2d-and-input-channels> adresinden elde edilmiştir.

Yani Keras adeta RGB resimlerin evrişiminden sanki gri tonlamalı bir resim elde ediyor gibi davranmaktadır.

Şimdi de model özet bilgilerinde belirtilen değerlerin nereden geldiğine ilişkin bazı açıklamalar yapmak istiyoruz. Birinci evrişim katmanının girdisi 32x32'lik 3 kanallı resimdir. Bu katmanda 3x3'lük filtre matrisi kullanılmıştır. Her kanal için ayrı bir filtre oluşturulacağına göre ve toplam 32 farklı filtre olacağına göre bu katmanda tahmin edilecek parametrelerin sayısı $9 * 3 * 32 + 32 = 896$ olacaktır. Yukarıda da belirttiğimiz gibi evrişim işleminden 32X32X1'lik 32 matris oluşmaktadır. Toplamladaki 32 değeri katmanın çıktısından oluşturulacak 32 resim için gereken bias değerinden gelmektedir. Pooling-1 katmanında MaxPooling2D işlemi 2x2'lik bir matris için uygulanmıştır. Böylece 32x32x32'lik matris 16x16x32'ye düşürülmüştür. Sonra 32 resim Convolution-2 katmanına sokulmuştur. Bu katmanda tahmin edilecek parametre sayısı $32 * 9 * 64 + 64 = 18496$ olacaktır. Bu katmandan 16x16x1'lik 64 resim elde edilecektir. Bu resimler Pooling-2 katmanına sokulduğunda 8x8'lik 64 resme dönüştürülür. Sonra bu 8x8'lik 64 resim Flatten katmanıyla tek boyutlu hale getirilmiştir. Buradan toplam $64 * 64 = 4096$ tane nöron elde edilmektedir. Sonra bu 4096 nöron Dense-1 katmanına bağlanmıştır. Bu katmanda tahmin edilecek parametre sayısı $4096 * 128 + 128 = 524416$ olacaktır. Dense-2 katmanın 128 girişi olacağına göre o katmandaki tahmin edilecek parametre sayısı da $128 * 128 + 128 = 16512$ 'dir. Nihayet Output katmanının girdi sayısı 128 olduğuna göre orada tahmin edilecek parametre sayısı da $128 * 10 + 10 = 1290$ olacaktır.

Artık modelimizi derleyip eğitebiliriz:

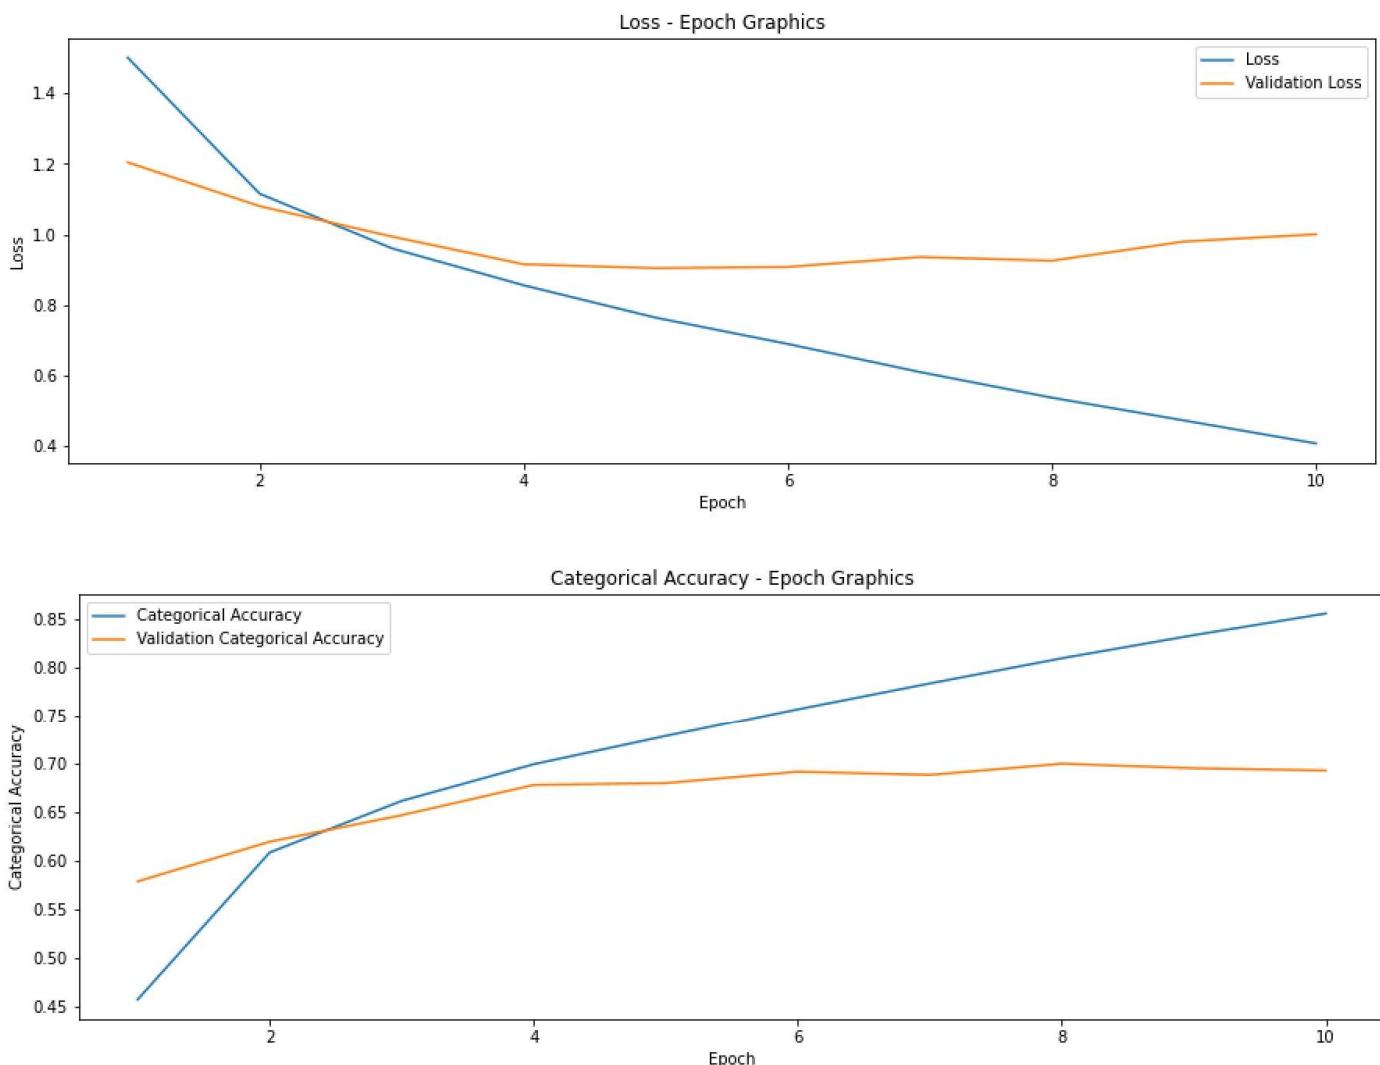
```
model.compile(optimizer='adam', loss='categorical_crossentropy',
metrics=['categorical_accuracy'])
hist = model.fit(training_dataset_x, training_dataset_y, epochs=10, batch_size=64,
validation_split=0.2)
```

Şimdi de Epoch grafiklerini çizdirelim:

```
import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Loss - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.plot(range(1, len(hist.history['loss']) + 1), hist.history['loss'])
plt.plot(range(1, len(hist.history['val_loss']) + 1), hist.history['val_loss'])
plt.legend(['Loss', 'Validation Loss'])
plt.show()

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Categorical Accuracy - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Categorical Accuracy')
plt.plot(range(1, len(hist.history['categorical_accuracy']) + 1),
hist.history['categorical_accuracy'])
plt.plot(range(1, len(hist.history['val_categorical_accuracy']) + 1),
hist.history['val_categorical_accuracy'])
plt.legend(['Categorical Accuracy', 'Validation Categorical Accuracy'])
plt.show()
```



Şimdi de modelimizi test edelim:

```
eval_result = model.evaluate(test_dataset_x, test_dataset_y)
for i in range(len(eval_result)):
    print(f'{model.metrics_names[i]} --> {eval_result[i]}')
```

Şöyledir bir sonuç elde edilmiştir:

```
loss --> 1.016248106956482
categorical_accuracy --> 0.6923999786376953
```

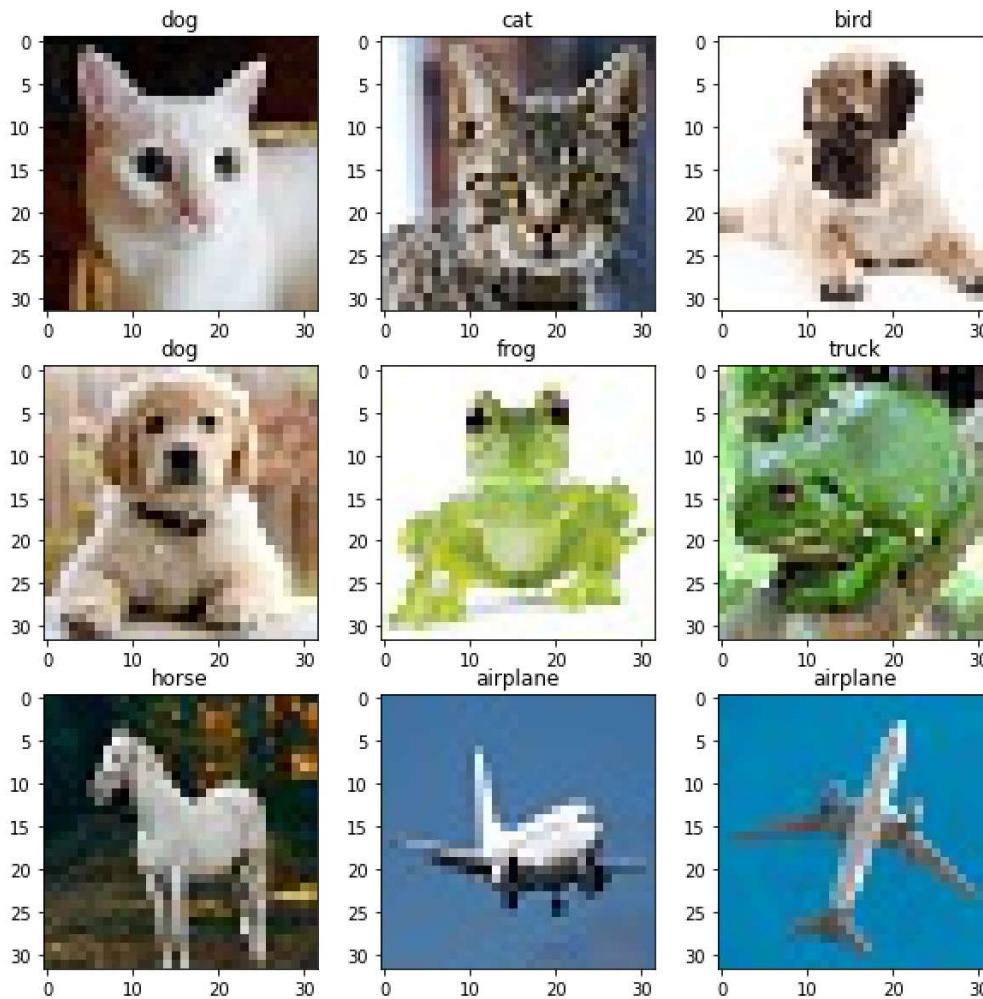
Şimdi de kendi bulduğumuz 32x32x3'lük 9 fotoğrafı sınıflandırmaya çalışalım:

```
import numpy as np
import itertools
import glob

figure = plt.gcf()
figure.set_size_inches((10, 10))
for index, path in enumerate(itertools.islice(glob.glob('*.*jpg'), 9)):
    img_data = plt.imread(path)
    scaled_img_data = img_data / 255
    result = model.predict(scaled_img_data.reshape(1, 32, 32, 3))
    number = np.argmax(result)
    plt.subplot(3, 3, index + 1)
    axis = plt.gca()
    axis.set_title(class_names[number])
```

```
plt.imshow(img_data)
plt.show()
```

Şöyledir bir sonuç elde edilmişdir:



CIFAR-10 uygulamasının kodlarını bütün olarak veriyoruz:

```
from tensorflow.keras.datasets import cifar10

(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) =
cifar10.load_data()

class_names = ['airplane', 'automobile', 'bird', 'cat', 'deer', 'dog', 'frog', 'horse', 'ship',
'truck']

print(f'training_dataset_x.shape: {training_dataset_x.shape}')
print(f'training_dataset_y.shape: {training_dataset_y.shape}')
print(f'test_dataset_x.shape: {test_dataset_x.shape}')
print(f'test_dataset_y.shape: {test_dataset_y.shape}')

import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches(10, 10)
for i in range(1, 10):
    plt.subplot(3, 3, i)
    axis = plt.gca()
    axis.set_title(class_names[training_dataset_y[i, 0]])
    plt.imshow(training_dataset_x[i], cmap='gray')
```

```

plt.show()

training_dataset_x = training_dataset_x / 255
test_dataset_x = test_dataset_x / 255

from tensorflow.keras.utils import to_categorical

training_dataset_y = to_categorical(training_dataset_y)
test_dataset_y = to_categorical(test_dataset_y)

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Conv2D, MaxPooling2D, Flatten, Dense

model = Sequential()
model.add(Conv2D(32, kernel_size=(3, 3), padding='same', input_shape=(32, 32, 3),
activation='relu', name='Convolution-1'))
model.add(MaxPooling2D(name='Pooling-1'))
model.add(Conv2D(64, kernel_size=(3, 3), padding='same', activation='relu', name='Convolution-2'))
model.add(MaxPooling2D(name='Pooling-2'))
model.add(Flatten(name='Flatten'))
model.add(Dense(128, activation='relu', name='Hidden-1'))
model.add(Dense(128, activation='relu', name='Hidden-2'))
model.add(Dense(10, activation='softmax', name='Output'))

model.summary()

model.compile(optimizer='adam', loss='categorical_crossentropy',
metrics=['categorical_accuracy'])
hist = model.fit(training_dataset_x, training_dataset_y, epochs=10, batch_size=64,
validation_split=0.2)

import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Loss - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.plot(range(1, len(hist.history['loss']) + 1), hist.history['loss'])
plt.plot(range(1, len(hist.history['val_loss']) + 1), hist.history['val_loss'])
plt.legend(['Loss', 'Validation Loss'])
plt.show()

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Categorical Accuracy - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Categorical Accuracy')
plt.plot(range(1, len(hist.history['categorical_accuracy']) + 1),
hist.history['categorical_accuracy'])
plt.plot(range(1, len(hist.history['val_categorical_accuracy']) + 1),
hist.history['val_categorical_accuracy'])
plt.legend(['Categorical Accuracy', 'Validation Categorical Accuracy'])
plt.show()

eval_result = model.evaluate(test_dataset_x, test_dataset_y)
for i in range(len(eval_result)):
    print(f'{model.metrics_names[i]} --> {eval_result[i]}')

import numpy as np
import glob

```

```

for path in glob.glob('*.jpg'):
    img_data = plt.imread(path)
    scaled_img_data = img_data / 255
    result = model.predict(scaled_img_data.reshape(1, 32, 32, 3))
    number = np.argmax(result)
    plt.title(class_names[number], fontsize=16)
    plt.imshow(img_data)
    plt.show()

```

Her ne kadar CIFAR-10 veri kümesi Keras'ın içinde hazır bulunuyorsa da CSV dosyası biçiminde de elde edilebilmektedir. CIFAR-10 veri kümesine ilişkin CSV dosyalarını ZIP dosyası olarak <https://www.kaggle.com/fedesoriano/cifar10-python-in-csv> adresinden indirebilirsiniz. İndirdiğiniz ZIP dosyasını açınca "train.csv" ve "test.csv" dosyalarını elde edeceksiniz. Bu dosyaların ilk satırında yine bir başlık kısmı vardır. Her satırındaki $3072 (3 * 32 * 32)$ değer ilgili resmin RGB pixel değerlerini, son değer ise ilgili resmin sınıfını belirtmektedir. Burada dikkat edilmesi gereken resmin pixel verilerinin CSV içerisinde $32 \times 32 \times 3$ olarak değil de $3 \times 32 \times 32$ biçiminde oluşturulduğudur. Bu nedenle numpy.loadtxt fonksiyonu ile dosya okunduktan sonra transpose işleminin uygulanması gereklidir. Şimdi dosyaların çalışma dizininde olduğunu varsayıyalım. numpy.loadtxt fonksiyonu ile okumayı şöyle yapabiliriz:

```

import numpy as np

training_dataset = np.loadtxt('train.csv', delimiter=',', skiprows=1, dtype=np.uint8)

training_dataset_x = training_dataset[:, :-1].reshape(-1, 3, 32, 32)
training_dataset_x = np.transpose(training_dataset_x, (0, 2, 3, 1))
training_dataset_y = training_dataset[:, -1]

test_dataset = np.loadtxt('test.csv', delimiter=',', skiprows=1, dtype=np.uint8)

test_dataset_x = test_dataset[:, :].reshape(-1, 3, 32, 32)
test_dataset_x = np.transpose(test_dataset_x, (0, 2, 3, 1))
test_dataset_y = test_dataset[:, :].reshape(-1, 3, 32, 32)

class_names = ['airplane', 'automobile', 'bird', 'cat', 'deer', 'dog', 'frog', 'horse', 'ship', 'truck']

import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches(10, 10)
for i in range(1, 10):
    plt.subplot(3, 3, i)
    axis = plt.gca()
    axis.set_title(str(training_dataset_y[i]))
    plt.imshow(training_dataset_x[i])

plt.show()

```

Kodun geri kalan kısmı yukarıdakini aynısıdır.

Renkli Resimlerin Sınıflandırılmasına İlişkin CIFAR-100 Örneği

CIFAR-100 veri kümesi CIFAR-10 veri kümesinin 100 sınıf içeren genişletilmiş bir biçimidir. Bu veri kümesinde 100 sınıfından her birine ilişkin $3 \times 32 \times 32$ 'lik 600 renkli resim bulunmaktadır. CIFAR-100 veri kümesinin organizasyonu 100 tane sınıfa sahip olmasının dışında tamamen CIFAR-10 veri kümesi ile aynıdır. CIFAR-100 veri kümesi içerisindeki resimlerin sınıfları şöyledir:

```

class_names = [
    'apple', 'aquarium_fish', 'baby', 'bear', 'beaver', 'bed', 'bee', 'beetle',
    'bicycle', 'bottle', 'bowl', 'boy', 'bridge', 'bus', 'butterfly', 'camel',
    'can', 'castle', 'caterpillar', 'cattle', 'chair', 'chimpanzee', 'clock',

```

```

'cloud', 'cockroach', 'couch', 'crab', 'crocodile', 'cup', 'dinosaur',
'dolphin', 'elephant', 'flatfish', 'forest', 'fox', 'girl', 'hamster',
'house', 'kangaroo', 'keyboard', 'lamp', 'lawn_mower', 'leopard', 'lion',
'lizard', 'lobster', 'man', 'maple_tree', 'motorcycle', 'mountain', 'mouse',
'mushroom', 'oak_tree', 'orange', 'orchid', 'otter', 'palm_tree', 'pear',
'pickup_truck', 'pine_tree', 'plain', 'plate', 'poppy', 'porcupine',
'possum', 'rabbit', 'raccoon', 'ray', 'road', 'rocket', 'rose',
'sea', 'seal', 'shark', 'shrew', 'skunk', 'skyscraper', 'snail', 'snake',
'spider', 'squirrel', 'streetcar', 'sunflower', 'sweet_pepper', 'table',
'tank', 'telephone', 'television', 'tiger', 'tractor', 'train', 'trout',
'tulip', 'turtle', 'wardrobe', 'whale', 'willow_tree', 'wolf', 'woman',
'worm'
]

```

CIFAR-100 veri kümesi de tensorflow.keras.datasets.cifar100 modülü içerisinde hazır biçimde bulundurulmaktadır. Veri kümesini biliriz

```

from tensorflow.keras.datasets import cifar100

(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) =
cifar100.load_data()

class_names = [
    'apple', 'aquarium_fish', 'baby', 'bear', 'beaver', 'bed', 'bee', 'beetle',
    'bicycle', 'bottle', 'bowl', 'boy', 'bridge', 'bus', 'butterfly', 'camel',
    'can', 'castle', 'caterpillar', 'cattle', 'chair', 'chimpanzee', 'clock',
    'cloud', 'cockroach', 'couch', 'crab', 'crocodile', 'cup', 'dinosaur',
    'dolphin', 'elephant', 'flatfish', 'forest', 'fox', 'girl', 'hamster',
    'house', 'kangaroo', 'keyboard', 'lamp', 'lawn_mower', 'leopard', 'lion',
    'lizard', 'lobster', 'man', 'maple_tree', 'motorcycle', 'mountain', 'mouse',
    'mushroom', 'oak_tree', 'orange', 'orchid', 'otter', 'palm_tree', 'pear',
    'pickup_truck', 'pine_tree', 'plain', 'plate', 'poppy', 'porcupine',
    'possum', 'rabbit', 'raccoon', 'ray', 'road', 'rocket', 'rose',
    'sea', 'seal', 'shark', 'shrew', 'skunk', 'skyscraper', 'snail', 'snake',
    'spider', 'squirrel', 'streetcar', 'sunflower', 'sweet_pepper', 'table',
    'tank', 'telephone', 'television', 'tiger', 'tractor', 'train', 'trout',
    'tulip', 'turtle', 'wardrobe', 'whale', 'willow_tree', 'wolf', 'woman',
    'worm'
]

print(f'training_dataset_x.shape: {training_dataset_x.shape}')
print(f'training_dataset_y.shape: {training_dataset_y.shape}')
print(f'test_dataset_x.shape: {test_dataset_x.shape}')
print(f'test_dataset_y.shape: {test_dataset_y.shape}')

```

Şu çıktı elde edilmiştir:

```

training_dataset_x.shape: (50000, 32, 32, 3)
training_dataset_y.shape: (50000, 1)
test_dataset_x.shape: (10000, 32, 32, 3)
test_dataset_y.shape: (10000, 1)

```

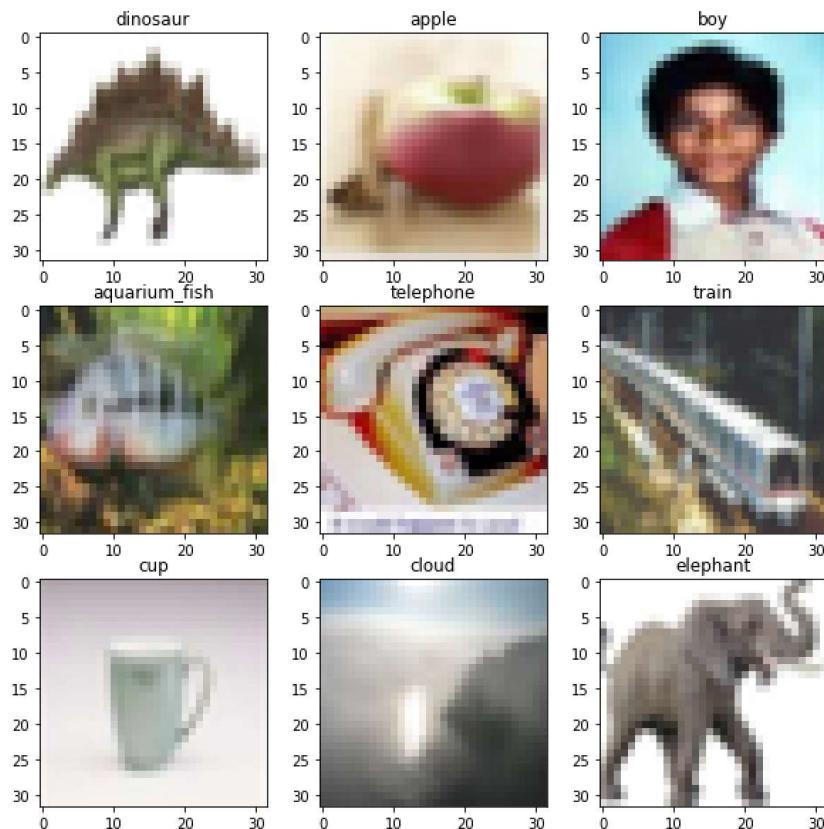
Veri kümesindeki resimlerden 9 tanesini görüntüleyelim:

```

figure = plt.gcf()
figure.set_size_inches(10, 10)
for i in range(1, 10):
    plt.subplot(3, 3, i)
    axis = plt.gca()
    axis.set_title(class_names[training_dataset_y[i, 0]])
    plt.imshow(training_dataset_x[i], cmap='gray')
plt.show()

```

Şöyledir bir görüntü elde edilmişdir:



Min-Max ölçeklendirmesini ve one hot encoding işlemlerini yapalım:

```
training_dataset_x = training_dataset_x / 255
test_dataset_x = test_dataset_x / 255

from tensorflow.keras.utils import to_categorical

training_dataset_y = to_categorical(training_dataset_y)
test_dataset_y = to_categorical(test_dataset_y)
```

Şimdi modelimizi oluşturalım. Modelimizde yine iki evrişim katmanı olsun. Evrişim katmanlarından sonra pooling katmanlarıyla nöron sayılarını azaltalım. Bunları iki saklı katman ve çıkış katmanı izlesin:

```
from tensorflow.keras.utils import to_categorical

training_dataset_y = to_categorical(training_dataset_y)
test_dataset_y = to_categorical(test_dataset_y)

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Conv2D, MaxPooling2D, Flatten, Dense

model = Sequential(name='CIFAR-100')
model.add(Conv2D(32, kernel_size=(3, 3), padding='same', input_shape=(32, 32, 3),
activation='relu', name='Convolution-1'))
model.add(MaxPooling2D(name='Pooling-1'))
model.add(Conv2D(64, kernel_size=(3, 3), padding='same', activation='relu', name='Convolution-2'))
model.add(MaxPooling2D(name='Pooling-2'))
model.add(Conv2D(64, kernel_size=(3, 3), padding='same', activation='relu', name='Convolution-3'))
model.add(MaxPooling2D(name='Pooling-3'))
```

```

model.add(Flatten(name='Flatten'))
model.add(Dense(256, activation='relu', name='Hidden-1'))
model.add(Dense(128, activation='relu', name='Hidden-2'))
model.add(Dense(100, activation='softmax', name='Output'))

model.summary()

```

Modelin özetini söyleyelim:

Layer (type)	Output Shape	Param #
<hr/>		
Convolution-1 (Conv2D)	(None, 32, 32, 32)	896
Pooling-1 (MaxPooling2D)	(None, 16, 16, 32)	0
Convolution-2 (Conv2D)	(None, 16, 16, 64)	18496
Pooling-2 (MaxPooling2D)	(None, 8, 8, 64)	0
Convolution-3 (Conv2D)	(None, 8, 8, 64)	36928
Pooling-3 (MaxPooling2D)	(None, 4, 4, 64)	0
Flatten (Flatten)	(None, 1024)	0
Hidden-1 (Dense)	(None, 256)	262400
Hidden-2 (Dense)	(None, 128)	32896
Output (Dense)	(None, 100)	12900
<hr/>		
Total params: 364,516		
Trainable params: 364,516		
Non-trainable params: 0		

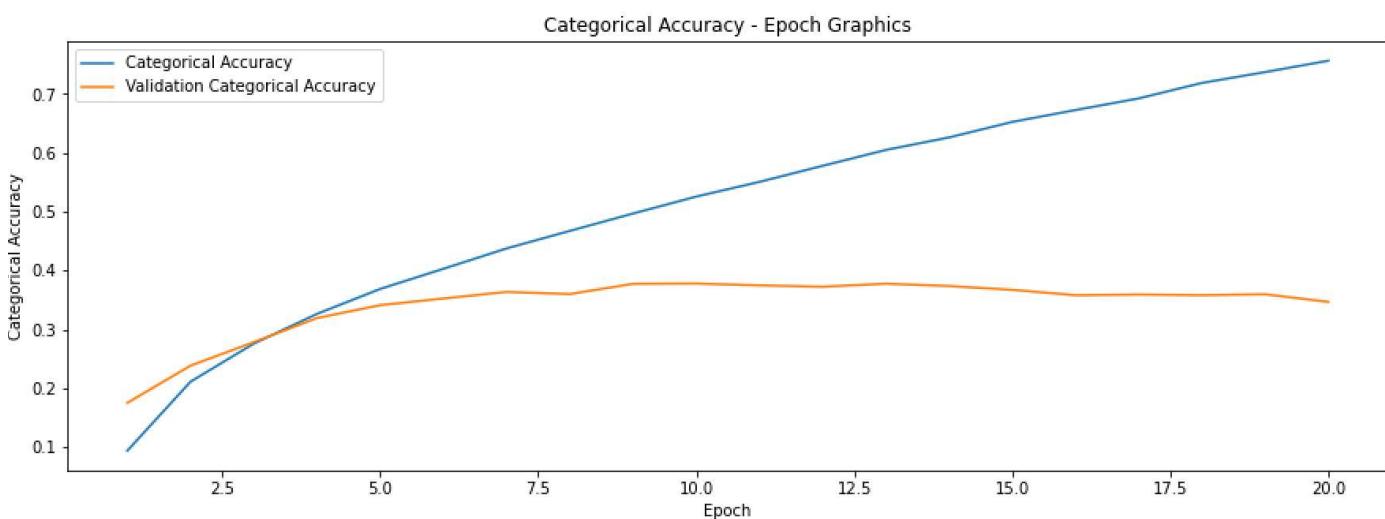
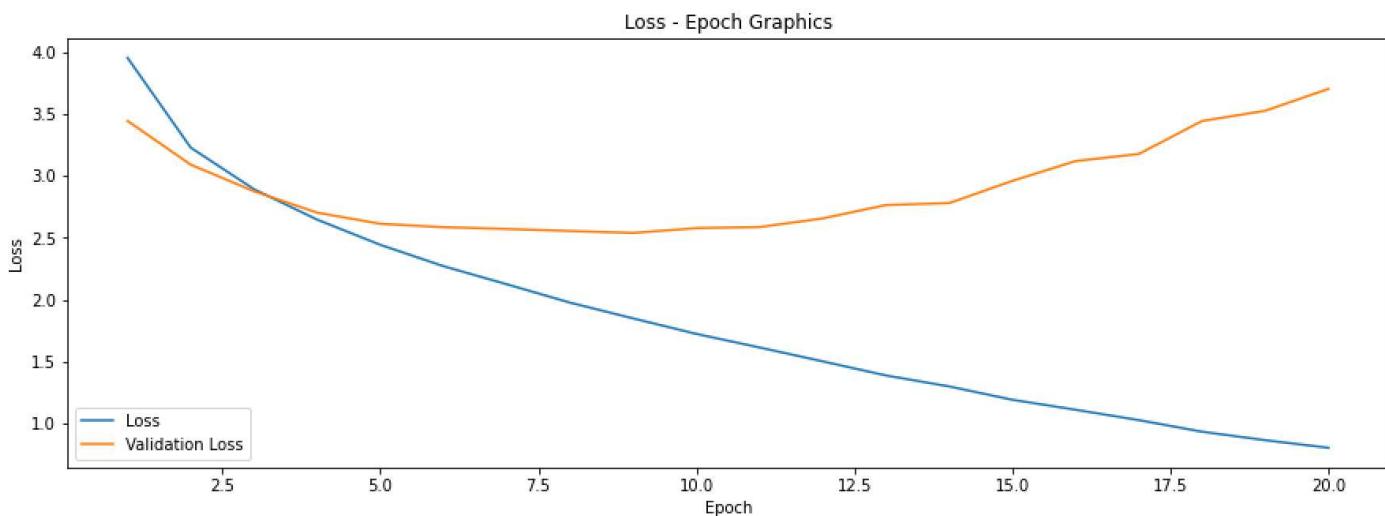
Modelimizi derleyelim ve eğitelim:

```

model.compile(optimizer='adam', loss='categorical_crossentropy',
metrics=['categorical_accuracy'])
hist = model.fit(training_dataset_x, training_dataset_y, epochs=10, batch_size=64,
validation_split=0.2)

```

Epoch grafiklerini çizdirelim:



Burada 7 civarında bir epoch uygun gözükmemektedir. Şimdi de modelimizi test edelim:

```
eval_result = model.evaluate(test_dataset_x, test_dataset_y)
for i in range(len(eval_result)):
    print(f'{model.metrics_names[i]} --> {eval_result[i]}')
```

Şu sonuçlar elde edilmiştir:

```
loss --> 3.6690242290496826
categorical_accuracy --> 0.35409998893737793
```

Şimdi modeldeki 100 sınıfın bazlarına ilişkin resimleri bulup bunları 32x32x3 boyutuna getirdiğimizi varsayıyalım. Kestirim işlemini CIFAR-10 örneğindekine benzer biçimde yapabiliriz:

```
import numpy as np
import glob

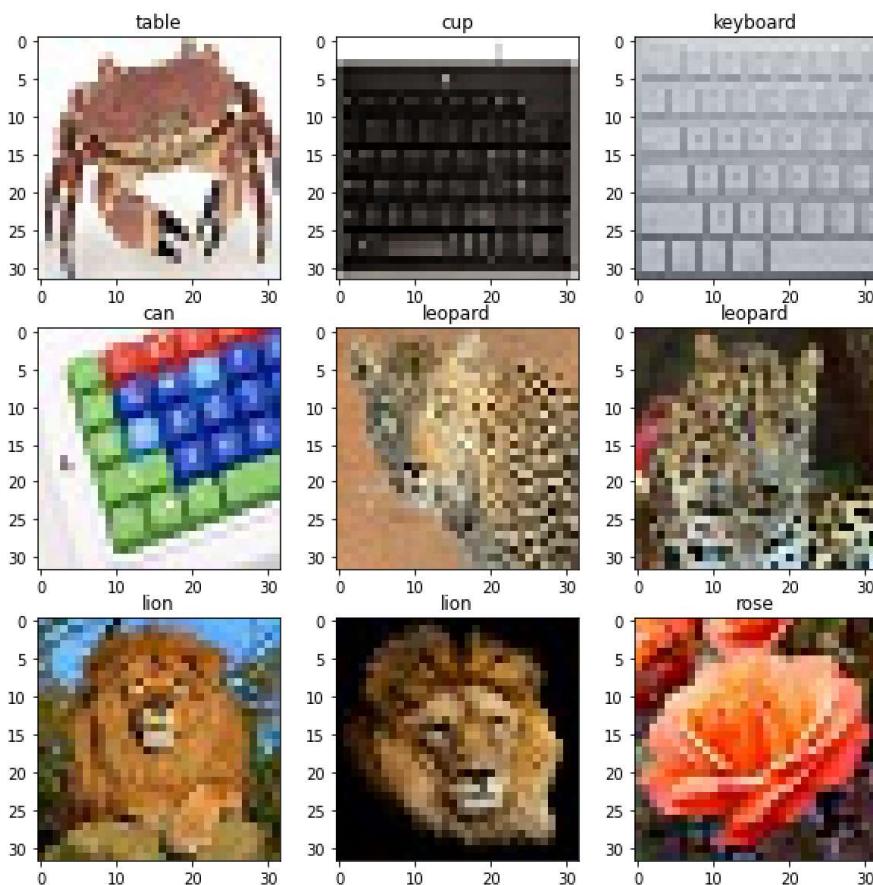
for path in glob.glob('*.*'):
    img_data = plt.imread(path)
    scaled_img_data = img_data / 255
    result = model.predict(scaled_img_data.reshape(1, 32, 32, 3))
    number = np.argmax(result)
    plt.title(class_names[number], fontsize=16)
    plt.imshow(img_data)
    plt.show()
```

Şimdi 9 tane resim için kestirim sonuçlarına bakalım:

```
import numpy as np
import itertools
import glob

figure = plt.gcf()
figure.set_size_inches((10, 10))
for index, path in enumerate(itertools.islice(glob.glob('*.*jpg'), 9)):
    img_data = plt.imread(path)
    scaled_img_data = img_data / 255
    result = model.predict(scaled_img_data.reshape(1, 32, 32, 3))
    number = np.argmax(result)
    plt.subplot(3, 3, index + 1)
    axis = plt.gca()
    axis.set_title(class_names[number])
    plt.imshow(img_data)
plt.show()
```

Şu sonuçlar elde edilmiştir:



Aşağıda CIFAR-100 örneğinin tüm kodlarını bütün olarak veriyoruz:

```
from tensorflow.keras.datasets import cifar100

(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) =
cifar100.load_data()

class_names = [
    'apple', 'aquarium_fish', 'baby', 'bear', 'beaver', 'bed', 'bee', 'beetle',
    'bicycle', 'bottle', 'bowl', 'boy', 'bridge', 'bus', 'butterfly', 'camel',
    'can', 'castle', 'caterpillar', 'cattle', 'chair', 'chimpanzee', 'clock',
    'cloud', 'cockroach', 'couch', 'crab', 'crocodile', 'cup', 'dinosaur',
```

```

'dolphin', 'elephant', 'flatfish', 'forest', 'fox', 'girl', 'hamster',
'house', 'kangaroo', 'keyboard', 'lamp', 'lawn_mower', 'leopard', 'lion',
'lizard', 'lobster', 'man', 'maple_tree', 'motorcycle', 'mountain', 'mouse',
'mushroom', 'oak_tree', 'orange', 'orchid', 'otter', 'palm_tree', 'pear',
'pickup_truck', 'pine_tree', 'plain', 'plate', 'poppy', 'porcupine',
'possum', 'rabbit', 'raccoon', 'ray', 'road', 'rocket', 'rose',
'sea', 'seal', 'shark', 'shrew', 'skunk', 'skyscraper', 'snail', 'snake',
'spider', 'squirrel', 'streetcar', 'sunflower', 'sweet_pepper', 'table',
'tank', 'telephone', 'television', 'tiger', 'tractor', 'train', 'trout',
'tulip', 'turtle', 'wardrobe', 'whale', 'willow_tree', 'wolf', 'woman',
'worm'
]

import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches((10, 10))
for i in range(9):
    plt.subplot(3, 3, i + 1)
    axis = plt.gca()
    axis.set_title(class_names[training_dataset_y[i, 0]])
    plt.imshow(training_dataset_x[i])
plt.show()

index = class_names.index('oak_tree')
image_data = training_dataset_x[training_dataset_y[:, 0] == index][:20]
for i in range(20):
    plt.imshow(image_data[i])
    plt.show()

training_dataset_x = training_dataset_x / 255
test_dataset_x = test_dataset_x / 255

from tensorflow.keras.utils import to_categorical

training_dataset_y = to_categorical(training_dataset_y)
test_dataset_y = to_categorical(test_dataset_y)

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Conv2D, MaxPooling2D, Flatten, Dense

model = Sequential(name='CIFAR-10')
model.add(
    Conv2D(32, kernel_size=(3, 3), padding='same', activation='relu', input_shape=(32, 32, 3),
name='Convolution-1'))
model.add(MaxPooling2D(name='Pooling-1'))
model.add(Conv2D(64, kernel_size=(3, 3), padding='same', activation='relu', name='Convolution-2'))
model.add(MaxPooling2D(name='Pooling-2'))
model.add(Conv2D(128, kernel_size=(3, 3), padding='same', activation='relu', name='Convolution-3'))
model.add(MaxPooling2D(name='Pooling-3'))
model.add(Flatten(name='Flatten'))
model.add(Dense(256, activation='relu', name='Dense-1'))
model.add(Dense(128, activation='relu', name='Dense-2'))
model.add(Dense(100, activation='softmax', name='Output'))

model.summary()

model.compile(optimizer='rmsprop', loss='categorical_crossentropy',
metrics=['categorical_accuracy'])
hist = model.fit(training_dataset_x, training_dataset_y, epochs=20, batch_size=64,
validation_split=0.2)

```

```

import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Loss - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.plot(range(1, len(hist.history['loss']) + 1), hist.history['loss'])
plt.plot(range(1, len(hist.history['val_loss']) + 1), hist.history['val_loss'])
plt.legend(['Loss', 'Validation Loss'])
plt.show()

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Categorical Accuracy - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Categorical Accuracy')
plt.plot(range(1, len(hist.history['categorical_accuracy']) + 1),
hist.history['categorical_accuracy'])
plt.plot(range(1, len(hist.history['val_categorical_accuracy']) + 1),
hist.history['val_categorical_accuracy'])
plt.legend(['Categorical Accuracy', 'Validation Categorical Accuracy'])
plt.show()

eval_result = model.evaluate(test_dataset_x, test_dataset_y)
for i in range(len(eval_result)):
    print(f'{model.metrics_names[i]} ---> {eval_result[i]}')

import numpy as np
import glob

for path in glob.glob('*.*'):
    img_data = plt.imread(path)
    scaled_img_data = img_data / 255
    result = model.predict(scaled_img_data.reshape(1, 32, 32, 3))
    number = np.argmax(result)
    plt.title(class_names[number], fontsize=16)
    plt.imshow(img_data)
    plt.show()

```

CIFAR-100 veri kümesi de veri dosyalarından hareketle indirilip yüklenebilir. Aşağıdaki adresten CIFAR-100 verilerini indirebilirisiniz:

<https://www.kaggle.com/fedesoriano/cifar100>

Buradan "train" ve "test" isimli iki dosya elde edeceksiniz. Bu dosyalar CSV formatında değildir. Bu dosyalar Python standart kütüphanesindeki pickle modülü ile seri hale getirilmiş sözlük nesnesi içermektedir. Dolayısıyla bu dosyaları aynı modülü kullanarak açmalısınız:

```

import pickle

with open('train', 'rb') as f:
    training_dataset_dict = pickle.load(f, encoding='bytes')

with open('test', 'rb') as f:
    test_dataset_dict = pickle.load(f, encoding='bytes')

```

Deserialize işleminden bir sözlük nesnesi elde edilmiştir. Bu sözlük nesnesinin anahtarları şöyledir:

Burada her anahtara karşılık değer olarak ilgili veriler bulunmaktadır. Resimlerdeki pixel'ler de yine CIFAR-10 örneğinde olduğu gibi $3 \times 32 \times 32$ biçimindedir. Dolayısıyla bunların da yine $32 \times 32 \times 3$ biçimine dönüştürülmesi gereklidir:

```
import numpy as np

training_dataset_x = training_dataset_dict[b'data']
training_dataset_y = np.array(training_dataset_dict[b'fine_labels'], dtype=np.uint32)

training_dataset_x = training_dataset_x.reshape(-1, 3, 32, 32)
training_dataset_x = np.transpose(training_dataset_x, (0, 2, 3, 1))

test_dataset_x = test_dataset_dict[b'data']
test_dataset_y = np.array(test_dataset_dict[b'fine_labels'], dtype=np.uint32)

test_dataset_x = test_dataset_x.reshape(-1, 3, 32, 32)
test_dataset_x = np.transpose(test_dataset_x, (0, 2, 3, 1))
```

Kodun geri kalan kısmı yukarıdaki örneğin aynısıdır.

Keras'ta EarlyStopping ve ModelCheckpoint Callback Sınıfları

Keras'taki bazı callback sınıflarını daha önce incelemiştik. Burada daha önce ele almadığımız iki callback sınıfını inceleyeceğiz. EarlyStopping eğitimi durdurmak için kullanılan bir callback sınıfıdır. Yani eğitim sırasında epoch'lardaki sinama (validation) değerleri belli koşulları sağladığında (örneğin artık daha fazla iyileşmediği ya da gerilediği zaman) eğitimi durdurabiliyoruz. Çünkü overfit durumlarında eğitimin devam ettirilmesi toplamda daha kötü sonuçlara yol açabilmektedir. Şüphesiz programcı önce yüksek bir epoch'la denemeyi yapıp sonra grafiklere bakarak uygun epoch miktarını belirleyebilmektedir. (Biz de şimdide kadar hep böyle yaptık.) İşte EarlyStopping callback sınıfı bu işlemi daha pratik hale getirmek amacıyla düşünülmüştür. EarlyStopping sınıfının `__init__` metodunun parametrik yapısı şöyledir:

```
tensorflow.keras.callbacks.EarlyStopping(
    monitor='val_loss',
    min_delta=0,
    patience=0,
    verbose=0,
    mode='auto',
    baseline=None,
    restore_best_weights=False
)
```

EarlyStopping callback sınıfı her zaman epoch'lardan sonra devreye girmektedir. Metodun birinci parametresi hangi metrik değerin izleneceğini belirtmektedir. Bu parametrenin default değerinin 'val_loss' biçiminde olduğuna dikkat ediniz. Yani default durumda "validation loss" değerine bakılarak erken sonlandırma yapılacaktır. Biz bu parametreye kullandığımız metrik isimlerini girebiliriz. Sinama verileri için bu metrik isimlerinin başına "val_" önekinin getirilmesi gereklidir. patience parametresine epoch sayısı girilir. Eğitim burada girilen epoch sayısı kadar epoch işleminde ilgili değerde olumlu bir değişiklik yoksa sonlandırılır. Örneğin bu parametrenin 5 girildiğini varsayıyalım. Artık 5 epoch'ta bir farklılık oluşmuyorsa işlem sonlandırılabilir. patience parametresindeki duyarlılık `min_delta` parametresiyle ayarlanmaktadır. `min_delta` parametresinin default değeri 0'dır. Örneğin biz `min_delta` parametresi için 0.2 değeri girmış olalım. Bu durumda patience değeri 5 ise, 5 epoch süresince validation loss değerinde 0.2'den daha yüksek bir iyileşme olmamışsa eğitim sonlandırılacaktır. Metodun mode parametresi üç değer alabilir: "min", "max" ve "auto". Bu parametre monitor parametresine göre belirlenmelidir. Örneğin monitor parametresi "val_loss" ise biz bu değerin düşmesine yönelik bir sonlandırma yapmak isteriz. Bu durumda mode parametresi 'min' girilebilir. Ancak örneğin monitor parametresi "val_accuracy" ise bu durumda biz bu değerin yükselmesi yönünde bir ilgi içerisinde oluruz. O halde mode parametresinin bu durumda max girilmesi gereklidir. "auto" ise monitor parametresinin durumuna göre bunu otomatik yapmaktadır. Bu parametrenin default değerinin "auto" olduğunu görüyorsunuz. Fonksiyonun baseline parametresi ise sonlandırmaın monitor edilen özellik belli bir değere eriştiğinde yapılmasını sağlamak için kullanılmaktadır. `restore_best_weights` parametresi True girilirse (default değer False biçimdedir) bu durumda model sonlandırılmadan önce ağıın ağırlık değerleri o zamana kadarki en iyi monitor değeri ile set edilmektedir.

Örneğin en son üzerinde çalıştığımız CIFAR-100 veri kümesi için aşağıdaki gibi bir EarlyStopping callback oluşturmuş olalım:

```
model.compile(optimizer='adam', loss='categorical_crossentropy', metrics=['accuracy'])

from tensorflow.keras.callbacks import EarlyStopping
esc = EarlyStopping(monitor='val_acc', patience=2, verbose=1, restore_best_weights=True)

history = model.fit(training_set_x, training_set_y, epochs=200, batch_size=512,
validation_split=0.2, callbacks=[esc])
```

Burada patience değerinin 5 olarak girildiğine dikkat ediniz. İşte model gitgide iyileştirilirken 3 epoch süresince elde edilen değer iyileştirilmeme işlem sonlandırılacaktır. Bu örnekte eğitimin çıktısı aşağıdaki gibi elde edilmiştir:

```
Epoch 1/20
625/625 [=====] - 51s 79ms/step - loss: 3.9653 - categorical_accuracy: 0.0923 - val_loss: 3.4964 - val_categorical_accuracy: 0.1603
Epoch 2/20
625/625 [=====] - 50s 80ms/step - loss: 3.2196 - categorical_accuracy: 0.2155 - val_loss: 3.0754 - val_categorical_accuracy: 0.2438
Epoch 3/20
625/625 [=====] - 51s 82ms/step - loss: 2.8290 - categorical_accuracy: 0.2871 - val_loss: 2.8634 - val_categorical_accuracy: 0.2870
Epoch 4/20
625/625 [=====] - 46s 74ms/step - loss: 2.5657 - categorical_accuracy: 0.3434 - val_loss: 2.7120 - val_categorical_accuracy: 0.3177
Epoch 5/20
625/625 [=====] - 29s 46ms/step - loss: 2.3601 - categorical_accuracy: 0.3830 - val_loss: 2.5911 - val_categorical_accuracy: 0.3433
Epoch 6/20
625/625 [=====] - 44s 71ms/step - loss: 2.1778 - categorical_accuracy: 0.4248 - val_loss: 2.5534 - val_categorical_accuracy: 0.3543
Epoch 7/20
625/625 [=====] - 35s 56ms/step - loss: 2.0178 - categorical_accuracy: 0.4629 - val_loss: 2.5052 - val_categorical_accuracy: 0.3718
Epoch 8/20
625/625 [=====] - 52s 82ms/step - loss: 1.8759 - categorical_accuracy: 0.4910 - val_loss: 2.6125 - val_categorical_accuracy: 0.3645
Epoch 9/20
625/625 [=====] - 43s 69ms/step - loss: 1.7417 - categorical_accuracy: 0.5210 - val_loss: 2.5440 - val_categorical_accuracy: 0.3772
Epoch 10/20
625/625 [=====] - 36s 58ms/step - loss: 1.6143 - categorical_accuracy: 0.5505 - val_loss: 2.6472 - val_categorical_accuracy: 0.3705
Epoch 11/20
625/625 [=====] - 38s 60ms/step - loss: 1.4937 - categorical_accuracy: 0.5800 - val_loss: 2.6714 - val_categorical_accuracy: 0.3842
Epoch 12/20
625/625 [=====] - 37s 60ms/step - loss: 1.3696 - categorical_accuracy: 0.6090 - val_loss: 2.7079 - val_categorical_accuracy: 0.3797
Epoch 13/20
625/625 [=====] - 38s 61ms/step - loss: 1.2629 - categorical_accuracy: 0.6347 - val_loss: 2.8481 - val_categorical_accuracy: 0.3788
Restoring model weights from the end of the best epoch.
Epoch 00013: early stopping
```

Burada 11'inci epoch'tan itibaren değerler bu epoch'taki değerleri 2 kez üst üste geçmemiştir. İşte restore_best_weights parametresi True geçildiği için artık model son halinin ağırlıklarıyla değil en iyi halinin ağırlıklarıyla yüklenecaktır.

ModelCheckpoint callback sınıfı modeli belli bir noktada saklamak için kullanılmaktadır. Sınıfın `__init__` metodu şöyledir:

```
tf.keras.callbacks.ModelCheckpoint(  
    filepath,  
    monitor='val_loss',  
    verbose=0,  
    save_best_only=False,  
    save_weights_only=False,  
    mode='auto',  
    save_freq='epoch',  
    options=None,  
    **kwargs  
)
```

Metodun birinci parametresi modelin saklanacağı dosyanın yol ifadesini belirtir. Bu yol ifadesi aşağıdaki örnekte olduğu gibi formatlı da girilebilmektedir. monitor parametresi yine izlenecek değeri belirtir. `save_weights_only` parametresi `False` girilirse (default durum) tüm model saklanır, `True` girilirse yalnızca model ağırlık değerleri saklanır. edilir. Eğer `save_best_only` parametresi `True` girilirse ancak daha iyi bir değer elde edildiğinde saklama işlemi yapılır. `period` parametresi (default değerinin 1 olduğuna dikkat ediniz) kaç epoch aralıklarla kontrollerin yapılacağını belirtir.

Fonksiyonun birinci parametresi formatsız girilirse saklama işlemi o dosyaya yapılır. Ancak birinci parametre formatlı girilirse bu durumda saklama işlemi formatta belirtilen farklı isimlerdeki dosyalara yapılır. Örneğin:

```
mcp = ModelCheckpoint('model.hdf5', save_best_only=False, verbose=1)
```

Burada her epoch'ta model "model.hdf5" dosyasında saklanır. Böylece dosyada son epoch'taki model bilgileri kalacaktır. Örneğin:

```
mcp = ModelCheckpoint('model.hdf5', save_best_only=True, verbose=1)
```

Burada ancak o epoch'a kadar en iyi olan monitor değeri "model.hdf5" dosyasında saklanır. Örneğin:

```
mcp = ModelCheckpoint('model.{epoch:02d}.hdf5', save_best_only=False, verbose=1)
```

Burada her epoch sonrasında model farklı bir dosya ismiyle saklanacaktır. Örneğin:

```
mcp = ModelCheckpoint('model.{epoch:02d}.hdf5', save_best_only=True, verbose=1)
```

Burada ancak o epoch'a kadar en iyi modeller farklı dosya isimleriyle saklanacaktır.

Metinsel Uygulamalar İçin Word Embedding Katmanları

Önceki konularda da belirttiğimiz gibi metne dayalı modellerde kestirim yapmak istendiğinde metinleri oluşturan öğeler girdi olarak sinir ağına verilmektedir. Genellikle bu girdiler sözcükler olur. Fakat bu amaçla karakterler de kullanılabilir. Metni oluşturan sözcüklerin nümerik girdilere dönüştürülmesi IMDB ve Reuters örneklerinde olduğu gibi sözcük indeksleme yoluyla yapılmaktadır. Yani tüm sözcükler (vocabulary) bir listede toplanır. Sonra metin içerisinde geçen sözcükler bu listedeki indeksler haline getirilir. Anımsayacağınız gibi biz IMDB ve Reuters örneklerinde metin içerisindeki tüm sözcükleri tek bir vektör olarak ele almış ve buradaki sözcük indekslerinden kurtulmak için binary encoding uygulamıştık. Böylece ağımızın girdi vektörü de tüm sözcüklerin (vocabulary) sayısı kadar uzunlukta olmuştu. Binary encoding işleminde metnin içerisindeki belli bir sözcük geçmişse biz o indeksli elemanı 1 yapıyorduk. Böylece girdi vektörümüz bazı elemanları 1 olan fakat pek çok elemanı 0 olan bir vektör biçimine dönüştürülmüş oluyordu.

Her sözcüğün one hot encoding biçiminde bir vektörle oluşturulmasının en önemli dezavantajlarından biri şüphesiz metin için oluşturulacak toplam girdi matrisinin çok büyük olmasıdır. Ayrıca bu yöntemin diğer biz dezavantajı da

sözcükler arasında semantik bir bağlantının oluşamamasıdır. Örneğin "güzel" ve "iyi" arasında bağlam bakımından bir yakınlık vardır. Halbuki model bu yakınlığı belirleyememektedir.

İşte "word embedding" denilen yöntemde metni oluşturan her bir sözcük büyük bir one hot encoding vektörü ile değil, küçük bir gerçek sayı vektörüyle ifade edilir. Örneğin metnimizdeki bir sözcük aşağıdaki gibi bir one hot encoding vektörüyle temsil edilmiş olsun:

```
[0, 0, ..., 0, 0, 1, 0, 0, ..., 0, 0, 0]
```

Bunun gerçek sayılarından oluşan karşılığı şöyle olabilir:

```
[0.78, 0.12, ..., 0.34, 0.67]
```

Metindeki her sözcüğün uzun bir one hot encoding vektörü ile değil de nispeten kısa bir gerçek sayı vektörüyle ifade edilmesinin şu avantajları vardır:

- 1) Bu sayede girdi kümesi azaltılmış olur. Yani uzun bir one hot encoding matrisinden kurtulmuş oluruz.
- 2) Bu sayede sözcükler arasında semantik bir bağlantı da kurulur. Çünkü bu dönüştürme işlemi aslında öğrenme modelinin bir parçasıdır ve söz konusu vektör ağ eğitildikçe daha iyi hale gelmektedir. Sonuçta iki sözcük arasındaki vektörel uzaklık ne kadar azsa o sözcüklerin eğitiminde kullanılan metinler içerisindeki anlamsal benzerlikler o kadar fazla olur.

Burada önemli bir noktayı vurgulamak istiyoruz. Word embedding sonucunda elde edilecek vektörler aslında modelin eğitilmesi sonucunda ağ tarafından oluşturulmaktadır. Yani word embedding işleminde sözcüklere karşı gelen vektör değerlerinin belirlenmesi aslında eğitim sırasında konumlandırılan birtakım eğitim parametreleri tarafından sağlanmaktadır. Peki "word embedding" katmanında vektör değerlerinin oluşturulması için hangi eğitim algoritmaları kullanılmaktadır? İşte word embedding eğitimi için kullanılan algoritmalar çeşitlidir. En popülerleri şunlardır:

Word2Vect (Google)
GloVe (Stanford)
fastText (Facebook)

Keras'taki Embedding katmanı Word2Vect temeline dayandırılmıştır. Biz burada bu algoritmalar üzerinde durmayacağız. Ancak bu katmanın Keras'taki kullanımı üzerinde duracağız.

Keras'ta Embedding katmanı Embedding isimli bir sınıfı temsil edilmiştir. Sınıfın `__init__` metodunun parametrik yapısı şöyledir:

```
tf.keras.layers.Embedding(  
    input_dim,  
    output_dim,  
    embeddings_initializer='uniform',  
    embeddings_regularizer=None,  
    activity_regularizer=None,  
    embeddings_constraint=None,  
    mask_zero=False,  
    input_length=None,  
    **kwargs  
)
```

Metodun `input_dim` isimli birinci parametresi sözcük indekslerinden oluşturulacak one hot encoding vektörünün uzunluğunu belirtmektedir. Yani bu parametre MNIST ve Reuters örnekleri için tüm sözcüklerin (vocabulary) sayısı olarak girilmelidir. Yukarıda da belirtildiği gibi Embedding katmanı için kullanılacak yazılarla ilişkin sözcük indekslerinden oluşan vektörler aşağıdaki görünümde olacaktır:

Bu sayıların metin içerisinde geçen sözcüklerin indeks numaraları olduğuna dikkat ediniz. (Tabii aslında Embedding katmanı kendi içerisinde bu vektördeki dizi elemanlarını "one hot encoding"e dönüştürerek işleme sokmaktadır. Girdinin kullanıcıdan bu biçimde istenmesi kullanıcıya kolaylık sağlamaktadır.) Ancak burada bir sorun vardır. Eğitimde kullanılacak indekslerden oluşan girdi vektörlerinin Keras tasarımdan kaynaklanan biçimde aynı uzunluk olması gereklidir. Oysa metinlerdeki sözcükler farklı sayıarda olabilmektedir. Peki bu sorun nasıl çözülecektir? Kullanılacak en makul yöntem tüm metinlerin sözcük uzunluğunu aynı yapmaktadır. Bunun için tensorflow.keras.preprocessing modülü içerisindeki sequence.pad_sequences fonksiyonundan faydalanabilir. Bu fonksiyon eğer dizi kısaysa onun başını sıfırlarla doldurur, eğer dizi uzunsa sonundan kırpmaya yapar. pad_sequences fonksiyonunun parametrik yapısı şöyledir:

```
tensorflow.keras.preprocessing.sequence.pad_sequences(
    sequences,
    maxlen=None,
    dtype='int32',
    padding='pre',
    truncating='pre',
    value=0.0
)
```

Foksiyonun birinci parametresi padding yapılacak iki boyutlu matrisi belirtmektedir. İkinci parametre padding sonrasında elde edilecek vektörün uzunluğunu belirtir. Fonksiyonun padding parametresi padding sırasında doldurma değerlerinin vektörün başa mı yoksa sonuna mı yapılacağını belirtmektedir. Bu parametrenin default değerinin 'pre' biçiminde olduğunu görüyorsunuz. Bu durumda padding işlemi baş tarafa yapılır. Padding işleminin vektörün sonuna yapılması isteniyorsa bu parametre 'post' biçiminde girilmelidir. Fonksiyonun value parametresi ise padding sırasında doldurulacak değeri belirtmektedir. Bu parametrenin default değerinin 0 olduğunu görüyorsunuz.

Peki tüm metinler için aynı olacak bu uzunluk nasıl tespit edilecektir? Aslında belli bir uzunluk sezgisel olarak belirlenebilir. Ya da kırılma durumu oluşmasın isteniyorsa en uzun metnin uzunluğu referans alınabilir.

Metodun output_dim isimli ikinci parametresi çıktı vektörünün uzunluğunu belirtmektedir. Aslında Embedding katmanın çıktısı her biri bu parametrede belirtilen uzunlukta sütundan oluşan bir matristir. Örneğin biz Embedding nesnesini şöyle yaratmış olalım:

```
Embedding(10000, 32)
```

Buradaki input_dim parametresi için girilen 10000 değeri bizim tüm metinlerimizdeki toplam farklı sözcük sayısını (vocabulary) belirtmektedir. Burada output_dim parametresi için girilmiş olan 32 değeri ise her sözcüğün temsil edildiği vektörün uzunluğudur. Yani her sözcük one hot encoding yerine 32'lük bir gerçek sayı vektörye temsil edilmektedir. Bu parametredeki vektör uzunluğu için genellikle 16, 32, 64 gibi değerler tercih edilmektedir. Ancak metin içerisindeki sözcüklerin toplam sayısı çok fazlaysa bu değerin de büyütülmesi olumlu sonuçlar doğurmaktadır. Yukarıda Embedding katmanın girdilerinin yazılıdaki sözcüklerin indekslerinden oluştuğunu söylemiştık. Pekiyi Embedding sınıfı girdi olarak kullanılacak bu sözcük indekslerine ilişkin vektörlerin uzunluğunu nasıl anlamaktadır? İşte metodun input_length isimli parametresi bu uzunluğu belirlemekte kullanılabilmektedir. Ancak bu parametre girilmediye fonksiyon otomatik olarak bu belirlemeyi eğitim sırasında girilen diziye bakarak yapmaktadır. Örneğin:

```
Embedding(10000, 32, input_length=100)
```

Burada tüm metinlerdeki farklı sözcüklerin sayısı (vocabulary) 10000'dir. Metinlerin hepsi 100 sözcük uzunluğundadır ve her metin için 32 uzunlığında bir gerçek sayı vektörü oluşturulacaktır.

Embedding katmanın çıktısı her zaman "input_length X output_dim" biçiminde iki boyutlu bir matristir. Eğer programcı çıktıının tek boyutlu olmasını istiyorsa (örneğin Embedding katmanın çıktısını Dense katmana bağlamak isteyebilir) bu durumda Flatten katmanından faydalanamalıdır. Aşağıdaki gibi bir metin söz konusu olsun:

```
"film çok güzeldi"
```

Bu metinde 3 sözcük vardır. Eğer metinlerdeki tüm yazıların 100 sözcükten oluştuğunu kabul edersek bu 3 sözcüklü metin 100 sözcüğe padding yapılacaktır. Ağın eğitilmesiyle bu yazı 32 elemanlı gerçek sayılarından oluşan bir vektöre dönüştürülecektir.

IMDB Örneğinde WordEmbedding Katmanının Kullanılması

Şimdi word embedding işlemini daha önce üzerinde çalışmış olduğumuz IMDB verileri üzerinde uygulayalım. Önce verileri Keras içerisindeki imdb modülünü kullanarak okuyalım:

```
from tensorflow.keras.datasets import imdb

VOCAB_SIZE = 30000
TEXT_SIZE = 300

(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) =
imdb.load_data(num_words=VOCAB_SIZE)

word_dict = imdb.get_word_index()

from tensorflow.keras.preprocessing.sequence import pad_sequences

training_dataset_x = pad_sequences(training_dataset_x, maxlen=TEXT_SIZE, padding='post')
test_dataset_x = pad_sequences(test_dataset_x, maxlen=TEXT_SIZE, padding='post')
```

Şimdi modelimizi kuralım. Modelimizde önce bir WordEmbedding katmanı kullanacağız. Bu katmanın çıktısı matrisel olduğu için onu Flatten katmanı ile düzeltceğiz:

```
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Embedding, Flatten, Dense

model = Sequential(name='IMDB')
model.add(Embedding(VOCAB_SIZE, 64, input_length=TEXT_SIZE, name='Embedding'))
model.add(Flatten(name='Flatten'))
model.add(Dense(128, activation='relu', name='Dense-1'))
model.add(Dense(128, activation='relu', name='Dense-2'))
model.add(Dense(1, activation='sigmoid', name='Output'))
model.summary()
```

Şimdi modeli derleyip eğitelim. Eğitim işleminde üst üste 5 kez "val_loss" değeri iyileştirilemezse eğitimi sonlandıracagız ve modele zamana kadarki en iyi ağırlık değerlerini yükleyeceğiz:

```
model.compile(optimizer='rmsprop', loss='binary_crossentropy', metrics=['binary_accuracy'])

from tensorflow.keras.callbacks import EarlyStopping

esc = EarlyStopping(monitor='val_loss', patience=5, restore_best_weights=True, verbose=1)

hist = model.fit(training_dataset_x, training_dataset_y, epochs=20, batch_size=32,
validation_split=0.2, callbacks=[esc])
```

Epoch grafiğini çizdirelim:

```
import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Loss - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Loss')
```

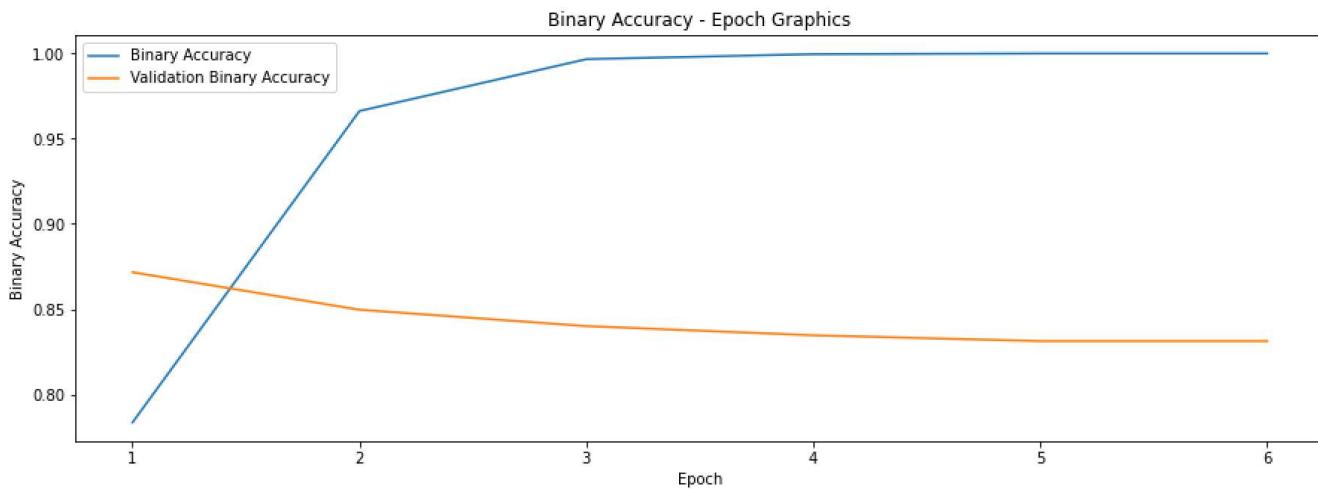
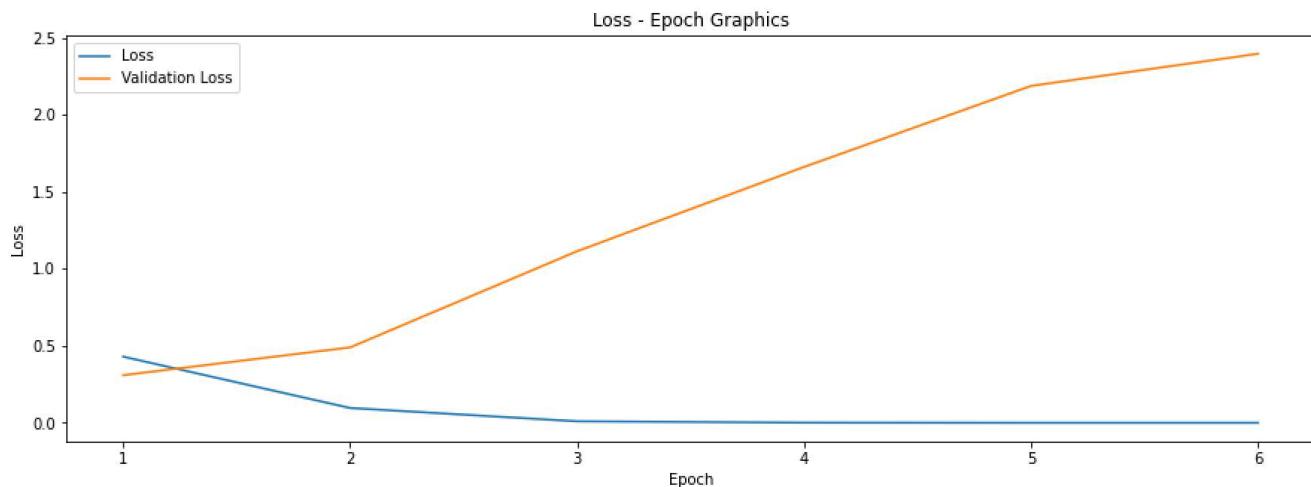
```

plt.plot(range(1, len(hist.history['loss']) + 1), hist.history['loss'])
plt.plot(range(1, len(hist.history['val_loss']) + 1), hist.history['val_loss'])
plt.legend(['Loss', 'Validation Loss'])
plt.show()

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Binary Accuracy - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Binary Accuracy')
plt.plot(range(1, len(hist.history['binary_accuracy']) + 1), hist.history['binary_accuracy'])
plt.plot(range(1, len(hist.history['val_binary_accuracy']) + 1),
hist.history['val_binary_accuracy'])
plt.legend(['Binary Accuracy', 'Validation Binary Accuracy'])
plt.show()

```

Şu grafikler elde edilmiştir:



Modelimiz test edelim:

```

eval_result = model.evaluate(test_dataset_x, test_dataset_y)
for i in range(len(eval_result)):
    print(f'{model.metrics_names[i]} --> {eval_result[i]}')

```

Şu sonuçlar elde edilmiştir:

```
loss --> 0.31072360277175903
```

```
binary_accuracy --> 0.8683199882507324
```

Word Embedding İşleminin Anlamı ve Görsel Bir Açıklama

Önceki bölümde word embedding işlemiyle birbirlerine semantik bakımdan yakın sözcüklerin birbirlerine yakın sayısal vektörlerle ifade edilebildiğini belirtmiştir. Bu bölümde bu durumu açıklayıp görsel bir örnek vereceğiz.

Analitik düzlemede (x_1, y_1) ve (x_2, y_2) noktaları arasındaki Öklit uzaklığının $\sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$ biçiminde hesaplandığını biliyorsunuz. Benzer biçimde N boyutlu uzayda da Öklit uzaklığı $\sqrt{\sum_{i=1}^n (p_i - q_i)^2}$ biçiminde hesaplanmaktadır. İşte word embedding eğitimi sonucunda semantik bakımdan benzer sözcüklerin arasındaki Öklit uzaklıklar daha az benzer olmayan sözcükler arasındaki Öklit uzaklıklar daha fazla olacaktır. Bu durumu IMDB örneği üzerinde iki boyutlu düzlemede basit bir örnekle gösterebiliriz. Örneğimizde her sözcük için düzlemede görüntüleme kolay olsun diye iki elemanlı bir word embedding vektörü üreteceğiz. Bunun için modeli şöyle oluşturabiliriz:

```
from tensorflow.keras.datasets import imdb

VOCAB_SIZE = 30000
TEXT_SIZE = 300

(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) =
imdb.load_data(num_words=VOCAB_SIZE)

word_dict = imdb.get_word_index()

from tensorflow.keras.preprocessing.sequence import pad_sequences

training_dataset_x = pad_sequences(training_dataset_x, maxlen=TEXT_SIZE, padding='post')
test_dataset_x = pad_sequences(test_dataset_x, maxlen=TEXT_SIZE, padding='post')

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Embedding, Flatten, Dense

model = Sequential(name='IMDB')
model.add(Embedding(VOCAB_SIZE, 2, input_length=TEXT_SIZE, name='Embedding'))
model.add(Flatten(name='Flatten'))
model.add(Dense(128, activation='relu', name='Dense-1'))
model.add(Dense(128, activation='relu', name='Dense-2'))
model.add(Dense(1, activation='sigmoid', name='Output'))
model.summary()

model.compile(optimizer='rmsprop', loss='binary_crossentropy', metrics=['binary_accuracy'])

from tensorflow.keras.callbacks import EarlyStopping

esc = EarlyStopping(monitor='val_loss', patience=5, restore_best_weights=True, verbose=1)

hist = model.fit(training_dataset_x, training_dataset_y, epochs=20, batch_size=32,
validation_split=0.2, callbacks=[esc])
```

Burada daha önce yaptığımız gibi IMDB modelimizi eğittik. Şimdi bir yazımı ağımıza girdi yapıp WordEmbedding katmanındaki çıktıyı elde edelim:

```
import numpy as np
import re

predict_text = 'great brilliant terrible bad fantastic movie wonderful horrible'
predict_words = re.findall("[a-zA-Z0-9]+", predict_text.lower())
```

```
predict_numbers = np.array([word_dict[pw] + 3 for pw in predict_words]).reshape(1, -1)
predict_data = pad_sequences(predict_numbers, TEXT_SIZE, padding='post')
```

Burada yazıyı eğitimde kullandığımız biçimde bir sayı dizisine dönüştürdük. Şimdi girişe bu yazıyı uygulayıp WordEmbedding katmanındaki çıktıyı elde edelim:

```
from tensorflow.keras.backend import function
get_embedding_out = function(model.layers[0].input, model.layers[0].output)
result_data = get_embedding_out(predict_data)[0]
```

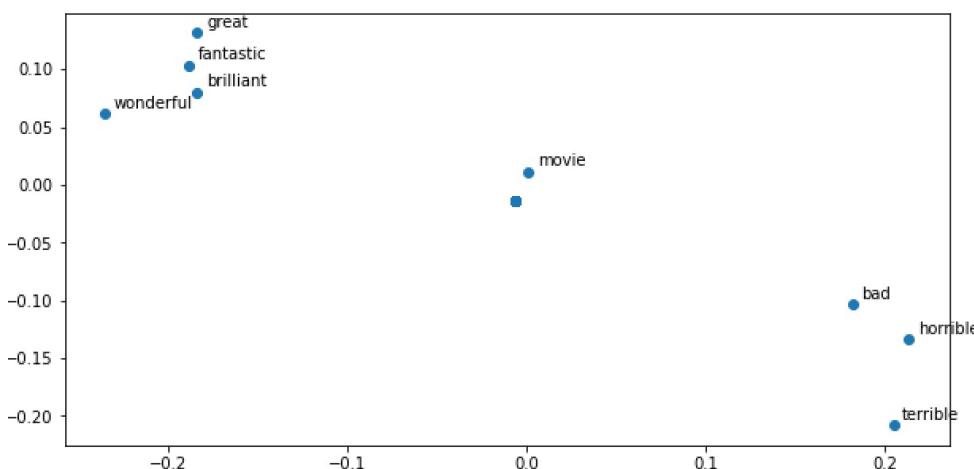
Burada result_data uyguladığımız girdiye karşılık elde ettiğimiz word embedding vektöründür. Nesnenin boyutuna dikkat ediniz:

```
In [140]: result_data.shape
Out[140]: (300, 2)
```

result_data 300 sözcüklük bir yazındaki her sözcüğün iki elemanlı word embedding vektörünü belirtmektedir. Bu matrisin ilk elemanları bizim yazında girdiğimiz sözcüklere ilişkin vektörler diğerleri de padding'ten dolayı sıfırlanmış değerleri ilişkin vektörlerdir. Şimdi sözcüklere karşı gelen noktaları düzleme gösterelim:

```
import matplotlib.pyplot as plt
figure = plt.gcf()
figure.set_size_inches((10, 5))
plt.scatter(result_data[:, 0], result_data[:, 1])
for i, txt in enumerate(predict_words):
    plt.annotate(txt, (result_data[i, 0] + 0.005, result_data[i, 1] + 0.005))
plt.show()
```

Şöyledir bir grafik elde edilmiştir:



Gördüğünüz gibi semantik olarak birbirlerine benzer sözcükler arasındaki Öklit uzaklıkları daha yakındır. Yukarıdaki kodu bir bütün olarak aşağıda veriyoruz:

```
from tensorflow.keras.datasets import imdb
VOCAB_SIZE = 30000
TEXT_SIZE = 300
(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) =
```

```

imdb.load_data(num_words=VOCAB_SIZE)

word_dict = imdb.get_word_index()

from tensorflow.keras.preprocessing.sequence import pad_sequences

training_dataset_x = pad_sequences(training_dataset_x, maxlen=TEXT_SIZE, padding='post')
test_dataset_x = pad_sequences(test_dataset_x, maxlen=TEXT_SIZE, padding='post')

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Embedding, Flatten, Dense

model = Sequential(name='IMDB')
model.add(Embedding(VOCAB_SIZE, 2, input_length=TEXT_SIZE, name='Embedding'))
model.add(Flatten(name='Flatten'))
model.add(Dense(128, activation='relu', name='Dense-1'))
model.add(Dense(128, activation='relu', name='Dense-2'))
model.add(Dense(1, activation='sigmoid', name='Output'))
model.summary()

model.compile(optimizer='rmsprop', loss='binary_crossentropy', metrics=['binary_accuracy'])

from tensorflow.keras.callbacks import EarlyStopping

esc = EarlyStopping(monitor='val_loss', patience=5, restore_best_weights=True, verbose=1)

hist = model.fit(training_dataset_x, training_dataset_y, epochs=20, batch_size=32,
validation_split=0.2,
callbacks=[esc])

import numpy as np
import re

predict_text = 'great brilliant terrible bad fantastic movie wonderful horrible'

predict_words = re.findall("[a-zA-Z0-9]+", predict_text.lower())
predict_numbers = np.array([word_dict[pw] + 3 for pw in predict_words]).reshape(1, -1)
predict_data = pad_sequences(predict_numbers, TEXT_SIZE, padding='post')

from tensorflow.keras.backend import function

get_embedding_out = function(model.layers[0].input, model.layers[0].output)

result_data = get_embedding_out(predict_data)[0]

import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches((10, 5))
plt.scatter(result_data[:, 0], result_data[:, 1])

for i, txt in enumerate(predict_words):
    plt.annotate(txt, (result_data[i, 0] + 0.005, result_data[i, 1] + 0.005))
plt.show()

```

Metinsel Uygulamalarda Word Embedding İşlemleri İle Evrişim İşlemlerinin Birlikte Kullanılması

Metinsel uygulamalarda word embedding işlemleri ile evrişim işlemleri birlikte de kullanılabilir. Bu tür modellere girdi katmanı olarak önce bir word embedding katmanı eklenir. Word embedding katmanının çıktısı tek boyutlu evrişim katmanına, evrişim katmanın da çıktısı bir ya da birden fazla dense katmana bağlanmaktadır. Şimdi böyle bir modeli IMDB veri kümesine uygulayalım. Bunun için yine önce Keras içerisinde hazır olarak bulunan IMDB verilerini yükleyelim:

```

from tensorflow.keras.datasets import imdb

VOCAB_SIZE = 30000
TEXT_SIZE = 300

(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) =
imdb.load_data(num_words=VOCAB_SIZE)

from tensorflow.keras.preprocessing.sequence import pad_sequences

training_dataset_x = pad_sequences(training_dataset_x, maxlen=TEXT_SIZE)
test_dataset_x = pad_sequences(test_dataset_x, maxlen=TEXT_SIZE)

```

Şimdi modelimizi kuralım:

```

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Embedding, Conv1D, MaxPooling1D, Flatten, Dense

model = Sequential(name='IMDB-Convolution')
model.add(Embedding(MAX_FEATURES, 32, name='Embedding', input_length=MAX_TEXT_LEN))
model.add(Conv1D(32, 3, padding='same', activation='relu', name='Conv1D'))
model.add(MaxPooling1D(name='MaxPooling1D'))
model.add(Flatten(name='Flatten'))
model.add(Dense(128, activation='relu', name='Dense'))
model.add(Dense(1, activation='sigmoid', name='Output'))
model.summary()

```

Modelde önce bir Embedding katmanı kullanarak word embedding işlemini gerçekleştirdik. Daha sonra word embedding işlemi ile elde edilen matrise Conv1D katmanı ile tek boyutlu evrişim işlemi uyguladık. Modelimizdeki Embedding katmanınının çıktısı iki boyutlu olduğu için Conv1D katmanınının ve MaxPooling1D katmanlarının çıktılarında iki boyutlu olduğuna dikkat ediniz. MaxPooling1D katmanınının çıktısını Dense katmana bağlayabilmek için Flatten katmanın kullanımını gerektiğini anımsayınız. Modelimiz için elde edilen summary bilgileri de şöyledir:

Model: "IMDB-Convolution"

Layer (type)	Output Shape	Param #
<hr/>		
Embedding (Embedding)	(None, 300, 32)	960000
Conv1D (Conv1D)	(None, 300, 32)	3104
MaxPooling1D (MaxPooling1D)	(None, 150, 32)	0
Flatten (Flatten)	(None, 4800)	0
Dense (Dense)	(None, 128)	614528
Output (Dense)	(None, 1)	129
<hr/>		
Total params: 1,577,761		
Trainable params: 1,577,761		
Non-trainable params: 0		

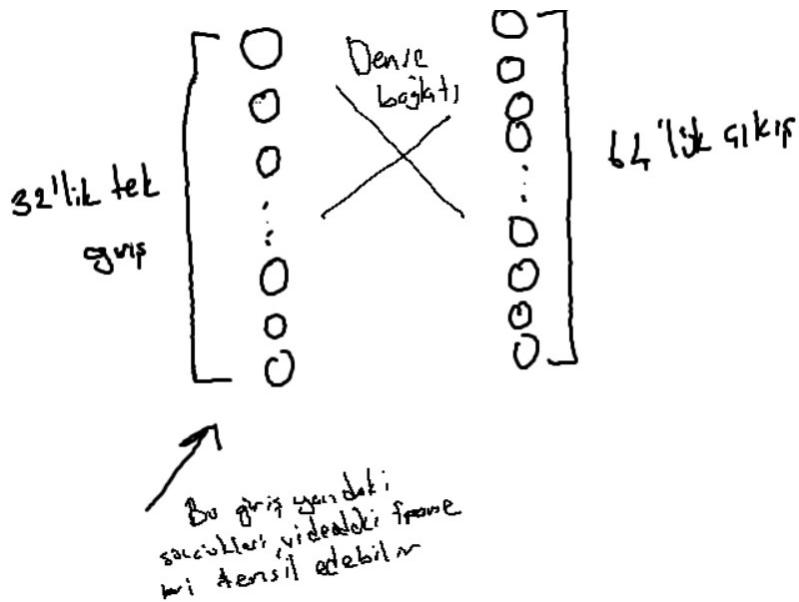
Buradaki değerlerin nasıl elde edildiği üzerinde durmak istiyoruz. Embedding katmanın girişinde 30000'lük bir one hot encoding vektörü vardır. Burada 32'lük çıktı için gereken nöron ağırlıklarının sayısı $30000 * 32 = 960000$ tanedir. Embedding katmanın çıkıştı 300X32'lük bir matris biçimindedir. Ancak buradaki her bir satır için ayrı bir filtre matrisi kullanılmamaktadır. Yani Conv1 katmanına giren bu 300X32'lük verilerin hepsi için aynı filtre kullanılmakadır.

Evrişim için seçilen filtre büyülüğu 3 olduğuna göre bu katmanda aslında matrisin her 32'lük elemanı için 3'lük bir filtreyi oluşturacak ağırlık değerleri tahmin edilmeye çalışılacaktır. Bu durumda Conv1D katmanındaki eğitilebilir parametrelerin sayısı $100 * 32$

Geri Beslemeli Sinir Ağları (Recurrent Neural Networks)

Şimdiye kadar görmüş olduğumuz ağ mimarilerinde bir nöronun çıktısı başka bir nörona girdi yapılıyordu. Bu tür ağ mimarilerine "ileriye doğru beslemeli (feed forward)" ağlar denilmektedir. İleriye doğru beslemeli ağlarda geçmişin kaydı ağıda tutulamamaktadır. Halbuki zamana dayalı uygulamalarda, doğal dil işleme uygulamalarında geçmişin de belli ölçülerde hatırlanması gerekmektedir. Örneğin IMDB veritabanında biz birtakım yorum yazılarından bu yorumların "iyi" mi "kötü" mü olduğu sonucunu çıkartmaya çalışıyorduk. Bu sonucun çıkartılması sözcüklerin önemli olduğu açıklır. Tasarladığımız ileriye doğru beslemeli ağ bu sözcüklerin önemini eğitim yoluyla öğrenmektedir. Ancak o örneğimizde sözcüklerin sırasının bir önemi yoktu. Halbuki yorum yazılarındaki sözcükler bir bağlam içerisinde gerçek anlamını bulabilmektedir. Yani o sözcüklerin kullandığı yerin geçmiş ve geleceği de o sözcüklerin anlamı üzerinde etkili olmaktadır. O halde böyle bir bağlamın sinir ağlarında oluşturulabilmesi için modelde bir biçimde geçmişin de etkili olması gereklidir. Aynı durum video görüntülerinde de söz konusudur. Videodaki görüntüler aslında frame'lerden (hareketli resmin anlık görüntüsü) oluşmaktadır. Fakat bu frame'ler birbirlerinden bağımsız değildir. Bir sonraki frame bir önceki frame'le ilgili olacak biçimde hareketli görüntüyü oluşturmaktadır. Başka bir deyişle görüntüde 10 saniye önce ne olduğu şimdi olanların anlamlandırılması için önemli olabilmektedir. Yani video frame'lerinden çıkartılacak sonuçlar anlık değil geçmişe de dayalıdır. Benzer biçimde finansal uygulamaların çoğu da belli bir geçmiş veri temelinde anlam kazanmaktadır. İşte "geri beslemeli ağ modeli geçmişin ve bağlamın da kestirimde dikkate alınmasını" sağlayan modeldir.

Şimdi biz yapay sinir ağı mimarisinde geri beslemeli bir ağ katmanın nasıl olması gerektiğini ele alalım. Geri beslemeli ağı yukarıda da açıkladığı gibi peşi sıra (zamansal) girdinin uygulandığı ağ modelidir. Bu birden fazla giriş muhtemelen bir sürecin içerisindeki elemanları oluşturmaktadır. Örneğin bir metindeki sözcükler, bir video görüntüsündeki frame'ler bu sıralı girişleri temsil ediyor olabilir. Örneğin 32'lük bir girdi katmanına (yani girişe) sahip olan çıktısı 64'lük olan bir katman düşünelim. Onun şekilsel gösterimi şöyle olacaktır:

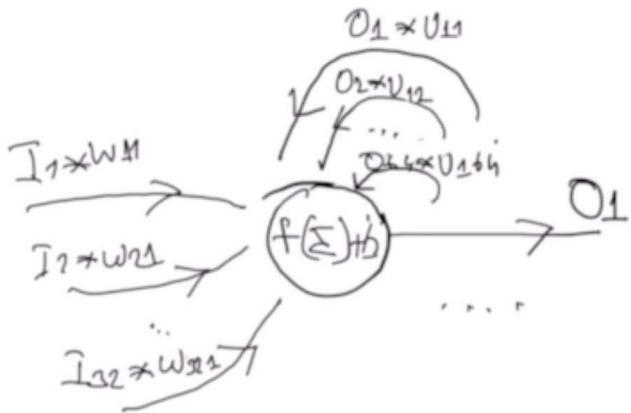


Geri beslemeli ağıda bir öğeye ilişkin girişler bir tane değildir. Bir grup giriş peşi sıra uygulanmaktadır. (Örneğin bizim daha önce yapmış olduğumuz IMDB ve Reuters örneklerinde biz tüm yorum yazısını tek bir girdi olarak ele almıştık. Halbuki aynı örneği geri beslemeli ağı ile yapacak olsak yazındaki her sözcük sıralı girdilerden birini temsil ediyor olacaktır.) Yukarıdaki çizimde girdi 32'lük olduğuna göre bu 32'lük giriş 64'lük bir dense katmana bağlanacağsa burada tahmin edilmesi gereken toplam W değerleri $32 * 64$ tane olacaktır. Çünkü ögenin sıralı girdileri için aynı W değerleri kullanılmaktadır. Geri beslemeli ağlarda bir girdi öğesinin parçalarının tek tek uygulanması meselenin bir yönünü oluşturmaktadır. Meselenin diğer yönü "geri besleme" işlemi ile ilgilidir. Peki bu ağlarda geri besleme nasıl yapılacaktır? Geri besleme çıktı nöron grubundaki her çıktı değerinin yeniden bu katmandaki girdilere geri

sokulmasıyla oluşturulur. Çıktı nöron grubundaki nöronların her bir tanesinin çıktısı başka ağırlık değerleriyle çarpılıp toplanarak (dot product işlemi) bir sonraki girdi ile beraber yine aynı katmana girdi yapılır. Girdinin belli bir öğesinin o andaki parçalı girdisi I_t olsun. Bir önceki parçalı girdiden elde edilen çıktıının da O_{t-1} olduğunu varsayıyalım. Bu durumda nöronun yeni çıkışı şöyle hesaplanır:

$$\text{nöronun yeni çıktı değeri} = \text{activation}(\text{np.dot}(I_t, W) + \text{np.dot}(O_{t-1}, U) + b)$$

Burada nörona uygulanan girdilerin hepsi oradaki ağırlık değerleriyle dot product işlemeye sokulmuş sonra da çıktı değerleri çıktı ağırlıklarıyla dot product işlemeye sokularak toplanmıştır. Bu toplama bias değeri eklenerek elde edilen toplam aktivasyon fonksiyonuna sokulmuştur. Yani başka bir deyişle nöronların çıktı değerleri sanki girdilerin bir parçası olmuş gibi işleme sokulmuştur. 32'lük parçalı girişin 64'lük bir dense katmana bağlanması durumundaki bir dense katman nörounundaki ilk nöronun bağlantıları şöyle olacaktır:



Buradaki bağlantı aşağıdaki gibi bir kod parçasıyla temsil edilebilir:

```
import numpy as np

TIMESPEC = 100          # ardışıl uygulanacak eleman sayısı
INPUT_FEATURES = 32      # girdi katmanındaki nöron sayısı
OUTPUT_FEATURES = 64      # çıktı katmanındaki nöron sayısı

def activation(x):
    return np.maximum(0, x)

inputs = np.random.random((TIMESPEC, INPUT_FEATURES))
W = np.random.random((OUTPUT_FEATURES, INPUT_FEATURES))
U = np.random.random((OUTPUT_FEATURES, OUTPUT_FEATURES))
b = np.random.random((OUTPUT_FEATURES,))

outputs = []

output_t = np.random.random((OUTPUT_FEATURES,))
for input_t in inputs:
    output_t = activation(np.dot(W, input_t) + np.dot(U, output_t) + b)
    outputs.append(output_t)

total_outputs = np.concatenate(outputs, axis=0)

print(total_outputs)
```

Bu kodda girdi kümesi 32, çıktı kümesi 64 nöronundan oluşmaktadır. Bir öğe toplam 100 ayrı parça biçiminde girişlere uygulanmaktadır. Yani buradaki örneği IMDB ya da Reuters'e benzetirsek yazının 100 sözcükten olduğunu, her sözcüğün toplam 32 sözcükten (vocabulary) bir tanesine ilişkin olduğunu (32'lük one hot encoding) söyleyebiliriz. Başka bir deyişle bu koddaki TIMESPEC peşi sıra oluşan girdilerin sayısını, INPUT_FEATURES ise bu girdilerin her birinin kaç seçenekten birine ilişkin olduğunu temsil etmektedir. Koddaki OUTPUT_FEATURES çıktı nöron grubundaki

nöron sayısını belirtmektedir. Kodumuzda işin başında W , U ve b vektörleri 0 ile 1 arasında rastgele sayılarından oluşanak biçimde alınmıştır. Buradaki W girdi değerlerinin çarpılacağı ağırlıkları, U ise çıktı değerlerinin yeniden girdi olarak işleme sokulurken çarpılacak ağırlıkları belirtmektedir. b ise çıktı nöron grubundaki nöronların bias değerleridir. Aktivasyon fonksiyonu olarak "relu" kullanılmıştır. Kodun döngü kısmına dikkat ediniz:

```
for input_t in inputs:  
    output_t = activation(np.dot(W, input_t) + np.dot(U, output_t) + b)  
    outputs.append(output_t)
```

Burada girdi vektörü W değerleriyle çarpılıp toplanıp bu toplama U değerlerinin çıktı vektörüyle çarpımı da eklenmiştir. Örnek kodumuzda tüm nöron çıktılarının bir liste içerisinde biriktirildiğini de görüyorsunuz. Çünkü bu katmanın çıktısının büyülüğu OUTPUT_FEATURES kadar olmayacağından. OUTPUT_FEATURES * TIMESPEC (yani 64 * 100) kadar olacaktır. Bütün bu çıktı bir sonraki katmana girdi olarak verilecektir. Kodumuzda en sonunda np.concatenate fonksiyonu ile elde edilen liste bir ndarray nesnesine dönüştürülmüştür.

Aslında yukarıdaki kodun yaptığı katman işlemini zaten yapan SimpleRNN isimli hazır bir Keras katman sınıfı vardır. Sınıfın init metodunun parametrik yapısı şöyledir:

```
tf.keras.layers.SimpleRNN(  
    units,  
    activation='tanh',  
    use_bias=True,  
    kernel_initializer='glorot_uniform',  
    recurrent_initializer='orthogonal',  
    bias_initializer='zeros',  
    kernel_regularizer=None,  
    recurrent_regularizer=None,  
    bias_regularizer=None,  
    activity_regularizer=None,  
    kernel_constraint=None,  
    recurrent_constraint=None,  
    bias_constraint=None,  
    dropout=0.0,  
    recurrent_dropout=0.0,  
    return_sequences=False,  
    return_state=False,  
    go_backwards=False,  
    stateful=False,  
    unroll=False,  
    **kwargs  
)
```

Buradaki units değeri katmanın çıkışındaki nöron sayısını belirtmektedir. (Yani örneğimizdeki OUTPUT_FEATURES değerini belirtmektedir.) Tabii Sequential modelde Keras katmanları peşi sıra yiğildiği için bu katmanın girdisi aslında bir önceki katmanın çıktı değeridir. Dolayısıyla SimpleRNN katmanı ağıın ilk katmanı olamaz. (Yani bu katmandan önce bir girdi katmanının olması gereklidir.) Uygulama bağlamında bu katman genellikle "word embedding" içeren Embedding katman olur.

Şimdi bir SimpleRNN katmanını Keras'ta oluşturup modeli analiz edelim:

```
from tensorflow.keras.models import Sequential  
from tensorflow.keras.layers import Embedding, SimpleRNN, Dense  
  
model = Sequential(name='RNN')  
model.add(Embedding(100, 32, name='Embedding'))  
model.add(SimpleRNN(64, activation='relu', name='SimpleRNN'))  
model.add(Dense(1, activation='sigmoid', name='Output'))  
  
model.summary()
```

Burada Embedding katmanının çıktısı tek bir vektör değildir. Her biri 32'lik vektörlerden oluşan bir matristir. Bu vektör aslında SimpleRNN katmanın girdilerini oluşturmaktadır. Başka bir deyişle aslında Embedding katmanın çıktısı olan 32'lik vektörler SimpleRNN katmanını zamansal olarak beslemekte kullanılacak girdileri oluşturmaktadır. Örneğimizdeki SimpleRNN katmanın çıktısı ise 64 nöronundan oluşmaktadır. Modelin summary çıktısı aşağıdaki gibidir:

Model: "RNN"

Layer (type)	Output Shape	Param #
=====		
Embedding (Embedding)	(None, None, 32)	3200
SimpleRNN (SimpleRNN)	(None, 64)	6208
Output (Dense)	(None, 1)	65
=====		
Total params: 9,473		
Trainable params: 9,473		
Non-trainable params: 0		

Modeldeki eğitilebilir parametrelerin sayısının nasıl elde edildiğine bakalım: Embedding katmandaki 32'lik girişlerin 100'lük bir one hot encoding'ten elde edilmesi için toplamda bu katmanda $100 * 32 = 3200$ tane ağırlık değerinin bulunması gereklidir. SimpleRNN katmanın girdileri ise 32'lik vektörlerden oluşmaktadır. Fakat bu girişler aynı W değerleri ile çarpılacağından giriş için gereken W değerleri $32 * 64 = 2048$ tane olur. Öte yandan her çıkış ayrıca dense biçimde yeniden SimpleRNN katmanındaki nöronlara bağlanacağından dolayı buradaki U katsayılarının sayısı da $64 * 64 = 4096$ olacaktır. Tabii bir de bias değerleri vardır. Bunlar da SimpleRNN katmanındaki nöron sayısı kadardır (yani 64). O halde toplam eğitilebilir parametrelerin sayısı $32 * 64 + 64 * 64 + 64 = 6208$ olur. SimpleRNN katmanın çıktısı 64 nöronundan oluşacağına göre ve çıktı katmanında tek bir nöron bulunduğuna göre çıktı katmanında tahmin edilecek parametre sayısı $64 * 1 + 1 = 65$ olacaktır.

Keras'in SimpleRNN katmanın çıktısı en son parçalı girişten elde edilen tek boyutlu bir vektördür. Bu durum SimpleRNN katmanın çıktısına başka bir SimpleRNN katmanı bağlanırken soruna yol açabilmektedir. Örneğin yukarıdaki modele bir tane daha SimpleRNN katmanı ekleyemeye çalışalım:

```
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Embedding, SimpleRNN, Dense

model = Sequential(name='RNN')
model.add(Embedding(100, 32, name='Embedding'))
model.add(SimpleRNN(64, activation='relu', name='SimpleRNN-1'))
model.add(SimpleRNN(64, activation='relu', name='SimpleRNN-2'))
model.add(Dense(1, activation='sigmoid', name='Output'))

model.summary()
```

Bu kod çalıştırılmak istendiğinde ikinci SimpleRNN katmanın eklenmesi işleminde exception oluşacaktır. Exception'ın nedeni ikinci SimpleRNN katmanın parçalı (zamansal) beslemede kullanılabilen matrisel bir girdi beklerken tek boyutlu vektörel bir bilgiyle karşılaşıyor olmasıdır. Çünkü SimpleRNN katmanı default durumda çıktı olarak zamansal girişler uygulandığındaki en son çıktının değerini vermektedir. (Halbuki bizim daha önce yazdığımız kod parçası bütün çıktıları biriktirip bir matris olarak veriyordu.) İşte SimpleRNN katmanın çıktısının biriktirilmiş çıktı değerlerinden oluşan bir matris olmasını sağlamak için SimpleRNN fonksiyonunun return_sequences isimli parametresi True geçilmelidir. Bu parametre True geçildiğinde artık ilk SimpleRNN katmanın çıktısı 64'lük vektörlerden oluşan bir matris olur. Böylece ikinci SimpleRNN katmanın girdisi için gereken zamansal matris ihtiyacı karşılanır. O halde yukarıdaki kodun düzeltilmiş biçimi şöyle olmalıdır:

```
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Embedding, SimpleRNN, Dense
```

```

model = Sequential(name='RNN')
model.add(Embedding(100, 32, name='Embedding'))
model.add(SimpleRNN(64, name='SimpleRNN-1', return_sequences=True))
model.add(SimpleRNN(64, name='SimpleRNN-2'))
model.add(Dense(1, activation='sigmoid', name='Output'))

model.summary()

```

Buradaki summary çıktısı da şöyledir:

Model: "RNN"

Layer (type)	Output Shape	Param #
<hr/>		
Embedding (Embedding)	(None, None, 32)	3200
SimpleRNN-1 (SimpleRNN)	(None, None, 64)	6208
SimpleRNN-2 (SimpleRNN)	(None, 64)	8256
Output (Dense)	(None, 1)	65
<hr/>		
Total params: 17,729		
Trainable params: 17,729		
Non-trainable params: 0		

Pekiyi burada son SimpleRNN katmanındaki eğitilebilir parametrelerin sayısı nasıl hesaplanmıştır? İkinci SimpleRNN katmanının girdi katmanı aslında 64×64 tane W değeri oluşacaktır. U değerleri de yine 64×64 tane olacaktır. Tabii 64 tane de bias değeri bulunacaktır. O halde toplam eğitilebilir parametrelerin sayısı $64 \times 64 + 64 \times 64 + 64 = 8256$ olmaktadır. Yine ikinci SimpleRNN katmanının çıkışında 64 nöron olacağından modelin çıktı katmanındaki eğitilebilir parametrelerin sayısı $64 \times 1 + 1 = 65$ tane olacaktır.

Geri Beslemeli Ağ Uygulaması Olarak SimpleRNN Katmanlarına Sahip IMDB Örneği

Şimdi yukarıda gördüğümüz konuları IMDB örneğiyle bir araya getirelim. Anımsanacağı gibi IMDB örneğinde kişilerin yorum yazılarından film hakkında olumlu mu olumsuz mu düşündükleri kestirilmeye çalışılıyordu. Daha önce yaptığımız IMDB örneğinde sözcüklerin öncelik sonralık ilişkisine baktık. Şimdi geri beslemeli bir ağ ile sözcükleri bağlam içerisinde değerlendirmeye çalışalım. IMDB verilerini daha önce yaptığımız gibi tensorflow.keras.datasets.imdb modülünü kullanarak okuyabiliriz:

```

from tensorflow.keras.datasets import imdb

VOCAB_SIZE = 10000
TEXT_SIZE = 300

(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) =
imdb.load_data(num_words=VOCAB_SIZE)

```

Burada zaten okunan training_dataset_x verileri yorumlardaki sözcük indekslerinden oluşan NumPy dizisi biçimindedir. Örneğin:

```
In [2]: training_dataset_x
```

```
Out[2]:
```

```
array([list([1, 14, 22, 16, 43, 530, 973, 1622, 1385, 65, 458, 4468, 66, 3941, 4, 173, 36, 256, 5, 25, 100, 43, 838, 112, 50, 670, 2, 9, 35, 480, 284, 5, 150, 4, 172, 112, 167, 2, 336, 385, 39, 4, 172, 4536, 1111, 17, 546, 38, 13, 447, 4, 192, 50, 16, 6, 147, 2025, 19, 14, 22, 4, 1920, 4613, 469, 4, 22, 71, 87, 12, 16, 43, 530, 38, 76, 15, 13, 1247, 4, 22, 17, 515, 17, 12, 16, 626, 18, 2, 5, 62, 386, 12, 8, 316, 8, 106, 5, 4, 2223, 5244, 16, 480, 66, 3785, 33, 4, 130, 12, 16, 38, 619, 5, 25, 124, 51, 36, 135, 48, 25, 1415, 33, 6, 22, 12, 215, 28, 77, 52, 5, 14, 407, 16, 82, 2, 8, 4, 107, 117, 5952, 15, 256, 4, 2, 7, 3766, 5, 723, 36, 71, 43, 530, 476, 26, 400, 317, 46, 7, 4, 2, 1029, 13, 104, 88, 4, 381, 15, 297, 98, 32, 2071, 56, 26, 141, 6, 194, 7486, 18, 4, 226, 22, 21, 134, 476, 26, 480, 5, 144, 30, 5535, 18, 51, 36, 28, 224, 92, 25, 104, 4, 226, 65, 16, 38, 1334, 88, 12, 16, 283, 5, 16, 4472, 113, 103, 32, 15, 16, 5345, 19, 178, 32]), list([1, 194, 1153, 194, 8255, 78, 228, 5, 6, 1463, 4369, 5012, 134, 26, 4, 715, 8, 118, 1634, 14, 394, 20, 13, 119, 954, 189, 102, 5, 207, 110, 3103, 21, 14, 69, 188, 8, 30, 23, 7, 4, 249, 126, 93, 4, 114, 9, 2300, 1523, 5, 647, 4, 116, 9, 35, 8163, 4, 229, 9, 340, 1322, 4, 118, 9, 4, 130, 4901, 19, 4, 1002, 5, 89, 29, 952, 46, 37, 4, 455, 9, 45, 43, 38, 1543, 1905, 398, 4, 1649, 26, 6853, 5, 163, 11, 3215, 2, 4, 1153, 9, 194, 775, 7, 8255, 2, 349, 2637, 148, 605, 2, 8003, 15, 123, 125, 68, 2, 6853, 15, 349, 165, 4362, 98, 5, 4, 228, 9, 43, 2, 1157, 15, 299, 120, 5, 120, 174, 11, 220, 175, 136, 50, 9, 4373, 228, 8255, 5, 2, 656, 245, 2350, 5, 4, 9837, 131, 152, 491, 18, 2, 32, 7464, 1212, 14, 9, 6, 371, 78, 22, 625, 64, 1382, 9, 8, 168, 145, 23, 4, 1690, 15, 16, 4, 1355, 5, 28, 6, 52, 154, 462, 33, 89, 78, 285, 16, 145, 95]), list([1, 14, 47, 8, 30, 31, 7, 4, 249, 108, 7, 4, 5974, 54, 61, 369, 13, 71, 149, 14, 22, 112, 4, 2401, 311, 12, 16, 3711, 33, 75, 43, 1829, 296, 4, 86, 320, 35, 534, 19, 263, 4821, 1301, 4, 1873, 33, 89, 78, 12, 66, 16, 4, 360, 7, 4, 58, 316, 334, 11, 4, 1716, 43, 645, 662, 8, 257, 85 1200 42 1228 2578 83 68 2912 15 36 165 1529 278 36 69 2 780 8 106 14 6905
```

Göründüğü gibi buradaki NumPy dizisi Python listelerinden oluşmaktadır. Python listelerinde de yorumlardaki sözcüklerin indeks numaraları vardır. Şimdi yorumlardaki sözcük sayılarını eşit hale getirelim:

```
from tensorflow.keras.preprocessing.sequence import pad_sequences
```

```
training_dataset_x = pad_sequences(training_dataset_x, maxlen=TEXT_SIZE)
test_dataset_x = pad_sequences(test_dataset_x, maxlen=TEXT_SIZE)
```

Şimdi artık tüm yorumlar eşit sayıda sözcüklerden oluşan gibi bir durum elde edilmiştir. Artık modelimizi kurabiliriz:

```
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Embedding, SimpleRNN, Dense

model = Sequential(name='IMDB')
model.add(Embedding(VOCAB_SIZE, 64, input_length=TEXT_SIZE, name='Embedding'))
model.add(SimpleRNN(32, activation='relu', return_sequences=True, name='SimpleRNN-1'))
model.add(SimpleRNN(32, activation='relu', name='SimpleRNN-2'))
model.add(Dense(1, activation='sigmoid', name='Output'))

model.summary()
```

Burada Embedding katmanının çıktısı 64'lük vektörlerden oluşan bir matristir. Bu matris SimpleRNN katmanına parçalı girdi yapılmıştır. İlk SimpleRNN katmanın çıktısı bu katmanda return_sequences=True yapıldığı için tek bir vektor değil 32'lük vektörlerden oluşan bir matris olacaktır. İkinci SimpleRNN katmanın çıktısı ise return_sequences=True yapılmadığı için tek bir vektördür (son vektor). Bu katman da çıktı katmanına dense biçimde bağlanmıştır. Bu tür modellerde nöron sayılarını artırırken dikkat etmelisiniz. Eğitim veri kümesi azken nöron sayılarını artırmak performansı yükseltmek yerine düşürebilmektedir. Modeldeki nöron sayılarının fazla tutulmadığına ve ek Dense katmanların bulundurulmadığına dikkat ediniz.

Modelden elde edilen summary bilgileri şöyledir:

Model: "IMDB"

Layer (type)	Output Shape	Param #
=====		
Embedding (Embedding)	(None, None, 64)	1920000

SimpleRNN-1 (SimpleRNN)	(None, None, 32)	3104
SimpleRNN-2 (SimpleRNN)	(None, 32)	2080
Output (Dense)	(None, 1)	33
=====		
Total params: 1,925,217		
Trainable params: 1,925,217		
Non-trainable params: 0		

Şimdi modelimi derleyip eğitelim:

```
model.compile(optimizer='rmsprop', loss='binary_crossentropy', metrics=['binary_accuracy'])

from tensorflow.keras.callbacks import EarlyStopping

esc = EarlyStopping(monitor='val_loss', patience=5, restore_best_weights=True, verbose=1)
hist = model.fit(training_dataset_x, training_dataset_y, epochs=20, batch_size=32,
validation_split=0.2, callbacks=[esc])
```

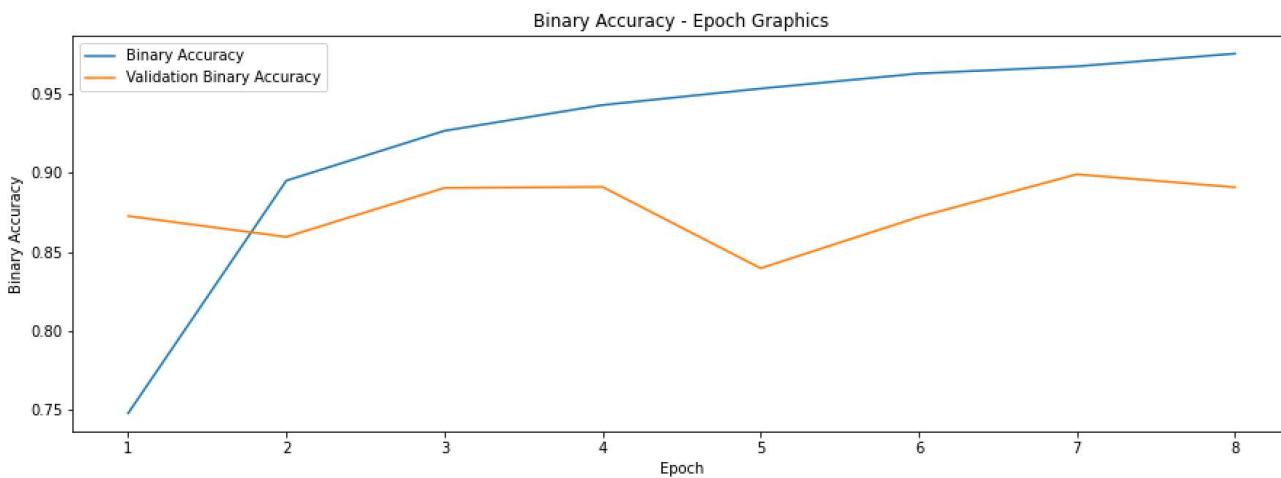
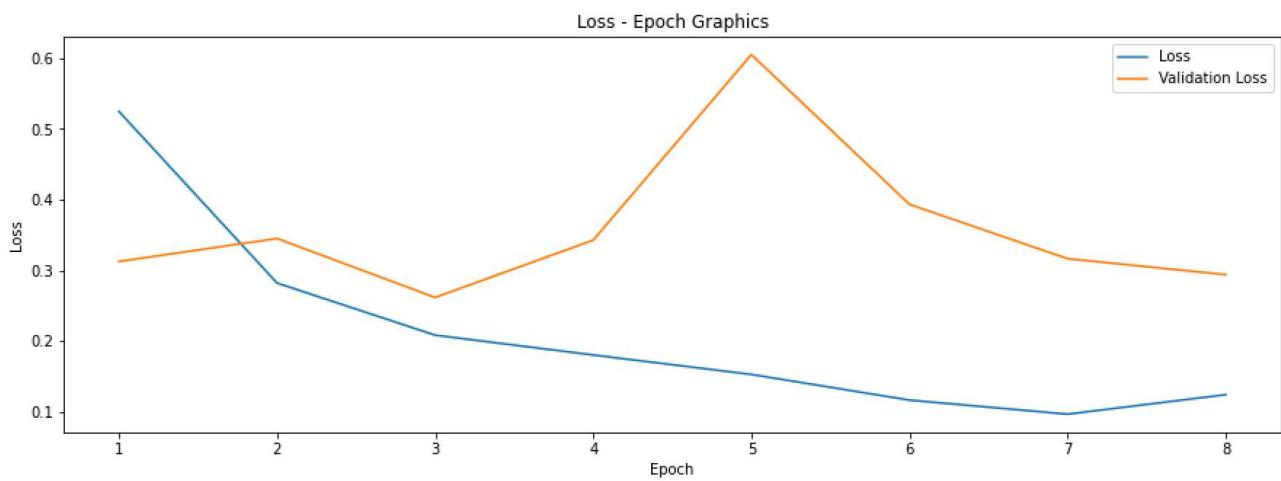
Burada "val_loss" değerinde üst üste 5 kere iyileşme olmazsa model sonlandırılmıştır ve en iyi ağırlık değerleri modele yüklenmiştir. Şimdi elde edilen modelin epoch grafiğini çizelim:

```
import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Loss - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.plot(range(1, len(hist.history['loss']) + 1), hist.history['loss'])
plt.plot(range(1, len(hist.history['val_loss']) + 1), hist.history['val_loss'])
plt.legend(['Loss', 'Validation Loss'])
plt.show()

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Binary Accuracy - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Binary Accuracy')
plt.plot(range(1, len(hist.history['binary_accuracy']) + 1), hist.history['binary_accuracy'])
plt.plot(range(1, len(hist.history['val_binary_accuracy']) + 1),
hist.history['val_binary_accuracy'])
plt.legend(['Binary Accuracy', 'Validation Binary Accuracy'])
plt.show()
```

EarlyStopping sonlandırmasına kadar elde edilmiş olan değerlerin grafiği şöyledir:



Şimdi de modelimizi test edelim:

```
eval_result = model.evaluate(test_dataset_x, test_dataset_y)
for i in range(len(eval_result)):
    print(f'{model.metrics_names[i]} --> {eval_result[i]}')
```

Şu sonuçlar elde edilmiştir:

```
loss --> 0.2805195450782776
binary_accuracy --> 0.8838000297546387
```

Yukardaki örneğin tüm kodları bir bütün olarak aşağıda veriyoruz:

```
from tensorflow.keras.datasets import imdb

VOCAB_SIZE = 30000
TEXT_SIZE = 300

(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) =
imdb.load_data(num_words=VOCAB_SIZE)

from tensorflow.keras.preprocessing.sequence import pad_sequences

training_dataset_x = pad_sequences(training_dataset_x, maxlen=TEXT_SIZE)
test_dataset_x = pad_sequences(test_dataset_x, maxlen=TEXT_SIZE)

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Embedding, SimpleRNN, Dense
```

```

model = Sequential(name='IMDB')
model.add(Embedding(VOCAB_SIZE, 64, input_length=TEXT_SIZE, name='Embedding'))
model.add(SimpleRNN(32, activation='relu', return_sequences=True, name='SimpleRNN-1'))
model.add(SimpleRNN(32, activation='relu', name='SimpleRNN-2'))
model.add(Dense(1, activation='sigmoid', name='Output'))
model.summary()

model.compile(optimizer='rmsprop', loss='binary_crossentropy', metrics=['binary_accuracy'])

from tensorflow.keras.callbacks import EarlyStopping

esc = EarlyStopping(monitor='val_loss', patience=5, restore_best_weights=True, verbose=1)

hist = model.fit(training_dataset_x, training_dataset_y, epochs=20, batch_size=32,
validation_split=0.2, callbacks=[esc])

import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Loss - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.plot(range(1, len(hist.history['loss']) + 1), hist.history['loss'])
plt.plot(range(1, len(hist.history['val_loss']) + 1), hist.history['val_loss'])
plt.legend(['Loss', 'Validation Loss'])
plt.show()

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Binary Accuracy - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Binary Accuracy')
plt.plot(range(1, len(hist.history['binary_accuracy']) + 1), hist.history['binary_accuracy'])
plt.plot(range(1, len(hist.history['val_binary_accuracy']) + 1),
hist.history['val_binary_accuracy'])
plt.legend(['Binary Accuracy', 'Validation Binary Accuracy'])
plt.show()

eval_result = model.evaluate(test_dataset_x, test_dataset_y)
for i in range(len(eval_result)):
    print(f'{model.metrics_names[i]} --> {eval_result[i]}')

```

Sinir Ağlarında Düzenleme (Regularization) İşlemleri

Önceki bölümlerde sinir ağlarının eğitiminde "overfitting" ve "underfitting" olgularını ele almıştık. Overfitting modelin istediğimiz şeyi değil başka şeyleri öğrenmesi underfitting ise modelin istediğimiz şeyleri arzu ettiğimiz düzeyde öğrenememesi anlamına geliyordu. Anımsayacağınız gibi modelin eğitimde gösterdiği başarıyı sınama ya da test sırasında gösteremiyor olması overfitting durumunun en önemli göstergesiydı. Yine ilgili bölümde overfitting durumunun başlıca nedenlerinin şunlar olabileceğini ifade etmiştik:

- Modelin karmaşık olması yani çok fazla nöron içermesi
- Eğitim verilerinin az olması
- Eğitim sırasında fazla epoch uygulanması

Makine öğrenmesinde overfitting durumunu engellemek için kullanılan yöntemlere düzenleme (regularization) işlemleri denilmektedir. En çok kullanılan düzenleme işlemlerinden iki tanesi "L1 / L2" düzenlemesi" ve "dropout" düzenlemesidir. Biz burada dropout düzenlemesi üzerinde duracağız.

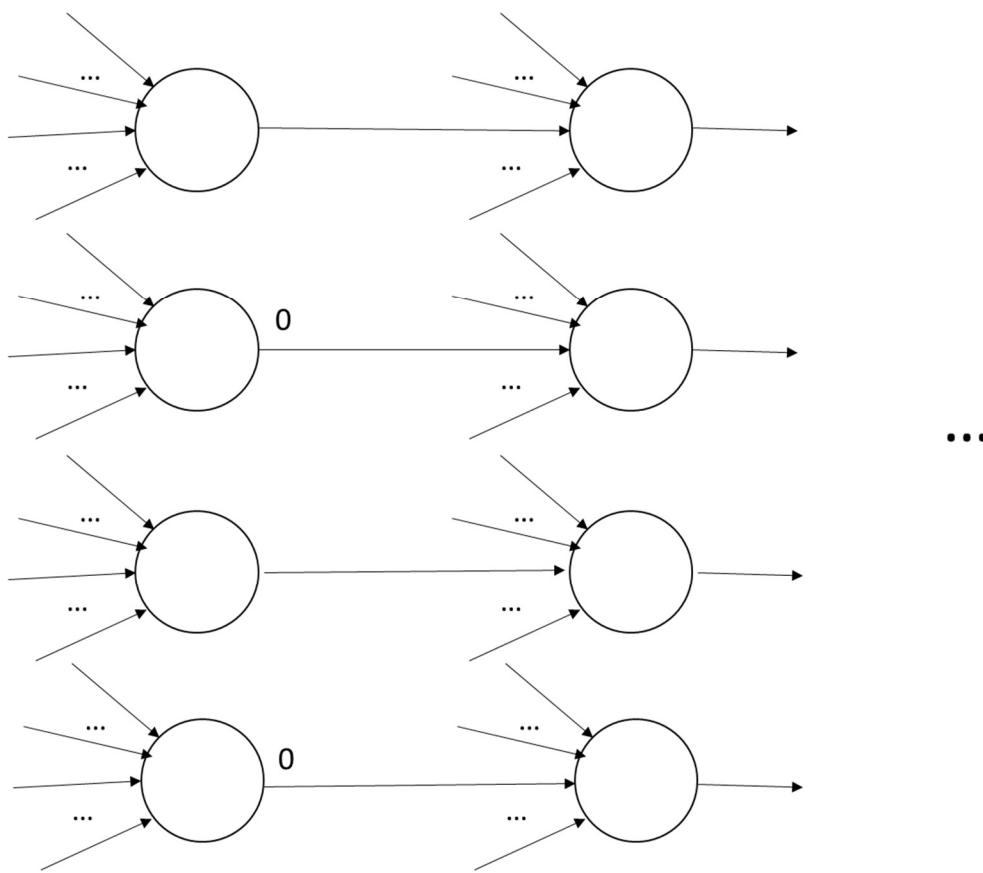
Dropout Düzenlemesi (Dropout Regularization)

Dropout düzenlemesi son zamanlarda en çok kullanılan düzenleme tekniklerinden biridir. Bu teknik ilk kez 2014 yılında Toronto Üniversitesi öğretim elemanları Srivastana, Hinton ve arkadaşları tarafından ortaya atılmıştır. Bu teknique göre sinir ağının saklı katmanlarındaki nöronların belli kısımları eğitim sırasında rastgele bir biçimde ağdan atılırsa bu durum overfitting durumuna direnç oluşturmaktadır. Teknik önce sezgisel olarak düşünülmüş ancak deneyisel olarak faydalı olduğu doğrulanmıştır. Dropout işlemi özellikle ağın saklı katmanları üzerinde uygulanmaktadır.

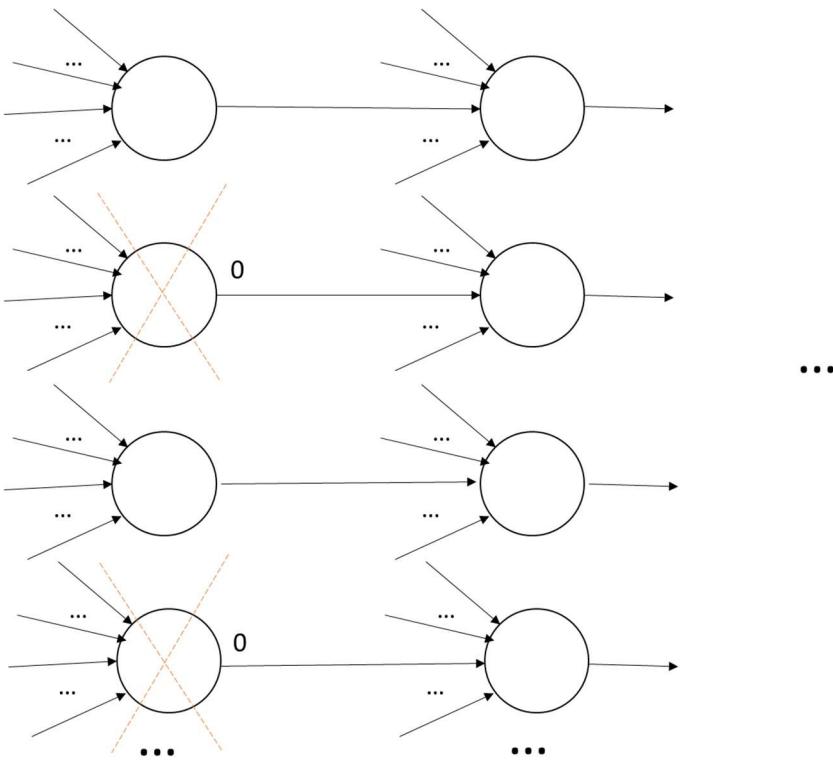
Aslında dropout işlemi sırasında uygulamada atılacak nöronlar gerçekten ağdan atılmamakta yalnızca onların çıktı değerleri bir sonraki katman için 0'a çekilmektedir. (Nöronun ağdan atılmasıyla çıktı değerinin 0'a çekilmesi arasında anlamsal bir farklılık olmadığına dikkat ediniz.) Pekiyyi dropout işlemi sırasında ağdan atılacak nöronlar nasıl belirlenmektedir? İşte bu işlem belli bir olasılık dahilinde rastgele bir biçimde yapılmaktadır. Örneğin nöron atılma olasılığı için 0.5 değerinin kullanıldığını varsayıyalım. Bu durumda katmandaki her nöronun atılma olasılığı 0.5'tir. (Yani örneğin bu durumda 0 ile 1 arasında rastgele bir sayı üretilebilir. Eğer bu sayı 0.5'ten düşükse nöron atılır, değilse nöron atılmaz. Benzer biçimde örneğin nöron atılma olasılığı 0.2 ise katmandaki her nöron için yine 0 ile 1 arasında rastgele bir sayı üretilebilir. Bu sayı 0.2'den küçükse nöron atılır, değilse nöron atılmaz. Uygulamada saklı katmanlar için genellikle 0.2 ile 0.5 arasında değerler girdi katmanı için ise 0.8 civarında değerler kullanılmaktadır.)

Dropout işlemi eğitim sırasında her batch işleminden sonra uygulanmaktadır. Yani her batch işlemi bittiğinde nöron ağırlık değerleri güncellendikten sonra yeniden ilgili katmanda belirlenen oranda nöron ağdan atılmaktadır. Böylece her batch işlemi sırasında ağdan farklı nöron grubu atılmaktadır. Geri beslemeli (recurrent) ağlarda bir nöronun ağdan atılması (yani çıkışının sıfır çekilmesi) yapılan geri beslemenin de iptal edilmesi gibi bir anlama gelmektedir.

Şimdi dropout işleminin nasıl yapıldığını şekilsel olarak göstermeye çalışalım. Aşağıdaki gibi bir ara katman söz konusu olsun:



Soldaki katmana dropout düzenlemesi uygulanacak olsun. Bu durumda her batch işleminde bu katmandaki rastgele nöronların çıkışları 0 yapılarak ağdan atılmış etkisi oluşturulmaktadır:



Dropout işleminden sonra genellikle katmanda sıfırlanmayan nöronlar belli değerlerle çarpılarak büyütülürler. Bu büyütme miktarları da genellikle dropout olasılığı ile orantılı biçimde yapılmaktadır. Örneğin katmandan atılma olasılığının 0.5 olduğunu varsayıyalım. Bu durumda katmandaki nöronların yarısı atılacaktır. İşte atılmayan nöronların çıktı değerleri de 2 ile çarpılarak büyütülebilmektedir.

Dropout işlemi yalnızca eğitim sırasında yapılan bir işlemidir. Ağ eğitildikten sonra test ya da kestirim sırasında dropout işlemi yapılmaz. Yani test ve kestirim işlemi ağdaki tüm nöronlar kullanılarak yapılmaktadır. Bir nöronun ağdan atılmasının aslında gerçek anlamda bir atılma anlamına gelmediğine nöron bilgilerinin korunup yalnızca çıkışının sıfır yapıldığına dikkat ediniz.

Keras'ta Dropout düzenlemesi için tensorflow.keras.layers modülünde Dropout isimli bir sınıf bulundurulmuştur. Dropout sınıfının `__init__` metodunun parametrik yapısı şöyledir:

```
tensorflow.keras.layers.Dropout(
    rate,
    noise_shape=None,
    seed=None,
    **kwargs
)
```

Metodun birinci parametresi katmandan atım için uygulanacak olasılığı belirtmektedir. Dropout katmanı yerleştirildiği yerin öncesindeki katmandaki nöronlar üzerinde etkili olmaktadır. Siz bu katmanı önceki katmanın çıkışlarının bazılarını 0 yapan bir katman olarak düşünebilirsiniz. Keras'in Dropout katmanı atılmayan nöronların çıktı değerlerini $1 / (1 - \text{rate})$ oranında yükseltmektedir. Örneğin:

```
import numpy as np
import tensorflow as tf

layer = tf.keras.layers.Dropout(0.5)
data = np.array([1, 2, 3, 4, 5, 6, 7, 8, 9, 10], dtype=np.float32)
result = layer(data, training=True)
print(data)
print(result)
```

Buradan şöyle bir çıktı elde edilmiştir:

```
[ 1.  2.  3.  4.  5.  6.  7.  8.  9. 10.]  
tf.Tensor([ 2.  4.  0.  0. 10. 12. 14. 16. 18.  0.], shape=(10,), dtype=float32)
```

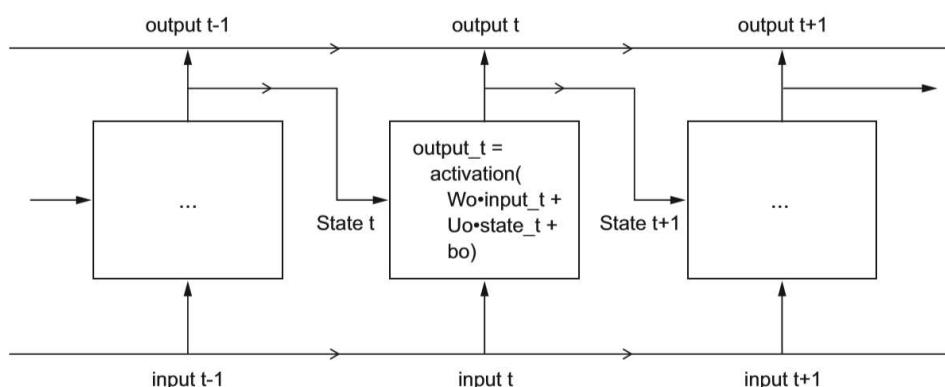
Göründüğü gibi burada her nöron için atılma olasılığı 0.5 olarak belirlenmiştir. Atılmayan nöronların çıktı değerleri de $1 / (1 - 0.5) = 2$ oranında yükseltilmiştir.

Geri Beslemeli Ağlar İçin LSTM Katmanı

Yukarıda kullanmış olduğumuz SimpleRNN katmanı aslında uygulamalarda pek tercih edilmemektedir. Çünkü bu katmanın bazı sorunları vardır. SimpleRNN katmanı her ne kadar geçmişe doğru bir hafıza oluşturuyorsa da bu hafıza "vanishing gradient problem" ismi verilen bir sorun yüzünden yakın geçmişe yönelik olarak kalmaktadır. Yani SimpleRNN katmanı o andaki bağlamın hemen öncesini yine bir biçimde hatırlayabilmekte geçmişi gittikçe daha zor hatırlayabilmektedir. Bu durum bağlamsal etkiyi azaltmaktadır. Bunun çözümü araştırcılar çeşitli yöntemler önermişlerdir. 90'lı yılların sonlarına doğru LSTM ve GRU katmanları bu sorunu çözmek için kullanılmıştır.

LSTM katmanını ele almaya başlamadan önce SimpleRNN katmanını anımsatmak istiyoruz. Aşağıda SimpleRNN katmanın parçalı (zamansal) verilerle beslenme biçimini görüyorsunuz:

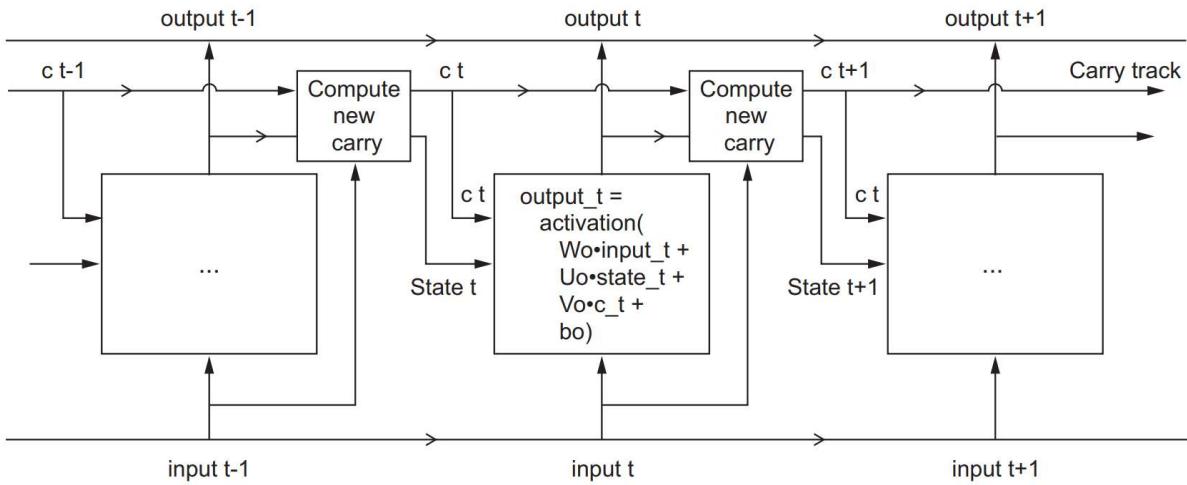
Bu yeni modeli SimpleRNN ile karşılaştırınız:



Alıntı Notu: Görsel "Deep Learning with Python (François Chollet)" isimli kitaptan alınmıştır.

Burada "input t" ile belirtilen veriler parçalı (zamansal) verilerdir. Şekilde her parça ayrı bir kutucukla gösterilmiştir. Göründüğünüz gibi önceki parçanın çıktısı sonraki parçayla birlikte yeniden girdi yapılmaktadır.

LSTM (Long Short Term Memory) katmanı ağa hem kısa süreli hem de uzun süreli bir hafıza oluşturmayı hedeflemektedir. LSTM SimpleRNN'nin mimari olarak biraz daha geliştirilmiş bir biçimidir. LSTM katmanında uzun dönem etkisi için yeni bir giriş daha ağa eklenmiş durumdadır. Mimarisinin temsili görüntüsü şöyledir:



Aıntı Notu: Görsel "Deep Learning with Python (François Chollet)" isimli kitaptan alınmıştır.

Bu mimaride SimpleRNN'den farklı olarak bir de c girişi uygulanmıştır. Bu durumda geri beslemeli ağın girdileri şunlar olmaktadır: Zamansal gerçek girdiler (yani metinsel uygulamalardaki sözcükler, şekildeki "input"lar), önceki çıktılar (şekildeki "state"ler) ve uzun dönem hafıza etkisi sağlayan "c" girişleri (şekildeki "c"ler). Pekiyi burada "c" vektörleri nasıl hesaplanmaktadır? Şekilden c vektörlerinin nöronun çıktısıyla, bir önceki c değeriyle ve girişle kombinere edilerek oluşturulduğunu görüyorsunuz. Bu oluşturulma işleminin matematiksel biçimini söyleyelim:

- Öncelikle buradaki parçalı girdinin çıktısı şöyle hesaplanmaktadır:

```
output_t = activation(np.dot(input_t, W) + np.dot(state_t, U) + np.dot(c_t, V) + b)
```

Buradaki V matrisi aslında 9 matrisin birleşimini temsil etmektedir. Eşitlikteki c_t girişleri şöyle hesaplanmaktadır:

```
c_t+1 = i_t * k_t + c_t * f_t
```

Yukarıda belirtilen c_t girişlerinin hesaplanmasıında kullanılan i_t , k_t ve f_t vektörleri ise şöyle hesaplanmaktadır:

```
i_t = activation(np.dot(state_t, U_i) + np.dot(input_t, W_i) + b_i)
f_t = activation(np.dot(state_t, U_f) + np.dot(input_t, W_f) + b_f)
k_t = activation(np.dot(state_t, U_k) + np.dot(input_t, W_k) + b_k)
```

Burada işin içine başka ağırlık değerlerinin de karıştığını görüyorsunuz: U_i , U_f , U_k , W_i , W_f , W_k , b_i , b_f ve b_k .

Şimdi LSTM katmanındaki eğitilebilir parametrelerin sayısını hesaplayalım. Bunun için önce iki büyülüye isim vereceğiz:

n : LSTM katmanına giren parçalı nöron sayısı olsun

m : LSTM katmanındaki nöron sayısı olsun

Bu durumda W matrisinin eleman sayısı $n * m$, U matrislerisinin eleman sayısı $m * m$ 'dir. U_i , U_f ve U_k matrislerinin eleman sayıları ise $m * m$, W_i , W_f ve W_k matrislerinin eleman sayıları ise $n * m$ tanedir. Bu katmandaki toplam bias değerlerinin sayısının da $b + b_i + b_f + b_k$ olduğuna dikkat ediniz. Bunların hepsi m tanedir. O halde LSTM katmanındaki eğitilebilir parametrelerin sayısı da $4 * (n * m + m * m + m)$ olacaktır.

Keras'ta LSTM katmanı doğrudan LSTM isimli sınıfla temsil edilmiştir. Bu katmanın kullanılması SimpleRNN katmanına benzemektedir.

```
tensorflow.keras.layers.LSTM(
    units,
    activation='tanh',
    recurrent_activation='sigmoid',
```

```

        use_bias=True,
        kernel_initializer='glorot_uniform',
        recurrent_initializer='orthogonal',
        bias_initializer='zeros',
        unit_forget_bias=True,
        kernel_regularizer=None,
        recurrent_regularizer=None,
        bias_regularizer=None,
        activity_regularizer=None,
        kernel_constraint=None,
        recurrent_constraint=None,
        bias_constraint=None,
        dropout=0.0,
        recurrent_dropout=0.0,
        implementation=2,
        return_sequences=False,
        return_state=False,
        go_backwards=False,
        stateful=False,
        unroll=False
)

```

Burada görüldüğü gibi tek zorunlu parametre birinci units parametresidir. Bu parametre çıktıının nöron sayısını belirtir. Yani bu anlamda LSTM katmanının basit kullanımı tamamen SimpleRNN katmanı gibidir. Burada önemli olan bir nokta LSTM katmanında aktivasyon fonksiyonunun "tanh" gibi bir şeyle sahip olmasıdır. LSTM katmanlarında relu aktivasyon fonksiyonunu kullanmayınız.

Pekiyi LSTM katmanı her zaman SimpleRNN'ye göre tercih edilmeli midir? Aslında LSTM uzun dönem hafıza etkisini sağladığına göre bunun bazı modellerde dezavantajı da olabilmektedir. Fakat genellikle bu uzun dönem etki istenir. Bu nedenle LSTM katmanı çoğu kez SimpleRNN'ye tercih edilmektedir. Şimdi LSTM katmanını IMDB veri kümesine uygulayalım. Önce yine Keras içerisinde hazır halde bulunan IMDB verilerini yükleyelim ve parçalı girdiler için düzenlemeyi yapalım:

```

VOCAB_SIZE = 30000
TEXT_SIZE = 300

from tensorflow.keras.datasets import imdb

(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) =
imdb.load_data(num_words=VOCAB_SIZE)

word_dict = imdb.get_word_index()

from tensorflow.keras.preprocessing.sequence import pad_sequences

training_dataset_x = pad_sequences(training_dataset_x, TEXT_SIZE, padding='post')
test_dataset_x = pad_sequences(test_dataset_x, TEXT_SIZE, padding='post')

```

Şimdi modelimizi oluşturalım. Aslında modelimiz SimpleRNN örneğindekine benzer olacaktır. Ancak tabii geri besleme katmanı olarak SimpleRNN yerine LSTM kullanacağız:

```

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Embedding, LSTM, Dropout, Dense

model = Sequential(name='IMDB-LSTM')
model.add(Embedding(VOCAB_SIZE, 64, input_length=TEXT_SIZE, name='Embedding'))
model.add(LSTM(64, activation='tanh', name='LSTM'))
model.add(Dropout(0.5, name='Dropout-1'))
model.add(Dense(128, activation='relu', name='Dense'))
model.add(Dropout(0.5, name='Dropout-2'))
model.add(Dense(1, activation='sigmoid', name='Output'))

```

```
model.summary()
```

Burada elde edilen modelin özet bilgileri şöyledir:

Model: "IMDB-LSTM"

Layer (type)	Output Shape	Param #
=====		
Embedding (Embedding)	(None, 300, 64)	1920000
LSTM (LSTM)	(None, 64)	33024
Dropout-1 (Dropout)	(None, 64)	0
Dense (Dense)	(None, 128)	8320
Dropout-2 (Dropout)	(None, 128)	0
Output (Dense)	(None, 1)	129
=====		
Total params:	1,961,473	
Trainable params:	1,961,473	
Non-trainable params:	0	

Embedding katmanınınındaki eğitilebilir parametrelerin sayısının $30000 * 64 = 1920000$ olduğunu görmüştük. Yukarıda LSTM katmanındaki eğitilebilir parametrelerin sayısının $4 * (n * m + m * m + m) = 33024$ olduğunu gördük. Değerleri yerine koyarsak $4 * (64 * 64 + 64 * 64 + 64) = 33024$ olur. Şimdi modeli derleyip eğitelim. Modelimizi yine loss değeri üst üste 5 kez iyileştirilmeden sonlandıracagız:

```
model.compile(optimizer='rmsprop', loss='binary_crossentropy', metrics=['binary_accuracy'])

from tensorflow.keras.callbacks import EarlyStopping

esc = EarlyStopping(monitor='val_loss', patience=5, restore_best_weights=True, verbose=1)
hist = model.fit(training_dataset_x, training_dataset_y, batch_size=32, epochs=20,
validation_split=0.2, callbacks=[esc])
```

Şimdi epoch grafiğini çizdirelim:

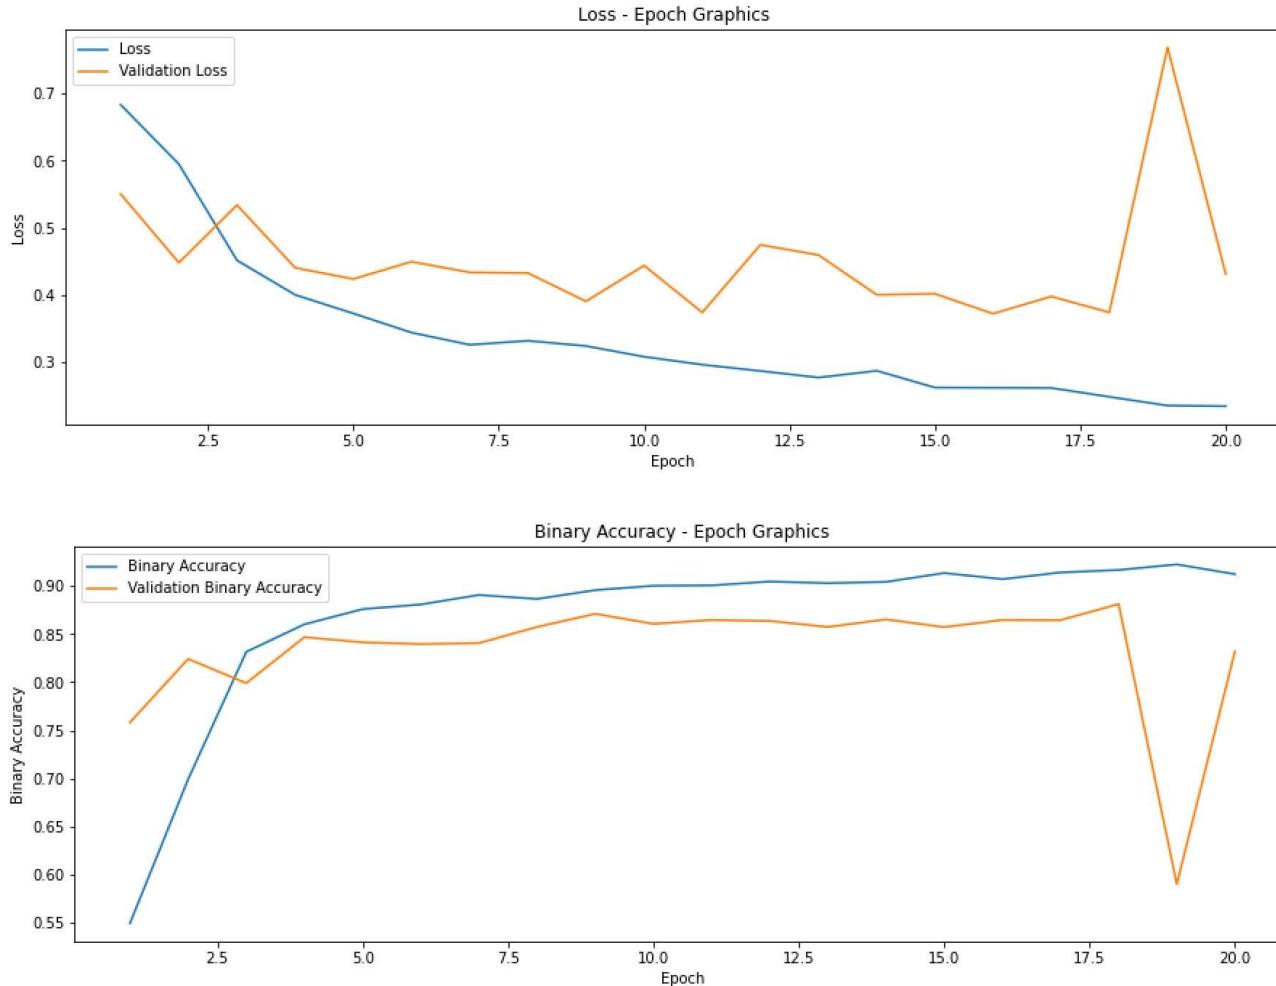
```
import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Loss - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.plot(range(1, len(hist.history['loss']) + 1), hist.history['loss'])
plt.plot(range(1, len(hist.history['val_loss']) + 1), hist.history['val_loss'])
plt.legend(['Loss', 'Validation Loss'])
plt.show()

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Binary Accuracy - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Binary Accuracy')
plt.plot(range(1, len(hist.history['binary_accuracy']) + 1), hist.history['binary_accuracy'])
plt.plot(range(1, len(hist.history['val_binary_accuracy']) + 1),
hist.history['val_binary_accuracy'])
plt.legend(['Binary Accuracy', 'Validation Binary Accuracy'])
plt.show()
```

```
eval_result = model.evaluate(test_dataset_x, test_dataset_y)
```

Buradan şu grafikler elde edilmiştir:



Şimdi test işlemimizi yapalım:

```
for i in range(len(eval_result)):  
    print(f'{model.metrics_names[i]} --> {eval_result[i]}')
```

Test işleminden şu değerler elde edilmiştir:

```
loss --> 0.4831244647502899  
binary_accuracy --> 0.809440016746521
```

Yukarıdaki kodu bir bütün olarak yeniden vermek itiyoruz:

```
VOCAB_SIZE = 30000  
TEXT_SIZE = 300  
  
from tensorflow.keras.datasets import imdb  
  
(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) =  
imdb.load_data(num_words=VOCAB_SIZE)  
  
word_dict = imdb.get_word_index()  
  
from tensorflow.keras.preprocessing.sequence import pad_sequences  
  
training_dataset_x = pad_sequences(training_dataset_x, TEXT_SIZE, padding='post')
```

```

test_dataset_x = pad_sequences(test_dataset_x, TEXT_SIZE, padding='post')

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Embedding, LSTM, Dropout, Dense

model = Sequential(name='IMDB-LSTM')
model.add(Embedding(VOCAB_SIZE, 64, input_length=TEXT_SIZE, name='Embedding'))
model.add(LSTM(64, activation='tanh', name='LSTM'))
model.add(Dropout(0.5, name='Dropout-1'))
model.add(Dense(128, activation='relu', name='Dense'))
model.add(Dropout(0.5, name='Dropout-2'))
model.add(Dense(1, activation='sigmoid', name='Output'))
model.summary()

model.compile(optimizer='rmsprop', loss='binary_crossentropy', metrics=['binary_accuracy'])

from tensorflow.keras.callbacks import EarlyStopping

esc = EarlyStopping(monitor='val_loss', patience=5, restore_best_weights=True, verbose=1)
hist = model.fit(training_dataset_x, training_dataset_y, batch_size=32, epochs=20,
validation_split=0.2, callbacks=[esc])

import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Loss - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.plot(range(1, len(hist.history['loss']) + 1), hist.history['loss'])
plt.plot(range(1, len(hist.history['val_loss']) + 1), hist.history['val_loss'])
plt.legend(['Loss', 'Validation Loss'])
plt.show()

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Binary Accuracy - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Binary Accuracy')
plt.plot(range(1, len(hist.history['binary_accuracy']) + 1), hist.history['binary_accuracy'])
plt.plot(range(1, len(hist.history['val_binary_accuracy']) + 1),
hist.history['val_binary_accuracy'])
plt.legend(['Binary Accuracy', 'Validation Binary Accuracy'])
plt.show()

eval_result = model.evaluate(test_dataset_x, test_dataset_y)
for i in range(len(eval_result)):
    print(f'{model.metrics_names[i]} --> {eval_result[i]}')

```

Çift Yönlü LSTM Katmanı

LSTM katmanı biraz daha iyileştirilebilir mi? Normal olarak LSTM katmanı uzun dönem geçmişi de hatırlama konusunda katkı sağlamaktadır. Pekiyi bağlamsal olarak gelecek geçmiş ile ilişkili olabilir mi? Yani bizim gelecek verilerden elde ettiğimiz bilgiler geçmiş'i yorumlamada kullanılabılır mı? Bunun yanıtı bazı uygulamalar için "evet" olacaktır. Ancak deneyimler bunun her türlü geri beslemeli ağda mutlak anlamda bir fayda sağlamadığını da göstermiştir. Gelecek bilginin geçmişteki verilerin anlaşılması kolaylaştırması metinsel uygulamalarda kullanılabilir bir durumdur. Örneğin kişi yorumunda önce birisinin bir yere gittiğini söylüyor olabilir. Daha sonra bu yerin eczane olduğu anlaşılıyor olabilir. Bu durumda geçmişte o yerin eczane olduğu bilinse belki de metin daha iyi anlaşılacaktır. Bazı dillerin gramatik yapısı bu durumu daha belirgin hale getirmektedir.

Keras'ta çift yönlü LSTM katmanını oluşturabilmek için LSTM nesnesi Biderictional isimli sınıfı verilir. Yani katmanın tipik oluşturulma biçimini söylemek:

```

model.add(Bidirectional(LSTM(64, name='LSTM'), name='Bidirectional'))

Şimdi aynı modeli Bidirectional LSTM ile kurmaya çalışalım. Aslında kodda tek değiştireceğimiz yer LSTM katmanının çıktısını Bidirectional katmanına bağlamak olacaktır.

VOCAB_SIZE = 30000
TEXT_SIZE = 300

from tensorflow.keras.datasets import imdb

(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) =
imdb.load_data(num_words=VOCAB_SIZE)

word_dict = imdb.get_word_index()

from tensorflow.keras.preprocessing.sequence import pad_sequences

training_dataset_x = pad_sequences(training_dataset_x, TEXT_SIZE, padding='post')
test_dataset_x = pad_sequences(test_dataset_x, TEXT_SIZE, padding='post')

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Embedding, LSTM, Bidirectional, Dropout, Dense

model = Sequential(name='IMDB-LSTM')
model.add(Embedding(VOCAB_SIZE, 64, input_length=TEXT_SIZE, name='Embedding'))
model.add(Bidirectional(LSTM(64, activation='tanh', name='LSTM'), name='Bidirectional'))
model.add(Dropout(0.5, name='Dropout-1'))
model.add(Dense(128, activation='relu', name='Dense'))
model.add(Dropout(0.5, name='Dropout-2'))
model.add(Dense(1, activation='sigmoid', name='Output'))
model.summary()

model.compile(optimizer='rmsprop', loss='binary_crossentropy', metrics=['binary_accuracy'])

from tensorflow.keras.callbacks import EarlyStopping

esc = EarlyStopping(monitor='val_loss', patience=5, restore_best_weights=True, verbose=1)
hist = model.fit(training_dataset_x, training_dataset_y, batch_size=32, epochs=20,
validation_split=0.2, callbacks=[esc])

import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Loss - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.plot(range(1, len(hist.history['loss']) + 1), hist.history['loss'])
plt.plot(range(1, len(hist.history['val_loss']) + 1), hist.history['val_loss'])
plt.legend(['Loss', 'Validation Loss'])
plt.show()

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Binary Accuracy - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Binary Accuracy')
plt.plot(range(1, len(hist.history['binary_accuracy']) + 1), hist.history['binary_accuracy'])
plt.plot(range(1, len(hist.history['val_binary_accuracy']) + 1),
hist.history['val_binary_accuracy'])
plt.legend(['Binary Accuracy', 'Validation Binary Accuracy'])
plt.show()

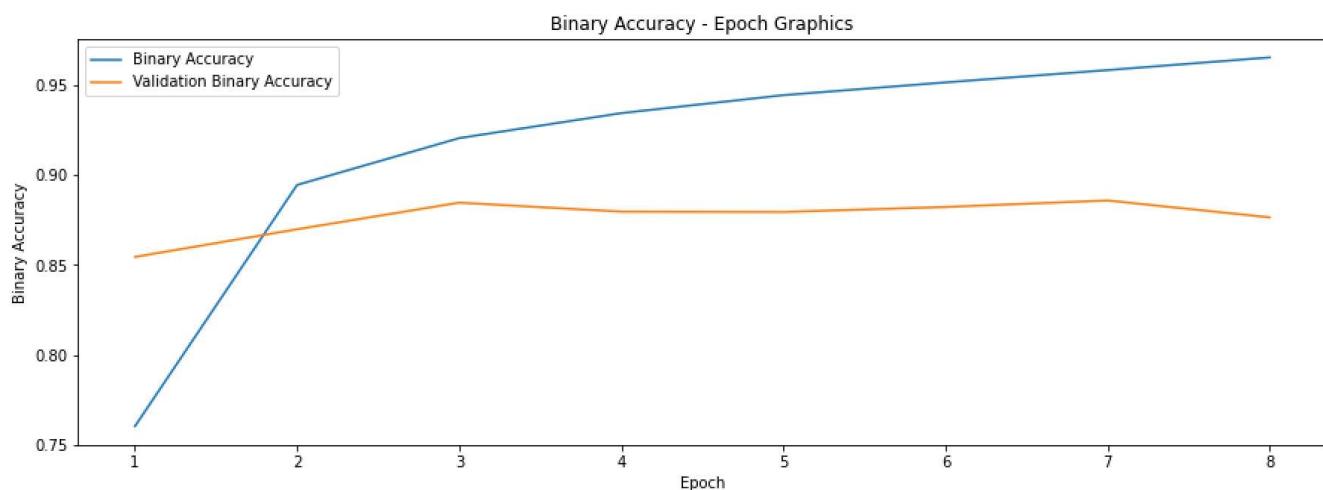
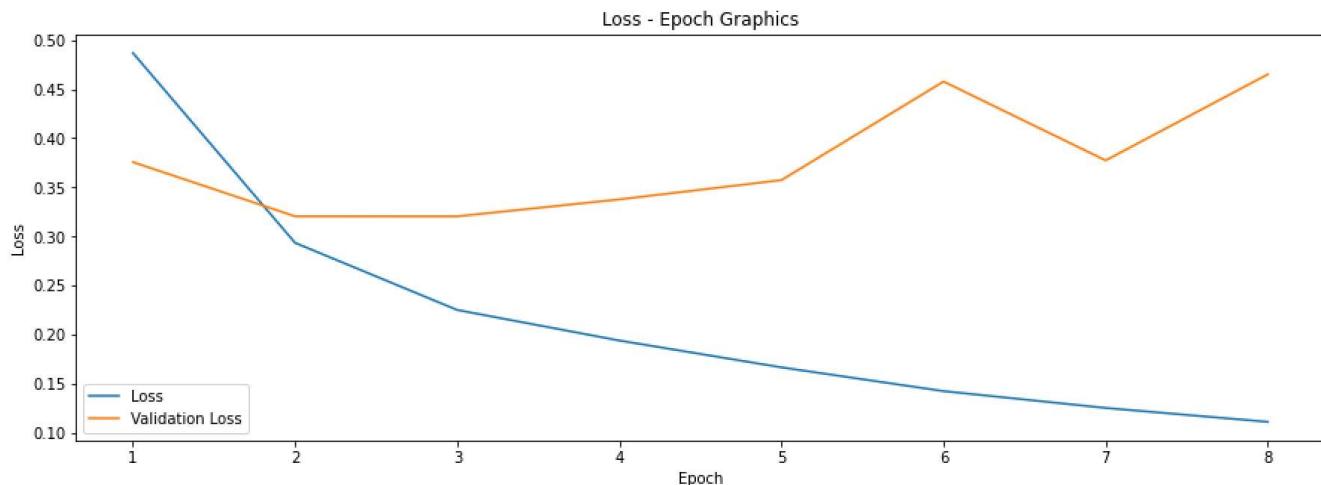
```

```

eval_result = model.evaluate(test_dataset_x, test_dataset_y)
for i in range(len(eval_result)):
    print(f'{model.metrics_names[i]} -> {eval_result[i]}')

```

Buradan elde edilen epoch grafikleri şöyledir:



Modelin testinden de şu sonuçlar elde edilmiştir:

```

loss --> 0.36292675137519836
binary_accuracy --> 0.8650000095367432

```

Göründüğü gibi burada değerler iyileşmiştir. Yani IMDBörneğinde çift yönlü geri beslemeli mimarının tek yönlü geri besleme mimarisine göre daha iyi sonuç verdiği görülmektedir.

Geri Beslemeli Ağlar İçin GRU Katmanı

GRU (Gated Recurrent Unit) yöntemi LSTM'ye bir alternatif oluşturmaktadır. GRU yöntemi de tipki LSTM yönteminde olduğu gibi ağa uzun dönem hafıza kazandırmaya çalışmaktadır. GRU yöntemi LSTM'ye göre daha az karmaşık olduğu için toplamdan LSTM'ye göre daha az eğitilebilir parametreye sahip olmaktadır. Dolayısıyla GRU yönteminde LSTM'ye göre hem eğitim süresi daha kısalıdır hem de bu yöntemde daha az bellek kullanılmaktadır. Ancak genel olarak (fakat her zaman değil) GRU katmanı LSTM'ye göre daha düşük performans göstermektedir. Bu nedenle pek çok uygulamada ilk tercih edilecek yöntem LSTM'dir. Eğer donanımsal bir kısıt söz konusuya (örneğin düşük güçlü CPU ve az miktarda bellek) LSTM yerine GRU katmanı tercih edilebilir. Katmanın genel kullanımı LSTM'de olduğu gibidir. Tabii GRU katmanı için genel performans LSTM'den kötü olabiliyorsa da SimpleRNN'den oldukça iyidir. Şimdi yukarıda LSTM katmanı ile yaptığımız IMDBörneğini bu kez GRU katmanı ile yapalım:

```

VOCAB_SIZE = 30000
TEXT_SIZE = 300

from tensorflow.keras.datasets import imdb

(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) =
imdb.load_data(num_words=VOCAB_SIZE)

word_dict = imdb.get_word_index()

from tensorflow.keras.preprocessing.sequence import pad_sequences

training_dataset_x = pad_sequences(training_dataset_x, TEXT_SIZE, padding='post')
test_dataset_x = pad_sequences(test_dataset_x, TEXT_SIZE, padding='post')

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Embedding, GRU, Dropout, Dense

model = Sequential(name='IMDB-LSTM')
model.add(Embedding(VOCAB_SIZE, 64, input_length=TEXT_SIZE, name='Embedding'))
model.add(GRU(64, activation='tanh', name='GRU'))
model.add(Dropout(0.5, name='Dropout-1'))
model.add(Dense(64, activation='relu', name='Dense'))
model.add(Dropout(0.5, name='Dropout-2'))
model.add(Dense(1, activation='sigmoid', name='Output'))

model.summary()

model.compile(optimizer='rmsprop', loss='binary_crossentropy', metrics=['binary_accuracy'])

from tensorflow.keras.callbacks import EarlyStopping

esc = EarlyStopping(monitor='val_loss', patience=5, restore_best_weights=True, verbose=1)
hist = model.fit(training_dataset_x, training_dataset_y, batch_size=32, epochs=20,
validation_split=0.2, callbacks=[esc])

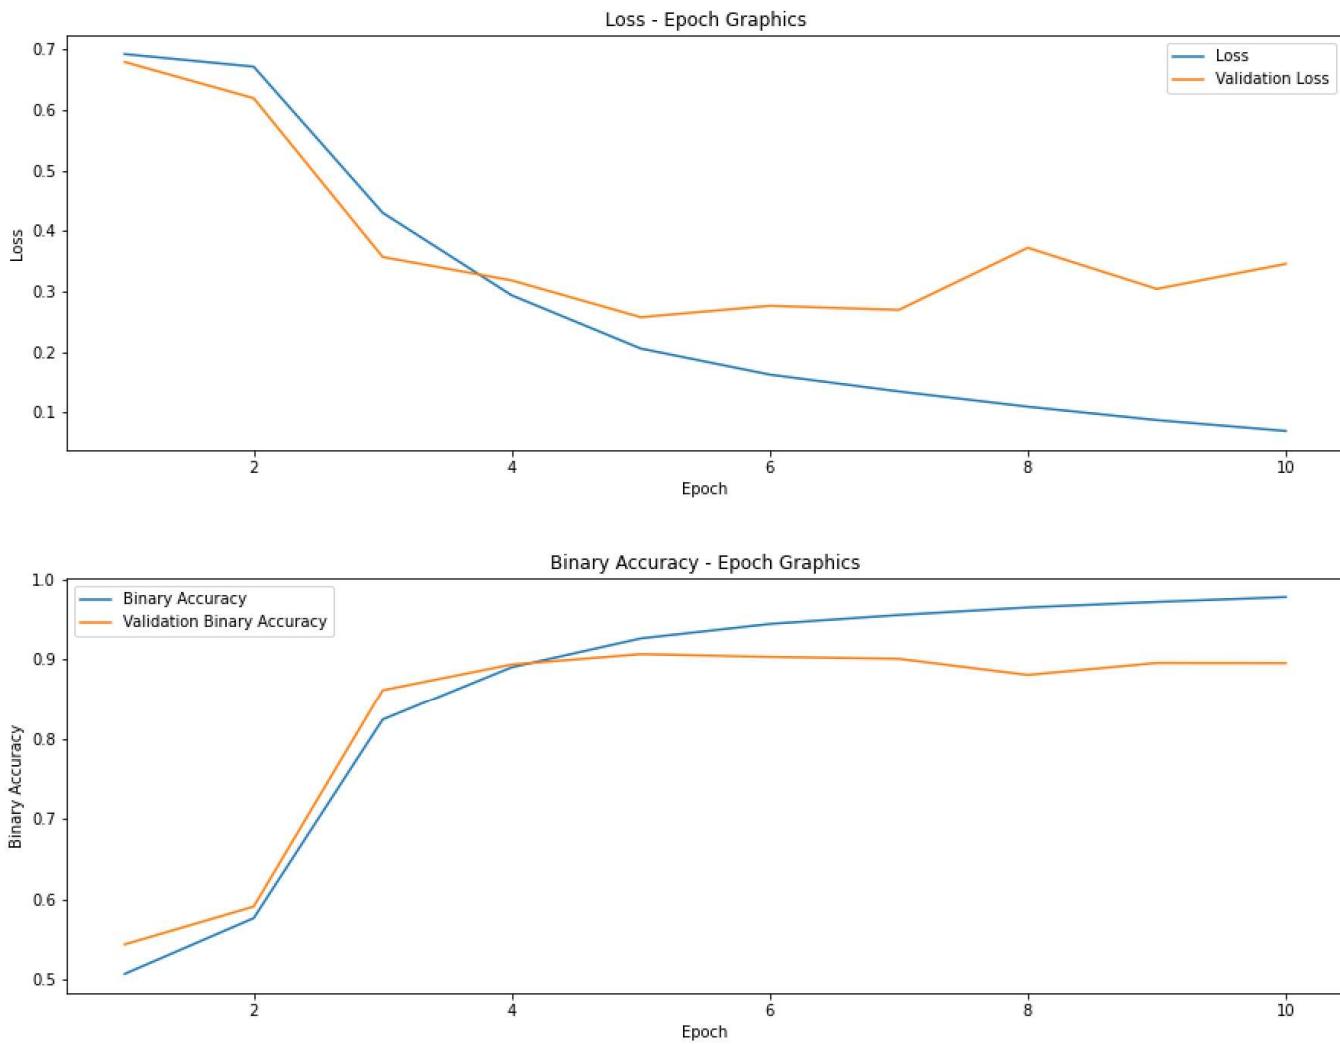
import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Loss - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.plot(range(1, len(hist.history['loss']) + 1), hist.history['loss'])
plt.plot(range(1, len(hist.history['val_loss']) + 1), hist.history['val_loss'])
plt.legend(['Loss', 'Validation Loss'])
plt.show()

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Binary Accuracy - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Binary Accuracy')
plt.plot(range(1, len(hist.history['binary_accuracy']) + 1), hist.history['binary_accuracy'])
plt.plot(range(1, len(hist.history['val_binary_accuracy']) + 1),
hist.history['val_binary_accuracy'])
plt.legend(['Binary Accuracy', 'Validation Binary Accuracy'])
plt.show()

```

Epoch grafikleri şöyledir:



Şimdi modeli test edelim:

```
eval_result = model.evaluate(test_dataset_x, test_dataset_y)
for i in range(len(eval_result)):
    print(f'{model.metrics_names[i]} --> {eval_result[i]}')
```

Şu sonuçlar elde edilmiştir:

```
loss --> 0.275068998336792
binary_accuracy --> 0.8964400291442871
```

Göründüğü gibi IMDB modeli için GRU katmanı LSTM ve İki yönlü LSTM'ye göre daha iyi bir performans göstermiştir. Ancak buradaki durumu genellemek yanlıştır.

Keras'taki Bidirectional katmanının bir dekoratör biçiminde oluşturulduğuna dikkat ediniz. Böylece biz herhangi bir geri beslemeli katmanı çift yönlü hale getirebiliriz. Örneğin GRU katmanı da aşağıdaki gibi çift yönlü hale getirilebilir:

```
training_dataset_x = pad_sequences(training_dataset_x, TEXT_SIZE, padding='post')
test_dataset_x = pad_sequences(test_dataset_x, TEXT_SIZE, padding='post')

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Embedding, Bidirectional, GRU, Dropout, Dense

model = Sequential(name='IMDB-Bidirectional-GRU')
model.add(Embedding(VOCAB_SIZE, 64, input_length=TEXT_SIZE, name='Embedding'))
model.add(Bidirectional(GRU(64, activation='tanh', name='GRU'), name='Bidirectional'))
model.add(Dropout(0.5, name='Dropout-1'))
```

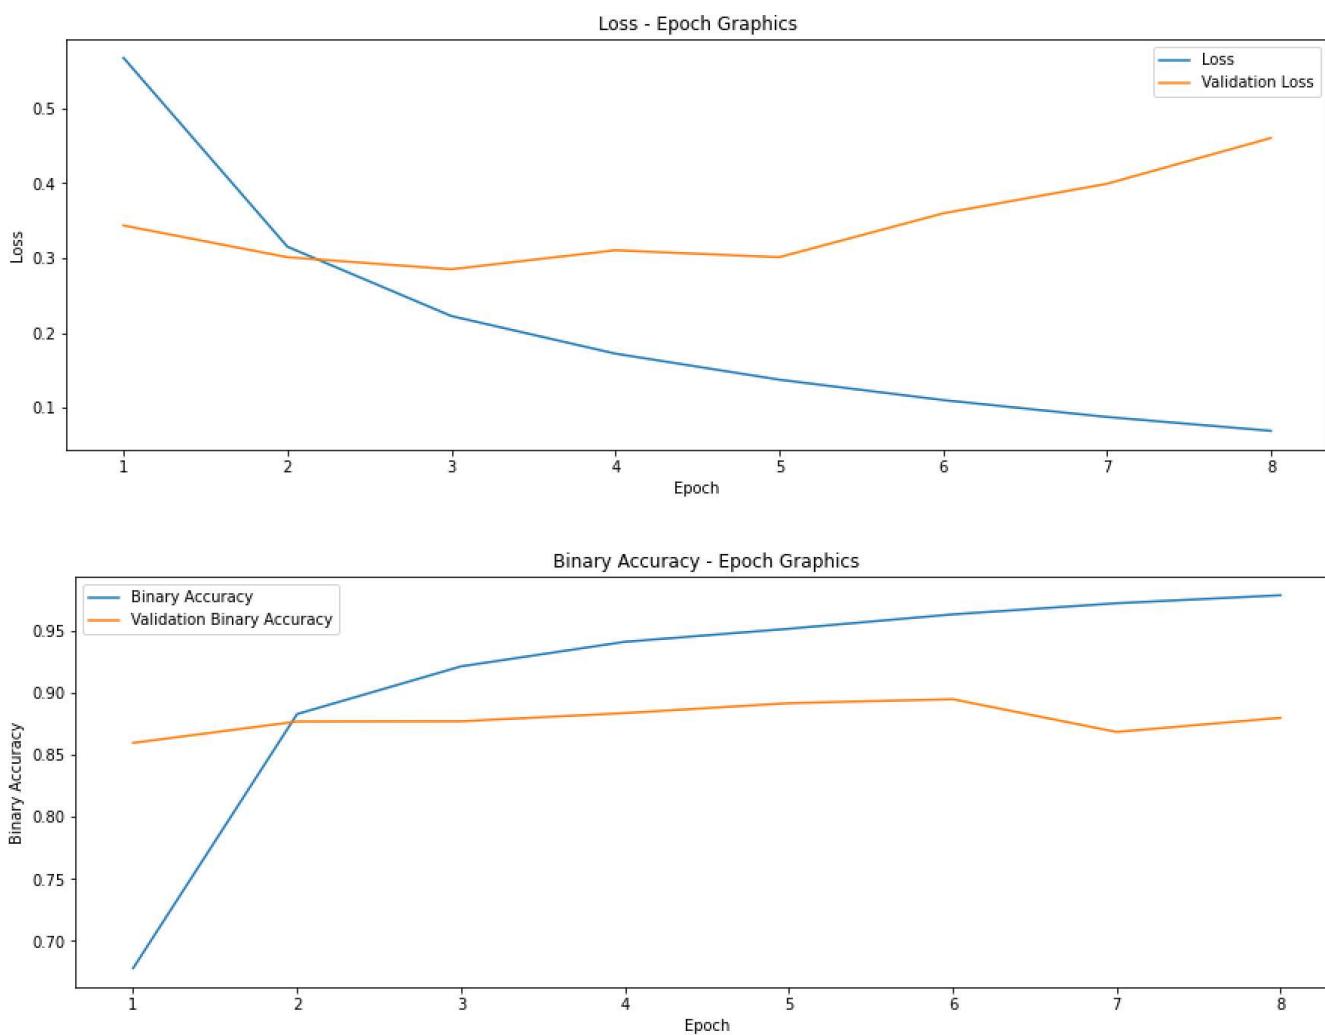
```

model.add(Dense(64, activation='relu', name='Dense'))
model.add(Dropout(0.5, name='Dropout-2'))
model.add(Dense(1, activation='sigmoid', name='Output'))

model.summary()

```

Modeli bu biçimde oluşturduğumuzda elde ettiğimiz epoch grafiği şöyledir:



Test sonuçları da şöyle elde edilmiştir:

```

loss --> 0.31287142634391785
binary_accuracy --> 0.8642799854278564

```

Geri Beslemeli Ağların Gelecek Kestiriminde Kullanılması ve Jena Climate Örneği

Biz yukarıdaki IMDB örneğinde geri beslemeli ağları yazışal metinlerden anlam çıkarmayı hedefleyen IMDB verilerinde kullandık. Halbuki bu ağlar yazışal verilerin dışında tamamen sayısal verilerin söz konusu olduğu kestirimlerde de kullanılabilmektedir. Çünkü pek çok sayısal veri tipki yazıyı oluşturan sözcükler gibi bir bağlama sahip olabilmektedir. Örneğin hava tahmini, borsada belli bir kağıdın gelecekteki değerinin tahmini geçmiş verilere bakılarak geri beslemeli bir ağ ile yapılmak istenebilir. Bir hava tahmini uygulamasında bir sonraki günü hava önceki günde havalara göre yani bir bağlam içerisinde oluşmaktadır. Benzer biçimde borsada bir kağıdın ya da kripto paranın fiyatı bir bağlam içerisinde değişmektedir.

Biz burada hava tahmini üzerinde örnek bir uygulama yapacağız. Geçmiş hava durumu raporlarına bakarak bir gün sonraki hava sıcaklığını tahmin edeceğiz. Tabii şüphesiz bu tahmin daha önce yaptığımız gibi geri beslemeli olmayan ağlarla (feed forward networks) da yapılabilir. Ancak biz burada bu kestirimini LSTM katmanlı bir ağla yapacağız.

Hava durumuna ilişkin "Jena Climate" örnek verileri aşağıdaki adresten indirilebilir:

<https://www.kaggle.com/stytch16/jena-climate-2009-2016>

Buradan indirilen "jena_climate_2009_2016.csv" dosyasının görünümü şöyledir:

```
Date Time","p (mbar)","T (degC)","Tpot (K)","Tdew (degC)","rh (%)","VPmax (mbar)","VPact (mbar)","VPdef (mbar)","sh (g/kg)","H2OC (mmol/mol)","rho (g/m**3)","wv (m/s)","max. wv (m/s)","wd (deg)"  
01.01.2009 00:10:00,996.52,-8.02,265.40,-8.90,93.30,3.33,3.11,0.22,1.94,3.12,1307.75,1.03,1.75,152.30  
01.01.2009 00:20:00,996.57,-8.41,265.01,-9.28,93.40,3.23,3.02,0.21,1.89,3.03,1309.80,0.72,1.50,136.10  
01.01.2009 00:30:00,996.53,-8.51,264.91,-9.31,93.90,3.21,3.01,0.20,1.88,3.02,1310.24,0.19,0.63,171.60  
01.01.2009 00:40:00,996.51,-8.31,265.12,-9.07,94.20,3.26,3.07,0.19,1.92,3.08,1309.19,0.34,0.50,198.00  
01.01.2009 00:50:00,996.51,-8.27,265.15,-9.04,94.10,3.27,3.08,0.19,1.92,3.09,1309.00,0.32,0.63,214.30  
01.01.2009 01:00:00,996.50,-8.05,265.38,-8.78,94.40,3.33,3.14,0.19,1.96,3.15,1307.86,0.21,0.63,192.70  
01.01.2009 01:10:00,996.50,-7.62,265.81,-8.30,94.80,3.44,3.26,0.18,2.04,3.27,1305.68,0.18,0.63,166.50  
01.01.2009 01:20:00,996.50,-7.62,265.81,-8.36,94.40,3.44,3.25,0.19,2.03,3.26,1305.69,0.19,0.50,118.60  
01.01.2009 01:30:00,996.50,-7.91,265.52,-8.73,93.80,3.36,3.15,0.21,1.97,3.16,1307.17,0.28,0.75,188.50  
...
```

Bu CSV dosyasının başında bir başlık kısmı vardır. Satırlar virgülerle ayrılmış değerler içermektedir. Hava durumuna ilişkin değerler 2009'dan 2016'ya kadar 10 dakika aralıklarla elde edilmiştir. İlk sütunda elde edilen bilginin tarih ve zaman bilgisi, üçüncü sütunda (2'inci indeksli sütunda) ise havanın derece cinsinden sıcaklığı bulunmaktadır.

İlk aşamada bizim bu CSV dosyasını alarak bir ndarray nesnesine dönüştürmemiz gereklidir. Tabii bu dönüştürme sırasında ilk sütunun da atılması uygun olur. Çünkü eğitimde bu sütunu kullanmayacağız. Önce CSV dosyasını okuyalım:

```
import numpy as np  
  
PREDICT_INTERVAL = 144  
  
dataset_x = np.loadtxt('jena_climate_2009_2016.csv', delimiter=',', skiprows=1,  
usecols=range(1, 15), dtype=np.float32)
```

Burada biz ilk sütunu atarak diğer tüm sütunları elde ettik. Bunlar bizim x verilerimizi oluşturacaktır. Şimdi dataset_y verilerini oluşturalım:

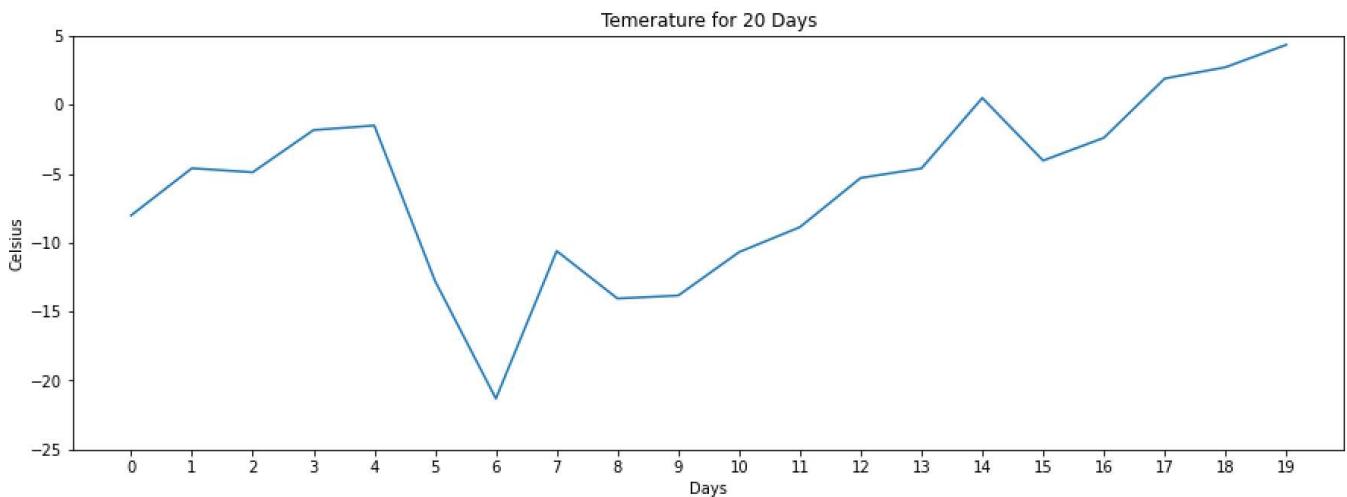
```
dataset_y = dataset_x[:, 1]
```

dataset_x matrisindeki her bir satırın öncekinden 10 dakika sonraki hava durumu bilgisini içerdigini söylemiştim. O halde örneğin index değeri dataset_x matrisindeki bir satırın sıra numarasını göstermek üzere, bu satırın belirttiği zamandan 1 gün sonraki hava sıcaklığı dataset_y[index + 144] ifadesiyle elde edilecektir. $24 * 6 // 10 = 144$ olduğuna dikkat ediniz.

Şimdi 20 günlük hava sıcaklığının grafiğini şöyle çizebiliriz:

```
import matplotlib.pyplot as plt  
  
figure = plt.gcf()  
figure.set_size_inches((15, 5))  
plt.title('Temerature for 20 Days')  
plt.xlabel('Days')  
plt.ylabel('Celsius')  
plt.ylim((-25, 5))  
plt.xticks(range(20))  
  
plt.plot(range(20), dataset_y[0:PREDICT_INTERVAL * 20:PREDICT_INTERVAL])  
plt.show()
```

Şöyledir bir grafik elde edilmişdir:



Şimdi de elimizdeki veri kümesini eğitim ve test olmak üzere iki kısma ayıralım:

```
from sklearn.model_selection import train_test_split

training_dataset_x, test_dataset_x, training_dataset_y, test_dataset_y =
train_test_split(dataset_x[:-PREDICT_INTERVAL], dataset_y[PREDICT_INTERVAL:], test_size=0.2)
```

Şimdi verileri ölçeklendirelim. Doğa olayları genel olarak normal dağılıma uydugu için Min-Max ölçeklendirmesi yerine Standart ölçeklendirme uygulayacağız:

```
from sklearn.preprocessing import StandardScaler

ss = StandardScaler()
ss.fit(training_dataset_x)
training_dataset_x = ss.transform(training_dataset_x)
test_dataset_x = ss.transform(test_dataset_x)
```

Önce modelimizi ileri beslemeli (feed forward) ağ ile deneyelim.

```
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dropout, Dense

model = Sequential(name='Jane-Climate')
model.add(Dense(128, input_dim=training_dataset_x.shape[1], activation='relu', name='Dense-1'))
model.add(Dropout(0.2, name='Dropout-1'))
model.add(Dense(128, activation='relu', name='Dense-2'))
model.add(Dropout(0.2, name='Dropout-2'))
model.add(Dense(1, activation='linear', name='Output'))

model.summary()

model.compile(optimizer='rmsprop', loss='mse', metrics=['mae'])

from tensorflow.keras.callbacks import EarlyStopping

esc = EarlyStopping(monitor='val_loss', patience=5, restore_best_weights=True, verbose=1)
hist = model.fit(training_dataset_x, training_dataset_y, batch_size=32, epochs=20,
validation_split=0.2, callbacks=[esc])

import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches((15, 5))
```

```

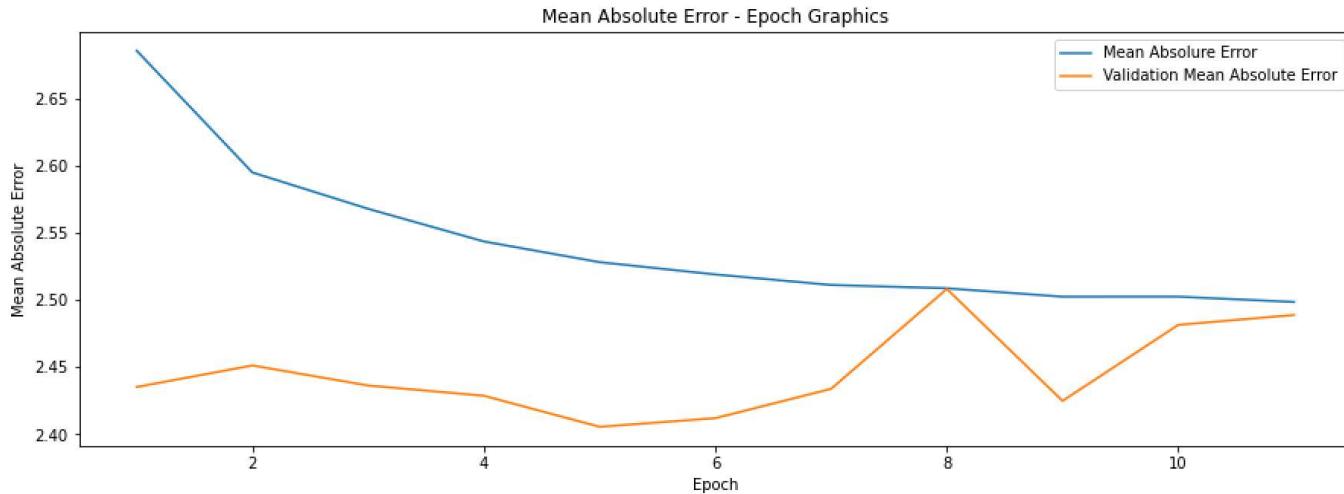
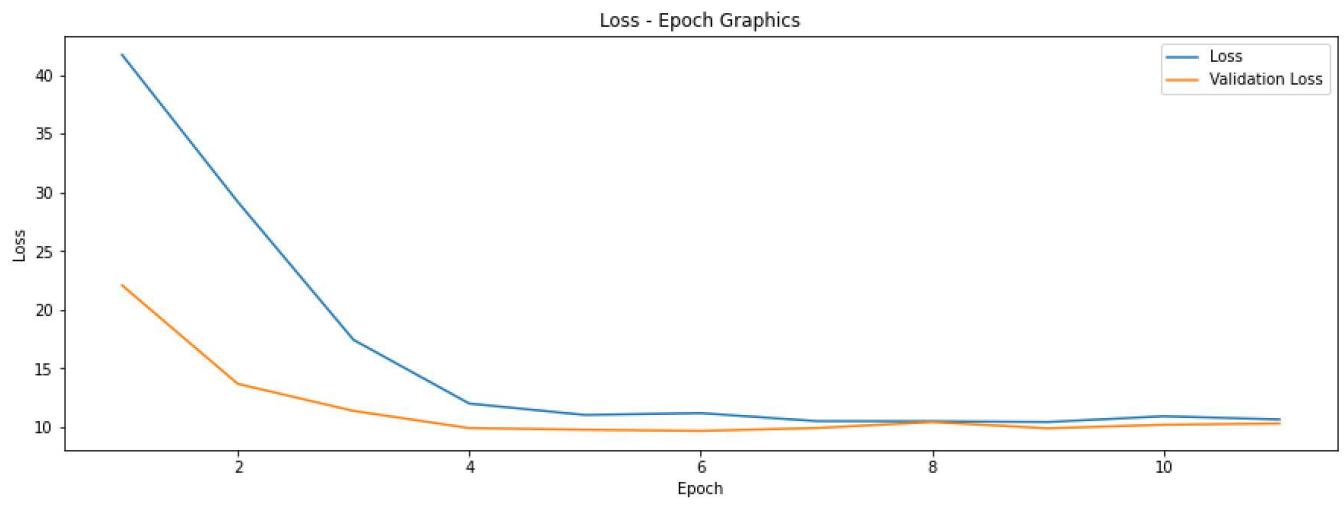
plt.title('Loss - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.plot(range(1, len(hist.history['loss']) + 1), hist.history['loss'])
plt.plot(range(1, len(hist.history['val_loss']) + 1), hist.history['val_loss'])
plt.legend(['Loss', 'Validation Loss'])
plt.show()

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Mean Absolute Error - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Mean Absolute Error')
plt.plot(range(1, len(hist.history['mae']) + 1), hist.history['mae'])
plt.plot(range(1, len(hist.history['val_mae']) + 1), hist.history['val_mae'])
plt.legend(['Mean Absolute Error', 'Validation Mean Absolute Error'])
plt.show()

eval_result = model.evaluate(test_dataset_x, test_dataset_y)
for i in range(len(eval_result)):
    print(f'{model.metrics_names[i]} --> {eval_result[i]}')

```

Elde edilen epoch grafiği şöyledir:



Test soncunda elde edilen değerler de şöyledir:

```

loss --> 9.610762596130371
mae --> 2.414771556854248

```

Yukarıdaki kodu bir bütün olarak aşağıda veriyoruz:

```
import numpy as np

PREDICT_INTERVAL = 144

dataset_x = np.loadtxt('jena_climate_2009_2016.csv', delimiter=',', skiprows=1,
usecols=range(1, 15), dtype=np.float32)

dataset_y = dataset_x[:, 1]

import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Temerature for 20 Days')
plt.xlabel('Days')
plt.ylabel('Celsius')
plt.ylim((-25, 5))
plt.xticks(range(20))
plt.plot(range(20), dataset_y[0:PREDICT_INTERVAL * 20:PREDICT_INTERVAL])
plt.show()

from sklearn.model_selection import train_test_split

training_dataset_x, test_dataset_x, training_dataset_y, test_dataset_y =
train_test_split(dataset_x[:-PREDICT_INTERVAL],

dataset_y[PREDICT_INTERVAL:],

test_size=0.2)

from sklearn.preprocessing import StandardScaler

ss = StandardScaler()
ss.fit(training_dataset_x)
training_dataset_x = ss.transform(training_dataset_x)
test_dataset_x = ss.transform(test_dataset_x)

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dropout, Dense

model = Sequential(name='Jane-Climate')
model.add(Dense(128, input_dim=training_dataset_x.shape[1], activation='relu', name='Dense-1'))
model.add(Dropout(0.2, name='Dropout-1'))
model.add(Dense(128, activation='relu', name='Dense-2'))
model.add(Dropout(0.2, name='Dropout-2'))
model.add(Dense(1, activation='linear', name='Output'))

model.summary()

model.compile(optimizer='rmsprop', loss='mse', metrics=['mae'])

from tensorflow.keras.callbacks import EarlyStopping

esc = EarlyStopping(monitor='val_loss', patience=5, restore_best_weights=True, verbose=1)
hist = model.fit(training_dataset_x, training_dataset_y, batch_size=32, epochs=20,
validation_split=0.2,
callbacks=[esc])

import matplotlib.pyplot as plt

figure = plt.gcf()
```

```

figure.set_size_inches((15, 5))
plt.title('Loss - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.plot(range(1, len(hist.history['loss']) + 1), hist.history['loss'])
plt.plot(range(1, len(hist.history['val_loss']) + 1), hist.history['val_loss'])
plt.legend(['Loss', 'Validation Loss'])
plt.show()

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Mean Absolute Error - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Mean Absolute Error')
plt.plot(range(1, len(hist.history['mae']) + 1), hist.history['mae'])
plt.plot(range(1, len(hist.history['val_mae']) + 1), hist.history['val_mae'])
plt.legend(['Mean Absolute Error', 'Validation Mean Absolute Error'])
plt.show()

eval_result = model.evaluate(test_dataset_x, test_dataset_y)
for i in range(len(eval_result)):
    print(f'{model.metrics_names[i]} -> {eval_result[i]}')

```

Şimdi bu kestirim için LSTM katmanına sahip geri beslemeli bir model kullanalım. Burada ağımızın belli sayıda 10'ar dakikalık bilgileri vererek belli bir zaman sonraki hava sıcaklığını tahmin etmeye çalışacağız. Önce bazı parametrik değerleri belirleyip CSV dosyasını okuyalım:

```

import numpy as np

PREDICT_INTERVAL = 144
LOOKBACK_INTERVAL = 144
BATCH_SIZE = 32

dataset_x = np.loadtxt('jena_climate_2009_2016.csv', delimiter=',', skiprows=1,
usecols=range(1, 15), dtype=np.float32)

dataset_y = dataset_x[:, 1]

```

Burada PREDICT_INTERVAL bizim kaç 10 dakika sonraki hava sıcaklığını tahmin etmek istediğimizi belirtiyor. Bu örnekte yine biz bir gün sonraki hava sıcaklığını tahmin edeceğiz. Biz burada zamansal olarak ağımızın bir bellek kazandırmak istiyoruz. LOOKBACK_INTERVAL ağımızın ne kadar geçmiş anımsayacağıdır. Yani biz burada belirtilen değer kadar 10 dakikalık verileri zamansal olarak ağımızın vereceğiz.

Bu uygulamada dikkat edilmesi gereken nokta bizim belli sayıda 10 dakikalık verileri ağa verip belli bir zaman sonraki değeri tahmin etmeye çalıştığımızdır. Bunun için training_dase_x ve training_dataset_y dizilerini oluşturmak çok zor ve verimsiz bir yöntemdir. Bu nedenle biz burada parçalı verilerle eğitim işlemi uygulayacağız. Yani her batch işleminde bizim metodumuz çağrılmak ve biz de bir batch uzunluğu kadar bilgiyi oluşturup vereceğiz. Böylelikle büyük bir bellek kullanmak zorunda kalmayacağz. Şimdi veri kümemizi önce eğitim ve test biçiminde iki parçaya ayıralım. Sonra da eğitim veri kümelerinden sınıma veri kümelerini oluşturalım:

```

from sklearn.model_selection import train_test_split

training_dataset_x, test_dataset_x, training_dataset_y, test_dataset_y =
train_test_split(dataset_x, dataset_y,
shuffle=False, test_size=0.1)

from sklearn.preprocessing import StandardScaler

ss = StandardScaler()
ss.fit(training_dataset_x)

```

```

training_dataset_x = ss.transform(training_dataset_x)
test_dataset_x = ss.transform(test_dataset_x)

training_dataset_x, validation_dataset_x, training_dataset_y, validation_dataset_y =
train_test_split(training_dataset_x, training_dataset_y, shuffle=False, test_size=0.2)

```

Şimdi parçalı verilerle eğitim için generator sınıfımızı yazalım:

```

from tensorflow.keras.utils import Sequence

class DataGenerator(Sequence):
    def __init__(self, dataset_x, dataset_y, batch_size):
        self.dataset_x = dataset_x
        self.dataset_y = dataset_y
        self.batch_size = batch_size
        self.indices = np.arange((len(self.dataset_x) - PREDICT_INTERVAL) // self.batch_size,
                               dtype=np.int32)

    def __len__(self):
        return (len(self.dataset_x) - PREDICT_INTERVAL) // self.batch_size

    def __getitem__(self, index):
        result_x = np.zeros((BATCH_SIZE, LOOKBACK_INTERVAL, training_dataset_x.shape[1]))
        result_y = np.zeros(BATCH_SIZE)

        for i in range(self.batch_size):
            start = self.indices[index] * self.batch_size + i
            result_x[i] = self.dataset_x[start:start + LOOKBACK_INTERVAL]
            result_y[i] = self.dataset_y[start + PREDICT_INTERVAL]

        return result_x, result_y

    def on_epoch_end(self):
        np.random.shuffle(self.indices)

```

Burada DataGenerator sınıfının `__init__` metodu bizden sırasıyla `dataset_x`, `dataset_y` ve `batch_size` değerlerini alıp bunları nesnenin örnek özniteliklerinde saklamaktadır. Anımsanacağı gibi sınıfın `__len__` metodu bir epoch işleminde kaç adet batch kullanacağını belirtmektedir. Yine her batch için batch numarasının `__getitem__` metoduna geçirildiğini anımsayınız. Biz de bu `__getitem__` metodu içerisinde bir batch uzunluğu kadar satır ve sütundan oluşan matris yaratıp bu matrisin içini doldurduk. Her bir batch elemanına karşı gelen değerin `PREDICT_INTERVAL` kadar sonraki değer olduğuna dikkat ediniz. Yine her epoch sonucunda eğitim veri kümesi karıştırılmaktadır.

Artık sıra modelimizi kurmaya gelmiştir. Modelin girdi katmanını LSTM olarak alacağız. LSTM katmanın girdisi `LOOKBACK_INTERVAL` kadar 10'ar dakikalık hava durumu verilerinden oluşacaktır ve bu 10'ar dakikalık veriler modele zamansal (temporal) olarak uygulanacaktır:

```

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dropout, LSTM, Dense

model = Sequential(name='Jane-Climate-LSTM')
model.add(LSTM(64, activation='tanh', name='LSTM', input_shape=(None,
                                                               training_dataset_x.shape[1])))
model.add(Dense(64, activation='relu', name='Dense-1'))
model.add(Dropout(0.2, name='Dropout-1'))
model.add(Dense(64, activation='relu', name='Dense-2'))
model.add(Dropout(0.2, name='Dropout-2'))
model.add(Dense(1, activation='linear', name='Output'))

model.summary()

```

Artık modeli derleyip eğitebiliriz:

```

model.compile(optimizer='rmsprop', loss='mse', metrics=['mae'])

from tensorflow.keras.callbacks import EarlyStopping

esc = EarlyStopping(monitor='val_loss', patience=5, restore_best_weights=True, verbose=1)
hist = model.fit(DataGenerator(training_dataset_x, training_dataset_y, BATCH_SIZE),
validation_data=DataGenerator(validation_dataset_x, validation_dataset_y, BATCH_SIZE),
epochs=10, callbacks=[esc])

```

Epoch grafiklerini çizdirelim:

```

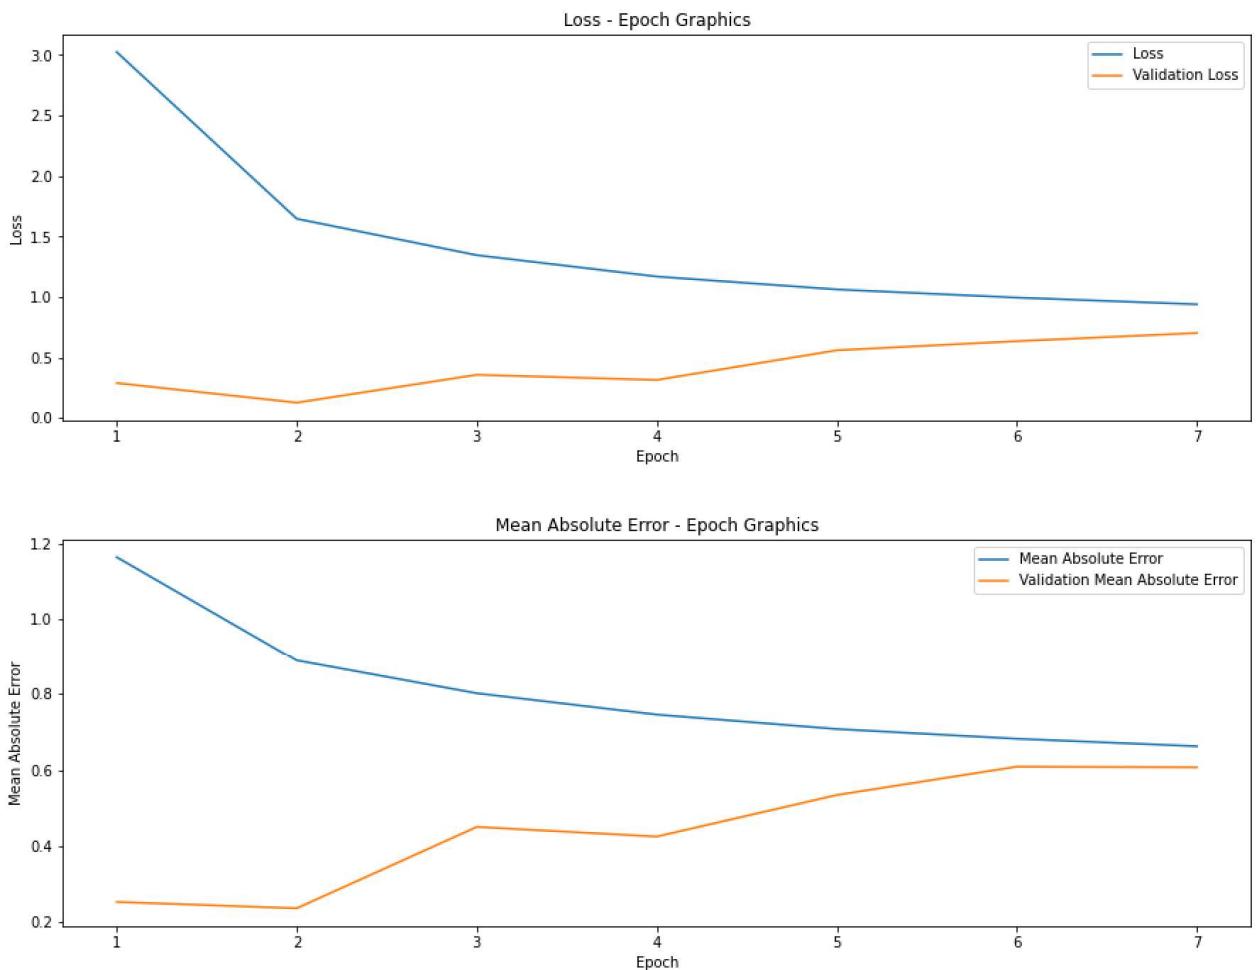
import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Loss - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.plot(range(1, len(hist.history['loss']) + 1), hist.history['loss'])
plt.plot(range(1, len(hist.history['val_loss']) + 1), hist.history['val_loss'])
plt.legend(['Loss', 'Validation Loss'])
plt.show()

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Mean Absolute Error - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Mean Absolute Error')
plt.plot(range(1, len(hist.history['mae']) + 1), hist.history['mae'])
plt.plot(range(1, len(hist.history['val_mae']) + 1), hist.history['val_mae'])
plt.legend(['Mean Absolute Error', 'Validation Mean Absolute Error'])
plt.show()

```

Şu grafikler elde edilmiştir:



Şimdi de modelimizi test edelim:

```
eval_result = model.evaluate(DataGenerator(test_dataset_x, test_dataset_y, BATCH_SIZE))
for i in range(len(eval_result)):
    print(f'{model.metrics_names[i]} --> {eval_result[i]}')
```

Şu değerler elde edilmiştir:

```
loss --> 0.1031017005443573
mae --> 0.22029602527618408
```

Bu değerlerin ileri beslemeli ağdan elde ettiğimiz değerlerden oldukça iyi olduğuna dikkat ediniz.

Pekiyi burada oluşturduğumuz modelde kestirim işlemini nasıl yapacağız? Daha önceki çeşitli defalar belirttiğimiz gibi kestirim işlemi eğitim nasıl yapılmışsa o koşullarda yapılmalıdır. Biz burada eğitimde 144 tane 10'ar dakikalık verileri standart ölçeklendirmeye sokarak kullandık. O halde kesitimi de tamamen aynı biçimde yapmamız gerekmektedir. Yani bu örneğimizde kestirim yapabilmemiz için elimizde 144 tane 10 dakikalık verilerin olması gerekmektedir.

Geri Beslemeli Ağlarla Çıktı Üretimi

Biz şimdide kadarki örneklerimizde gelecek kestirimini yapmaya çalıştık. Ancak bazen bu gelecek kestirimini çıktı üretimleri için de kullanılabilmektedir. Özellikle metinlerin üretiminde 2015 yılından itibaren LSTM tabanlı geri beslemeli ağlar kullanılmıştır. Bu konuda önemli başarılar elde edilmiştir.

Geri beslemeli ağlarla metin oluşturma işlemi tipik olarak şöyle yapılmaktadır:

- 1) Üretilen metni belli bir kişinin tarzına uydurmak için o kişinin yazıları elde edilir.

2) Sonra bir geri beslemeli sinir ağı oluşturularak sinir ağı bu yazılarla eğitilir. Burada karakter temelli bir çıktı üretiminin söz konusu olduğunu düşünelim. Bunun için seçilen kişiye ilişkin yazıların belli miktardaki karakterden oluşan kısımları - örneğin 32 karakter olduğunu varsayıyalım- ve bu kısımdan sonra gelen karakterler eğitim amacıyla toplanır. Böylece bu işlemden 32 karakterden oluşan bir yazı parçaları ile (dataset_x), 1 karakterden oluşan sonuç değerleri (dataset_y) elde edilecektir. İ

3) Geri beslemeli bir yapay sinir ağı modeli kurularak ağ oluşturulan veri kümesiyle eğitilir. Geri besleme için genellikle LSTM modeli tercih edilmektedir.

4) Artık elimizde 32 karakterini girdi olarak verdigimiz bir metnin 33'üncü karakterini tahmin edebilen bir geri beslemeli yapay sinir ağı modeli vardır. Bu durumda biz 32 karakterlik bir yazıyı başlangıç yazısı olarak verirsek ağdan bunun 33'üncü karakterini elde edebiliriz. Bundan sonra yine bu 33 karakterli yazının son 32 karakterini alarak yeni bir karakter elde ederiz. Bu işlemi böyle sürdürürsek istediğimiz uzunlukta bir yazı elde etmiş oluruz.

5) Modelin bu biçimde oluşturulması yazının tek düzeye ve yaratıcılık içermeyen bir yapıda olmasına yol açabilmektedir. Bu nedenle her defasında ağdan elde edilen karakteri doğrudan kullanmak yerine işin içine bir miktar rassallık da katılarak belli bir olasılık dağılımı çerçevesinde yeni karakterin elde edilmesi daha yaratıcı bir metnin oluşmasına yol açmaktadır.

Tabii çıktı üretimi aslında yalnızca metinsel girdiler üzerinde değil yaratıcılık etkinliği olarak değerlendirilen diğer girdiler üzerinde de uygulanabilmektedir. Örneğin belli bir bestecinin tarzına göre beste yapan bir sinir ağı modeli oluşturulabilir.

Şimdi Nietzsche'nin metinlerinden oluşan bir yazıyı kullanarak Nietzsche tarzında metin üreten bir uygulama üzerinde duralım.

Akıntı Notu: Bu uygulama "Deep Learning With Python (François Chollet)" isimli kitabın 274. Sayfasında da bulunmaktadır.

Uygulamaya konu olan Nietzsche metinleri aşağıdaki adresden indirilebilir:

<https://s3.amazonaws.com/text-datasets/nietzsche.txt>

Aslında indirme işlemini tensorflow.keras.utils modülündeki get_file fonksiyonuyla da yapabiliriz:

```
import tensorflow.keras

path = tensorflow.keras.utils.get_file('nietzsche.txt', origin='https://s3.amazonaws.com/text-datasets/nietzsche.txt')

with open(path) as f:
    text = f.read().lower()

print(text)
```

Burada artık tüm metin bir string olarak text değişkeninde bulunmaktadır.

Şimdi metin okunduktan sonra yazıda 3'er atlamlı olarak 60'ar karakterden oluşan parçaları sentences isimli bir listeye yerlestirelim. Yapay sinir ağı 60 karakterden sonraki 61'inci karakteri tahmin edeceğini söylemektedir dolayısıyla bu 60 karakterden sonraki karakteri de next_char isimli bir listede toplayacağız:

```
TEXT_LENGTH = 60
STEP = 3

sentences = []
next_chars = []

for i in range(0, len(text) - TEXT_LENGTH, STEP):
    sentences.append(text[i:i + TEXT_LENGTH])
    next_chars.append(text[i + TEXT_LENGTH])
```

```

next_chars.append(text[i + TEXT_LENGTH])

print(f'Number of sequences: {len(sentences)}')

```

Böylece biz eğitimde kullanacağımız 60'ar karakterden oluşan bir liste (`training_dataset_x`) ile bunlardan sonra gelen karakterlerden oluşan diğer bir liste (`training_dataset_y`) elde etmiş olduk. Bundan sonra yazı içerisinde farklı kaç tane karakter olduğunu tespit edip bu karakterleri de bir listeye yerleştirerek koda devam edelim:

```

chars = sorted(list(set(text)))
print('Number of unique chars: {}'.format(len(chars)))

```

Tabii bizim yazı parçalarındaki karakterlerin her birini "one hot encoding" biçiminde oluşturmamız gereklidir. Zira eğer biz karakter kodlarını doğrudan kullanırsak model sanki sıralı (ordinal) bir ölçek söz konusu olmuş gibi davranış olacaktır. One hot encoding işlemini kolaylaştırmak için bir sözlük oluşturabiliriz. Bu sözlük sayesinde yazı içerisindeki bir karakter verildiğinde onun indeksini hızlı bir biçimde elde edebileceğiz:

```
char_dict = {char: index for index, char in enumerate(chars)}
```

Bu özlük sayesinde biz karakteri verdiğimizde ona karşı gelen sayısal değeri alabileceğiz. Artık sıra `training_dataset_x` ve `training_dataset_y` nesnelerinin ndarray olarak oluşturulmasına geldi. Bunun için önce bu diziler içinde sıfır olacak biçimde aşağıdaki yaratalım:

```

import numpy as np

training_dataset_x = np.zeros((len(sentences), TEXT_LENGTH, len(chars)), dtype=np.uint8)
training_dataset_y = np.zeros((len(sentences), len(chars)), dtype=np.uint)

```

Burada `training_dataset_x` üç boyutlu bir NumPy dizisidir. Dizinin `TEXT_LENGTH` (60) uzunluktaki her yazının her karakterinin index numaralarını one hot encoding biçiminde tuttuğuna dikkat ediniz. `training_dataset_y` ise yazındaki `TEXT_LENGTH + 1`'inci karakterin one hot encoding karşılığını tutmaktadır. Mademki bu iki dizinin tüm elemanları `np.zeros` fonksiyonuyla sıfır yapılmıştır. O halde biz yalnızca uygun elemanı 1 yaparak one hot encoding vektörlerini kolay bir biçimde oluşturabiliriz:

```

for i, sentence in enumerate(sentences):
    for k, char in enumerate(sentence):
        training_dataset_x[i, k, char_dict[char]] = 1
        training_dataset_y[i, char_dict[next_chars[i]]] = 1

```

Artık `trainig_dataset_x` ve `training_dataset_y` one hot encoding biçiminde oluşturmuş durumdadır. Şimdi artık LSTM katmanı içeren geri beslemeli ağ modelimizi oluşturabiliriz:

```

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import LSTM, Dropout, Dense

model = Sequential(name='TextProduction')
model.add(LSTM(128, activation='tanh', input_shape=(TEXT_LENGTH, len(chars)), name='LSTM'))
model.add(Dropout(0.3, name='Dropout'))
model.add(Dense(len(chars), activation='softmax', name='Output'))
model.summary()

```

Cıktı katmanının toplamda `len(chars)` uzunlukta nöronlardan oluştuğuna dikkat ediniz. Cıktı katmanının aktivasyon fonksiyonu "softmax" olduğuna göre tüm çıktı nöronlarının toplam değeri 1 olacaktır. Tabii biz bunlar arasından en yüksek değeri tahmin olarak alacağız. Ağımızın optimizasyon algoritması "rmsprop" olarak loss fonksiyonu da daha önceki benzer sınıflandırma örneklerinde yapmış olduğumuz gibi "categorical_crossentropy" olarak alınmıştır. Şimdi artık ağımızı derleyip eğitebiliriz:

```

optimizer = RMSprop(lr=0.01)
model.compile(optimizer, loss='categorical_crossentropy', metrics=['categorical_accuracy'])

```

```

from tensorflow.keras.callbacks import EarlyStopping

esc = EarlyStopping(monitor='val_loss', patience=5, restore_best_weights=True, verbose=1)
hist = model.fit(training_dataset_x, training_dataset_y, batch_size=32, epochs=20,
validation_split=0.2, callbacks=[esc])

```

Burada "rmsprop" algoritması için learning_rate değerini biraz yükselttik. learning_rate parametresinin yükseltilmesi hedefe daha hızlı yakınsama sağlamaktadır. Bu konu ileride ele alınacaktır. Şimdi de epoch grafiklerini çizelim:

```

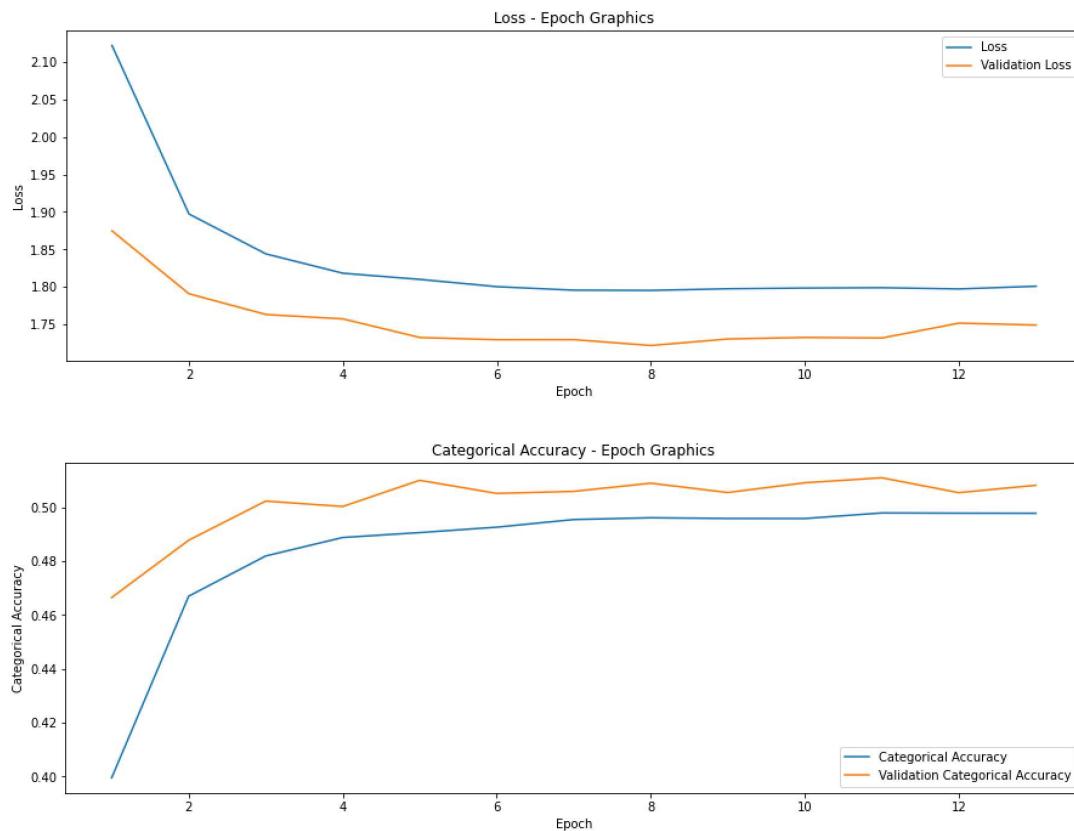
import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Loss - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.plot(range(1, len(hist.history['loss']) + 1), hist.history['loss'])
plt.plot(range(1, len(hist.history['val_loss']) + 1), hist.history['val_loss'])
plt.legend(['Loss', 'Validation Loss'])
plt.show()

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Categorical Accuracy - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Categorical Accuracy')
plt.plot(range(1, len(hist.history['categorical_accuracy']) + 1),
hist.history['categorical_accuracy'])
plt.plot(range(1, len(hist.history['val_categorical_accuracy']) + 1),
hist.history['val_categorical_accuracy'])
plt.legend(['Categorical Accuracy', 'Validation Categorical Accuracy'])
plt.show()

```

Şu grafikler elde edilmiştir:



Şimdi de belli bir TEXT_LENGTH (60) uzunluğunda yazı alıp bir döngü içerisinde ona 400 karakter ekleyerek yeni bir yazı üretelim. Bu işlemi şöyle yapabiliriz: TEXT_LENGTH uzunluğundaki yazıyı verip bundan edilecek TEXT_LENGTH + 1'inci karakteri tahmin ederiz. Sonra son TEXT_LENGTH uzunlukta yazıyı verip sonraki karakteri tahmin ederiz. Böylece 400 karakteri bir döngü içerisinde bu biçimde elde ederiz. Örneğimizde ağ tarafından elde edilen karakterlerin olasılık dağılımına göre biraz değiştirilmesi gerekebilmiştir. Yani üretilen karakterin değil de ona yakın olan bir karakterin seçilmesi tekdüzeliği engellemek bakımından uygun olur. Bunun için aşağıdaki gibi bir fonksiyondan faydalana bilir:

```
def sample(preds, temperature=1.0):
    preds = np.asarray(preds).astype('float64')
    preds = np.log(preds) / temperature
    exp_preds = np.exp(preds)
    preds = exp_preds / np.sum(exp_preds)
    probas = np.random.multinomial(1, preds, 1)

    return np.argmax(probas)
```

Programın yazı üretim kısmı için TEXT_LENGTH uzunluktaki yazıları one hot encoding biçimine dönüştürmemiz gereklidir. Bunun için aşağıdaki gibi bir fonksiyon yazabilirmiz:

```
def str_to_ohe(s):
    ohe = np.zeros(shape=(1, TEXT_LENGTH, len(chars)))
    for index, char in enumerate(s):
        ohe[0, index, char_dict[char]] = 1.0

    return ohe
```

Şimdi rastgele bir TEXT_LENGTH (60) uzunluğunda bir yazı oluşturalım:

```
r = np.random.randint(len(sentences) - maxlen - 1)
random_initial_sentence = text[r:r + 60]
```

Şimdi de 400 karakterlik bir yazı üretelim:

```
generated_text = initial_text
for i in range(400):
    ohe = str_to_ohe(generated_text[i: TEXT_LENGTH + i])
    result = model.predict(ohe)[0]
    char = chars[sample(result, 0.2)]
    generated_text += char

print(f'{generated_text[0:TEXT_LENGTH]}\n{generated_text[TEXT_LENGTH:]}')
```

Tüm kodları aşağıda bir bütün olarak veriyoruz:

```
from tensorflow.keras.utils import get_file

path = get_file('nietzsche.txt', origin='https://s3.amazonaws.com/text-datasets/nietzsche.txt')

with open(path) as f:
    text = f.read().lower()

print(text)

TEXT_LENGTH = 60
STEP = 3

sentences = []
next_chars = []

for i in range(0, len(text) - TEXT_LENGTH, STEP):
```

```

sentences.append(text[i:i + TEXT_LENGTH])
next_chars.append(text[i + TEXT_LENGTH])

print(f'Number of sequences: {len(sentences)}')

chars = sorted(list(set(text)))
print(f'Number of unique chars: {len(chars)}')

char_dict = {char: index for index, char in enumerate(chars)}

import numpy as np

training_dataset_x = np.zeros((len(sentences), TEXT_LENGTH, len(chars)), dtype=np.uint8)
training_dataset_y = np.zeros((len(sentences), len(chars)), dtype=np.uint8)

for i, sentence in enumerate(sentences):
    for k, char in enumerate(sentence):
        training_dataset_x[i, k, char_dict[char]] = 1
    training_dataset_y[i, char_dict[next_chars[i]]] = 1

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import LSTM, Dropout, Dense

model = Sequential(name='TextProduction')
model.add(LSTM(128, activation='tanh', input_shape=(TEXT_LENGTH, len(chars)), name='LSTM'))
model.add(Dropout(0.3, name='Dropout'))
model.add(Dense(len(chars), activation='softmax', name='Output'))
model.summary()

from tensorflow.keras.optimizers import RMSprop

optimizer = RMSprop(learning_rate=0.01)
model.compile(optimizer, loss='categorical_crossentropy', metrics=['categorical_accuracy'])

from tensorflow.keras.callbacks import EarlyStopping

esc = EarlyStopping(monitor='val_loss', patience=5, restore_best_weights=True, verbose=1)
hist = model.fit(training_dataset_x, training_dataset_y, batch_size=32, epochs=20,
                  validation_split=0.2,
                  callbacks=[esc])

import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Loss - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.plot(range(1, len(hist.history['loss']) + 1), hist.history['loss'])
plt.plot(range(1, len(hist.history['val_loss']) + 1), hist.history['val_loss'])
plt.legend(['Loss', 'Validation Loss'])
plt.show()

figure = plt.gcf()
figure.set_size_inches((15, 5))
plt.title('Categorical Accuracy - Epoch Graphics')
plt.xlabel('Epoch')
plt.ylabel('Categorical Accuracy')
plt.plot(range(1, len(hist.history['categorical_accuracy']) + 1),
          hist.history['categorical_accuracy'])
plt.plot(range(1, len(hist.history['val_categorical_accuracy']) + 1),
          hist.history['val_categorical_accuracy'])
plt.legend(['Categorical Accuracy', 'Validation Categorical Accuracy'])

```

```

plt.show()

def sample(preds, temperature=1.0):
    preds = np.asarray(preds).astype('float64')
    preds = np.log(preds) / temperature
    exp_preds = np.exp(preds)
    preds = exp_preds / np.sum(exp_preds)
    probas = np.random.multinomial(1, preds, 1)

    return np.argmax(probas)

def str_to_ohe(s):
    ohe = np.zeros(shape=(1, TEXT_LENGTH, len(chars)))
    for index, char in enumerate(s):
        ohe[0, index, char_dict[char]] = 1.0

    return ohe

r = np.random.randint(len(text) - TEXT_LENGTH + 1)
initial_text = text[r:r + TEXT_LENGTH]

generated_text = initial_text
for i in range(400):
    ohe = str_to_ohe(generated_text[i:i + TEXT_LENGTH])
    result = model.predict(ohe)[0]
    char = chars[sample(result, 0.2)]
    generated_text += char

print(f'{generated_text[0:TEXT_LENGTH]}{generated_text[TEXT_LENGTH:]}')

```

Yukarıdaki örnekte word embedding uygulanmamıştır. Bu örneğin word embedding uygulanmış halini de aşağıda veriyoruz. Anımsanacağı gibi Keras'taki Embedding katmanı girdi olarak 3 boyutlu değil 2 boyutlu indekslerden oluşan bir matris istemektedir. Çıktı olarak one hot encoding kullanılmaktadır.

```

import tensorflow.keras

path = tensorflow.keras.utils.get_file('nietzsche.txt', 'https://s3.amazonaws.com/text-dataset')
text = open(path).read().lower()

sentences = []
next_chars = []
maxlen = 60
step = 3

for i in range(0, len(text) - maxlen, step):
    sentences.append(text[i:i + maxlen])
    next_chars.append(text[i + maxlen])

chars = sorted(list(set(text)))
char_dict = dict((char, index) for index, char in enumerate(chars))

import numpy as np

training_dataset_x = np.zeros((len(sentences), maxlen), dtype='int8')
training_dataset_y = np.zeros((len(sentences), len(chars)), dtype='int8')

for i, sentence in enumerate(sentences):
    for k, char in enumerate(sentence):
        training_dataset_x[i, k] = char_dict[char]
    training_dataset_y[i, char_dict[next_chars[i]]] = 1

from tensorflow.keras.models import Sequential

```

```

from tensorflow.keras.layers import Embedding, Dropout, LSTM, Dense

model = Sequential()
model.add(Embedding(maxlen, 64))
model.add(Dropout(0.2))
model.add(LSTM(128))
model.add(Dropout(0.2))
model.add(Dense(64, activation='relu'))
model.add(Dropout(0.2))
model.add(Dense(len(chars), activation='softmax'))

epochs = 1

model.compile(optimizer='RMSprop', loss='categorical_crossentropy')
hist = model.fit(training_dataset_x, training_dataset_y, batch_size=128, epochs=epochs)

def sample(preds, temperature=1.0):
    preds = np.asarray(preds).astype('float64')
    preds = np.log(preds) / temperature
    exp_preds = np.exp(preds)
    preds = exp_preds / np.sum(exp_preds)
    probas = np.random.multinomial(1, preds, 1)

    return np.argmax(probas)

def str_to_indexes(s):
    a = np.zeros((1, len(s)), dtype='int8')
    for index, char in enumerate(s):
        a[0, index] = char_dict[char]

    return a

import matplotlib.pyplot as plt

plt.title('Epoch - Loss Graph')
plt.xlabel = 'Epoch'
plt.ylabel = 'Loss'
plt.plot(range(1, len(hist.epoch) + 1), hist.history['loss'])
plt.legend(['loss', 'val_loss'])

r = np.random.randint(len(text) - maxlen - 1)
random_initial_sentence = text[r:r + maxlen]

generated_text = random_initial_sentence
for i in range(400):
    a = str_to_indexes(generated_text[i:i + maxlen])
    result = model.predict(a)[0]
    generated_text += chars[sample(result, 0.2)]

print('[{}][{}].format(generated_text[0:maxlen], generated_text[maxlen:]))
```

Keras'ta Modellerin Fonksiyonel Olarak Oluşturulması

Şimdiye kadar biz Keras'ta Sequential bir model nesnesi yarattık ve bu model nesnesine katmanları add metoduyla ekledik. Model sınıfının add metodu bir önceki katmanın çıktısını bir sonraki katmana girdi yapmaktadır. Zaten buradaki Sequential ismi de bunu anlatmaktadır. Bu biçimde model oluşturmak pek çok problem için yeterliyse de bazı tarz problemlerde yetersiz kalabilmektedir. Örneğin bazı modellerin girdileri birden fazla olabilmektedir. Benzer biçimde bazı modellerin çıktıları da yine birden fazla olabilmektedir. Halbuki Sequential modelde tek girdi ve tek çıktı vardır. Örneğin biz yazıyı hem sınıflandıracak olalım hem de yazının eleştiri derecesini tespit edecek olalım. Buradaki çıktı bir tane değildir, iki tanedir. Tabii ilk akla gelen şey modelleri ayrı ayrı kurmak ve iki ayrı çıktıyı ayrı ayrı elde etmektir. Fakat böylesi bir çaba fazladan programlama yükü oluşturmaktadır. Çünkü bu çıktılar için eğitimin yeniden

yapılması gereklidir. Ayrıca oluşan ağırlık değerlerinin yeniden saklanması da gerekmektedir. Oysa tek bir modelle iki ya da daha fazla çıktı elde edilebilir. Benzer biçimde örneğin biz bir yazıyı hem sınıflandırmak istediğimizi hem de yazının diline bakılarak onun hangi tarihte yazıldığını belirlemek istediğimizi düşünelim. Bu örnekte de iki çıktı fakat tek bir girdi vardır. Bu iki çıktı için iki ayrı model oluşturulabilir fakat tek bir modelle de bu işlem yapılabilir. Tabii girdilerin de birden fazla olması durumuyla karşılaşılabilirmektedir. Örneğin birinci girdi olarak yazının kendisini, ikinci girdi olarak da yazının yazarına ilişkin bilgileri kullanabiliyoruz. Bu iki girdi kümelerinden hareketle de yazıyı sınıflandırmak isteyebiliriz. Ya da örneğin bir evin fiyatını belirleyebilmek için evin büyülüğü, merkeze uzaklığı gibi birtakım bilgilerin yanı sıra evin fotoğraflarından da faydalanan makine öğrenmesi isteyebiliriz. Bu iki tür girdi birbirlerinden farklıdır ve bu iki tür bilgi üzerinde uygulanacak işlemler de birbirinden farklı olacaktır. Bu tür çok girdili modelleri tek girdili hale getirmek için bazen verilerin birleştirilmesi yoluna gidilebilmektedir. Ancak son örnekte olduğu gibi pek çok modelde farklı veriler girdi katmanının farklılığından dolayı tek bir girdi olarak birleştirilememektedir. İşte Keras'ın Sequential modeli böyle çoklu girdi ve çoklu çıktı üzerinde işlem yapamamaktadır. Bu işlemlerin yapılabilmesi için Sequential model yerine modelin fonksiyonel biçimde oluşturulması gerekmektedir.

Keras'ta aslında Dense gibi LSTM gibi katman sınıflarının fonksiyon çağrıma operatör metotları (`__call__` metotları) yazılmıştır. Bu metot çağrıma metotları katmanın girdisini oluşturmak ve katmanları birbirlerine bağlamak için kullanılmaktadır. Örneğin aşağıdaki gibi bir kod parçası olsun:

```
from tensorflow.keras.models import Model
from tensorflow.keras.layers import Input, Dense

inp = Input(shape=(784, ), name='Input')
a = Dense(128, activation='relu', name='Dense-1')(inp)
b = Dense(128, activation='relu', name='Dense-2')(a)
output = Dense(10, activation='softmax', name='Output')(b)
model = Model(inputs=inp, outputs=output, name='Model')

model.summary()
```

Buradan elde edilen özet bilgiler şöyledir:

Model: "Model"

Layer (type)	Output Shape	Param #
<hr/>		
Input (InputLayer)	[(None, 784)]	0
Dense-1 (Dense)	(None, 128)	100480
Dense-2 (Dense)	(None, 128)	16512
Output (Dense)	(None, 10)	1290
<hr/>		
Total params: 118,282		
Trainable params: 118,282		
Non-trainable params: 0		

Burada Dense fonksiyonu Dense türünden bir sınıf nesnesi yaratmaktadır. Bu sınıf nesnesi ile fonksiyon çağrıma operatörü kullanıldığından aslında bir önceki katmanın girdileri bu katmana bağlanmış olur. Dolayısıyla yukarıdaki kod parçasında Input katmanı aslında birinci Dense katmanına girdi yapılmıştır. Diğer Dense katmanları da diğerlerine girdi yapılmıştır. Toplamda bu kod parçası Sequential sınıfının yaptığı şeyi yapmaktadır. Başka bir deyişle bu işlemin Sequential eşdeğeri şöyledir:

```
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense

model = Sequential(name='Sequential')
model.add(Dense(128, input_dim=784, activation='relu', name='Dense-1'))
```

```
model.add(Dense(128, activation='relu', name='Dense-2'))
model.add(Dense(10, activation='softmax', name='Output'))
model.summary()
```

Buradan elde edilen özet bilgiler de şöyledir:

Model: "Sequential"

Layer (type)	Output Shape	Param #
=====		
Dense-1 (Dense)	(None, 128)	100480
Dense-2 (Dense)	(None, 128)	16512
Output (Dense)	(None, 10)	1290
=====		
Total params: 118,282		
Trainable params: 118,282		
Non-trainable params: 0		

Her ne kadar yukarıdaki iki kod parçası işlevsel bakımdan eşdeğerse de biz birinci kod parçasında artık Sequential sınıfından kurtulmuş olduk. Böylece bu yöntemle Sequential sınıfı ile yapamadığımız bazı şeyleri de yapar hale gelebileceğiz.

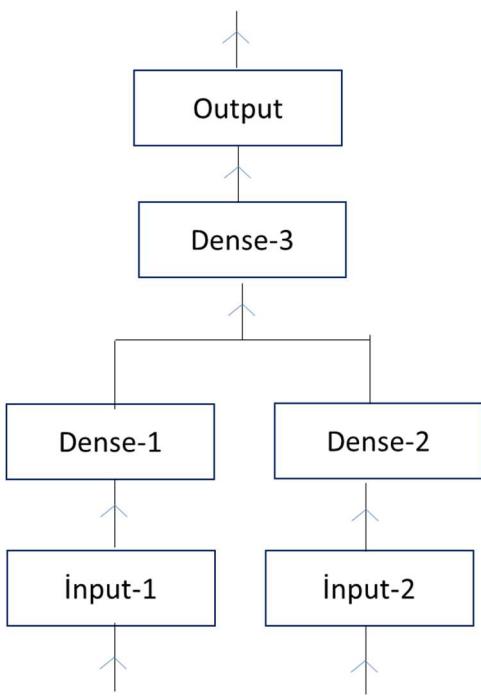
Sinir ağı modelini fonksiyonel olarak oluştururken girdileri oluşturmak için Input isimli bir katmanın kullanıldığına dikkat ediniz. Bu katmanın shape isimli parametresi girdinin boyutlarını belirtmektedir. Bu parametre bir demet biçiminde girilmelidir.

Fonksiyonel modelin kendisi Sequential sınıfı ile değişim Model isimli sınıf ile oluşturulmaktadır. Model sınıfının inputs parametresi modelin girdilerini outputs parametresi ise modelin çıktılarını belirtir. Biz yukarıdaki örnekte Model nesnesini şöyle yarattık:

```
model = Model(inputs=inp, outputs=output, name='Model')
```

Burada girdi ve çıktı katmanları bir tanedir. Eğer girdi ve çıktı katmanları birden fazla ise inputs ve outputs parametreleri demet ya da liste olarak girilir.

Fonksiyonel model sayesinde biz modeli graf biçiminde oluşturabiliriz. Örneğin:



Buradaki modelde Input-1 ve Input-2 isimli iki girdi katmanı bulunmaktadır. Bu katmanlardan ayrı ayrı Dense-1 ve Dense-2 katmanlarına bağlanmış, daha sonra da Dense-1 ve Dense-2 katmanlarının çıktıları birleştirilerek Dense-3 katmanına, Dense-3 katmanı da Output katmanına bağlanmıştır. Burada Dense-1 ve Dense-2 katmanlarının birleştirildiğini görüyorsunuz. Bu birleştirme işlemi tensorflow.keras.layers modülündeki concatenate fonksiyonuyla yapılmaktadır. concatenate fonksiyonu bizden birleştirilecek katmanların çıktılarını (ya da NumPy dizilerini) bir demet ya da liste biçiminde parametre olarak alır ve bunları birleştirerek birleştirilmiş bir çıktı haline getirir. Fonksiyonun axis parametresi hangi eksene göre birleştirme yapılacağını belirtmektedir. Birleştirme işleminde birleştirilen eksenin dışındaki tüm eksenlerin uzunlıklarının aynı olması gereklidir. Örneğin:

```

from tensorflow.keras.layers import concatenate
import numpy as np

x = np.arange(20).reshape(4, 5)
y = np.arange(20).reshape(4, 5)
concatenated = concatenate([x, y], axis=0)

print(concatenated)

```

Burada birleştirme ilk eksene göre yapılacaktır. Şu sonuç elde edilmiştir:

```

tf.Tensor(
[[ 0  1  2  3  4]
 [ 5  6  7  8  9]
 [10 11 12 13 14]
 [15 16 17 18 19]
 [ 0  1  2  3  4]
 [ 5  6  7  8  9]
 [10 11 12 13 14]
 [15 16 17 18 19]], shape=(8, 5), dtype=int32)

```

Örneğin:

```
concatenated = concatenate([x, y], axis=1)
```

Burada birleştirme 1 numaralı eksen üzerinde yapılmıştır. Yani sütunlar birleştirilmektedir. Şu sonuç elde edilmiştir:

```

tf.Tensor(
[[ 0  1  2  3  4  0  1  2  3  4]

```

```
[ 5  6  7  8  9  5  6  7  8  9]
[10 11 12 13 14 10 11 12 13 14]
[15 16 17 18 19 15 16 17 18 19]], shape=(4, 10), dtype=int32)
```

axis parametresinin default değeri 1'dir.

Şimdi bir metin ve o metne dayalı bir soruyu içeren ve sorunun Doğru ya da Yanlış biçiminde yanıtlandığı temsili çok girişli bir örnek verelim. Modelimizi fonksiyonel olarak şöyle kurabiliyoruz:

```
VOCAB_SIZE = 30000
TEXT_SIZE = 300
QUESTION_SIZE = 100

from tensorflow.keras.models import Model
from tensorflow.keras.layers import Input, Embedding, LSTM, concatenate, Dense, Dropout

inp1 = Input(shape=(TEXT_SIZE,), name='Input-Text')
inp2 = Input(shape=(QUESTION_SIZE,), name='Input-Question')

x = Embedding(VOCAB_SIZE, 64, name='Embedding-Text')(inp1)
x = LSTM(64, activation='tanh', name='LSTM-Text')(x)
x = Dropout(0.2, name='Dropout-1')(x)

y = Embedding(VOCAB_SIZE, 64, name='Embedding-Question')(inp2)
y = LSTM(32, activation='tanh', name='LSTM-Question')(y)
y = Dropout(0.2, name='Dropout-2')(y)

z = concatenate([x, y])
z = Dense(128, activation='relu', name='Dense-1')(z)
z = Dropout(0.2, name='Dropout-3')(z)
z = Dense(64, activation='relu', name='Dense-2')(z)
z = Dropout(0.2, name='Dropout-4')(z)
z = Dense(1, activation='sigmoid', name='Output')(z)

model = Model(inputs=[inp1, inp2], outputs=z)
model.summary()
```

Burada metinler 300 karakterden sorular da 100 karakterden oluşmaktadır. Modelin iki ayrı girdisi vardır ve her girdiye word embedding uygulanmıştır. Sonra bu girdiler concatenate fonksiyonuyla birleştirilmiş ve Dense katmanlarla devam edilmiştir. Buradan elde edilen özet model bilgileri şöyledir:

Model: "model"

Layer (type)	Output Shape	Param #	Connected to
Input-Text (InputLayer)	[(None, 300)]	0	
Input-Question (InputLayer)	[(None, 100)]	0	
Embedding-Text (Embedding)	(None, 300, 64)	1920000	Input-Text[0][0]
Embedding-Question (Embedding)	(None, 100, 64)	1920000	Input-Question[0][0]
LSTM-Text (LSTM)	(None, 64)	33024	Embedding-Text[0][0]
LSTM-Question (LSTM)	(None, 32)	12416	Embedding-Question[0][0]
Dropout-1 (Dropout)	(None, 64)	0	LSTM-Text[0][0]
Dropout-2 (Dropout)	(None, 32)	0	LSTM-Question[0][0]
concatenate (Concatenate)	(None, 96)	0	Dropout-1[0][0] Dropout-2[0][0]

Dense-1 (Dense)	(None, 128)	12416	concatenate[0][0]
Dropout-3 (Dropout)	(None, 128)	0	Dense-1[0][0]
Dense-2 (Dense)	(None, 64)	8256	Dropout-3[0][0]
Dropout-4 (Dropout)	(None, 64)	0	Dense-2[0][0]
Output (Dense)	(None, 1)	65	Dropout-4[0][0]
=====			
Total params:	3,906,177		
Trainable params:	3,906,177		
Non-trainable params:	0		

Çok girişli modelleri eğitirken x verilerinin de bir demet ya da liste biçiminde verilmesi gerekmektedir. Biz burada girdileri rastgele değerlerle üreteceğiz. Çünkü amacımız belli bir problemi çözmekten ziyade çok girişli bir modelin yapısına ilişkin açıklamalar yapmak olacak:

```
import numpy as np

def generate_random_inputs(n):
    x1 = np.random.randint(0, VOCAB_SIZE, (n, TEXT_SIZE))
    x2 = np.random.randint(0, VOCAB_SIZE, (n, QUESTION_SIZE))
    y = np.random.randint(0, 2, n)

    return x1, x2, y

model.compile(optimizer='rmsprop', loss='binary_crossentropy', metrics=['binary_accuracy'])

training_dataset_text_x, training_dataset_question_x, training_dataset_y
=generate_random_inputs(1000)

hist = model.fit([training_dataset_text_x, training_dataset_question_x], training_dataset_y,
validation_split=0.2, epochs=5)
```

Burada fit metodunun x girdilerinin iki tane olduğuna dikkat ediniz. Bu girdiler bir demet ya da liste biçiminde girilebilmektedir. Tabii test işlemi de yine iki girdi kullanılarak yapılacaktır:

```
test_dataset_text_x, test_dataset_question_x, test_dataset_y = generate_random_inputs(100)

eval_result = model.evaluate([test_dataset_text_x, test_dataset_question_x], test_dataset_y)
for i in range(len(eval_result)):
    print(f'{model.metrics_names[i]} --> {eval_result[i]}')
```

Kestirim işlemini de tabii metin ve soru olmak üzere girdi ile yapmalıyız:

```
predict_text = np.random.randint(0, VOCAB_SIZE, TEXT_SIZE)
predict_question = np.random.randint(0, VOCAB_SIZE, QUESTION_SIZE)

predict_result = model.predict([predict_text.reshape(1, -1), predict_question.reshape(1, -1)])
if predict_result[0, 0] < 0.5:
    print('YANLIŞ')
else:
    print('DOĞRU')
```

Bir modelin birden fazla çıktısı da olabilir. Bu durumda çıktılar için ayrı Dense katmanları oluşturulur. Sonra bu katmanlar fit işleminde ayrı ayrı belirtilir. Buradaki önemli bir nokta üç farklı çıkışın skalalarının farklı olabilmesidir. Elde edilen modelin ağırlıklarını güncellenirken kullanılan optimizasyon algoritmaları tek bir loss değerine bakmaktadır. O halde üretilen çıktıların tek bir loss değeri elde edilmek üzere birleştirilmesi gerekmektedir. Keras bu işlemi de arka planda otomatik olarak yapar.

TENSORFLOW KÜTÜPHANESİNNİN KULLANIMI

TensorFlow Google tarafından 2015 yılında yapay zeka ve makine öğrenmesi konuları için tasarlanmış bir kütüphanedir. Daha önce de belirttiğimiz gibi Keras backend olarak Tensorflow ve diğer kütüphaneleri de kullanabilen yüksek seviyeli bir kütüphane durumundayken Tensorflow 2 ile birlikte artık Tenserflow kütüphanesinin bir parçası haline getirilmiştir. Kütüphaneye ismini veren Tensor matematik ve makine öğrenmesinde matrisel bir kavramı temsil etmektedir. İsimdeki Flow ise sözcüğü işlemlerin aksal bir biçimde yürütüldüğünü anlatmaktadır. TensorFlow yalnızca Python'dan değil pek çok programlama dilinden de kullanılabilir. Zaten kütüphanenin önemli bir bölümü C++ Programlama Dilinde yazılmıştır.

TensorFlow kütüphanesinin Python için ana API dokümantasyonu aşağıdaki adreste bulunmaktadır:

https://www.tensorflow.org/api_docs/python

TenserFlow kütüphanesini Python'da kullanırken pek çokları gibi biz de import işlemini aşağıdaki gibi yapacağız:

```
import tensorflow as tf
```

Bir süre önceye kadar kursumuzda Tensorflow kütüphanesinin 1'li versiyonlarını anlatıyordu. Sonra kütüphanenin 2'li versiyonları çıktığında her ikisini de anlatmaya başladık. Ancak bir süredir artık kütüphanenin yalnızca 2'li versiyonlarını anlatıyoruz.

TensorFlow kütüphanesi 2'li versiyonlarla birlikte "egear execution" denilen pratik bir özelliğe sahip olmuştur. Bu özellik nedeniyle artık Tensorflow 1 için geçerli olan bazı özellikler Tensorflow 2 için geçerli olmamaktadır. Yani Tensorflow 2 ile birlikte kütüphanenin geriye doğru uyumluluğu (backward compatibility) bozulmuş durumdadır. Ancak TensorFlow ekibi bu uyumsuzluğu pratik bir biçimde gidermek için ayrı bir paket de düzenlemiştir. Eğer Tensorflow 1 ile çalışmak istiyorsanız fakat makinenizde TensorFlow'un 2'li versiyonları yüklü ise geriye doğru uyumu koruyabilmek için aşağıdaki bildirimleri yapmalısınız:

```
import tensorflow.compat.v1 as tf
tf.disable_v2_behavior()
```

Aşağıdaki dokümanda TensorFlow'un 1'li versiyonları ile 2'li versiyonları arasındaki farklılıklar resmi olarak dokümante edilmiştir:

<https://www.tensorflow.org/guide/migrate>

Yukarıda da belirttiğimiz gibi biz artık kursumuzda yalnızca Tensorflow'un 2'li versiyonlarını ele alacağımız.

TensorFlow ile NumPy Kütüphaneleri Arasındaki Benzerlikler ve Farklılıklar

Tensorflow kütüphanesinin 1'li versiyonları metaprogramlama modeline dayandırılmıştı. Bu versiyonlarda önce kod akışını bir graf biçiminde oluşturup sonra onu çalıştırıyorduk. Dolayısıyla Tensorflow'un 1'li versiyonları programlama modeli NumPy kütüphanesindeki modelden oldukça farklıydı. Ancak TensorFlow'da 2'li versiyonlarla birlikte bu metaprogramlama modeli karmaşık olduğu gereçesiyle kaldırılmıştır. Bu nedenle TensorFlow 2'deki model klasik NumPy modeline daha çok benzer hale gelmiştir.

Hem NumPy hem de TensorFlow vektörel işlemler yapabilen kütüphanelerdir. Yani her iki kütüphanede de biz dizileri tek hamlede hiç döngü kullanmadan işlemlere sokabilmekteyiz. Bu bağlamda TensorFlow'daki Tensor nesnelerini NumPy'daki ndarray nesnelerine benzetilebiliriz. Her iki kütüphane de işlevsel bakımından birbirlerine benzese de aralarında belirgin farklılıklar davardır. Bu farklılıkları tek tek ele almak istiyoruz:

- TensorFlow makine öğrenmesi için kullanılan bir kütüphanedir. Halbuki NumPy nümerik işlemler için kullanılan genel amaçlı bir kütüphanedir. Bu nedenle Tensorflow yapay sinir ağları, görüntü işleme gibi alanlarda hazır modüllere de sahiptir.
- NumPy Python için yazılmış bir kütüphanedir. Oysa TensorFlow Python dışında başka programlama dillerinden de kullanılabilmektedir.
- TensorFlow gradient tabanlı optimizasyon işlemlerini otomatik olarak bünyesinde bulundurmaktadır. Gradient tabanlı optimizasyonun makine öğrenmesinde önemli bir yeri vardır.
- TensorFlow paralel programlama yeteneğine sahiptir. Paralel programlama uygularken CPU çekirdeklerini ve GPU'yu da kullanabilmektedir. Oysa NumPy paralel programlama yeteneğine sahip değildir.

Tensör Nesnelerinin Yaratılması

TensorFlow kütüphanesindeki en önemli kavram "tensor" kavramıdır. Bir tensör matrisel bir bilgidir. Tensorflow için tensörler NumPy'daki ndarray nesneleri ile benzer anlamdadır. TensorFlow'da da tıpkı NumPy'da olduğu gibi ensörlerin birer dtype türleri ve shape özellikleri vardır. Tensörler read only ya da read/write olabilmektedir. TensorFlow 1'de tensörlere isimler ilişirilmektedir. Graf oluştururken bu isimlerden faydalanaabiliyordu. Tensorflow 2'de tensörlerin yine ism olsa da "eager execution" özelliği nedeniyle artık isimlerin bir önemi kalmamıştır.

Bir tensor yaratmanın en çok kullanılan yöntemlerinden biri tf.constant fonksiyonunu kullanmaktadır. Fonksiyonun parametrik yapısı şöyledir:

```
tf.constant(
    value,
    dtype=None,
    shape=None,
    name='Const'
)
```

Fonksiyonun birinci parametresi yaratılacak tensörün bilgilerini, ikinci parametresi de dtype türünü belirtmektedir. dtype türü belirtilmezse tam sayı değerler için dtype türü tf.int32, noktalı sayılar için float32'dir (NumPy'da noktalı sayılar için default dtype türünün np.float64 olduğunu anımsayınız). dtype türü yine NumPy'da olduğu gibi string biçiminde de belirtilebilmektedir. shape parametresi de tensörün boyut bilgisini belirtir. name parametrelerinin Tensorflow 2 için önemi yoktur. Örneğin:

```
t = tf.constant([1, 2, 3, 4, 5, 6], dtype=tf.float32, shape=(2, 3))
print(t)
```

Şu çıktı elde edilmiştir:

```
tf.Tensor(
[[1. 2. 3.]
 [4. 5. 6.]], shape=(2, 3), dtype=float32)
```

Burada value parametresi herhangi bir dolaşılabilir nesne olarak girilebilmektedir. shape parametresi girilmezse value parametresindeki şekil tensörün boyutu olarak kabul edilmektedir. constant fonksiyonu ile yaratılan tensörün elemanları değiştirilemez. constant fonksiyonuyla yaratılan tensör read-only durumdadır. Biz onun herhangi bir elemanını değiştirememiz: Örneğin:

```
In [16]: t[2] = 10
Traceback (most recent call last):

  File "C:\Users\aslan\AppData\Local\Temp\ipykernel_12508/2011961731.py",
line 1, in <module>
    t[2] = 10

TypeError: 'tensorflow.python.framework.ops.EagerTensor' object does not
support item assignment
```

Fonksiyonun value parametresi tek bir değer olarak da girilebilir. Bu durumda shape ile belirtilen boyuttaki elemanların tamamı o değerle doldurulur. Örneğin:

```
In [15]: tf.constant(1, shape=(3, 3))
Out[15]:
<tf.Tensor: shape=(3, 3), dtype=int32, numpy=
array([[1, 1, 1],
       [1, 1, 1],
       [1, 1, 1]])>
```

Tensör yaratmak için diğer bir seçenek de tf.convert_to_tensor fonksiyonunu kullanmaktadır. Fonksiyonun parametrik yapısı şöyledir:

```
tf.convert_to_tensor(
    value,
    dtype=None,
    dtype_hint=None,
    name=None
)
```

Bu fonksiyon da read-only bir tensör yaratmaktadır. Örneğin:

```
t = tf.convert_to_tensor([[1, 2, 3], [4, 5, 6], [7, 8, 9]])
```

Fonksiyonun bir shape parametresinin olmadığına dikkat ediniz.

TensorFlow'da da tipki NumPy'da olduğu gibi zeros, ones ve fill fonksiyonları vardır:

```
tf.zeros(
    shape,
    dtype=tf.dtypes.float32,
    name=None
)

tf.ones(
    shape,
    dtype=tf.dtypes.float32,
    name=None
)

tf.fill(
    dims,
    value,
    name=None
)
```

Örneğin:

```
In [21]: tf.zeros((3, 2))
Out[21]:
<tf.Tensor: shape=(3, 2), dtype=float32, numpy=
array([[0., 0.],
       [0., 0.],
       [0., 0.]], dtype=float32)>
```

Yine TensorFlow'da NumPy'da olduğu gibi zeros_like ve ones_like fonksiyonları da bulunmaktadır.

```
In [22]: tf.ones((3, 2))
Out[22]:
<tf.Tensor: shape=(3, 2), dtype=float32, numpy=
array([[1., 1.],
       [1., 1.],
       [1., 1.]], dtype=float32)>
```

```
In [23]: tf.fill((3, 2), 10)
Out[23]:
<tf.Tensor: shape=(3, 2), dtype=int32, numpy=
array([[10, 10],
       [10, 10],
       [10, 10]])>
```

tf.range fonksiyonu Python'un range fonksiyonu gibi kullanılmaktadır. Bize dizilimdeki değerleri içeren bir tensör nesnesi verir. Fonksiyonun parametrik yapısı şöyledir:

```
tf.range(
    start,
    limit,
    delta=1,
    dtype=None,
    name='range'
)
```

Örneğin:

```
In [33]: tf.range(10)
Out[33]: <tf.Tensor: shape=(10,), dtype=int32, numpy=array([0, 1, 2, 3,
4, 5, 6, 7, 8, 9])>
```

Örneğin:

```
In [34]: tf.range(10.5, 20.5, 0.5)
Out[34]:
<tf.Tensor: shape=(20,), dtype=float32, numpy=
array([10.5, 11. , 11.5, 12. , 12.5, 13. , 13.5, 14. , 14.5, 15. ,
       16. , 16.5, 17. , 17.5, 18. , 18.5, 19. , 19.5, 20. ],
       dtype=float32)>
```

Fonksiyon parametrelerinin int değil float türden olabildiğine dikkat ediniz. Yine TensorFlow'da da NumPy'da olduğu gibi bir linspace fonksiyonu vardır:

```
tf.linspace(
    start,
    stop,
    num,
    name=None,
    axis=0
)
```

Örneğin:

```
In [6]: tf.linspace(5, 10, 10)
Out[6]:
<tf.Tensor: shape=(10,), dtype=float64, numpy=
array([ 5.          ,  5.55555556,  6.11111111,  6.66666667,  7.22222222,
       7.77777778,  8.33333333,  8.88888889,  9.44444444, 10.        ])>
```

Bir tensör nesnesinin dtype örnek özniteliği nesnenin dtype türünü elde etmek için, shape örnek özniteliği ise nesnesinin boyut bilgisini elde etmek için kullanılmaktadır. Örneğin

```
In [24]: t = tf.constant([1, 2, 3, 4, 5, 6], shape=(2, 3),
dtype=tf.float32)
```

```
In [25]: t.dtype
Out[25]: tf.float32
```

```
In [26]: t.shape
Out[26]: TensorShape([2, 3])
```

Tensör nesnesinin boyutsal özellikleri shape örnek özniteliğinin yanı sıra eşdeğer olarak get_shape metoduyla da elde edilebilmektedir. Aslında tensör nesnelerinin boyutsal özellikleri tf.shape fonksiyonuyla da elde edilebilmektedir. Örneğin:

```
In [18]: tf.shape(t)
Out[18]: <tf.Tensor: shape=(1,), dtype=int32, numpy=array([10])>
```

Tensor sınıfının shape örnek özniteliğinin boyutsal özellikleri TensorShape nesnesi biçiminde, ancak tf.shape fonksiyonunun bir Tensor nesnesi biçiminde verdiğine dikkat ediniz. TensorShape nesnesi bir Tensor nesnesi değildir. Tensor nesnelerinin boyutsal özellikleri de tf.rank fonksiyonuyla elde edilebilmektedir. Bu fonksiyonun bir örnek özniteliği ya da metot karşılığı yoktur. Örneğin:

```
In [24]: t = tf.constant([[1, 2, 3], [4, 5, 6], [7, 8, 9]])
```

```
In [25]: tf.rank(t)
Out[25]: <tf.Tensor: shape=(), dtype=int32, numpy=3>
```

Skaler tensör nesnelerinin boyutsal özelliklerinin boş olduğuna dikkat ediniz. Örneğin:

```
In [46]: a = tf.constant(10)
```

```
In [47]: b = tf.constant([10, 20, 30])
```

```
In [48]: a.shape
Out[48]: TensorShape([])
```

```
In [49]: b.shape
Out[49]: TensorShape([3])
```

Bir tensör nesnesinin boyutsal özelliklerini değiştirebilmek için tf.reshape fonksiyonu kullanılmaktadır. Bu fonksiyonun bir metot karşılığı yoktur. Örneğin:

```
In [106]: t = tf.constant([[1, 2, 3], [4, 5, 6], [7, 8, 9]])  
In [107]: k = tf.reshape(t, (9, ))  
  
In [108]: k  
Out[108]: <tf.Tensor: shape=(9,), dtype=int32, numpy=array([1, 2, 3,  
4, 5, 6, 7, 8, 9])>
```

Tıpkı NumPy kütüphanesinde olduğu gibi belli bir eksen değeri -1 girilirse bu durum "diğer eksenlerin durumuna göre bu eksenin değerini belirle" anlamına gelmektedir.

Bir tensör nesnesinin toplam eleman sayısı tf.size fonksiyonuyla elde edilebilir. Bu fonksiyonun bir örnek özniteliği ya da metot karşılığı yoktur. Örneğin:

```
In [78]: t = tf.Variable([[1, 2, 3], [4, 5, 6], [7, 8, 9]])  
In [79]: tf.size(t)  
Out[79]: <tf.Tensor: shape=(), dtype=int32, numpy=9>
```

Tensör nesnelerinin elemanlarına köşeli parantez operatörleriyle erişilebilir. Dilimleme işlemi yine NumPy dizilerinde olduğu gibidir. Örneğin:

```
In [28]: t = tf.constant([[1, 2, 3, 4], [5, 6, 7, 8], [9, 10, 11, 12]])  
In [29]: t[2]  
Out[29]: <tf.Tensor: shape=(4,), dtype=int32, numpy=array([ 9, 10, 11, 12])>  
  
In [30]: t[0:3, 2:4]  
Out[30]:  
<tf.Tensor: shape=(3, 2), dtype=int32, numpy=  
array([[ 3,  4],  
       [ 7,  8],  
       [11, 12]])>  
  
In [31]: t[:-1, :-2]  
Out[31]:  
<tf.Tensor: shape=(2, 2), dtype=int32, numpy=  
array([[1, 2],  
       [5, 6]])>
```

Bir tensör nesnesi içerisindeki değer NumPy dizisi olarak NumPy isimli metot ile elde edilebilir. Örneğin:

```
In [92]: t = tf.constant([[1, 2, 3], [4, 5, 6], [7, 8, 9], [10, 11, 12]])  
In [93]: t.numpy()  
Out[93]:  
array([[ 1,  2,  3],  
       [ 4,  5,  6],  
       [ 7,  8,  9],  
       [10, 11, 12]])
```

Bir tensör nesnesi tf.Variable sınıfıyla da oluşturulabilir. tf.Variable sınıfıyla oluşturulan tensörlerin tuttuğu değerler değiştirilebilmektedir. tf.Variable sınıfının `__init__` metodunun parametrik yapısı şöyledir:

```
tf.Variable(  
    initial_value=None,  
    trainable=False,  
    validate_shape=True,
```

```
caching_device=None,  
name=None,  
variable_def=None,  
dtype=None,  
import_scope=None,  
constraint=None,  
synchronization=tf.VariableSynchronization.AUTO,  
aggregation=tf.compat.v1.VariableAggregation.NONE,  
shape=None  
)
```

Variable nesnesi yaratılırken yine ilkdeğer verilmek zorundadır. Örneğin:

```
In [35]: t = tf.Variable([[1, 2, 3], [4, 5, 6], [7, 8, 9]])
```

```
In [36]: t  
Out[36]:  
<tf.Variable 'Variable:0' shape=(3, 3) dtype=int32, numpy=  
array([[1, 2, 3],  
       [4, 5, 6],  
       [7, 8, 9]])>
```

Variable nesneleri de birer tensör olduğu için tensörler üzerindeki işlemler bunlar üzerinde de uygulanabilmektedir. Bir Variable nesnesinin içerisindeki değer assign metodu ile değiştirilebilir Örneğin:

```
In [65]: t = tf.Variable([[1, 2, 3], [4, 5, 6], [7, 8, 9]])
```

```
In [66]: t  
Out[66]:  
<tf.Variable 'Variable:0' shape=(3, 3) dtype=int32, numpy=  
array([[1, 2, 3],  
       [4, 5, 6],  
       [7, 8, 9]])>
```

```
In [67]: t.assign([[10, 20, 30], [40, 50, 60], [70, 80, 90]])  
Out[67]:  
<tf.Variable 'UnreadVariable' shape=(3, 3) dtype=int32, numpy=  
array([[10, 20, 30],  
       [40, 50, 60],  
       [70, 80, 90]])>
```

```
In [68]: t  
Out[68]:  
<tf.Variable 'Variable:0' shape=(3, 3) dtype=int32, numpy=  
array([[10, 20, 30],  
       [40, 50, 60],  
       [70, 80, 90]])>
```

Bir Variable nesnesinin belli bir elemanına köşeli parantez operatörüyle değer atayamayız. Örneğin:

```
In [73]: t[1, 2] = 10
Traceback (most recent call last):
  File "C:\Users\aslan\AppData\Local\Temp\ipykernel_19348/3177698712.py",
line 1, in <module>
    t[1, 2] = 10
```

TypeError: 'ResourceVariable' object does not support item assignment

Rastgele değerlerden tensör nesneleri oluşturmak için tf.random modülündeki fonksiyonlar kullanılmaktadır. tf.random.uniform fonksiyonu düzgün dağılmış rastgele sayılarından oluşan tensör nesneleri oluşturmaktadır. Fonksiyonun parametrik yapısı şöyledir:

```
tf.random.uniform(
    shape,
    minval=0,
    maxval=None,
    dtype=tf.dtypes.float32,
    seed=None,
    name=None
)
```

Burada minval değeri aralığa dahil, maxval değeri aralığa dahil değildir. Örneğin:

```
In [81]: tf.random.uniform((3, 3), 0, 10, dtype=tf.int32)
Out[81]:
<tf.Tensor: shape=(3, 3), dtype=int32, numpy=
array([[6, 9, 3],
       [9, 2, 3],
       [0, 8, 4]])>
```

tf.random.normal fonksiyonu ise normal dağılıma uygun rastgele sayılar üretmektedir. Fonksiyonun parametrik yapısı şöyledir:

```
tf.random.normal(
    shape,
    mean=0.0,
    stddev=1.0,
    dtype=tf.dtypes.float32,
    seed=None,
    name=None
)
```

Örneğin:

```
In [84]: tf.random.normal((5, 5))
Out[84]:
<tf.Tensor: shape=(5, 5), dtype=float32, numpy=
array([[ 0.6709525 , -0.5455337 , -0.09969767, -0.5458125 , -0.72455513],
       [ 0.7689879 , -0.23801427,  0.46185434,  0.88133913, -0.39394924],
       [ 0.49497288,  0.39744157,  0.8921115 , -0.57044065, -0.90798306],
       [ 0.0737021 ,  0.59513694, -1.9811838 ,  0.3674018 , -1.4103378 ],
       [-1.830832 , -0.0887295 , -1.4519913 ,  0.62525374,  0.48967224]],
```

tf.random.shuffle fonksiyonu in-place karıştırma işlemi yapmaktadır. Fonksiyonun parametrik yapısı şöyledir:

```
tf.random.shuffle(
    value,
```

```
    seed=None,  
    name=None  
)
```

Karıştırma her zaman ilk eksene göre yapılmaktadır. Örneğin:

Örneğin:

```
In [89]: t = tf.constant([[1, 2, 3], [4, 5, 6], [7, 8, 9], [10, 11, 12]])
```

```
In [90]: t
```

```
Out[90]:  
<tf.Tensor: shape=(4, 3), dtype=int32, numpy=  
array([[ 1,  2,  3],  
       [ 4,  5,  6],  
       [ 7,  8,  9],  
       [10, 11, 12]])>
```

```
In [91]: tf.random.shuffle(t)
```

```
Out[91]:  
<tf.Tensor: shape=(4, 3), dtype=int32, numpy=  
array([[ 1,  2,  3],  
       [ 7,  8,  9],  
       [10, 11, 12],  
       [ 4,  5,  6]])>
```

tf.random modülünde daha pek çok fonksiyon vardır. Bunlar hakkında bilgileri Tensorflow dokümanlarından elde edebilirsiniz.

Tensör Nesneleri Üzerinde İşlemler

Tıpkı NumPy kütüphanesinde olduğu gibi TensorFlow kütüphanesinde de tensör nesneleri üzerinde vektörel işlemler yapılabilmektedir. Tensor sınıfının operatör metodları iki tensor nesnesi üzerinde işlemler yapılmasına olanak sağlamaktadır. Örneğin:

```
import tensorflow as tf  
  
a = tf.constant([1, 2, 3], dtype=tf.float32)  
b = tf.constant([1, 2, 3], dtype=tf.float32)  
  
c = a + b  
print(c)
```

Şöyledir bir çıktı elde edilmiştir:

```
tf.Tensor([2. 4. 6.], shape=(3,), dtype=float32)
```

Vektörel işlemler NumPy kütüphanesinde olduğu gibidir. * operatörü karşılıklı elemanları çarpmaktadır. Matrisel çarpım için tf.matmul fonksiyonu kullanılır. Örneğin:

```
import tensorflow as tf  
  
a = tf.constant([[1, 2, 3], [4, 5, 6], [7, 8, 9]], dtype=tf.float32)  
b = tf.constant([[1, 2, 3], [4, 5, 6], [7, 8, 9]], dtype=tf.float32)  
  
c = tf.matmul(a, b)  
print(c)
```

Şu çıktı elde edilmiştir:

```
tf.Tensor(  
[[ 30.  36.  42.]  
 [ 66.  81.  96.]  
[102. 126. 150.]], shape=(3, 3), dtype=float32)
```

Örneğin:

NumPy kütüphanesinde olduğu gibi Tensorflow kütüphanesinde de "broadcasting" özelliği vardır. Örneğin:

```
import tensorflow as tf  
  
a = tf.constant([[1, 2, 3]], dtype=tf.float32)  
  
b = tf.constant([[1, 2, 3], [4, 5, 6], [7, 8, 9]], dtype=tf.float32)  
  
c = a + b  
print(c)
```

Şu çıktı elde edilmiştir:

```
tf.Tensor(  
[[ 2.  4.  6.]  
 [ 5.  7.  9.]  
[ 8. 10. 12.]], shape=(3, 3), dtype=float32)
```

tf.math modülü içerisinde axis parametresi alarak matematiksel işlem yapan pek çok hazır fonksiyon bulunmaktadır. Bu fonksiyonlardaki axis parametresi NumPy fonksiyonlarındaki axis parametresi ile aynı anlamdadır. axis parametresi değişimin hangi eksen üzerinde yapılacağı (işlem sırasında hangi eksen değerler değiştirilerek işlemin yapılacağı) anlamına gelir. Tensörün satırları ya da sütunları üzerinde temel işlemler tf.math.reduce_sum, tf.math.reduce_mean, tf.math.reduce_max, tf.math.reduce_min gibi tf.math.reduce_xxx biçiminde isimlendirilmiş fonksiyonlarla yapılmaktadır. Örneğin:

```
In [128]: t = tf.constant([[1, 2, 3], [4, 5, 6], [7, 8, 9], [10, 11,  
12]])  
  
In [129]: tf.math.reduce_sum(t)  
Out[129]: <tf.Tensor: shape=(), dtype=int32, numpy=78>  
  
In [130]: tf.math.reduce_sum(t, axis=0)  
Out[130]: <tf.Tensor: shape=(3,), dtype=int32, numpy=array([22, 26,  
30])>  
  
In [131]: tf.math.reduce_sum(t, axis=1)  
Out[131]: <tf.Tensor: shape=(4,), dtype=int32, numpy=array([ 6, 15,  
24, 33])>
```

tf.math modülündeki reduce_xxx biçiminde isimlendirilmemiş fonksiyonlar axis parametresi almamaktadır. Örneğin:

```
In [142]: t = tf.constant([[1, 2, 3], [4, 5, 6], [7, 8, 9], [10, 11, 12]], dtype=tf.float32)
```

```
In [143]: tf.math.sqrt(t)
```

```
Out[143]:
```

```
<tf.Tensor: shape=(4, 3), dtype=float32, numpy=
array([[0.99999994, 1.4142134 , 1.7320508 ],
       [1.9999999 , 2.236068 , 2.4494896 ],
       [2.6457512 , 2.8284268 , 2.9999998 ],
       [3.1622777 , 3.3166249 , 3.4641016 ]], dtype=float32)>
```

tf.math modülündeki segment_xxx biçiminde isimlendirilmiş olan fonksiyonlar matristeki değerleri bölmelere (segment'lere) ayırarak o bölmeler üzerinde işlemler yaparlar. Bölmeler 0'dan başlayarak artan sırada tamsayı değerlerle ifade edilmektedir ve bölüm belirten bu değerlerin sıralı olması gerekmektedir. Örneğin:

```
In [147]: a = tf.constant([3, 5, 7, 9, 4, 2, 1, 6])
```

```
In [148]: tf.math.segment_sum(a, [0, 0, 1, 1, 1, 2, 2, 3])
```

```
Out[148]: <tf.Tensor: shape=(4,), dtype=int32, numpy=array([ 8, 20, 3, 6])>
```

Burada segment değerlerinin tensör'ün eleman sayısı ile aynı uzunlukta olduğuna dikkat ediniz. 0, 1, 2, 3 değerlerine karşı gelen elemanlar kendi aralarında toplama işlemine sokulmuştur. Bölümleme her zaman 0'dan itibaren yapılmaktadır. Örneğin:

```
In [152]: a = tf.constant([3, 5, 7, 9, 4, 2, 1, 6])
```

```
In [153]: tf.math.segment_sum(a, [1, 1, 1, 2, 2, 3, 4, 4])
```

```
Out[153]: <tf.Tensor: shape=(5,), dtype=int32, numpy=array([ 0, 15, 13, 2, 7])>
```

Çok boyutlu tenseörlerdeki segment numaraları her zaman son eksene ilişkindir. Örneğin:

```
In [177]: a = tf.constant([[1, 2, 3], [4, 5, 6], [7, 8, 9], [10, 11, 12]])
```

```
In [178]: tf.math.segment_sum(a, [0, 0, 1, 1])
```

```
Out[178]: <tf.Tensor: shape=(2, 3), dtype=int32, numpy=
array([[ 5,  7,  9],
       [17, 19, 21]])>
```

tf.math modülündeki unsorted_segment_xxx isimli fonksiyonlarda bölüm numaraları sıralı olmak zorunda değildir. Bu fonksiyonlarda ayrıca bölüm sayısının da belirtilmesi gerekmektedir. Örneğin:

```
In [166]: a = tf.constant([3, 5, 7, 9, 4, 2, 1, 6])
```

```
In [167]: tf.math.unsorted_segment_sum(a, [0, 1, 0, 1, 2, 0, 1, 2], num_segments=3)
```

```
Out[167]: <tf.Tensor: shape=(3,), dtype=int32, numpy=array([12, 15, 10])>
```

Buradaki segment_num bölüm sayılarından fazla girilirse geri kalan elemanlar 0 olarak doldurulmaktadır. Örneğin:

```
In [174]: a = tf.constant([3, 5, 7, 9, 4, 2, 1, 6])
In [175]: tf.math.unsorted_segment_sum(a, [0, 1, 0, 1, 2, 0, 1, 2],
num_segments=5)
Out[175]: <tf.Tensor: shape=(5,), dtype=int32, numpy=array([12, 15,
10, 0, 0])>
```

tf.math.argmax ve tf.math.argmin fonksiyonları NumPy'da olduğu gibi en büyük ve en küçük elemanların kendilerini değil indekslerini bulmaktadır.

Tensorflow Veri Kümelerinin Kullanımı

Nasıl Keras içerisinde hazır çeşitli veri kümeleri varsa Tensorflow içerisinde de hazır bazı veri kümeleri bulunmaktadır. Bu veri kümeleri ayrı bir paket olarak oluşturulmuştur. Tensorflow kurulumu sırasında bu paket kurulmamaktadır. Tensorflow veri kümelerini yüklemesini komut satırında pip kurulum programıyla şöyle indirip kurabilirsiniz:

```
pip install tensorflow-datasets
```

Paketi aşağıdaki gibi import ederek kullanabiliriz:

```
import tensorflow_datasets as tfds
```

Tüm veri kümeleri tensorflow_datasets.core.DatasetBuilder sınıfından türetilmiş sınıflar biçiminde oluşturulmuştur. Tüm veri kümelerinin isimleri liste biçiminde şöyle elde edilebilir:

```
all_datasets = tfds.list_builders()
print(all_datasets)
```

Veri kümeleri tensorflow_datasets.load fonksiyonuyla yüklenebilir. Örneğin:

```
datasets = tfds.load( name='horses_or_humans' , split=['train', 'test'])
```

split parametresi veri kümelerini 'train', 'test' ya da ['train', 'test'] biçiminde ayırmak için kullanılmaktadır. Default ayırım %80-%20 biçimindedir. Ancak oran da verilebilmektedir. load fonksiyonundan elde edilen veri kümelerinin elemanlarına köşeli parantez operatörüyle erişilebilir.

with_info parametresi True geçilirse load fonksiyonunun geri dönüş değeri bir demet olmaktadır:

```
datasets, info = tfds.load( name='horses_or_humans' , split=['train', 'test'], with_info=True)
```

Bu biçimde elde edilen datasets nesnesi bir listedir. Listenin ilk elemanı "train" verilerini ikinci elemanı ise "test" verilerini tutmaktadır.

PYTORCH KÜTÜPHANESİİN KULLANIMI

Tensorflow kütüphanesinin yanı sıra Pytorch kütüphanesi de yapay sinir ağları ve derin öğrenme ağları için en çok kullanılan kütüphanelerden biridir. PyTorch kütüphanesi Torch isimli kütüphane temel alınarak Facebook AI Research Lab tarafından geliştirilmiştir. Açık kaynak kodlu bir kütüphanedir. Kütüphane hem alçak seviyeli hem de yüksek seviyeli kullanıma olanak sağlamaktadır. PyTorch kütüphanesi Tensorflow kütüphanesine göre daha nesne yönelimli ve daha Pythonic biçimde tasarlanmıştır. PyTorch kütüphanesi bir aile olarak da düşünülebilir. Bu aile içerisinde PyTorch ile organik bağlantısı olan Torchvision, Torchaudio, Torchtext, Torchvideo gibi eklenti kütüphaneler de bulunmaktadır.

PyTorch kütüphanesi pip programı ile aşağıdaki gibi kurulabilir:

```
pip install pytorch
```

PyTorch ile organik bağlantısı olan diğer kütüphaneleri de benzer biçimde kurabilirsiniz. Örneğin:

```
pip install torchvision
```

PyTorch kütüphanesinin ana import ismi "torch" biçimindedir. Kütüphaneyi şöyle import edebilirsiniz:

```
import torch
```

Aşağıdaki örneklerde bu modülün import edilmiş olduğunu varsayacağız.

PyTorch Tensörleri

Tıpkı Tensorflow kütüphanesinde olduğu gibi PyTorch kütüphanesinde işlemler tensörler yoluyla yapılmaktadır. Tensörler çeşitli işlemlere sokulabilen çok boyutlu matriksel veri yapılarıdır. Tensörler NumPy kütüphanesindeki NumPy dizilerine benzetilebilir. Ancak Tensorflow ve PyTorch kütüphanelerindeki tensörler paralel bir biçimde ve GPU işlemeye sokulabilen bir niteliğe sahiptir. PyTorch'ta tensörler Tensor isimli sınıfta temsil edilmiştir.

PyTorch'ta bir tensör çeşitli biçimlerde oluşturulabilir. Bunun en temel yolu tensor isimli fonksiyonu kullanmaktır (Tensor isminin bir sınıf belirttiğine, tensor isminin ise bir fonksiyon belirttiğine dikkat ediniz). Fonksiyonun birinci parametresine biz liste, demet ya da NumPy dizisi girebiliriz.

```
import torch  
  
t1 = torch.tensor([[1, 2, 3], [4, 5, 6], [7, 8, 9]])  
  
import numpy as np  
  
a = np.random.random((3, 3))  
  
t2 = torch.tensor(a)  
  
print(t1)  
print(t2)
```

Aşağıdaki gibi bir çıktı elde edilmiştir:

```
tensor([[1, 2, 3],  
       [4, 5, 6],  
       [7, 8, 9]])  
tensor([[0.1567, 0.0075, 0.6885],  
       [0.6852, 0.7238, 0.5855],  
       [0.6262, 0.0473, 0.2755]], dtype=torch.float64)
```

Nasıl NumPy dizilerinin ve Tensorflow tensörlerinin C Programlama Dili temelinde dtype ismiyle temsil edilen türleri varsa PyTorch kütüphanesindeki tensörlerin de yine dtype ismiyle temsil edilen türleri vardır. PyTorch tensör türlerininin en çok kullanılanlarını aşağıda veriyoruz:

- torch.float32 ya da torch.float
- torch.float64 ya da torch.double
- torch.int8 ve torch.uint8
- torch.int16 ve torch.uint16
- torch.int32 ve torch.uint32
- torch.int64 ve torch.uint64
- torch.bool

Listenin bütünü için PyTorch dokümanlarına başvurabilirsiniz:

https://pytorch.org/docs/stable/tensor_attributes.html

PyTorch tensörleri yaratılırken dtype parametresi yazışal biçimde girilememektedir. Halbuki NumPy ve Tensorflow kütüphanelerinde dtype='float32' gibi yazışal girişlere izin verildiğini anımsayınız.

Tensörler yaratılırken yaratılacak tensörlerin türleri yaratıcı fonksiyonlardaki dtype parametreleri yoluyla belirlenmektedir. Biz bir tensörün türünü Tensor sınıfının dtype örnek özniteliği ile elde edebiliriz. Örneğin:

```
t = torch.tensor([[1, 2, 3], [4, 5, 6], [7, 8, 9]], dtype=torch.float32)  
print(t.dtype)
```

empty isimli fonksiyon belli bir boyutta ilkdeğer verilmemiş tensör oluşturmaktadır. Örneğin:

```
t = torch.empty((3, 3), dtype=torch.float32)
```

Tıpkı NumPy kütüphanesinde olduğu gibi zeros ve ones fonksiyonları içi sıfırlarla ve birlerle doldurulmuş tensörler oluşturmaktadır:

```
t1 = torch.zeros((3, 3), dtype=torch.float32)  
print(t1)  
  
t2 = torch.ones((3, 3), dtype=torch.float32)  
print(t2)
```

rand fonksiyonu 0 ile 1 arasında rastgele değerlerden, randn fonksiyonu standart normal dağılıma göre rastgele değerlerden ve torch.randint fonksiyonu belli aralıkta rastgele tamsayı değerlerden tensörler oluşturmaktadır. Örneğin:

```
import torch  
  
t1 = torch.rand((3, 10), dtype=torch.float32)  
print(t1)  
  
t2 = torch.randn((3, 3), dtype=torch.float32)  
print(t2)  
  
t3 = torch.randint(10, 20, (3, 3), dtype=torch.int32)  
print(t3)
```

eye fonksiyonu birim matric biçiminde tensör oluşturmaktadır. Örneğin:

```
t = torch.eye(10, dtype=torch.float32)  
print(t)
```

Yukarıda da belirttiğimiz gibi Pytorch tensörleri Tensor isimli bir sınıf türündendir. Bu sınıfın pek çok faydalı metodu ve özniteliği vardır. shape isimli örnek özniteliği bize tensörün boyutlarını torch.Size isimli bir sınıf türünden vermektedir. torch.Size sınıfı tuple sınıfından türetilmiştir ve [...] operatörünü desteklemektedir. Dolayısıyla biz tensörün boyutlarını böyle elde edebiliriz.

```
import torch

t = torch.tensor([[1, 2, 3], [4, 5, 6], [7, 8, 9]], dtype=torch.float32)

print(t.shape)
print(t.shape[0], t.shape[1])
```

Tensor sınıfının dim isimli metodu bize tensörün boyutunu int bir değer olarak vermektedir. Tensörler yaratılırken device parametresi yoluyla tensörlerin nerede işleme sokulacağına yönelik bir bilgi verilebilmektedir. Default durum 'cpu' biçimindedir. Bu parametre 'cuda' olarak girilirse tensör Cuda kütüphanesi yoluyla GPU tarafından işleme sokulacaktır. Tabii tensörün Cuda kütüphanesi yoluyla GPU tarafından işleme sokulabilmesi için Cuda kütüphanesinin yüklü olması gerekmektedir. Diğer evice parametreleri için PyTorch dokümanlarından elde edebilirsiniz.

Bir Pytorch tensörünün içerisindeki bilgiler Tensor sınıfının NumPy isimli metodu ile NumPy dizisine dönüştürülebilmektedir. Örneğin:

```
import torch

t = torch.tensor([[1, 2, 3], [4, 5, 6], [7, 8, 9]], dtype=torch.float32)

a = t.numpy()
print(a)
```

Aşağıdaki gibi bir çıktı elde edilecektir:

```
[[1. 2. 3.]
 [4. 5. 6.]
 [7. 8. 9.]]
```

Bir NumPy dizisinden tensör elde etmek için tensör fonksiyonunun yanı sıra from_numpy fonksiyonu da kullanılmaktadır. Bu fonksiyonun yalnızca NumPy dizisini parametre olarak almaktadır. Tensörün diğer bilgilerini NumPy dizisi içerisinde elde eder. Örneğin:

```
import numpy as np
import torch

a = np.array([[1, 2, 3], [4, 5, 6], [7, 8, 9]], dtype=np.float32)

t = torch.from_numpy(a)
print(t)
```

Bir tensör nesnesinin elemanlarına [...] operatörü ile erişebiliriz. Tensor nesnelerinin elemanlarını bu yolla değiştirebiliriz. [...] operatörü ile tek bir elemana bile erişsek o eleman bize bir Tensor nesnesi olarak verilmektedir. Tensörler üzerinde tipki NumPy kütüphanesinde olduğu gibi dilimleme işlemi yapılabilir. Dilimleme yoluyla tensörün birden fazla elemanı güncellenebilir.

```
import torch

t = torch.tensor([[1, 2, 3], [4, 5, 6], [7, 8, 9]], dtype=torch.float32)

print(t)
t[0, 0] = 100
```

```

t[1, 1] = 200
t[2, 2] = 300

print(t)

a = t[1:2, 0:3]
print(a)
t[1:2, 0:3] = 0
print(t)

```

Bu işlemlerden aşağıdaki gibi bir çıktı elde edilecektir:

```

tensor([[1., 2., 3.],
       [4., 5., 6.],
       [7., 8., 9.]])
tensor([[100., 2., 3.],
       [4., 200., 6.],
       [7., 8., 300.]])

```

Tensör nesneleri üzerinde aritmetik işlemler yapılabilmektedir. Örneğin iki tensör nesnesi toplanabilir, çıkartılabilir. Bir tensör nesnesi bir skalerle işleme sokulabilir. Bu kullanım NumPy kütüphanesindekine oldukça benzemektedir. Örneğin:

```

import torch

t1 = torch.tensor([[1, 2], [3, 4]], dtype=torch.float32)
t2 = torch.tensor([[2, 5], [3, 1]], dtype=torch.float32)

t3 = t1 + t2
print(t3)

t3 = t1 * t2
print(t3)

t3 = 2 * t1 + t2
print(t3)

```

Şöyledir bir çıktı elde edilmiştir:

```

tensor([[3., 7.],
       [6., 5.]])
tensor([[ 2., 10.],
       [ 9.,  4.]])
tensor([[4., 9.],
       [9., 9.]])

```

Bir tensör içerisinde tek bir eleman varsa (bu eleman çok boyutlu bir tensörün içerisinde de olabilir) o eleman Tensor sınıfının item metoduyla elde edilebilir. item metodu birden fazla elemana sahip tensörlere uygulanamaz. Bu durumda eleman önce köşeli parantez operatöryle alınıp sonra item metodu uygulanmalıdır. [] operatörünün her zaman tensör nesnesi olduğunu anımsayınız. Örneğin:

```

import torch

t = torch.tensor([[[1]]], dtype=torch.float32)

val = t.item()
print(val)

t = torch.rand((5, 5))
val = t[3, 2].item()
print(val)

```

Tıpkı NumPy kütüphanesinde olduğu gibi PyTorch kütüphanesinde de pek çok işlem hem Tensor sınıfının metodlarıyla hem de global fonksiyonlarla yapılabilmektedir. Örneğin mutlak değer alan abs fonksiyonu hem Tensor sınıfının bir metodu olarak hem de global bir fonksiyon olarak bulunmaktadır:

```
import torch

t = torch.tensor([[1, -7], [3, -2], [-3, -6]]), dtype=torch.float32)

result = t.abs()
print(result)

result = torch.abs(t)
print(result)
```

Başka bir deyişle t bir Tensör nesnesi olmak üzere foo isimli bir fonksiyonu t.foo(...) biçiminde ya da torch.foo(t, ...) biçiminde çağırabiliriz.

NumPy kütüphanesinde olduğu gibi PyTorch kütüphanesinde de eksensel işlemler yapılmaktadır. PyTorch fonksiyonlarında eksen parametresi "axis" ismiyle değil "dim" ismiyle bulunmaktadır. Bu parametre girilmezse default durumda yine NumPy kütüphanesinde olduğu gibi işlemleri tüm tensör verileri üzerinde yapmaktadır. Örneğin bir matristeki sütun ya da satırların en büyük elemanlarını bulan max fonksiyonuna bakalım. Bu fonksiyon "dim" parametresi almaktadır. max fonksiyonu ikili bir demete geri döner. Demetin birinci elemanı en büyük elemanlara ilişkin tensörden, ikinci elemanı ise onların indislerinden oluşmaktadır.

```
import torch

t = torch.tensor([[1, 4, 8], [3, 8, 6], [4, 9, 2]]), dtype=torch.float32)

tmax, tind = t.max(dim=0)
print(tmax, tind)

tmax, tind = torch.max(t, dim=0)
print(tmax, tind)
```

Örneğin bir tensörün sattır ve sütun toplamların sum fonksiyonu ile elde edebiliriz:

```
import torch

t = torch.tensor([[1, 4, 8], [3, 8, 6], [4, 9, 2]]), dtype=torch.float32)

result = t.sum(dim=1)
print(result)
```

Burada biz tensörün satırsal toplamlarını elde etmiş olduk. Kodun çıktısı şöyledir:

```
tensor([13., 17., 15.])
```

Aşağıda tensörler üzerinde işlemler yapan önemli fonksiyonları veriyoruz:

- sqrt, square, pow
- max, min ,argmax, argmin
- sin, cos, tan, asin, acos, atan
- remainder
- transpose
- unique

Temel tensor fonksiyonlarının tam listesini PyTorch dokümanlarından inceleyebilirsiniz.

PyTorch Kütüphanesinde Dataset Sınıfları

Giriş bölümünde PyTorch kütüphanesinin TensorFlow kütüphanesine göre daha nesne yönelimli olduğunu belirtmişik. Gerçekten de PyTorch kütüphanesinde yapay sinir ağı modelini oluşturmak için çeşitli sınıfların bir arada kullanılması gerekmektedir. PyTorch kütüphanesinde veri kaynağı torch.utils.data paketindeki Dataset isimli bir soyut sınıf ile temsil edilmiştir. Programcı başlangıçta çalışacağı veri kümесini Dataset sınıfı nesnesi biçiminde oluşturmalıdır. Veri kümescinin Dataset nesnesi biçiminde oluşturulması için iki yolla yapılabilmektedir:

- 1) Programcı torch.utils.data.Dataset sınıfından türetme yaparak kendi Dataset sınıfını oluşturabilir. Programcı türrettiği sınıfta [...] operatörü için `__getitem__` metodunu yazmak zorundadır. `__len__` metodunun yazılması zorunlu değilse de genellikle gerekmektedir.
- 2) Programcı torch.utils.data.Dataset sınıfından türetilmiş olan hazır bazı sınıfları kullanabilir. Örneğin elinde NumPy dizisi olarak `dataset_x` ve `dataset_y` değerleri varsa torch.utils.data paketindeki `TensorDataset` isimli sınıfı kullanabilir.

Ayrıca tıpkı Tensorflow kütüphanesinde olduğu gibi PyTorch kütüphanesinde de hazır bazı veri kümeleri bulunmaktadır. Bu veri kümeleri bize Dataset nesnesi olarak verilmektedir.

Şimdi Boston Housing Price veri kümescini .csv dosyasından okuyarak Dataset nesnesini oluşturalım. Bunun için Dataset sınıfından türetilmiş Hazır `TensorDataset` sınıfını kullanacağız.

```
import numpy as np

dataset = np.loadtxt('housing.csv')
data_x = dataset[:, :-1]
data_y = dataset[:, -1]

from sklearn.model_selection import train_test_split

training_x, test_x, training_y, test_y = train_test_split(data_x, data_y, test_size=0.20)

import torch

training_x = torch.from_numpy(training_x)
training_y = torch.from_numpy(training_y)

test_x = torch.from_numpy(test_x)
test_y = torch.from_numpy(test_y)

from torch.utils.data import TensorDataset

training_dataset = TensorDataset(training_x, training_y)
test_dataset = TensorDataset(test_x, test_y)
```

Yukarıda da belirttiğimiz gibi burada `TensorDataset` sınıfı `Dataset` sınıfından türetilmiştir.

Şimdide hazır bazı veri kümelerini yükleyelim. Daha önce de PyTorch kütüphanesi ile organik bağlantı içerisinde olan `torchvision`, `torchaudio`, `torchtext` gibi projelerden bahsetmiştik. `torchvision.datasets` paketindeki `CIFAR10` isimli sınıf bize "CIFAR-10" veri kümescini `torch.utils.data.Dataset` sınıfından türetilmiş bir sınıf olarak verir. `CIFAR10` sınıfının `__init__` metodunun parametrik yapısı şöyledir:

```
Dataset(root, train = True, transform = None,
        target_transform = None, download = False)
```

Metodun `root` parametresi indirilen verilerin saklanacağı dizini belirtmektedir. Veriler daha önce indirilmişse yeniden indirilmemektedir. Metodun `train` parametresi `True` girilirse eğitim veri kümesi `False` girilirse test veri kümlesi elde

edilmektedir. transform parametresi veriler üzerinde dönüştürme işlemini yapar. download parametresi True ise veriler indirilmekte False ise indirilmiş veriler kullanılmaktadır.

Örneğin:

```
from torchvision.datasets import CIFAR10

training_dataset = CIFAR10(root='cifar10-data', train=True, download=True)
training_dataset = CIFAR10(root='cifar10-data', train=False, download=True)
```

PyTorch Kütüphanelerinde Sampler ve DataLoader Sınıfları

PyTorch kütüphanesinde torch.utils.data paketindeki Sampler sınıfı veri kümesinden örnekleme almak için kullanılan soyut bir sınıfır. Bu sınıfın türetilmiş çeşitli Sampler sınıfları bulunmaktadır. Programcı kendine özgü örnekleme sınıfını Sampler sınıfından türetme yaparak oluşturabilir. Türettiği sınıfta __iter__ ve __len__ metodlarının bulunması gereklidir. Sampler sınıflarının dolaşılabilir olduğuna dikkat ediniz. Bu sınıflar dolaşıldığında neler değil indeksler elde edilmektedir.

Sampler sınıfından türetilmiş olan SequentialSampler isimli sınıf sıralı indeksleri bize verir. RandomSampler isimli sınıf ise indeksleri rastgele sırada vermektedir. Örneğin:

```
from torch.utils.data import SequentialSampler, RandomSampler

a = [10, 20, 30, 40, 50]

ss = SequentialSampler(a)

for i in ss:
    print(i, end=' ')
print()

rs = RandomSampler(a)

for i in rs:
    print(i, end=' ')
```

Aslında Sampler nesneleri doğrudan değil DataLoader nesneleri tarafından dolaylı bir biçimde kullanılmaktadır.

PyTorch kütüphanesinde bir veri kümesinden belirli uzunluktaki (batch_size kadar) verileri kısım kısım elde etmek için torch.utils.data paketindeki DataLoader sınıfı kullanılmaktadır. DataLoader sınıfının __init__ metodunun parametrik yapısı şöyledir:

```
DataLoader(dataset, batch_size=1, shuffle=False, sampler=None, batch_sampler=None,
num_workers=0, collate_fn=None, pin_memory=False, drop_last=False, timeout=0,
worker_init_fn=None, *, prefetch_factor=2, persistent_workers=False)
```

Metodun birinci parametresi kullanılacak veri kümesini almaktadır. Bu veri kümesi tipik olarak Dataset sınıfından türetilmiş bir sınıf türünden olur. İkinci parametre olan batch_size verilerin kaçarlı gruplar haline elde edileceğini belirtir. Metodun shuffle parametresi her epoch'ta karıştırma yapılmış olup yapılmayacağını belirtir. sampler parametresi ise örneklemede kullanılacak nesneyi parametre olarak almaktadır. Eğer programcı bu parametreye bir örnekleme nesnesi girmezse bu nesne shuffle parametresi True ise RandomSample, False ise SequentialSample nesnesi biçiminde alınır.

DataLoader sınıfı dolaşılabilir (iterable) bir sınıfır. Bu sınıf nesnesi dolaşılırken her adımda belirtilen batch_size kadar x ve y değerleri elde edilmektedir. Örneğin:

```
import torch
```

```

from torch.utils.data import TensorDataset, DataLoader

x = torch.rand((100, 5))
y = torch.randint(0, 2, (100,))

tds = TensorDataset(x, y)
dl = DataLoader(tds, batch_size=32)

for x, y in dl:
    print(x.shape, y.shape)

```

Burada biz 100 satır 5 sütunluk bir x veri kümesi ve 100'lük bir y veri kümesini oluşturduk. Sonra bu veri kümelerinden bir Dataset nesnesini, Dataset nesnesinden de bir DataLoader nesnesi oluşturduk. DataLoader nesnesinin dolaştığımızda her biri 32 satır 5 sütun olan x değerlerini ve her biri 32 tane olan y değerlerini elde ettik. Kodun çıktısı şöyledir:

```

torch.Size([32, 5]) torch.Size([32])
torch.Size([32, 5]) torch.Size([32])
torch.Size([32, 5]) torch.Size([32])
torch.Size([4, 5]) torch.Size([4])

```

Burada son döngünün son yinelenmesinden elde edilen x ve y veri kümelerinin uzunlıklarının 4 olduğunu dikkat ediniz. Son yinelemede 32 eleman kalmayınca kalan miktardaki veriler elde edilmişdir.

PyTorch Kütüphanesinde Yapay Sinir Ağlarının Oluşturulması

PyTorch kütüphanesinde yapay sinir ağlarını oluşturmak için çeşitli katman sınıfları bulunmaktadır. Bu katman sınıfları torch.nn paketinde bulunmaktadır. Pytorch'ta katman nesneleri fonksiyonel tarzda kullanılmaktadır. Yani katmana girdiler sanki katman nesnesi bir fonksiyonmuş gibi fonksiyon çağrıma operatörü ile argüman olarak verilmektedir. Yapay sinir ağlarını oluşturmakta kullanılan en yaygın katman sınıfı Linear isimli sınıfır. Linear "dot product" işlemi yapan yalın bir sınıfır. Linear sınıfının `__init__` metodunun parametrik yapısı şöyledir:

```
Linear(in_features, out_features, bias=True, device=None, dtype=None)
```

Metodun birinci parametresi katmana giren nöron sayısı, ikinci parametresi katmandan çıkan nöron sayısını belirtir. İlk saklı katman için katmanın girdi nöronlarının sayısının veri tablosundaki özellik sayısı (yani sütun sayısı) kadar olması gerektiğini biliyorsunuz. Örneğin Linear katmanın aşağıdaki gibi kullanılmış olduğunu varsayıyalım:

```

import torch
from torch.nn import Linear

input = torch.rand((100, 5))
layer = Linear(5, 64)
result = layer(input)

print(result.shape)

```

Şöyle bir çıktı elde edilmiştir:

```
torch.Size([100, 64])
```

Burada input tensörü 100x5 boyutundadır. Linear katmanında da 32x64 boyutunda bir tensör bulunmaktadır. `layer(input)` çağrıyla aşağıdaki gibi bir işlem yapılmıştır:

```
input * layer
```

(100x5) boyutundaki bir matrisi (64x5) boyutundaki bir matrisle çarpılmış oluyoruz. Bunun sonucunda 100x64 boyutunda bir tensör elde edilecektir.

Linear sınıfı yalnızca "dot product" yapmaktadır. Bu "dot product" sonucunu herhangi bir aktivasyon fonksiyonuna sokmamaktadır. PyTorch'ta aktivasyon fonksiyonları ayrı katman sınıfları biçiminde bulundurulmuştur. Örneğin ReLU sınıfı "relu" aktivasyon fonksiyonunu uygulamaktadır:

```
import torch
from torch.nn import Linear, ReLU

x = torch.rand((100, 5))
linear_layer = Linear(5, 64)
output = linear_layer(x)
relu_layer = ReLU()
result = relu_layer(output)
```

Şimdi de PyTorch'ta yapay sinir ağı modelinin nasıl oluşturulacağı üzerinde duralım. Pytorch'ta yapay sinir ağı modeli torch.nn paketindeki Module isimli sınıfından türetilen bir sınıfla temsil edilmektedir. Örneğin:

```
from torch.nn import Module

class MyModel(Module):
    pass
```

Modelin taban sınıfı için seçilen Module ismi aslında güzel bir isim değildir. Bildiğiniz gibi Python'da "module" kavramı import edilebilen Python dosyaları için kullanılan bir kavramdır. Bu kavramın PyTorch'taki modül sınıfı ile bir ilgisinin olmadığını dikkat ediniz.

Programcı Module sınıfından sınıf türettiğten sonra sınıfı için `__init__` ve `forward` isimli metotları yazmalıdır. Katman nesneleri tipik olarak `__init__` metodunda yaratılır. `forward` metodu ise kütüphane tarafından her bir batch işlemede çağrılmaktadır. `forward` metodu parametre olarak girdi nöron değerlerini alır. Metot çıktı nöron değerlerine geri dönmelidir.

Programcı Module sınıfından türettiği sınıfın `__init__` metodunda yarattığı katman nesnelerini sınıfın örnek özniteliklerine atmalıdır. Bu atama işlemi sırasında Module sınıfının `__setattr__` metodu yoluyla atanmış katman nesneleri bir listede toplanmaktadır.

DENETİMSİZ ÖĞRENME (UNPERVISED LEARNING)

Kursumuzun giriş kısımlarında da belirttiğimiz gibi makine öğrenmesi temelde üç grup öğrenme yöntemlerinden oluşmaktadır:

- 1) Denetimli Öğrenme (supervised learning)
- 2) Denetimsiz Öğrenme (unsupervised learning)
- 3) Pekiştirmeli Öğrenme (Reinforcement learning)

Biz şimdide kadar yapay sinir ağlarını kullanarak denetimli öğrenme (supervised learning) süreçlerini ele aldık. Kursumuzun bu bölümünde ise denetimsiz (unsupervised) öğrenme konuları üzerinde duracağız.

Denetimsiz öğrenmede bir eğitim süreci yoktur. Eğitim sürecinin olmaması bir eğitim veri kümesinin de olmayacağı anlamına gelir. Yani örneğin biz denetimli öğrenmede ağı eğitmek için `training_dataset_x` ve `training_dataset_y` veri kümelerini kullandık. Halbuki denetimsiz öğrenmede elimizde yalnızca `dataset_x` kümesi bulunmaktadır.

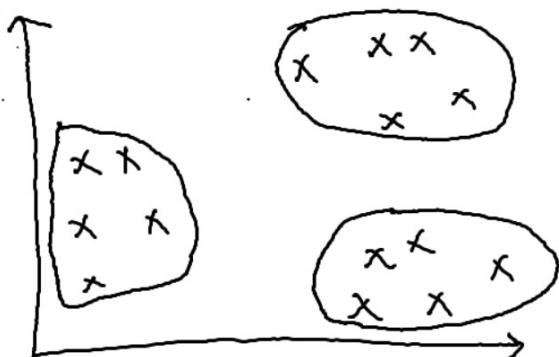
Denetimli öğrenme ile denetimsiz öğrenme arasındaki farkı MNIST örneği ile daha iyi açıklayabiliriz. Biz MNIST örneğinde 28x28 tane pixel'den oluşan resimlerin hangi rakamlara ilişkin olduğunu ağa girdi yaparak modeli eğitiyoruz. Yani biz denetimli öğrenmede aslında "bak bu 28x28'luk pixel'ler bu rakamı belirtiyor, bu 28x28'luk pixel'ler de bu rakamı belirtiyor" diyerek sistemin hangi 28x28'luk pixel'lerin hangi rakamı belirttiğini anlamasını sağlıyoruz. Oysa denetimsiz öğrenmede biz modele "bu 28x28'luk pixel'ler bazı bakımlardan birbirlerine benzıyor. Birbirlerine benzeyen 28x28'luk pixel'leri grupta" diyoruz. Böylece MNIST için kullandığımız denetimsiz modeller rakamları bilmiyor ancak o rakamların birbirine benzediğini fark ederek onları birbirlerinden ayırbiliyor.

Kümeleme İşlemleri

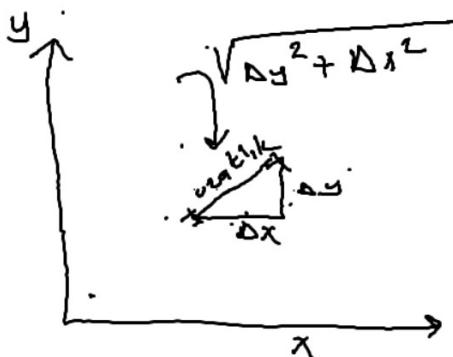
Denetimsiz öğrenme yaklaşımının en önemlilerinden biri kümeleme (clustering) işlemleridir. Nesnelerin ya da olguların özelliklerine bakılarak birbirlerine benzeyenlerin bir araya getirilmesi sürecine kümeleme denilmektedir. Makine öğrenmesinde sınıflandırma ile kümeleme süreçleri birbirine karıştırılabilir. Sınıflandırma bir olgunun daha önce belirlenmiş sınıflardan birine atanması süreci ile ilgilidir. Halbuki kümeleme olguların benzerliklerine göre bir araya getirilmesi süreci ile ilgilidir. Örneğin elimizde üç farklı meyveye ilişkin resimler bulunuyor olsun. Eğer biz bir resmin hangi meyveye ilişkin olduğunu anlamaya çalışıyorsak bu bir sınıflandırma işlemidir. Ancak biz bu resimleri benzerliklerine göre üç gruba ayırmaya çalışıyorsak bu bir kümeleme işlemidir. Yani sınıflandırmada sınıflar işin başında zaten bilinmektedir. Oysa kümelemede sınıfların kendisi oluşturulmaya çalışılmaktadır. Makine öğrenmesinde sınıflandırma işlemlerinin "denetimli öğrenme (supervised learning)" yöntemlerine kümeleme işlemlerinin ise "denetimsiz öğrenme (unsupervised learning)" yöntemlerine ilişkin olduğuna dikkat ediniz.

Mademki kümeleme işlemleri birbirine benzeyenlerin bir araya getirilme sürecidir. O halde kümelemenin yapılabilmesi için olguların birbirine benzerliğinin belirlenmesi gereklidir. Benzemek fiili insan sezgisi ile ilgilidir. Makinelerin böyle sezgileri olmadığına göre makine öğrenmesinde benzerliklerin somut niceliklerle ifade edilmesi gereklidir. Makine öğrenmesinde benzerlikler için çeşitli ölçütler kullanılabilmektedir. Örneğin benzerlikler için en çok kullanılan ölçütlerden biri "uzaklık (distance)" ölçütüdür. Uzaklık ölçütüne göre biz birbirlerine yakın olan öğelerin birbirlerine benzediğini, birbirlerine uzak olan öğelerin ise birbirlerine benzemediğini iddia ederiz.

İki ögenin uzaklığını ölçmek için değişik yöntemler kullanılabilmektedir. En çok kullanılan uzaklık ölçme yöntemlerinden biri "Öklit Uzaklığı (Euclidean Distance)" denilen yöntemdir. Öklit uzaklığı n boyutlu uzayda iki nokta arasındaki uzaklığı belirtmektedir. Örneğin iki özelliği olan olguları Öklit uzaklığa göre görsel olarak kümelemeye çalışalım. Söz konusu bu iki özellik x ve y olsun. Bu durumda bu olgular kartezyen koordinat sisteminde birer nokta belirtecektir. Aşağıdaki şekele göz gezdiriniz:



Burada gözle baktığımızda noktaların Öklit uzaklıklarına göre kendi aralarında üç grup oluşturduğunu görüyoruz. Birbirlerine yakın olan noktalar aynı grup içerisinde bulunmaktadır. Bildiğiniz gibi kartezyen koordinat sisteminde Öklit uzaklığı şöyle hesaplanmaktadır:



Lineer cebirde aslında iki boyutlu düzlem ile n boyutlu uzay arasında işlemlerin uygulanma biçimini bakımından bir farklılık yoktur. Yani iki boyutlu düzlem için söz konusu olan her şey üç boyutlu, dört boyutlu ve genel olarak n boyutlu uzay için de söz konusu olmaktadır. Örneğin üç boyutlu uzayda iki nokta arasındaki Öklit uzaklığı benzer biçimde aşağıdaki gibi hesaplanabilir:

$$\sqrt{\Delta x^2 + \Delta y^2 + \Delta z^2}$$

n boyutlu uzay için ise iki nokta arasındaki Öklit uzaklığı boyutlar x_i ile gösterilmek üzere hesaplanacaktır:

$$\sqrt{\sum_{i=1}^n \Delta x_i^2}$$

iki boyutlu düzlem ile n boyutlu uzay arasında genel işlemler bakımından bir farklılık olmadığı için konu anlatımları insan algısına yakınlık nedeniyle genellikle iki boyutlu düzlem üzerinde yapılmaktadır. Makine öğrenmesinde n boyutlu uzayı n tane özelliğe (sütuna) sahip olan bir veri tablosu anlamına geldiğine dikkat ediniz.

Şimdi n boyutlu uzay için (yani n tane sütunu olan bir veri tablosu için) iki nokta arasındaki Öklit uzaklığını hesaplayan bir Python fonksiyonu yazalım:

```
import numpy as np

def euclidean_distance(a, b, axis = 0):
    return np.sqrt(np.sum((a - b) ** 2, axis=axis))
```

Örneğin 5 boyutlu uzayda iki nokta arasındaki uzaklığı bu fonksiyonla şöyle hesaplayabiliriz:

```
a = np.array([3, 4, 2, 6, 7])
b = np.array([1, 5, 9, 2, 4])

distance = euclidean_distance(a, b)
print(distance)
```

Buradan şöyle bir çıktı elde edilecektir:

```
8.888194417315589
```

Tabii fonksiyonun parametresi olan a ve b birer matris olarak da girilebilir. Bu durumda axis=1 parametresi ile fonksiyon karşılıklı satırları nokta olarak ele alacaktır:

```
a = np.array([[3, 4, 2, 6, 7], [3, 4, 6, 7, 3], [2, 6, 1, 5, 6]], dtype=np.float32)
b = np.array([[1, 5, 9, 2, 4], [3, 5, 7, 1, 2], [4, 5, 2, 1, 7]], dtype=np.float32)

distance = euclidean_distance(a, b, axis=1)
print(distance)
```

Buradan şöyle bir çıktı elde edilecektir:

```
[8.888194 6.244998 4.7958317]
```

Öklit uzaklığı için `scipy.spatial.distance` modülündeki `euclidean` fonksiyonu da kullanılabilir. Örneğin:

```
from scipy.spatial.distance import euclidean

a = np.array([3, 4, 2, 6, 7])
b = np.array([1, 5, 9, 2, 4])
```

```
distance = euclidean(a, b)
print(distance)
```

Bu fonksiyon iki matrisin karşılıklı satırları üzerinde işlem yapamamaktadır. Fonksiyonun parametreleri olan noktalar tek boyutlu dizi olarak girilmek zorundadır.

Tensorflow kütüphanesinde Öklit uzaklıği için hazır bir fonksiyon bulunmamaktadır. Ancak böyle bir fonksiyonu aşağıdaki gibi yazabiliriz:

```
import tensorflow as tf

def tf_euclidean_distance(a, b, axis=0):
    return tf.sqrt(tf.math.reduce_sum((a - b) ** 2, axis=axis))

a = tf.Variable([[3, 4, 2, 6, 7], [3, 4, 6, 7, 3], [2, 6, 1, 5, 6]], dtype=tf.float32)
b = tf.Variable([[1, 5, 9, 2, 4], [3, 5, 7, 1, 2], [4, 5, 2, 1, 7]], dtype=tf.float32)

distance = euclidean_distance(a, b, axis=1)
print(distance)
```

Kümeleme Yöntemlerinin Sınıflandırılması

Kümeleme için yüzün üzerinde algoritma önerilmiştir. Bu algoritmaların bazıları birbirinden çok farklı olmasına karşılık bazıları birbirlerine benzemektedir. Kümeleme algoritmalarını aşağıdaki gibi sınıflara ayıralım:

- 1) Ağırlık Merkezi Temelli (Centroid Based) Kümeleme Algoritmaları
- 2) Bağlantı Temelli (Connectivity Based) Kümeleme Algoritmaları (Hiyerarşik Kümeleme Algoritmaları)
- 3) Yoğunluk Temelli (Density Based) Kümeleme Algoritmaları
- 4) Dağılım Temelli (Distribution Based) Kümeleme Algoritmaları
- 5) Bulanık Temelli (Fuzzy Based) Kümeleme Algoritmaları

Ağırlık merkezi temelli algoritmalarla bir kümelerin ağırlık merkezleri temel alınarak elemanlar kümelere ayrılmaktadır. En popüler kümeleme algoritmalarından biri olan K-Means bu gruba örnek olarak verilebilir. Ağırlık merkezi temelli kümeleme algoritmaları verimli (efficient) olmalarına karşın başlangıç koşullarına ve uç değerlere çok duyarlıdır. Bağlantı temelli algoritmalarla hiyerarşik kümeleme algoritmaları da denilmektedir. Bunlar "aşağıdan yukarı (bottom up)" ya da "yukarıdan aşağıya (top-down)" kümelerin birleştirilmesi esasına dayanmaktadır. Aşağıdan yukarıya kümeleme algoritmalarına "agglomerative" algoritmalar, yukarıdan aşağıya kümeleme algoritmalarına ise "divisive" algoritmalar da denilmektedir. Yoğunluk temelli algoritmalarla belli bir bölgedeki yoğunluğa bakılmaktadır. DBSCAN ve OPTICS bu grup algoritmaların en yaygın kullanılanlardandır. Dağılım temelli algoritmalar benzer dağılıma sahip olan eleman gruplarını kümelemeye çalışan algoritmalarıdır. Dağılım temelli algoritmalar daha esnek olmasına karşın daha çok ayarlamaya gereksinim duymaktadır. Bulanık temelli algoritmalarla öğeler birden fazla kümeye dahil edilebilmektedir. Bunlara ilişkin maliyet fonksiyonları oluşturulmaktadır.

K-Means Kümeleme Yöntemi

En yaygın kullanılan ve en yalın kümeleme yöntemlerinden biri K-Means denilen yöntemdir. K-Means yönteminde işin başında verilerin kaç kümeye ayrılacağı belirlenmiş olması gereklidir. Bu değerin k olduğunu varsayıyalım. Algoritmada kümelenenecek elemanları nokta olarak ifade edeceğiz. Kümelenenecek noktaların sayısının da n tane olduğunu varsayıyalım. Algoritmanın işleyişi şöyledir:

- 1) Önce k tane kümeye (yani her kümeye) rastgele k tane ağırlık merkezi (centroid) oluşturulur.
- 2) Tüm noktaların bu ağırlık merkezlerine olan uzaklıklar hesaplanır. Bir nokta hangi ağırlık merkezine yakınsa o kümeye dahil edilir. Böylece bu adımda n tane nokta k tane kümeye atanmış olur.

3) Kümelerin ağırlık merkezleri bu kümelere atanmış noktalar kullanılarak yeniden hesaplanır. Ağırlık merkezi hesaplaması ortalama yoluyla yapılmaktadır. Yani o kümedeki tüm noktaların kendi aralarında ortalaması bulunur. (Örneğin 3 boyutlu uzayda bu ortalama kümedeki tüm noktaların x'lerinin, y'lerinin ve z'lerinin kendi aralarında ortalaması bulunarak hesaplanmaktadır.) Böylece yeni ve daha uygun bir ağırlık merkezi oluşturulmuş olur.

4) Bundan sonra yine tüm noktalar yeni ağırlık merkezlerine uzaklıklarına göre yeniden kümelenir. Bu kümleme bir öncekinden farklı olabilmektedir. (Yani yeni ağırlık merkezleri dikkate alındığında bazı noktalar küme değiştirebilmektedir.)

5) Yeni kümelerin ağırlık merkezleri yeniden ortalama yöntemiyle bulunur ve işlemler böyle devam ettirilir.

6) Yeniden kümleme sonucunda önceki kümelerle yeni kümeler arasında eleman bakımından hiç fark yoksa artık işlemler sonlandırılır. Yani artık hiçbir nokta küme değiştirmiyorsa algoritma devam etmenin bir anlamlı yoktur.

Algoritmanın işleyişini kartezyen koordinat sisteminde noktalarla açıklamaya çalışalım. Örneğimizde toplam 12 nokta olsun. Bu 12 nokta iki kümede kümelenmek istensin. Başlangıçtaki noktalar şöyledir:

Sıra	X	Y
1	7	8
2	2	4
3	6	4
4	3	2
5	6	5
6	5	7
7	3	3
8	1	4
9	5	4
10	7	7
11	7	6
12	2	1

İki küme için rastgele ağırlık merkezleri şöyle olsun: $C_1(1, 4)$, $C_2(7, 8)$. Şimdi bu 12 noktanın bu ağırlık merkezlerine Öklid uzaklıklarını hesaplayıp bu 12 noktayı iki kümeye dağıtalım:

Sıra	X	Y	C_1 Uzaklığı	C_2 Uzaklığı	Atanan Küme
1	7	8	7.21	0	Cluster-2
2	2	4	1.00	6.40	Cluster-1
3	6	4	5.00	4.12	Cluster-2
4	3	2	2.83	7.21	Cluster-1
5	6	5	5.10	3.16	Cluster-2
6	5	7	5.00	2.24	Cluster-2
7	3	3	2.24	6.40	Cluster-1
8	1	4	0.00	7.21	Cluster-1
9	5	4	4.00	4.47	Cluster-1
10	7	7	6.71	1.00	Cluster-2
11	7	6	6.32	2.00	Cluster-2
12	2	1	3.16	8.60	Cluster-1

Bu işlemin sonucunda Cluster-1 kümesinde $\{2, 4, 7, 8, 9, 12\}$, Cluster-2 kümesinde ise $\{1, 3, 5, 6, 10, 11\}$ noktaları bulunacaktır. Şimdi yeni ağırlık merkezlerini hesaplayalım. Bu hesaptan yeni ağırlık merkezleri $C_1 = (2.67, 3.00)$ ve $C_2 = (6.33, 6.17)$ biçiminde elde edilir. Şimdi bu noktaların hepsinin yeni ağırlık merkezlerine göre uzaklıklarını hesaplayarak yeniden kümleme yapmamız gereklidir:

Sıra	X	Y	C_1 Uzaklığı	C_2 Uzaklığı	Atanan Küme
1	7	8	7.21	0	Cluster-2

1	7	8	6.61	1.95	Cluster-2
2	2	4	1.20	4.84	Cluster-1
3	6	4	3.48	2.19	Cluster-2
4	3	2	1.05	5.34	Cluster-1
5	6	5	3.88	1.22	Cluster-2
6	5	7	4.63	1.57	Cluster-2
7	3	3	0.33	4.60	Cluster-1
8	1	4	1.95	5.75	Cluster-1
9	5	4	2.54	2.55	Cluster-1
10	7	7	5.89	1.07	Cluster-2
11	7	6	5.27	0.69	Cluster-2
12	2	1	2.11	6.74	Cluster-1

Burada kümelerdeki elemanlar değişmediği için artık algoritmaya son verilecektir.

K-Means algoritmasında ilk başta alınan rastgele noktalardan dolayı algoritmanın farklı çalıştırılmalarında farklı kümeler elde edilebilmektedir. Burada genellikle izlenen yol algoritmayı n defa çalıştmak ve bu n çalışmadan elde edilen kümeleri karşılaştırarak en iyi olanını bulmaktadır. Peki洒 kümeleri neye göre karşılaştırmalıyız? İşte burada izlenen yol genellikle her kümenin noktalarının kendi ağırlık merkezlerine uzaklıklarının toplamı en küçük olan kümelemeyi tercih etmektedir. Bu da aslında toplam varyansın en küçük olduğu kümenin seçilmesi anlamına gelmektedir.

Şimdi biz K-Means algoritmasını Python'da bir fonksiyon olarak kendimiz yazalım. Fonksiyonumuzun parametrik yapısı şöyledir olsun:

```
kmeans(dataset, nclusters, centroids=None)
```

Fonksiyonun birinci parametresi olan dataset k tane sütundan ve n tane satırda oluşan noktaların kümesini belirtmektedir. Örneğin iki boyutlu kartezyen koordinat sistemi için sütun sayısı 2 olacaktır. İkinci parametre toplam kaç kümenin kullanılacağını belirtir. Üçüncü parametre default None değerini almıştır. Programcı isterse başlangıç centroid değerlerini kendisi verebilir. Eğer bu değerleri kendisi vermezse rastgele olarak alınacaktır. centroids dizisi iki boyutludur. Bunun sütun sayısı veri kümesinin sütun sayısı kadar, satır sayısı ise nclusters kadar olmalıdır.

Fonksiyonumuzda işin başında her küme için rastgele bir ağırlık merkezin atanması gerekmektedir. Bu işlemi yapan aşağıdaki gibi bir fonksiyon yazılmıştır:

```
def rand_centroids(dataset, nclusters):
    ncols = dataset.shape[1]
    centroids = np.zeros((nclusters, ncols), dtype=np.float32)
    for i in range(ncols):
        maxi = np.max(dataset[:, i])
        mini = np.min(dataset[:, i])
        rangei = maxi - mini
        centroids[:, i] = mini + rangei * np.random.random(nclusters)

    return centroids
```

Burada dataset matrisinin sütunları tek tek ele alınmış sütunların en küçük ve en büyük değerleri arasında rastgele değerlerden noktalar oluşturulmuştur. Bu fonksiyon kmeans tarafından çağrılacaktır. Şimdi de kmeans fonksiyonunu yazalım:

```
from scipy.spatial.distance import euclidean

def kmeans(dataset, nclusters, centroids=None):
    nrows = dataset.shape[0]
    clusters = np.full(nrows, -1)
    if centroids == None:
        centroids = rand_centroids(dataset, nclusters)
```

```

change_flag = True
while change_flag:
    change_flag = False
    for i in range(nrows):
        min_val = np.inf
        min_index = -1
        for k in range(nclusters):
            if not np.any(np.isnan(centroids[k])):
                result = euclidean(dataset[i], centroids[k])
                if result < min_val:
                    min_val = result
                    min_index = k
        if clusters[i] != min_index:
            change_flag = True
        clusters[i] = min_index

    for i in range(nclusters):
        idataset = dataset[clusters == i]
        centroids[i] = np.mean(idataset, axis=0) if len(idataset) else np.nan

dataset_clusters = []
inertias = []
for i in range(nclusters):
    idataset = dataset[clusters == i]
    dataset_clusters.append(idataset)
    inertias.append(np.sum((idataset - centroids[i]) ** 2) if len(idataset) else np.nan)

return clusters, dataset_clusters, centroids, inertias

```

Buradaki kmeans fonksiyonumuz dörtlü bir demete geri dönmektedir. Fonksiyonun geri döndürdüğü demetin ilk elemanı her bir noktanın hangi kümeye atandığını gösteren bir ndarray nesnesidir. Buradaki küme numaraları 0'dan başlamaktadır. Geri döndürülen demetin ikinci elemanı hangi kümelerin hangi noktalara sahip olduğunu veren bir ndarray listedir. Bu listenin uzunluğu küme sayısı kadardır ve her elemanı o kümeye ilişkin noktaları tutmaktadır. Tabii büyük uygulamalarda büyük dizilerin bu biçimde geri döndürülmesi uygun olmayabilir. Geri döndürülen demetin üçüncü elemanı kümelerin ağırlık merkezlerinin bulunduğu ndarray nesnesidir. Geri döndürülen demetin son elemanı ise nihai durumdaki noktaların kendi ağırlık merkezlerine uzaklıklarının kareleri toplamıdır. Bu da istatistiksel bakımdan kümeler içerisindeki varyans toplamları anlamına gelmektedir. Bu varyans toplamlarına bu bağlamda "atalet (inertia)" denilmektedir. Daha önceden de belirtildiği gibi kmeans algoritması bir kez değil n kez çalıştırılmalı ve ev küçük atalet değerine sahip olan çalıştırmanın sonuçları nihai sonuç olarak ele alınmalıdır.

Yukarıdaki kodun daha önce verdigimiz örnek değerlerle iki küme için 5 kez çalıştırılmaları sonucunda aşağıdaki saçılım grafikleri elde edilmiştir

```

import matplotlib.pyplot as plt

dataset = np.loadtxt('points.csv', delimiter=',', dtype=np.float32)

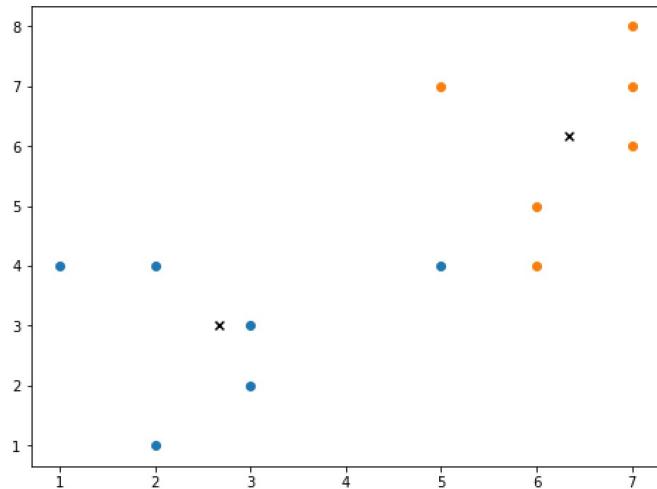
for i in range(5):
    clusters, dataset_clusters, centroids, inertias = kmeans(dataset, 2)

    plt.title('Clustered Points')
    figure = plt.gcf()
    figure.set_size_inches((8, 6))
    for i in range(2):
        plt.scatter(dataset[clusters == i, 0], dataset[clusters == i, 1])

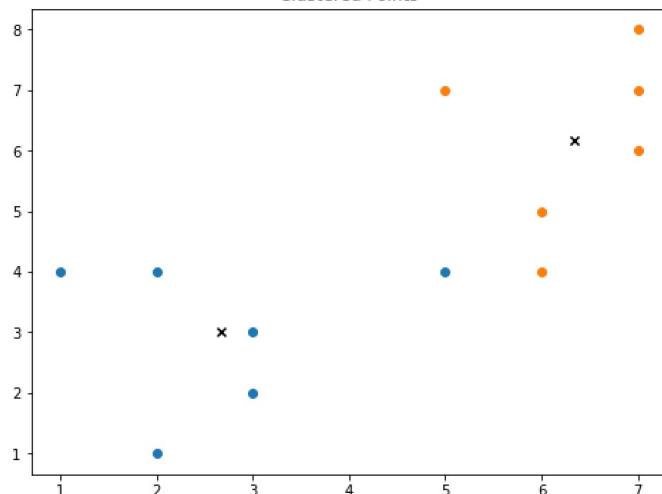
    plt.scatter(centroids[:, 0], centroids[:, 1], color='black', marker='x')
plt.show()

```

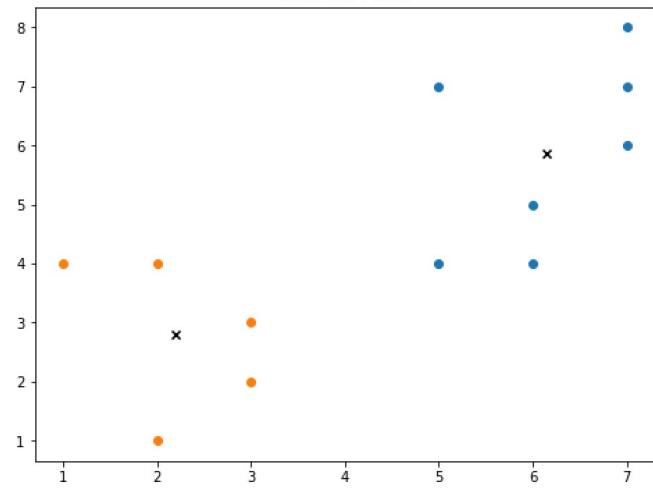
Clustered Points

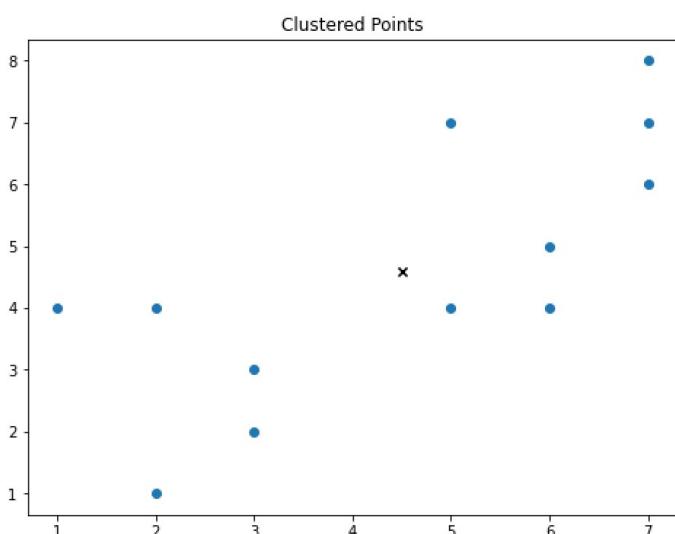
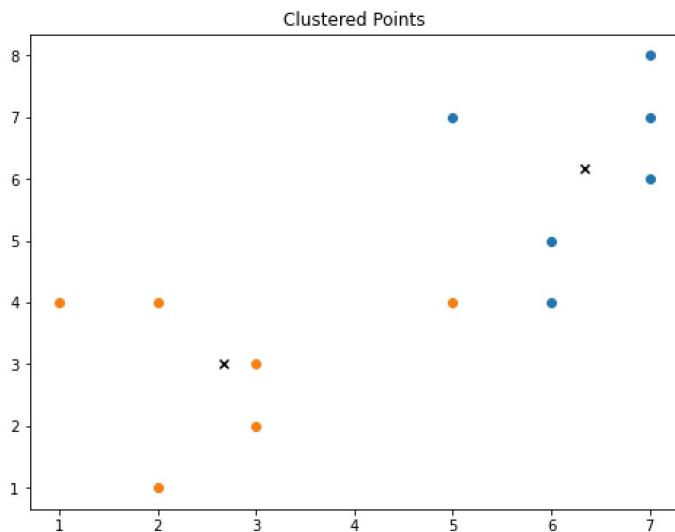


Clustered Points



Clustered Points





Algoritmanın her çalıştırılması sonucunda aynı noktaların aynı kümeler içerisinde bulunmayabileceğine dikkat ediniz. Burada son kümelemede biz iki küme oluşturulmasını istediğimiz halde tek küme oluşturulmuştur. Bunun nedeni kullandığımız algoritmada bir kusurdan kaynaklanmaktadır. Biz başlangıçta ağırlık merkezleri için rastgele noktalar aldık. Bu ağırlık merkezlerine ilişkin bir kümede hiçbir eleman yoksa artık o kümeye herhangi bir elemanın girme olasılığı kalmamaktadır. K-Means algoritmasında bu nedenle başlangıç ağırlık merkezlerinin rastgele seçiminde çeşitli teknikler kullanılmaktadır. Bunların en çok tercih edilenlerinden biri K-Means++ teknigidir. Biz burada bu ağırlık merkezlerinin rastgele seçiminde kullanılan teknikler üzerinde durmayacağız.

Örnekte kullandığımız "points.csv" dosyasının içeriği şöyledir:

```
7,8
2,4
6,4
3,2
6,5
5,7
3,3
1,4
5,4
7,7
7,6
2,1
```

Yukarıda da belirtildiği gibi algoritmanın n kez çalıştırılıp en iyi değerin (toplam ataletin en düşük olduğu değerin) alınması tipik uygulanan yöntemdir. Aşağıda bu yöntem uygulanmıştır:

```

REPEAT_COUNT = 20

dataset = np.loadtxt('points.csv', delimiter=',', dtype=np.float32)

min_inertia = np.inf
for i in range(REPEAT_COUNT):
    result = kmeans(dataset, 2)
    total = np.sum(inertias)
    if total < min_inertia:
        result_best = result

clusters, dataset_clusters, centroids, inertias = result_best

print(f'Best clusters: {clusters}')
print(f'Best dataset_clusters: {dataset_clusters}')
print(f'Best centroids: {centroids}')
print(f'Best inertias: {inertias}')

plt.title('Clustered Points')
figure = plt.gcf()
figure.set_size_inches((8, 6))
for i in range(2):
    plt.scatter(dataset[clusters == i, 0], dataset[clusters == i, 1])

plt.scatter(centroids[:, 0], centroids[:, 1], color='black', marker='x')
plt.show()

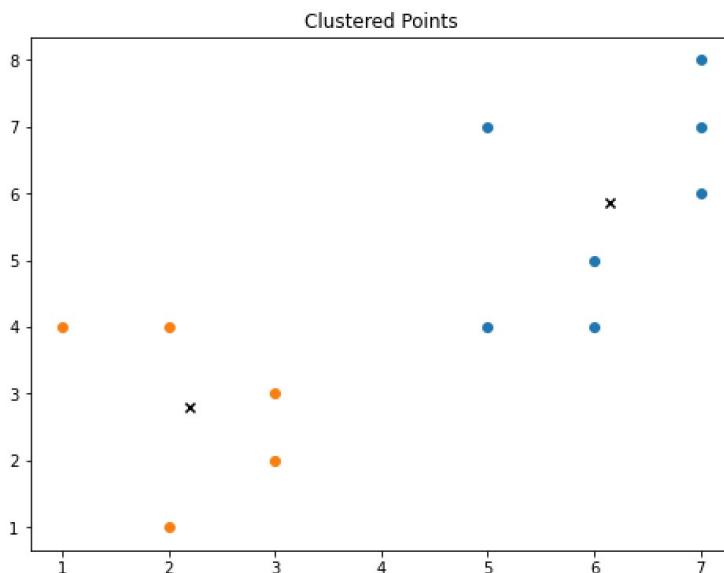
```

Buradan şöyle bir çıktı elde edilmiştir:

```

Best clusters: [0 1 0 1 0 0 1 1 0 0 0 1]
Best dataset_clusters: [array([[7., 8.],
   [6., 4.],
   [6., 5.],
   [5., 7.],
   [5., 4.],
   [7., 7.],
   [7., 6.]]), dtype=float32], array([[2., 4.],
   [3., 2.],
   [3., 3.],
   [1., 4.],
   [2., 1.]]), dtype=float32]
Best centroids: [[6.142857 5.857143]
 [2.2      2.8      ]]
Best inertias: [19.714285, 9.599999]

```



Biz yukarıdaki örnekte noktaları toplamda iki kümeye ayırdık. Pekiyi noktaların iki kümeye ayrılacağını nasıl biliyorduk? Aslında biz böyle bir bilgiye sahip değildik. Önce noktaların saçılma grafiğini çizdik. Bu grafikte noktaların kendi aralarında iki farklı toplasmaya sahip olduğunu gördük. Tabii noktalar iki boyutlu düzlemede gözle kolay biçimde algılanabilmektedir. Ancak ikiden fazla özelliğe (yani sütuna) sahip olan veri kümelerinde böyle bir grafik çizme imkanımız yoktur. O halde biz elimizdeki veri kümelerindeki satırların kaç kümeye ayrılacağını işin başında nasıl belirleyebiliriz? İşte izleyen bölümlerde bu konu ele alınacaktır. Şimdi yukarıdaki örnekteki noktaları 3 kümeye ayırtıralım:

```

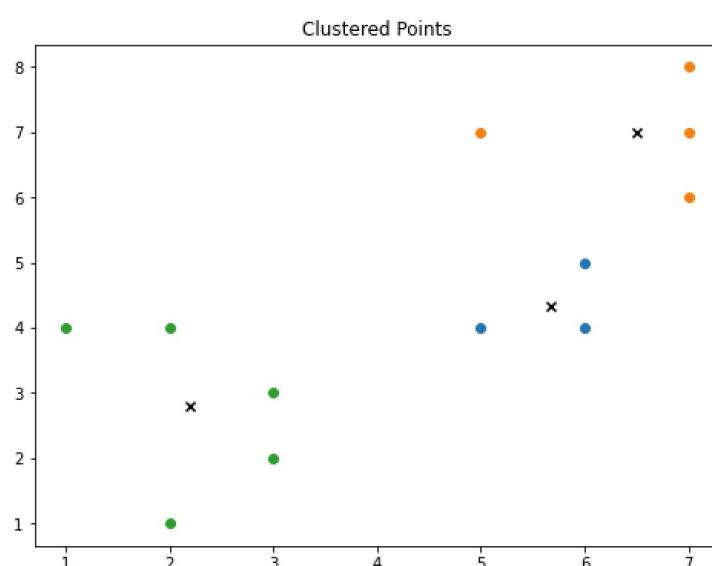
clusters, dataset_clusters, centroids, inertias = kmeans(dataset, 3)

plt.title('Clustered Points')
figure = plt.gcf()
figure.set_size_inches((8, 6))
for i in range(3):
    plt.scatter(dataset[clusters == i, 0], dataset[clusters == i, 1])

plt.scatter(centroids[:, 0], centroids[:, 1], color='black', marker='x')
plt.show()

```

Elde edilen saçılma grafiğini inceleyiniz:



Scikit-learn Kütüphanesindeki KMeans Sınıfının Kullanımı

K-Means kümeleme işlemleri için Scikit-learn kütüphanesinde sklearn.cluster modülü içerisinde KMeans isimli bir sınıf bulunmaktadır. Sınıfın `__init__` metodunun parametreleri şöyledir:

```
KMeans(n_clusters=8, init='kmeans++', n_init=10, max_iter=300, tol=0.0001, precompute_distances='auto', verbose=0, random_state=None, copy_x=True, n_jobs=None, algorithm='auto')
```

Fonksiyonun `n_clusters` parametresi noktaların ayırtılacağı küme sayısını belirtmektedir. `n_init` parametresi en iyi değerin bulunması için uygulanacak çalışma sayısıdır. Bu parametrenin default durumda 10 değerini aldığına görürorsunuz. Yani sınıf default durumda rastgele ağırlık merkezleriyle 10 çalışma yapıp bunun en iyisini bize vermektedir. `max_iter` parametresi belli bir çözüm için yineleme yapılrken çözümün uzun süre bulunmaması durumunda işlenen maksimum iterasyon sayısını belirtmektedir. Bilindiği gibi K-Means algoritmasında her yinelemede (iterasyonda) kümelerdeki elemanlar yer değiştirebilmektedir. Zaten kümelerde hiçbir değişiklik olmadığı durumda sonuç elde edilmiş olmaktadır. `tol` parametresi farklı çalışırmalardaki yakınsama değerlerinin (yani toplam `inertia`'nın) duyarlığını belirtmektedir. Yani bir çalışırmayı diğerlerinden iyi kabul edilmesi için o çalışırmadaki toplam ateletin (`inertia`) burada belirtilen değerden daha iyi olması gereklidir. Fonksiyonun diğer parametrelerini Scikit-learn dokümanlarından inceleyebilirsiniz.

KMeans sınıfının `fit` isimli metodu algoritmayı işleyen asıl metottur. `fit` metodu bizden veri kümelerini parametre olarak alır, algoritmayı işletir, sonuçları sınıfın örnek özniteliklerine yerleştirir ve KMeans nesnesinin kendisine geri döner. Örneğin:

```
dataset = np.loadtxt('points.csv', delimiter=',', dtype=np.float32)

from sklearn.cluster import KMeans

km = KMeans(n_clusters=2)
km.fit(dataset)
```

Mademki `fit` metodu da aslında KMeans nesnesinin kendisine geri dönmektedir. O halde yukarıdaki işlem tek bir satırda şöyle de yapılabilirdi:

```
km = KMeans(n_clusters=2).fit(dataset)
```

Pekiye çözümün sonuçları nasıl elde edilecektir? İşte `fit` metodu sonuçları KMeans sınıfının çeşitli örnek özniteliklerine yerleştirmektedir. Bu örnek öznitelikleri ve tuttuğu değerler şunlardır:

labels_: Her noktanın atandığı küme numarasına ilişkin NumPy dizisidir. Küme numarası 0'dan başlatılmaktadır. KMeans sınıfı bize kümelerde hangi noktaların bulunduğu değil, noktaların hangi kümede olduğunu vermektedir. Tabii biz bu `labels_` örnek özniteliği sayesinde kümelerdeki elemanları aşağıdaki gibi kolay bir biçimde elde edebiliriz:

```
from sklearn.cluster import KMeans

km = KMeans(n_clusters=2)
km.fit(dataset)

print(km.labels_)

print('İlk grubun noktaları:')
print(dataset[km.labels_ == 0])

print('İkinci grubun noktaları:')
print(dataset[km.labels_ == 1])
```

Şöyledir bir çıktı elde edilmiştir:

```
[1 0 1 0 1 1 0 0 1 1 1 0]
```

ilk grubun noktaları:

```
[[2. 4.]  
 [3. 2.]  
 [3. 3.]  
 [1. 4.]  
 [2. 1.]]
```

ikinci grubun noktaları:

```
[[7. 8.]  
 [6. 4.]  
 [6. 5.]  
 [5. 7.]  
 [5. 4.]  
 [7. 7.]  
 [7. 6.]]
```

cluster_centers_: Nihai çözümdeki kümelerin ağırlık merkezlerine ilişkin NumPy dizisidir. Örneğin:

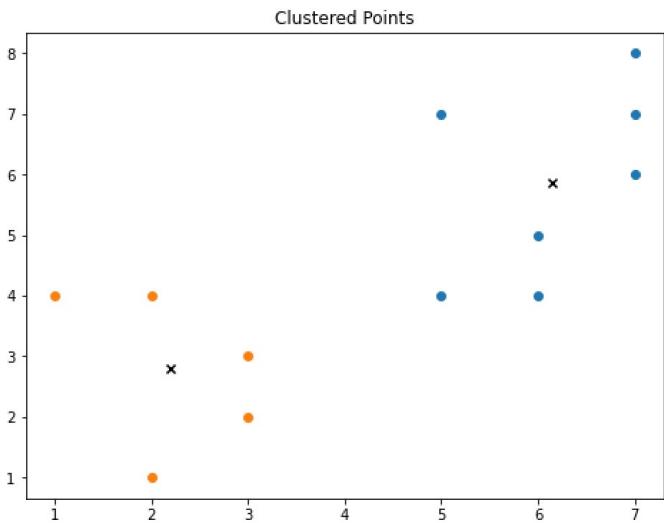
```
In [11]: km.cluster_centers_  
Out[11]:  
array([[2.2      ,  2.7999997],  
       [6.142857 ,  5.857143 ]], dtype=float32)
```

inertia_: Tüm noktaların kendi ağırlık merkezlerine uzaklıklarının karelerinin toplamını verir. Bu öznitelik tek elemandan oluşan toplam bir değer vermektedir. (Halbuki kendi yaptığımız örnekte kmeans fonksiyonun geri döndürdüğü inertia değerinin her kümenin kendi elemanlarına ilişkin inertia değeri olduğuna dikkat ediniz.)

n_iter_: En iyi çözümün bulunması için uygulanan yineleme sayısını belirtmektedir.

Şimdi de yukarıdaki noktalar için Scikit-learn KMeans sınıfı ile elde edilen çözümün saçılma grafiğini çizelim:

```
import numpy as np  
from sklearn.cluster import KMeans  
  
dataset = np.loadtxt('points.csv', delimiter=',', dtype=np.float32)  
km = KMeans(n_clusters=2)  
km.fit(dataset)  
  
import matplotlib.pyplot as plt  
  
plt.title('Clustered Points')  
figure = plt.gcf()  
figure.set_size_inches(8, 6)  
for i in range(2):  
    plt.scatter(dataset[km.labels_ == i, 0], dataset[km.labels_ == i, 1])  
  
plt.scatter(km.cluster_centers_[:, 0], km.cluster_centers_[:, 1], color='black', marker='x')  
plt.show()
```



KMeans sınıfının transform metodu bizden noktaları alır ve noktaların her ağırlık merkezine uzaklığına ilişkin bir matris verir. transform metodunun verdiği matrisin satır sayısı bizim metoda girdiğimiz noktaların sayısı kadar, sütun sayısı ise küme sayısı kadar olacaktır. Yukarıdaki örnekte noktaların ağırlık merkezlerine uzaklığını şöyle elde edebiliriz:

```
import numpy as np
from sklearn.cluster import KMeans

dataset = np.loadtxt('points.csv', delimiter=',', dtype=np.float32)
km = KMeans(n_clusters=2)
km.fit(dataset)
transformed_data = km.transform(dataset)

print(transformed_data)
```

Bu işlemden şöyle bir çıktı elde edilmiştir:

```
[[2.3079278  7.0767226 ]
 [4.540071   1.2165529 ]
 [1.8626293  3.9849718 ]
 [4.97545   1.1313707 ]
 [0.86896616 4.3908997 ]
 [1.616244   5.047772 ]
 [4.247448   0.82462114]
 [5.4679027  1.6970565 ]
 [2.1806197  3.0463095 ]
 [1.4285715  6.3780875 ]
 [0.86896616 5.7688823 ]
 [6.383972   1.8110768 ]]
```

Aslında fit işlemi ile transform işlemi fit_transform metoduyla bir arada da yapılabilmektedir. Örneğin:

```
km = KMeans(n_clusters=2)
transformed_data = km.fit_transform(dataset)
```

KMeans sınıfının predict isimli metodu yeni bir verinin sınıfını bize vermektedir. Örneğin:

```
predict_data = np.array([[2, 3], [12, 10]], dtype=np.float32)
predict_result = km.predict(predict_data)

print(predict_result)

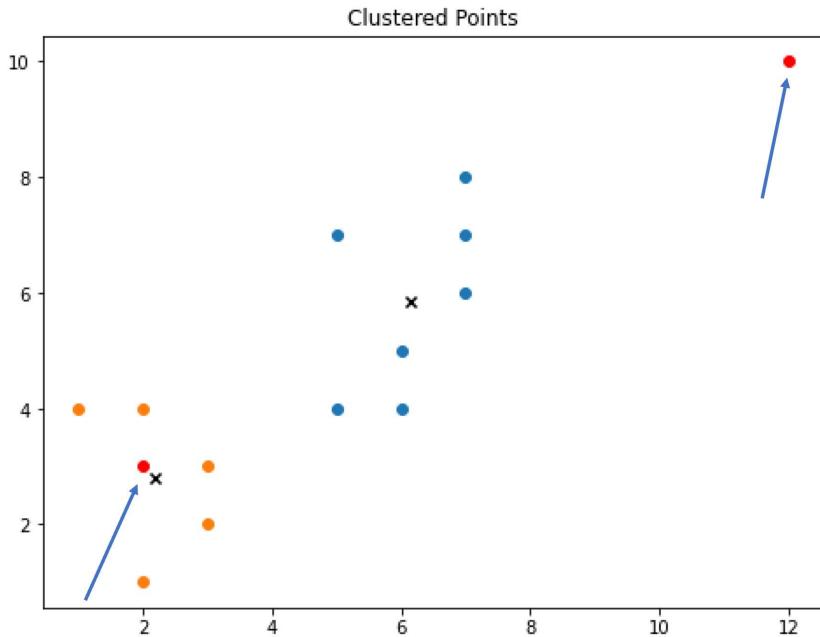
plt.title('Clustered Points')
```

```

figure = plt.gcf()
figure.set_size_inches((8, 6))
for i in range(2):
    plt.scatter(dataset[km.labels_ == i, 0], dataset[km.labels_ == i, 1])

plt.scatter(km.cluster_centers_[:, 0], km.cluster_centers_[:, 1], color='black', marker='x')
plt.scatter(predict_data[:, 0], predict_data[:, 1], color='red')
plt.show()

```



Oluşturduğumuz örnek iki noktanın kestiriminde şu sonuç elde edilmiştir:

[1 0]

Burada mavi 0 numaralı küme, kavuniçi 1 numaralı kümedir.

K-Means Kümeleme Yönteminde Özelliğ Ölçeklemesinin Önemi

K-Means kümeleme yönteminde eğer sütunlardaki değerlerin skalaları birbirlerinden farklıysa noktalar arasındaki Öklit uzaklıklar hesaplanırken skalası büyük olan sütunlardaki etki skalası küçük olan sütunlara göre yüksek olacaktır. Bu da kümelemenin yanlış oluşturulmasına yol açabilecektir. Örneğin sütunlardan birisi üç basamaklı değerlerden diğeri de tek basamaklı değerlerden oluşuyor olsun. Uzaklık hesabında üç basamaklı değerlere ilişkin sütun çok baskın hale gelecektir değil mi? İşte bu tür durumlarda sütunlardaki değerlerin skala bakımından birbirlerine yaklaştırılması için özellik ölçeklemesi gerekmektedir. Daha önceden de belirttiğimiz gibi bu tür durumlarda eğer sütun özellikleri normal dağılıyorsa standart ölçeklendirme değilse min-max ölçeklemesi tercih edilebilmektedir.

K-Means Yönteminin Zambak (Iris-Plant) Veri Kümesine Uygulanması

Zambak (Iris) resimleri sınıflandırma için eğitim amacıyla en fazla kullanılan veri kümelerinden biridir. Zambak veri kümesini aşağıdaki adresten indirebilirsiniz:

<https://www.kaggle.com/uciml/iris>

Veri tablosunda zambak resimleri alınarak bunların aşağıdaki özellikleri sayısal biçimde kodlanmıştır:

- Çanak yaprakların santimetre cinsinden uzunluğu
- Çanak yaprakların santimetre cinsinden genişliği
- Taç yaprakların santimetre cinsinden uzunluğu
- Taç yaprakların santimetre cinsinden genişliği

Bu verilerden hareketle zambaklar üç sınıfa ayrılmaktadır: Iris Setosa, Iris Versicolor ve Iris Virginica. Zambak veri kümesi 150 zambak bilgisinden oluşmaktadır. Her zambak için onun bulunduğu sınıf da veri tablosunda yer almaktadır (yani bu tablo eğitimli ağlarda da kullanılabilmektedir). Ancak biz burada K-Means yöntemini kullanarak eğitsiz biçimde kümeleme yapacağız.

Zambak veri tablosu bir CSV dosyası biçiminde indirilebilir. Dosyanın görünümü aşağıdaki gibidir:

```
5.1,3.5,1.4,0.2,Iris-setosa  
4.9,3.0,1.4,0.2,Iris-setosa  
4.7,3.2,1.3,0.2,Iris-setosa  
4.6,3.1,1.5,0.2,Iris-setosa  
5.0,3.6,1.4,0.2,Iris-setosa  
5.4,3.9,1.7,0.4,Iris-setosa  
4.6,3.4,1.4,0.3,Iris-setosa  
5.0,3.4,1.5,0.2,Iris-setosa  
4.4,2.9,1.4,0.2,Iris-setosa  
4.9,3.1,1.5,0.1,Iris-setosa  
5.4,3.7,1.5,0.2,Iris-setosa  
.....
```

Bu dosyadan hareketle veri kümesini dataset_x ve dataset_y biçiminde aşağıdaki gibi ikiye ayıralırız:

```
import pandas as pd  
  
df = pd.read_csv('iris.csv')  
  
dataset_x = df.iloc[:, :-1].to_numpy()  
  
from sklearn.preprocessing import LabelEncoder  
  
le = LabelEncoder()  
dataset_y = le.fit_transform(df.iloc[:, 4])
```

Aslında Keras ve Scikit-learn paketlerinde bu zambak verilerini bu biçimde bize veren sınıflar ve fonksiyonlar zaten bulunmaktadır. Yani benzer işlemleri Scikit-learn'de şöyle de yapabiliyoruz:

```
from sklearn.datasets import load_iris  
  
iris = load_iris()  
  
dataset_x = iris.data  
dataset_y = iris.target
```

Biz burada verileri dataset_x ve dataset_y biçiminde iki gruba ayırdık. Ancak tabii hedefimiz bir eğitim uygulamak değildir. dataset_y'yi biz kümelemenin başarısını test etmek için ayrıca kullanacağız.

Şimdi veriler üzerinde min-max ölçeklendirmesi yapalım:

```
from sklearn.preprocessing import MinMaxScaler  
  
mms = MinMaxScaler()  
mms.fit(dataset_x)  
scaled_dataset_x = mms.transform(dataset_x)
```

Şimdi de KMeans sınıfını kullanarak bu verileri üç kümeye ayıralım:

```
from sklearn.cluster import KMeans  
  
km = KMeans(n_clusters=3)
```

```

km.fit(scaled_dataset_x)

print(km.labels_)

for i in range(3):
    cluster = dataset_x[km.labels_ == i]
    print('-----')
    print(f'Cluster-{i}')
    print('-----')
    print(cluster)

```

Veri kümemizdeki özellik sayısı 4 olduğu için noktaları kartezyen koordinat sisteminde gösteremiyoruz. Ancak sütunları "PCA (Principle Component Analysis)" işlemi ile 2'ye indirgerek böyle bir grafiği çizebiliriz. Sütun indirgemeleri kursumuzda ilerideki bölümlerde ele alınmaktadır. Ancak burada biz henüz görmemiş olsak da sütun indirgemesi uygulayacağız:

```

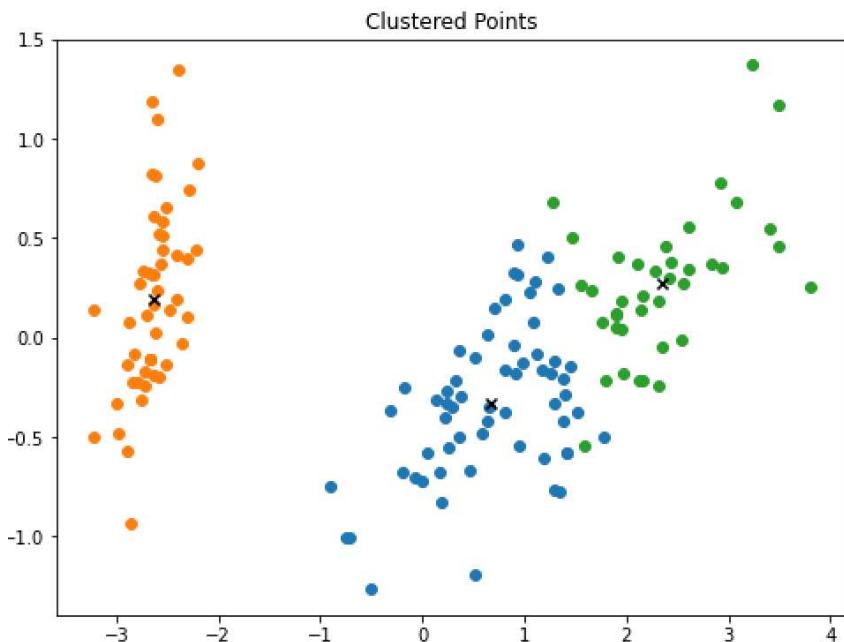
pca = PCA(n_components=2)
reduced_dataset_x = pca.fit_transform(dataset_x)

import matplotlib.pyplot as plt

plt.title('Clustered Points')
figure = plt.gcf()
figure.set_size_inches((8, 6))
for i in range(3):
    plt.scatter(reduced_dataset_x[km.labels_ == i, 0], reduced_dataset_x[km.labels_ == i, 1])
plt.scatter(reduced_centroids[:, 0], reduced_centroids[:, 1], color='black', marker='x')
plt.show()

```

Şöyledir bir grafik elde edilmiştir:



Şimdi de bir zambak bilgisi uydurup onun hangi sınıfa ilişkin olabileceğini kestirelim:

```

import numpy as np

predict_data = np.array([[4.9, 3.1, 1.5, 0.2]])
predict_data = mms.transform(predict_data)
predict_result = km.predict(predict_data)

```

```
print(predict_result[0])
```

Buradan şu sonuç elde edilmiştir:

1

Tabii burada bize predict ile verilen yalnızca bir küme numarasıdır. Hangi küme numarasının hangi zambak çeşidine karşılık geldiğini algoritma bilemez. Bunu bizim belirlememiz gerekir. Başka bir deyişle K-Means algoritması sayısal bilgilere göre kümelenme yapmaktadır. O kümelerin ne anlam ifade ettiği hakkında bize bir bilgi vermemeektedir.

Bazen uygulamacılar fit işlemi sonrasında labels_ özniteligine bakmak yerine doğrudan asıl veri kümesiyle predict işlemi de yapabilmektedir. Örneğin:

```
labels = km.fit(dataset_x).predict(dataset_x)
```

Burada result ile elde edilen sonuç zaten labels_ özniteliği ile de alınmaktadır. fit metodunun KMeans nesnesinin kendisine geri döndüğünü anımsayınız.

Pekiyi mademki zambakların gerçek sınıfları (`dataset_y`) elimizde var. O halde biz K-Means algoritmasından elde ettiğimiz sonucun başarısını test edebiliriz. Ancak burada KMeans sınıfı ile elde ettiğimiz sınıf numaralarının `dataset_y`'deki sınıf numaralarıyla aynı olmayabileceğine dikkat etmek gereklidir. Bu nedenle önce gözle inceleyerek bu sınıf numaralarını dönüştürmek zorunda kalabiliriz. Aşağıda `km.labels_` ile kümelenen zambaklarla onların gerçek kümeleri ekrana yazdırılmıştır:

In [14]: dataset v

In [14]:

In [15]: km.labels_

Out[15]:

Burada gördüğünüz gibi aslında 0 numaralı küme bizde 1 numaralı olarak, 1 numaralı küme bizde 2 numaralı olarak, 2 numaralı küme ise bizde 0 numaralı olarak bulunmaktadır. Şimdi bunları dönüştürüp kümelenmenin performansını değerlendirelim:

```
converted_labels = np.zeros(dataset_y.shape)
converted_labels[km.labels_ == 2] = 1
converted_labels[km.labels_ == 0] = 2

performance_ratio = np.mean(converted_labels == dataset_y)
print(performance_ratio)
```

Burada 0.886 gibi bir oran elde edilmektedir. Yani bu örneğimizde zambakların %88.6'sı doğru bir biçimde kümelere ayrılmıştır. Burada elde edilen küme numaralarının dolayısıyla da yapılan dönüştürmenin programın her çalıştırılmasında farklı olabileceğine dikkat ediniz.

Yukarıdaki kodun tamamını aşağıda veriyoruz. (Ancak performans kısmını koda dahil etmiyoruz. Çünkü bu kısmı siz gözle bakarak o anki çalışmaya göre oluşturmanız gereklidir):

```
import pandas as pd

df = pd.read_csv('iris.csv')

dataset_x = df.iloc[:, :-1].to_numpy()

from sklearn.preprocessing import LabelEncoder

le = LabelEncoder()
dataset_y = le.fit_transform(df.iloc[:, 4])

from sklearn.preprocessing import MinMaxScaler

mms = MinMaxScaler()
mms.fit(dataset_x)
scaled_dataset_x = mms.transform(dataset_x)

from sklearn.cluster import KMeans

km = KMeans(n_clusters=3)
km.fit(scaled_dataset_x)

print(km.labels_)

for i in range(3):
    cluster = dataset_x[km.labels_ == i]
    print('-----')
    print(f'Cluster-{i}')
    print('-----')
    print(cluster)

from sklearn.decomposition import PCA

pca = PCA(n_components=2)
reduced_dataset_x = pca.fit_transform(dataset_x)

import matplotlib.pyplot as plt

plt.title('Clustered Points')
figure = plt.gcf()
figure.set_size_inches((8, 6))
for i in range(3):
    plt.scatter(reduced_dataset_x[km.labels_ == i, 0], reduced_dataset_x[km.labels_ == i, 1])

plt.show()

import numpy as np

predict_data = np.array([[4.9, 3.1, 1.5, 0.2]])
predict_data = mms.transform(predict_data)
predict_result = km.predict(predict_data)

print(predict_result[0])
```

K-Means Kümeleme Yönteminin MNIST Veri Kümesine Uygulanması

Şimdi de rakamları sınıflandırmak için kullandığımız MNIST veri kümesini K-Means kümeleme yöntemine uygulayalım. Önce MNIST verilerini yükleyip min-max ölçeklendirmesi yapalım:

```
from tensorflow.keras.datasets import mnist

(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) = mnist.load_data()

training_dataset_x = training_dataset_x.reshape(-1, 28 * 28)
training_dataset_x = training_dataset_x / 255
test_dataset_x = training_dataset_x.reshape(-1, 28 * 28)
test_dataset_x = test_dataset_x / 255
```

Şimdi KMeans işlemini uygulayalım:

```
from sklearn.cluster import KMeans

km = KMeans(n_clusters=10)
km.fit(training_dataset_x)

print(km.labels_)
```

Şimdi her sınıfın rastgele 9 tane resmi çizdirelim:

```
import matplotlib.pyplot as plt
import numpy as np

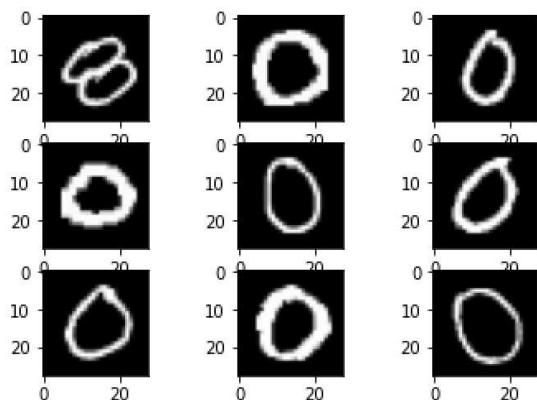
for i in range(10):
    random_indices, = np.where(km.labels_ == i)
    random_images = training_dataset_x[np.random.choice(random_indices, 9)]

    print('-----')
    print(f'Cluster {i}')
    print('-----')

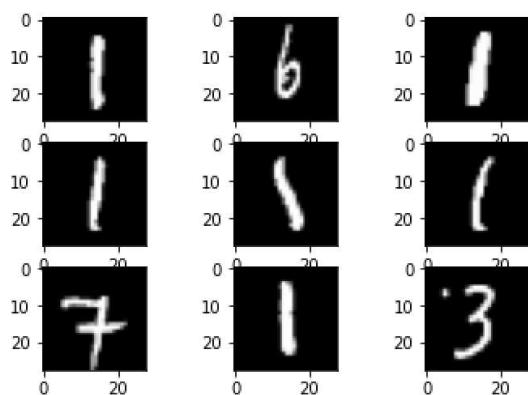
    for k in range(9):
        plt.subplot(3, 3, k + 1)
        plt.imshow(random_images[k].reshape(28, 28), cmap='gray')
    plt.show()
```

Bu sınıfların bazıları şöyledir:

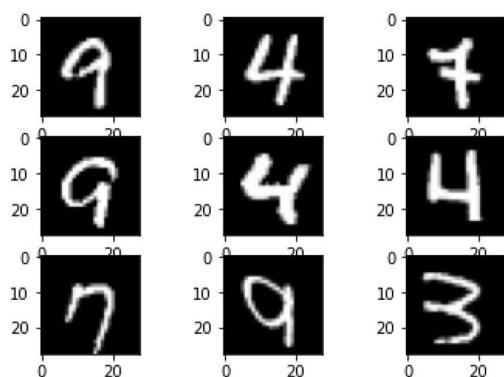
Cluster 2



Cluster 5



Cluster 6



MNIST veri kümesi için yapay sinir ağları ile yapılan sınıflandırmanın K-Means ile yapılan kümelendirmeden oldukça iyi olduğu bu sonuçlardan da görülmektedir.

Kümelemede Uygun Küme Sayısının İşin Başında Tahmin Edilmesi

Biz K-Means yöntemini kullanırken verileri işin başında kaç kümeye ayıracagımızı biliyor olmamız gerekmektedir. Aslında bu bilgi bazen problemin kendisinde bulunmaktadır. Örneğin birtakım meye fotoğrafları olabilir. Bu fotoğraftaki meyveleri gruplandırmak isteyebiliriz. İşte eğer fotoğraflarda toplam kaç çeşit meye olduğunu zaten biliyorsak küme sayısını da biliyoruz demektir. Peki ya resimlerde toplamda kaç çeşit meye olduğunu bilmiyorsak? İşte bu tür durumlarda K-Means yöntemini kullanmadan önce verileri inceleyerek toplam kaç kümeyi söylemenin söz konusu olacağına ilişkin bir çıkarımın yapılması gerekecektir.

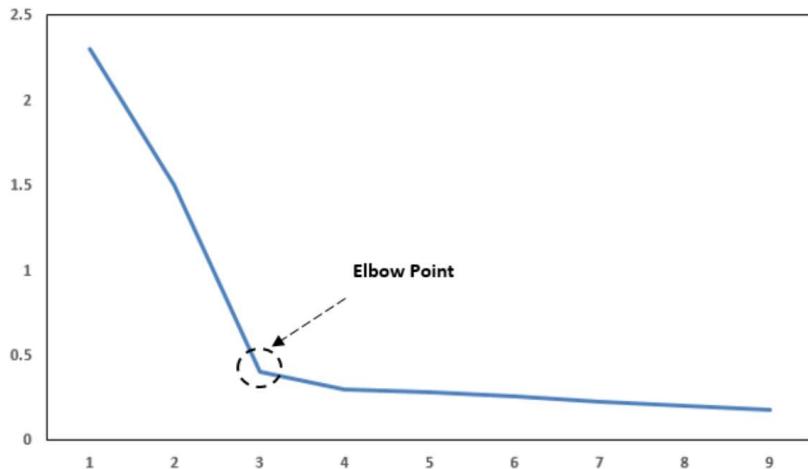
K-Means yönteminde işin başında küme sayısının bulunması temelde iki yöntemle yapılmaktadır:

- 1) Dirsek (Elbow) Yöntemi
- 2) Silhouette Yöntemi

Her iki yöntemde de biz deneysel olarak küme sayılarını 1'den belli bir sayıya kadar oluşturarak kümelemeyi yaparız. Sonra birtakım değerleri karşılaştırarak en uygun küme sayısını belirleriz.

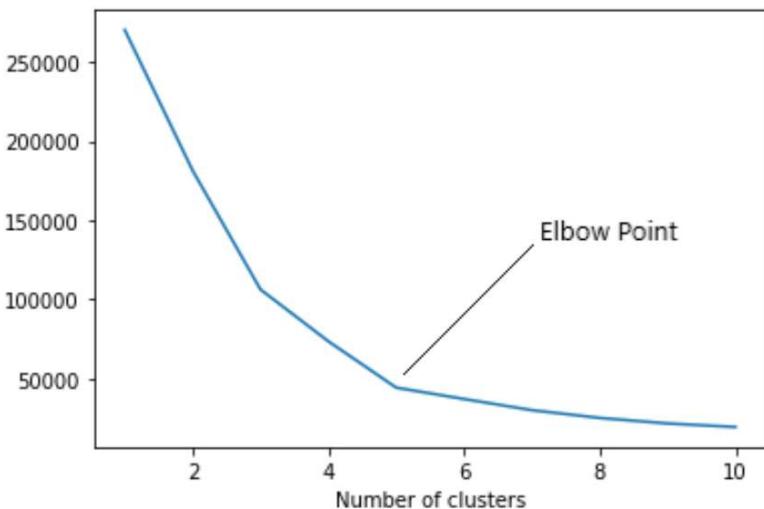
Dirsek yönteminde her kümedeki elemanın kendi kümelerinin ağırlık merkezlerine uzaklıklarının karelerinin toplamı hesaplanır. (Buna "atalet (inertia)" denildiğini anımsayınız.) Sonra bu toplam uzaklıkların grafiği çizilir. Bu grafikte

eğim düşümlerinin azaldığı yere ilişkin olan küme sayısı (bu dirseğin bulunduğu yerdır) en iyi küme sayısı olarak seçilir. Bu yöntem görsel biçimde karar vermeye dayalıdır. Aşağıda örnek dirsek grafiğini inceleyiniz:



Alıntı Notu: GörSEL <https://www.oreilly.com/library/view/statistics-for-machine/9781788295758/c71ea970-0f3c-4973-8d3ab09a7a6553c1.xhtml> adresinden alınmıştır.

Burada dirsek noktası 3'tür. Aşağıdaki dirsek grafiğinde dirsek noktası 5'tir.



Alıntı Notu: GörSEL <https://www.analyticsvidhya.com/blog/2021/01/in-depth-intuition-of-k-means-clustering-algorithm-in-machine-learning/> adresinden alınmıştır.

Grafiklerden de görüldüğü gibi dirsek noktası eğrinin kırılıp yataylaşmaya başladığı noktadır. Şimdi biz ilk örneğimizdeki noktalardan küme sayısını tahmin etmek için dirsek yöntemini kullanalım. Noktalarımız şöyleydi:

```
import numpy as np

dataset = np.loadtxt('points.csv', delimiter=',', dtype=np.float32)

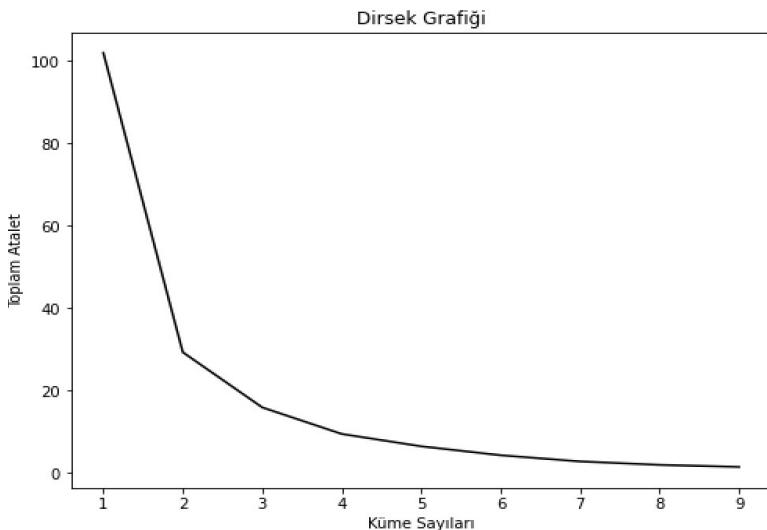
from sklearn.cluster import KMeans

total_inertias = [KMeans(n_clusters=i).fit(dataset).inertia_ for i in range(1, 10)]

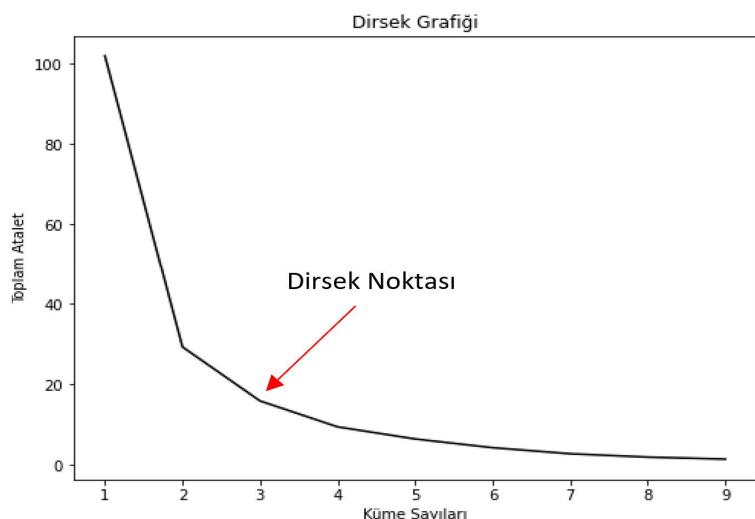
import matplotlib.pyplot as plt

plt.title('Dirsek Grafiği')
figure = plt.gcf()
figure.set_size_inches((8, 6))
plt.xlabel('Küme Sayıları')
plt.ylabel('Toplam Atalet')
```

```
plt.plot(range(1, 10), total_inertias, c='black')
plt.show()
```



Bu grafiğe baktığımızda yataya geçme eğiliminin 3'ten başladığı görülmektedir. Yani grafikteki eğrinin kırılma noktası 3 gibi gözükmektedir. O halde dirsek yöntemine göre bu noktalar üç kümeye ayrılmalıdır.



Şimdi noktaları üç kümeye ayırarak çözümü yeniden bulalım:

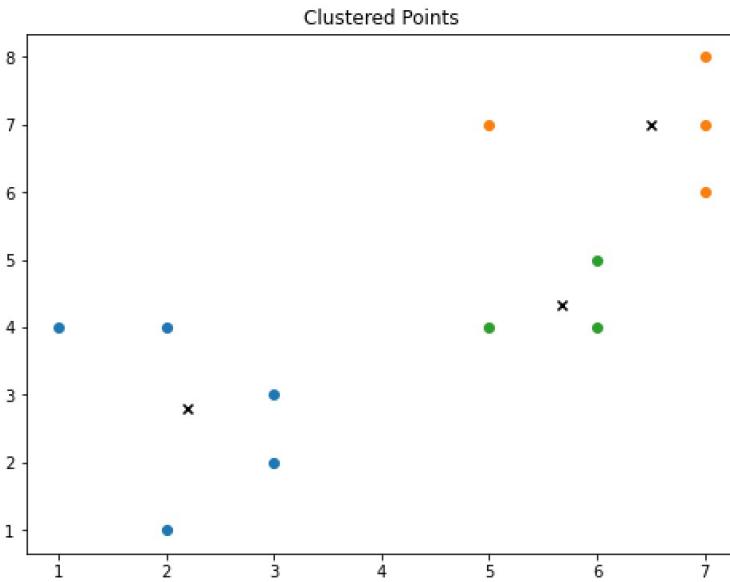
```
import numpy as np
from sklearn.cluster import KMeans

dataset = np.loadtxt('points.csv', delimiter=',', dtype=np.float32)
km = KMeans(n_clusters=3)
km.fit(dataset)

import matplotlib.pyplot as plt

plt.title('Clustered Points')
figure = plt.gcf()
figure.set_size_inches((8, 6))
for i in range(3):
    plt.scatter(dataset[km.labels_ == i, 0], dataset[km.labels_ == i, 1])

plt.scatter(km.cluster_centers_[:, 0], km.cluster_centers_[:, 1], color='black', marker='x')
plt.show()
```



Şimdi de zambak verileri için dirsek noktası grafiğini çizelim:

```

import pandas as pd

df = pd.read_csv('iris.csv')

dataset_x = df.iloc[:, :-1].to_numpy()

from sklearn.preprocessing import LabelEncoder

le = LabelEncoder()
dataset_y = le.fit_transform(df.iloc[:, 4])

from sklearn.preprocessing import MinMaxScaler

mms = MinMaxScaler()
mms.fit(dataset_x)
scaled_dataset_x = mms.transform(dataset_x)

from sklearn.cluster import KMeans

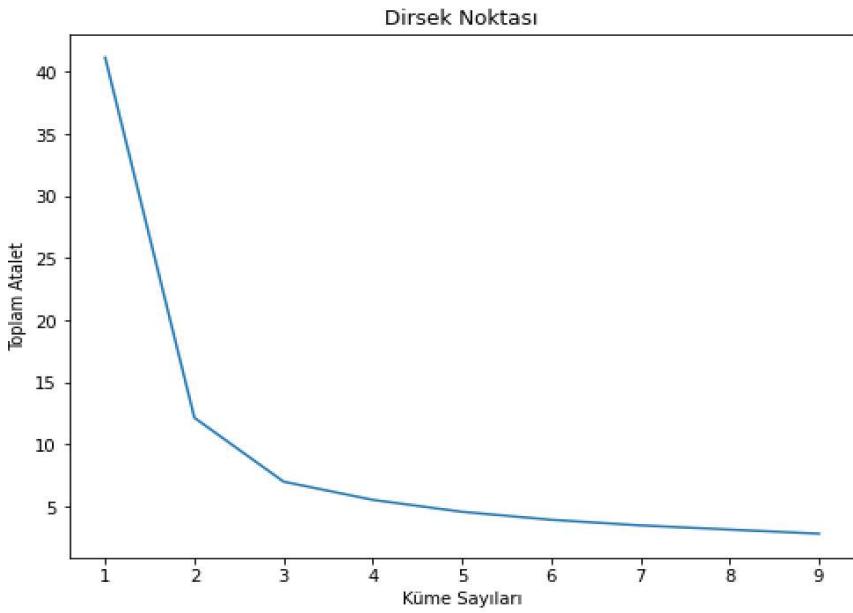
total_inertias = [KMeans(n_clusters= i).fit(scaled_dataset_x).inertia_ for i in range(1, 10)]

import matplotlib.pyplot as plt

plt.title('Dirsek Noktası')
plt.xlabel('Küme Sayıları')
plt.ylabel('Toplam Atalet')
figure = plt.gcf()
figure.set_size_inches((8, 6))
plt.plot(range(1, 10), total_inertias)
plt.show()

```

Şöyledir bir grafik elde edilmiştir:



Grafikten de görüldüğü gibi eğrinin yataya geçtiği küme sayısı 3'tür.

Silhouette yöntemi nümerik bir yöntemdir. Yöntemin ayrıntılarını burada ele almayacağımız. Scikit-learn kütüphanesinin `sklearn.metrics` modülünde bu yöntemi uygulayan `silhouette_score` isimli hazır bir fonksiyon bulunmaktadır. Silhouette yönteminde kümeler için tek tek "silhouette score" değerleri bulunur. Bu değerin en yüksek olduğu küme sayısından 1 fazlası nihai küme sayısı olarak tespit edilir. Yukarıdaki "point.csv" dosyasındaki veriler için en uygun küme sayısını bu kez Silhouette yöntemiyle bulmaya çalışalım:

```
import numpy as np

dataset = np.loadtxt('points.csv', delimiter=',', dtype=np.float32)

from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score

kms = [KMeans(n_clusters=i).fit(dataset) for i in range(2, 10)]
sscores = [silhouette_score(dataset, km.labels_) for km in kms]

for i, sscore in enumerate(sscores, 2):
    print(f'{i}---->{sscore}')
print(np.argmax(sscores) + 2 + 1)
```

Elde edilen çıktı şöyledir:

```
2---->0.5544097423553467
3---->0.47607627511024475
4---->0.4601795971393585
5---->0.4254012405872345
6---->0.3836685121059418
7---->0.29372671246528625
8---->0.21625618636608124
9---->0.114889957010746
3
```

Görüldüğü gibi burada 2 kümeli çözümdeki silhouette değeri en yüksektir (0.5544). O halde en uygun küme sayısı bu değerden bir fazla yani 3 olacaktır. Yukarıdaki örnekte de gördüğünüz gibi küme sayıları 2'den başlatılmıştır. 1 küme için silhouette değeri söz konusu olmamaktadır.

Zambak örneği için de Silhouette değeri şöyle hesaplanabilir:

```

import pandas as pd

df = pd.read_csv('iris.csv')

dataset_x = df.iloc[:, :-1].to_numpy()

from sklearn.preprocessing import LabelEncoder

le = LabelEncoder()
dataset_y = le.fit_transform(df.iloc[:, 4])

from sklearn.preprocessing import MinMaxScaler

mms = MinMaxScaler()
mms.fit(dataset_x)
scaled_dataset_x = mms.transform(dataset_x)

from sklearn.cluster import KMeans

kms = [KMeans(n_clusters=i).fit(scaled_dataset_x) for i in range(2, 10)]
sscores = [silhouette_score(scaled_dataset_x, km.labels_) for km in kms]

for i, sscore in enumerate(sscores, 2):
    print(f'{i}---->{sscore}')
print(np.argmax(sscores) + 2 + 1)

```

Bu örnekte 2'den başlayarak 10'a kadar tek tek küme sayıları için silhouette_score değerleri hesaplanmıştır. Değerler şu biçimdedir:

```

2---->0.6294675561906644
3---->0.5043188549150884
4---->0.4446273300650682
5---->0.351912893247111
6---->0.3503813557935231
7---->0.3454247860838419
8---->0.33179775523346855
9---->0.309906255181826
3

```

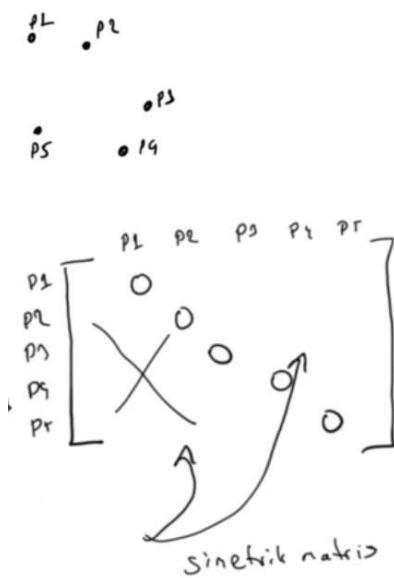
Bu değerler içerisindeki en yüksek değer 2 kümeli değerdir. Bundan bir fazla küme sayısı 3'tür. Bu durumda 3 en iyi küme sayısı olacak belirlenecektir.

Hiyerarşik Kümeleme (Hierachical Clustering) Yöntemleri

K-Means kümeleme yönteminin yanı sıra daha pek çok kümeleme yöntemi de vardır. Bazı yöntemler bazı yöntemlerin biraz değiştirilmiş ve özel durumlara göre genişletilmiş biçimleridir. Hiyerarşik kümeleme yöntemleri grup olarak özgün bir yöntem grubudur. Hiyerarşik kümeleme yöntemleri de kendi aralarında "agglomerative" ve "divisive" olmak üzere ikiye ayrılmaktadır. Agglomerative yöntemler türmevarımsal yani aşağıdan yukarıya (bottom-up), divisive yöntemler ise tümdeğelimsel yani yukarıdan aşağıya (top-down) yöntemlerdir. Uygulamada daha çok agglomerative yöntemler tercih edilmektedir. Agglomerative hiyerarşik kümeleme algoritmasının tipik biçimlerinden biri şöyledir:

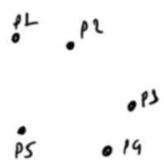
- 1)** Önce her nokta ayrı bir küme varsayılarak işleme başlanır.
- 2)** Sonra her noktanın her noktadan uzaklığı (distance) hesaplanır. Uzaklık hesaplamada çeşitli yöntemler ve metrikler kullanılabilir. Burada yöntem uzaklık hesaplamasının neye dayalı olarak yapılacağını belirtir. Metrik ise hesaplama biçimini belirtmektedir. Örneğin "öklit uzaklığı" bir yöntem değil metriktir. Ancak hesaplamada iki kümenin en yakın noktalarını kullanmak bir yöntemdir. Başka bir deyişle "yöntem birden fazla noktanın tek nokta olarak ifade edilmesiyle, metrik ise iki noktanın uzaklığının hesaplanması biçimile" ilgilidir. İleride ele alınacağı gibi

uzaklık hesaplamada çeşitli yöntemler tercih edilebilmektedir. Bu adımın sonunda bir uzaklık matrisi elde edilir. Örneğin 5 nokta söz konusu olsun. Uzaklık matrisi şöyle bir yapıda olacaktır:



3) Uzaklık matrisinde en yakın iki nokta bulunur ve bu iki nokta yeni bir küme oluşturacak biçimde birleştirilir. Sonra yeniden tüm uzaklıklar yeni duruma göre hesaplanır. İşlemler bu biçimde devam ettirilir. Her yinelemede bir eleman diğer bir küme ile birleştirilecektir. Bu işlem arzu edilen küme sayısına gelinene kadar devam ettirilir.

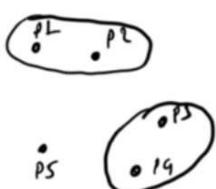
Örneğin işin başında aşağıdaki gibi 5 nokta olsun:



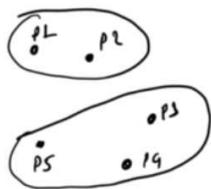
Burada tüm noktalar arasındaki uzaklıklar hesaplandığında P1 ile P2'nin en yakın noktalar olduğunu varsayıyalım. Bu durumda bu iki noktayı tek bir küme olarak birleştiririz.



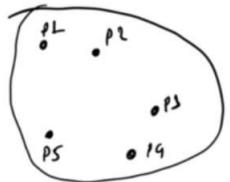
Artık burada 4 küme vardır. Bu 4 kümenin birbirlerine uzaklıği hesaplanarak yeni bir uzaklık matrisi oluşturulur. Buradaki sorunlardan biri birden fazla noktadan oluşan kümeler için uzaklık yerinin neresi alınacağıdır. İşte bunun için izleyen kısımda açıklayacak olduğumuz birkaç yöntem kullanılmaktadır. Örneğin bu kümelerin en yakın noktalarının kullanılması yöntemlerden biridir. Bu haliyle yukarıdaki örnekte en yakın iki nokta P3 ve P4 noktalarıdır. O halde bu noktalar da birleştirilir:



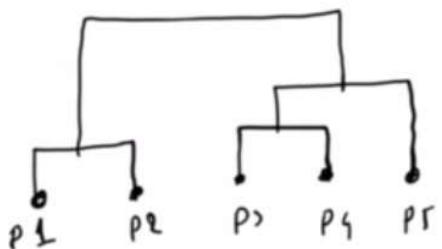
Bu yeni durumda P5 ile {P3, P4} kümelerinin mesafelerinin en yakın olduğunu varsayıyalım. O halde bunlardan yeni bir küme yapılacaktır:



Artık burada iki tane kume kalmıştır. Bu aşamada onlar da birleştirilir:



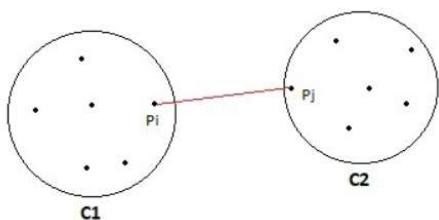
Hangi kümelerin hangi kümelerle birleştirildiğini gösteren grafiğe "dendrogram" denilmektedir. Yukarıdaki birleştirmenin örnek dendrogram'ı şöyledir:



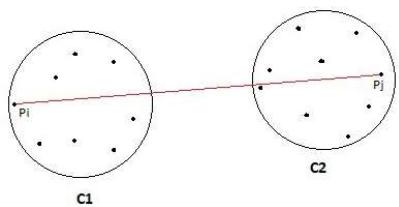
Divisive yöntemlerde işlemler tersten yapılmaktadır. Yani işin başında sanki tek bir kume varmış gibi başlanır. Sonra her defasında bu kümelenin ayrılmaları yapılır. Başka bir deyişle agglomerative yöntemler tümevarımsal (bottom-up), divisive yöntemler ise tümdeğelimisel (top-down) biçimdedir. Makine öğrenmesi bağlamında agglomerative yöntemler divisive yöntemlere göre çok daha yoğun kullanılmaktadır.

Şimdi birden fazla noktadan oluşan kümeler için uzaklık hesaplamasında kullanılan yöntemler üzerinde duralım. Burada dört yöntem tanıtacağız:

Min Yöntemi: Burada uzaklık olarak iki kümeyi en yakın iki noktası arasındaki uzaklık alınır. Örneğin:



Max Yöntemi: Burada uzaklık olarak iki kümeyi en uzak iki elemanı arasındaki uzaklık alınır.



Grup Ortalaması Yöntemi: Bu yöntemde iki kümenin tüm iki noktalarının uzaklıklarının ortalaması alınır. Örneğin kümelerden birinin 10 noktası diğerinin 5 noktası olsun. Mümkün uzaklıkların sayısı $10 * 5 = 50$ 'dir. Bu 50 uzaklık toplanıp 50'ye bölünür.

Ward Yöntemi: Bu yöntem grup ortalaması yönteminin çok benzeridir. Tek farkı noktalar arasındaki uzaklıkların karelerinin ortalamasının alınmasıdır. Uygulamaların çoğu default olarak bu yöntem tercih edilmektedir.

Agglomerative yöntemler tipik olarak $O(n^3)$ karmaşıklıktadır. Çünkü her nokta ile her nokta arasında uzaklık hesaplamaları iç içe iki döngü ile ve gruplar arası ortalama uzaklıklar da bir iç döngüyle yapılmaktadır. Bu karmaşıklık agglomerative yöntemlerin çok sayıda nokta için yavaş bir yöntem olduğu anlamına gelir. Ancak agglomerative yöntemlerin SLINK ve CLINK denilen varyasyonları karmaşıklığı $O(n^2)$ ye düşürmektedir. Uygulamada genellikle SLINK ve CLINK algoritmaları tercih edilmektedir.

Hiyerarşik Kümeleme Yönteminin Scikit-learn Kütüphanesi İle Gerçekleştirilmesi

Hiyerarşik kümeleme için scikit-learn içerisindeki sklearn.cluster modülünde bulunan AgglomerativeClustering isimli sınıf kullanılmaktadır. Sınıfın `__init__` metodunun parametrik yapısı şöyledir:

```
sklearn.cluster.AgglomerativeClustering(n_clusters=2, affinity='euclidean', memory=None, connectivity=None, compute_full_tree='auto', linkage='ward', pooling_func='deprecated', distance_threshold=None)
```

Fonksiyonun `n_clusters` parametresi ayrıacak küme sayısını, `linkage` parametresi kullanılacak yöntemi belirtir. Bunun default olarak 'ward' olduğuna dikkat ediniz. `affinity` parametresi kullanılacak metriki belirtmektedir. Bu parametre de default olarak 'euclidean' biçimindedir. Fonksiyon bize bir sınıf nesnesi verir. Buradan alınan nesneye tıpkı KMeans sınıfında olduğu gibi fit metodunu çağırılır. Benzer biçimde yine kümeler sınıfın `labels_` isimli özniteligidenden elde edilmektedir. Şimdi yukarıdaki "points.csv" örneğini üç sınıf için AgglomerativeClustering sınıfını kullanarak çözelim:

```
import numpy as np

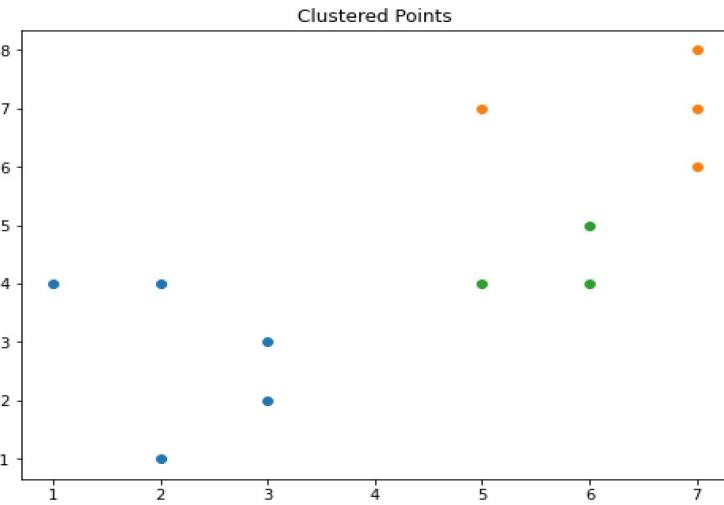
dataset = np.loadtxt('points.csv', delimiter=',', dtype=np.float32)

from sklearn.cluster import AgglomerativeClustering

ac = AgglomerativeClustering(n_clusters=3)
ac.fit(dataset)

import matplotlib.pyplot as plt

plt.title('Clustered Points')
figure = plt.gcf()
figure.set_size_inches(8, 6)
for i in range(3):
    plt.scatter(dataset[ac.labels_ == i, 0], dataset[ac.labels_ == i, 1])
plt.show()
```



AgglomerativeClustering sınıfının clusters_centers_ biçiminde bir örnek özniteliği yoktur. Çünkü hiyerarşik kümelemede ağırlık merkezi (centroid) kullanılmamaktadır. Benzer biçimde yine bu sınıfın predict metodu da yoktur. Çünkü hiyerarşik kümelemede bu anlamda bir kestirim yapılamaz. Yeni bir nokta için tüm işlemlerin baştan başlatılması gerekmektedir. AgglomerativeClustering sınıfının fit_predict isimli bir metodu varsa da bu metot fit işlemi yapıp nesnenin labels_ örnek özniteliği ile geri dönmektedir.

Şimdi de Zambak örneğini hem K-Means yöntemi ile hem de hiyerarşik yöntemle çözüp sonuçları kontrol edelim.

```
from sklearn.datasets import load_iris

iris = load_iris()
dataset_x = iris.data
dataset_y = iris.target

from sklearn.preprocessing import MinMaxScaler

mms = MinMaxScaler()
scaled_dataset_x = mms.fit_transform(dataset_x)

from sklearn.cluster import KMeans, AgglomerativeClustering

km = KMeans(n_clusters=3)
km.fit(scaled_dataset_x)

ac = AgglomerativeClustering(n_clusters=3)
ac.fit(scaled_dataset_x)

print(dataset_y)
print(km.labels_)
print(ac.labels_)
```

Şu sonuçlar elde edilmiştir:

Şimdi kümeleri gözle kontrol edip küme numaralarını dataset_y değerlerini referans alarak düzeltelim. Tabii bu örneği yaparken siz düzeltmeleri kendi kümelerinize göre yapmalısınız:

```
km_labels = [{0: 2, 1: 0, 2: 1}[label] for label in km.labels_]
ac_labels = [{0: 1, 1: 0, 2: 2}[label] for label in ac.labels_]

import numpy as np

km_success_ratio = np.mean(km_labels == dataset_y)
ac_success_ratio = np.mean(ac_labels == dataset_y)

print(f'KMeans success ratio: {km_success_ratio}')
print(f'Agglomerative success ratio: {ac_success_ratio}')

identical_ratio = np.mean(km.labels_ == ac.labels_)
print(f'Identical ratio: {identical_ratio}'
```

Şu sonuçlar elde edilmiştir:

```
KMeans success ratio: 0.8866666666666667
Agglomerative success ratio: 0.8866666666666667
Identical ratio: 0.3733333333333335
```

Göründüğü gibi zambak veri kümesinde K-Means yöntemi ile Agglomerative hiyerarşik yöntem aynı başarı yüzdesine sahip bulunmaktadır. Tabii bu yöntemlerin değişik veri kümelerindeki başarı yüzdeleri birbirinden farklı olabilmektedir.

Hiyerarşik Agglomerative Yöntemde Dendrogram Çizilmesi

Anımsanacağı gibi dendrogram hiyerarşik agglomerative kümelemede hangi noktaların hangi noktalarla birleştirildiğini gösteren bir ağaç grafiğidi. Dendrogram denilen ağaç grafiğinin oluşturulması için SciPy kütüphanesinde scipy.cluster.hierarchy modülünde dendrogram isimli bir fonksiyon bulunmaktadır. Bu fonksiyon çizimin kendisini yapar. Ancak bu fonksiyon çizimin nasıl yapılacağını parametresiyle aldığı matrise bakarak tespit etmektedir. Bu matris de aynı modüldeki linkage isimli fonksiyon tarafından elde edilmektedir. Yani linkage fonksiyonu aslında agglomerative kümeleme işlemini yapıp birleştirme bilgilerini bize matris olarak vermektedir. Biz de bu matrisi dendrogram fonksiyonuna veririz.

Points.csv verileri üzerinde dendrogram şöyle çizilebilir:

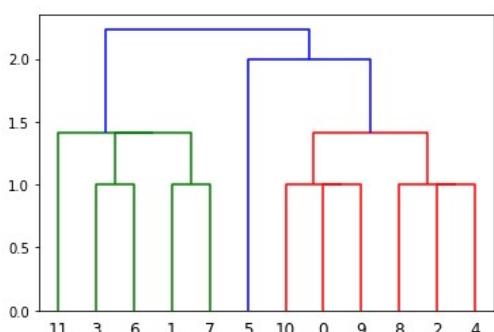
```
import numpy as np

points = np.loadtxt('points.csv', delimiter=',', dtype=np.float32)

from scipy.cluster.hierarchy import linkage, dendrogram

import matplotlib.pyplot as plt

m = linkage(points)
dendrogram(m)
```



Iris verileri için de dendrogram şöyle çizilebilir:

```
from sklearn import datasets
from scipy.cluster.hierarchy import linkage, dendrogram

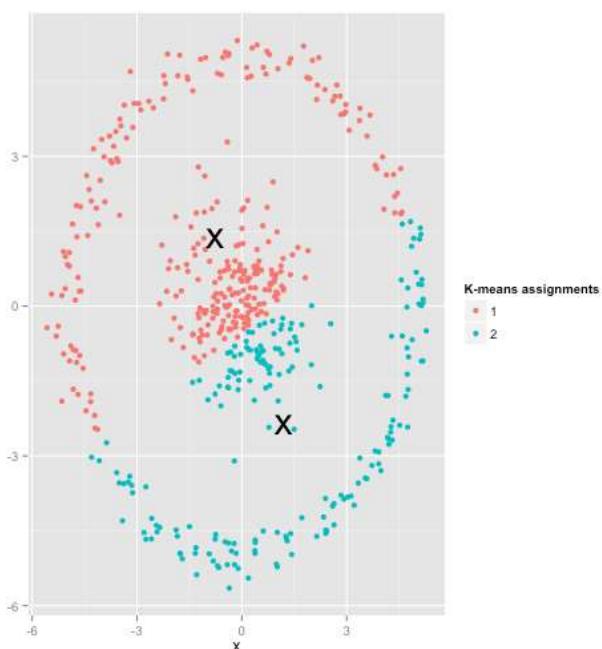
import matplotlib.pyplot as plt

plt.figure(figsize=(25, 10))
m = linkage(transformed_dataset_x)
dendrogram(m)
```

K-Means Yöntemiyle Hiyerarşik Agglomerative Yöntemin Karşılaştırılması

Aslında her iki yöntemin de başarısı birbirine benzer olabilmektedir. Ancak iki yöntemin arasındaki farklılıklar şöyle özetlenebilir:

- Yüksek sayıda nokta söz konusu olduğunda hiperarşik agglomerative yöntem daha fazla zaman almaktadır. Çünkü işin başında tüm noktaların ayrı kümeler olarak ele alınması ve gitgide birleştirilmesi uzun hesaplama zamanına yol açmaktadır.
- Hiperarşik agglomerative yöntemde algoritma rastgele değerlerle başlatılmamaktadır. Dolayısıyla bu da algoritmanın her çalıştırılmasında aynı sonucun bulunması anlamına gelmektedir. Halbuki K-Means yönteminde başlangıç ağırlık merkezleri rastgele alındığı için algoritmanın her çalıştırılmasında farklı sonuçlar elde edilmektedir.
- Hiperarşik agglomerative yöntem daha esnektir. Çünkü kümeler arasındaki uzaklık hesaplama yöntemi değiştirilebilmektedir. Oysa K-Means yönteminde yalnızca metrik değer değiştirilebilmektedir.
- Hiperarşik agglomerative yöntemde dendrogram çizilemeyecektir. Dendrograma bakılarak küme uzaklıklarına dayalı küme sayıları bulunamamaktadır.
- KMeans yöntemi küresel (spherical) olmayan nokta dağılımlarında iyi çalışmaz. Küresel nokta dağılımları noktaların bir merkez etrafında toplanması biçiminde oluşan dağılımlardır. Küresel olmayan nokta dağılımlarında hiperarşik agglomerative yöntem daha iyi sonuç vermektedir. Aslında küresel olmayan noktalar için en iyi yöntem grubu yoğunluk tabanlı (density based) olanlardır. Aşağıda küresel olmayan nokta dağılımlarındaki KMeans kümelerini görüyorsunuz:



Şekil <http://varianceexplained.org/r/kmeans-free-lunch/> makalesinden alınmıştır.

Burada belki de dış dairesel noktaların ayrı bir küme, iç dairesel noktaların ayrı bir küme olarak değerlendirilmesi daha uygun olabilecektir. Ancak KMeans hiçbir zaman buna yönelik bir kümeleme yapamamaktadır.

DBSCAN Kümeleme Yöntemi

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) yoğunluk tabanlı kümeleme yöntemlerinin en çok tercih edilenlerinden biridir. Algoritma 90'lı yıllarda son haline getirilmiştir. DBSCAN yönteminde yoğunluk (density) en önemli unsurdur. Yoğunluk belli bir alanda bulunan nokta sayısı ile ilgilidir. Yani belli bir alanda çok nokta varsa o alan yoğundur, az nokta varsa o alan yoğun değildir. Yoğunluk için kullanılan alan genellikle daireseldir ve bu dairenin yarı çapı epsilon ile gösterilmektedir.



Şekil <https://towardsdatascience.com/dbscan-algorithm-complete-guide-and-application-with-python-scikit-learn-d690cbae4c5d> makalesinden alınmıştır.

Tabii buradaki dairesellik üç boyutlu uzayda küre ve n boyutlu uzayda o uzayın küresidir. Ancak biz burada algoritmanın anlatımında iki boyutlu kartezyen koordinat sistemini kullanacağız. Bu nedenle yoğunluk belirten alanı dairesel olarak nitelendireceğiz. Bilindiği gibi iki boyutlu uzayda (kartezyen koordinat sisteminde) daire denklemi şöyledir:

$$(x - a)^2 + (y - b)^2 = r^2$$

Bu denklemde dairenin merkezi (a, b) noktası ve yarı çapı da r'dir. Üç boyutlu uzayda ise kürenin denklemi şöyledir:

$$(x - a)^2 + (y - b)^2 + (z - c)^2 = r^2$$

Burada da kürenin merkezi (a, b, c) noktası ve yarıçapı r'dir. N boyutlu uzayda da denklem benzer biçimde oluşturulmaktadır.

DBSCAN algoritmasında iki önemli parametre vardır: "Yarıçap (epsilon)" ve "en az nokta sayısı (minPts ya da min_samples)". Biz kurs notlarımızda yarıçapı "eps" biçiminde en az nokta sayısını da "min_samples" biçiminde kısaltacağız. Pek çok doküman en az nokta sayısını "minPts" biçiminde kısaltmaktadır. Yarıçap yukarıda belirtildiği gibi ilgili noktadan çizilen çemberin yarıçapıdır. En az nokta sayısı ise bir alanın yoğun kabul edilebilmesi için o çemberin içerisinde en az kaç noktanın bulunması gerektiğini belirtir. Örneğin "eps = 0.5, min_samples = 15" demek, 0.5 yarıçaplı çizilen çemberin içerisinde 15 ya da daha fazla nokta varsa orası yoğun kabul edilecek" demektir. Algoritmada yoğunluğun nokta temelinde ve dairesel olarak değerlendirildiğine dikkat ediniz. Yani bir nokta çemberin merkezi varsayılarak o noktanın oluşturduğu alanın yoğun olup olmadığına bakılmaktadır.

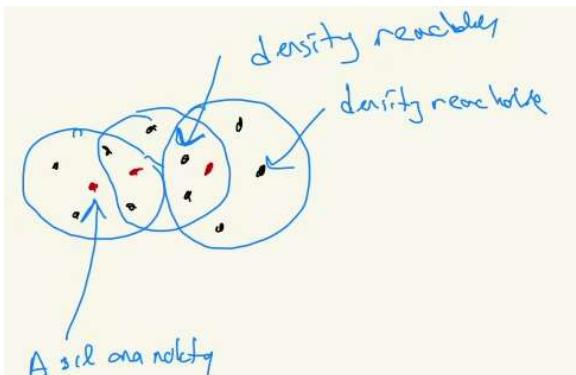
DBSCAN algoritmasını daha kolay açıklayabilmek için birkaç kavramdan faydalılmaktadır. Önce bu kavramları açıklamak istiyoruz:

Ana Noktalar (Core Points): Eğer bir noktanın epsilon yarıçaplı çemberi içerisinde min_samples ya da daha fazla nokta kalıyorsa, yani o noktanın belirttiği alan yoğun ise böyle noktalara ana noktalar (core points) denilmektedir.

Doğrudan Erişilebilir Noktalar (Direct Reachable Points): Bir ana noktanın oluşturduğu çemberin içerisindeki noktalara o ana noktanın doğrudan erişilebilen noktaları denilmektedir.

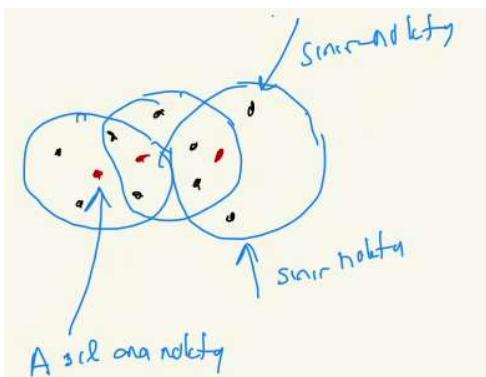
Yoğunluk Yoluyla Erişilebilir Noktalar (Density Reachable Points): Bir ana noktanın doğrudan erişilebilen (yani onun çemberi içerisinde kalan) bir noktası da ana nokta ise o noktanın doğrudan erişilebilen noktası asıl noktanın

"yoğunluk yoluyla erişilebilen" noktasıdır. Yani yoğunluk yoluyla erişilebilen noktalar "arkadaşımın arkadaşı arkadaşımdır" önermesine benzetilebilir. Tabii geçişlilik özelliği devam etmektedir. Yani bir ana noktanın doğrudan erişilebilen ana noktalarının doğrudan erişilebilen noktaları o ana noktanın yoğunluk yoluyla erişilebilen noktalarıdır. (Yani "arkadaşımın arkadaşının arkadaşı da benim arkadaşlarımdır.") Örneğin:

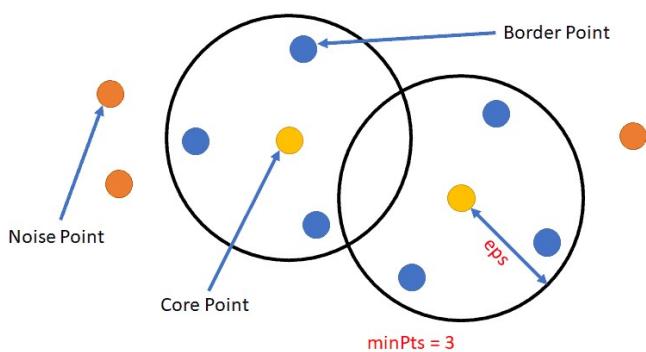


Burada şu duruma dikkat ediniz: Bir ana noktanın yoğunluk yoluyla erişilebilen noktaları içerisindeki tüm ana noktaların yoğunluk yoluyla erişilebilen noktaları aynıdır. Örneğin yukarıdaki şekilde kırmızı ile gösterilen üç ana noktanın da yoğunluk yoluyla erişilebilen noktaları aynıdır.

Sınır Noktalar (Border Points): Bir noktanın yoğunluk yoluyla erişilebilen ancak ana nokta olmayan noktalara sınır noktalar (border points) denilmektedir. Buradaki "sınır noktalar" ismi bu noktaların ilgili kümenin üç noktaları olması nedeniyle verilmiştir. Örneğin:



Gürültü Noktaları (Noise Points): Ana nokta ve sınır nokta olmayan noktalara gürültü noktaları denilmektedir. Bu noktalar bir kümenin içerisine dahil edilmezler ve anomali olarak değerlendirilirler. Yani gürültü noktaları hiçbir ana noktanın yoğunluk yoluyla erişilebilen noktası olamayan noktalardır. Anomali tespit yöntemlerinde buna benzer gürültü noktaları üzerinde durulmaktadır. Örneğin:



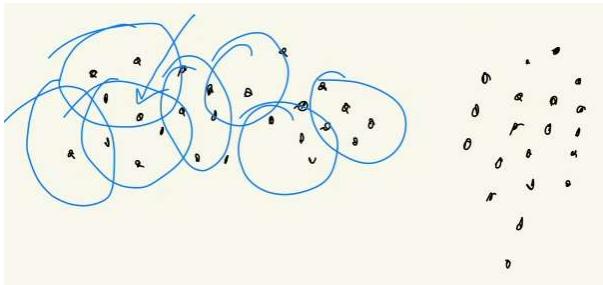
Akıntı Notu: Görsel <https://machinelearninggeek.com/dbSCAN-clustering/> adresinden alınmıştır.

Bu kavramlardan sonra şimdi de DBSCAN algoritmasını açıklayalım. Eps ve min_samples değerlerinin algoritmaya girdi olarak verildiğini varsayıyalım. Herhangi bir kümeye sokulmamış ve gürültü noktası olarak belirlenmemiş

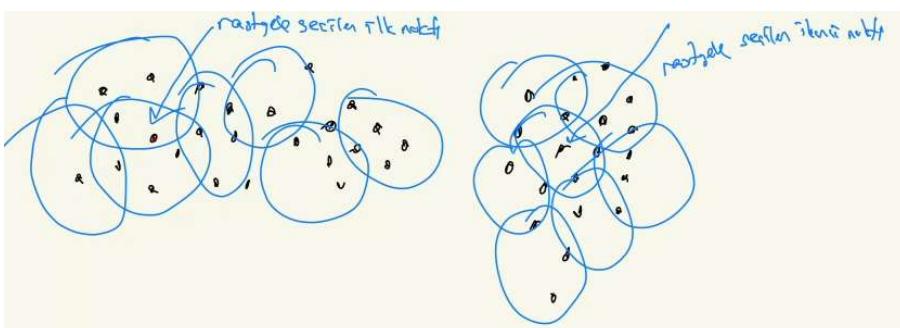
noktaların kümesine "kalan noktalar kümesi" diyeceğiz. Algoritmanın başında tüm noktalar kalan noktalar kümesindedir.

1) Kalan noktalar kümesinde rastgele bir nokta seçilir. Bu noktanın ana nokta olup olmadığına (yani etrafının yoğun olup olmadığına) bakılır. Eğer bu nokta ana nokta değilse gürültü noktası biçiminde işaretlenir. Tabii önce gürültü noktası biçiminde işaretlenen bir nokta daha sonra bir kümeye dahil edilebilmektedir.

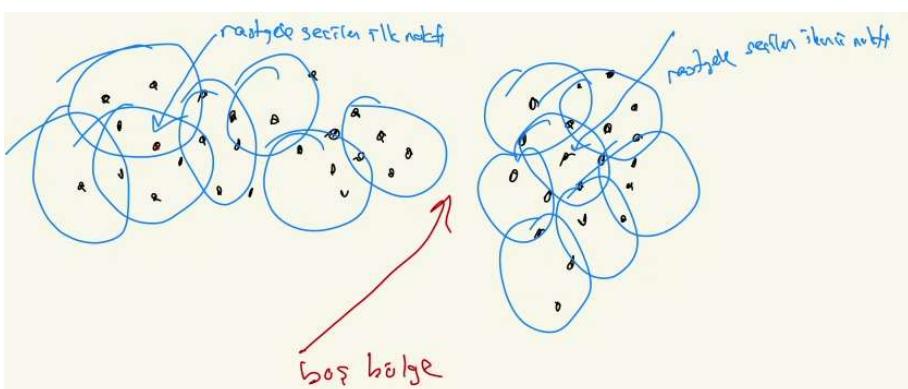
2) Eğer rastgele seçilen nokta bir ana noktaya bir kume yaratılarak onun yoğunluk yoluyla erişilebilen tüm noktaları yaratılan kümeye dahil edilir. Bu işlem sırasında gürültü noktası olarak belirlenmiş noktaların bazılarının da daha sonra bir kümeye dahil edilemeyeceğine dikkat ediniz.



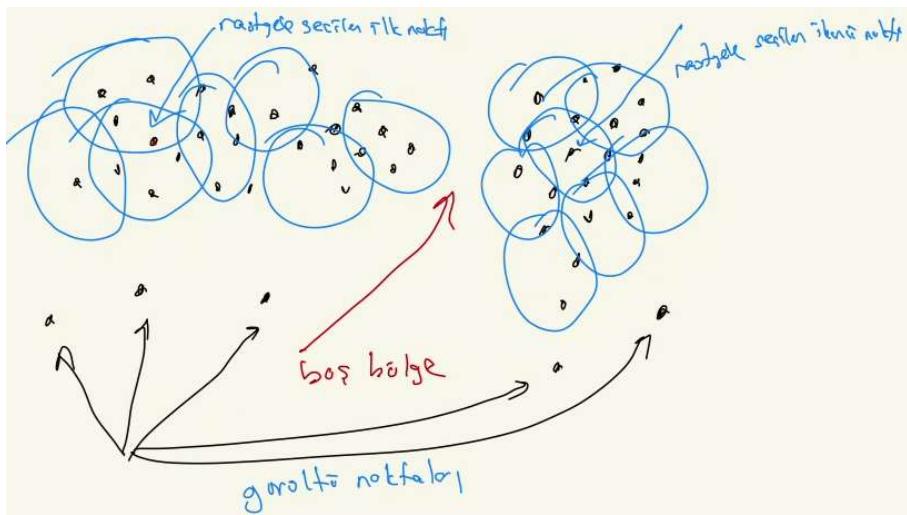
Bu işlem yalnızca bir kümeyi tespit edebilmiştir. Burada algoritma 1'inci adıma geri dönerek kalan noktalar kümesinden (yani bir kümeye sokulmamış ve gürültü olarak işaretlenmemiş noktalar arasından) yeni rastgele bir nokta seçer. Aynı şeyleri o nokta için de yapar. Böylece diğer kümeler elde edilmiş olur.



Burada görüldüğü gibi kümelerin birbirlerinden ayrılması için arada boş bir bölgenin olması gerekmektedir:

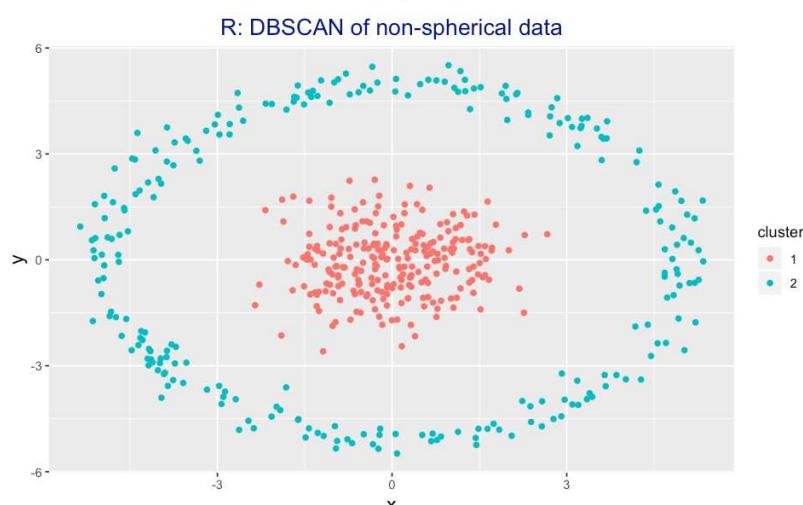
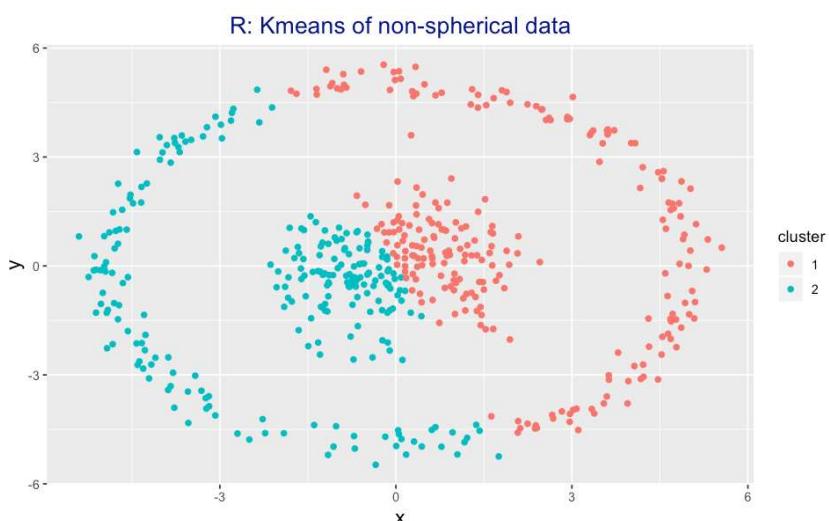


Algoritmanın sonunda hiçbir kümeye dahil edilememiş gürültü noktaları kalabilmektedir. Örneğin:



Burada birkaç noktaya dikkatinizi çekmek istiyoruz. DBSCAN algoritmasında biz algoritmaya küme sayısını vermemekteyiz. Algoritma kümeleri eps ve min_samples değerlerine dayalı olarak kendisi belirlemektedir. Diğer önemli bir nokta da algoritmanın tüm noktaları kümelendirmediği gürültü noktalarını kümelerin dışında bıraktığıdır. Bu iki durum daha önce görmüş olduğumuz K-Means ve Hiyerarşik Agglomerative kümeleme yöntemlerinden farklıdır.

DBSCAN algoritması küresel olmayan noktaları da iyi biçimde kümeleyebilmektedir. Aşağıda küresel olmayan noktalar için K-Means ve DBSCAN kümelendirmelerinin sonuçlarını görüyorsunuz:



Alıntı Notu: Görüler https://datascience-enthusiast.com/Python/DBSCAN_Kmeans.html adresinden alınmıştır.

DBSCAN Kümeleme Yönteminin Scikit-learn Kütüphanesi Kullanılarak Gerçekleştirilmesi

DBSCAN kümeleme yöntemi Scikit-learn kütüphanesindeki DBSCAN isimli sınıfla temsil edilmiştir. Sınıfın `__init__` metodunun parametrik yapısı şöyledir:

```
class sklearn.cluster.DBSCAN(eps=0.5, *, min_samples=5, metric='euclidean', metric_params=None,
    algorithm='auto', leaf_size=30, p=None, n_jobs=None)
```

Fonksiyonun iki önemli parametresi `eps` ve `min_samples` parametreleridir. `eps` parametresi epsilon değerini, `min_samples` parametresi de alanın yoğun kabul edilmesi için gereken en az nokta sayısını belirtir. Bunların default değer aldığına dikkat ediniz. Ayrıca fonksiyonun `metric` parametresi de bir noktanın çember içerisinde kalıp kalmadığını anlamak için kullanılan uzaklık hesaplama biçimini belirtmektedir. Bu değerin default olarak "euclidean" alındığına dikkat ediniz. Diğer yöntemlerde olduğu gibi burada da DBSCAN nesnesi yaratıldıktan sonra `fit` metoduyla algoritmayı çalıştırmak gereklidir. `fit` metodu kümeleneyecek verileri parametre olarak almaktadır. Kümeleme yapıldıktan sonra hangi noktaların hangi kümelere dahil edildiği yine sınıfın `labels_` isimli özniteliğinden elde edilmektedir. `labels_` özniteliğinde kümeler 0'dan başlanarak numaralandırılmıştır. -1 değeri gürültü noktaları anlamına gelmektedir. Sınıfın `n_features_in_` isimli örnek özniteliği ise algoritmanın noktalardan kaç küme oluşturduğunu bize vermektedir.

Şimdi "points.csv" dosyasındaki noktaları DBSCAN algoritmasıyla kümelendirelim:

```
import numpy as np

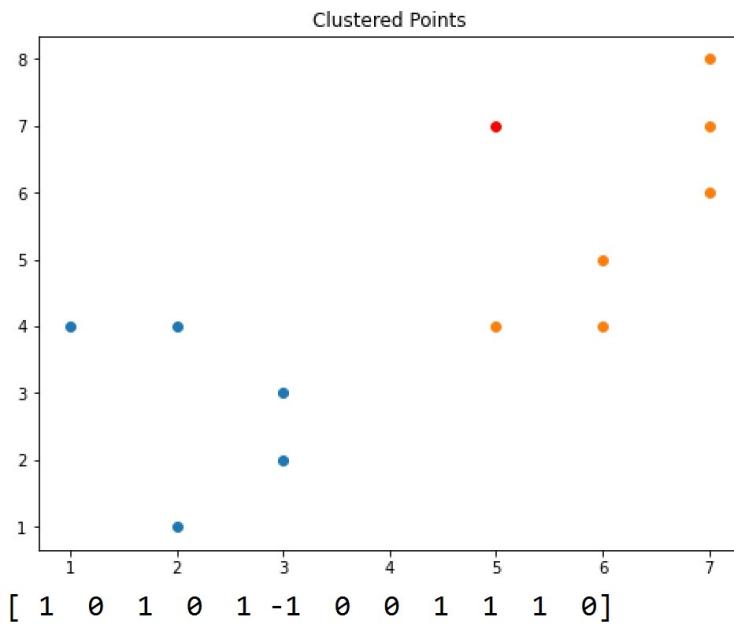
dataset = np.loadtxt('points.csv', delimiter=',', dtype=np.float32)

from sklearn.cluster import DBSCAN

dbs = DBSCAN(eps=1.5, min_samples=3)
dbs.fit(dataset)

import matplotlib.pyplot as plt

plt.title('Clustered Points')
figure = plt.gcf()
figure.set_size_inches((8, 6))
for i in range(dbs.n_features_in_):
    plt.scatter(dataset[dbs.labels_ == i, 0], dataset[dbs.labels_ == i, 1])
plt.scatter(dataset[dbs.labels_ == -1, 0], dataset[dbs.labels_ == -1, 1], color='red')
plt.show()
print(dbs.labels_)
```



Örneğimizde gürültü noktalarını kırmızı renkle gösterdik. Grafikten DBSCAN'in $\text{eps} = 1.5$, $\text{min_sample} = 3$ parametreleriyle noktaları iki kümeye ayırdığını ve bir noktanın da gürültü noktası olarak belirlendiğini görüyorsunuz. Bu örneği eps ve min_samples parametrelerine değişik değerler verip deneyiniz. Bu iki parametre uygun seçilmezse daha çok noktanın gürültü noktası haline gelebileceğine dikkat ediniz. Uygun olmayan değerlerde tüm noktalar bile gürültü noktası haline gelebilmektedir.

DBSCAN sınıfının `fit_predict` isimli metodу fit işlemini yaptıktan sonra sınıfın `labels_` isimli örnek özniteliğinin değeriyle geri dönmektedir. Yani örneğin:

```
result = dbs.fit_predict(dataset)
```

işlemi ile aşağıdaki işlem eşdeğerdir:

```
dbs.fit(dataset)
result = dbs.labels_
```

DBSCAN yöntemi için tablo özellikleri (sütunları) arasında sakala farklılıklarının olduğu durumda özellik ölçeklendirmesinin yapılması gerektiğine dikkat ediniz. Çünkü bu yöntemde de noktalar arasında uzaklık hesabı yapılmaktadır ve bu uzaklık hesabında tablo özellikleri arasındaki skala farklılıkları sorunlara yol açabilmektedir.

Şimdi küresel olmayan eliptik tarzda veriler için K-Means, Agglomerative ve DBSCAN yöntemlerini uygulayıp sonuçlara bakalım:

```
from sklearn.datasets import make_circles
dataset, clusters = make_circles((100, 200), factor=0.5, noise=0.03, random_state=100)

import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches((8, 8))
plt.title('Circular Random Data')
plt.scatter(dataset[:, 0], dataset[:, 1])
plt.show()

from sklearn.cluster import KMeans

kmeans = KMeans(n_clusters=2)
kmeans.fit(dataset)
```

```

plt.title('K-Means Clustered Points')
figure = plt.gcf()
figure.set_size_inches((8, 8))
for i in range(3):
    plt.scatter(dataset[kmeans.labels_ == i, 0], dataset[kmeans.labels_ == i, 1], 70)
plt.show()

from sklearn.cluster import AgglomerativeClustering

ac = AgglomerativeClustering(n_clusters=2)
ac.fit(dataset)

import matplotlib.pyplot as plt

plt.title('Agglomerative Clustered Points')
figure = plt.gcf()
figure.set_size_inches((8, 8))
for i in range(3):
    plt.scatter(dataset[ac.labels_ == i, 0], dataset[ac.labels_ == i, 1], 70)
plt.show()

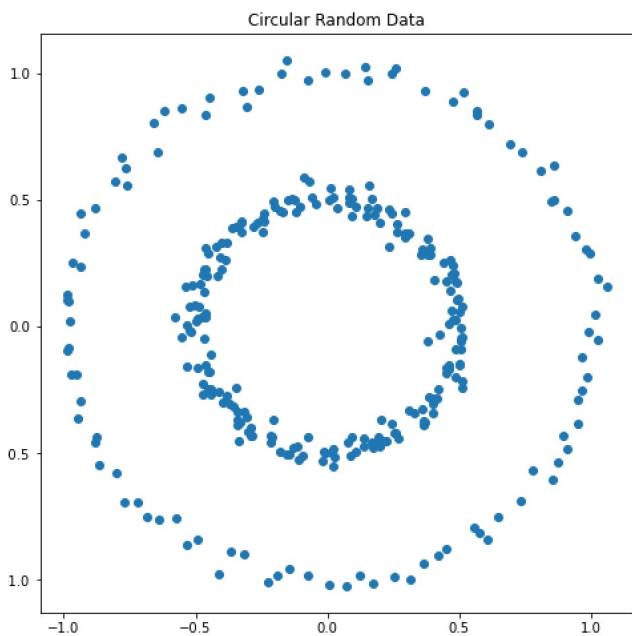
from sklearn.cluster import DBSCAN

dbs = DBSCAN(eps=0.20, min_samples=5)
dbs.fit(dataset)

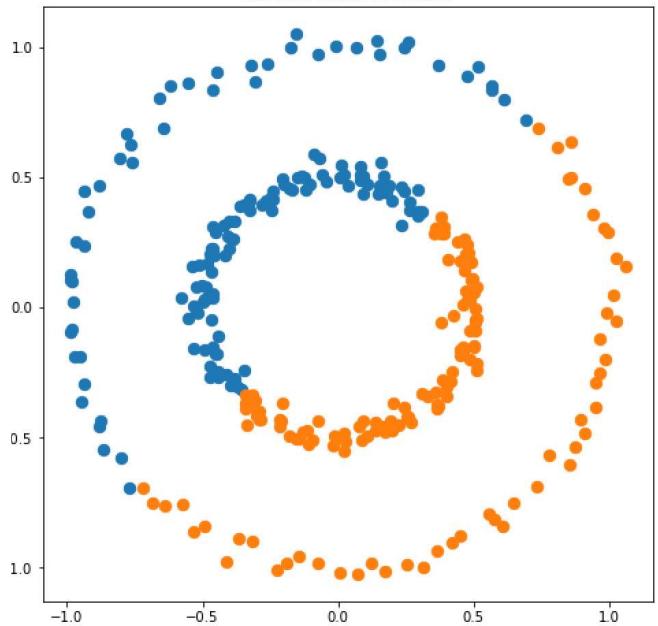
plt.title('DBSCAN Clustered Points')
figure = plt.gcf()
figure.set_size_inches((8, 8))
for i in range(dbs.n_features_in_):
    plt.scatter(dataset[dbs.labels_ == i, 0], dataset[dbs.labels_ == i, 1], 70)
plt.scatter(dataset[dbs.labels_ == -1, 0], dataset[dbs.labels_ == -1, 1], 70, color='red')
plt.show()

```

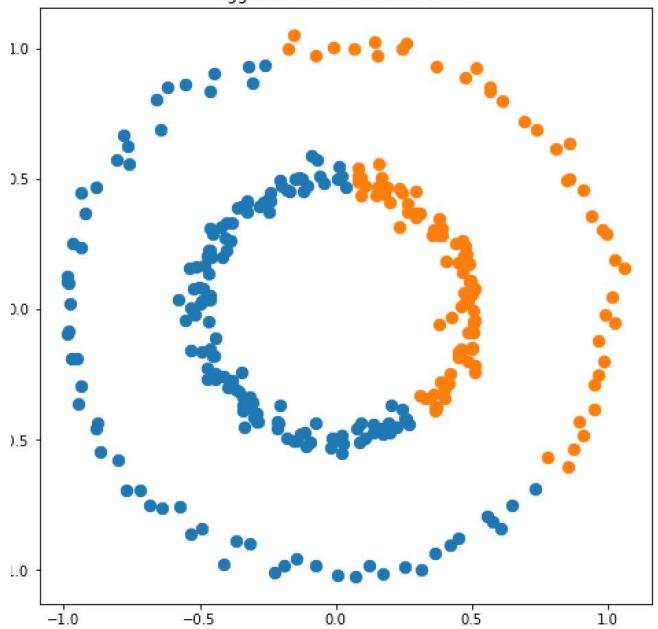
Elde edilen grafikler şöyledir:

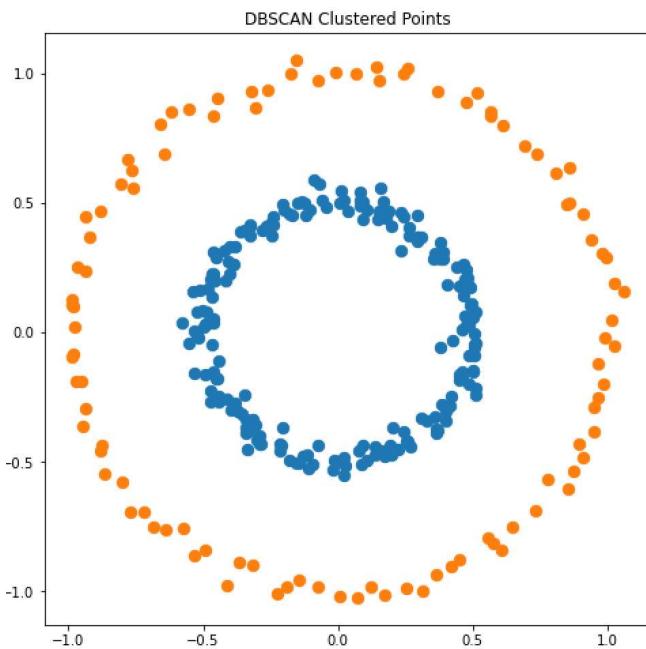


K-Means Clustered Points



Agglomerative Clustered Points





Göründüğü gibi küresel olmayan eliptik tarzda verilerde K-Means ile Agglomerative yöntem benzer performans sergilemiştir. Ancak DBSCAN burada kümelemeyi ideal olarak yapabilmişdir.

DBSCAN Kümeleme Yönteminin Zambak Veri Kümesine Uygulanması

Şimdi de zambak verileri üzerinde DBSCAN yöntemini kullanalım:

```
from sklearn.datasets import load_iris

iris = load_iris()
dataset_x = iris.data
dataset_y = iris.target

from sklearn.preprocessing import MinMaxScaler

mms = MinMaxScaler()
scaled_dataset_x = mms.fit_transform(dataset_x)

from sklearn.cluster import DBSCAN

dbs = DBSCAN(eps=0.2, min_samples=5)
dbs.fit(scaled_dataset_x)

print(dbs.labels_)

from sklearn.decomposition import PCA

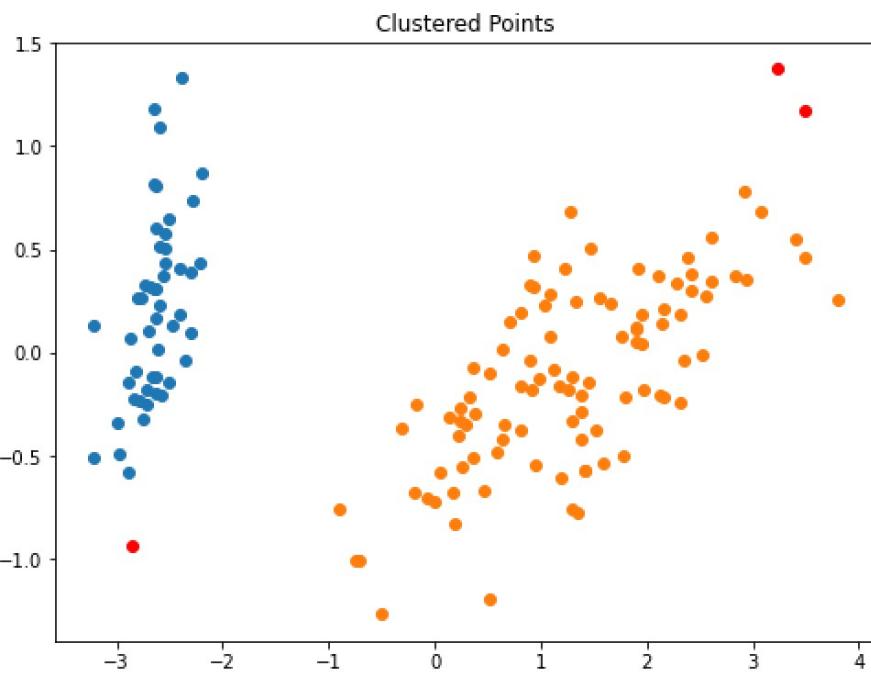
pca = PCA(n_components=2)
pca.fit(dataset_x)
reduced_dataset_x = pca.transform(dataset_x)

import matplotlib.pyplot as plt

plt.title('Clustered Points')
figure = plt.gcf()
figure.set_size_inches((8, 6))
for i in range(dbs.n_features_in_):
    plt.scatter(reduced_dataset_x[dbs.labels_ == i, 0], reduced_dataset_x[dbs.labels_ == i, 1])
    plt.scatter(reduced_dataset_x[dbs.labels_ == -1, 0], reduced_dataset_x[dbs.labels_ == -1, 1],
```

```
color='red')  
plt.show()
```

İşlemler sonucunda elde edilen sonuçlar şöyledir:



Göründüğü gibi DBSCAN $\text{eps} = 1.5$, $\text{min_sample} = 3$ parametreleriyle zambak verilerini iki sınıfa ayırmıştır. Bu parametrelerle yalnızca üç tane gürültü noktası oluştuguına dikkat ediniz. Algoritmayı default parametreler olan $\text{epsilon} = 0.5$, $\text{min_sample} = 5$ değerleriyle çalıştırırsanız tüm noktaların tek bir kümeye sokulduğunu göreceksiniz. Şimdi yukarıdaki örneği standart ölçekleme ile default değerlerle çalışıralım:

```
from sklearn.datasets import load_iris

iris = load_iris()
dataset_x = iris.data
dataset_y = iris.target

from sklearn.preprocessing import StandardScaler

ss = StandardScaler()
scaled_dataset_x = ss.fit_transform(dataset_x)

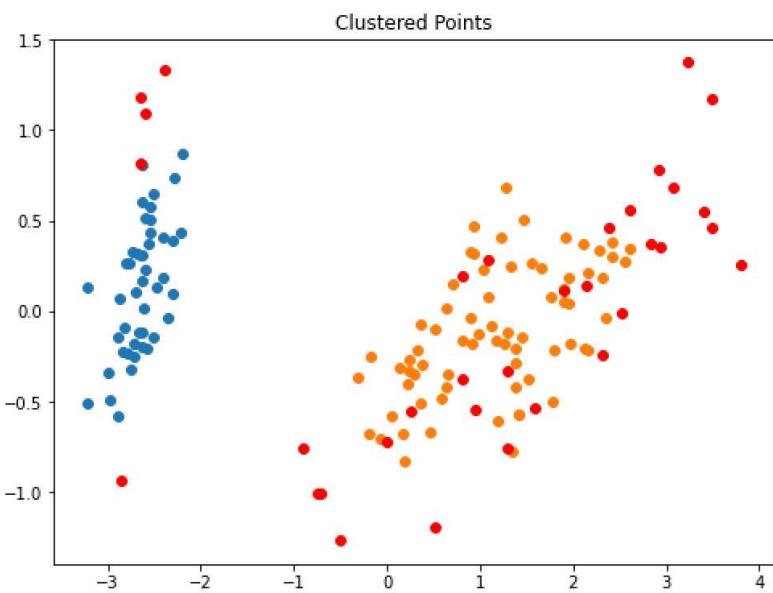
from sklearn.cluster import DBSCAN

dbs = DBSCAN()
dbs.fit(scaled_dataset_x)

print(dbs.labels_)

from sklearn.decomposition import PCA

pca = PCA(n_components=2)
pca.fit(dataset_x)
reduced_dataset_x = pca.transform(dataset_x)
```



DBSCAN yönteminde küme sayısının belirtilmediğini epsilon ve min_samples değerlerine göre otomatik oluşturulduğunu anımsayınız.

OPTICS Kümeleme Yöntemi

Çok tercih edilen diğer bir yoğunluk tabanlı kümeyeleme yöntemi de OPTICS (Ordering Points To Identify the Clustering Structure) isimli yöntemdir. OPTICS algoritması aslında DBSCAN algoritmasına benzemektedir. Ancak OPTICS algoritması noktaları kümeler içerisine yerleştirmek yerine onlara ilişkin iki uzaklık hesaplamaktadır. Noktalar için hesaplanan iki uzaklık şöyledir:

Bir Noktanın Ana Uzaklığı (Core Distance): İlgili noktanın bir ana nokta olması için (yani en az min_samples kadar noktayı içerebilmesi için) gereken en kısa uzaklık. Eğer ilgili nokta bir ana nokta değilse o noktanın ana uzaklığı olmaz (NumPy'da bu durum np.inf ile belirtilebilir).

Bir Noktanın Bir Ana Noktaya Erişim Uzaklığı (Reachability Distance): Bir p noktasının bir ana nokta olan q noktasına erişim uzaklığı p ile q arasındaki uzaklıktır. Ancak eğer p ile q arasındaki uzaklık q'nun ana uzaklığından küçüke (yani q'nun doğrudan erişilebilir bir noktası ise) bu durumda p noktasının erişim uzaklığı q noktasının ana uzaklığı olmaktadır. Eğer p noktasına hiçbir q noktası tarafından yoğunluk yoluyla erişilemiyorsa bu durumda p noktasının ana noktaya erişim uzaklığı tanımsızdır (NumPy'da bu durum np.inf ile belirtilebilir).

OPTICS algoritmasında yalnızca bir noktanın "ana nokta (core point)" olması için gereken min_samples (ya da minPts) değeri belirtilmektedir. Algoritma bu min_samples değerinden hareketle eps değerini kendisi hesaplamaktadır.

Sckit-Learn kütüphanesinde OPTICS algoritması sklearn.cluster modülündeki OPTICS sınıfıyla temsil edilmektedir. OPTICS sınıfının __init__ metodunun parametrik yapısı şöyledir:

```
class sklearn.cluster.OPTICS(*, min_samples=5, max_eps=inf, metric='minkowski', p=2,
metric_params=None, cluster_method='xi', eps=None, xi=0.05, predecessor_correction=True,
min_cluster_size=None, algorithm='auto', leaf_size=30, memory=None, n_jobs=None)
```

OPTICS nesnesi yaratırken biz yalnızca min_samples değerini parametre olarak veririz. Sınıfın core_distances_ örnek özniteligi noktaların ana nokta olması için gereken uzaklığı vermektedir. Şimdi "points.csv" verileri üzerinde OPTICS yöntemini uygulayalım:

```
import numpy as np
from sklearn.cluster import OPTICS

dataset = np.loadtxt('points.csv', delimiter=',', dtype=np.float32)

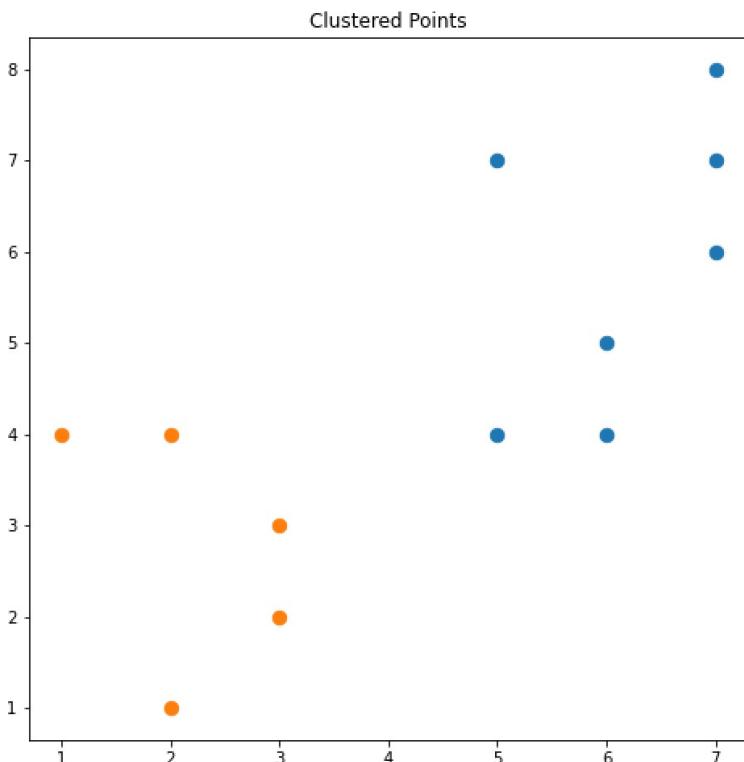
optics = OPTICS(min_samples=3)
optics.fit(dataset)

nclusters = len(np.unique(optics.labels_[optics.labels_ != -1]))

import matplotlib.pyplot as plt

plt.title('Clustered Points')
figure = plt.gcf()
figure.set_size_inches((8, 8))
for i in range(nclusters):
    plt.scatter(dataset[optics.labels_ == i, 0], dataset[optics.labels_ == i, 1], 70)
plt.scatter(dataset[optics.labels_ == -1, 0], dataset[optics.labels_ == -1, 1], 70,
color='red')
plt.show()
```

Elde edilen grafik şöyledir:



Örneğimizde min_sample = 3 olarak alındığına dikkat ediniz. Bu parametre uygulamacı tarafından belirlenmelidir.

OPTICS Algoritmasıyla DBSCAN Algoritmasının Karşılaştırılması

OPTICS algoritması DBSCAN algoritmasına göre hem daha fazla bellek kullanmakta hem de daha fazla hesap gerektirmektedir. Bu da OPTICS algoritmasının DBSCAN algoritmasına göre daha yavaş olduğu anlamına gelmektedir. OPTICS algoritması noktaları doğrudan kümelere ayırmaz, bir yoğunluk haritası çıkarır. Değerlerin kümelere ayrılması bu yoğunluk haritasından hareketle yapılmaktadır. OPTICS algoritması büyük veri kümeleri için DBSCAN algoritmasından daha iyi sonuç verme eğilimindedir. Ancak uygulamacının üzerinde çalıştığı veriler için her iki yöntemi de denemesi, hangisinin performansı mevcut durum için daha iyi ise onu tercih etmesi tavsiye edilmektedir.

OPTICS yönteminin DBSCAN yöntemine göre en önemli farklılığı OPTICS yönteminde epsilon parametresine gerek kalmamasıdır. OPTICS yönteminde kullanıcı yalnızca minPts değerini belirler. Halbuki DBSCAN yönteminde kullanıcı min_samples değerinin yanı sıra epsilon parametresini de belirlemektedir.

Varyans, Kovaryans, Korelasyon Kavramları ve Özdeğerler

Giriş böölümelerinde varyans ve standart sapma hakkında temel bazı bilgiler vermiştık. Burada önce varyans kavramının yeniden üzerinden geçmek istiyoruz. Varyans istatistikteki en önemli kavamlardan biridir. Genel olarak dağılımdaki değerlerin ortalamadan uzaklığını ölçmek için kullanılır. Örneğin ortalamaları aynı olan iki dağılımin varyanslarına bakıldığında varyansı yüksek olan daha dağılım değerleri ortalamaya göre daha fazla yayılmıştır. Varyansı düşük olan dağılımin değerleri ortalamaya daha yakındır. Örneğin ortalama yıllık gelirin 10000\$ olduğu iki ülkeden hangisinde varyans daha yüksekse o ülkede gelir adeletsizliği diğerinden daha yüksektir. Varyansın kareköküne standart sapma (standard deviation) denilmektedir. Bu anlamda varyans ile standart sapma aynı amaçla kullanılmaktadır. Varyans değerlerin ortalamadan farklarının karelerinin toplamının ortalamasıyla hesaplanır. Varyans formülünde ortalama alınırken genel olarak ana kütle (population) için N'e örneklemeler için N – 1'e bölme ugulandığını anımsayınız.

Kovaryans birden fazla değişkenin olduğu durumda bu değişkenlerin birlikte değişimlerini hesaplamak için yanı birindeki değişimin diğerini etkileme biçimini incelemek için kullanılmaktadır.

X ve Y'nin kovaryansları olan Cov(X, Y) şu formülle hesaplanmaktadır:

$$Cov(X, Y) = \frac{\sum(X_i - \bar{X})(Y_i - \bar{Y})}{N \text{ (ya da } N - 1\text{)}}$$

Cov(X, Y) ile Cov(Y, X) değerlerinin aynı olacağına dikkat ediniz. Ayrıca Cov(X, X) ile Var(X) tamamen eşdeğer, benzer biçimde Cov(Y, Y) ile Var(Y) değerleri de tamamen aynıdır. Örneğin iki değişken için manuel kovaryans işlemini şöyle yapabiliriz:

```
>>> covxy = np.sum((x - np.mean(x)) * (y - np.mean(y))) / (len(x) - 1)
>>> covxy
24.45000000000003
```

İki değişken arasındaki kovaryans hesabı Python standart kütüphanesine 3.10 versiyonu ile eklenmiştir. Bu ekleme henüz çok yeni olduğu için üzerinde durmak istemiyoruz. NumPy kütüphanesinde isen kovaryans hesabı cov isimli fonksiyonla yapılmaktadır. Biz cov fonksiyonunda iki değişken için ilk iki parametreyi kullanabiliriz. Fakat daha fazla değişken söz konusu olursa birinci parametreyi çok boyutlu dizi biçiminde vermemeliyiz. cov fonksiyonu çok boyutlu dizinin her bir satırını ayrı bir değişken biçiminde ele almaktadır. cov fonksiyonunun ddof parametresi bölümü belirlemek için kullanılmaktadır. Bu parametre 1 ise N – 1 değerine, 0 ise N değerine bölüm yapmaktadır. Default durumda fonksiyon N – 1 değerine bölüm uygulamaktadır. cov fonksiyonu değişkenlerin birbirlerine göre korelasyonlarını gösteren simetrik bir kovaryans matrisine geri dönmektedir. Örneğin:

```
import numpy as np

x = np.array([2, 4, 7, 3, 4, 8, 4, 3, 10, 6])
y = np.array([6, 2, 5, 9, 1, 6, 10, 1, 12, 16])

cov = np.cov(x, y)
print(cov)
```

Buradan şöyle bir çıktı elde edilmiştir:

```
[[ 6.54444444  5.1333333]
 [ 5.13333333 24.62222222]]
```

Bu matrisdeki kovaryanslar şöyledir:

$$\begin{bmatrix} \text{cov}(x, x) & \text{cov}(x, y) \\ \text{cov}(y, x) & \text{cov}(y, y) \end{bmatrix}$$

Birden çok değişken söz konusu olduğunda kovaryans hesabı hepsinin birbirlerine göre ikişerli kovaryanslarını içerecek biçimde matrisel bir hal almaktadır. Örneğin:

x	y	z
5	3	1
7	9	6
2	8	5
1	9	5
5	3	7

Burada kovaryans hesabı $\text{Cov}(x, y)$, $\text{Cov}(x, z)$, $\text{Cov}(y, z)$ biçiminde ayrı ayrı yapılmaktadır. Bu üç değişkenden elde edilecek kovaryans matrisi aşağıdaki gibi bir görünümü sahiptir:

$$\begin{bmatrix} \text{cov}(x, x) & \text{cov}(x, y) & \text{cov}(x, z) \\ \text{cov}(y, x) & \text{cov}(y, y) & \text{cov}(y, z) \\ \text{cov}(z, x) & \text{cov}(z, y) & \text{cov}(z, z) \end{bmatrix}$$

`cov` fonksiyonunun `axis` parametresine sahip olmadığını belirtmiştık. `cov` fonksiyonu her satırı ayrı bir değişken olarak ele almaktadır. Örneğin:

```
x = [5, 7, 2, 1, 3]
y = [3, 4, 8, 9, 3]
z = [1, 6, 5, 4, 7]

a = np.array([x, y, z], dtype=np.float32)

cov = np.cov(a)
print(cov)
```

Sonuç şöyledir:

```
[[ 5.8 -5.05 -0.2 ]
 [-5.05  8.3 -0.05]
 [-0.2   -0.05  5.3 ]]
```

Matrisin simetrik olduğuna dikkat ediniz. Örneğin matrisin [0, 3] indeksli elemanı $\text{Cov}(x, z)$ değerini vermektedir. Bu değeri şöyle sinyayabiliriz:

```
result = np.sum((x - np.mean(x)) * (z - np.mean(z))) / (len(x) - 1)
print(result)
```

Kovaryans iki değişkenin birlikte nasıl değiştigini anlamakta kullanılmaktadır. Yani değişkenlerden birisi artarken diğerinin ne olmaktadır? İki değişkenin kovaryansları pozitif bir değerde ise bunların değişimleri aynı yönedir. Yani birisi artarken diğer de artmaktadır. İki değişkenin kovaryansları negatif ise bunların değişimleri farklı yönlerdedir. Yani biri artarken diğer azalmaktadır. Aşağıdaki x, y noktalarının grafiğini çizelim:

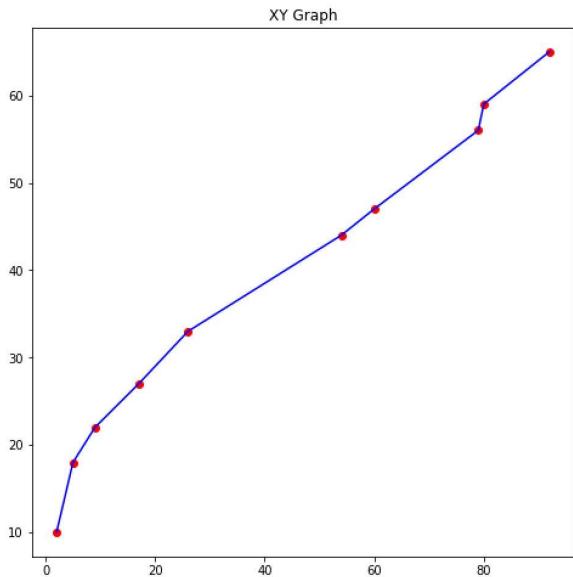
```
x = [2, 5, 9, 17, 26, 54, 60, 79, 80, 92]
y = [10, 18, 22, 27, 33, 44, 47, 56, 59, 65]

import matplotlib.pyplot as plt
```

```

plt.title('XY Graph')
figure = plt.gcf()
figure.set_size_inches((8, 8))
plt.xlabel('X')
plt.ylabel('Y')
plt.plot(x, y, color='blue')
plt.scatter(x, y, color='red')
plt.show()

```



Şimdi $\text{cov}(x,y)$ değerine bakalım:

```

cov = np.cov([x,y])
print(cov)

```

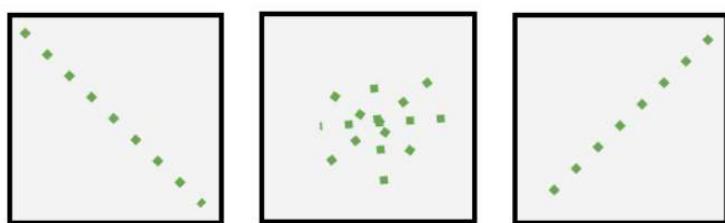
Sonuç şöyledir:

```

[[1190.93333333 643.4]
 [ 643.4 355.21111111]]

```

Göründüğü gibi $\text{Cov}(x, y) = 643.4$ gibi pozitif bir değerdedir. O halde x artarken y de artmaktadır. Eğer iki değişken arasında artmalı azalmalı bir ilişki yoksa kovaryans değeri 0'a yaklaşmaktadır. Kovaryans değerinin yüksekliği x ve y arasında artış ilişkisinin bağlantısı ile ilgilidir. Ancak bu değer doğrudan yorumlanabilecek bir değer değildir.



Sekil <https://www.geeksforgeeks.org/mathematics-covariance-and-correlation/> adresinden alınmıştır.

Buradan gördüğünüz gibi iki değişken arasındaki ilişki ne kadar doğrusala kovaryans değeri o kadar artmaktadır. Dairel değerlerin kovaryanslarının düşük olduğuna dikkat ediniz.

Korelasyon kovaryansın normalize edilmiş bir biçimidir. Korelasyon da tipki kovaryans gibi iki değişken arasındaki ilişkiye açığa çıkartır. Ancak korelasyonda değerler -1 ile +1 arasında normalize edilmiştir. Yani bir değişken

yükselirken diğer de benzer biçimde yükseliyorsa bunların arasındaki korelasyon 1'e yaklaşır fakat bir değişken yükselirken diğer düşüyorsa bunlar arasındaki korelasyon -1'e yaklaşmaktadır. Korelasyonun 0 civarında olması demek iki değişken arasında ilişkinin çok zayıf olması demektir.

Tabii iki değişken arasında korelasyon olması bu iki değişkenin neden sonuç ilişkisi içerisinde olduğu anlamına gelmemektedir. Örneğin dondurma tüketimi ile boğulma sayıları arasında pozitif bir korelasyon bulunuyor olabilir. Ancak bu durum dondurma yemenin boğulmaya yol açacağı anlamına gelmez. (Muhtemelen dondurma yazın daha fazla yendiğinden dolayı boğulma vakaları ile arasında bir korelasyon vardır.) Korelasyon katsayısının hesaplanması için değişik yöntemler kullanılabilmektedir. Ancak en yaygın kullanılan yöntem "Pearson korelasyon katsayı" denilen yöntemidir. Bu yöntem iki değişkenin kovaryanslarının bu iki değişkenin standart sapmalarının çarpımı bölümü ile hesaplanır.

$$\text{corr}(x, y) = \frac{\text{cov}(x, y)}{\text{std}(x) * \text{std}(y)}$$

NumPy'da Pearson korelasyon katsayısı corrcoef isimli fonksiyonla hesaplanmaktadır. Bu fonksiyon bize yine matrisel bir sonuç verir. Bu fonksiyonun da axis parametresi yoktur. Kullanımı cov fonksiyonu ile benzerdir. Yukarıdaki değerler için Pearson korelasyon katsayısını hesaplayalım:

```
import numpy as np

x = [2, 5, 9, 17, 26, 54, 60, 79, 80, 92]
y = [10, 18, 22, 27, 33, 44, 47, 56, 59, 65]

corr = np.corrcoef([x, y])
print(corr)
```

Buradan şöyle bir çıktı elde edilmiştir:

```
[[1.          0.98922267]
 [0.98922267 1.        ]]
```

corr(x, y) değerinin 0.98 gibi çok yüksek bir değerde olduğunu görüyoruz. Şimdi aynı işlemi kovaryans hesabı ile yapalım:

```
import numpy as np

x = [2, 5, 9, 17, 26, 54, 60, 79, 80, 92]
y = [10, 18, 22, 27, 33, 44, 47, 56, 59, 65]

std_matrix = np.array([[np.std(x, ddof=1) * np.std(x, ddof=1), np.std(x, ddof=1) * np.std(y, ddof=1)],
                      [np.std(y, ddof=1) * np.std(x, ddof=1), np.std(y, ddof=1) * np.std(y, ddof=1)]])
cov = np.cov([x, y])
corr = cov / std_matrix
print(corr)
```

Sosyal bilimlerde iki değişkenin arasındaki korelasyon için şunlar söylemektedir:

0 - 0.2 ise çok zayıf ilişki ya da korelasyon yok
0.2-0.4 arasında ise zayıf korelasyon
0.4-0.6 arasında ise orta şiddette korelasyon
0.6-0.8 arasında ise yüksek korelasyon
0.8 – 1 > ise çok yüksek korelasyon

Doğrusal bir ilişkinin mükemmel bir korelasyon ilişkisi oluşturduğunu söyleyebiliriz. Örneğin:

```
import numpy as np
```

```

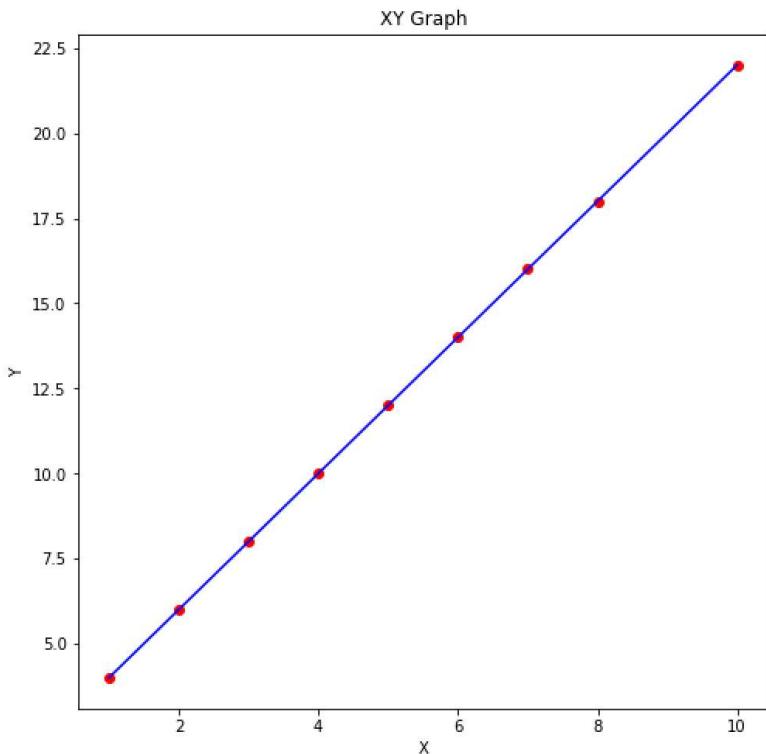
x = np.array([1, 2, 3, 4, 5, 6, 7, 8, 10], dtype=np.float32)
y = 2 * x + 2

import matplotlib.pyplot as plt

plt.title('XY Graph')
figure = plt.gcf()
figure.set_size_inches((8, 8))
plt.xlabel('X')
plt.ylabel('Y')
plt.plot(x, y, color='blue')
plt.scatter(x, y, color='red')
plt.show()

corr = np.corrcoef(x, y)
print(corr)

```



Elde edilen korelasyon sonucu şöyledir:

```
[[1. 1.]
 [1. 1.]]
```

Örneğin:

```

import numpy as np

x = np.array([3, 5, 8, 3, 17, 19, 3, 2, 10, 21])
y = np.array([2, 11, 12, 19, 20, 5, 6, 16, 4, 9])

cor = np.corrcoef([x, y])
print(cor)

import matplotlib.pyplot as plt

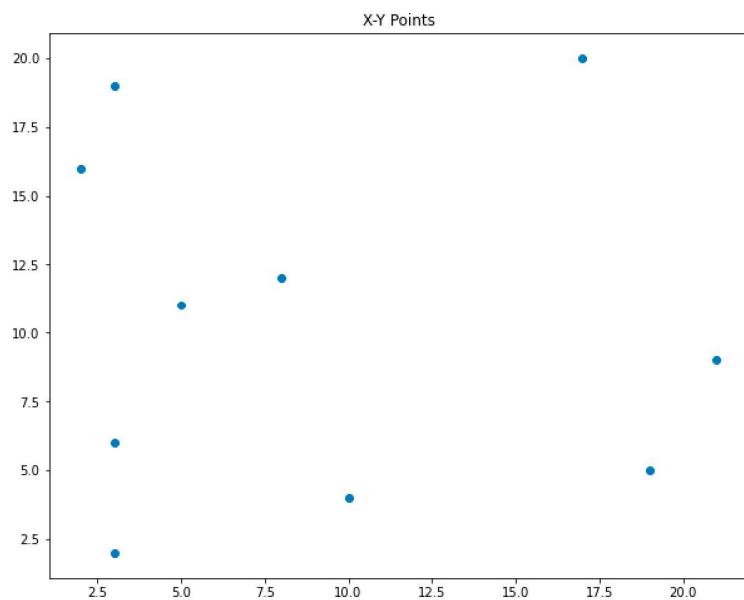
plt.title('X-Y Points')
figure = plt.gcf()
figure.set_size_inches((10, 8))
```

```
plt.scatter(x, y)
plt.show()
```

Korelasyon matrisi şöyle elde edilmiştir:

```
[[ 1.      -0.04398404]
 [-0.04398404  1.      ]]
```

Noktaların saçılma grafiği de şöyledir:



Buradaki grafikten x ve y arasındaki korelasyonun çok düşük olduğu zaten görülmektedir. Örneğin:

```
import numpy as np

x = np.array([3, 8, 10, 14, 23, 62, 71, 78, 80, 82])
y = np.array([2, 11, 12, 19, 20, 30, 40, 42, 47, 49])

cor = np.corrcoef([x, y])
print(cor)

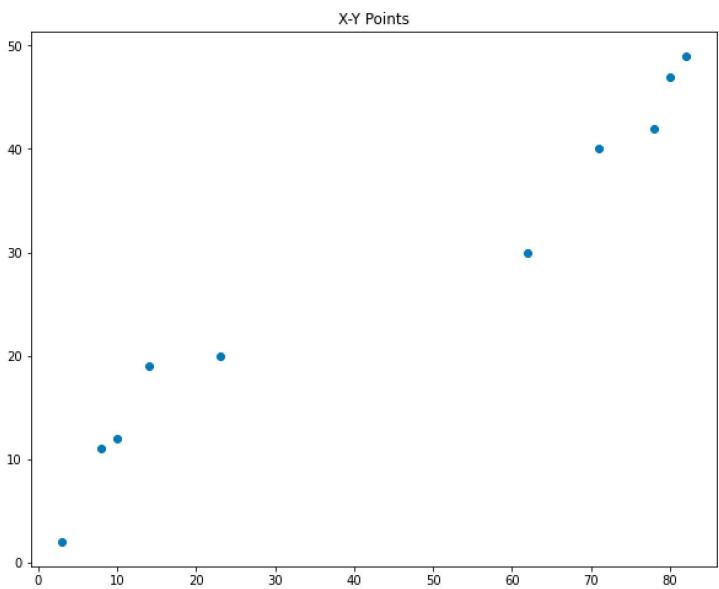
import matplotlib.pyplot as plt

plt.title('X-Y Points')
figure = plt.gcf()
figure.set_size_inches((10, 8))
plt.scatter(x, y)
plt.show()
```

Bu değerlerden şu korelasyon matrisi elde edilmiştir:

```
[[1.      0.97306728]
 [0.97306728  1.      ]]
```

Noktaların saçılma grafiği de şöyledir:



Buradaki grafikten de x ve y arasında kuvvetli bir korelasyon olduğu anlaşılmaktadır.

Öz Değerler ve Öz Vektörler (Eigen Values and Eigen Vectors)

Öz değerler ve öz vektörler konusu pek çok alanda kullanılmaktadır. Öz değer ve öz vektör bir kare matrise dayalı olarak hesaplanmaktadır. Hesaplama için genel eşitlik öyledir:

$$AX = \lambda X$$

Burada A ilgili kare matrisi belirtmektedir. X bir sütun vektördür. Bu X vektörüne öz vektör denir. Lamda ise bir skalerdir. Bu lamda skalerine de öz değer denilmektedir. Buradaki eşitliğin daha belirgin gösterimi şöyle yapılabilir:

$$\begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1k} \\ a_{21} & a_{22} & \cdots & a_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ a_{k1} & a_{k2} & \cdots & a_{kk} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_k \end{bmatrix} = \lambda \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_k \end{bmatrix},$$

Yukarıdaki eşitlikten şöyle bir anlam çıkmaktadır: Biz bir vektörü (eşitlikteki x) bir matrisle çarptığımızda yine bir vektör elde ederiz. Ancak elde ettiğimiz vektör ilkiyle aynı doğrultuda yalnızca büyülüklük olarak farklıdır. Yani biz bir vektörü bir matrisle çarptığımızda vektör doğrultu değiştirmemektedir. Yalnızca vektörün büyülüğü değişmektedir. Tabii biz bir vektörü her türlü matrisle çarparsak böyle bir sonuç elde edemeyiz. Bu vektörün matrise uygun seçilmesi gereklidir. İşte bu vektöre matrisin öz vektörü buradaki skaler lamda değerine de matrisin özdeğeri denilmektedir. Yalnızca kare matrislerin öz değerleri ve öz vektörleri vardır. Ayrıca her kare matrisin de öz değer ve öz vektörü olmak zorunda değildir. Genel olarak $n \times n$ 'lik bir kare matrisin n tane öz değeri ve öz vektörü vardır.

Öz değerler ve öz vektörler lineer cebirde aşağıdaki biçimde elde edilmektedir. Bu yöntemde önce Lamda değerlerini (yani öz değerleri) buluruz.

$$\begin{aligned} AX &= \lambda X \\ A x - \lambda x &= \emptyset \\ (A - \lambda I) x &= \emptyset \\ (A - \lambda I) x &= \emptyset \\ A - \lambda I &= \emptyset \end{aligned}$$

Bu denklem aslında A nxn'lik bir kare matris olmak üzere n'inci dereceden bir denklem oluşturur. Bu n'inci dereceden denklemin de n tane kökü vardır. Örneğin aşağıdaki matris için lamda öz değerlerini bulmak isteyelim:

$$A = \begin{bmatrix} 2 & 3 \\ 2 & 1 \end{bmatrix}$$

Örneğin:

$$\begin{bmatrix} 2 & 3 \\ 2 & 1 \end{bmatrix} - \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \emptyset$$

$$\begin{bmatrix} 2-\lambda & 3 \\ 2 & 1-\lambda \end{bmatrix} = \emptyset$$

$$(2-\lambda)(1-\lambda) - 6 = \emptyset$$

$$2-2\lambda-\lambda^2+6=0$$

$$\lambda^2-3\lambda-4=0$$

$$\lambda = \{-1, 4\}$$

Göründüğü gibi buradan öz değerler 4 ve -1 biçiminde bulunmuştur. Aslında biz özdeğer bulma işlemini numpy.linalg modülündeki eigvals fonksiyonuyla da yapabiliyoruz:

```
>>> import numpy as np
>>> a = np.array([[2, 3], [2, 1]])
>>> np.linalg.eigvals(a)
array([-1.,  4.])
```

Pekiyi öz vektörler nasıl elde edilmektedir? İşte elimizde öz değerler (yani lamda'lar) varsa biz buradan öz vektörleri elde edebiliriz:

$$\begin{bmatrix} 2 & 3 \\ 2 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \lambda \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

$$2x_1 + 3x_2 = \lambda x_1$$

$$2x_1 + x_2 = \lambda x_2$$

$$(2-\lambda)x_1 + 3x_2 = 0$$

$$2x_1 + (1-\lambda)x_2 = 0$$

Şimdi burada lamda yerine 4 koyarak denklemi çözmeye çalışalım:

$$-2x_1 + 3x_2 = 0$$

$$2x_1 - 3x_2 = 0$$

Göründüğü gibi denklemin sonsuz sayıda kökü vardır. Bunlardan birisi $[3, 2]$ kökleridir. İşte $[3, 2]$ vektörü bir öz vektördür. Ama bunun gibi sonsuz sayıda öz vektör vardır. Lineer cebirde bu denklemi sağlayan bütün vektörlere öz vektör uzayı denilmektedir. Fakat pratikte biz bu sonsuz sayıda öz vektörle ilgilenmemiziz. Mademki öz vektör bizim için

bir doğrultu belirtmektedir. Biz uzunluğu 1 olan normalize edilmiş öz vektörlerle işlemlerimizi yaparız. Bir vektörü normalize etmek için pisagor teoreminden hareketle şu işlemi uygularız:

$$x_1 / \sqrt{x_1^2 + x_2^2}$$

$$x_2 / \sqrt{x_1^2 + x_2^2}$$

Tabii burada nokta sayısı 3 tane olsaydı biz karekök içerisinde üçüncü bileşenin de karesini ekleyecektik. Normalize edilmiş değerler şöyledir:

```
>>> 3 / np.sqrt(3 ** 2 + 2 ** 2)
0.8320502943378437
>>> 2 / np.sqrt(3 ** 2 + 2 ** 2)
0.5547001962252291
```

Şimdi aynı işlemi -1 için yapalım:

$$\begin{bmatrix} 2 & 3 \\ 2 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = -1 \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

$$2x_1 + 3x_2 = -x_1$$

$$2x_1 + x_2 = -x_2$$

$$\begin{array}{l} 3x_1 + 3x_2 = 0 \\ 2x_1 + 2x_2 = 0 \end{array} \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

$$1\sqrt{2}, -1\sqrt{2}$$

```
>>> 1 / np.sqrt(1 ** 2 + (-1) ** 2)
0.7071067811865475
>>> -1 / np.sqrt(1 ** 2 + (-1) ** 2)
-0.7071067811865475
```

Aslında bu normalize edilmiş öz vektörleri biz NumPy'in linalg modülündeki eig fonksiyonuyla elde edebilmekteyiz. Örneğin:

```
>>> a = np.array([[2, 3], [2, 1]])
>>> np.linalg.eig(a)
(array([ 4., -1.]), array([[ 0.83205029, -0.70710678],
   [ 0.5547002 ,  0.70710678]]))
```

eig fonksiyonun bize verdiği vektörler sütun vektörü biçimindedir. Yani yukarıdaki çözümdeki vektörler aslında şöyledir:

$$\begin{bmatrix} 0.83205029 \\ 0.5547002 \end{bmatrix} \begin{bmatrix} -0.70710678 \\ 0.70710678 \end{bmatrix}$$

Öz vektörler bir birine diktir.

BOYUTSAL ÖZELLİK İNDİRİGEMESİ (DIMENSIONALITY FEATURE REDUCTION)

Makine öğrenmesindeki veri tabloları sütunlardan (özelliklerden) oluşmaktadır. Pek çok uygulamada sütun sayısı çok fazla olabilmektedir. Ancak bu sütunlar analiz edildiğinde aslında örneğin bazı sütunların birbirleriyle ilişkili olduğu görülebilmektedir. Örneğin iki sütun söz konusu olsun. Biri diğerinin iki katı değerlere sahip olsun. Aslında öğrenme algoritmaları için bu iki sütunun aynı tabloda bulunması bir kazanç sağlayacağı gibi "overfitting" gibi, "zaman kaybı" ve "işlem miktarı" gibi dezavantajlar doğurmaktadır. Boyutsal özellik indirgemesi demek veri tablosundaki n tane sütun yerine bu n tane sütunu temsil edebilecek $k < n$ koşulunu sağlayan k tane sütun oluşturmak demektir. Örneğin üç sütunlu bir tabloda bu üç sütun yerine bu üç sütunu temsil edeceğini düşündüğümüz iki sütun oluşturabiliriz.

Boyutsal özellik indirgemesi aynı zamanda çok sütunlu öğelerin grafiklerinin çizilmesinde de tercih edilmektedir. İnsan olarak bizler iki değişkenli yani iki boyutlu grafikleri güzel bir biçimde algılayabilmekteyiz. Çünkü iki boyutlu grafikler kağıt üzerinde ya da bilgisayar ekranında görüntülenebilmektedir. Üç boyutlu grafiklerin kağıt üzerinde ya da bilgisayar ekranında görüntülenmesi mümkün olabiliyorsa da çok zahmetlidir. Üç boyuttan yüksek boyuta sahip olan veri tablolarının grafikleri zaten çizilemez. İşte özellik indirgemesi yardımıyla örneğin biz 4 özellikli (sütunlu) bir veri tablosunu iki boyuta indirgeyip onun grafiğini iki boyutlu olarak çizebiliriz.

Özetlersek boyutsal özellik indirgemesi makine öğrenmesinde şu amaçlarla kullanılmaktadır:

- Veri tablosundaki sütunların (özelliklerin) sayısını azaltarak hesaplamalar için gereken zamanı ve bellek alanını azaltmak yani performans kazancı sağlamak.
- Eğitimli öğrenmede overfitting durumunu azaltmak
- Veri tablosunun grafiksel olarak görüntülenmesini sağlamak.

Boyutsal veri indirgemesi için pek çok yöntem kullanılabilmektedir. Örneğin:

- Missing Value Ratio
- Low Variance Filter
- High Correlation Filter
- Random Forest
- Backward Feature Elimination
- Forward Feature Selection
- Factor Analysis
- Principal Component Analysis
- Independent Component Analysis
- Methods Based on Projections
- t-Distributed Stochastic Neighbor Embedding (t-SNE)
- UMAP

Bu yöntemlerden en fazla kullanılan temel bileşenler analizi (principal component analysis) dir.

Boyutsal özellik indirgemesi yöntemleri çeşitli bakımlardan gruplandırılabilmektedir. Biz burada bu yöntemleri iki gruba ayıracagız:

- 1) Orijinal n tane sütundan bazı sütunları atarak k tane ($k < n$) sütun elde etmeye çalışan yöntemler.
- 2) Orijinal n tane sütunun yerine bunlarla ilişkili olan yeni k tane sütun ($k < n$) elde etmeye çalışan yöntemler.

Birinci grup yöntemlerde n tane sütundaki bazı sütunlar çeşitli istatistiksel ölçütler temelinde atılmaktadır. Kalan sütunlar orijinal tablodaki k tane sütundur. İkinci grup yöntemlerde n tane sütunun tamamı başka bir k tane sütunla değiştirilmektedir. Örneğin temel bileşenler analizi (principal component analysis) ikinci grup yöntemlere bir örnektir. Temel bileşenler analizinde biz n tane sütun yerine onları temsil edecek k tane ($k < n$) yeni sütunlar elde ederiz. Şimdi bu iki grup yöntemlerden bazılarını kısaca burada tanıtacağız. Ancak yukarıda da belirtildiği gibi bu alanda en çok tercih edilen yöntem "temel bileşenler analizi (principal component analysis)" yöntemidir. Bu yöntem üzerinde ayrı bir başlıkta daha geniş duracağız.

Eksik Değerli Sütunların Atılması Yöntemi (Missing Value Ratio): Veri tablosundaki bazı sütunlar eksik veriler içerebilmektedir. Örneğin çok kişisel ya da politik birtakım soruların yanıtlarını insanlar vermek istemeyebilirler. Bu durumda bu sorulara ilişkin sütunlarda bilgi eksikliği bulunabilir. İşte bilgi eksikliği belirli bir oranda olan sütunlar tümden atılıp boyutsal bir özellik indirgemesi oluşturulabilmektedir.

Düşük Varyans Filtrelemesi (Low Variance Filtering): Veri tablosundaki bir sütundaki bilgilerin hep aynı olduğunu düşünelim. Böyle bir sütunun tabloda bulunmasının bir faydası olabilir mi? Tabii ki olmaz. Tüm değerleri aynı olan sütunun varyansı 0'dır. Demek ki bir sütunun kestirimde bir faydasının olup olmaması o sütunun varyansıyla da ilgilidir. İşte bu yöntemde bir eşik değeri belirleyip varyansı düşük olan sütunlar tablodan atılabilir. Tabii varyanslar için bir eşik değerinin oluşturulması ayrı bir problemdir. Bu tür durumlarda işlemlerin kolay yürütülebilmesi için önce bir ölçeklendirme (normalizasyon) yapılmaktadır. Örneğin elimizde aşağıdaki gibi bir data.csv dosyası bulunuyor olsun:

```
10,180,3,1345  
10,100,3,3456  
13,125,2,2340  
12,200,9,5250  
10.01,170,7,1980  
10,160,8,2900  
10,120,5,5200
```

Şimdi biz sütunları MinMax ölçeklendirmesine göre ölçeklendirip varyanslarına bakalım:

```
import numpy as np  
  
dataset = np.loadtxt('data.csv', delimiter=',', dtype=np.float32)  
  
from sklearn.preprocessing import MinMaxScaler  
  
mms = MinMaxScaler()  
  
transformed_dataset = mms.fit_transform(dataset)  
col_vars = np.var(transformed_dataset, axis=0)  
print(col_vars)
```

Aşağıdaki gibi bir sonuç elde edilmiştir:

```
[0.14943445 0.11316326 0.13244483 0.1314027 ]
```

Burada atılmaya en uygun sütun birinci indeksli en küçük varyansa sahip sütundur. Tabii iki sütun atmak istersek birinci ve üçüncü indeksli sütunları atmalıyız. Örneğin:

```
reduced_dataset = np.delete(transformed_dataset, [1, 3], axis=1)  
print(reduced_dataset)
```

```
[[0.          0.14285716]
 [0.          0.14285716]
 [1.          0.          ]
 [0.66666665  1.0000001 ]
 [0.00333333  0.71428573]
 [0.          0.8571429 ]
 [0.          0.42857143]]
```

Bu yöntem Scikit-learn kütüphanesinde VarianceThreshold isimli sınıf ile gerçekleştirilmiştir. Bu fonksiyon 0 ile 1 arasında elimine edilecek sütunların düşük varyans limitini parametre olarak almaktadır. Daha sonra elde edilen sınıf nesnesi ile fit ve transform işlemleri yapılabilir. (Bu işlemler tek adımda fit_transform metoduyla da yapılabilmektedir.) Örneğin:

```
import numpy as np

dataset = np.loadtxt('data.csv', delimiter=',', dtype=np.float32)
from sklearn.preprocessing import MinMaxScaler

mms = MinMaxScaler()
transformed_dataset = mms.fit_transform(dataset)

from sklearn.feature_selection import VarianceThreshold

vt = VarianceThreshold(0.13)
reduced_dataset = vt.fit_transform(transformed_dataset)
print(vt.variances_)
print(reduced_dataset)

[0.14943445 0.11316326 0.13244484 0.1314027 ]
[[0.          0.14285716 0.          ]
 [0.          0.14285716 0.540589  ]
 [1.          0.          0.25480154]
 [0.66666665  1.0000001  1.          ]
 [0.00333333  0.71428573 0.16261205]
 [0.          0.8571429  0.39820746]
 [0.          0.42857143 0.98719597]]
```

VarianceThreshold sınıfının kendisi ölçeklendirme yapmamaktadır. Dolayısıyla düşük varyanslı sütunların karşılaşılmalı olarak elimine edilmesi için bizim ölçeklendirme yaptıktan sonra bu sınıfı kullanmamız gereklidir.

Yüksek Korelasyon Filtrelemesi Yöntemi (High Correlation Filtering): Yüksek korelasyona sahip iki sütunun aynı tabloda bulunması makine öğrenmesi modellerinde önemli bir fayda sağlamamaktadır. Örneğin bir sütun diğer sütunun iki katından dört fazla olsun. Bu durumda bu iki sütun arasında doğrusal bir ilişki vardır. Dolayısıyla bu iki sütunun korelasyon katsayısı 1'dir. Bu iki sütunun tablomuzda bir arada bulunmasının kestirimler için bir faydası yoktur. Bunlardan biri tablodan atılabilir. Yüksek korelasyon demekle ne kastedildiği veri bilimcisine bağlıdır. Genellikle burada kastedilen 0.90 ve yukarısıdır. Bu yöntemi Python'da şöyle uygulayabiliriz. Aşağıdaki gibi bir "data.csv" dosyası bulunuyor olsun:

```
10,180,3,302,20,21
10,1790,3,205,20.1,20.2
26,600,2,200,26.2,53
12,1925,9,920,24.1,25
10.1,192,7,710,20.100,20.3
18,28,8,820,20,27
10,890,5,520,20,21
```

```
import numpy as np

dataset = np.loadtxt('data.csv', delimiter=',', dtype=np.float32)
corr = np.corrcoef(dataset, rowvar=False)
```

```

reduced_features = []

for i in range(corr.shape[0]):
    for k in range(corr.shape[1]):
        if i != k and i not in reduced_features and np.abs(corr[i, k]) > 0.90:
            reduced_features.append(i)

print(reduced_features)

reduced_dataset = np.zeros((dataset.shape[0], len(reduced_features)))

for i, col in enumerate(reduced_features):
    reduced_dataset[:, i] = dataset[:, col]

print(reduced_dataset)

```

Burada reduced_features listesi içerisindeki sütun numaraları indirgenmiş olan sütunları belirtmektedir. Yani biz buradaki reduced_features sütunlarını alıp bunlardan yeni bir dataset oluşturmalıyız. Yukarıdaki programdan elde edilen sonuçlar şöyledir:

```

[0, 2, 3, 5]
[[ 10.      3.      302.      21.      ]
 [ 10.      3.      205.      20.20000076]
 [ 26.      2.      200.      53.      ]
 [ 12.      9.      920.      25.      ]
 [ 10.10000038 7.      710.      20.29999924]
 [ 18.      8.      820.      27.      ]
 [ 10.      5.      520.      21.      ]]

```

Göründüğü gibi orijinal dataset'teki iki sütun diğer iki sütunla yüksek bir korelasyona sahip olduğu için atılmıştır. scikit-learn kütüphanesinde doğrudan yüksek varyans indirmesini yapan bir sınıf ya da fonksiyon bulunmamaktadır.

Rassal Ormalar Yöntemi (Random Forests): Rassal ormanlar yöntemi kursumuzda ilerideki konularda ele alınmaktadır.

Geriye Doğru Özellik İndirmesi Yöntemi (Backward Feature Elimination): Bu yöntem eğitimli öğrenme modellerinde uygulanabilmektedir. Bu yöntemde n tane sütun ile modelin başarısı test edilir. Sonra sütunlardan bir tanesi atılarak yeniden modelin başarısına bakılır. Eğer sütun atıldıktan sonra modelin başarısı çok değişmemişse bu sütunun gerçekten atılabilecek bir sütun olduğunu karar verilir. Bu biçimde tüm sütunlar gözden geçirilir. Tabii bu yöntem çok uzun bir bilgisayar zamanına mal olmaktadır. Bu nedenle pratikte pek tercih edilmemektedir.

İleriye Doğru Özellik İndirmesi Yöntemi (Forward Feature Elimination): Bu yöntem geriye doğru özellik indirmesi yönteminin tersidir. Yani modelin başarısı tek bir sütunla başlatılır. Sonra başarıyı daha çok yükselten sütun dahil edilir. Tabii yöntem de eğitimli öğrenmede kullanılabilecek bir yöntemdir. Yine bu yöntem de yüksek bir bilgisayar zamanına yol açmaktadır.

Temel Bileşenler Analizi (Principle Componen Analyses): Bu yöntem izleyen başlıkta ayrıntılı biçimde ele alınmaktadır.

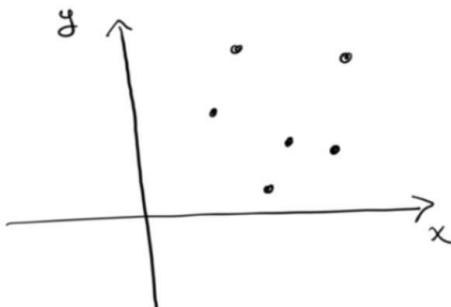
Faktör Analizi Yöntemi (Factor Analysis): Faktör analizi istatistikte ve özellikle sosyal bilimlerde çok kullanılan yöntemlerden biridir. Faktör analizinde bir olguya açıklayabilecek n tane özellik aralarındaki kovaryanslara göre k tane özelliğe indirgenmektedir. Yani birbirlerine benzeyen özellikler atılarak onlar yerine o özellikleri temsil eden yeni bir özellik sınıfı oluşturulmaktadır. Faktör analizi ayrı ve önemli bir konudur. Temel Bileşenler Analizi yöntemi de aslında bir bakıma faktör analizi yöntemi olarak değerlendirilebilmektedir.

Biz kursumuzda boyutsal özellik indirmesini yöntemi olarak "temel bileşenler analizi (principal component analysis)" üzerinde ağırlıklı biçimde duracağız. Bu yöntem izleyen başlıkta açıklanmaktadır.

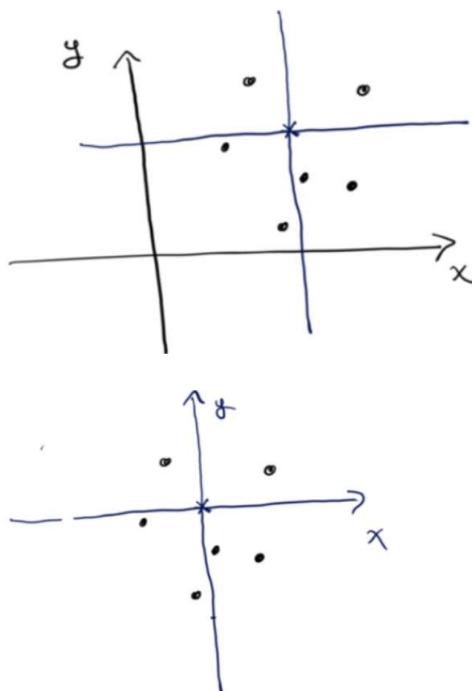
Temel Bileşenler Analizi (Principal Component Analysis)

Yukarıda da belirtildiği gibi boyutsal özellik indirgemesi için en yaygın kullanılan yöntem "temel bileşenler analizi"dir. NumPy'da temel bileşenler analizini uygulayan yetenekli bir sınıf vardır. Bu sınıf sayesinde aslında veri bilimcisi burada açıklanacak manuel hesapları yapmak zorunda kalmaz. Ancak biz burada temel bileşen analizinin manuel bir biçimde nasıl yapıldığı üzerinde biraz duracağız.

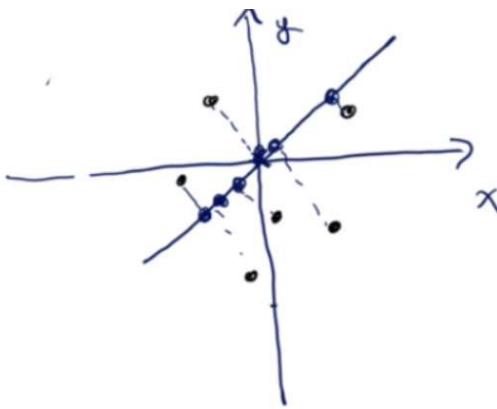
Örneğin iki sütunlu bir veri tablomuz olsun ve bu veri tablosunu tek sütuna indirmek isteyelim. Bu işlemi nasıl yapabiliriz? Buradaki temel mantık iki sütunlu (yani iki bileşene sahip) veri yerine onu temsil edebilecek tek sütunlu (yani tek bileşene sahip) bir veri tablosu oluşturmaktır. Bu yapılrken de orijinal noktaların yeni eksendeki projeksiyonlarının varyansının yüksek tutulması gerekmektedir. Örneğin:



Biz burada x ve y değerlerine sahip iki sütunlu bilgilerin saçılma grafiğini çizdik. Amacımız da bu iki sütunlu bilgi yerine tek sütunlu (yani tek eksenli) değerleri oluşturmaktır. Bunun için uygun bir eksenin seçilmesi gereklidir. İlk yapılacak şey eksenlerin orta noktaya ötelenmesidir. Bu ötemele sonucunda grafiğin şu hale geldiğini varsayalım:



Bundan sonra iki boyutlu noktaların tek boyutlu eksende oluşturulması için (buna "noktaların projekte edilmesi" denilmektedir) uygun bir eksenin seçilmesi gereklidir. Orijin noktasından geçen sonsuz sayıda eksen olabilir. Bizim seçeceğimiz eksenin şöyle bir özelliği olmalıdır: Noktalar bu eksene projekte edildiğinde toplam varyansın en yüksek olması istenir. Başka bir deyişle noktaların orijine olan uzaklıklarını toplamının maksimum olması arzu edilmektedir. Böylece iki boyutlu bilginin daha az kayıpla tek boyuta indirgenmesi sağlanmış olur. Aşağıda böyle bir eksen çizilmiştir:



Pekiyi böyle bir doğrunun denklemi nedir ve projeksiyon bu doğru üzerine nasıl yapılacaktır? İşte bu işlemler daha önce görmüş olduğumuz kovaryans matrisi ve öz değer vektörleri kullanılarak yapılmaktadır. Şimdi bu işlemleri adım adım açıklayalım.

Örneğin N tane sütuna sahip bir veri tablosundan k tane sütuna sahip ($k < n$) bir veri tablosunu temel bileşenler analizi yöntemiyle elde etmek isteyelim. İşlem adımları şöyle gerçekleştirilir:

- 1) Önce N sütunlu veriler üzerinde gerekli özellik ölçeklendirmesi uygulanır.
- 2) N sütunlu matristen $N \times N$ 'lik kovaryans matrisi elde edilir.
- 3) Bu kovaryans matrisinden N tane öz vektör bulunur.
- 4) Bu N tane özvektör arasından k tanesi seçilerek (seçimin nasıl yapılacağı belirtilecektir) asıl matrisle çarpılır ve böylece sonuçta k tane sütuna indirgenmiş veri tablosu elde edilir.

Şimdi bu işlemleri adım adım Python'da yapalım. Bu örneğimizde iki sütunlu tabloyu tek sütuna indirmeye çalışacağımız. İki sutunlu tablonun bilgileri şöyle olsun:

x1	x2
0.72	0.13
0.18	0.23
2.5	2.3
0.45	0.16
0.04	0.44
0.13	0.24
0.30	0.03
2.65	2.1
0.91	0.91
0.46	0.32

Bu bilgilerin "data.csv" isimli dosyada bulunduğu varsayıcağız.

Şimdi ilk yapılacak şey normalize etmek yani orijin noktasını değerlerin ortasına kaydırmaktır. Bu işlem şöyle yapılabılır:

```
import numpy as np

dataset = np.loadtxt('data.csv', delimiter=',', dtype=np.float32)
dataset = dataset - np.mean(dataset, axis=0)
```

Şimdi bu normalize edilmiş 2 boyutlu tablodan 2×2 'lik kovaryans matrisi elde edilir:

```
cmat = np.cov(dataset, rowvar=False)
print(cmat)
```

Elde edilen kovaryans matrisi şöyledir:

```
array([[0.91316003, 0.75931776],
       [0.75931776, 0.69689329]])
```

Bundan sonra bu kovaryans matrisinin öz değerleri ve öz vektörleri bulunur:

```
evals, evecs = np.linalg.eig(cmat)
print(evals)
print(evecs)
```

Elde edilen öz değerler ve öz vektörler şöyledir:

```
[1.57200534 0.03804799]
[[ 0.75530992 -0.65536778]
 [ 0.65536778  0.75530992]]
```

Şimdi bizim projeksiyon işlemini yapmamız gereklidir. Biz asıl ölçeklendirilmiş asıl matrisimizi (biz bu örnekte ölçeklendirme yapmadık, çünkü gerekmedi) nxn'lik özvektör matrisinin k tanesiyle çarptığımızda artık k tane sütunlu bir matris elde ederiz. Buradaki amacımız iki sütunu tek sütuna indirmektedir. Demek ki biz tek bir özvektörle çarpma yaparak tek sütunumuzu elde edeceğiz. Pekiyi n tane öz vektör arasından hangi k tane özvektörü bu çarpma işlemine sokmalıyız? İşte öz değeri yüksek vektörlerin bu işlem için seçilmesi gerekmektedir. Çünkü öz değeri yüksek olan öz vektörler daha yüksek varyansa yol açmaktadır. Yukarıdaki örneğimizde birinci özvektör (1.57 olan) diğerinden daha yüksektir. O halde biz birinci öz vektörü asıl matrisle çarpmalıyız:

```
reduced_dataset = np.matmul(dataset, evecs[:, 0].reshape((-1, 1)))
```

Elde edilen değerler şöyledir:

```
[[ -0.45048978]
 [-0.79282036]
 [ 2.3161099 ]
 [-0.63476248]
 [-0.76093652]
 [-0.8240322 ]
 [-0.83325676]
 [ 2.29833288]
 [ 0.20420599]
 [-0.5223505 ]]
```

Aslında temel bileşenler analizi Scikit-learn kütüphanesinde decomposition modülündeki PCA sınıfıyla kolay bir biçimde yapılmaktadır. PCA sınıfının `__init__` metodunun parametrik yapısı şöyledir:

```
sklearn.decomposition.PCA(n_components=None, copy=True, whiten=False, svd_solver='auto', tol=0.0, iterated_power='auto', random_state=None)
```

Buradaki `n_components` indirgenme sonucunda elde edilecek sütun sayısını belirtmektedir. Diğer parametrelerin çok önemi yoktur.

PCA sınıfının `fit` metodu gerçek hesaplama yapmaktadır. Veri tablosu bu metoda parametre olarak girilir. Ancak `fit` metodu indirgenmiş değerleri bize vermez. (Bu metot PCA nesnesinin yine kendisini bize vermektedir.) Indirgenmiş değerleri almak için ayrıca PCA sınıfının `transform` metodunun çağrılması gerekmektedir. Fakat `fit_transform` isimli metot bu ikisini zaten bir arada yapmaktadır. `inverse_transform` metodu ise işlemin tersini yapmaktadır. Yani bu metot az sütunlu bir tabloyu çok sütunlu hale getirmektedir. Bu işlemin amaçsız olduğu düşünülebilir. Ancak bazı uygulamalarda (örneğin anomalileri tespit etme uygulamalarında) bu metot kullanılmaktadır. Sınıfın iki önemli

özniteliği explained_variance_ ve explained_varience_ratio öznitelikleridir. Bu öznitelikler belirlenen sütun sayısına göre asıl tablonun varyansının ne kadarının indirgenmiş tabloya yansıtıldığını belirtmektedir. explained_variance_ bir değer olarak bunu verirken explained_variance_ratio_ bir yüzde olarak bunu vermektedir.

Şimdi yukarıda elle yaptığımız örneği PCA sınıfı ile yapalım:

```
import numpy as np

dataset = np.loadtxt('data.csv', delimiter=',', dtype=np.float32)
print(dataset, '\n')

from sklearn.decomposition import PCA

pca = PCA(n_components=1)
reduced_dataset = pca.fit_transform(dataset)
print(reduced_dataset, '\n')
print('Explained variance: {}'.format(pca.explained_variance_))
print('Explained variance ratio: {}'.format(pca.explained_variance_ratio_))
```

Burada elde edilen sonuçlar şöyledir:

```
[[ 0.72  0.13]
 [ 0.18  0.23]
 [ 2.5   2.3 ]
 [ 0.45  0.16]
 [ 0.04  0.44]
 [ 0.13  0.24]
 [ 0.3   0.03]
 [ 2.65  2.1 ]
 [ 0.91  0.91]
 [ 0.46  0.32]]

[[ -0.45048997]
 [ -0.7928204 ]
 [  2.31611   ]
 [ -0.6347626 ]
 [ -0.7609365 ]
 [ -0.82403225]
 [ -0.8332568 ]
 [  2.298333  ]
 [  0.20420602]
 [ -0.52235055]]
```

```
Explained variance: [1.572005]
Explained variance ratio: [0.9763685]
```

Açıklanan varyans oranının %97 civarında olduğu görülmektedir. Bu %97 değeri kabaca şu anlamda gelmektedir: Biz iki sütunlu bu tabloyu tek sütuna indirgediğimizde yalnızca %3'lük bir kayıp oluşturduk. Tabii şüphesiz indirgeme sonrasında elde edilecek sütun sayısı azaltıldıkça bu oran düşecektir. Bu oranın iyi bir noktada kalacağı biçimde asıl tablonun kaç sütuna indirgenmesi gereğiği izleyen başlıkta ele alınmaktadır.

Anımsanacağı gibi boyutsal özellik indirgemesi çok boyutlu olguların iki ya da üç boyuta indirgenerek grafiklerinin çizilmesi için de kullanılıyordu. Şimdi biz zambak veritabanında sınıflandırma sonucunda elde edilen 4 sütunlu verileri iki sütuna indirgerek grafiğini çizelim:

```
from sklearn.datasets import load_iris

iris = load_iris()

dataset_x = iris.data
dataset_y = iris.target

from sklearn.cluster import KMeans

km = KMeans(n_clusters=3)
```

```

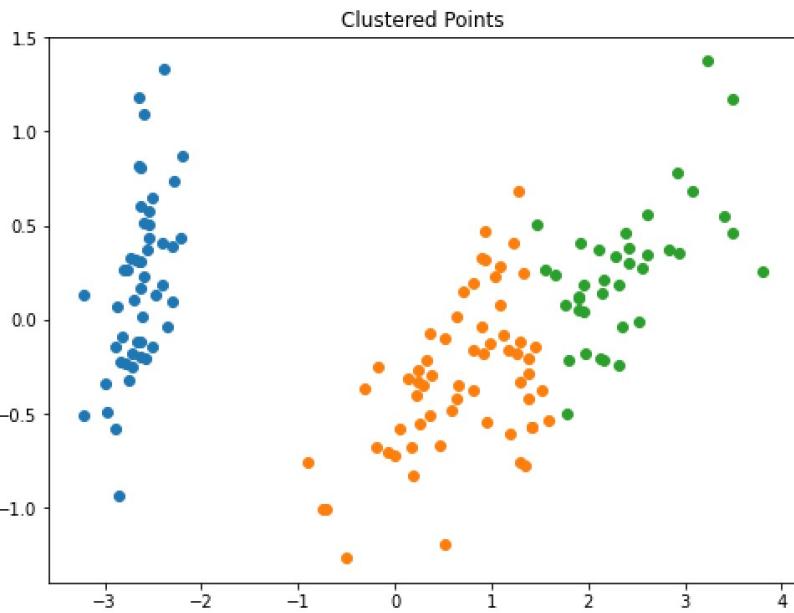
km.fit(dataset_x)

from sklearn.decomposition import PCA
pca = PCA(n_components=2)
reduced_dataset_x = pca.fit_transform(dataset_x)

import matplotlib.pyplot as plt

plt.title('Clustered Points')
figure = plt.gcf()
figure.set_size_inches((8, 6))
for i in range(3):
    plt.scatter(reduced_dataset_x[km.labels_ == i, 0], reduced_dataset_x[km.labels_ == i, 1])
plt.show()

```



Biz bu örnekte aslında dört özelliğe (sütuna) sahip olan Iris verilerini iki kümeye ayırdık. 4 özelliğin grafiğini çizemeyeceğimizden dolayı onu PCA yöntemiyle iki özelliğe indirgeyip grafiğini çizdik.

PCA İşleminde İndirgenecek Sütun Sayısının Belirlenmesi

Elimizde n sütunlu bir veri tablosu olsun. Biz n sütunu PCA yöntemiyle k sütuna indirmek isteyelim. Pekiyi bu k değeri ne olmalıdır? Yani örneğin elimizde 100 sütunlu bir veri tablosu varsa biz bu tabloyu sütuna önemli bir kayıp olmadan kaç sütuna indirmeliyiz? Şüphesiz sezgisel olarak bu 100 sütunun 99 sütuna indirgenmesi ile 10 sütuna indirgenmesi arasında bir farklılık olduğu anlaşılabılır. Biz kabaca indirmeyi ne kadar yüksek yaparsak orijinal verilerin o kadar bozulacağını söyleyebiliriz. O halde "optimum indirgeme için sütun sayısı ne olmalıdır?" sorusu gündeme gelmektedir. İşte bunu belirleyebilmek için iki yöntem önerilmektedir:

- 1)** Açıklanan varyans oranının en çok düşüğü sütun sayısını bulmak. Yani açıklanan varyans eğrisinin eğiminin yatay eksene göre stabil olarak kaldığı noktanın başlangıcı bulmak.
- 2)** Açıklanan varyansın kabaca arzu edilen yüzdede olduğu (örneğin %80) sütun sayısını bulmak.

Birinci yöntem büyük ölçüde gözle kontrol edebilecek bir yöntemdir. İkinci yöntemi programlamak çok kolaydır. İkinci yöntemdeki yüzde değeri duruma göre değiştirilebilir. Örneğin yüzde değeri %80 alınırsa bu durum "orijinal verilerdeki bozulmanın %20 düzeyinde kaldığı en çok sütunlu durumun elde edileceği" anlamına gelmektedir. Şimdi biz bu yöntemleri MNIST verilerinde kullanmaya çalışalım.

```

from tensorflow.keras.datasets import mnist

(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) = mnist.load_data()
dataset_x = training_dataset_x.reshape(-1, 28 * 28)
dataset_x = dataset_x / 255

import numpy as np
from sklearn.decomposition import PCA

ratios = []
optimal_feature = None
for i in range(1, 100):
    pca = PCA(n_components=i)
    pca.fit(dataset_x)
    ratios.append(np.sum(pca.explained_variance_ratio_))
    if not optimal_feature and ratios[-1] >= 0.80:
        optimal_feature = i
print('{}---> {}'.format(i, ratios[-1]))

import matplotlib.pyplot as plt

plt.title('Finding Optimal Components')
figure = plt.gcf()
figure.set_size_inches((30, 10))
plt.plot(ratios, color='red')
plt.plot(ratios, 'bs')
plt.xticks(range(1, 100))

plt.show()

print(optimal_feature)

```

Bu programdan elde edilen veriler aşağıdaki gibidir:

```

0---> 0.0
1---> 0.09704664359411821
2---> 0.16800588405555902
3---> 0.22969677170660122
4---> 0.28359096140493656
5---> 0.33227893102047446
6---> 0.3754012485672624
.....
25---> 0.6917966534434756
26---> 0.7001939613296784
27---> 0.7083190671384518
28---> 0.7161844162745432
29---> 0.723623901698142
30---> 0.7305381991707998
31---> 0.737103904740151
.....
43---> 0.7993004114124839
44---> 0.8032580490108351
45---> 0.8071143109151905
46---> 0.8108497261629446
47---> 0.81449252518249
48---> 0.8180094304518465
.....
59---> 0.850151959089285
60---> 0.8525806719701093
61---> 0.8550143536639044
62---> 0.8573916039952458
63---> 0.8597069516137059
64---> 0.8619171933388575

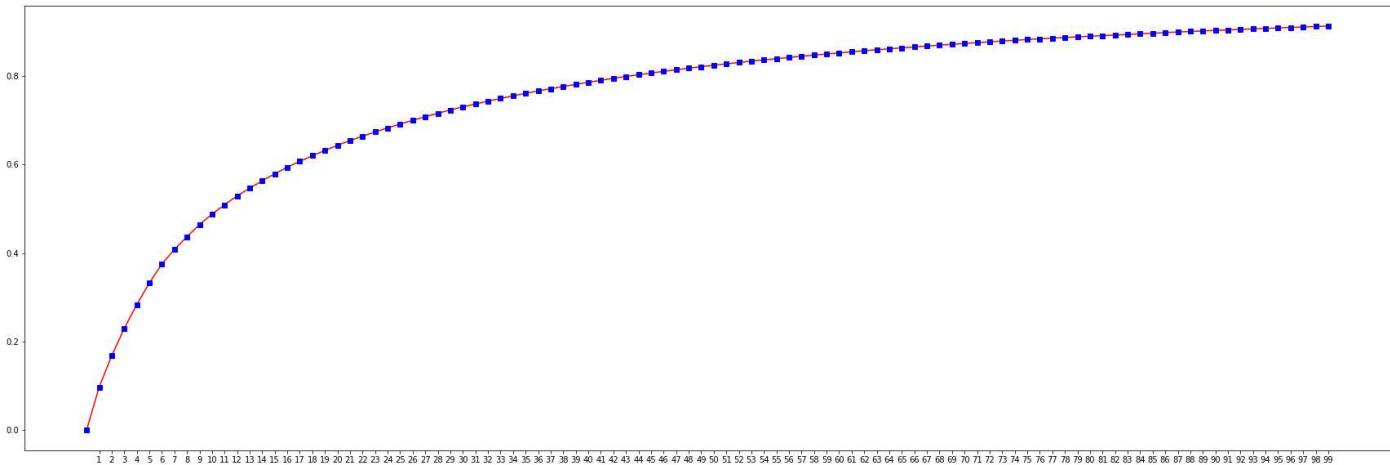
```

```

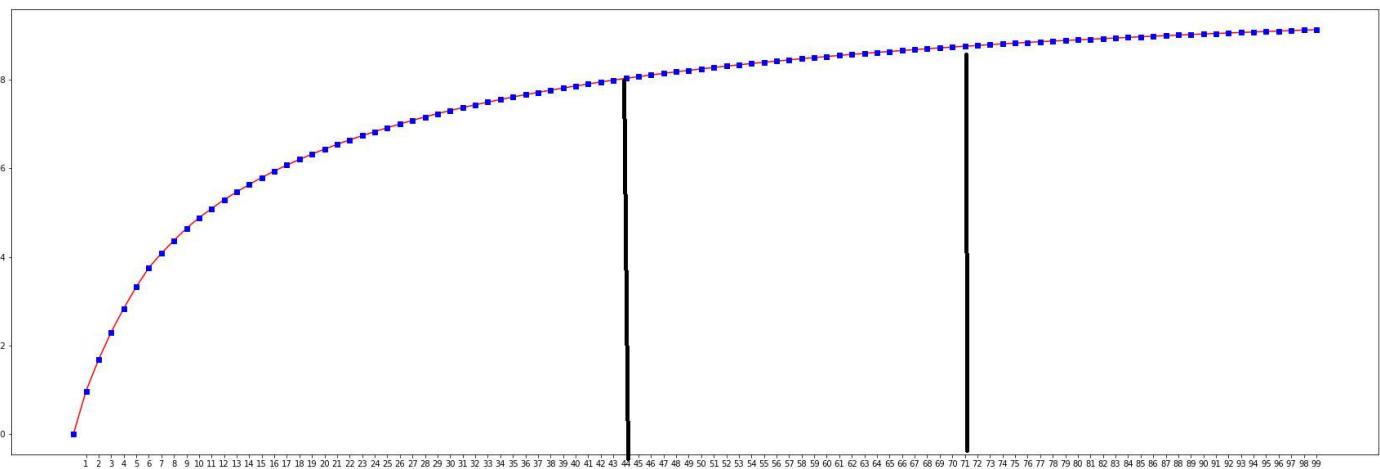
.....
80---> 0.8902214119703338
81---> 0.8916782708014838
82---> 0.892996569814878
83---> 0.8943441647586491
84---> 0.8957344823217974
85---> 0.8972051043024051
86---> 0.8985277299960197
.....
95---> 0.9091421162637744
96---> 0.9101542304308556
97---> 0.9111446067892256
98---> 0.9123344433204897
99---> 0.9132516893488988

```

Burada %80 varyans için elde edilen sütun sayısı 44 olarak bulunmuştur. Elde edilen grafik de şöyledir:



Gözle tespitin yapıldığı birinci yöntem bu grafikte nasıl uygulanabilir? Grafikte artık kazancın iyice düştüğü ve eğrinin eğiminin yatay eksene göre stabil hale geldiği nokta gözle tespit edilebilir. Aşağıdaki çizimde gözle tespit edilen yer ile %80'lik yer gösterilmiştir:



Aslında optimal sütun sayısının elde edilmesi için şöyle bir fonksiyon da yazabiliriz:

```

def optimal_reduction(x, ratio=0.80):
    for i in range(1, x.shape[1]):
        pca = PCA(n_components=i)
        pca.fit(x)
        if np.sum(pca.explained_variance_ratio_) >= ratio:
            return i

```

```
return x.shape[1]

result = optimal_reduction(dataset_x)
print(result)
```

Şimdi MNIST örneğini PCA ile 44 sütuna düşürerek KMeans yöntemiyle kümelendirelim:

```
import numpy as np
from tensorflow.keras.datasets import mnist

(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) = mnist.load_data()

dataset_x = training_dataset_x.reshape(-1, 28 * 28).astype(np.float32)
dataset_x = dataset_x / 255.0

from sklearn.decomposition import PCA

pca = PCA(n_components=44)
reduced_dataset_x = pca.fit_transform(dataset_x)

from sklearn.cluster import KMeans

kmeans = KMeans(n_clusters=10)
kmeans.fit(reduced_dataset_x)
print(kmeans.labels_)
```

ANOMALİLERİN TESPİT EDİLMESİ (ANOMALY DETECTION)

Denetimsiz makine öğrenmesinde popüler konulardan biri de anomalilerin tespit edilmesidir. Bu sayede hiçbir niteliksel bilgiye sahip olmadan hileli işlemleri ve verileri diğerlerinden belli bir güvenilirlikle ayırt edebilmektedir. Dolayısıyla anomalilerin tespit edilmesi konusu şüpheli işlemler, bilgisayar güvenliği, bilgisayar virüsleri, kötü niyetli yazılımların belirlenmesi gibi işlemlerde kullanılabilmektedir. İngilizce anomalilerin tespit edilmesi anlamına gelen çeşitli terimer ve tamlamalar kullanılmaktadır. Bunların bazıları şunlardır: "Anomaly detection", "outliers", "novelties", "noise", "deviations", "exceptions". Biz kursumuzda bu konuya "anomalilerin tespit edilmesi (anomaly detection)" diyeceğiz.

Anomalilerin tespit edilmesi için pek çok yöntem kullanılmaktadır. Bunlardan bazıları şunlardır:

- Yoğunluk Tabanlı Yöntemler (Isolation Forest, K-Nearest Neighbor, vs.)
- Destek Vektör Makineleri (Support Vector Machines)
- Bayes Ağları (Bayesian Networks)
- Saklı Markov Modelleri (Hidden Markov Models)
- Kümeleme Esasına Dayanan Yöntemler (Custering Based Methods)
- Bulanık Mantık Kullanan Yöntemler (Fuzzy Logic Methods)

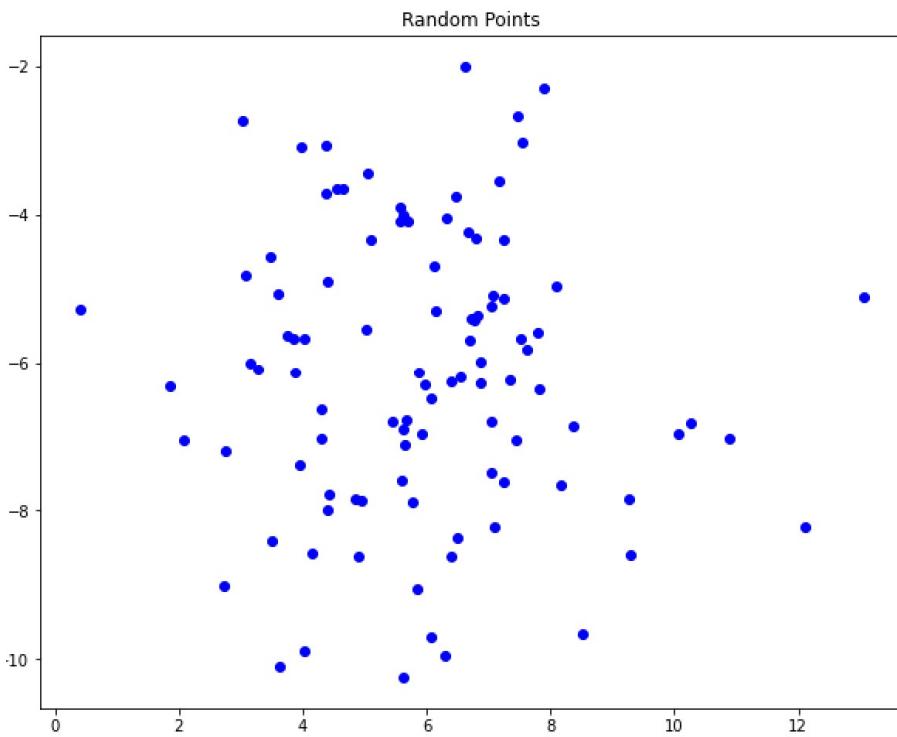
Biz kursumuzda birkaç model üzerinde duracağız.

DBSCAN Kümeleme Yöntemiyle Anomalilerin Tespit Edilmesi

Anımsanacağı gibi DBSCAN yönteminde yoğunluk esas alınmaktadır. Böylece bu yöntem küresel (spherical) kümelerin dışında örneğin eliptik kümeler gibi diğer kümeleri de tespit edebiliyordu. DBSCAN yönteminde noktaların ilişkilendirileceği kume sayısını biz vermiyorduk. Bu kume sayısı zaten algoritmanın işleyışı sırasında otomatik olarak belirleniyordu. Yine bu yöntemde bazı noktalar hiçbir kümeye dahil edilemiyordu. Bu noktalara biz "gürültü (noise)" noktaları diyoruz. İşte DBSCAN yöntemiyle anomali tespitinde uygulamacı sanki bir kümeleme işlemi yapıyormuş gibi işlemlerini yürütür. Gürültü noktaları anomali olarak değerlendirilir.

Şimdi DBSCAN yöntemine bir örnek verelim. Bunun için sklearn.datasets modülü içerisindeki make_blobs fonksiyonuyla rastgele veri kümlesi elde edeceğiz. Anımsanacağı gibi bu fonksiyon istenilen kume sayısına uygun istenilen miktarda rastgele nokta üretmektedir. Biz burada anomali tespiti için kume sayısını 1 alacağız. Örneğin:

```
from sklearn.datasets import make_blobs
dataset, clusters = make_blobs(n_samples=100, cluster_std=2, centers=1)
import matplotlib.pyplot as plt
plt.title('Random Points')
figure = plt.gcf()
figure.set_size_inches((10, 8))
plt.scatter(dataset[:, 0], dataset[:, 1], color='blue')
plt.show()
```



Şimdi DBSCAN algoritmasını çalıştırarak gürültü noktalarını belirleyelim:

```
from sklearn.cluster import DBSCAN

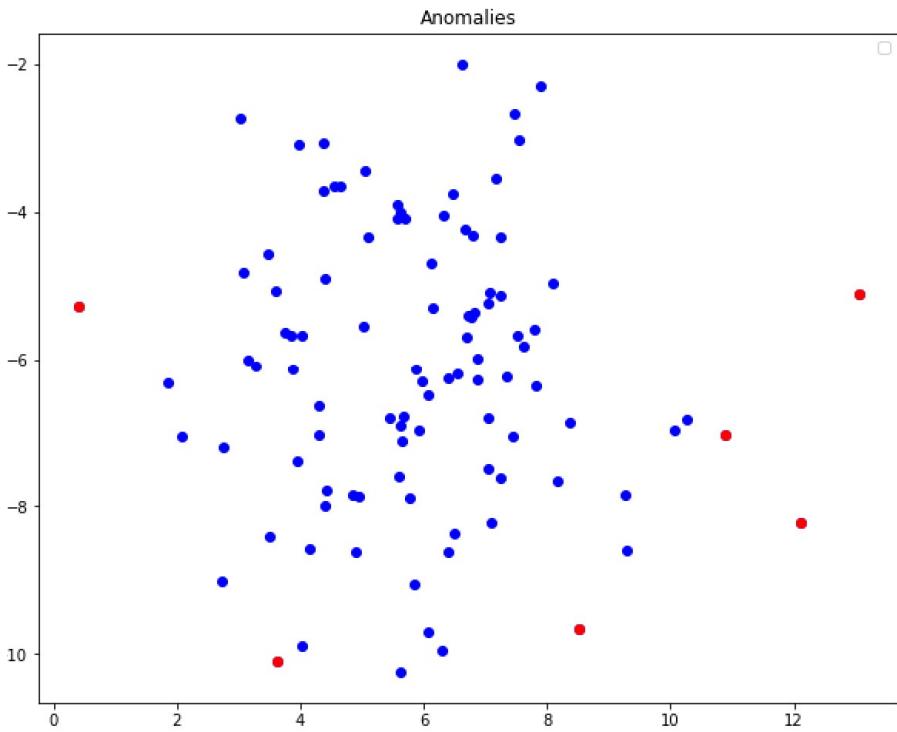
dbs = DBSCAN(eps=1.5, min_samples=5)
dbs.fit(dataset)

anomalies = dataset[dbs.labels_ == -1]
```

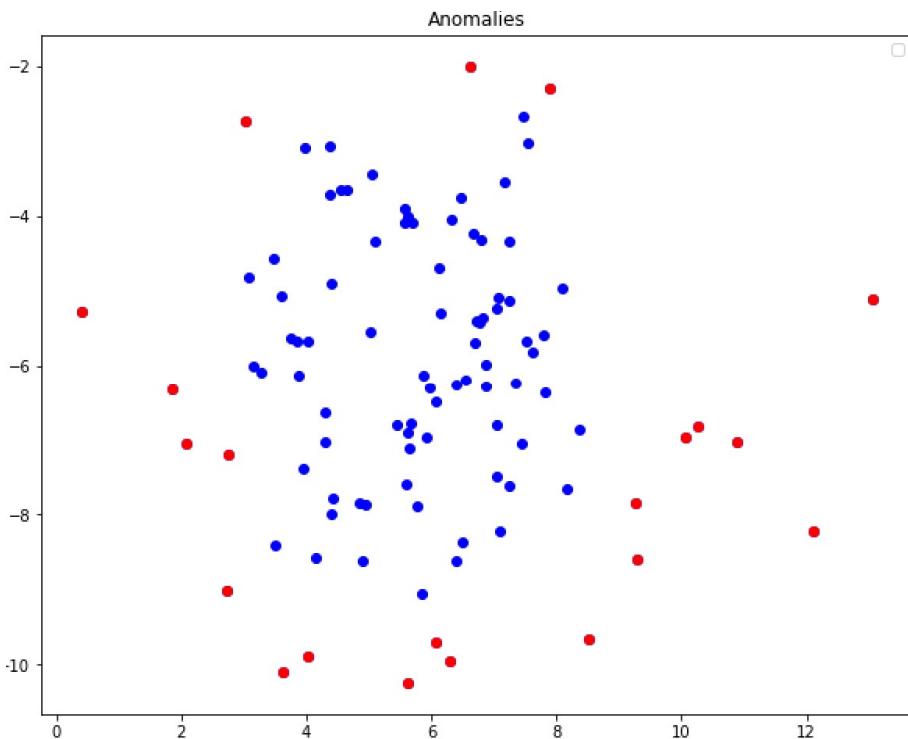
Gürültü noktalarını grafikte gösterelim:

```
import matplotlib.pyplot as plt

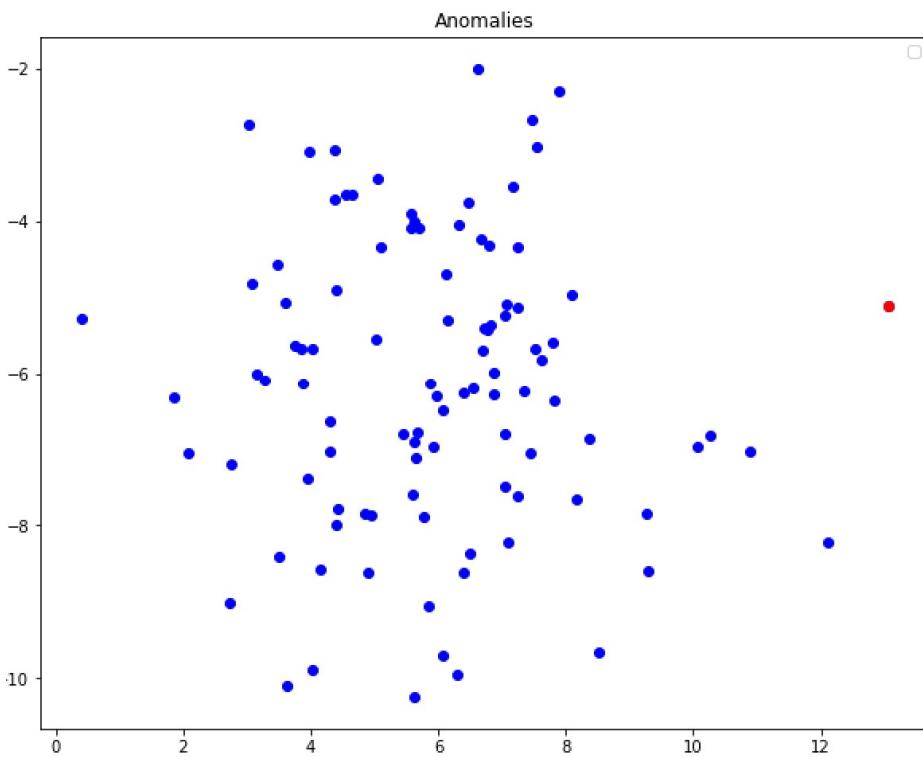
plt.title('Anomalies')
plt.legend(['Normal points', 'Anomalies'])
figure = plt.gcf()
figure.set_size_inches(10, 8)
plt.scatter(dataset[:, 0], dataset[:, 1], color='blue')
plt.scatter(anomalies[:, 0], anomalies[:, 1], color='red')
plt.show()
```



Tabii DBSCAN yöntemini uygularken yoğun belirten epsilon ve min_samples değerlerinin iyi bir biçimde belirlenmesi gereklidir. Anımsanacağı gibi epsilon ve min_samples değeri küçüldükçe gürültü noktalarının sayıları artmaktadır, epsilon ve min_samples değeri yükseldikçe gürültü noktalarının sayıları azalmaktadır. Yukarıdaki örnekte epsilon 1.5 alınmıştır. Epsilon değerini 1'e çekip örneği bir daha çalışıralım:



Şimdi de epsilon'u 2'ye çekip kodumuzu çalışıralım:



Göründüğü gibi epsilon ve min_samples parametrelerinin uygulamacı tarafından ayarlanması gerekmektedir.

OPTICS Kümeleme Yöntemiyle Anomalilerin Tespit Edilmesi

Anımsanacağı gibi OPTICS algoritmasında uygulamacı epsilon değerini değil min_samples değerini belirliyordu. OPTICS sınıfının core_distances_ örnek özniteliği noktaların min_samples kadar noktayı barındıracak biçimde ana nokta (core point) olması için gereken uzaklıkları belirtiyordu. İşte biz OPTICS algoritmasını yalnızca min_samples değerini belirterek çalıştırabiliriz. Sonra bu core_distances_ değerlerine bakarak ana nokta olması en zor olan noktaları belirleyebiliriz. Şimdi yukarıdaki örneği aynı değerlerle OPTICS algoritmasına sokalım:

```
from sklearn.datasets import make_blobs
dataset, clusters = make_blobs(n_samples=100, cluster_std=2, centers=1)
import matplotlib.pyplot as plt
plt.title('Random Points')
figure = plt.gcf()
figure.set_size_inches((10, 8))
plt.scatter(dataset[:, 0], dataset[:, 1], color='blue')
plt.show()

from sklearn.cluster import OPTICS
optics = OPTICS(min_samples=5)
optics.fit(dataset)
```

Şimdi core_distances_ değerlerine bakarak belli uzaklıktaki değerleri anomali olarak değerlendireceğiz. Pekiyi buradaki ölçütümüz ne olacak? İşte belli bir yüzde belirleyebiliriz. Örneğin en uzak %5'lik kısmı alabilirim:

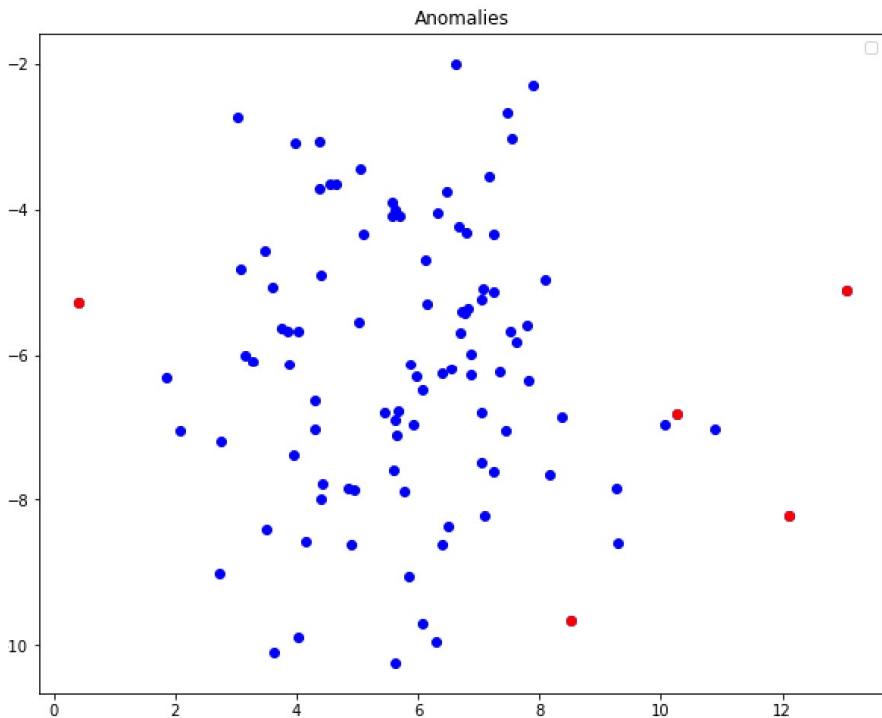
```
ANOMALY_RATIO = 0.05
import numpy as np
q = np.quantile(optics.core_distances_, 1 - ANOMALY_RATIO)
anomalies = dataset[optics.core_distances_ > q]
```

```

import matplotlib.pyplot as plt

plt.title('Anomalies')
plt.legend(['Normal points', 'Anomalies'])
figure = plt.gcf()
figure.set_size_inches((10, 8))
plt.scatter(dataset[:, 0], dataset[:, 1], color='blue')
plt.scatter(anomalies[:, 0], anomalies[:, 1], color='red')
plt.show()

```



KMeans Kümeleme Yöntemiyle Anomalilerin Tespit Edilmesi

Şimdi de K-Means algoritmasıyla anomalileri belirlemeye çalışalım. Anımsanacağı gibi K-Means yönteminde algoritmanın noktaları ayıracığı küme sayısını başlangıçta biz veriyorduk. Algoritma da tüm noktaları kümelere dahil ediyordu. (Yani noktalar ağırlık merkezlerine çok uzak olsalar bile K-Means algoritması yine de bu noktaları bir kümeye dahil etmektedir.) K-Means algoritmasının 1 küme için çalıştırılması size anlamsız gelebilir. Gerçekten de önceki konularda bizim yazdığımız K-Means kodu tek küme için tek bir iterasyonla işlemini sonlandırmaktadır. Ancak K-Means algoritmasının ince versiyonları vardır. Örneğin scikit-learn kütüphanesinin kullandığı K-Means algoritmasında küme sayısı 1 olsa bile algoritma o tek küme için rastgele aldığı ağırlık merkezini iyileştirmektedir. İşte K-Means yoluyla anomali tespitinde algoritma 1 küme için çalıştırılır. Algoritma tüm noktaları o tek kümeye dahil etmeye birlikte o kümenin ağırlık merkezini iyi bir noktaya çeker. Böylece uygulamacı tüm noktaların bu ağırlık merkezine uzaklıklarını hesaplayarak en uzak n tane noktayı anomali olarak belirleyebilir. KMeans sınıfının transform metodunun zaten bu işlemi yaptığını anımsayınız.

Örneğin make_blobs fonksiyonuyla bir küme için ağırlık merkezini bularak noktaların grafiğini çizdirelim (bu işlemlerde yine önceki örneklerdeki make_blobs değerlerini kullanacağız):

```

from sklearn.cluster import KMeans

km = KMeans(n_clusters=1)
distances = km.fit_transform(dataset).ravel()

ANOMALY_RATIO = 0.05

import numpy as np

```

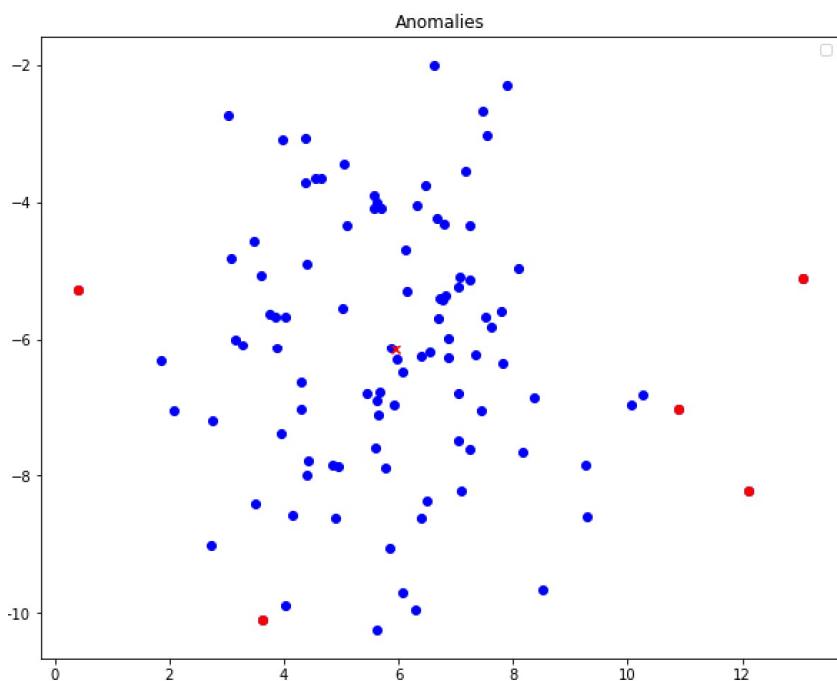
```

q = np.quantile(distances, 1 - ANOMALY_RATIO)
anomalies = dataset[distances > q]

import matplotlib.pyplot as plt

plt.title('Anomalies')
plt.legend(['Normal points', 'Anomalies'])
figure = plt.gcf()
figure.set_size_inches(10, 8)
plt.scatter(dataset[:, 0], dataset[:, 1], color='blue')
plt.scatter(km.cluster_centers_[:, 0], km.cluster_centers_[:, 1], color='red', marker='x')
plt.scatter(anomalies[:, 0], anomalies[:, 1], color='red')
plt.show()

```



Grafikte noktalar, ağırlık merkezi ve anomali noktaları gösterilmiştir.

Özellik İndirgemesi ve Yükseltmesi Yoluyla Anomalilerin Tespit Edilmesi

Şimdi de özellik indirgemesi ve yükseltilmesi yöntemiyle anomali tespiti üzerinde duralım. Bu yöntemde n tane sütünden (özellikten) oluşan veri tabloları üzerinde özellik indirgemesi yapılarak bu n tane sütun k tane sütuna indirgenir. Sonra bu k tane sütun ters dönüşümle yeniden n tane sütuna yükseltilir. Daha sonra orijinal veri tablosuyla indirgenip yükseltilmiş veri tablosu arasında karşılaştırma yapılır. Bu yöntemde önce indirgeme sonra yükselme yapıldığında anomali içeren satırlarda daha ciddi bir farklılaşma oluşmaktadır. Yöntemde indirgeme için genellikle PCA tercih edilse de diğer bazı indirgeme yöntemleri de kullanılabilir.

Peki bu yöntemde indirgenip yükseltilmiş verilerle orijinal verilerin arasındaki farka nasıl bakılmaktadır? Yaygın kullanılan bir yöntem iki vektörel nokta arasındaki farkların karelerinin toplamlarını $[0, 1]$ arasında normalize ederek karşılaştırmaktadır. Örneğin bunun için aşağıdaki gibi bir uzaklık fonksiyonu yazılabilir:

```

def anomaly_scores(original_data, manipulated_data):
    loss = np.sum((original_data - manipulated_data) ** 2, axis=1)
    loss = (loss - np.min(loss)) / (np.max(loss) - np.min(loss))

    return loss

```

Fonksiyonun sonunda değerleri 0 ile 1 arasına getirdik. Aslında bu işlem yapılması da olurdu. Ancak bunu yapmaktan amacımız oransal bir değerin elde etmektedir. Oransal değerler seçim işlemini kolaylaştırmaktadır.

Önce bu yöntemi yukarıdaki make_blobs ile elde ettiğimiz yönteme uygulayalım:

```
from sklearn.datasets import make_blobs

dataset, clusters = make_blobs(n_samples=100, cluster_std=2, centers=1)

import matplotlib.pyplot as plt

plt.title('Random Points')
figure = plt.gcf()
figure.set_size_inches((10, 8))
plt.scatter(dataset[:, 0], dataset[:, 1], color='blue')
plt.show()

from sklearn.decomposition import PCA
pca = PCA(n_components=1)
reduced_dataset = pca.fit_transform(dataset)
inversed_dataset = pca.inverse_transform(reduced_dataset)

def anomaly_scores(original_data, manipulated_data):
    loss = np.sum((original_data - manipulated_data) ** 2, axis=1)
    loss = (loss - np.min(loss)) / (np.max(loss) - np.min(loss))

    return loss

scores = anomaly_scores(dataset, inversed_dataset)

import numpy as np

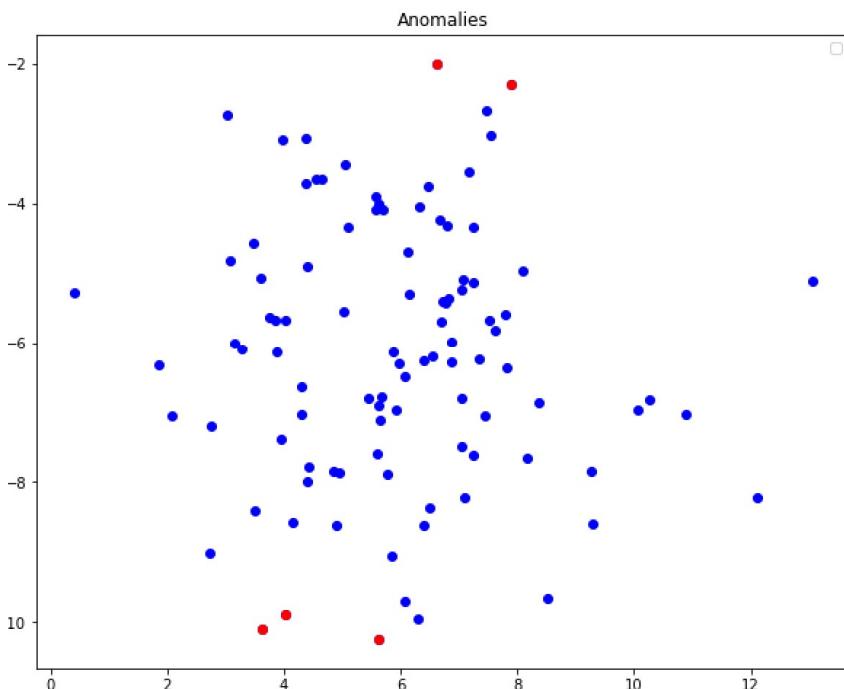
ANOMALY_RATIO = 0.05

q = np.quantile(scores, 1 - ANOMALY_RATIO)
anomalies = dataset[scores > q]

import matplotlib.pyplot as plt

plt.title('Anomalies')
plt.legend(['Normal points', 'Anomalies'])
figure = plt.gcf()
figure.set_size_inches((10, 8))
plt.scatter(dataset[:, 0], dataset[:, 1], color='blue')
plt.scatter(anomalies[:, 0], anomalies[:, 1], color='red')
plt.show()
```

Anomali noktalarının grafiği şöyle elde edilmiştir:



Kredi Kartı İşlemlerindeki Anomalilerin Tespit Edilmesine İlişkin Bir Örnek

Kredi kartı işlemlerinde sahteciliklerle sık karşılaşılmaktadır. Bir işlemin kötü niyetli biçimde gerçekleştirilip gerçekleştirilmemiğine yönelik ipucu anomali tespit yöntemleriyle elde edilebilmektedir. Bu örneğimizde çeşitli kredi kartı işlemlerine ilişkin verilerden hareketle anomalii içeren kredi kartı işlemlerini tespit etmeye çalışacağız.

Veri tablosunu "Kaggle" sitesinden indirerek kullanacağız. Siz de bu tabloyu CSV dosyası olarak <https://www.kaggle.com/mlg-ulb/creditcardfraud> adresinden indirebilirsiniz. (Kursumuzda bu dosya "creditcard.csv" ismiyle indirilmiştir.) "creditcard.csv" dosyası 30 sütundan oluşmaktadır. Dosyanın başında bir başlık kısmı vardır. Eğer dosya doğrudan numpy.loadtxt fonksiyonuyla okunacaksa bu başlık kısmı geçilmelidir. Dosyanın 30'uncu sütunu iki tırnak içerisinde "0" ya da "1" olan yazılarından oluşmaktadır. Bu yazılar ilgili işlemin geçerli mi (0 değeri) yoksa geçersiz mi (1 değeri) olduğunu belirtmektedir. Dolayısıyla bu sütun diğer sütunlardan ayırtılmalıdır. Toplam 284807 tane işlem arasında sahte olanların sayısı 492 tanedir. "creditcard.csv" dosyasının yüklenip kullanıma hazır hale getirilmesi şöyle yapılabilir:

```
import pandas as pd

df = pd.read_csv('creditcard.csv')

dataset_x = df.iloc[:, :-1].to_numpy()
dataset_y = df.iloc[:, -1].to_numpy()
```

Şimdi bu bilgilere KMeans yöntemini uygulayalım:

```
from sklearn.cluster import KMeans

km = KMeans(n_clusters=1)
distances = km.fit_transform(dataset_x).ravel()

ANOMALY_RATIO = 0.05

import numpy as np

q = np.quantile(distances, 1 - ANOMALY_RATIO)
anomalies = dataset_x[distances > q]
```

Buradan dataset_x ve dataset_y isminde iki ndarray elde etmiş olduk. Şimdi dataset_x verilerini PCA ile indirgeyip sonra yükseltelim:

```
from sklearn.decomposition import PCA  
  
pca = PCA(n_components=19)  
reduced_dataset_x = pca.fit_transform(dataset_x)  
inversed_dataset_x = pca.inverse_transform(reduced_dataset_x)
```

Biz şimdi orijinal veri tablosunu (dataset_x) önce 19 sütuna indirgeyip sonra yine 30 sütuna yükselttik. Bu işlemden inversed_dataset_x tablosunu elde ettik. Artık orijinal dataset_x tablosu ile inversed_dataset_x tablosunu yukarıda yazmış olduğumuz anomaly_scores fonksiyonuna sokarak anomali değerlerini elde edebiliriz:

```
scores = anomaly_scores(dataset_x, inversed_dataset_x)
```

Şimdi bu skorlar arasında en yüksek n tanesini (örneğin 1000 tanesini) alalım:

```
sorted_scores = np.argsort(scores)  
anomaly_results = dataset_x[sorted_scores[-1000:]]  
  
anomaly = np.sum(dataset_y[sorted_scores[-fraud_count:]])  
print(anomaly)
```

Burada görüldüğü gibi önce indirgeme sonra yükseltme yapılip orijinal verilerle satır temelinde uzaklık hesaplanmıştır. Elde edilen scores vektörü tek boyutludur ve yalnızca satırların (yani kredi kartı işlemlerinin) anomali değerini barındırır. Biz en yüksek değere sahip olan işlemlerin anomali içeriği varsayımda bulunmuştu. Bu durumda buradaki scores vektörünü sıraya dizersek en kötü n tane değeri kolayca elde edebiliriz. Ancak bu vektörün sıraya dizilmesi orijinal verilerdeki satır ilişkisini bozacaktır. Bu nedenle örneğimizde bu vektör sort etmek yerine bu vektörün indislerini sort ettik. Sonuçta n_components = 19 değeri için en kötü 1000 anomali değeri arasında 314 tane anomalili işlem, en kötü 100 arasında ise 77 tane anomalili işlem yakalanmıştır. Ancak programın her çalıştırılmasında farklı değerler bulunabilmektedir. 1000 tane değer arasında 314 tane şüpheli işlemin yakalanması aslında oldukça başarılıdır. Çünkü zaten veri kümesindeki 284807 işlemin yalnızca 492 tanesi sahtecilik içermektedir.

İSTATİSTİKSEL YÖNTEMLERLE GERÇEKLEŞTİRİLEN DOĞRUSAL VE POLİNOMSAL REGRESYON İŞLEMLERİ

Konularımızı ele almadan önce bir tazeleme yapmak istiyoruz. Daha önce de belirttiğimiz gibi regresyon girdi ile çıktı arasında ilişki kurma sürecidir. Bağımsız değişken birden fazlaysa buna çoklu regresyon (multiple regression), bağımlı değişken birden fazlaysa buna da "çok değişkenli (multivariate) regresyon" denilmektedir. Örneğin x_1, x_2, x_3, x_4, x_5 değerlerinden hareketle bir y değerini bulmak isteyelim. Bu çoklu regresyona bir örnektir. Çünkü burada bulunmak istenen fonksiyon $y = f(x_1, x_2, x_3, x_4, x_5)$ gibi bir fonksiyondur. Ancak x_1, x_2, x_3, x_4, x_5 değerlerinden hareketle biz y_1 ve y_2 değerlerini bulmak istersek bu çok değişkenli regresyona örnektir. Çünkü burada biz $(y_1, y_2) = f(x_1, x_2, x_3, x_4, x_5)$ gibi bir fonksiyonu bulmaya çalışırız. Çok değişkenli regresyon ayrı ayrı yapılan çoklu regresyonla aynı şey değildir. Örneğin biz x_1, x_2, x_3, x_4, x_5 değerlerinden hareketle y_1 ve y_2 değerlerini bulmaya çalışalım. İlk bakışta bu y_1 ve y_2 değerlerinin iki ayrı çoklu regresyon ile elde edilmesi mümkün gibi görülmektedir. Ancak ayrı ayrı yapılan çoklu regresyon tek hamlede yapılan çok değişkenli regresyon aynı sonuçları vermez. Çünkü çok değişkenli regresyonda bağımlı değişkenler de birbirlerini etkileyemektedir. Bu durumda bağımlı değişkenler arasındaki ilişkiyi görmezden gelerek ayrı ayrı çoklu regresyon uygulamak farklı sonuçların elde edilmesine yol açmaktadır.

Önceki bölümlerde regresyonları da aynı zamanda bulunacak fonksiyonun biçimine göre de "doğrusal", "polinomsal", "üstel" gibi sınıflara ayırmıştık. Makine öğrenmesinde en yaygın kullanılan regresyon modeli "çoklu doğrusal regresyon (multiple linear regression)" modelidir. Tekli doğrusal regresyona "basit doğrusal regresyon" da denilmektedir.

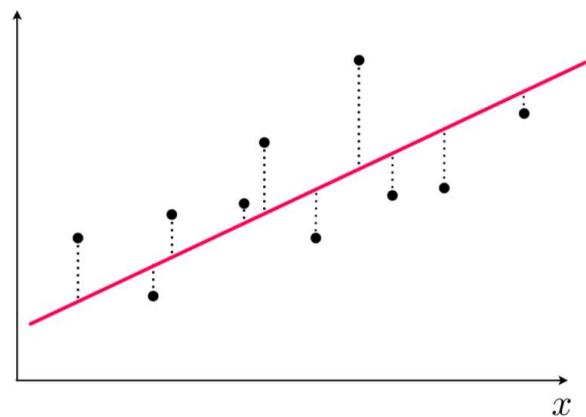
Doğrusal regresyon ile korelasyon arasında önemli bir ilişki vardır. Aralarında korelasyonun sağlam olmadığı değişkenlerde doğrusal regresyon analizi yapmak genellikle uygun olmaz. Bu tür durumlarda regresyon sonucuna dayanılarak yapılan kestirimler başarısız olmaktadır. Bu nedenle doğrusal regresyonun uygunlığını anlamak için önce değerlerin korelasyon katsayılarına bakmak uygun olabilmektedir.

Daha önce biz regresyon problemlerini yapay sinir ağlarıyla çözmüşük. Korelasyonu zayıf olan olgular için yapay sinir ağları oldukça iyi bir yöntem haline gelmektedir. Maalesef karşılaşılan gerçek problemlerin büyük kısmında istatistiksel doğrusal regresyon uygulanamayacak derecede düşük korelasyonlar bulunmaktadır. Bu durumda aralarında düşük korelasyon ilişkisi bulunan, çok fazla değişkenin söz konusu olduğu, değişkenler arasındaki ilişkilerin karmaşık olduğu durumlarda kestirim yöntemi olarak yapay sinir ağları tercih edilmelidir.

Istatistiksel Doğrusal Regresyon

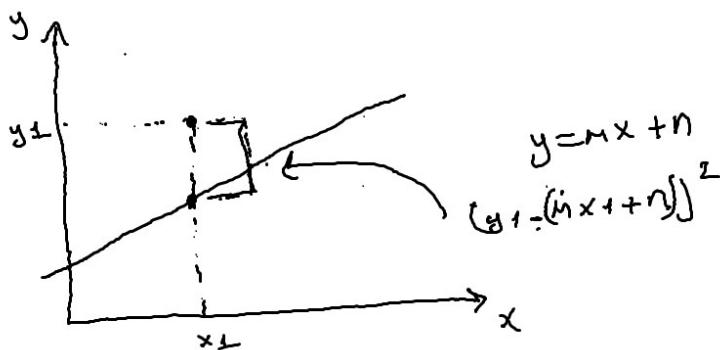
Yukarıda da belirtildiği gibi doğrusal regresyon birtakım noktaları temsil edebilecek bir doğru denkleminin elde edilmesi sürecidir. Örneğin tek bağımsız değişkenli doğrusal regresyonda elde edilmek istenen doğru $y = \beta_0 + \beta_1 x$ biçimindedir. (İstatistikte bu bağlamda katsayılar için $y = mx + n$ ya da $y = a_0 + a_1 x$ gösterimleri yerine β_0 ve β_1 gösterimleri tercih edilmektedir). Burada β_1 doğrunun eğimi (slope), β_0 da doğrunun y eksenini kestiği noktadır (intercept). Çoklu doğrusal regresyon ile tekli doğrusal regresyon (basit doğrusal regresyon) arasında aslında yapılan işlemler bakımından önemli farklılıklar yoktur. Tekli doğrusal regresyon iki boyutlu düzlemdede bir doğru denkleminin elde edilmesi süreciyle çoklu doğrusal regresyon n boyutlu uzayda bir hyperplane denkleminin elde edilmesi sürecidir. Çok boyutlu uzaydaki hyperplane denkleminin $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \dots + \beta_n x_n$ olduğuna dikkat ediniz. Bu durumda n bağımsız değişken için çoklu regresyon analizi sonucunda bizim n + 1'tane değer elde etmemiz gerekmektedir.

Tekli doğrusal regresyondaki (yani basit doğrusal regresyondaki) katsayı değerlerinin elde edilmesi için kullanılan formüle "en küçük kareler (least squares)" formülü denilmektedir. $y = \beta_0 + \beta_1 x$ doğrusundaki β_0 ve β_1 değerlerini veren en küçük kareler formülü aslında söz konusu noktaları en iyi biçimde ortalayan doğruya ilişkin β_0 ve β_1 değerlerini veren formüldür. Burada noktaları en iyi biçimde ortalayan doğru demekle noktaların doğuya uzunlukları toplamını en küçükleyen doğru kastedilmektedir. Bir noktanın koordinatları (x_1, y_1) ise bu noktadan doğuya uzaklık $y_1 - \beta_1 x_1 + \beta_0$ 'dır. $((x_1, y_1)$ noktasının doğru üzerindeki izdüşümündeki x değerinin de x_1 olduğuna dikkat ediniz. Yani ilgili noktadan doğuya dikme indirilmemektedir.)



Alıntı Notu: Görsel https://kenndanielso.github.io/mlrefined/blog_posts/8_Linear_regression/8_1_Least_squares_regression.html adresinden elde edilmiştir.

Burada en küçüklemeye çalışılan şey noktaların doğruya uzaklıklarının toplamıdır. Ancak bu uzaklıklar negatif olabileceğinden dolayı negatiflikten onları kurtarmak için kare alma işlemi uygulanır. Belli bir noktanın buradaki doğruya uzunluğu basit biçimde şöyle hesaplanabilmektedir:



Amaç tüm noktaların doğruya toplam uzaklıklarının en küçükleneceği olduğuna göre x ve y noktaları belirten vektörler olmak üzere en küçüklenecek ifade şöyle oluşturulabilir:

$$\sum_{i=1}^n (y_i - (\beta_1 x_i + \beta_0))^2$$

Bizim buradaki asıl amacımız β_0 ve β_1 değerlerini bulmaktır. Bu işlem matematiksel olarak β_1 ve β_1 'e göre kısmi türevlerinin sıfırlanması ile gerçekleştirilebilir. O halde biz de yukarıdaki ifadenin β_0 ve β_1 'e göre kısmi türevlerini alıp sıfırlayalım ve buradan β_0 ve β_1 'i çekelim:

$$\frac{\partial f}{\partial \beta_1} = -2 \sum (Y - \beta_0 - \beta_1 X)X = 0$$

$$\frac{\partial f}{\partial \beta_0} = -2 \sum (Y - \beta_0 - \beta_1 X) = 0$$

...

$$\beta_1 = \frac{\sum (X - \bar{X})(Y - \bar{Y})}{\sum (X - \bar{X})^2}$$

$$\beta_0 = \frac{\sum Y - \beta_1 \sum X}{len(X)}$$

Bu eşitlikler şöyle de ifade edilebilmektedir:

$$\beta_1 = \frac{N \sum(xy) - \sum x \sum y}{N \sum(x^2) - (\sum x)^2}$$

$$\beta_0 = \frac{\sum y - B_1 \sum x}{N}$$

Tabii aslında bu tek bağımsız değişken için elde edilen formül çok bağımsız değişken için de benzer biçimde uygulanmaktadır. Örneğin yukarıda bizim çıkarttığımız formülde x aslında tek bir değeri değil bir vektörü temsil ediyor olabilir. Bu durumda x ortalama (x üstü çizgi) da aslında her değişkene ilişkin sütunun kendi ortalamasıdır.

Şimdi basit doğrusal regresyon için β_0 ve β_1 değerlerini bulan bir fonksiyon yazalım:

```
import numpy as np

def linear_regression(x, y):
    a = np.sum((x - np.mean(x)) * (y - np.mean(y)))
    b = np.sum((x - np.mean(x)) ** 2)
    b1 = a / b
    b0 = (np.sum(y) - b1 * np.sum(x)) / len(x)

    return b0, b1
```

Şimdi de "test.csv" içerisindeki noktalar için doğrusal regresyon grafiğini çizelim. "test.csv" dosyasının içeriği şöyledir:

```
2,4
3,5
5,7
7,10
7,8
8,12
9.5,10.5
9,15
10,17
13,18
```

Program şöyle oluşturulabilir:

```
import numpy as np

def linear_regression(x, y):
    a = np.sum((x - np.mean(x)) * (y - np.mean(y)))
    b = np.sum((x - np.mean(x)) ** 2)
    b1 = a / b
    b0 = (np.sum(y) - b1 * np.sum(x)) / len(x)

    return b0, b1

dataset = np.loadtxt('test.csv', dtype=np.float32, delimiter=',')
b0, b1 = linear_regression(dataset[:, 0], dataset[:, 1])

x = np.linspace(1, 15, 100)
y = b1 * x + b0

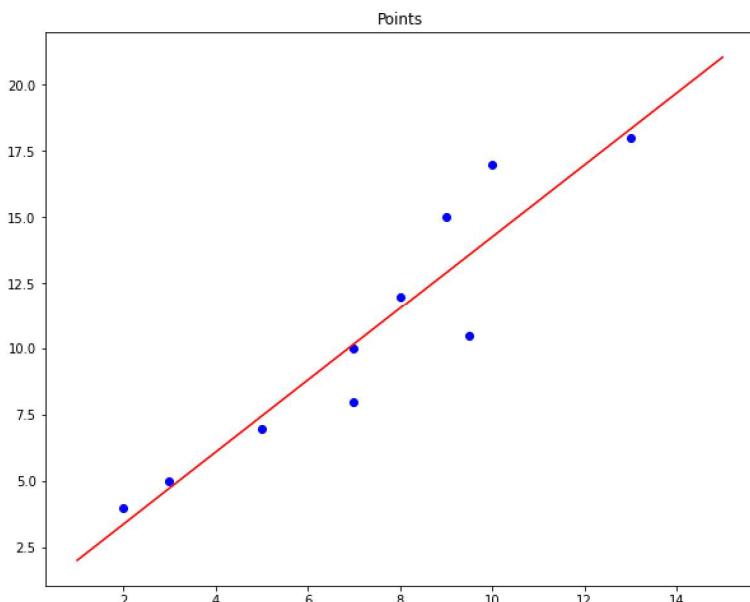
import matplotlib.pyplot as plt

plt.title('Points')
plt.xlabel('x')
plt.ylabel('y')
```

```

figure = plt.gcf()
figure.set_size_inches((10, 8))
plt.scatter(dataset[:, 0], dataset[:, 1], color='blue')
plt.plot(x, y, color='red')
plt.show()

```



Şimdi de interpolasyonla kestirimde bulunalım. Örneğin $x = 11$ için y 'nin değeri nedir?

```

xval = 11
yval = b1 * xval + b0
print(f'{xval} --> {yval}')

```

Şu sonuç elde edilmiştir:

```
11 --> 15.611846947669983
```

Doğrusal regresyon için Scikit-learn kütüphanesinde `linear_model` isimli modülde `LinearRegression` isimli bir sınıf bulunmaktadır. Bu sınıf hem tekli, hem çoklu hem de çok değişkenli regresyon için kullanılabilir. Sınıfın `__init__` metodu şöyledir:

```
class sklearn.linear_model.LinearRegression(fit_intercept=True, normalize=False, copy_X=True, n_jobs=None)
```

`LinearRegression` sınıfı türünden nesne yaratıldıktan sonra sınıfın `fit` metodu ile regresyon işlemi uygulanır. Sınıfın `predict` metodu ise değerleri doğru denkleminde yerine koyarak bize sonucu vermektedir. Doğru denklemdeki katsayıları nesnenin `coef_` isimli özniteligidinden, y eksenini kesim noktasını da `intercept_` isimli özniteligidinden elde edebiliriz. Anımsanacağı gibi çoklu regresyonlarda doğru katsayıları bir tane değil n tanedir. Şimdi yukarıdamanuel olarak yaptığımız doğrusal regresyon örneğini `LinearRegression` sınıfı ile yapalım:

```

import numpy as np

dataset = np.loadtxt('test.csv', dtype=np.float32, delimiter=',')
from sklearn.linear_model import LinearRegression

lr = LinearRegression()
lr.fit(x.reshape(-1, 1), y)
x = np.linspace(1, 15, 100)
y = lr.coef_[0] * x + lr.intercept_

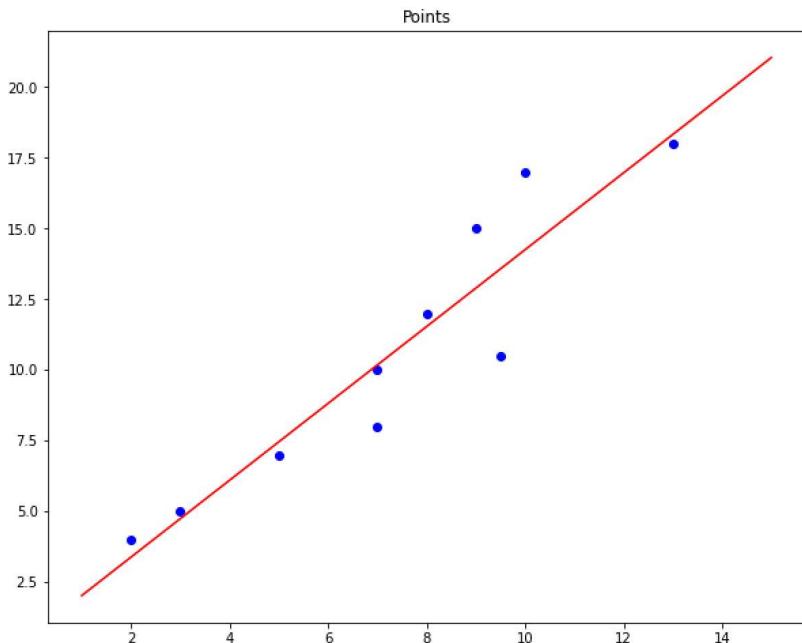
```

```

import matplotlib.pyplot as plt

plt.title('Points')
plt.xlabel('x')
plt.ylabel('y')
figure = plt.gcf()
figure.set_size_inches((10, 8))
plt.scatter(dataset[:, 0], dataset[:, 1], color='blue')
plt.plot(x, y, color='red')
plt.show()

```



Burada fit metodunun iki boyutlu bir matris istediği dikkat ediniz. Çünkü LinearRegression sınıfı çoklu regresyonlarda da kullanılabilir ve kullanılmaktadır. Yukarıdaki örnekte reshape metodu bu amaçla kullanılmıştır. Yukarıdaki örneğimizde x değerleri reshape yapıldıktan sonra aşağıdaki duruma getirilmiştir:

```

array([[ 2. ],
       [ 3. ],
       [ 5. ],
       [ 7. ],
       [ 7. ],
       [ 8. ],
       [ 9.5],
       [ 9. ],
       [10. ],
       [13. ]], dtype=float32)

```

Kestirim işlemi için de sınıfı predict isimli metod bulunmuştur. (Tabii kesitim işlemi coef_ ve intercept_ örnek öznitelikleri ile manuel olarak da yapılabilir.) predict metodu ile kestirimini şöyle yapabiliyoruz:

```

xval = np.array([[11]], dtype=np.float32)
yval = lr.predict(xval)
print(yval)

```

Şu sonuç elde edilmiştir:

```
[15.61184695]
```

Doğrusal regresyon işleminde yapılan regresyonun noktaları ne kadar iyi temsil edebildiğine yönelik R^2 denilen bir ölçüt kullanılmaktadır. R^2 0 ile 1 arasında bir değerdir. R^2 değeri ne kadar yüksekse noktaların doğruya uzunlukları o

kadar kısıdadır. Yani regresyon doğrusu noktalara o kadar yakındır. R^2 değeri düştükçe regresyon doğrusunun noktaları temsil etme yeteneği azalmaktadır. Yani yüksek bir R^2 değeri söz konusu olduğunda bizim yapacağımız kestirim de o kadar iyi olacaktır. R^2 değeri modelin açıkladığı varyansın toplam varyansa oranıdır. Başka bir deyişle R^2 değeri noktaların doğruya olan uzaklıklarının karelerinin toplamının, noktaların kendi ortalamalarına uzaklıklarının karelerinin toplamına oranıdır. Biz burada R^2 değerinin nasıl hesaplanacağı üzerinde durmayacağız. LinearRegression sınıfının score isimli metodu bize R^2 değerini vermektedir. Örneğin yukarıdaki "test.csv" dosyasındaki noktalar için R^2 değeri şöyle elde edilebilir:

```
rsquare = lr.score(dataset[:, 0].reshape(-1, 1), dataset[:, 1])
print(rsquare)
```

0.871811303294605

İstatistiksel Çoklu Doğrusal Regresyon

Bu bölümde istatistiksel çoklu doğrusal regresyon işlemlerinin bazı sorunlarından bahsedeceğiz. Sonra da bazı örnekler üzerinde duracağız.

Çoklu doğrusal regresyon bağımsız değişkenlerle bağımlı değişkenler arasında doğrusal bir ilişkinin olduğu varsayıma dayanmaktadır. Bağımsız değişken ile bağımlı değişken arasındaki ilişkinin doğrusallığının "korelasyon katsayısı" ile ölçüldüğünü anımsayınız. İşte çoklu doğrusal regresyonda bizim veri kümesindeki tüm özellikleri değil yalnızca bağımlı değişken ile yüksek korelasyonu olan özellikleri almamız uygun olmaktadır. Ayrıca çoklu doğrusal regresyonda "özellik ölçeklendirmesinin" genel olarak bir fayda sağlayacağını da belirtmek istiyoruz.

Şimdi de LinearRegression sınıfını kullanarak çoklu doğrusal regresyon örneği verelim. Biz daha önce Boston'daki ev fiyatları tahmin eden örneği yapay sinir ağlarıyla gerçekleştirmiştik. Şimdi Boston örneğini istatistiksel çoklu doğrusal regresyon ile gerçekleştireceğiz. Önce Boston verilerini yükleyelim. Bunun için tensorflow.keras.datasets paketi içerisindeki içerisindeki boston_housing modülünden faydalananabiliriz. Tabii aynı işlemi isterseniz CSV dosyasından hareketle de yapabilirsiniz:

```
from tensorflow.keras.datasets import boston_housing

(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) =
boston_housing.load_data()
```

Şimdi yüksek birbirine yakın koelasyonu olan ve yüksek korelasyonu olan sütunları belirlemeye çalışalım. Bunun için training_dataset_y sütununu da training_dataset_x matrisine ekleyip korelasyon matrisi elde edeceğiz:

```
import numpy as np

dataset = np.concatenate((training_dataset_x, training_dataset_y.reshape(-1, 1)), axis=1)
corcoef = np.corrcoef(dataset, rowvar=False)
```

Korelasyon katsayısını matisel biçimde görüntülemek için seaborn kütüphanesindeki heatmap fonksiyonundan faydalananabiliriz. Bu fonksiyonları renklerle gösterip yüksek korelasyonlu sütunları gözle belirlememize olanak sağlamaktadır:

```
import seaborn as sns
import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches(15, 10)

sns.heatmap(data=corcoef, annot=True)
plt.show()
```

Buradan elde edilen korelasyon grafiği şöyledir:



Burada 13 numaralı sütun bağımlı değişken olan `training_dataset_y` sütunudur. Grafikte açık renkler pozitif yüksek korelasyonları koyu renkler ise negatif yüksek korelasyonları belirtmektedir. Bu bağlamda bizim için korelasyonun pozitif ya da negatif olması değil mutlak değer olarak yüksek olması önemlidir.

Çoklu doğrusal regresyonda tüm sütunların değil bağımlı değişken ile yüksek korelasyonlu sütunların seçilmesinin önemli olduğunu belirtmiştim. Çünkü bu sütunlar bağımlı değişken ile doğrusal ilişki içerisinde olan sütunlardır. Biz yukarıdaki heatmap grafiğinde son sütuna bağımlı değişkeni yerleştirmiştik. Burada 0.40'tan yukarı olan sütunları almak isteyelim. Bu sütunlar 2, 4, 5, 9, 10 ve 12 numaralı sütunlardır. Şimdi bu sütunları kullanarak doğrusal regresyon uygulayalım:

```
from tensorflow.keras.datasets import boston_housing

(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) =
boston_housing.load_data()
from sklearn.linear_model import LinearRegression

lr = LinearRegression()

lr.fit(training_dataset_x[:, [2, 4, 5, 9, 10, 12]], training_dataset_y)
r2 = lr.score(training_dataset_x[:, [2, 4, 5, 9, 10, 12]], training_dataset_y)

print(f'Coefficients = {lr.coef_}')
print(f'Intercept = {lr.intercept_}')
print(f'R2 = {r2}')

predict_result = lr.predict(test_dataset_x[:, [2, 4, 5, 9, 10, 12]])

from sklearn.metrics import mean_absolute_error

mae = mean_absolute_error(predict_result, test_dataset_y)
print(mae)
```

Burada elde edilen katsayılar ve R² değeri şöyledir:

```
Coefficients = [ 1.04354819e-01 -5.32742084e+00  4.33537756e+00 -1.26800692e-03
 -9.04535580e-01 -5.60803648e-01]
```

```
Intercept = 21.407322098588736
R2 = 0.6604563171062072
```

Test verileriyle elde edilen ortalama mutlak hata da (mean absolute error) şöyle bulunmuştur:

```
Mean absolute error = 3.4048143379961573
```

Biz bu örnekte veri kümesindeki 6 özelliği (sütunu) kullandık. Regresyon sonucunda bulduğumuz doğru denkleminin genel biçimini söyledir:

$$y = a_0 + a_1x_1 + a_2x_2 + a_3x_3 + a_4x_4 + a_5x_5 + a_6x_6$$

Burada a_0 değeri sınıfın intercept_ özniteliğinden elde edilmiştir. a_1, a_2, a_3, a_4, a_5 , ve a_6 değerleri ise sınıfın coef_ özniteliğinden elde edilmiştir.

Şimdi aynı örneği tüm sütunları işleme dahil ederek yineleyelim:

```
from tensorflow.keras.datasets import boston_housing
(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) =
boston_housing.load_data()
from sklearn.linear_model import LinearRegression

lr = LinearRegression()

lr.fit(training_dataset_x, training_dataset_y)
r2 = lr.score(training_dataset_x, training_dataset_y)

print(f'R2 = {r2}')

predict_result = lr.predict(test_dataset_x)

from sklearn.metrics import mean_absolute_error

mae = mean_absolute_error(predict_result, test_dataset_y)
print(f'Mean absolute error = {mae}')
```

Buradan elde edilen değerler söyledir:

```
R2 = 0.7399643695249463
Mean absolute error = 3.464185812406726
```

Göründüğü gibi R^2 değeri ve ortalama mutlak hata daha yüksek çıkmıştır. R^2 değerinin daha yüksek çıkması iyi olsa da ortalama mutlak hatanın daha yüksek çıkması modelin tahmin gücünün kötüleştiğini göstermektedir.

Çoklu doğrusal regresyonda önemli problemlerden diğeri de "multi-collinearity" denilen problemdir. Eğer çoklu regresyonu oluşturan özellikler (yani sütunlar) arasında yüksek korelasyon varsa bu durum doğrusal regresyon işlemini olumsuz etkilemektedir. Bu nedenle çoklu doğrusal regresyona başlamadan önce yüksek korelasyon filtrelemesi yapılmalıdır. Yani bizim yüksek korelasyona sahip olan özelliklerin hepsini değil yalnızca birini almamız gereklidir.

Yukarıda çizdirdiğimiz heatmap grafiğine baktığımızda Grafikten 8'inci ve 9'uncu sütunların (0.92), 2'inci ve 4'üncü (0.77) sütunların, Benzer biçimde 4 ile 6 numaralı sütunların (0.73) kendi aralarındaki korelasyonlarının yüksek olduğu görülmektedir. İşte yüksek korelasyonlu sütunların her ikisinin çoklu regresyona sokulması yukarıda belirttiğimiz "multi-collinearity" denilen problemin oluşmasına yol açmaktadır. O halde bizim buradaki sütunların yalnızca bir tanesini işleme sokmamız yerinde olacaktır.

Biz yukarıdaki ilk örnekte 2, 4, 5, 9, 10 ve 12 numaralı sütunları alarak işlemimizi yapmıştık. Buradaki 2 ve 4 numaralı sütunların korelasyonları yüksek olduğu için şimdi bunlardan yalnızca birini alarak aynı programı çalıştırılarım. Bu durumda aşağıdaki sonuçlar elde edilmiştir:

```
from tensorflow.keras.datasets import boston_housing  
  
(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) =  
boston_housing.load_data()  
  
from sklearn.linear_model import LinearRegression  
  
lr = LinearRegression()  
  
lr.fit(training_dataset_x[:, [2, 5, 9, 10, 12]], training_dataset_y)  
r2 = lr.score(training_dataset_x[:, [2, 5, 9, 10, 12]], training_dataset_y)  
  
print(f'R2 = {r2}')  
  
predict_result = lr.predict(test_dataset_x[:, [2, 5, 9, 10, 12]])  
  
from sklearn.metrics import mean_absolute_error  
  
mae = mean_absolute_error(predict_result, test_dataset_y)  
print(f'Mean absolute error: {mae}')
```

Şu sonuçlar elde edilmiştir:

```
R2 = 0.6590017333232043  
Mean absolute error: 3.3686258631211614
```

R^2 değeri kötüleşse de ortalama mutlak hatada küçük bir iyileşme olduğunu göreyorsunuz. Aslında sütunlar arasındaki korelasyonlara bakmak yerine ismine VIF (Variance Inflation Factor) denilen bir yöntem de vardır. Bir sütunun VIF değeri aşağıdaki formülle hesaplanmaktadır:

$$VIF_i = \frac{1}{1 - R_i^2}$$

Burada R_i^2 terimi i'inci sütunun dışındaki sütunların regresyon analizinden elde edilen R^2 değeridir. Biz burada bu formülün anlamı üzerinde durmayacağız. Bunun için başka kaynaklara başvurabilirsiniz. Bir sütunun VIF değeri için şunlar söylenebilmektedir:

- Eğer 1 ise sütunun diğerleri ile korelasyonu yoktur.
- Eğer 1 ile 5 arasında ise sütunun diğer sütunlarla orta derecede bir korelasyonu vardır.
- 5'ten büyük ise sütun diğer sütunlarla yüksek bir korelasyon içерisindedir.

Yüksek bir korelasyon için kesim değeri genellikle 5 alınmaktadır. Yani bu yönteme göre biz VIF değeri 5'ten yüksek olan sütunları atabiliyoruz.

Sütunların VIF değerleri statmodels isimli kütüphanenin statsmodels.stats.outliers_influence modülündeki variance_inflation_factor fonksiyonuyla hesaplanabilmektedir. variance_inflation_factor fonksiyonunun birinci parametresi dataset matrisi, ikinci parametresi de VIF değeri elde edilecek sütunu belirtmektedir.

Şimdi Boston verilerindeki 13 sütun için VIF değerlerini bulalım:

```
from tensorflow.keras.datasets import boston_housing  
  
(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) =  
boston_housing.load_data()
```

```

from statsmodels.stats.outliers_influence import variance_inflation_factor

vifs = [variance_inflation_factor(training_dataset_x, i) for i in
range(training_dataset_x.shape[1])]

for i, vif in enumerate(vifs):
    print(f'{i} ---> {vif}')

```

Şu değerler elde edilmiştir:

```

0 ---> 1.9881877151979828
1 ---> 2.804118579367551
2 ---> 14.145753573906159
3 ---> 1.125530342044093
4 ---> 73.08329671342511
5 ---> 76.61643270931764
6 ---> 22.825374214058293
7 ---> 15.680198501096752
8 ---> 16.922433536136374
9 ---> 67.03752350696183
10 ---> 82.6002684911088
11 ---> 19.408593504685076
12 ---> 10.373716006715824

```

Burada VIF değeri 5'ten küçük olan sütunlar 0, 1 ve 3 numaralı sütunlardır.

Lasso, Ridge ve ElasticNet Regresyon Modelleri

Scikit-learn kütüphanesindeki LinearRegression sınıfı giriş bölümünde de bahsetmiş olduğumuz en küçük kareler yöntemini uygulamaktadır. Bu en küçük kareler yönteminin üç farklı varyasyonu daha vardır. Bu varyasyonlara "Lasso Regresyonu", "Ridge Regresyonu" ve "ElasticNet Regresyonu" denilmektedir. Lasso, Ridge ve ElasticNet regresyon modelleri aslında en küçük kareler yönteminin ceza terimleri eklenmiş biçimleridir. Bazı durumlarda klasik en küçük kareler yöntemi yerine bu varyasyonları kullanmak daha uygun olmaktadır.

Lasso regresyonunda eklenen ceza mutlak değer içermektedir. Bu mutlak değerli ceza terimine L1 düzenlemesi (L1 regulation) denilmektedir:

$$\sum_{i=1}^n (Y_i - \sum_{j=1}^p X_{ij}\beta_j)^2 + \lambda \sum_{j=1}^p |\beta_j|$$

Aıntı Notu: Görsel <https://towardsdatascience.com/l1-and-l2-regularization-methods-ce25e7fc831c> adresinden alınmıştır.

Lasso regresyonu bağımlı değişken ile yüksek korelasyonu olmayan sütunların ve aralarında yüksek korelasyon bulunan sütunları elimine edebilmektedir. Yani bu anlamda Lasso regresyonu kendi içerisinde bir "özellik seçimi (feature selection)" de uygulamaktadır. Böylece çok sayıda sütunun bulunduğu karmaşık çoklu regresyonlarda Lasso regresyonunun seçilmesi en küçük kareler yöntemine göre daha iyi bir sonucun elde edilmesine yol açılmaktedir. Lasso regresyonunda bizim özellik seçimi uygulamamıza gerek kalmadığınıza dikkat ediniz. Çünkü Lasso regresyonu özellik seçiminin kendisi yapmaktadır.

Lasso regresyonu Scikit-learn kütüphanesinde sklearn.linear_model modülündeki Lasso sınıfı ile temsil edilmiştir. Sınıfın __init__ metodunun parametrik yapısı şöyledir:

```

class sklearn.linear_model.Lasso(alpha=1.0, *, fit_intercept=True, normalize='deprecated',
precompute=False, copy_X=True, max_iter=1000, tol=0.0001, warm_start=False, positive=False,
random_state=None, selection='cyclic')

```

Buradaki en önemli parametre ceza teriminde lamda ile gösterdiğimiz alpha parametresidir. Bu parametrenin default durumda 1 olduğunu görürsünüz. alpha parametresi düşürülürse özellik seçimi azaltılmakta, yükseltilirse özellik

seçimi artırılmaktadır. alpha parametresi 0 yapıldığında Lasso regresyonunun en küçük kareler regresyonundan bir farkı kalmamaktadır. Lasso sınıfının diğer kullanımı tamamen LinearRegression sınıfına olduğu gibidir.

Şimdi Boston verileri ile Lasso regresyonu uygulayalım:

```
from tensorflow.keras.datasets import boston_housing  
  
(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) =  
boston_housing.load_data()  
from sklearn.linear_model import Lasso  
  
lasso = Lasso()  
lasso.fit(training_dataset_x, training_dataset_y)  
  
r2 = lasso.score(test_dataset_x, test_dataset_y)  
  
predict_result = lasso.predict(test_dataset_x)  
  
from sklearn.metrics import mean_absolute_error  
  
mae = mean_absolute_error(predict_result, test_dataset_y)  
  
print(f'R2 = {r2}')  
print(f'Mean absolute error = {mae}')
```

Şu sonuç elde edilmiştir:

```
R2 = 0.6898070950696363  
Mean absolute error = 3.4053070968148784  
Coefficients = [-0.06179437  0.06205298 -0.          0.          -0.          0.  
  0.04384185 -0.45530823  0.27444509 -0.01546212 -0.63152917  0.00805141  
 -0.80926677]
```

Doğru denklemindeki değişkenlerin katsayılarının bazılarının sıfırlandığına dolayısıyla modelden atıldığına dikkat ediniz. Biz burada alpha değerini default değer olan 1 aldık. Şimdi alpha değerini 0.5'e düşürerek yeniden deneyelim:

```
from tensorflow.keras.datasets import boston_housing  
  
(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) =  
boston_housing.load_data()  
  
import numpy as np  
from sklearn.linear_model import Lasso  
from sklearn.metrics import mean_absolute_error  
  
for alpha in np.arange(0, 1.5, 0.1):  
    rounded_alpha = round(alpha, 1)  
    lasso = Lasso(rounded_alpha)  
    lasso.fit(training_dataset_x, training_dataset_y)  
  
    r2 = lasso.score(test_dataset_x, test_dataset_y)  
  
    predict_result = lasso.predict(test_dataset_x)  
    mae = mean_absolute_error(predict_result, test_dataset_y)  
  
    print(f'Alpha = {rounded_alpha}')  
    print(f'R2 = {r2}')  
    print(f'Mean absolute error = {mae}')  
    print('-----')
```

Şu sonuçlar elde edilmiştir:

```

Alpha = 0.0
R2 = 0.7213535934621554
Mean absolute error = 3.464185812406717
-----
Alpha = 0.1
R2 = 0.7398935022179378
Mean absolute error = 3.3549345605161403
-----
Alpha = 0.2
R2 = 0.7464112357066792
Mean absolute error = 3.2284662275991276
-----
Alpha = 0.3
R2 = 0.7439214326662168
Mean absolute error = 3.203516962392463
-----
Alpha = 0.4
R2 = 0.7392904848152486
Mean absolute erro = 3.2037518831429543
-----
Alpha = 0.5
R2 = 0.7336306646805897
Mean absolute error = 3.223212235565337
-----
Alpha = 0.6
R2 = 0.7269388249633093
Mean absolute error = 3.2459136784180878
-----
Alpha = 0.7
R2 = 0.7192161550894022
Mean absolute error = 3.274148940150287
-----
Alpha = 0.8
R2 = 0.7104627103909433
Mean absolute error = 3.308700128874368
-----
Alpha = 0.9
R2 = 0.7006805194349739
Mean absolute error = 3.354609593903275
-----
Alpha = 1.0
R2 = 0.6898070950696363
Mean absolute error = 3.4053070968148784
-----
Alpha = 1.1
R2 = 0.6779031271992308
Mean absolute error = 3.4620826221567222
-----
Alpha = 1.2
R2 = 0.6649964840600084
Mean absolute error = 3.5190438246719133
-----
Alpha = 1.3
R2 = 0.6616660190721735
Mean absolute error = 3.539611962387601
-----
Alpha = 1.4
R2 = 0.6582817326026693
Mean absolute error = 3.5591636414065118

```

Burada alpha parametresinin 0.2 ve 0.3 değerleri için daha iyi bir sonuç elde edildiğini görüyorsunuz. Pekiyi Lasso regresyonundaki alpha (formülüümüzdeki lamda) parametresi nasıl belirlenmelidir? Maalesef bunun pratik bir yolu

yoktur. Bunun için yukarıda yaptığımız gibi değişik alpha değerleri ile sonuçlara bakıp seçimi bu değerlere göre yapabilirsiniz.

Ridge regresyonu en küçük karelere ilişkin loss fonksiyonuna mutlak değer değil karesel bir ceza terimi (penalty term) eklemektedir. Bu terimin eklenmesine genel olarak L2 düzenlenmesi (L2 regulation) denilmektedir:

$$\sum_{i=1}^n (y_i - \sum_{j=1}^p x_{ij}\beta_j)^2 + \lambda \sum_{j=1}^p \beta_j^2$$

Alıntı Notu: Görsel <https://towardsdatascience.com/l1-and-l2-regularization-methods-ce25e7fc831c> adresinden alınmıştır.

Buradaki formülün sarıyla boyanmamış kısmı en küçük kareler yönteminin terimlerini oluşturmaktadır. Formüldeki lamda parametresinin seçimi önemli olmaktadır. Eğer lamda çok küçük seçilirse yöntem klasik en küçük kareler yöntemine benzer. Lamda çok büyük seçilirse de bu kez "underfitting" oluşabilmektedir. Ridge regresyonu da bağımlı değişken ile yüksek korelasyonu olmayan sütunların ve aralarında yüksek korelasyona sahip sütunların etkisini azaltmaktadır. Ancak Ridge regresyonu aslında gereksiz sütunları tam olarak atmamakta yalnızca onların etkilerini azaltmaktadır.

Scikit-learn kütüphanesinde Ridge regresyonu sklearn.linear_model modülündeki Ridge sınıfıyla temsil edilmiştir. Ridge sınıfının `__init__` metodunun parametrik yapısı şöyledir:

```
class sklearn.linear_model.Ridge(alpha=1.0, *, fit_intercept=True, normalize='deprecated',
copy_X=True, max_iter=None, tol=0.001, solver='auto', positive=False, random_state=None)
```

Şimdi Boston örneğini default değer olan alpha = 1 için deneyelim:

```
from tensorflow.keras.datasets import boston_housing

(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) =
boston_housing.load_data()

from sklearn.linear_model import Ridge

ridge = Ridge()
ridge.fit(training_dataset_x, training_dataset_y)

r2 = ridge.score(test_dataset_x, test_dataset_y)

predict_result = ridge.predict(test_dataset_x)

from sklearn.metrics import mean_absolute_error

mae = mean_absolute_error(predict_result, test_dataset_y)

print(f'R2 = {r2}')
print(f'Mean absolute error = {mae}')
print(f'Coefficients = {ridge.coef_}'')
```

Şu sonuçlar elde edilmiştir:

```
R2 = 0.729131232028436
Mean absolute error = 3.402405404574685
Coefficients = [-1.14888464e-01  5.94704490e-02 -3.49394006e-02  3.88595860e+00
 -1.12134334e+01  3.46916452e+00 -6.95864636e-05 -1.57156750e+00
  3.21228523e-01 -1.29882213e-02 -7.97302562e-01  9.45780279e-03
 -5.65040927e-01]
```

Burada katsayırlara baktığımızda onların sıfırlanmadığını ama sıfıra yaklaştığını (yani etkisinin oldukça azaltıldığını) görüyoruz. Şimdi alpha değerlerini değiştirerek Lasso regresyonundaki benzer denemeleri yapalım:

```

from tensorflow.keras.datasets import boston_housing

(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) =
boston_housing.load_data()

import numpy as np
from sklearn.linear_model import Ridge
from sklearn.metrics import mean_absolute_error

for alpha in np.arange(0, 1.5, 0.1):
    rounded_alpha = round(alpha, 1)
    ridge = Ridge(rounded_alpha)
    ridge.fit(training_dataset_x, training_dataset_y)

    r2 = ridge.score(test_dataset_x, test_dataset_y)

    predict_result = ridge.predict(test_dataset_x)
    mae = mean_absolute_error(predict_result, test_dataset_y)

    print(f'Alpha = {rounded_alpha}')
    print(f'R2 = {r2}')
    print(f'Mean absolute error = {mae}')
    print('-----')

```

Şu sonuçlar elde edilmiştir:

```

Alpha = 0.0
R2 = 0.7213535934621557
Mean absolute error = 3.4641858124067118
-----
Alpha = 0.1
R2 = 0.7230701486703126
Mean absolute error = 3.4485597162319546
-----
Alpha = 0.2
R2 = 0.7244023344258351
Mean absolute error = 3.435759991188835
-----
Alpha = 0.3
R2 = 0.7254561180726031
Mean absolute error = 3.4263462608376005
-----
Alpha = 0.4
R2 = 0.7263041375670568
Mean absolute error = 3.4190724776998045
-----
Alpha = 0.5
R2 = 0.7269973803671559
Mean absolute error = 3.4136527694521206
-----
Alpha = 0.6
R2 = 0.7275723842437185
Mean absolute error = 3.408707162548558
-----
Alpha = 0.7
R2 = 0.7280558122232679
Mean absolute error = 3.4041627434454993
-----
Alpha = 0.8
R2 = 0.7284674367370297
Mean absolute error = 3.4014387510705855
-----
```

```

Alpha = 0.9
R2 = 0.7288221319853339
Mean absolute error = 3.4019929049462276
-----
Alpha = 1.0
R2 = 0.729131232028436
Mean absolute error = 3.402405404574685
-----
Alpha = 1.1
R2 = 0.7294034739119166
Mean absolute error = 3.4026958248951207
-----
Alpha = 1.2
R2 = 0.7296456637003335
Mean absolute error = 3.402880470374586
-----
Alpha = 1.3
R2 = 0.7298631540345548
Mean absolute error = 3.402973027300957
-----
Alpha = 1.4
R2 = 0.7300601913199961
Mean absolute error = 3.40321319276012
-----
```

Gördüğünüz gibi bu örnekle bazı sütunların tamamen atılmasını sağlayan Lasso regresyonu daha tatmin edici sonuçların elde edilmesini sağlamıştır.

Yukarıdaki örnekte olduğu gibi pek çok durumda sütunların tamamen atılması daha iyi sonuç verse de bazı uygulamalarda daha iyi sonuç vermemektedir. Lasso regresyonu ile Ridge regresyonu arasında bir seçim yapmak durumunda kaldığınızda Lasso regresyonunu seçebilirsiniz. Ancak en iyi yöntem problemi her iki yöntemle de çözüp verileriniz için daha iyi sonuç veren yöntemi tercih etmek olacaktır.

ElasticNet regresyonu Lasso ve Ridge regresyonunun hibrit bir biçimidir. Bu regresyonda regülasyon terimi hem Lasso hem de Ridge regülasyonlarını (yani L1 ve L2 regülasyonlarını) içermektedir.

ElasticNet regresyonu Scikit-learn kütüphanesinde ElasticNet isimli sınıfı temsil edilmektedir. Sınıfın `__init__` metodunun parametrik yapısı şöyledir:

```
class sklearn.linear_model.ElasticNet(alpha=1.0, *, l1_ratio=0.5, fit_intercept=True,
normalize='deprecated', precompute=False, max_iter=1000, copy_X=True, tol=0.0001,
warm_start=False, positive=False, random_state=None, selection='cyclic')
```

ElasticNet regresyonunda ceza terimi için alpha ve l1_ratio isimli iki çarpan kullanılmaktadır. Alpha parametresi Lasso ve Ridge regresyonunaki alpha çarpanını belirtmektedir. l1_ratio parametresi 0 ile 1 arasında olmalıdır. l1_ratio eğer 0 alınırsa bu durum tamamen Ridge regresyonuna, 1 olursa da bu durumda Lasso regresyonuna benzemektedir. Bu değer $0 < \text{l1_ratio} < 1$ biçimine 0 ile 1 arasında alındığında ceza terimi Lasso ve Ridge regresyonunun (yani L1 ve L2 regülasyonunun) hibrit bir biçimini almaktadır.

Şimdi Boston örneğini alpha = 1 ve l1_ratio = 0.5 default değerleri ile gerçekletirelim:

```
from tensorflow.keras.datasets import boston_housing

(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) =
boston_housing.load_data()

from sklearn.linear_model import ElasticNet

elastic = ElasticNet()
elastic.fit(training_dataset_x, training_dataset_y)
```

```

r2 = elastic.score(training_dataset_x, training_dataset_y)

predict_result = elastic.predict(test_dataset_x)

from sklearn.metrics import mean_absolute_error

mae = mean_absolute_error(predict_result, test_dataset_y)

print(f'R2 = {r2}')
print(f'Mean absolute error = {mae}')

```

Elde edilen sonuçlar şöyledir:

```

R2 = 0.679487679418803
Mean absolute error = 3.3959782432654526

```

Şimdi alpha değerini 0.5'te tutup l1_ratio değerini değiştirerek denemelerimizi yapalım:

```

from tensorflow.keras.datasets import boston_housing

(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) =
boston_housing.load_data()

import numpy as np
from sklearn.linear_model import ElasticNet
from sklearn.metrics import mean_absolute_error

for l1_ratio in np.arange(0, 1, 0.1):
    rounded_l1_ratio = round(l1_ratio, 1)
    elastic = ElasticNet(alpha=0.5, l1_ratio=rounded_l1_ratio)
    elastic.fit(training_dataset_x, training_dataset_y)

    r2 = elastic.score(test_dataset_x, test_dataset_y)

    predict_result = elastic.predict(test_dataset_x)
    mae = mean_absolute_error(predict_result, test_dataset_y)

    print(f'l1_ratio = {rounded_l1_ratio}')
    print(f'R2 = {r2}')
    print(f'Mean absolute error = {mae}')
    print('-----')

```

Şu değerler elde edilmiştir:

```

l1_ratio = 0.0
R2 = 0.712790266919328
Mean absolute error = 3.371395759289885
-----
l1_ratio = 0.1
R2 = 0.7138272369099639
Mean absolute error = 3.3609324943916206
-----
l1_ratio = 0.2
R2 = 0.7150296991190546
Mean absolute error = 3.3488988331953857
-----
l1_ratio = 0.3
R2 = 0.7163758976678496
Mean absolute error = 3.3356338067921723
-----
l1_ratio = 0.4
R2 = 0.7178908178844765

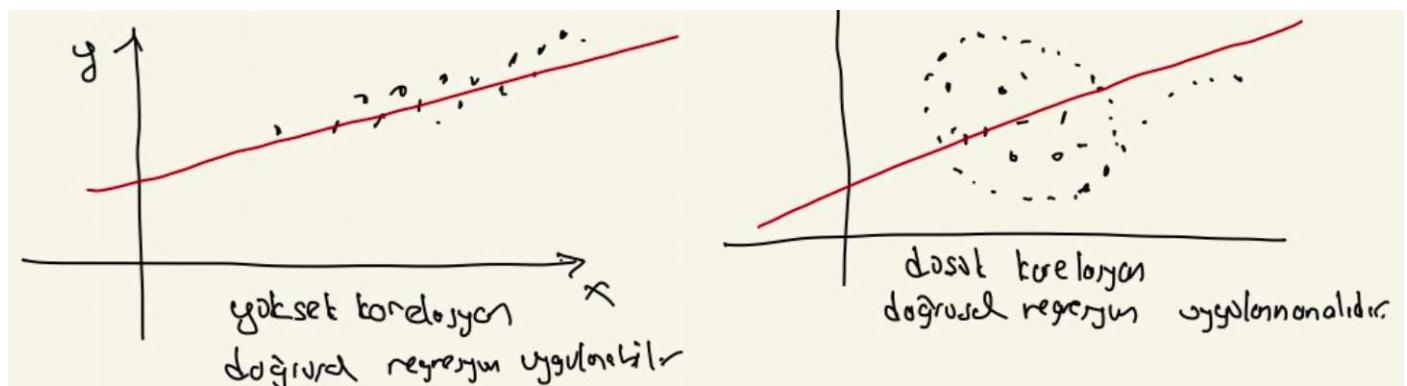
```

```

Mean absolute error = 3.3204931309984014
-----
11_ratio = 0.5
R2 = 0.71954627668898
Mean absolute error = 3.305839419867127
-----
11_ratio = 0.6
R2 = 0.7213527175314869
Mean absolute error = 3.294043836193311
-----
11_ratio = 0.7
R2 = 0.7234968395658389
Mean absolute error = 3.280654113285065
-----
11_ratio = 0.8
R2 = 0.7261062398396858
Mean absolute error = 3.265017950377641
-----
11_ratio = 0.9
R2 = 0.7293769057986847
Mean absolute error = 3.2460747365196734
-----
```

İstatistiksel Doğrusal Regresyon Yöntemiyle Yapay Sinir Ağlarıyla Regresyon Yönteminin Karşılaştırılması

Istatistiksel doğrusal regresyon yukarıda da belirtildiği gibi korelasyonun yüksek olduğu verilere uygulanabilmektedir. x ve y verileriyle y arasındaki korelasyon düşükse bu verileri bir doğru ile temsil etmek iyi bir fikir değildir. Örneğin:

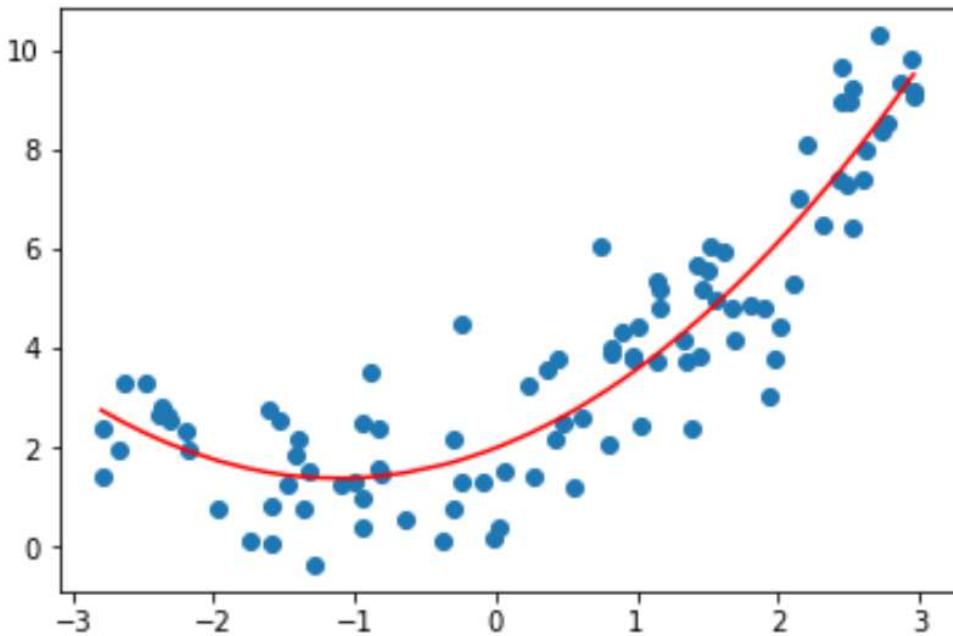


Yapay sinir ağları için böyle bir korelasyon koşulu yoktur. Yapay sinir ağları korelasyonu düşük verilerde de uygun kalıpları bulup bir tahminde bulunmamıza olanak sağlamaktadır. Öte yandan yapay sinir ağlarının eğitilmesi için nispeten yüksek sayıda veriye gereksinim vardır. Eğer eğitimde kullanılacak veri sayısı düşükse yapay sinir ağları zayıf bir performans göstermektedir. Halbuki doğrusal regresyon az sayıda verinin korele bir biçimde bulunduğu durumlarda iyi sonuçlar verebilmektedir.

Makine öğrenmesinin pek çok alanında yöntemlerin mutlak anlamda birbirlerinden iyi ya da kötü olmadığını elimizde bulunan verilere ve onların miktarlarına bağlı olduğunu bir kez daha vurgulamak istiyoruz. Belli bir durumda yapay sinir ağlarının mı yoksa istatistiksel doğrusal regresyonun mu daha iyi sonuç vereceği konusuna önemli noktaları belirtmiş olsak da pek çok durumda iki yöntemin de uygulanıp bir karşılaştırma yapılması uygun olmaktadır.

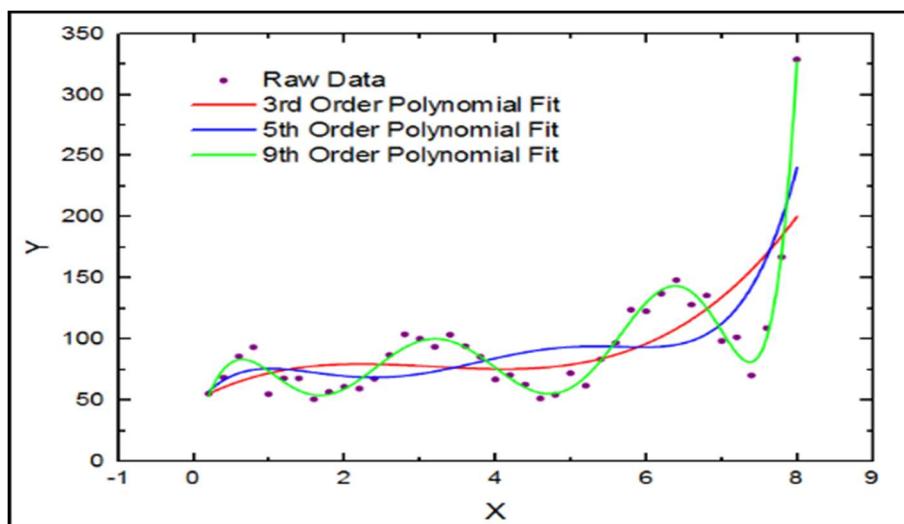
Polinomsal Regresyon

Polinomsal regresyon noktaları temsil edebilecek bir polinomsal eğrinin elde edilmesi sürecidir. Bağımsız değişkenlerle bağımlı değişkenler arasında doğrusal ilişkilerin olmadığı durumlarda tercih edilebilmektedir. Aşağıdaki grafiğe bakınız:



Alıntı Notu: Görüel <https://developpaper.com/polynomial-regression-and-model-generalization-in-machine-learning/> adresinden alınmıştır.

Burada doğrusal bir regresyonun uygulanmasının uygun olmadığı grafikten görülmektedir. Pekiyi polinomsal regresyon uygulayacak olduğumuzda uygulayacağımız polinom kaçinci dereceden olmalıdır? İşte polinomun derecesi yükseltildikçe daha uygun bir eğri elde edilebiliyor gibi gözükse de yüksek dereceli polinomlar doğrusal regresyon işlemindeki bağımsız değişken sayısını da artırmaktadır. Bu nedenle uygulamacının bu dereceyi yükseltirken dikkat etmesi gereklidir. Derece yükseltildikçe daha iyi bir sonucun elde edileceği yönünde bir garanti bulunmamaktadır.



Polinomsal regresyon Scikit-learn kütüphanesinde preprocessing modülündeki `PolynomialFeatures` sınıfının yardımıyla yapılmaktadır. Sınıfın `__init__` metodunun parametrik yapısı şöyledir:

```
sklearn.preprocessing.PolynomialFeatures(degree=2, interaction_only=False, include_bias=True, order='C')
```

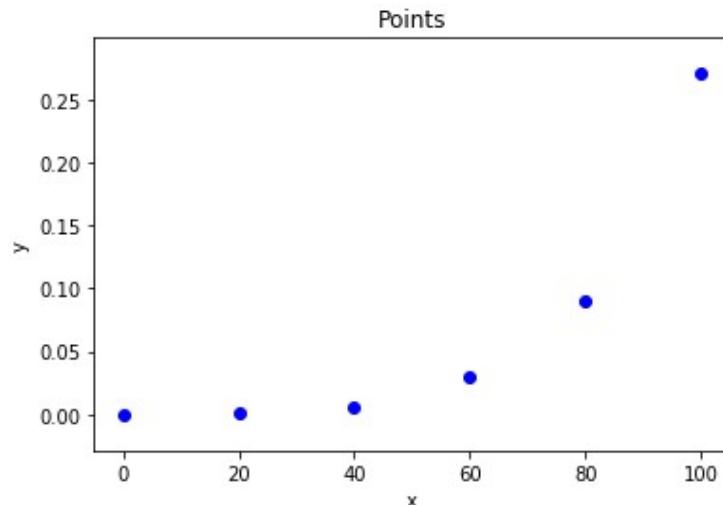
Fonksiyonun `degree` parametresi kaçinci derece bir polinomla ilgilenildiğini belirtir. Nesne yaratıldıktan sonra önce fit sonra da transform işlemlerini yapmak gereklidir. İki işlem bir arada `fit_transform` fonksiyonuyla da yapılabilmektedir. `transform` ya da `fit_transform` bize dönüştürülmüş bir matris verir. Burada biz öncelikle bize verilen bu dönüştürülmüş matrisin anlamı üzerinde duracağız. Örneğin aşağıdaki gibi tek bağımsız değişken ve tek bağımlı değişkenden oluşan bir verimiz olsun:

`test.csv`

```
0,0.0002  
20,0.0012  
40,0.0060  
60,0.0300  
80,0.0900  
100,0.27
```

Bu noktaların serpilme grafiğini çizelim:

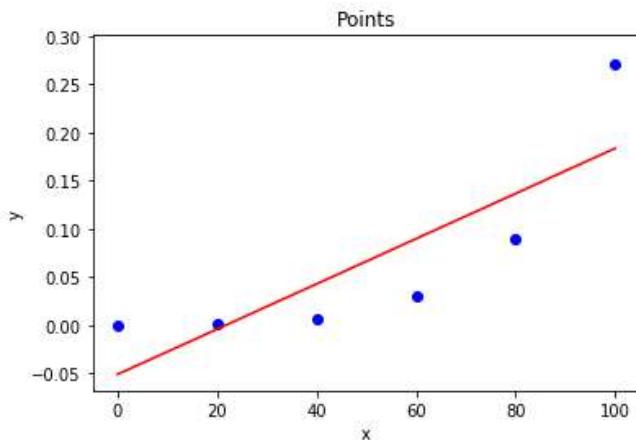
```
import numpy as np  
  
dataset = np.loadtxt('test.csv', dtype=np.float32, delimiter=',')  
  
import matplotlib.pyplot as plt  
  
plt.title('Points')  
plt.xlabel('x')  
plt.ylabel('y')  
plt.scatter(dataset[:, 0], dataset[:, 1], color='blue')
```



Grafikten de görüldüğü gibi x ve y arasında ikinci derece polinomsal bir ilişkinin varlığı anlaşılmaktadır. O halde biz tahminleme yapmak için ikinci derece polinomsal bir regresyon analizi uygulayabiliriz. Pekiyi biz noktalara polinomsal regresyon yerine doğrusal regresyon uygulamak istesek elde edeceğimiz doğru ne kadar uygun olabilir? Deneyelim:

```
import numpy as np  
  
dataset = np.loadtxt('test.csv', dtype=np.float32, delimiter=',')  
  
from sklearn.linear_model import LinearRegression  
  
lr = LinearRegression()  
lr.fit(dataset[:, 0].reshape(-1, 1), dataset[:, 1])  
  
x = np.linspace(0, 100, 100)  
y = lr.coef_[0] * x + lr.intercept_  
  
import matplotlib.pyplot as plt  
  
plt.title('Points')  
plt.xlabel('x')  
plt.ylabel('y')  
plt.scatter(dataset[:, 0], dataset[:, 1], color='blue')  
plt.plot(x, y, color='red')
```

Elde edilen grafik şöyledir:



Burada elde edilen doğrunun noktaları iyi temsil etmediği gözle görülmektedir. Şimdi de R^2 değerine bakalım:

```
rsquared = lr.score(dataset[:, 0].reshape(-1, 1), dataset[:, 1])
print(rsquared)
```

```
0.6903499390522619
```

R^2 değerinin düşük olduğunu görüyorsunuz. Yukarıda da belirtildiği gibi bu noktalar için bir doğru geçirmeye çalışmak yerine ikinci dereceden bir polinom eğrisi geçirmeye çalışmak daha uygun olacaktır.

Scikit-learn kütüphanesinde polinomsal regresyon iki aşamada uygulanmaktadır. Birinci aşamada `sklearn.preprocessing` modülündeki `PolynomialFeatures` sınıfı kullanılarak noktalar transpoze edilir. İkinci aşamada transpoze edilmiş noktalar yoluyla doğrusal regresyon uygulanır. İzleyen paragraflarda da açıklandığı gibi polinomsal regresyon aslında çoklu doğrusal regresyonla aynı anlamdadır. Şimdi biz `PolynomialFeatures` sınıfı ile noktalarımızı transpoze edelim:

```
import numpy as np

dataset = np.loadtxt('test.csv', dtype=np.float32, delimiter=',')
dataset_x = dataset[:, 0].reshape(-1, 1)
dataset_y = dataset[:, 1]

from sklearn.preprocessing import PolynomialFeatures

pf = PolynomialFeatures(degree=2)
transformed_dataset_x = pf.fit_transform(dataset_x)
print(transformed_dataset_x)
```

Burada `fit_transform` işleminden elde edilen matrisin şekline bakınız:

```
[[1.0e+00  0.0e+00  0.0e+00]
 [1.0e+00  2.0e+01  4.0e+02]
 [1.0e+00  4.0e+01  1.6e+03]
 [1.0e+00  6.0e+01  3.6e+03]
 [1.0e+00  8.0e+01  6.4e+03]
 [1.0e+00  1.0e+02  1.0e+04]]
```

Buradaki matrisin 6x3'lük olduğuna dikkat ediniz. Buradaki 6 değer, 6 tane noktanın olmasından gelmektedir. Pekiyi 3 değeri nereden gelmektedir? Buradaki 3 sütun tek değişkenli (örneğimizde x) ikinci derece polinomun tüm terimlerinin sayısı ilgilidir. Tek değişkenli ikinci derece polinomun genel ifadesi şöyledir:

$$y = a_0 + a_1x + a_2x^2$$

Göründüğü gibi burada toplam 3 tane tahmin edilmesi istenilen a_i katsayıları vardır. Transform edilen matrisin birinci sütunu x^0 değerini, ikinci sütunu x^1 değerini, üçüncü sütunu ise x^2 değerini belirtmektedir.

Aslında bizim tahmin etmeye çalıştığımız değerler bu a_i değerleridir. Pekiyi bağımsız değişken sayısı 2 tane olsaydı ikinci derece polinomun genel biçimi nasıl olurdu?

$$y = a_0 + a_1x_1 + a_2x_2 + a_3x_1x_2 + a_4x_1^2 + a_5x_2^2$$

Göründüğü gibi burada tahmin edilmeye çalışılacak 6 tane a_i değeri bulunmaktadır. Buradaki sütunlar da sırasıyla $x_1^0x_2^0$, x_1 , x_2 , x_1x_2 , x_1^2 , x_2^2 biçimindedir. Yani bizim "test.csv" dosyamızdaki verilerde iki tane x değeri olsaydı bizim transform ettiğimiz matrisin 6 tane sütunu olacaktır:

$$\left[\begin{array}{cccccc} x_1^0 & x_2^0 & x_1 & x_2 & x_1x_2 & x_1^2 \\ - & - & - & - & - & - \\ - & - & - & - & - & - \\ \dots & \dots & \dots & \dots & \dots & \dots \end{array} \right]$$

`PolynomialFeatures` sınıfının `fit_transform` metodundan elde ettiğimiz matris aslında yukarıda açıklanan sütun değerlerine ilişkindir. Pekiyi bu durumun polinomsal regresyonla ne ilgisi vardır?

İşte aslında polinomsal regresyon çoklu (multiple) doğrusal regresyon aynı anlamdadır. Örneğin aslında tek değişkenli ikinci derece polinomsal regresyon üç değişkenli çoklu doğrusal regresyonla aynı anlama gelmektedir. İki değişkenli ikinci derece polinomsal regresyon da 6 değişkenli çoklu doğrusal regresyonla aynı anlamdadır. Örneğin tek değişkenli ikinci derece bir polinom söz konusu olsun. Bu poliomun genel biçimi şöyledir:

$$y = a_0 + a_1x + a_2x^2$$

Burada aslında doğrusal regresyon bağlamında x ve x^2 'ler değişken değil katsayı olarak ele alınabilir. Yani biz polinomu şöyle doğrusal bir biçimde dönüştürebiliriz:

$$y = a_0 + xa_1 + x^2a_2$$

Burada aslında x değerleri bizim gözlediğimiz değerlerdir. Biz burada a_i değerlerini bulmaya çalışmaktadır. Şimdi değişken sayısı iki olduğunda da benzer biçimde bu da 6 terimli bir çoklu doğrusal regresyon modeline dönüştürülebilir.

$$y = a_0 + x_1a_1 + x_2a_2 + x_1x_2a_3 + x_1^2a_4 + x_2^2a_5$$

Başka bir deyişle aslında:

$$y = AX$$

birimde matrisel formda gösterilmiş bir polinomsal deneklem,

$$y = XA$$

birimde de ifade edilebilir. Buradan hareketle bizim yapacağımız şey aslında transform edilmiş çok sütunlu değerleri doğrusal regresyona sokmak olacaktır. Örneğin:

```

import numpy as np

dataset = np.loadtxt('test.csv', dtype=np.float32, delimiter=',')
dataset_x = dataset[:, 0].reshape(-1, 1)
dataset_y = dataset[:, 1]

from sklearn.preprocessing import PolynomialFeatures

pf = PolynomialFeatures(degree=2)
transformed_dataset_x = pf.fit_transform(dataset_x)
print(transformed_dataset_x)

from sklearn.linear_model import LinearRegression

lr = LinearRegression()
lr.fit(transformed_dataset_x, dataset_y)

a0 = lr.coef_[0]
a1 = lr.coef_[1]
a2 = lr.coef_[2]

print('a0 = {}, a1 = {}, a2 = {}'.format(a0, a1, a2))

x = np.linspace(0, 100, 100)
y = a0 + a1 * x + a2 * x ** 2

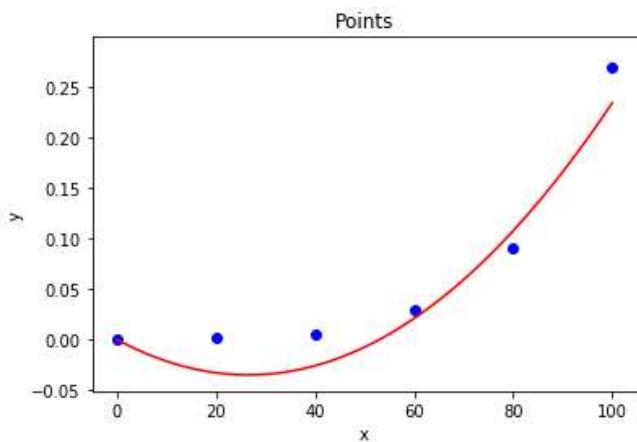
import matplotlib.pyplot as plt
plt.title('Points')
plt.xlabel('x')
plt.ylabel('y')
plt.scatter(dataset[:, 0], dataset[:, 1], color='blue')
plt.plot(x, y, color='red')

```

Buradan elde ettiğimiz a₀, a₁, ve a₂ katsayıları şöyledir:

a₀ = 0.0, a₁ = -0.0026392594445496798, a₂ = 4.9812791985459626e-05

Elde ettiğimiz polinomun noktalarla birlikte grafiği de şöyledir:



Şimdi burada yapılanların anlamını bir daha değerlendirelim. Başlangıçta bizim elimizde tek değişkenli ikinci derece bir polinomun tahmin edilmesi problemi vardı:

$$y = a_0 + a_1 x + a_2 x^2$$

Burada bizim tahmin etmeye çalıştığımız değerler a₀, a₁ ve a₂ değerleridir. Biz bu polinomu aşağıdaki gibi doğrusal hale getirdik:

$$y = x_0 + x_1 a_0 + x_2 a_1 + x_3 a_2$$

Aslında biz LinearRegression sınıfının predict metodu ile de elde etmeye çalıştığımız polinoma ilişkin y değerlerini bulabiliyoruz. Yani grafiğimizi şöyle de çizebilirdik:

```
x = np.linspace(0, 100, 100).reshape(-1, 1)
transformed_x = pf.fit_transform(x)
y = lr.predict(transformed_x)

import matplotlib.pyplot as plt
plt.title('Points')
plt.xlabel('x')
plt.ylabel('y')
plt.scatter(dataset[:, 0], dataset[:, 1], color='blue')
plt.plot(x, y, color='red')
```

Doğrusal regresyondan elde ettiğimiz katsayıları inceleyiniz:

```
a0 = 0.0, a1 = -0.0026392594445496798, a2 = 4.9812791985459626e-05
```

Yani aslında bizim elde ettiğimiz polinom şöyledir:

```
y = -0.0026 x + 4.98 x^2
```

Şimdi de polinomsal regresyonu doğrusal regresyona dönüştürdükten sonra elde ettiğimiz R² değerine bakalım:

```
rsquared = lr.score(transformed_dataset_x, dataset_y)
print(rsquared)
```

Elde edilen sonuç şöyledir:

```
0.9568460873349596
```

Anımsanacağı gibi biz daha önce bu noktalardan doğru geçirdiğimizde 0.6903499390522619 değeri elde etmişik. Göründüğü gibi bu noktalardan ikinci bir derece bir polinomun geçirilmesi modeli çok daha iyileştirmiştir.

Şimdi de n sütunlu bir veri kümесinin k'inci dereceden bir polinoma nasıl uydurulacağını özet olarak verelim:

1) Önce PolynomialFeatures sınıfı türünden bir nesne yaratılır. Sonra sınıfın fit_transform metodu çağrılarak transform edilmiş katsayı matrisi elde edilir:

```
pf = PolynomialFeatures(degree=k)
transformed_dataset_x = pf.fit_transform(dataset_x)
```

2) Sonra transform edilmiş değerleri LinearRegression sınıfında kullanıp fit işlemi yapmalıyız.

```
lr = LinearRegression()
lr.fit(transformed_dataset_x, dataset_y)
```

3) Artık her şey hazırır. LinearRegression sınıfının predict metoduna x değerleri verilirse y değeri elde edilir. Örneğin:

```
x_transformed = pf.fit_transform(x)
y = lr.predict(x_transformed)
```

4) k'inci derece polinomun katsayıları da istenirse lr.coef_ özniteligidenden alınır. lr.intercept özniteliginin orijinal polinomun katsayılarıyla bir ilgisi yoktur. Yani bir deyişle aslında elde edilen polinomun katsayıları şöyledir:

```
y = lr.coef_[0] + lr.coef_[1] * x + lr.coef_[2] * x ** 2 + .... + lr.coef_[k] * x ** k
```

Pekiyi biz elimizdeki noktalardan bir doğru mu, yoksa bir polinom mu geçireceğimizi nasıl belirleyeceğiz? Ya da eğer polinom geçireceksek bunun kaçinci dereceden polinom olacağını nasıl belirleyeceğiz? Aslında bu kararı otomatik bir biçimde veren Scikit-learn içerisinde bir fonksiyon bulunmamaktadır. Uygulamacı noktaların grafiğine bakarak sezgisel biçimde bunu belirleyebilir. Gerçekten de biz yukarıdaki örnekte noktalardan ikinci derece bir polinomun geçirilebileceğini grafiğe bakarak sezgisel biçimde belirledik. Tabii noktaların grafiğine gözle bakabilmek için değişken sayısının 1 tane olması gerekir. Halbuki gerçek uygulamalarda değişken sayısı 1'den fazla olmaktadır. Kaçinci dereceden bir polinomun uygun olacağını belirlemek aslında deneme yanılma yoluyla yapılabilir. Yani uygulamacı ikinci derece, üçüncü derece, dördüncü derece gibi farklı derecelerde polinom geçirerek R^2 değerine bakabilir. Bu R^2 değerinin en iyi olduğu dereceyi belirleyebilir. Örneğin yukarıda üzerinde alıştığımız noktalardan üçüncü derece bir polinom geçirmeye çalışalım:

```
import numpy as np

dataset = np.loadtxt('test.csv', dtype=np.float32, delimiter=',')
dataset_x = dataset[:, 0].reshape(-1, 1)
dataset_y = dataset[:, 1]

from sklearn.preprocessing import PolynomialFeatures

pf = PolynomialFeatures(degree=3)
transformed_dataset_x = pf.fit_transform(dataset_x)
print(transformed_dataset_x)

from sklearn.linear_model import LinearRegression

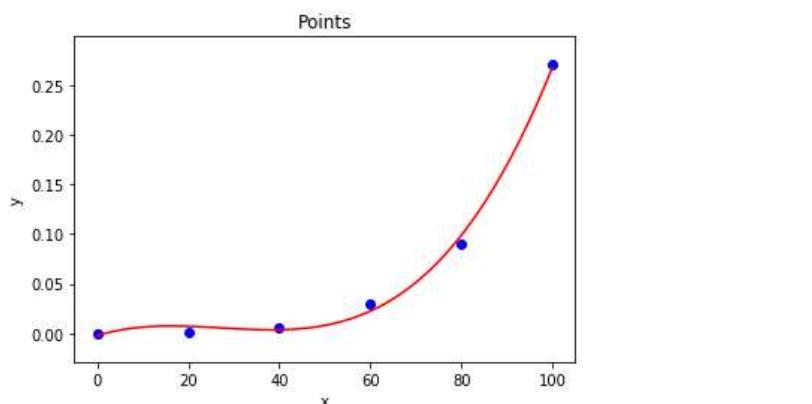
lr = LinearRegression()
lr.fit(transformed_dataset_x, dataset_y)

x = np.linspace(0, 100, 100).reshape(-1, 1)
transformed_x = pf.fit_transform(x)
y = lr.predict(transformed_x)

import matplotlib.pyplot as plt
plt.title('Points')
plt.xlabel('x')
plt.ylabel('y')
plt.scatter(dataset[:, 0], dataset[:, 1], color='blue')
plt.plot(x, y, color='red')

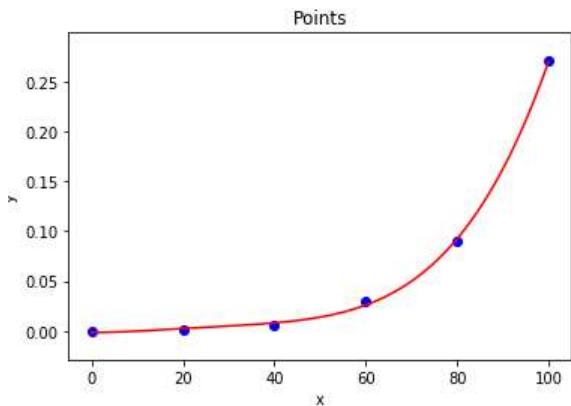
rsquared = lr.score(transformed_dataset_x, dataset_y)
print(rsquared)
```

Buradan elde ettiğimiz grafik ve R^2 değeri şöyledir:



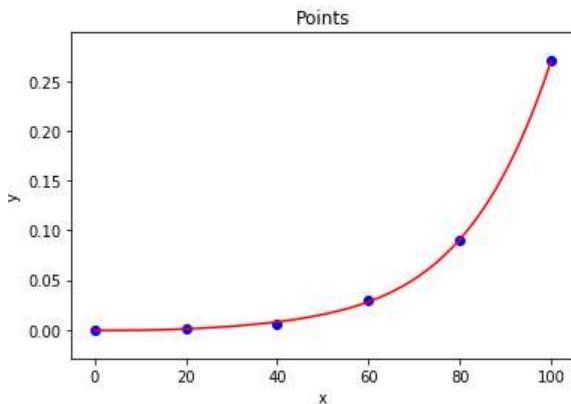
0.9966690525829125

O halde bu noktalar için üçüncü derece bir polinom aslında daha uygundur. Dördüncü derece polinom için elde edilen grafik ve R^2 değerleri de şöyledir:



0.9994477004504332

Görüldüğü gibi R^2 değeri çok az daha iyileşmiştir. Ancak yüksek dereceli polinomlardan genel olarak kaçınmak gereklidir. Şimdi 5'inci derece polinom için grafik ve R^2 değerine bakalım:



0.9998423761893278

Yukarıda da belirttiğimiz gibi az bir iyileşme için derece yükseltmesi iyi bir teknik değildir. Burada üçüncü derece bir polinom uygun olabilir.

GRADIENT ASCENT ve GRADIENT DESCENT ALGORİTMALARININ ANLAMI

Gradient ascent ve gradient descent algoritmaları makine öğrenmesinde çok sık kullanılmaktadır. Anımsanacağı gibi biz de yapay sinir ağlarında optimizasyon algoritması olarak "stochastic gradient descent (sgd)" algoritmasını kullanmıştık. Stochastic gradient descent algoritması gradient descent algoritmasının bir türüdür. Pekiyi bu algoritmaların çalışma biçimini nasıldır? Aslında bu algoritmalar bir noktadan başlayarak uygun bir doğrultuda yavaş yavaş ilerleme ile karakterize olmaktadır. Yani gradient ascent ve gradient descent algoritmaları iteratifdir olarak en yüksek ya da en düşük optimal noktaya yavaş yavaş erişmeyi hedeflemektedir. Algoritmada doğrultu hedefe varmayı sağlayacak biçimde hesaplanmaktadır. Matematiksel anlamda eğer bir maksimizasyon problemi söz konusu ise "gradient ascent" bir minimizasyon söz konusu ise "gradient descent" yöntemi söz konusu olmaktadır.

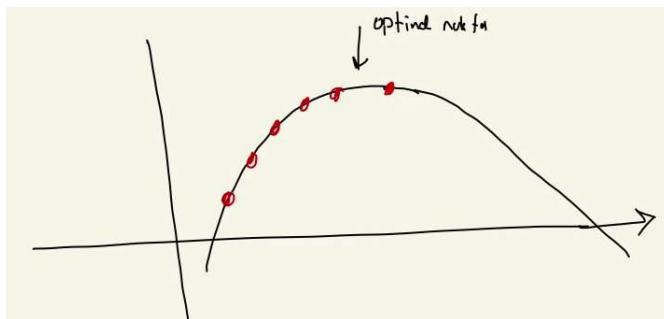
Bu yöntemlerde önce bir amaç fonksiyonu tespit edilmelidir. Yani ilerlendikçe ne hedeflenmektedir? Neyin maksimize ya da minimize edilmesi istenmektedir? Bunun bir biçimde matematiksel ifadesi ortaya konmalıdır. İkinci olarak hedefe varılıp varılmadığının tespit edilmesi gereklidir. Yani amaç fonksiyonu bir doğrultu belirtir. Fakat tatmin edici bir noktaya gelinip gelinmediği "malliyet fonksiyonu (cost function)" ya da "kayıp fonksiyonu (loss function)" denilen bir fonksiyonla belirlenmektedir.

Yukarıda da belirtildiği gibi gradient ascent ve gradient descent algoritmalarında bir amaç ve bu amaca uygun bir doğrultunun tespit edilmesi gerekmektedir. Sonra bu doğrultuda ilerlenir ve tatmin edici bir noktaya gelinip gelinmediği kontrol edilir. Matematiksel olarak doğrultu belirleme işlemi amaç fonksiyonun birinci türevi alınarak yapılmaktadır. Eğer amaç fonksiyonu birden fazla değişkenden oluşuyorsa bu durumda her değişken için parçalı türevler alınır. Bu parçalı türevlerin oluşturduğu vektöre de gradient vektör denilmektedir. Gradient vektör ters üçgenle temsil edilmektedir. Örneğin:

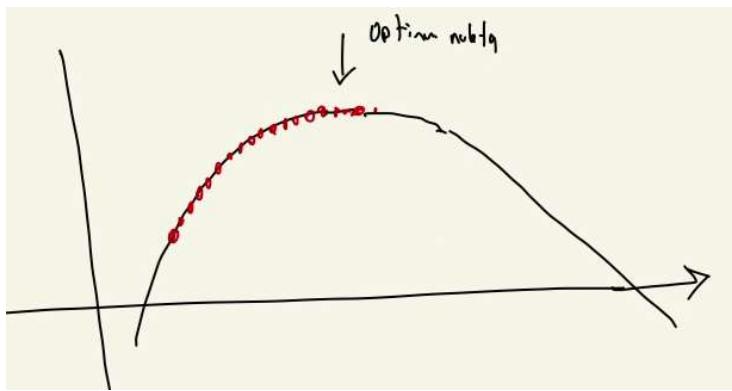
$$\nabla f = \left[\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_n} \right]$$

Pekiyi amaç fonksiyonu nasıl tespit edilecektir? Amaç fonksiyonunun spesifik probleme dayalı olarak tespit edilmesi gereklidir. Bu nedenle her problemin amaç fonksiyonu farklı olabilir. Benzer biçimde maliyet (ya da kayıp) fonksiyonu da probleme dayalı biçimde tespit edilmektedir. Pekiyi neden bu tür problemler denklem yoluyla değil de iteratif doğrultuda ilerleme yoluyla çözülmek istenmektedir? Bunun nedeni bazı tür problemlerde denklemlerin sembolik biçimde mümkün olmamasıdır.

Pek çok iteratif yöntemde ilerleme belli bir çarpansal değere orantılı olarak yapılmaktadır. Buna "öğrenme hızı" (learning rate) denilmektedir. Öğrenme hızı değer olarak yükseltilirse noktalar arasındaki sıçramalar daha yüksek olur. Hedefe daha hızlı yaklaşılır. Ancak öğrenme hızı yüksek olduğunda hedefe yaklaşım hızlı olsa da hedefin hassas bir biçimde elde edilmesi zorlaşmaktadır. Benzer biçimde öğrenme hızı düşürüldüğünde hedefin daha hassas bir biçimde bulunması sağlanır. Ancak hedefe yaklaşma uzun zaman alabilemektedir. Örneğin:

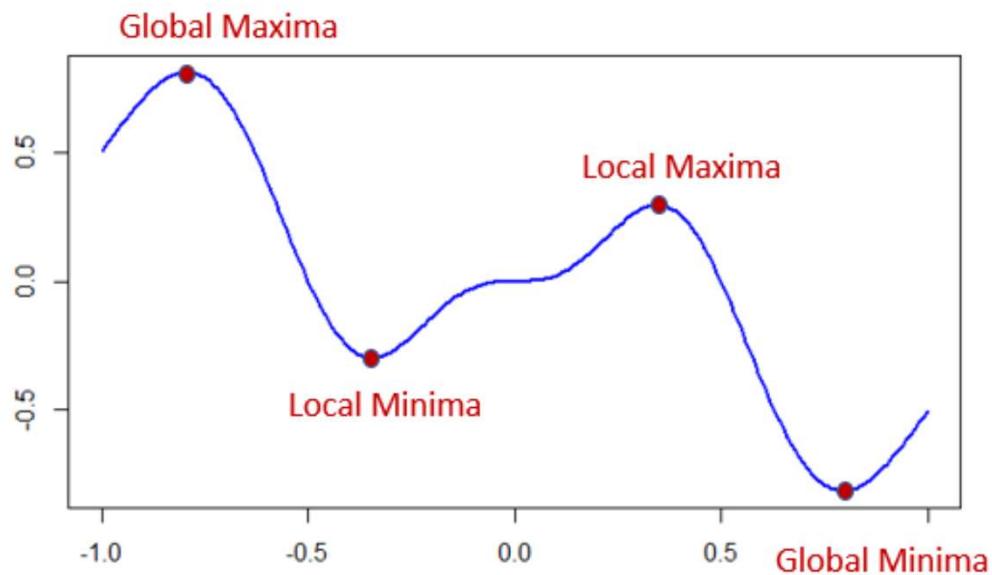


Burada sıçrama yani öğrenme hızı yüksek tutulduğu için hedefe (maksimum noktaya) hızlı yaklaşılmış ancak hedef hassas bir biçimde belirlenememiştir. Fakat örneğin:



Burada hedefe (maksimum nokta) daha uzun sürede yaklaşılmıştır. Ancak hedef daha hassas bir biçimde belirlenebilmektedir. Biz makine öğrenmesinde "öğrenme hızı (learning rate)" biçiminde bir parametreyle karşılaşlığımızda şu çıkarımda bulunmalıyız: "Bu parametrenin değeri yükseltilirse ben daha kısa bir zamanda hedefin yakınılarına gelebilirim. Böylece hedefe yaklaşmam daha az bilgisayar zamanı alır. Ama hedefi daha az bir hassasiyetle belirleyebilirim. Eğer ben "learning rate" değerini düşürürsem hedefe yaklaşmam daha uzun bir zaman alır ama ben hedefi daha hassas belirleyebilirim." Öğrenme hızı algoritmayı kuranın belirdiği görelî bir değerdir.

Yukarıda bir eğrinin maksimum ve minimum noktalarının fonksiyonun türevini 0 yapan noktalar olduğundan bahsettik. Ancak türevin sıfır olduğu yani eğimin en düşük olduğu noktalar tüm noktalar içerisindeki en büyük ve en küçük noktalar olmak zorunda değildir. Türev eğrinin bazı yerlerine 0 olabilir ancak bu yerler global olarak en küçük ya da en büyük yerler olmayabilir. İşte bu bağlamda "lokal minimum (local minima)", "global" minimum (global minima)", "lokal maksimum (local maxima)", "golabal maksimum (global maxima)" kavramları devreye girmektedir. Lokal minimum belli bir bölgedeki minimum, global minimum ise her yer dikkate alındığında gerçek minimumu belirtmektedir. Benzer biçimde lokal maksimum belli bir bölgedeki maksimum, global maksimum ise her yer dikkate alındığında gerçek maksimum noktalardır. Aşağıdaki şekilde lokal minimum, global minimum, lokal maksimum ve global maksimum noktalarını görüyorsunuz:



Alıntı Notu: Görsel <https://www.datasciencecentral.com/profiles/blogs/optimization-techniques-finding-maxima-and-minima> adresinden alınmıştır.

Pekiyi biz gradient descent ve gradient ascent algoritmalarında bir noktanın lokal ya da global minimum ya da maksimum olduğunu nasıl anlayabiliriz? İşte bunun için değişik teknikler kullanılmaktadır. Stokastik gradient descent ve stokastik gradient ascent değişik rastgele noktalardan hareketle bulunan yerin lokal mı yoksa global mı olduğunu anlamaya çalışmaktadır.

Şimdi biz gradient descent yöntemiyle bir parabolün en küçük y değerini bulmak isteyelim. Bunun için bizim bir x değerinden başlayıp belli bir doğrultuda giderek en düşük değeri bulmamız gereklidir. Parabolün genel fonksiyonu şöyledir:

$$y = ax^2 + bx + c$$

Burada amacımız y değerinin en küçük yapılmasıdır. Amaç fonksiyonumuz da $ax^2 + bx + c$ fonksiyonudur. Buradaki maliyet fonksiyonu amaç fonksiyonundan elde edilen değer ile varmak istenilen değer (örneğimizde 0 olabilir) arasındaki fark olarak tanımlanabilir. Biz bu farkı belirlediğimiz bir epsilon değerinden küçük hale getirmeye çalışabiliriz. Gideceğimiz doğrultuyu belirlemek için gradient vektör kullanılır. Zaten bu örneğimizde tek bir değişken olduğundan gradient vektörümüz de amaç fonksiyonun türevinden oluşan tek elemanlı bir vektördür:

$$\nabla f = \left[\frac{\partial f}{\partial x} \right] = [2ax + b]$$

Şimdi bu fonksiyon üzerinde "gradient descent" yöntemini uygulayalım:

```
import numpy as np

def gradient_descent_parabol(a, b, c, *, xinit, epsilon, learning_rate):
    x = xinit
    y_prev = a * x ** 2 + b * x + c
    count = 1
    while True:
        x -= (2 * a * x + b) * learning_rate
        y_next = a * x ** 2 + b * x + c
        if (np.abs(y_prev - y_next) < epsilon):
            break
        y_prev = y_next
        count += 1

    print(count)
    return x, a * x ** 2 + b * x + c

x, y = gradient_descent_parabol(1, 0, -4, xinit=-5, epsilon=1e-9, learning_rate=0.01)
print(f'x = {x:.5f}, y = {y:.5f}')
```

Şu sonuçlar elde edilmiştir:

Minimum y value = -1.9996555600890138 (-2.000), Total iteration = 804

Şimdi de doğrusal regresyon problemini gradient descent algoritmasıyla çözelim. Anımsanacağı gibi doğrusal regresyonda amaç $y = mx + n$ doğrusundaki m ve n değerlerini uygun biçimde belirlemekti. Buradaki amaç fonksiyonu şöyledi:

$$E = \frac{1}{N} \sum_{i=0}^N (y_i - (mx_i + n))^2$$

Şimdi gradient descent algoritması için bu amaç fonksiyonundaki iki değişken olan m ve n için türev alarak gradient vektörü bulmaya çalışalım:

$$\frac{\partial E}{\partial m} = \frac{-2}{N} \sum_{i=0}^N x_i (y_i - mx_i - n)$$

$$\frac{\partial E}{\partial n} = \frac{-2}{N} \sum_{i=0}^N (y_i - mx_i - n)$$

Şimdi artık maliyet fonksiyonu olmadan gradient vektördeki doğrultularda belirli bir miktarda iteratif olarak ilerleyeceğimde kodu yazabilirim. Aşağıdaki fonksiyonda x ve y değerleri noktaların değerleridir. epoch uygulanacak iterasyon sayısını belirtmektedir. learning_rate ise ilerleme adımlarının büyüklüğünü belirtir. Biz buarada gradient vektörde belirtilen doğrultuda küçük adımlarla doğruya oluşturan m ve n değerlerini güncelleyeceğiz. Şüphesiz doğrusal regresyonun bu biçimde iteratif olarak çözülmesine gerek yoktur. Zaten doğrusal regresyon için "en küçük kareler", "lasso" ve "ridge" gibi formülize edilmiş yöntemler bulunmaktadır. Ancak biz burada bu örneği yalnızca gradient algoritmaların çalışma biçimini anlatabilmek için veriyoruz:

```
import numpy as np

dataset = np.loadtxt('test.csv', dtype=np.float32, delimiter=',')
dataset_x = dataset[:, 0]
dataset_y = dataset[:, 1]

def mae(ypred, y):
    return np.sum(np.abs(y - ypred)) / len(ypred)

def linear_regression_gradient(x, y, *, loss, epsilon, learning_rate):
    N = len(x)
    m = 0
    n = 0

    prev_loss = 0
    while True:
        ypred = m * x + n
        next_loss = loss(y, ypred)
        if np.abs(prev_loss - next_loss) < epsilon:
            break
        prev_loss = next_loss
        dfm = (-2 / N) * np.sum(x * (y - ypred))
        dfn = (-2 / N) * np.sum(y - ypred)
        m = m - learning_rate * dfm
        n = n - learning_rate * dfn

    return m, n

m, n = linear_regression_gradient(dataset_x, dataset_y, loss=mae, epsilon=0.00000001,
learning_rate=0.001)

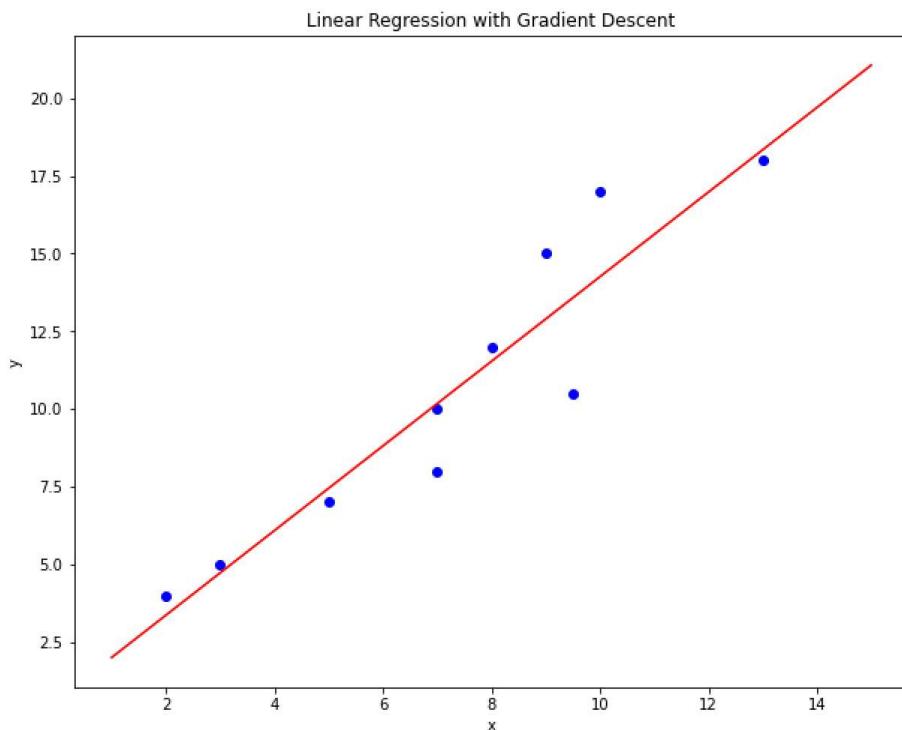
x = np.linspace(1, 15, 100)
y = m * x + n

import matplotlib.pyplot as plt

plt.title('Linear Regression with Gradient Descent')
figure = plt.gcf()
figure.set_size_inches(10, 8)
plt.xlabel('x')
plt.ylabel('y')
plt.scatter(dataset[:, 0], dataset[:, 1], color='blue')
plt.plot(x, y, color='red')
plt.show()

print(f'Slope = {m}, Intercept={n}')
```

Elde edilen grafik ve doğrunun m ve n değerleri şöyledir:



Slope = 1.3609250213623068, Intercept=0.6451712964534733

Buradaki test.txt dosyası daha önceki örneklerimizde kullandığımız dosyanın aynısıdır. test.txt dosyasının şöyledir:

```
2,4
3,5
5,7
7,10
7,8
8,12
9.5,10.5
9,15
10,17
13,18
```

Yukarıdaki örnekte loss fonksiyonu olarak "mae (mean absolute error)" kullandık. Gradient descent algoritmamız iki iterasyon arasındaki "mae" değeri belli bir epsilon'dan küçük olduğunda işlemini sonlandırdı. Şimdi de bu problemi problemi iteratif olmayan biçimde en küçük kareler yöntemiyle LinearRegression sınıfıyla çözelim:

```
import numpy as np

dataset = np.loadtxt('test.csv', dtype=np.float32, delimiter=',')
from sklearn.linear_model import LinearRegression

lr = LinearRegression()
lr.fit(dataset[:, 0].reshape(-1, 1), dataset[:, 1])

x = np.linspace(1, 15, 100)
y = lr.coef_[0] * x + lr.intercept_

x = np.linspace(1, 15, 100)
y = m * x + n

import matplotlib.pyplot as plt

plt.title('Linear Regression with Gradient Descent')
figure = plt.gcf()
figure.set_size_inches((10, 8))
```

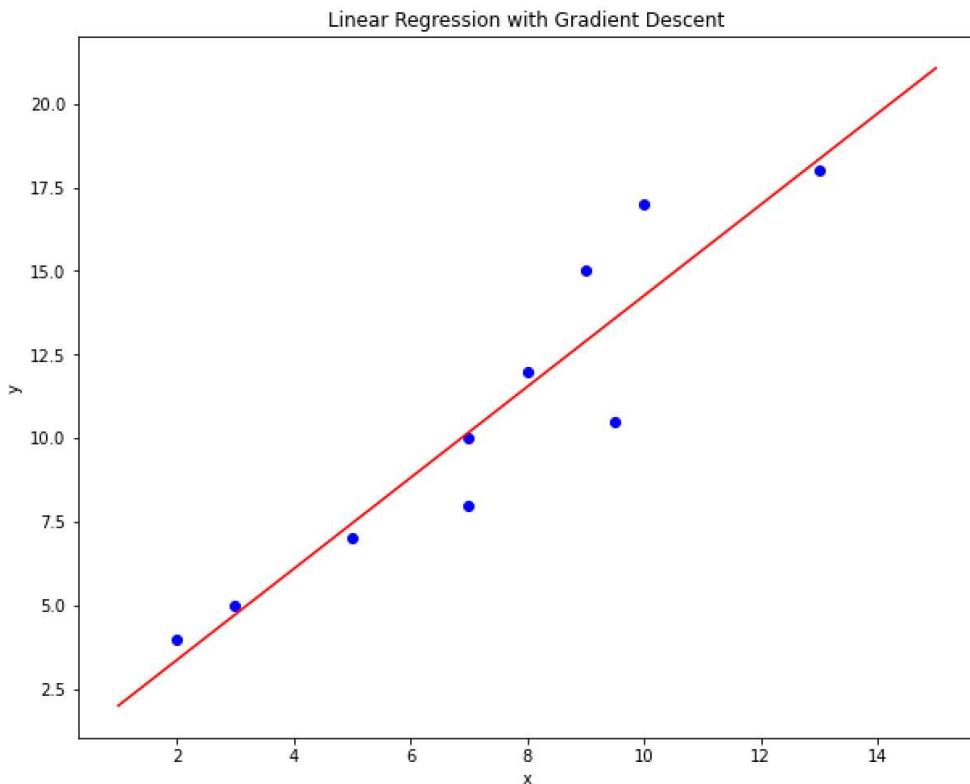
```

plt.xlabel('x')
plt.ylabel('y')
plt.scatter(dataset[:, 0], dataset[:, 1], color='blue')
plt.plot(x, y, color='red')
plt.show()

print(f'Slope = {lr.coef_[0]}, Intercept={lr.intercept_}')

```

Elde edilen sonuç şöyledir:



Slope = 1.3594104051589966, Intercept=0.6583328247070312

Elde edilen değerlerin birbirlerine yakın olduğunu görüyorsunuz.

Batch Gradient, Stokastik Gradient ve Mini Batch Gradient Yöntemleri

Gradient ascent ve gradient descent yöntemlerinde doğrultuda ilerleme veri kümesindeki elemanların kullanılma biçimlerine göre üç gruba ayrılmaktadır. Eğer her adımda veri kümesindeki tüm elemanlar işleme sokuluyorsa (yukarıdaki örneklerde yaptığımız gibi) bu biçimde ilerlemeye "batch gradient descent" ya da "batch gradient ascent" denilmektedir. Bu yöntemde ilerleme de belli miktarda bir döngüyle (epoch) devam ettirilir. Halbuki "stokastik gradient ascent" ve "stokastik gradient descent" yöntemlerinde doğrultuda ilerleme veri kümesinden çekilen rastgele elemanlar için (stokastik sözcüğü bu nedenden kullanılmıştır) tek tek yapılmaktadır. Bu rastgele eleman seçme işlemleri belli bir sayıda devam ettirilmektedir.

Veri kümesindeki tüm vektörün işleme sokulmasına "batch" işlem denilmektedir. Mini batch yöntemi bu bakımdan gradient yöntemleriyle stokastik gradient yöntemlerinin bir ortalaması gibidir. Mini batch yönteminde tüm veriler içerisindeki belli miktarda kümeler oluşturularak bunlar işleme sokulmaktadır. Örneğin tüm veriler 1000 tane olsun. Biz bu yöntemde 1000 taneyi tek hamlede değil, tek tek de değil belirlediğimiz bir miktarda (örneğin 10'arlık) grup halinde işleme sokarız. Yine bu işlem toplamda baştan sona bir kez ya da n kez yapılabilmektedir.

Örneğin veri kümesinde 100000 eleman bulunuyor olsun. Batch gradient descent ya da batch gradient ascent yöntemlerinde her iterasyonda bu 100000 eleman tek hamlede işleme sokulup bundan sonra değerler güncellenir. Bu işlemler de belli bir sayıda (örneğin 10000 kere) devam ettirilir. Stokastik gradient yönteminde ise bu 100000 eleman rastgele seçilmiş olan tek elemanlarla işleme sokulmaktadır. Bu işlem de belli bir sayıda devam

ettirilmektedir. Mini Batch işleminde ise bu elemanlar küçük gruplar (örneğin 100'erli gruplar) halinde işleme sokulmaktadır. Bu işlem de belli bir sayıda devam ettirilmektedir.

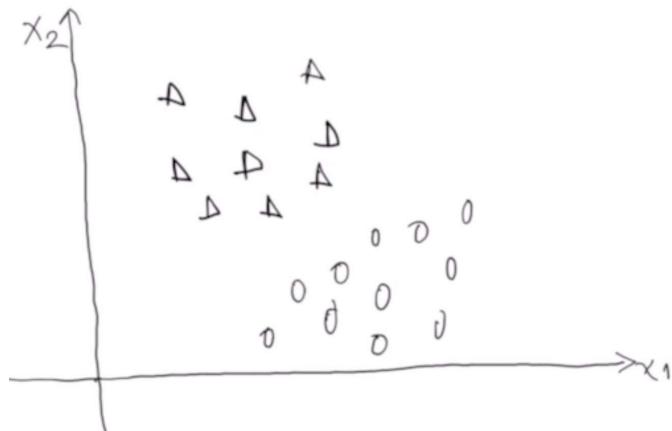
Genel olarak stokasik gradient descent yöntemi maksimum ya da minimum değere çok daha hızlı yakınsamaktadır. Ancak batch gradient yöntem stokastik yönteme göre daha iyi sonuç verir. Veri miktarının az olduğu durumlarda stokastik gradient yerine batch gradient yöntem daha uygun kaçmaktadır. (Örneğin 5 noktadan oluşan doğrusal regresyonda stokastik gradient normal gradient yönteme göre çok daha kötü sonuç vermektedir.) Ayrıca veri miktarı az ise stokastik gradient yöntemde learning_rate değerini yükseltmek daha iyi sonuç verebilmektedir.

İSTATİSTİKSEL YÖNTEMLERLE GERÇEKLEŞTİRİLEN LOJİSTİK REGRESYON İŞLEMLERİ

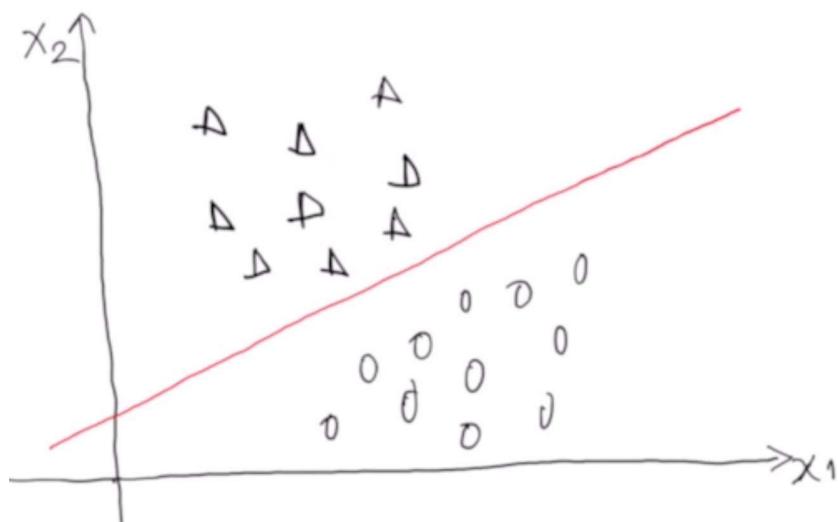
Anımsanacağı gibi çıktısı kategorik değerlerden oluşan ve sınıflandırma amacıyla kullanılan regresyon modeline lojistik regresyon modeli denilmektedir. Veri bilimi uygulamalarının neredeyse %70 kadarı sınıflandırma problemleriyle ilgiliidir. Yine anımsanacağı gibi lojistik regresyon problemlerinin çözümü için genel olarak iki ana yöntem grubundan faydalankmaktadır: Sınıflandırma (classification) ve kümeleme (clustering). Daha önce görmüş olduğumuz sinir ağları sınıflandırma yöntemine bir örnek oluştururken K-Means ya da DBSCAN yöntemleri kümeleme yöntemlerine örnek oluşturmaktadır. Bildiğiniz gibi sınıflandırma tarzı lojistik regresyon yöntemleri genel olarak denetimli (supervised) yöntemler olduğu halde kümeleme tarzı lojistik regresyon yöntemleri denetimsiz (unsupervised) yöntemlerdir. Lojistik regresyon problemleri yapay sinir ağları ve kümeleme yöntemi kullanılmadan optimizasyon yöntemleriyle de çözülebilmektedir.

Doğrusal Olarak Ayrıntıyalabilirlik (Linear Separability)

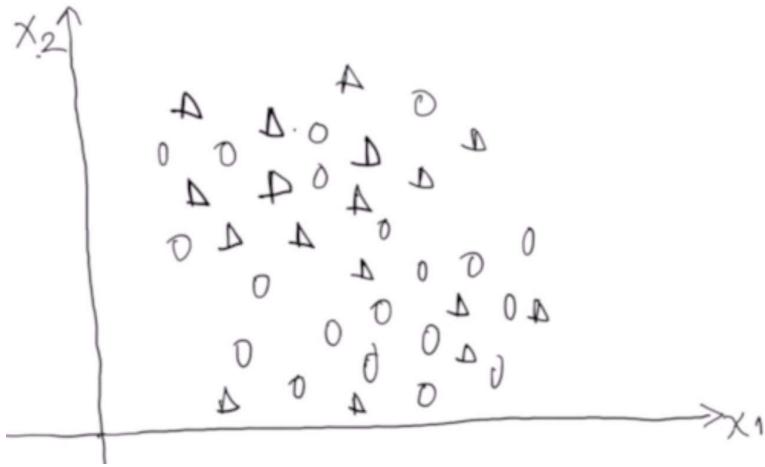
Doğrusal olarak ayrıntıyalabilirlik lojistik regresyon problemlerinde sıkça karşılaşılan bir kavramdır. Biz de bu kavramı daha önce çeşitli yerlerde kullanmıştık. Doğrusal olarak ayrıntıyalabilirlik kabaca iki kümenin bir doğru ile ayrıntıyalabilmesi anlamına gelmektedir. Kartezyen koordinat sisteminde x_1 ve x_2 isimli iki özellikten oluşan iki sınıfı aşağıdaki veri kümesi bulunuyor olsun:



Biz buradaki iki kümeyi bir doğru ile ayırtıyalabiliyorsak bu iki kümeye doğrusal olarak ayırtıyalabilir biçimdedir:



Şimdi aşağıdaki veri kümesine bakınız:



Bu veri kümesi doğrusal olarak ayırtılabilir değildir. Çünkü buradaki iki kümeyi bir doğru ile ayırtıramayız.

İki boyutlu kartezyen koordinat sisteminde doğrusal olarak ayırtılabilen bir kümeyi ayırtıran genel doğru denklemi şöyle yazılabilir:

$$a_0 + a_1x_1 + a_2x_2 = 0$$

Pekiyi veri kümemizde x_1, x_2, x_3 olmak üzere üç özellik olsayı ne olacaktı? İşte bu durumda üç boyutlu uzayda bir düzlem söz konusu olacaktır. Üç boyutlu uzaydaki düzlem denkleminin genel biçimi şöyledir:

$$a_0 + a_1x_1 + a_2x_2 + a_3x_3 = 0$$

İşte genel olarak n boyutlu bir uzayın bir düzlemi bulunmaktadır ve o düzlemin denklemi şöyledir:

$$a_0 + a_1x_1 + a_2x_2 + a_3x_3 \dots a_nx_n = 0$$

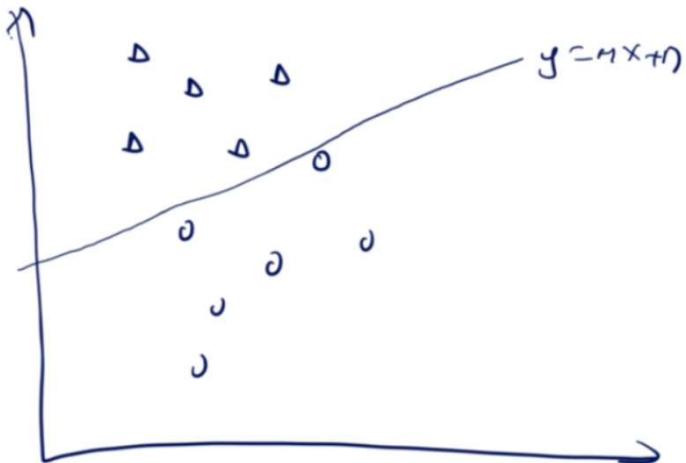
n boyutlu uzayın düzlemine "hyperplane" denilmektedir. Doğrusal olarak ayırtılabilirlik genel anlamda bir hyperplane ile n boyutlu uzayın (yani n özellikli bir veri kümесinin) ayırtılabilmesidir.

İstatistiksel Lojistik Regresyon

Aslında lojistik regresyon iki kümeyi ayıran bir doğru denkleminin belirlenmesi ile de gerçekleştirilebilmektedir. Örneğin iki özelliğe sahip bir lojistik regresyon problemi söz konusu olsun. Bu iki özelliğin x ye y olduğunu düşünelim. Yani veri kümemiz aşağıdakine benzer bir durumda olsun:

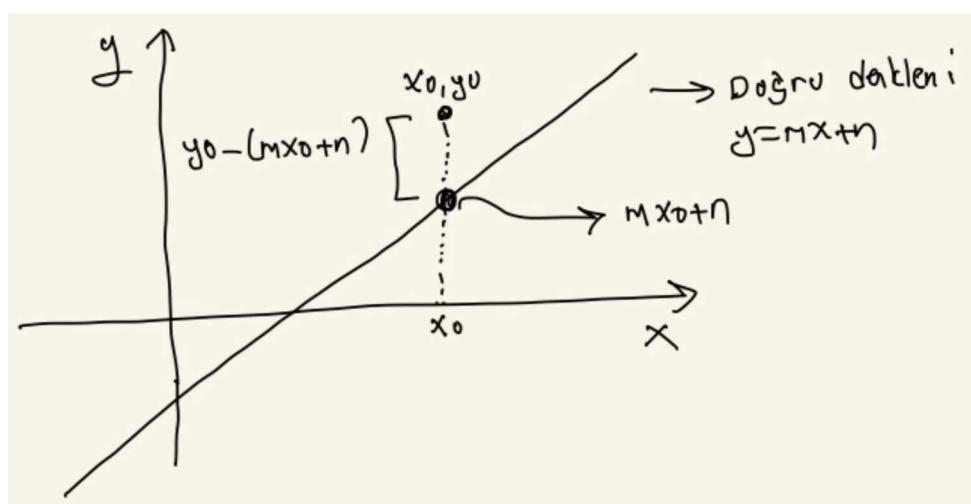
```
x,y,class
5,10,1
7.14,1
2,3,0
...
```

İki özellik söz konusu olduğuna göre böylesi noktalar kartezyen koordinat sisteminde aşağıdaki gibi gösterilebilir:

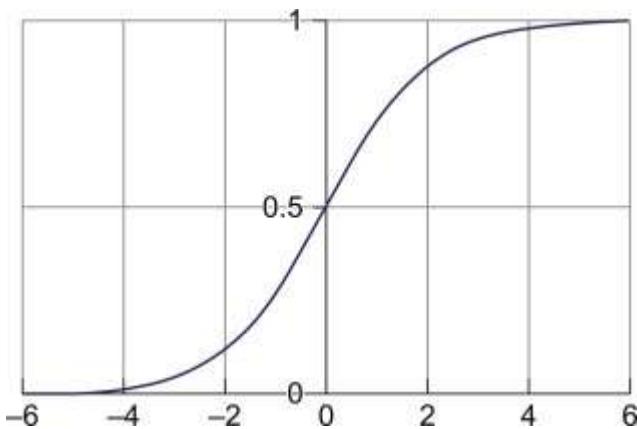


İşte burada iki kümeyi en iyi biçimde ayıran doğru denklemi elde edilirse hem bir sınıflandırma yapılabilir hem de yeni değerlerin hangi sınıf içerisinde gireceği yönünde bir kestirim aracı da elde edilebilir. Bu durumda kestirim işlemi sınıfı belirlenecek noktanın doğrunun yukarısında mı yoksa aşağısında mı kaldığına göre yapılabilecektir. Aslında buradaki yaklaşım yukarıda yaptığımız doğrusal regresyon örneğine benzemektedir.

Pekiyi iki sınıfı birbirinden ayırmak için elde edeceğimiz doğru denkleminde amaç fonksiyonu ne olmalıdır? Yani biz iterasyonlar sırasında neyi küçütmeye çalışmalıyız? İki kümeyi ayıran doğru denklemi $y = mx + n$ olarak ifade edelim. Bir (x_0, y_0) gibi nokta söz konusu olsun. Buradaki x_0 değerinin doğru üzerindeki yeri $mx_0 + n$ olacaktır. Bu durumda noktanın doğruya uzaklışı da $y_0 - (mx_0 + n)$ olur.



Burada eğer nokta doğrunun yukarısındaysa $y_0 - (mx_0 + n)$ değerinin pozitif aşağısındaysa negatif olacağına dikkat ediniz. Şimdi bizim noktanın doğruya uzaklığını onun sınıfıyla ilişkilendirmemiz gereklidir. Bunun da basit bir yolu sigmoid fonksiyonunu kullanmaktır. Sigmoid fonksiyonunu anımsayınız. Bu fonksiyon herhangi bir x değerini 0 ile 1 arasında bir y değerine eşliyor:



Akıntı Notu: Görsel <https://www.sciencedirect.com/topics/computer-science/logistic-sigmoid> adresinden alınmıştır.

Bu durumda biz noktanın doğruya uzunluğunu sigmoid fonksiyonuna sokarsak bu fonksiyon bize 0 ile 1 arasında bir değer verecektir. Ve aynı zamanda söz konusu olan nokta doğrunun ne kadar yukarısındaysa 1'e o kadar yaklaşacak, ne kadar aşağısındaysa 0'a o kadar yaklaşacaktır. Bu durumda problemimizin amaç fonksiyonu (yani en küçüklenecek fonksiyon) gerçek değerlerden bu sigmoid değerlerinin çıkartılması biçiminde oluşturulabilir. Yani bizim bu problemde minimize etmeye çalışacağımız ifade şöyledir:

noktanın sınıfı - sigmoid(noktanın doğruya uzunluğu)

Noktaların sınıfının 0 ve 1 ile temsil edildiğine dikkat ediniz. O halde lojistik regresyon problemi aslında bu amaç fonksiyonunun minimize edilmesi biçiminde bir optimizasyon problemi haline dönüştürülmüş olmaktadır. Bu optimizasyon işlemi de yavaş yavaş, oluşan hata dikkate alınarak gradient descent yöntemiyle yapılabilmektedir. Çözüme bu biçimde varan bir programı şöyle yazabilirisiz:

```

import numpy as np

dataset = np.loadtxt('test.csv', skiprows=1, delimiter=',', dtype=np.float32)
dataset_x = dataset[:, :2]
dataset_y = dataset[:, 2].reshape(-1, 1)

dataset_x = np.append(dataset_x, np.ones((dataset_x.shape[0], 1)), axis=1)

def sigmoid(x):
    return 1.0 / (1 + np.exp(-x))

def gradeint_descent_logistic(dataset_x, dataset_y, learning_rate=0.001, epoch=50000):
    weights = np.ones((dataset_x.shape[1], 1))

    for k in range(epoch):
        h = sigmoid(np.matmul(dataset_x, weights))
        error = dataset_y - h
        weights = weights + learning_rate * np.matmul(dataset_x.transpose(), error)

    return weights

weights = gradeint_descent_logistic(dataset_x, dataset_y)

import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches(10, 8)
plt.title("Gradient Descent Logistic Regression")
plt.scatter(dataset[dataset[:, 2] == 1, 0], dataset[dataset[:, 2] == 1, 1], color='blue')
plt.scatter(dataset[dataset[:, 2] == 0, 0], dataset[dataset[:, 2] == 0, 1], color='red')
plt.xlabel('x')
plt.ylabel('y')

```

```

x = np.linspace(-5, 5, 100)
y = (-weights[2] - weights[0] * x) / weights[1]
plt.plot(x, y)
plt.show()

```

Buradaki "test.csv" dosyasının içeriği şöyledir:

```

x,y,class
-0.017612,14.053064,0
-1.395634,4.662541,1
-0.752157,6.538620,0
-1.322371,7.152853,0
0.423363,11.054677,0
0.406704,7.067335,1
0.667394,12.741452,0
-2.460150,6.866805,1
0.569411,9.548755,0
-0.026632,10.427743,0
0.850433,6.920334,1
1.347183,13.175500,0
1.176813,3.167020,1
-1.781871,9.097953,0
-0.566606,5.749003,1
0.931635,1.589505,1
-0.024205,6.151823,1
-0.036453,2.690988,1
-0.196949,0.444165,1
1.014459,5.754399,1
1.985298,3.230619,1
-1.693453,-0.557540,1
-0.576525,11.778922,0
-0.346811,-1.678730,1
-2.124484,2.672471,1
1.217916,9.597015,0
-0.733928,9.098687,0
-3.642001,-1.618087,1
0.315985,3.523953,1
1.416614,9.619232,0
-0.386323,3.989286,1
0.556921,8.294984,1
1.224863,11.587360,0
-1.347803,-2.406051,1
1.196604,4.951851,1
0.275221,9.543647,0
0.470575,9.332488,0
-1.889567,9.542662,0
-1.527893,12.150579,0
-1.185247,11.309318,0
-0.445678,3.297303,1
1.042222,6.105155,1
-0.618787,10.320986,0
1.152083,0.548467,1
0.828534,2.676045,1
-1.237728,10.549033,0
-0.683565,-2.166125,1
0.229456,5.921938,1
-0.959885,11.555336,0
0.492911,10.993324,0
0.184992,8.721488,0
-0.355715,10.325976,0
-0.397822,8.058397,0
0.824839,13.730343,0
1.507278,5.027866,1
0.099671,6.835839,1
-0.344008,10.717485,0
1.785928,7.718645,1
-0.918801,11.560217,0
-0.364009,4.747300,1
-0.841722,4.119083,1
0.490426,1.960539,1
-0.007194,9.075792,0
0.356107,12.447863,0
0.342578,12.281162,0
-0.810823,-1.466018,1
2.530777,6.476801,1
1.296683,11.607559,0

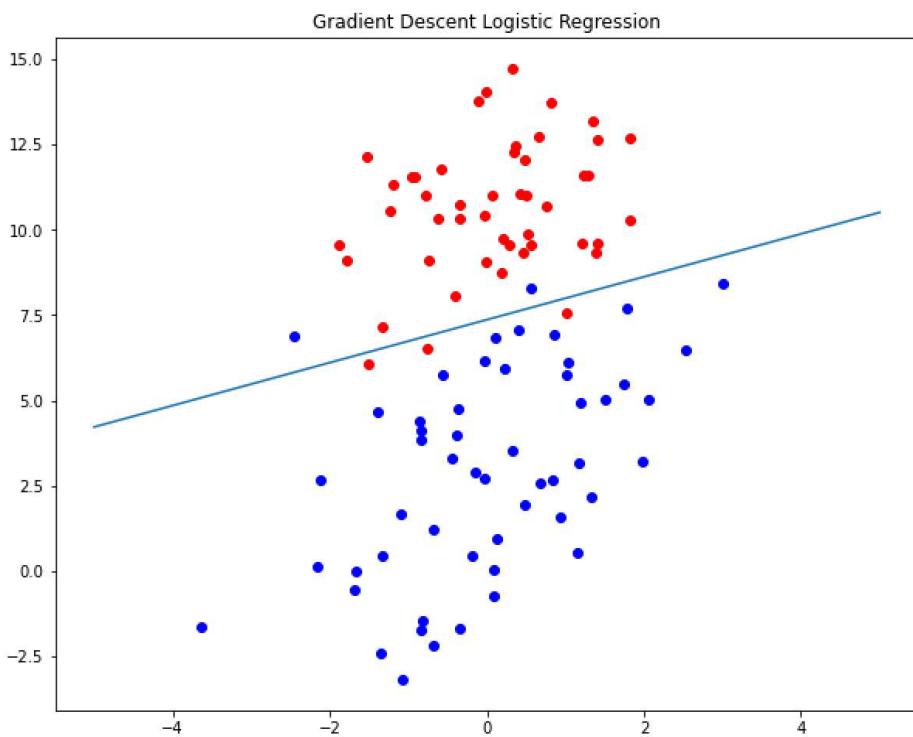
```

```

0.475487, 12.040035,0
-0.783277,11.009725,0
0.074798,11.023650,0
-1.337472,0.468339,1
-0.102781,13.763651,0
-0.147324,2.874846,1
0.518389,9.887035,0
1.015399,7.571882,0
-1.658086,-0.027255,1
1.319944,2.171228,1
2.056216,5.019981,1
-0.851633,4.375691,1
-1.510047,6.061992,0
-1.076637,-3.181888,1
1.821096,10.283990,0
3.010150,8.401766,1
-1.099458,1.688274,1
-0.834872,-1.733869,1
-0.846637,3.849075,1
1.400102,12.628781,0
1.752842,5.468166,1
0.078557,0.059736,1
0.089392,-0.715300,1
1.825662,12.693808,0
0.197445,9.744638,0
0.126117,0.922311,1
-0.679797,1.220530,1
0.677983,2.556666,1
0.761349,10.693862,0
-2.168791,0.143632,1
1.388610,9.341997,0
0.317029,14.739025,0

```

Şöyledir bir çıktı elde edilmiştir:



Şimdi algoritmada yapılanları adım adım açıklamak istiyoruz:

- Önce "test.csv" dosyasından değerler okunmuştur. Bu işlemin sonucunda dataset_x ve dataset_y biçiminde iki ndarray elde edilmiştir. dataset x iki sütunlu aşağıdaki biçimde bir matristir:

—
—
—
—
—
...

dataset_y ise tek sütunlu aşağıdaki biçimsel görünümü sahiptir:

—
—
—
—
—
...

dataset_y dizisi 0 ve 1 değerlerinden oluşmaktadır. Bu değerler sınıfları belirtmektedir.

- Bizim eğitimden amacımız aslında noktaların doğruya uzaklıklarının sigmoid fonksiyonuna sokularak gerçek y değerlerinden çıkartılması ile elde edilen ifadenin minimize edilmesidir. Doğru denkleminin $y = mx + n$ biçiminde olduğunu ve x_0 ve y_0 noktalarının doğruya uzunlıklarının $y_0 - (mx_0 + n)$ olduğunu anımsayınız. Aslında biz bu uzunluğu kolaylık olsun diye $ax_0 + by_0 + c$ biçiminde de ifade edebiliriz. Tabii buradaki a, b, c değerleri pozitif negatif ya da sıfır olabilir. Bizim bu algoritmada yapmaya çalıştığımız şey aslında $ax_0 + by_0 + c$ değerlerini en küçükleyen a, b, ve c değerlerini bulmaktır. Biz de bu işlemi kolay yapabilmek için dataset_x matrisine bir sütun daha ekledik. Başlangıçta bu sütundaki değerleri 1 olarak aldık:

↙ 1 deger
—
—
—
—
—
...

- Bundan sonra programda a, b, c değerleri için weights isminde 3 elemanlı bir sütun vektörü oluşturduk.

weights
—
—
—

Böylece aslında biz dataset_x ile weights matrislerini matrisel biçimde çarptığımızda noktanın doğruya uzaklıklarını elde etmiş oluyoruz.

- Daha sonra elde edilen uzaklıkları sigmoid fonksiyonuna sokup bunları y değerlerinden çıkartılarak hata miktarlarını bulduk.

```
for k in range(epoch):
    h = sigmoid(np.matmul(dataset_x, weights))
    error = dataset_y - h
    weights = weights + learning_rate * np.matmul(x.transpose(), error)
```

- Buradaki amaç fonksiyonu (yani minimize edilecek fonksiyon) dataset_y – h fonksiyonudur. Her yinelemede bu error değerleri weights değerleriyle çarpılarak hata azaltılmaya çalışılmıştır.

Pekiyi yukarıdaki örnekte yöntemin başarısını nasıl test edebiliriz? Bunun için ilk akla gelen yol başarılı olanların oranını tespit etmektir. Bu tespit şöyle yapılabilir:

```
result = np.matmul(dataset_x, weights)
success_ratio = np.sum((result > 0) == dataset_y) / len(dataset_y)
print(success_ratio)
```

Buradan 0.95 değeri elde edilmiştir.

Birtakım değerleri gruplandırmak için kursumuzda şimdiye kadar şu yöntemleri görmüş olduk:

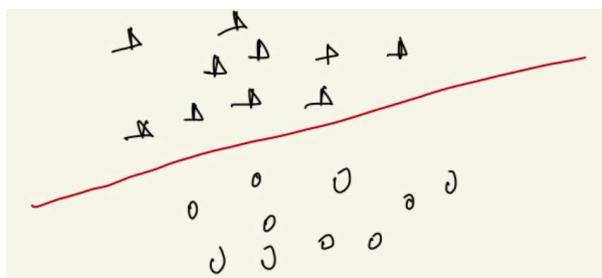
- Yapay Sinir Ağları (Denetimli Sınıflandırma Tarzı)
- Kümeleme Yöntemleri (Denetimsiz Kümeleme Tarzı)
- İstatistiksel Lojistik Regresyon (Denetimli Sınıflandırma Tarzı)

Pekiyi gruplandırma amacıyla biz bu yöntemlerden hangisini ne zaman tercih etmeliyiz?

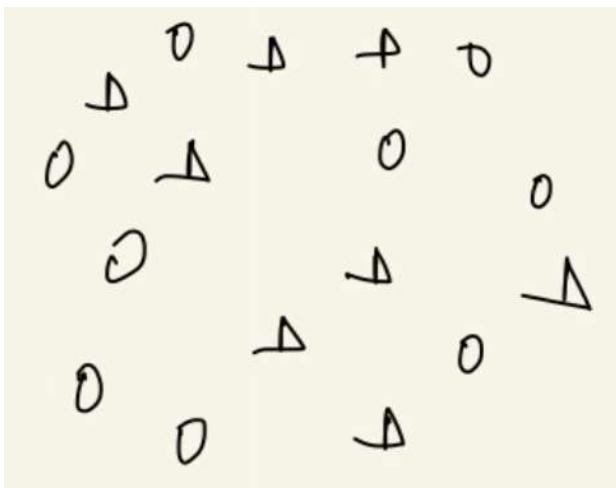
- Eğer elimizde yalnızca dataset_x varsa ama bunların hangi gruptara girdiğine yönelik dataset_y yoksa biz mecburen K-Means, DBSCAN, OPTICS gibi denetimsiz kümeleme yöntemlerini kullanırız.
- Eğer elimizde dataset_x verilerinin yanı sıra bunların zaten hangi sınıflarda olduğunu belirten bir dataset_y verileri de varsa biz yapay sinir ağları ve istatistiksel lojistik regresyon yöntemlerini kullanabiliriz. (Tabii aslında eğitim için gereken dataset_y verileri olsa da biz bunlardan faydalananmayıp yine K-Means ve DBSCAN gibi kümeleme yöntemlerini kullanabiliriz. Ancak genel olarak eğitimli sınıflandırma yöntemleri bu durumda kümeleme yöntemlerine göre tercih edilmektedir.)

Pekiyi elimizde eğitimli öğrenme için kullanabileceğimiz dataset_x ve dataset_y verileri bulunuyor olsun. Bu durumda yapay sinir ağları mı yoksa istatistiksel lojistik regresyon yöntemi mi tercih edilmelidir? İşte eğer veri kümelerindeki noktalar "doğrusal olarak ayırtılabilir" biçimdeyse yani bir doğru ile iki sınıf birbirlerinden ayrılabiliriyorsa istatistiksel lojistik regresyon daha hızlı ve uygun olmaktadır. Ancak veri kümelerindeki noktalar doğrusal olarak ayırtılabilir biçimde değilse bu durumda istatistiksel lojistik regresyon yönteminin performansı düşmektedir. Eğitim için yeterli veri varsa yapay sinir ağları bu tür durumlarda daha uygun olmaktadır.

Örneğin aşağıdaki veri kümelerindeki noktalar doğrusal olarak ayırtılabilir biçimdedir:



Burada biz yapay sinir ağı yerine istatistiksel lojistik regresyon yöntemini tercih edebiliriz. Aşağıdaki veriler ise doğrusal olarak ayırtılabilir olmayan biçimdedir:



Burada biz bir doğru denklemi elde ederek verileri iyi bir biçimde sınıflandıramayız. İşte bu tür durumlarda eğitim için yeterli veri varsa yapay sinir ağları tercih edilmelidir. Maalesef sınıflandırma problemlerinin önemli bir bölümü "doğrusal olarak ayırtılabilir" biçimde değildir.

Çoklu İstatistiksel Lojistik Regresyon

Yukarıdaki örneklerde biz x ve y biçiminde iki özelliği olan veri kümesindeki noktaları istatistiksel lojistik regresyonla sınıflandırırdık. Pekiyi özellik sayısı ikiden fazla olursa bu durumda ne yapabiliz? İşte aslında n tane özellik n boyutlu bir uzayı tanımlamaktadır. Dolayısıyla n tane özelliğe sahip olan bir veri kümesindeki noktalar n boyutlu uzayın hyperplane'ı ile ayırtılabilirlerdir. Yani iki boyutlu uzaya lojistik regresyon için bir doğru elde edilmeye çalışılırken n boyutlu uzaya lojistik regresyon için o n boyutlu uzayın düzlemi olan bir hyperplane elde edilmeye çalışılmaktadır.

Scikit-learn'deki Hazır LogisticRegression Sınıfının Kullanılması

Aslında Scikit-learn içerisinde zaten gradient descent yöntemiyle lojistik regresyon işlemini yapan LogisticRegression isimli yetenekli bir sınıf vardır. Bu sınıfın kullanılması oldukça kolaydır. Tek yapacağımız şey LogisticRegression sınıfı türünden bir nesne yaratmak ve bu nesneyle fit işlemini uygulamaktır. Bundan sonra artık predict metoduyla tahminleme yapabiliriz. Sınıfın score isimli metodu yapılan regresyonun başarı yüzdesini bize vermektedir. Yine burada elde edilen doğru denkleminin katsayılarını biz sınıfın coef_ isimli örnek özniteliğinden, eksen kesim noktasını da sınıfın intercept_ örnek özniteliğinden elde edebiliriz. Şimdi yukarıdaki örneği LogisticRegression sınıfıyla gerçekleştirelim. Önce verileri okuyalım:

```
import numpy as np

dataset = np.loadtxt('test.csv', skiprows=1, delimiter=',', dtype=np.float32)
dataset_x = dataset[:, :2]
dataset_y = dataset[:, 2]
```

Sonra LogisticRegression sınıfını kullanarak regresyon işlemini gerçekleştirelim:

```
lr = LogisticRegression()
lr.fit(dataset_x, dataset_y)

print(lr.coef_)
print(lr.intercept_)
```

Buradan elde ettiğimiz coef_ ve intercept_ değerlerine dikkat ediniz:

```
[[ 0.85767008 -1.54232427]]
[11.38607714]
```

Modelimizde iki değişken olduğu için bizim lojistik regresyon işleminden elde edeceğimiz doğru denklemi $a_0 + a_1x_1 + a_2x_2$ biçiminde olacaktır. Biz bunlara x ve y isimlerini verdığımızda elde edilen doğru denklemi de $lr.intercept_[0] + lr.coef_[0, 0] * x + lr.coef_[0, 1] * y$ biçiminde olacaktır. Buradan y değerini de şöyle elde edebiliriz:

$$y = (-lr.coef_[0, 0] * x - lr.intercept_[0]) / lr.coef_[0, 1]$$

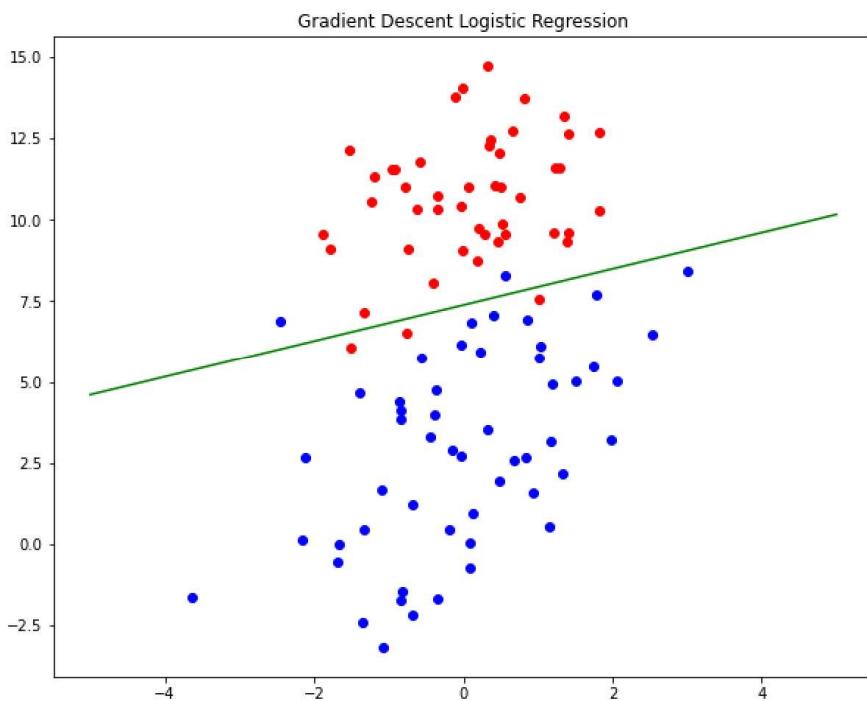
O halde noktaların ve doğrunun grafiğini de şöyle çizebiliriz:

```
x = np.linspace(-5, 5, 100)
y = (-lr.coef_[0, 0] * x - lr.intercept_[0]) / lr.coef_[0, 1]

import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches((10, 8))
plt.title("Gradient Descent Logistic Regression")
plt.scatter(dataset[dataset[:, 2] == 1, 0], dataset[dataset[:, 2] == 1, 1], color='blue')
plt.scatter(dataset[dataset[:, 2] == 0, 0], dataset[dataset[:, 2] == 0, 1], color='red')
plt.xlabel('x')
plt.ylabel('y')
plt.plot(x, y, color='green')
plt.show()
```

Şöyledir bir grafik elde edilmişdir:

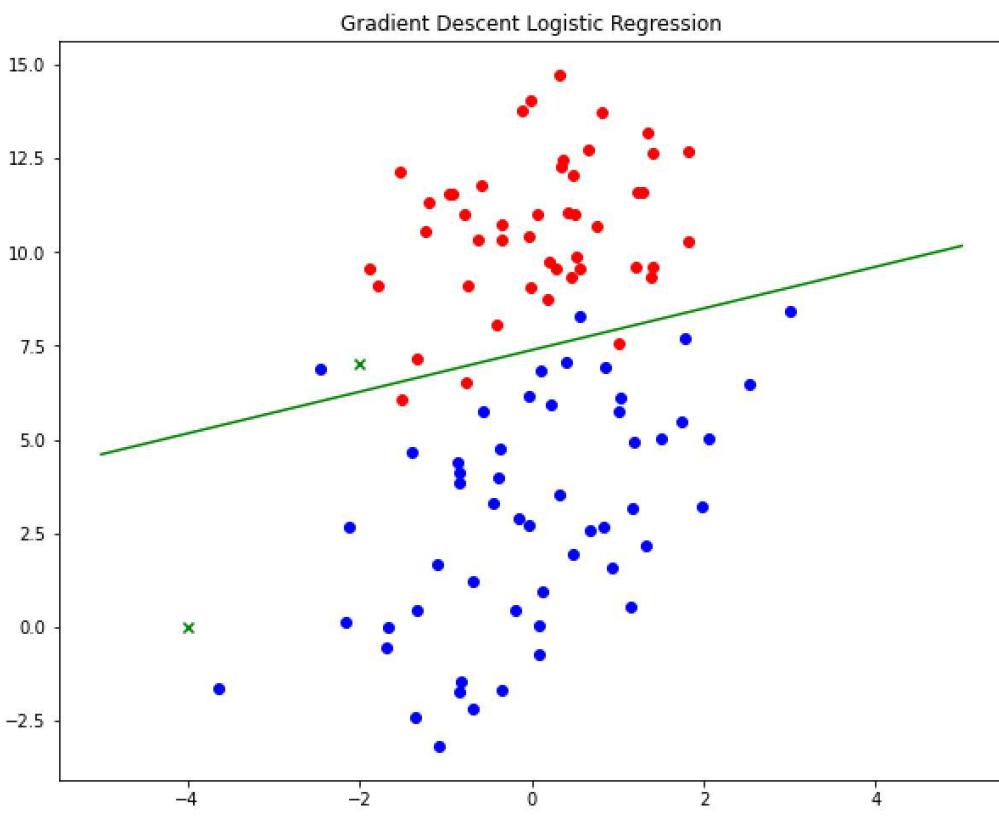


Şimdi de kestirim işlemini görsel olarak yapalım:

```
plt.title("Gradient Descent Logistic Regression")
figure = plt.gcf()
figure.set_size_inches((10, 8))
plt.scatter(dataset[dataset[:, 2] == 1, 0], dataset[dataset[:, 2] == 1, 1], color='b')
plt.scatter(dataset[dataset[:, 2] == 0, 0], dataset[dataset[:, 2] == 0, 1], color='r')
plt.xlabel('x')
plt.ylabel('y')
plt.plot(x, y, color='green')

plt.scatter(predict_points[:, 0], predict_points[:, 1], color='green', marker='x')
plt.show()
```

Şu grafik elde edilmiştir:



Burada görsel olarak noktalardan birinin 1 numaralı sınıfı, diğerinin 0 numaralı sınıfı ilişkin olduğu görülmektedir. Tabii kestirimi doğrudan aslında LogisticRegression sınıfının predict metodu ile yapabiliriz. Bu metot kestirim yapılacak noktayı doğru denkleminde yerine koyarak değerin pozitif ya da negatif olmasına göre bize 0 ya da 1 değerini vermektedir:

```
predict_result = lr.predict(predict_points)  
print(predict_result)
```

Şu sonuçlar elde edilmiştir:

```
[0. 1.]
```

Yine LogisticRegression sınıfının score isimli metodunu bize yapılan tahminlerin doğruluk yüzdesini vermektedir:

```
print(lr.score(dataset_x, dataset_y))
```

Şu sonuç elde edilmiştir:

```
0.95
```

LogisticRegression nesnesini yaratırken aslında `__init__` metodunda pek çok argüman da girebiliriz. Bu argümanların hepsi default değer almış durumdadır. Aşağıda fonksiyonun parametre listesi görülmektedir:

```
class sklearn.linear_model.LogisticRegression(penalty='L2', dual=False, tol=0.0001, C=1.0, fit_intercept=True, intercept_scaling=1, class_weight=None, random_state=None, solver='lbfgs', max_iter=100, multi_class='auto', verbose=0, warm_start=False, n_jobs=None, l1_ratio=None)
```

Buradaki `max_iter` parametresi gradient descent uygulanırken kaç yineleme yapılacağını (yani bizim örneğimizdeki epoch) belirtmektedir. Bu parametrenin default değerinin 100 olduğunu dikkat ediniz. Fonksiyonun `solver` parametresi çözüm algoritmasını belirlemek için kullanılmaktadır. Küçük veri kümesi için bu parametrenin 'liblinear' girilmesi uygun olabilmektedir.

Lojistik regresyon uygulamalarında veri bilimcisi gerçek değerlerle tahmin edilen değerler arasındaki farkı görmek isteyebilir. Örneğin gerçekte 1 olması gereken değerlerin kaç tanesi 1 kaç tanesi 0 olmuştur gibi. İşte bunu gösteren matrise "confusion matrix" denilmektedir. Confusion matrix şüphesiz manuel biçimde oluşturulabilir. Ancak Scikit-Learn içerisinde sklearn.metrics modülünde bu matrisi oluşturan hazır bir confusion_matrix isimli fonksiyon vardır. Bu fonksiyon bizden iki parametre ister. Birinci parametre gerçek y değerlerini ikinci parametre ise tahmin edilmiş olan y değerlerini belirtmektedir. Yukarıdaki örneğimiz için confusion matrix şöyle oluşturulmuştur:

```
from sklearn.metrics import confusion_matrix

result = confusion_matrix(dataset_y, lr.predict(dataset_x))
print(result)

[[44  3]
 [ 2 51]]
```

Burada sınıflandırmada kullanılacak sınıf sayısı iki olduğu için confusion matrix 2x2 boyutundadır. Genel olarak sınıf sayısı n olmak üzere bu matris nxn boyutunda olur. Confusion matrix'te (i, j) hücresi gerçek durumun i olması halinde bunun j biçiminde tespit edildiği nokta sayısını vermektedir. Örneğin yukarıdaki matriste gerçek sonuç 0 iken 0 sonucu 44 kez elde edilmiştir. Öte yandan gerçek sonuç 0 iken 1 sonucu 3 kez elde edilmiştir. Benzer biçimde gerçek sonuç 1 iken 0 sonucu 2 kez, gerçek sonuç 1 iken 1 sonucu 51 kez elde edilmiştir. Gerçekten de grafik incelendiğinde kırmızıların 3 tanesinin doğrunun altında olduğu, mavilerin de 2 tanesinin doğrunun üzerinde olduğu görülmektedir.

Şüphesiz biz bu confusion matrix'i nokta sayısına bölersek oransal bir matris elde edebiliriz:

```
result_ratio = result / len(dataset_y)
print(result_ratio)

[[0.44 0.03]
 [0.02 0.51]]
```

Yukarıdaki kodu bir bütün olarak aşağıda veriyoruz:

```
import numpy as np

dataset = np.loadtxt('test.csv', skiprows=1, delimiter=',', dtype=np.float32)
dataset_x = dataset[:, :2]
dataset_y = dataset[:, 2]

from sklearn.linear_model import LogisticRegression

lr = LogisticRegression()
lr.fit(dataset_x, dataset_y)

print(lr.coef_)
print(lr.intercept_)

x = np.linspace(-5, 5, 100)
y = (-lr.coef_[0, 0] * x - lr.intercept_[0]) / lr.coef_[0, 1]

import matplotlib.pyplot as plt

figure = plt.gcf()
figure.set_size_inches((10, 8))
plt.title("Gradient Descent Logistic Regression")
plt.scatter(dataset[dataset[:, 2] == 1, 0], dataset[dataset[:, 2] == 1, 1], color='b')
plt.scatter(dataset[dataset[:, 2] == 0, 0], dataset[dataset[:, 2] == 0, 1], color='r')
plt.xlabel('x')
plt.ylabel('y')
plt.plot(x, y, color='green')
```

```

plt.show()

predict_points = np.array([[-2, 7], [-4, 0]])

plt.title("Gradient Descent Logistic Regression")
figure = plt.gcf()
figure.set_size_inches(10, 8)
plt.scatter(dataset[dataset[:, 2] == 1, 0], dataset[dataset[:, 2] == 1, 1], color='b')
plt.scatter(dataset[dataset[:, 2] == 0, 0], dataset[dataset[:, 2] == 0, 1], color='r')
plt.xlabel('x')
plt.ylabel('y')
plt.plot(x, y, color='green')

plt.scatter(predict_points[:, 0], predict_points[:, 1], color='green', marker='x')
plt.show()

score = lr.score(dataset_x, dataset_y)
print('score = {}'.format(score))

predict_result = lr.predict(predict_points)
print(predict_result)

print(lr.score(dataset_x, dataset_y))

from sklearn.metrics import confusion_matrix

result = confusion_matrix(dataset_y, lr.predict(dataset_x))
print(result)

result_ratio = result / len(dataset_y)
print(result_ratio)

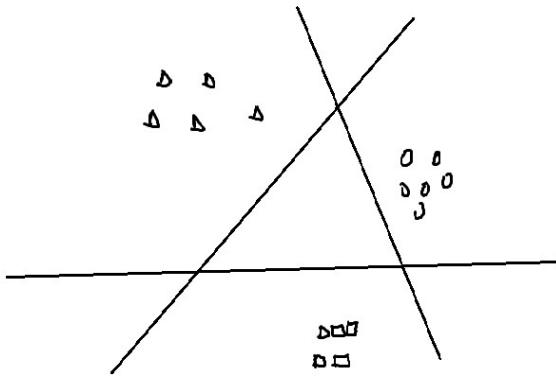
```

Scikit-learn kütüphanesindeki hazır LogisticRegression sınıfı aslında çok daha genel gerçekleştirilmiştir. Biz bu sınıfla sonraki konularda da ele alınacağı gibi çok sütundan oluşan ve birden fazla sınıftan ve etiketten oluşan lojistik regresyon problemlerini de çözebiliriz. Önceki konularda da belirtildiği gibi lojistik regresyon denildiğinde ikili sınıflandırma anlaşılmaktadır. Fakat LogisticRegression sınıfı aslında çok çok sınıflı lojistik regresyon modellerinde de kullanılabilmektedir. İzleyen bölümlerde böyle çok sınıflı lojistik regresyon örnekleri verilmektedir. Ayrıca Scikit-learn kütüphanesindeki LogisticRegression sınıfı çok etiketli (çok değişkenli) sınıflandırmalar için de kullanılabilmektedir.

Çok Sınıflı İstatistiksel Lojistik Regresyon

İstatistiksel lojistik regresyon işleminde biz iki sınıfı veri kümesi kullandık. İki sınıfı veri kümesi tek bir doğru ile (genel olarak hyperplane ile) ayırtılabilimektedir. Peki ya sınıf sayısı ikiden fazla olursa ne olacaktır? İşte ikiden fazla sınıf ancak ikiden fazla doğru ile ayırtılabilimektedir.

Daha önce çok sınıfı (yani sınıf sayısı 2'den fazla olan) lojistik regresyonlar için sınıf sayısı kadar doğru oluşturduğunu belirtmiştim. Örneğin zambak verilerinde zambaklar 3 sınıftan birine sokulmak istenmektedir. Yani örneğin zambak veri kümesindeki sınıf sayısı 3'tür. Bu durumda LogisticRegression sınıfı bize 3 tane doğru vermelidir. Gerçekten de bu problemde coef_ matrisi 3X4 boyutunda olacaktır. Tabii her doğru eksenleri kestiğine göre her doğru için bir intercept_ olması gereklidir. Bu durumda zambak örneğinde bize verilen intercept_ vektörü de 3 olacaktır. Peki neden n sınıf için n tane doğru gerekmektedir? Aslında bu n doğrunun her biri bir sınıfı diğer tümünden ayırmak için kullanılmaktadır.



Çok Sınıflı İstatistiksel Lojistik Regresyon İçin Zambak Örneği

Anımsanacağı gibi zambak (iris) veri kümesi 4 özellikten hareketle zambakların ürünü 3 seçenekten biri biçiminde belirleyebilmek için oluşturulmuş bir örnek veri kümesidir. Burada biz bu veri kümesini kullanarak LogisticRegression sınıfı ile çok sınıflı lojistik regresyon uygulaması yapacağız. Aşağıdaki kodu inceleyiniz:

```
from sklearn.datasets import load_iris

iris = load_iris()
dataset_x = iris.data
dataset_y = iris.target

from sklearn.model_selection import train_test_split

training_dataset_x, test_dataset_x, training_dataset_y, test_dataset_y =
train_test_split(dataset_x, dataset_y, test_size=0.25)

from sklearn.linear_model import LogisticRegression

lr = LogisticRegression()
lr.fit(training_dataset_x, training_dataset_y)

result = lr.score(test_dataset_x, test_dataset_y)
print(f'Score = {result}')

from sklearn.metrics import confusion_matrix

predict_result = lr.predict(test_dataset_x)
cm = confusion_matrix(test_dataset_y, predict_result)
print(cm)
```

Buradan elde edilen skor ve confusion_matrix değerleri şöyledir:

```
score = 0.9736842105263158
[[13  0  0]
 [ 0 12  1]
 [ 0  0 12]]
```

Göründüğü gibi test verileri ile yapılan denemedede yalnızca 1 numaralı tür 1 kere 2 olarak tespit edilmiştir.

Burada zambak örneğindeki %97'lük bu başarı Iris verilerinin "doğrusal olarak ayırtılabilir (linearly separable)" olduğunu göstermektedir. Eğer Iris verileri doğrusal olarak ayırtılabilir olmasaydı bizim başarımız düşük kalırdı. Böylece biz burada gredient descent lojistik regresyon kullanmamamız gerektiğini anladık ve yapay sinir ağları ya da ileride göreceğimiz "destek vektör makineleri (support vector machines)" gibi alternatif yöntemleri denememiz uygun olurdu.

Buradaki Iris örneğinde coef_ ve intercept_ örnek özniteliklerini yazdırduğumda şunları görmekteyiz:

```
print(lr.coef_)
print()
print(lr.intercept_)

[[-0.44695305  0.7897291 -2.34012927 -0.95547692]
 [ 0.60398165 -0.30810544 -0.19988568 -0.93823562]
 [-0.15702859 -0.48162367  2.54001496  1.89371254]]

[ 9.86891014  1.52164148 -11.39055162]
```

Burada katsayı matrisinin 3×4 'luk olduğunu görüyorsunuz. Matrisin 3 satırdan oluşması sonraki konuda açıklandığı gibi 3 sınıfın 3 doğru ile ayrıştırılmasından kaynaklanmaktadır. Yani 3 sınıfı bir lojistik regresyonda biz bu 3 sınıfı 3 ayrı doğruya ayrıstırabilmekteyiz. Katsayı matrisinin 4 sütundan oluşması ise regresyonda 4 tane değişkenin (yani sütunun) bulunuyor olmasındanandır. Eksen kesim matrisinin 1×3 'luk olduğuna da dikkat ediniz. Her doğrunun bir tane eksen kesim noktası bulunmaktadır.

Çok Sınıflı İstatistiksel Lojistik Regresyon İçin MNIST Örneği

Anımsanacağı gibi MNIST veri kümesi her biri 28×28 pixelden oluşan gray-scale resimlerden oluşuyordu. Bu resimlerde 0-9 arasındaki sayılar bulunmaktadır. Bizim amacımız da yeni bir resmi verdığımızda bunun üzerindeki sayının belirlenmesiydi. Biz MNIST örneğini daha önce yapay sinir ağları konusunda yapmıştık. Şimdi aynı örneği LogisticRegression sınıfıyla yapalım:

```
from tensorflow.keras.datasets import mnist

(training_dataset_x, training_dataset_y), (test_dataset_x, test_dataset_y) = mnist.load_data()

training_dataset_x = training_dataset_x.reshape(-1, 28 * 28)
training_dataset_y = training_dataset_y
test_dataset_x = test_dataset_x.reshape(-1, 28 * 28)

from sklearn.linear_model import LogisticRegression

lr = LogisticRegression(max_iter=1000)
lr.fit(training_dataset_x, training_dataset_y)

result = lr.score(test_dataset_x, test_dataset_y)
print(f'Score = {result}')
```

Elde ettiğimiz başarı skoru şöyledir:

```
score = 0.9255
```

Bu yüksek başarı değerinden yine MNIST verilerinin "doğrusal olarak ayırtılabilir olduğunu" görüyorsunuz. Confusion matrix ise şöyledir:

```
from sklearn.metrics import confusion_matrix

predicted_test_y = lr.predict(test_dataset_x)
cm = confusion_matrix(test_dataset_y, predicted_test_y)
print(cm)
```

```

[[ 963    0    0    3    1    3    4    4    2    0]
 [  0 1112    4    2    0    1    3    2   11    0]
 [  3   10  926   15    6    4   15    8   42    3]
 [  4    1   21  916    1   26    3    9   22    7]
 [  1    1    7    3  910    0    9    7   10   34]
 [ 11    2    1   33   11  776   11    6   35    6]
 [  9    3    7    3    7   16  910    2    1    0]
 [  1    6   24    5    7    1    0  951    3   30]
 [  8    7    6   23    6   26   10   10  869    9]
 [  9    7    0   11   25    6    0   22    7  922]]
```

Çok Sınıflı İstatistiksel Lojistik Regresyonlarda Regresyon Doğruları

Çok sınıflı lojistik regresyon problemlerinin "doğrusal olarak ayırtılabilir" olması aslında her bir sınıfın yalnızca bir doğru ile diğerlerinden ayırtılabilir olması anlamına gelmektedir. Daha önce belirttiğimiz gibi doğrusal olarak ayırtılamayan sınıflandırma problemlerinde istatistiksel lojistik regresyonun başarısı düşük olacaktır.

Şimdi biz bu doğruları elde edebilmek için 2 sütunlu 3 sınıfı bir lojistik regresyon örneği yapalım:

```

import numpy as np

from sklearn.datasets.samples_generator import make_blobs

dataset_x, dataset_y = make_blobs(n_samples=100, n_features=2, centers=3, cluster_std=1)

from sklearn.linear_model import LogisticRegression

lr = LogisticRegression()
lr.fit(dataset_x, dataset_y)
from sklearn.datasets.samples_generator import make_blobs

dataset_x, dataset_y = make_blobs(n_samples=100, n_features=2, centers=3, cluster_std=0.5)

from sklearn.linear_model import LogisticRegression

lr = LogisticRegression()
lr.fit(dataset_x, dataset_y)

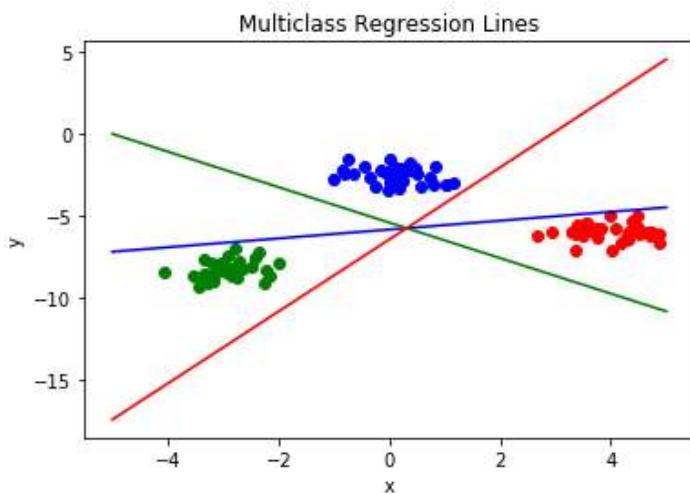
score = lr.score(dataset_x, dataset_y)
print(score)

import numpy as np
import matplotlib.pyplot as plt

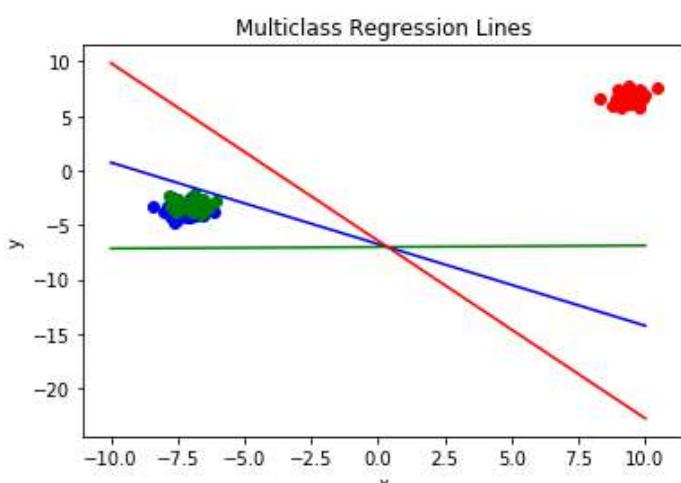
plt.title('Multiclass Regression Lines')
plt.xlabel('x')
plt.ylabel('y')

plt.scatter(dataset_x[dataset_y == 0, 0], dataset_x[dataset_y == 0, 1], color='blue')
plt.scatter(dataset_x[dataset_y == 1, 0], dataset_x[dataset_y == 1, 1], color='green')
plt.scatter(dataset_x[dataset_y == 2, 0], dataset_x[dataset_y == 2, 1], color='red')

x = np.linspace(-5, 5, 100)
for i in range(3):
    y = (-lr.coef_[i, 0] * x - lr.intercept_[i]) / lr.coef_[i, 1]
    plt.plot(x, y, color=['blue', 'green', 'red'][i])
```



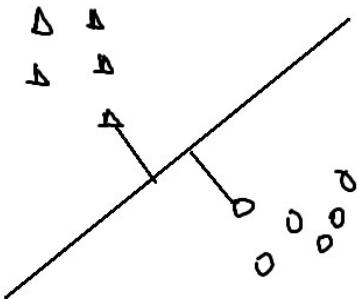
Buradan elde edilen score 1'dir. Bu mükemmel bir ayrıştırma anlamına gelmektedir. Şimdi doğrusal olarak ayrıştırılabilir olmayan bir örnek verelim:



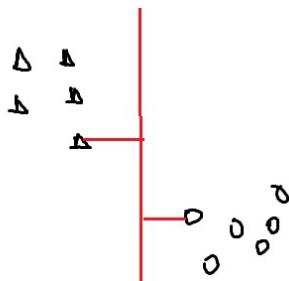
Buradaki skor 0.78 olarak elde edilmiştir.

DESTEK VEKTÖR MAKİNELERİ (SUPPORT VECTOR MACHINES)

Destek vektör makineleri de eğitimli (supervised) sınıflandırma yöntemlerinden biridir. Destek vektör makinelerinde de aslında sınıfları ayırmak için doğrular kullanılmaktadır. Ancak bu doğrular en yakın noktaları ayırma amacıyla oluşturulmaktadır. Bu en yakın noktalara destek vektörleri (support vectors) denilmektedir. Örneğin:

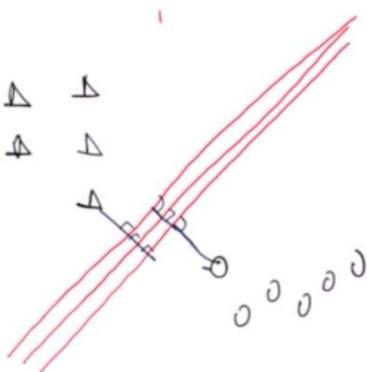


Burada iki sınıfı ayırmak için öyle bir doğru oluşturulur ki bu doğru şu özelliğe sahiptir: "Bu doğuya en yakın iki sınıfındaki noktalar ele alındığında bu noktalar ile doğru arasındaki toplam uzaklık diğer alternatif doğrulara göre daha fazla olmalıdır". Buradaki noktanın doğuya uzaklığında dikme uzaklığı kullanılmaktadır. Örneğin aşağıdaki diğer bir alternatif doğruya göz önüne alalım:

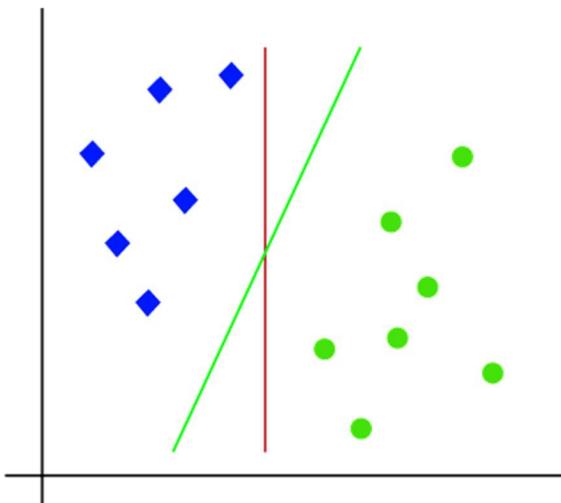


Peki yukarıdaki iki doğruda hangi doğru için doğuya en yakın iki nokta ile doğru arasındaki toplam uzaklık daha fazladır? Şekilden gözle baktığımızda birinci doğrunun en yakın iki noktasının doğuya olan toplam uzaklığının daha fazla olduğu görülmüyor. Ancak bu iki kümeyi ayırbilecek sonsuz sayıda doğru söz konusu olmaktadır. Bu doğruların belirlediğimiz ölçüte göre en iyisini bulmak bir optimizasyon problemdir. Bu optimizasyon probleminde hedefimiz yukarıda da belirttiğimiz gibi doğuya iki sınıfındaki en yakın noktaların uzakları toplamını maksimum yapan doğruya elde etmektir.

Doğuya en yakın noktalarla doğru arasındaki toplam uzaklığa marjin, söz konusu bu doğuya da genel olarak "hyperplane" denilmektedir. Peki marjini aynı olan sonsuz sayıda paralel doğru elde edilebileceğine göre bunlardan hangisi seçilecektir? İşte en yakın iki noktaya uzaklıklarını eşit olan marjini en yüksek doğru seçilmektedir.



Aşağıda iki sınıfı bir model için alternatif iki destek doğrusu görüyorsunuz:



Burada gözle de görüldüğü gibi yeşil kırmızı doğrudan daha iyidir.

Aslında belli bir marjin değerine ilişkin en yakın noktalar arasındaki uzaklık toplamına ilişkin aynı eğimde sonsuz sayıda doğru da söz konusu olmaktadır. Bu durumda destek vektörlerine eşit uzaklıktaki doğru hyperplane olarak belirlenmektedir.

Destek vektör makinelerinde uygun doğrunun elde edilmesi süreci teorik bakımdan biraz karışıktır. Biz burada bu doğrunun nasıl elde edileceği üzerinde durmayacağız. Bunun için başka kaynaklara başvurulabilir.

Destek vektör makineleri Scikit-learn içerisindeki SVC sınıfıyla temsil edilmektedir. Sınıfın `__init__` metodunun parametrik yapısı şöyledir:

```
class sklearn.svm.SVC(C=1.0, kernel='rbf', degree=3, gamma='scale', coef0=0.0, shrinking=True, probability=False, tol=0.001, cache_size=200, class_weight=None, verbose=False, max_iter=-1, decision_function_shape='ovr', break_ties=False, random_state=None)
```

Aslında destek vektör makineleri yalnızca sınıflandırma amacıyla değil aynı zamanda regresyon amacıyla da kullanılmaktadır. sklearn.svm modülündeki SVR (Support Vector Regression) sınıfı destek vektör makinelerinin regresyon amacıyla kullanılan biçimidir.

Şimdi destek vektör makineleri ile sınıflandırmaya bir örnek verelim. Bu sınıflandırma örneğinde Scikit-learn içerisinde bulunan kanser tarama verilerinin gerçekten kanser olup olmadığını belirlemeye çalışacağz. Scikit-learn'deki bu veri kümesinde kişilerden meme kanseri riski için önemli olabilecek bazı biyomedikal veriler elde edilmiştir. Amaç bu verilere dayanarak kişideki lezyonun iyi huylu mu (benign) yoksa kötü huylu mu (malign) olduğuna karar vermektir. Bu sınıflandırma probleminin destek vektör makineleri ile çözümü şöyledir:

```
from sklearn.datasets import load_breast_cancer

bc = load_breast_cancer()
print(f'Feature Names: {bc.feature_names}')
print(f'Class Names: {bc.target_names}')

dataset_x = bc.data
dataset_y = bc.target

from sklearn.model_selection import train_test_split

training_dataset_x, test_dataset_x, training_dataset_y, test_dataset_y =
train_test_split(dataset_x, dataset_y, test_size=0.3)
```

```

from sklearn.svm import SVC

svc = SVC(kernel='linear')
svc.fit(dataset_x, dataset_y)

score = svc.score(test_dataset_x, test_dataset_y)
print(score)

result = svc.predict(test_dataset_x)
ratio = sum(result == test_dataset_y) / len(test_dataset_y)
print(ratio)

```

Şöyledir bir sonuç elde edilmiştir:

```

0.9532163742690059
0.9532163742690059

```

Burada SVC nesnesi yaratılırken kernel olarak 'linear' verildiğine dikkat ediniz. Bu kernel doğrusal olarak ayırtılabilir veri kümesi için en iyi seçimdir. Anımsanacağı gibi doğrusal olarak ayırtılabilir veriler için gradient descent lojistik regresyon da kullanılabilir. Fakat eğer veriler doğrusal olarak ayırtılabilir değilse destek vektör makinelerinde ismine "kernel trick" denilen yöntemle boyut yükseltilmesi yapılarak sorun çözülmektedir. Halbuki lojistik regresyonda böyle bir "kernel trick" durumu yoktur. (Kernel trick aslında doğrusal olarak ayırtılamayan veri kümelerini boyut yükselterek doğrusal olarak ayırtılabilir hale getiren bir yöntemdir.) SVC sınıfının predict metodu ile kestirim yapılabilir. Yukarıdaki örnekte test_dataset_x verileri üzerinde predict ile kestirimde bulunulmuştur. SVC sınıfının score metodu yine kestirim yapıp başarı yüzdesini bize vermektedir. Yukarıdaki örnekte biz hem score metoduyla başarı yüzdesini bulduk hem de bunu manuel olarak hesapladık.

Tıpkı LinearRegression sınıfında olduğu gibi SVC sınıfında da hyperplane'e ilişkin doğru denkleminin katsayıları sınıfın coef_ örnek özniteliği ile, eksen kesim noktası da intercept_ özniteliği ile elde edilebilmektedir.

Şimdi aynı örneği Lojistik regresyon ile yapalım:

```

from sklearn.datasets import load_breast_cancer

bc = load_breast_cancer()
print(f'Feature Names: {bc.feature_names}')
print(f'Class Names: {bc.target_names}')

dataset_x = bc.data
dataset_y = bc.target

from sklearn.model_selection import train_test_split

training_dataset_x, test_dataset_x, training_dataset_y, test_dataset_y =
train_test_split(dataset_x, dataset_y, test_size=0.3)

from sklearn.linear_model import LogisticRegression

lr = LogisticRegression(max_iter=10000)
lr.fit(dataset_x, dataset_y)

score = lr.score(test_dataset_x, test_dataset_y)
print(score)

result = lr.predict(test_dataset_x)
ratio = sum(result == test_dataset_y) / len(test_dataset_y)
print(ratio)

```

Şu sonuçlar elde edilmiştir:

```
0.9532163742690059
0.9532163742690059
```

Elde edilen sonuçların aynı olduğunu görüyorsunuz.

Şimdi de iki özellik için make_blobs fonksiyonuyla rastgele veriler üreterek destek vektör makineleriyle elde edilen doğrula lojistik regresyondan elde edilen doğrulu grafiksel biçimde göstermeye çalışalım. SVC için yine "linear" kernel kullanacağız. Aşağıda böyle bir kod görüyorsunuz:

```
from sklearn.datasets import make_blobs

dataset_x, dataset_y = make_blobs(n_samples=100, n_features=2, centers=2, cluster_std=0.8)

from sklearn.svm import SVC

svc = SVC(kernel='linear')
svc.fit(dataset_x, dataset_y)

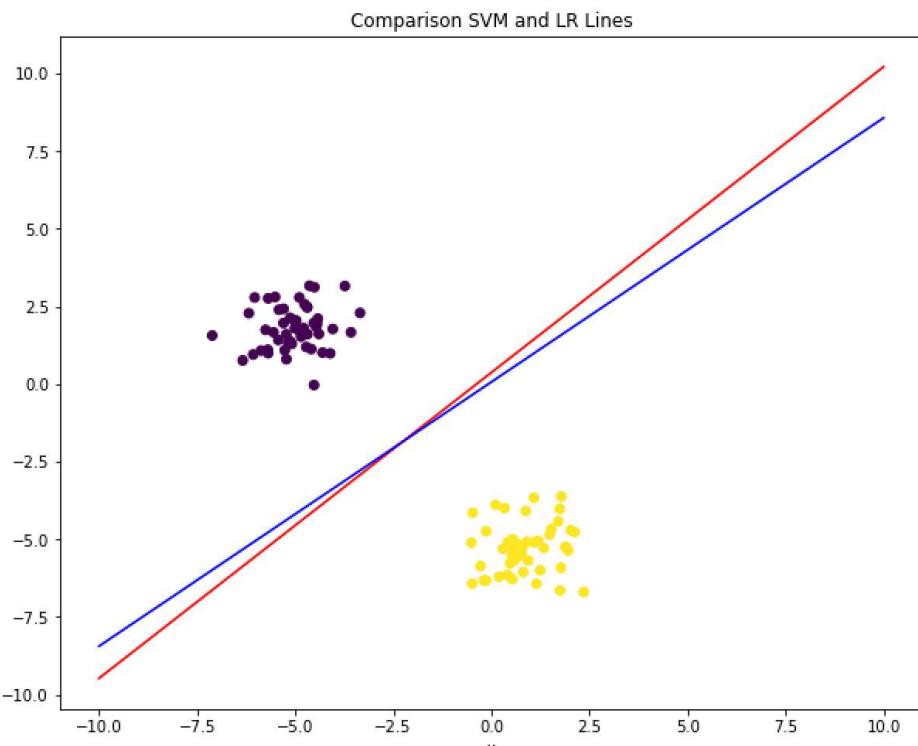
from sklearn.linear_model import LogisticRegression

lr = LogisticRegression()
lr.fit(dataset_x, dataset_y)

import numpy as np
import matplotlib.pyplot as plt

plt.title('Comparison SVM and LR Lines')
plt.xlabel('x')
plt.ylabel('y')
figure = plt.gcf()
figure.set_size_inches((10, 8))

plt.scatter(dataset_x[:, 0], dataset_x[:, 1], c=dataset_y)
x = np.linspace(-10, 10, 100)
y = (-svc.coef_[0][0] * x - svc.intercept_[0]) / svc.coef_[0][1]
plt.plot(x, y, c='red')
y = (-lr.coef_[0][0] * x - lr.intercept_[0]) / lr.coef_[0][1]
plt.plot(x, y, c='blue')
plt.show()
```



Burada kırmızı destek vektör makineleri ile mavi ise lojistik regresyon ile elde edilmiş olan doğruslardır.

Yukarıdaki örneklerdeki veri kümeleri doğrusal olarak ayırtılabilir biçimdedir. Pekiyi veri kümesi doğrusal olarak ayırtılabilir değilse ne yapmalıyız? İşte istatistiksel lojistik regresyonda yapılacak bir şey yoktur. Bu durumda yapay sinir ağları ya da destek vektör makineleri tercih edilmelidir. Yukarıda da belirtildiği gibi destek vektör makinelerinde kernel değiştirilerek boyut yükseltmesi ile doğrusal olarak ayırtılabilir olmayan sınıflandırma problemleri de çözülebilmektedir. Bunun için destek vektör makinelerinde birkaç hazır kernel bulunmaktadır. Şimdi doğrusal olarak ayırtılabilir olmayan dairesel bir veri kümesi için "radial kernel" kullanımını örnek olarak verelim. Bunun için önce dairesel iki sınıfı rasgele noktalar oluşturalım. Bu işlem sklearn.datasets modülü içerisindeki make_circles fonksiyonuyla yapılabilmektedir.

```

import numpy as np

from sklearn.datasets import make_blobs

dataset_x, dataset_y = make_blobs(n_samples=100, n_features=2, centers=2, cluster_std=0.8)

from sklearn.svm import SVC

svc = SVC(kernel='linear')
svc.fit(dataset_x, dataset_y)

from sklearn.linear_model import LogisticRegression

lr = LogisticRegression()
lr.fit(dataset_x, dataset_y)

import matplotlib.pyplot as plt

plt.title('Comparison SVM and LR Lines')
plt.xlabel('x')
plt.ylabel('y')

figure = plt.gcf()
figure.set_size_inches(10, 8)

plt.scatter(dataset_x[:, 0], dataset_x[:, 1], c=dataset_y)

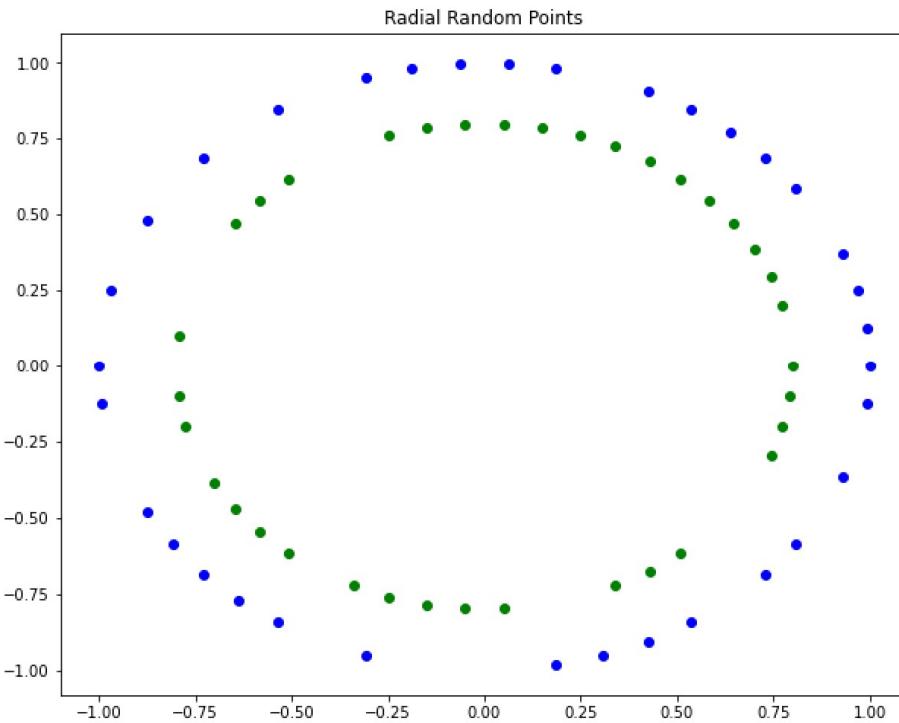
```

```

x = np.linspace(-10, 10, 100)
y = (-svc.coef_[0][0] * x - svc.intercept_[0]) / svc.coef_[0][1]
plt.plot(x, y, c='red')
y = (-lr.coef_[0][0] * x - lr.intercept_[0]) / lr.coef_[0][1]
plt.plot(x, y, c='blue')
plt.show()

```

Bu işlemler sonucunda aşağıdaki gibi rastgele 2 sınıfı dairesel noktalar elde ettik:



Göründüğü gibi bu iki sınıfı dairesel noktalar bir doğru ile ayırtılabilirler. Olsa olsa bu noktalar dairesel bir eğri ile ayırtılabilirler. İşte SVC sınıfındaki "radial kernel (rbf)" bunu sağlamaktadır. Şimdi yukarıdaki verileri kullanarak istatistiksel lojistik regresyon, SVC linear kernel ve SVC radial kernel arasındaki performans farkına bakalım:

```

from sklearn.linear_model import LogisticRegression

lr = LogisticRegression()
lr.fit(dataset_x, dataset_y)

from sklearn.svm import SVC

svc_linear = SVC(kernel='linear')
svc_linear.fit(dataset_x, dataset_y)

svc_radial = SVC(kernel='rbf')
svc_radial.fit(dataset_x, dataset_y)

lr_score = lr.score(test_dataset_x, test_dataset_y)
print(f'Logistic Regression Score: {lr_score}')
svc_linear_score = svc_linear.score(test_dataset_x, test_dataset_y)
print(f'SVC Linear Kernel Score: {svc_linear_score}')
svc_radial_score = svc_radial.score(test_dataset_x, test_dataset_y)
print(f'SVC Radial Kernel Score: {svc_radial_score}')

```

Buradan sonuç elde edilmiştir:

```

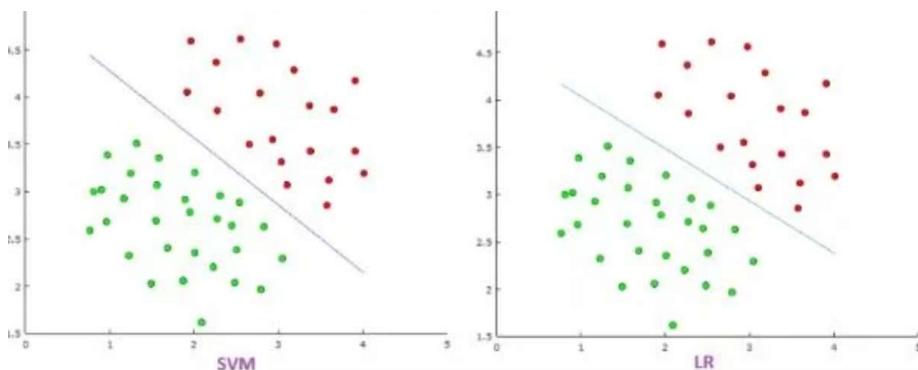
Logistic Regression Score: 0.5333333333333333
SVC Linear Kernel Score: 0.3666666666666666
SVC Radial Kernel Score: 1.0

```

SVC sınıfındaki "poly" kernel ise sınıfları bir doğru ile ya da dairesel olarak değil polinomsal bir fonksiyonla ayırtırmaya çalışmaktadır.

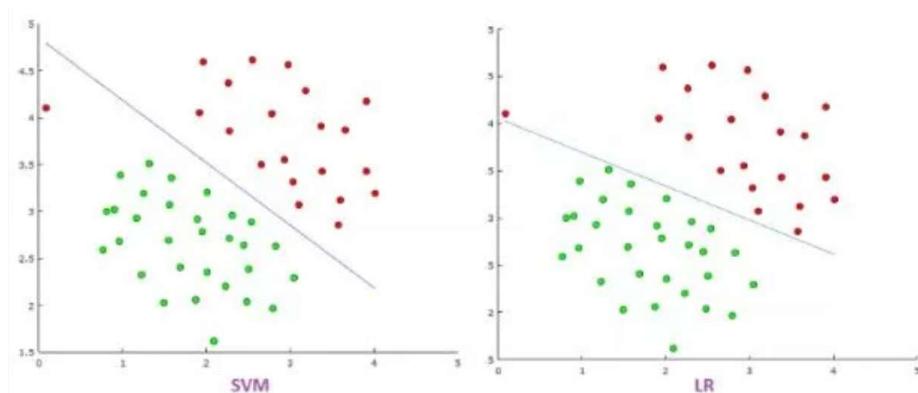
Lojistik Regresyon, Destek Vektör Makineleri, Kümeleme ve Yapay Sinir Ağları Yöntemlerinin Karşılaştırması

Eğer veri kümesi doğrusal olarak ayırtılabilir değilse zaten lojistik regresyon düşünülmeliidir. Bu durumda destek vektör makineleri (kernel değiştirerek), kümeleme yöntemleri ya da yapay sinir ağları kullanılmalıdır. Eğer veri kümesi doğrusal olarak ayırtılabilir ise lojistik regresyon, destek vektör makineleri ve yapay sinir ağları yöntemlerinin her biri kullanılabilir. Genel olarak destek vektör makinelerinin daha adil (ortalayacak biçimde) bir sınır tespiti yaptığı söylenebilir.



Alıntı Notu: GörSEL <https://www.vaishalilambe.com/blogs/data-science-algorithms-svm> adresinden elde edilmiştir.

Öte yandan lojistik regresyon üç değerler olması durumunda bu üç değerleri dikkate alacak biçimde daha iyi bir sınıflandırma yapabilmektedir:



Alıntı Notu: GörSEL <https://www.vaishalilambe.com/blogs/data-science-algorithms-svm> adresinden elde edilmiştir.

Büyük veriler için lojistik regresyon destek vektör makinelerinden daha fazla işlem gerektirmektedir. Dolayısıyla daha yavaş olma eğilimindedir.

Yapay sinir ağları her türlü verilerde çalışabilen genel bir yöntem olmasına karşın eğitim konusunda sorunları olabilmektedir. Yapay sinir ağlarından performans elde edebilmek için onları belli miktarda veri ile eğitmek gerekmektedir. Halbuki lojistik regresyon ve destek vektör makinelerinde makul çözüm az sayıda veri ile elde edilebilmektedir.

Kümeleme yöntemlerinin denetimli (supervised) değil denetimsiz (unsupervised) yöntemler olduğunu anımsayınız. Dolayısıyla elimizde yalnızca dataset_x varsa fakat dataset_y yoksa mecburen kümeleme yöntemlerini kullanız.

DOĞRUSAL KARAR MODELLERİNİN ÇÖZÜMÜ

Doğrusal programlama (linear programming) "yöneylem araştırması (operational research)" denilen alanın en önemli konularından biridir. (Yöneylem Araştırması karar verme süreçlerini iyileştirme ve optimizasyonla ilgili konuları içeren bir bilim dalıdır. Ülkemizdeki üniversitelerde Endüstri Mühendisliği, Ekonometri ve Matematik anabilim dallarının içerisinde bir bilim dalı olarak konumlandırılmıştır.) Doğrusal programlama belli doğrusal kısıtlar altında maksimizasyon ve minimizasyon problemlerinin çözümü ile ilgilenmektedir. Yöneylem Araştırması ve doğrusal programlama teknikleri büyük ölçüde kısıtlı kaynakların verimli kullanılmasının ön plana çıktığı 2. Dünya Savaşı yıllarda geliştirilmiştir.

Doğrusal programlama her ne kadar doğrudan makine öğrenmesinin konuları içerisinde olmasa da makine öğrenmesi ile ilgili süreçlerin belli aşamalarında doğrusal programlama modellerinin kullanılması gerekebilmektedir. Başka bir deyişle bu konu doğrudan makine öğrenmesi içerisine girmese de bir biçimde makine öğrenmesi konusuyla ilişkilidir.

Doğrusal programlamadaki doğrusallık kullanılan değişkenlerin birinci dereceden olması ile ilgilidir. Eğer kısıtları ve amaç fonksiyonunu oluşturan değişkenler birinci dereceden değilse buna da "doğrusal olmayan programlama (nonlinear programming)" denilmektedir. Doğrusal karar modellerinde kısıtlar (constraints) ve amaç fonksyonları (objective functions) bulunur. Doğrusal programlama faaliyetinde kısıtları sağlayan amaç fonksyonlarının en büyük ya da en küçük değeri elde edilmeye çalışılmaktadır. Genellikle amaç fonksyonu bir tane olsa da aslında genel olarak birden fazla olabilmektedir (multiple decision criteria).

Doğrusal karar modellerinde kısıtlar bir çözüm alanı oluşturmaktadır. Bu çözüm alanı içerisinde kısıtları sağlayacak biçimde amaç fonksyonu en büyütlenmeye ya da en küçütlenmeye çalışılmaktadır. Doğrusal karar modellerinin çözüm alanı konveks bir kümedir. Bu konveks kümede uç noktalar (extreme points) vardır. En iyi çözüm de bu uç noktalardan birindedir. Doğrusal karar modellerin çözümü için yalnızca uç noktaları dolaşan algoritmalar önerilmiştir. En etkin algoritmaların biri "Simplex" denilen algoritmadır. Simplex algoritmasının iyileştirilmiş biçimine de "Revised Simplex" denilmektedir. Ancak biz burada Simplex algoritmasının kendisini ele almayacağız. Yalnızca doğrusal karar modellerinin oluşturulmasını ve çözümünde kullanılan hazır sınıfları ve fonksyonları ele alacağız.

Doğrusal karar modelleri matematiksel olarak iki biçimde ifade edilebilmektedir. Bunlardan birine kanonik biçim diğerine standart biçim denilmektedir. Kanonik biçimde tüm kısıtlar \leq biçimine ya da \geq biçimine getirilir. Standart biçimde ise kısıtlar $=$ biçiminde bulunmaktadır. Kanonik biçimin genel biçimini söyleyelim:

$$\begin{aligned} a_{11}x_1 + a_{12}x_2 + a_{13}x_3 + \dots + a_{1n}x_n &\leq b_1 \\ a_{21}x_1 + a_{22}x_2 + a_{23}x_3 + \dots + a_{2n}x_n &\leq b_2 \\ \vdots & \vdots \\ a_{m1}x_1 + a_{m2}x_2 + a_{m3}x_3 + \dots + a_{mn}x_n &\leq b_m \end{aligned}$$

$$Z_{\text{Max}} = c_1x_1 + c_2x_2 + \dots + c_nx_n$$

Aslında bu modeli matrisel biçimde aşağıdaki gibi de ifade edilebilmektedir:

$$\begin{aligned} AX &\leq b \\ X &\geq 0 \\ Z_{\text{max}} &= CX \end{aligned}$$

Tabii yukarıda da belirttiğimiz gibi kanonik biçimde kısıtlar " \geq " biçiminde de olabilmektedir:

$$\begin{aligned} AX &\geq b \\ X &\geq 0 \\ Z_{\text{min}} &= CX \end{aligned}$$

Standart form ise matrisel biçimde şöyle gösterilebilir:

$$AX = b$$

$$X \geq 0$$

$$Z_{min} = CX \text{ ya da } Z_{max} = CX$$

Doğrusal karar problemleri genellikle sözel ya da yazışal biçimde önmüze gelir. Biz de sözel ya da yazışal biçimde önmüze gelen problemin matematiksel modelini yukarıda belirtildiği gibi kanonik ya da standart biçimde ifade ederiz. Sonra da bunu ilgili yazılım araçlarıyla çözeriz. Örnek bir doğrusal karar modeli problemi şöyle olabilir:

Bir çiftçinin buğday, mısır ve arpa ürünlerinin ekimi için 300 hektarlık arazisi vardır. Çiftçi hektar başına buğdaydan 150 TL, mısırдан 220 TL, arpadan da 180 TL kar beklemektedir. İşgücü yüzünden çiftçi buğday için 150 hektardan ve arpa için 120 hektardan daha fazla yer ayırmamalıdır. Verimlilik yönünden ise en az 80 hektar buğday için yer ayırmalı ve mısır ekimi için de toplam arazinin %30'undan daha fazla yer ayırmamalıdır. Çiftçi karını en büyüklemek istemektedir. Çiftçinin hangi ürün için ne kadar alan ayırması gereklidir?

Alıntı Notu: Problemin metni <https://www.coursehero.com/file/23876054/DogrusalProgramlama/> adresinden elde edilmiştir.

Bu tür problemlerde önce problemin matematiksel modelini oluşturmak gereklidir. Matematiksel model oluşturulurken problemdeki nicelikler değişkenlerle temsil edilmektedir. Örneğin yukarıdaki problemden eklecek buğday, mısır ve arpa ürünlerinin hektar büyülükleri sırasıyla x_1 , x_2 ve x_3 değişkenleriyle temsil edilebilir. Bu problemden x_1 buğday için ayrılan alan, x_2 mısır için ayrılan alan ve x_3 de arpa için ayrılan alan olmak üzere kısıtlar ve amaç fonksiyonu şöyle modellenebilir:

- Buğday, mısır ve arpa için ekim yapılacak toplam alan 300 hektardır:

$$x_1 + x_2 + x_3 = 300$$

- Çiftçi buğday için 150 hektardan daha fazla yer ayırmamalıdır:

$$x_1 \leq 150$$

- Çiftçi arpa için 150 hektardan daha fazla yer ayırmamalıdır:

$$x_3 \leq 120$$

- Verimlilik yönünden buğday için en az 80 hektar yer ayırmalıdır:

$$x_1 \geq 80$$

- Mısır için arazinin %30'undan fazla yer ayırmamalıdır:

$$x_2 \leq 90$$

Arpa, mısır ve buğday için ayrılan alanlar negatif olamazlar:

$$x_1, x_2, x_3 \geq 0$$

- Çiftçi kazancını maksimize etmeye çalışmaktadır:

$$Z_{max} = 150 x_1 + 220 x_2 + 180 x_3$$

Göründüğü gibi burada problem matematiksel terimlerle ifade edilmiştir. Artık biz bu modelden hareketle Python'daki hazır modülleri kullanarak problemi çözebiliriz. Diğer bir problem de şöyle olabilir:

Bir boyacı fabrikası hem iç hem dış boyacı üretiyor. Boya üretiminde A ve B olmak üzere iki tip hammadde kullanılıyor. Bir günde A hammaddesinden en çok 6 ton, B hammaddesinden en çok 8 ton kullanılabilir. Günlük hammadde ihtiyacı iç ve dış boyacı için ton olarak aşağıdaki tabloda verilmiştir.

Hammadde	Gereken Hammadde		Mevcut Miktar (ton)
	Miktarı (ton)		
	Dış Boya	İç Boya	
A	1	2	6
B	2	1	8

Bir pazar araştırması iç boyanın günlük istemini, dış boyanın istemini 1 tondan fazla aşmadığını ve iç boyanın en büyük istemini 2 ton olduğunu gösteriyor. İç boyanın toplam satış fiyatı bir tonda 2 birim, dış boyanın toplam satış fiyatı bir tonda 3 birimdir. Şirket toplam geliri en büyütleyecek biçimde kaç ton iç boyanın kaç ton dış boyanın üretimi yapması gerektiğini belirlemek istemektedir.

Alıntı Notu: Problem <https://docplayer.biz.tr/48876868-Yoneylem-arastirmasi-i.htmlb> adresinden elde edilmiştir.

Bu problemde iki değişken vardır: İç boyanın ve dış boyanın miktarı. Bunları x_1 ve x_2 biçiminde temsil edebiliriz. Amaç fonksiyonu bir maksimizasyon biçimindedir. Kısıtlar şu biçimde ifade edilebilir:

$$X_1 + 2X_2 \leq 6 \quad (\text{A hammadde kısıtı})$$

$$2X_1 + X_2 \leq 8 \quad (\text{B hammadde kısıtı})$$

$$X_2 - X_1 \leq 1 \quad (\text{İç boyanın günlük istemi dış boyayı 1 tondan fazla aşmayacak})$$

$$X_2 \leq 2 \quad (\text{İç boyanın en büyük istemi 2 ton})$$

$$X_1, X_2 \geq 0$$

$$\max f(\mathbf{X}) = \max Z = 3X_1 + 2X_2$$

Doğrusal programlama beslenme problemlerine de uygulanabilmektedir:

Bir kişi sadece et, süt ve yumurta yiyerek diyet yapmaktadır. Bu kişinin günde en az 15 mg A vitamini, 30 mg C vitamini ve 10 mg D vitamini olması gerekmektedir. Buna karşılık besinlerle aldığı kolesterol 80 br/günü geçmemelidir. 1 litre sütte 1 mg A, 100 mg C, 10 mg D ve 70 birim kolesterol vardır ve sütün litre 800 TL dir. 1 kg ette 1 mg A, 10 mg C, 100 mg D vitamini ve 50 br kolesterol vardır. Etin kilosu 3700 TL dir. Yumurta 10 mg A, 10 mg C ve 10 mg D vitamini ile 120 birim kolesterol bulunmakta olup, yumurta 275 TL'dir. Kişi istediği, bu diyeti en ucuz yolla gerçekleştirmektedir. Buna göre problemin doğrusal programlama modelini oluşturunuz.

Alıntı Notu: Problem

https://acikders.ankara.edu.tr/pluginfile.php/22659/mod_resource/content/0/3.DP%20Problemleri%20ile%20%C4%B0lgili%20Ornekler.pdf adresinden elde edilmiştir.

Problemin matematiksel modeli şöyle oluşturulabilir:

x_1 : Bir günde tüketilecek süt miktarı (litre)

x_2 : Bir günde tüketilecek et miktarı (kg)

x_3 : Bir günde tüketilecek yumurta miktarı (tane)

$$Z_{\min} = 800x_1 + 3700x_2 + 275x_3$$

Kısıtlar şunlardır:

$$\begin{array}{ll} x_1 + x_2 + 10x_3 \geq 15 & (\text{A vitamini kısıtı}) \\ 100x_1 + 10x_2 + 10x_3 \geq 30 & (\text{C vitamini, kısıtı}) \\ 10x_1 + 100x_2 + 10x_3 \geq 10 & (\text{D vitamini kısıtı}) \\ 70x_1 + 50x_2 + 120x_3 \leq 80 & (\text{Kolesterol kısıtı}) \\ x_1, x_2, x_3 \geq 0 & \end{array}$$

Diger örnek söyle olabilir:

Bir oyuncak imalatçısı model otomobil ve uçak üretimi yapmayı planlamaktadır. Şirket bu iki imalatını iki ayrı işlemin yapıldığı I ve II nolu atölyelerinde gerçekleştirmektedir. Çizelgede bir adet model otomobil ile bir adet model uçak imali için atölye işlem süreleri ve atölye kapasiteleri verilmiştir. Bir model otomobil satışından 45 TL, bir model uçak satışından ise 55 TL kar elde edilecektir. Maksimum kar için her bir üründen ne kadar imal edilmelidir?

Atölyeler	Mallar		Kapasite (saat)
	Otomobil	Uçak	
	İşlem zamanı (saat/ad.)		
I	6	4	120
II	3	10	180

Örnek https://kemalsonmez.weebly.com/uploads/2/4/7/1/24712761/sm_ders_3_dogrusal_programlama_genel.pdf URL'sinden alınmıştır.

Problemin değişkenleri şöyle ifade edilebilir:

x1: Model otomobil miktarı (adet)

x2: Model uçak miktarı (adet olarak)

Problemin amaç fonksiyonu şöyledir:

$$Z_{\max} = 45x_1 + 55x_2$$

Problemin kısıtları şöyledir:

$$6x_1 + 4x_2 \leq 120$$

$$3x_1 + 10x_2 \leq 180$$

$$x_1, x_2 \geq 0$$

Doğrusal Programlama Modelinin SciPy Kütüphanesi Kullanılarak Çözülmesi

Doğrusal karar modellerinin çözümü için `scipy.optimize` modülü içerisindeki `linprog` fonksiyonu kullanılabilir. Fonksiyonun parametrik yapısı şöyledir:

```
scipy.optimize.linprog(c, A_ub=None, b_ub=None, A_eq=None, b_eq=None, bounds=None, method='simplex', callback=None, options=None)
```

Bu fonksiyonun kullanılabilmesi için amaç fonksiyonun minimizasyon biçiminde olması gereklidir. Eğer amaç fonksiyonu maksimizasyon biçimindeyse bizim onu negatif değerlerle çarpıp minimizasyon haline getirmemiz gereklidir. Çünkü amaç fonksiyonunun en büyüğlenmesi onun negatifinin en küçüğlenmesi ile aynı anlamdadır. Fonksiyonun `c` parametresi amaç fonksiyonun katsayılarını belirtmektedir. Fonksiyondaki `A_ub` (upper bound) parametresi modeldeki " \leq " kısıtlarının A katsayı matrisini belirtir. Eğer kısıtlar içerisinde " \geq " olanlar varsa eşitsizliğin her iki tarafı negatif ile çarpılıp " \leq " haline getirilmelidir. `A_eq` parametresi " $=$ " olan kısıtların A katsayı matrisini belirtmektedir. Fonksiyondaki `bounds` parametresi kısıtlardaki değişkenlerin alabileceği değer aralığını belirlemek için kullanılır. Bu parametre için argüman girilmezse default durum " ≥ 0 " biçimindedir. Eğer değişkenler özel bir kısıt içeriysorsa burada tüm değişkenler sırasıyla bir dolaşılabilir nesne içerisinde demetler biçiminde oluşturulmalıdır. Örneğin `x1` koşulunun " ≥ 10 " olduğunu, `x2` koşulunun da " ≥ -5 " ve " ≤ 20 " olduğunu varsayıyalım. Burada `bounds` parametresi şöyle düzenlenmelidir.

```
bounds = [(10, None), (-5, 20)]
```

Buradaki `None` değeri minimal için $-\infty$, Maksimum için $+\infty$ anlamına gelmektedir.

`linprog` fonksiyonunun geri dönüş değeri bir sınıf türündendir. Bu sınıfın `__str__` ve `__repr__` metotları karar modelini sonucunu bize yazı olarak verir. Fakat bu sonuçları biz de şu örnek özniteliklerden ayrı ayrı nümerik biçiminde alabiliyoruz:

fun: Amaç fonksiyonun değeri (Eğer amaç fonksiyonu maksimizasyonda bu değerin negatifi dikkate alınmalıdır.)

x: Karar değişkenlerinin optimum değerlerini belirtmektedir.

success: Optimal çözüm var mı, yok mu? Bu öznitelik bool bir değer vermektedir.

nit: Optimal çözüm için gereken iterasyon sayısı (number of iterations).

Şimdi bir örnek yapalım. Amaç fonksiyonumuz şöyle olsun:

$$Z_{\max} = 3x + 2y$$

Kısıtlarımızın da şöyle olduğunu varsayıyalım:

$$\begin{aligned}2x + y &\leq 18 \\2x + 3y &\leq 42 \\3x + y &\leq 24 \\x, y &\geq 0\end{aligned}$$

Burada bir maksimizasyon problemi söz konusudur. c parametresi için katsayıların minimizasyona göre ayarlanması gerekmektedir. (Pozitif bir değeri en büyüklemekle negatif değeri en küçüklemenin aynı anlama geldiğine dikkat ediniz. Tabii bizim elde edeceğimiz amaç fonksiyonun değerinin işaretini de değiştirmemiz gerekecektir).

Çözüm şöyle yapılabılır:

```
import numpy as np
from scipy.optimize import linprog

c = np.array([-3, -2], dtype=np.float32)
aub = np.array([[2, 1], [2, 3], [3, 1]], dtype=np.float32)
bub = np.array([18, 42, 24])
lp = linprog(c, A_ub=aub, b_ub=bub)

print(lp)
print('-----')
print(f'Variables: {lp.x}')
print(f'Max Value: {-lp.fun}'')
```

Sonuç şöyle elde edilmiştir:

```
con: array([], dtype=float64)
fun: -32.9999980043574
message: 'Optimization terminated successfully.'
nit: 4
slack: array([9.60302629e-08, 3.18105720e-07, 3.0000009e+00])
status: 0
success: True
x: array([ 3.00000001, 11.99999989])
-----
Variables: [ 3.00000001 11.99999989]
Max Value: 32.9999980043574
```

Şimdi daha önce verdigimiz beslenme problemini çözelim. Matematiksel modelimiz şöyleydi:

$$\begin{aligned}x_1 + x_2 + 10x_3 &\geq 15 && \text{(A vitamini kısıtı)} \\100x_1 + 10x_2 + 10x_3 &\geq 30 && \text{(C vitamini, kısıtı)} \\10x_1 + 100x_2 + 10x_3 &\geq 10 && \text{(D vitamini kısıtı)} \\70x_1 + 50x_2 + 120x_3 &\leq 80 && \text{(Kolesterol kısıtı)} \\x_1, x_2, x_3 &\geq 0\end{aligned}$$

$$Z_{\min} = 800x_1 + 3700x_2 + 275x_3$$

Burada bir minimizasyon problemi söz konusudur.

Çözümü şöyle bulabiliriz:

```
import numpy as np
from scipy.optimize import linprog

c = np.array([-800, -3700, -275], dtype=np.float32)
aub = np.array([[-1, -1, -10], [-100, -10, -10], [-10, -100, -10], [70, 50, 120]], dtype=np.float32)
bub = np.array([-15, -30, -10, 80])
lp = linprog(c, A_ub=aub, b_ub=bub)

print(lp)
print('-----')
print(f'Variables: {lp.x}')
print(f'Min Value: {-lp.fun}')
```

Burada bazı kısıtların " \geq " biçimindedir. Biz de onları -1 ile çarparak " \leq " biçimine dönüştürdük. Benzer biçimde problemin amaç fonksiyonunun minimizasyon biçimindedir. Amaç fonksiyonunu da -1 ile çarparak onu maksimizasyon haline dönüştürdük. Şu sonuçlar elde edilmiştir:

```
con: array([], dtype=float64)
fun: -17881.8917142943
message: 'The algorithm terminated successfully and determined that the problem is
infeasible.'
nit: 6
slack: array([-6.37703638, 163.4252051, 457.03735395, -278.9482721])
status: 2
success: False
x: array([1.45778728, 4.49792227, 0.26672541])
-----
Variables: [1.45778728 4.49792227 0.26672541]
Min Value: 17881.8917142943
```

Doğrusal Programlama Modeli İçin Pulp Kütüphanesinin Kullanımı

Pulp kütüphanesi linprog fonksiyonundan daha detaylıdır. Ancak gösterim daha doğal bir formattadır. Ancak bu kütüphane default olarak Anaconda içerisinde yoktur. Kütüphane aşağıdakilerden biriyle kurulabilir:

```
pip install pulp
python -m pip install pulp
```

Anaconda için conda programıyla kurulum da şöyle yapılabilir:

```
conda install -c conda-forge pulp
```

Kurulum sırasında hangi python sürümünün pip ya da python programının çalıştığını dikkat ediniz.

Pulp kütüphanesini dokümantasyonuna aşağıdaki adresten erişebilirsiniz:

<https://coin-or.github.io/pulp/>

Pulp kütüphanesinin kullanımı şöyledir:

1) Önce pulp modülündeki LpProblem sınıfı türünden bir nesne yaratılır. Bu nesne yaratılırken problemin ismi ve maksimizasyon mu, minimizasyon mu olduğu belirtilir.

```
pulp.LpProblem(name='NoName', sense=1)
```

Örneğin:

```
import pulp  
  
lp = pulp.LpProblem('My Problem', pulp.LpMaximize)
```

2) Bundan sonra değişkenleri oluşturmak gereklidir. Değişkenler pulp.LpVariable isimli bir sınıfı temsil edilmişlerdir. Değişkenler oluşturulurken onlara isimler ve sınır değerler verilebilir. Burada lowBound ve upBound parametreleri default olarak None değerini almıştır. Bu None değeri lowBound için $-\infty$, upBound için $+\infty$ biçimindedir.

```
pulp.LpVariable(name, lowBound=None, upBound=None, cat='Continuous', e=None)
```

Örneğin:

```
import pulp  
  
lp = pulp.LpProblem('My Problem', pulp.LpMaximize)  
  
x = pulp.LpVariable("x", lowBound=0)  
y = pulp.LpVariable("y", lowBound=0)
```

3) Şimdi sıra amaç fonksiyonunu ve kısıtları oluşturmaya gelmiştir. Amaç fonksiyonu LpProblem sınıfının `+=` operatör metoduyla oluşturulmaktadır. Örneğin:

```
lp += 3 * x + 2 * y
```

Kısıtlar da tamamen aynı yöntemle oluşturulmaktadır. Ancak kısıtlarda "`<=`", "`>=`" ya da "`==`" operatörleri de kullanılmalıdır.

```
lp += 3 * x + 2 * y  
  
lp += 2 * x + y <= 18  
lp += 2 * x + 3 * y <= 42  
lp += 3 * x + y <= 24
```

Sınıfın `__str__` ve `__repr__` metodları modelin matematiksel temsili yazı olarak bize vermektedir.

4) Bundan sonra sıra modeli çözmeye gelmiştir. Çözme işlemi LpProblem sınıfının `solve` isimli metoduyla yapılmaktadır.

```
solve(solver=None, **kwargs)
```

Programcı isterse çözüm algoritmasını ya da çözüm yazılımını değiştirebilmek için `solver` parametresini kullanabilir.

LpProblem sınıfının `objective`, `constraints`, ve `status` örnek öznitelikleri bize modele ilişkin bilgileri vermektedir.

5) Çözüm sonucunda değişkenlerin optimal değerlerini alabilmek için `pulp.value` fonksiyonu kullanılmaktadır. Örneğin:

```
print('x = {}'.format(pulp.value(x)))  
print('y = {}'.format(pulp.value(y)))
```

Amaç fonksiyonunun değeri de yine `pulp.value` metoduyla `constraints` özniteligi verilerek elde edilebilir. Örneğin:

```
print('Objective: {}'.format(pulp.value(lp.objective)))
```

Çözümün tüm kodları şöyledir:

```

import pulp

lp = pulp.LpProblem('MyProblem', pulp.LpMaximize)
x = pulp.LpVariable('x', lowBound=0)
y = pulp.LpVariable('y', lowBound=0)

lp += 3 * x + 2 * y

lp += 2 * x + y <= 18
lp += 2 * x + 3 * y <= 42
lp += 3 * x + y <= 24

print(lp)

lp.solve()
print('x = {}'.format(pulp.value(x)))
print('y = {}'.format(pulp.value(y)))
print('Objective: {}'.format(pulp.value(lp.objective)))

```

LpProblem sınıfının writeLP metodu modeli bir text dosyanın içerişine yazar. Ancak maalesef pulp modülünde modülü okuyan bir fonksiyon yoktur.

Şimdi son olarak daha çok değişkenli bir doğrusal programlama modelini metinden hareketle çözmeye çalışalım:

Bir şehirde her biri 1200 kişilik öğrenci kapasitesi olan üç ayrı lise bulunmaktadır. Şehir yönetimi Kuzey, Güney, Doğu, Batı ve Merkez olarak beş ayrı bölgeye ayırmıştır. Bazı öğrenciler bölgelerinin dışındaki okullara gitmek durumundadır. Bu durumda okul yönetimleri öğrencilerin alacağı toplam mesafeyi en az indirőek istemektedir. Gerekli olan doğrusal modeli kurunuz. Okullar birey mesafeleri aşağıdaki tabloda verilmiştir:

Bölgeler	Merkez Lisesi	Batı Lisesi	Güney Lisesi	Öğrenci Sayısı
Kuzey	8	11	14	700
Güney	12	9	0	300
Doğu	9	16	10	900
Batı	8	0	9	600
Merkez	0	8	12	500

Bu problemde bölgelerden liselere kaç kişinin gideceği karar değişkenlerini oluşturmaktadır. X_{ij} karar değişkeni j 'inci bölgeden i 'inci okula kaç kişinin gideceğini belirtmektedir. Örneğin X_{13} karar değişkeni Doğu bölgesinden Merkez liseye kaç kişinin gideceğini belirtmektedir. Model şöyle kurulabilir:

$$\text{Min } Z = 8X_{11} + 12X_{12} + 9X_{13} + 8X_{14} + 0 * X_{15} + 11X_{21} + 9X_{22} + 16X_{23} + 0X_{24} + 8X_{25} + 14X_{31} + 0X_{32} + 10X_{33} + 9X_{34} + 12X_{35}$$

Kısıtlar:

$$X_{11} + X_{21} + X_{31} = 700 \quad (\text{Kuzey bölgesindeki toplam öğrenci kısıtı})$$

$$X_{12} + X_{22} + X_{32} = 300 \quad (\text{Güney bölgesindeki toplam öğrenci kısıtı})$$

$$X_{13} + X_{23} + X_{33} = 900 \quad (\text{Doğu bölgesindeki toplam öğrenci kısıtı})$$

$$X_{14} + X_{24} + X_{34} = 600 \quad (\text{Batı bölgesindeki toplam öğrenci kısıtı})$$

$$X_{15} + X_{25} + X_{35} = 500 \quad (\text{Merkez bölgesindeki toplam öğrenci kısıtı})$$

$$X_{11} + X_{12} + X_{13} + X_{14} + X_{15} \leq 1200 \quad (\text{Merkez lisesinin kapasite kısıtı})$$

$$X_{21} + X_{22} + X_{23} + X_{24} + X_{25} \leq 1200 \quad (\text{Batı lisesinin kapasite kısıtı})$$

$$X_{31} + X_{32} + X_{33} + X_{34} + X_{35} \leq 1200 \quad (\text{Güney lisesinin kapasite kısıtı})$$

$$X_{11}, X_{12}, X_{13}, X_{14}, X_{15}, X_{21}, X_{22}, X_{23}, X_{24}, X_{25}, X_{31}, X_{32}, X_{33}, X_{34}, X_{35} \geq 0$$

Xik --> i'nci okuldan k'inci bölgeye gidecek öğrenci sayısı

Problemi önce linprog ile çözelim:

```
import numpy as np
from scipy.optimize import linprog

c = np.array([8, 12, 9, 8, 0, 11, 9, 16, 0, 8, 14, 0, 10, 9, 12])
A_ub = np.array([[1, 1, 1, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0], 
                 [0, 0, 0, 0, 1, 1, 1, 1, 0, 0, 0, 0, 0, 0, 0, 0], 
                 [0, 0, 0, 0, 0, 0, 0, 0, 1, 1, 1, 1, 1, 1, 1, 1]])
b_ub = np.array([1200, 1200, 1200])

A_eq = np.array([[1, 0, 0, 0, 1, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0], 
                 [0, 1, 0, 0, 0, 1, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0], 
                 [0, 0, 1, 0, 0, 0, 0, 1, 0, 0, 0, 1, 0, 0, 0, 0], 
                 [0, 0, 0, 1, 0, 0, 0, 0, 1, 0, 0, 0, 1, 0, 0, 0], 
                 [0, 0, 0, 0, 1, 0, 0, 0, 1, 0, 0, 0, 0, 1, 0, 0]])
b_eq = np.array([700, 300, 900, 600, 500])

result = linprog(c=c, A_ub=A_ub, b_ub=b_ub, A_eq=A_eq, b_eq=b_eq)
print(result)
```

Elde edilen sonuç şöyledir:

```
fun: 14600.0
message: 'Optimization terminated successfully.'
nit: 14
slack: array([ 0., 600., 0.])
status: 0
success: True
x: array([700., 0., 0., 0., 500., 0., 0., 0., 600., 0., 0.,
       300., 900., 0., 0.])
```

Şimdi aynı problemi pulp ile çözelim:

```
import pulp

lp = pulp.LpProblem('District_School_Problem', pulp.LpMinimize)

x11 = pulp.LpVariable("x11", lowBound=0)
x12 = pulp.LpVariable("x12", lowBound=0)
x13 = pulp.LpVariable("x13", lowBound=0)
x14 = pulp.LpVariable("x14", lowBound=0)
x15 = pulp.LpVariable("x15", lowBound=0)

x21 = pulp.LpVariable("x21", lowBound=0)
x22 = pulp.LpVariable("x22", lowBound=0)
x23 = pulp.LpVariable("x23", lowBound=0)
x24 = pulp.LpVariable("x24", lowBound=0)
x25 = pulp.LpVariable("x25", lowBound=0)

x31 = pulp.LpVariable("x31", lowBound=0)
x32 = pulp.LpVariable("x32", lowBound=0)
x33 = pulp.LpVariable("x33", lowBound=0)
x34 = pulp.LpVariable("x34", lowBound=0)
x35 = pulp.LpVariable("x35", lowBound=0)

variables = [x11, x12, x13, x14, x15, x21, x22, x23, x24, x25, x31, x32, x33, x34, x35]

lp += 8 * x11 + 12 * x12 + 9 * x13 + 8 * x14 + 0 * x15 + 11 * x21 + 9 * x22 + 16 * x23 + 0 *
      0 * x24 + 0 * x25 + 0 * x31 + 0 * x32 + 0 * x33 + 0 * x34 + 0 * x35
```

```

x24 + 8 * x25 + 14 * x31 + 0 * x32 + 10 * x33 + 9 * x34 + 12 * x35

lp += x11 + x12 + x13 + x14 + x15 <= 1200
lp += x21 + x22 + x23 + x24 + x25 <= 1200
lp += x31 + x32 + x33 + x34 + x35 <= 1200

lp += x11 + x21 + x31 == 700
lp += x12 + x22 + x32 == 300
lp += x13 + x23 + x33 == 900
lp += x14 + x24 + x34 == 600
lp += x15 + x25 + x35 == 500

lp.solve()

for variable in variables:
    print('{} = {}'.format(variable, pulp.value(variable)))

```

Elde edilen sonuçlar şöyledir:

```

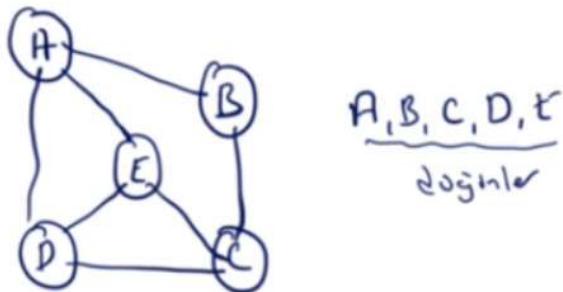
x11 = 700.0
x12 = 0.0
x13 = 0.0
x14 = 0.0
x15 = 500.0
x21 = 0.0
x22 = 0.0
x23 = 0.0
x24 = 600.0
x25 = 0.0
x31 = 0.0
x32 = 300.0
x33 = 900.0
x34 = 0.0
x35 = 0.0

```

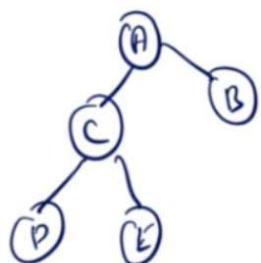
GRAFLAR ÜZERİNDE İŞLEMLER

Graflar optimizasyon uygulamalarında en çok karşılaşılan veri yapılarından biridir. Biz bu bölümde graf veri yapısının Python'da nasıl kullanılacağı ve bu veri yapısıyla temel graf optimizasyon problemlerinin nasıl çözüleceği üzerinde duracağız.

Graflar düğümlerden(nodes) ve kenarlardan (edges) oluşmaktadır. Genellikle şekilsel olarak düğümler yuvarlaklarla, kenarlar da çizgilerle gösterilirler. Örneğin:

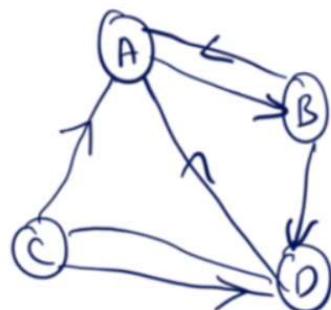


Veri yapılarında bir düğüme birden fazla yolla ulaşılabilirse buna graf ancak bir düğüme tek bir yolla ulaşılıyorsa buna da ağaç (tree) denilmektedir. Ağaçlar grafların özel bir durumudur. Aşağıda bir ağaç veri yapısı görülmektedir:



Graflarda düğümlere ve kenarlara bilgiler ilişirilebilir. Örneğin Mecidiyeköy'den Beşiktaş'a gidilebilecek en kısa yolu bulmak isteyelim. Bu bir graf problemidir. Yani problemin öncelikle bir graf olarak modellenmesi gereklidir. Bu modelleme yapılırken kavşak noktaları düğüm olarak alınır. Düğümler arasındaki tüm yollar kenarlarla grafta belirtilir. Sonra da graf üzerinde en kısa yol problemi uygulanır.

Graflar yönsüz (undirected) ve yönlü (directed) olmak üzere ikiye ayrılmaktadır. Yönsüz graflar aslında çift yönlü graflar biçiminde değerlendirilebilir. Yönsüz graflarda A ve B düğümü arasında bir kenar varsa bu durum hem A'dan B'ye hem de B'den A'ya gidiş olduğu anlamına gelir. Yönlü graflarda ise A'dan B'ye gidiş olması B'den A'ya gidiş olacağının anlamına gelmemektedir. Yönlü graflar genellikle kenarlarda oklarla belirtilirler. Örneğin:



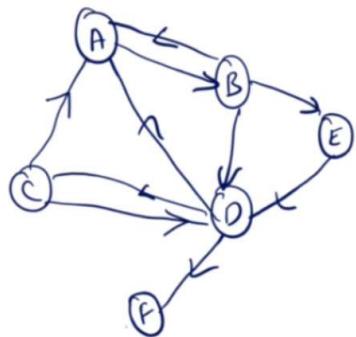
Örneğin karayollarını temsil eden graflar yönlüdür. Fakat sosyal ağlardaki arkadaşlık grafları yönüzdür.

Yapay zeka uygulamaları bazen graf veri yapısı ilgili olabilmektedir. Örneğin sosyal ağlar graf veri yapısı ile temsil edilip bunun üzerinde yapay zeka algoritmaları uygulanabilmektedir.

Graf veri yapıları tipik olarak iki yöntemle gerçekleştirilmektedir: Komşuluk Matrisi (Adjacency Matrix) ve Komşuluk Listeleri (Adjacency Lists). Komşul matrisi yöntemi daha seyrek kullanılmaktadır. Bu yöntemde hangi düğümden hangi düğüme yol olduğu bir matrisle belirlenir. Örneğin yukarıdaki graf için komşuluk matrisi şöyle oluşturulabilir:

$$\begin{matrix} & \begin{matrix} A & B & C & D \end{matrix} \\ \begin{matrix} A \\ B \\ C \\ D \end{matrix} & \left[\begin{matrix} 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 1 \\ 1 & 0 & 1 & 1 \end{matrix} \right] \end{matrix}$$

Komşuluk listesi yöntemi en sık kullanılan yöntemdir. Bu yöntemde her düğümün hangi düğümlerle bağlı olduğu bir listede tutulur. Tabii bağlı düğümlerin sayısı fazlaysa liste yerine aramayı hızlandırmak için sözlük tarzı bir veri yapısı tercih edilmektedir. Komşuluk listesi yöntemi Python'da sözlük nesneleriyle basit biçimde oluşturulabilir. Örneğin aşağıdaki yönlü grafi komşuluk listesi yöntemiyle Python'da oluşturmak isteyelim:



```
graph = {A: {B}, B: {A, D, E}, C: {A, D}, D: {A, F, C}, E: {D}, F: {}}
```

Fakat graflarda düğümlere ve kenarlara da bilgiler ilişirilebilmektedir. Pekiyi bu durumda nasıl bir genelleştirme yapılabilir? Örneğin Networkx kütüphanesi grafi aşağıdaki gibi temsil etmiştir:

```
graph = nx.DiGraph()
graph.add_node('A', name='Ankara', size=1300)
graph.add_node('B', name='Izmir', size=2100)
graph.add_node('C', name='Istanbul', size=1200)
graph.add_node('D', name='Antalya', size=1000)
graph.add_node('E', name='Samsun', size=1000)
graph.add_node('F', name='Trabzon', size=1000)

edges = [
    ('A', 'B', {'length': 1200}),
    ('A', 'C', {'length': 1300}),
    ('B', 'D', {'length': 1000}),
    ('C', 'D', {'length': 1200}),
    ('D', 'B', {'length': 1000}),
    ('D', 'E', {'length': 1000}),
    ('D', 'F', {'length': 1000}),
    ('E', 'D', {'length': 1000}),
    ('F', 'D', {'length': 1000})
]
```

Gördüğü gibi graf düğümlerden ve kenarlardan oluşmaktadır. Düğümler bir sözlük içerisindeindedir. Ama sözlüğün anahtarına karşılık gelen değer de sözlüktür. Çünkü bir düğüme atanacak birden fazla özellik olabilir. Benzer biçimde kenarlar da birer sözlük biçimindedir. Her kenara ilişirilecek bilgi de bir sözlükle temsil edilmiştir. Bu bilgiler de birden fazla olabilirler.

Graf veri yapısı için Python'ın standart kütüphanelerinde bir modül yoktur. Ancak graf işlemleri için üçüncü parti çeşitli kütüphaneler bulunmaktadır. Bunların arasından en çok tercih edilenlerden ikisi Networkx ve igraph kütüphaneleridir. Biz buarada Networkx kütüphanesini ele alacağız.

Anaconda sürümünde Networkx default olarak yüklenmiş biçimde gelmektedir. Diğer sürümlerde kütüphane manuel biçimde pip yoluyla yüklenebilir. Biz kütüphaneyi nx ismiyle import ederek kullanacağz. Örneğin:

```
import networkx as nx
```

Kütüphanenin dokümantasyonuna şuradan erişilebilir:

<https://networkx.github.io/documentation/stable/>

Networkx Kütüphanesinin Kullanımı

Kütüphanenin tipik kullanımı şöyledir:

1) Kütüphanede toplam dört farklı graph veri yapısı bulunmaktadır. Graph isimli sınıf yönsüz (undirected) graflar için, DiGraph isimli sınıf yönlü graflar için, MultiGraph yönsüz paralel kenarlara izin veren graflar için, MultiDiGraph yönlü paralel kenarlara izin veren graflar için kullanılmaktadır. Tipik olarak önce bu sınıflar türünden bir graph nesnesi yaratılır. Graph ve DiGraph sınıfının `__init__` metodlarının parametrik yapıları şöyledir:

```
Graph(incoming_graph_data=None, **attr)  
Graph(incoming_graph_data=None, **attr)
```

Bu fonksiyonla `**` parametresini kullanarak grafa istediğimiz bilgileri ilişirebiliriz. Bu bilgiler grafi temsil eden herhangi şeyler olabilir. `incoming_graph_data` grafi yaratırken hemen düğüm ve kenar girmek için kullanılmaktadır. Bu girişin bazı biçimleri vardır. Örneğin:

```
import networkx as nx
```

```
g = nx.Graph()
```

Burada biz boş bir graph yattık. Tabii istersek graph nesnesine kendi istediğimiz birtakım bilgileri `**` parametresine karşı gelecek biçimde isimli olarak girebiliriz. Örneğin:

```
import networkx as nx
```

```
g = nx.Graph(name='My Graph', date='19/07/2020')
```

2) Yaratılmış grafa `add_node` metoduyla düğüm, `add_edge` metodula kenar ekleyebiliriz. Önce düğüm ekleyip sonra kenar eklemek zorunlu değildir. Bir kenar eklenirken kenara konu olan düğümler yoksa zaten bu düğümler de garafa eklenmektektir. `add_node` metodunun parametrik yapısı şöyledir:

```
add_node(node_for_adding, **attr)
```

Bir düğüm yaratılırken düğüme bir isim verilir. Bu isim hash'lenebilir herhangi bir türden (int, str gibi) olabilir. Düğüme yine istenilen bilgiler `**` parametresiyle ilişirilebilmektedir. Örneğin:

```
g.add_node('A', x=10, y=20)
```

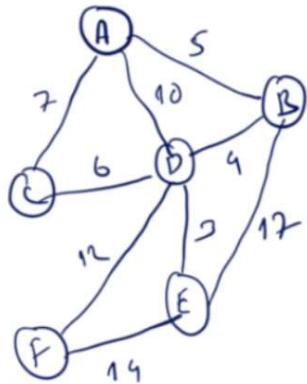
Grafa kenarlar `add_node` isimli metodla eklenmektedir. Metodun parametrik yapısı şöyledir:

```
add_edge(u_of_edge, v_of_edge, **attr)
```

Fonksiyonun ilk iki parametresi başlangıç ve bitiş düğümlerini belirtir. `**` parametresi ile yine biz kenarlara istediğimiz bilgileri ilişirebiliriz. `add_edge` metoduyla grafa bir kenar eklerken verdığımız düğümlerin daha önce yaratılmış olması gerekmemektedir. Eğer metoda verdığımız düğümler daha önce yaratılmamışsa zaten metot önce bu düğümleri de yaratmaktadır. Örneğin:

```
g.add_edge('A', 'B', length=100)
```

Şimdi aşağıdaki grafin yollarını add_edge ile oluşturmaya çalışalım:



Buradaki sayılar ilgili yolların uzunluğu olsun. Networkx graf veri yapısı şöyle oluşturulabilir:

```
import networkx as nx

g = nx.Graph(title='Road Graph')

g.add_edge('A', 'B', length=5)
g.add_edge('A', 'C', lenght=7)
g.add_edge('A', 'D', lenght=10)
g.add_edge('D', 'B', lenght=4)
g.add_edge('D', 'C', lenght=6)
g.add_edge('D', 'F', lenght=12)
g.add_edge('D', 'E', lenght=3)
g.add_edge('B', 'E', lenght=17)
g.add_edge('F', 'E', lenght=10)
```

Graf sınıflarının number_of_nodes ve number_of_edges isimli metodları graftaki düğüm ve kenar sayılarını bize verir. Örneğin:

```
print(g.number_of_edges())
print(g.number_of_nodes())
```

Graftaki tüm düğümleri nodes örnek özniteliği ile, tüm kenarları da edges örnek özniteliği ile alabiliriz. Bu sınıflar bize dolaşılabilir bir nesne verirler. Bu nesneler dolaşıldığında bizim düğümler için verdığımız nesneler (yukarıdaki örnekte 'A', 'B' biçiminde harfler) kenarlar dolaşıldığında da iki düğümden oluşan demetler elde edilmektedir. Örneğin:

```
for node in g.nodes:
    print(node, '--->', type(node))

for edge in g.edges:
    print(edge, '--->', type(edge))
```

Kodun ekran çıktısı şöyle olacaktır:

```
A ---> <class 'str'>
B ---> <class 'str'>
C ---> <class 'str'>
D ---> <class 'str'>
F ---> <class 'str'>
E ---> <class 'str'>
('A', 'B') ---> <class 'tuple'>
```

```
('A', 'C') ---> <class 'tuple'>
('A', 'D') ---> <class 'tuple'>
('B', 'E') ---> <class 'tuple'>
('B', 'D') ---> <class 'tuple'>
('C', 'D') ---> <class 'tuple'>
('D', 'F') ---> <class 'tuple'>
('D', 'E') ---> <class 'tuple'>
('F', 'E') ---> <class 'tuple'>
```

Dolaşılabilir sınıfın `__str__` metodu bize düğümleri ve kenarları bir demet yazısı biçiminde vermektedir. O halde biz doğrudan nodes ve edges örnek özniteliklerini print fonksiyonuyla da yazdırabiliriz.

```
print(g.nodes)
print(g.edges)
```

Kodun çıktısı şöyle olacaktır:

```
['A', 'B', 'C', 'D', 'F', 'E']
[('A', 'B'), ('A', 'C'), ('A', 'D'), ('B', 'E'), ('B', 'D'), ('C', 'D'), ('D', 'F'), ('D', 'E'), ('F', 'E')]
```

Graftan herhangi bir düğüm `remove_node` metodu ile silinebilir. Bir düğüm silindiğinde o düğüme bağlı olan kenarların hepsi de silinmektedir. Benzer biçimde bir kenar da `remove_edge` metoduyla silinebilmektedir. Ancak kenar silindiğinde kenara ilişkin düğümler silinmemektedir.

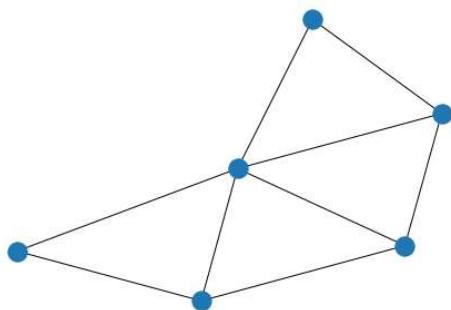
Graftaki belli bir düğümün komşularını (yani o düğüme bağlı kenarları) elde etmek için `[..]` operatörü kullanılabilir. Bu işlem bize sözlük tarzı (AtlasView isimli bir sınıf) dolaşılabilir bir nesne vermektedir. Örneğin:

```
for s in g['A']:
    print(s)
```

Burada A'nın komşuları yazı olarak elde edilmektedir. Eğer biz A ile B arasındaki kenar özelliklerini elde etmek istiyorsak `g['A']['B']` ifadesini kullanmalıyız.

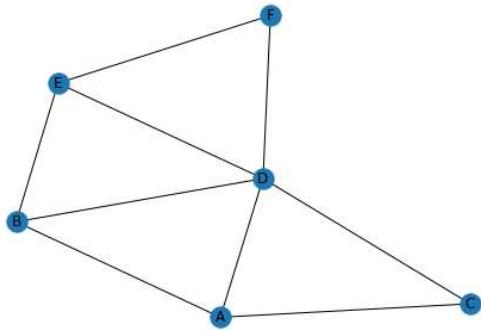
Oluşturulan grafin çizdirilmesi oldukça kolaydır. Tek yapılacak şey networkx modülündeki `draw` fonksiyonunu kullanmaktır. Örneğin:

```
nx.draw(g)
```



Düğümlerin üzerinde isimlerin yazılması isteniyorsa `with_labels` parametresi `True` geçilmelidir. Örneğin:

```
nx.draw(g, with_labels=True)
```

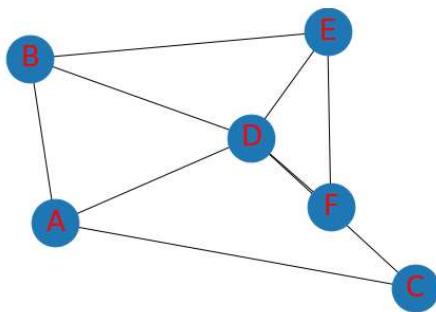


Fonksiyonun pek çok isimli parametresi vardır. Bu parametreler aşağıdaki link'ten incelenebilir:

https://networkx.github.io/documentation/stable/reference/generated/networkx.drawing.nx_pylab.draw_networkx.html?highlight=draw_networkx#networkx.drawing.nx_pylab.draw_networkx

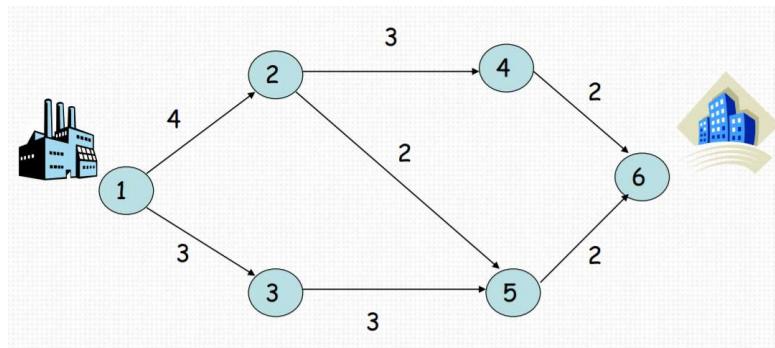
Örneğin:

```
nx.draw(g, with_labels=True, font_size=26, node_size=2000, font_color='red')
```



Tabii aslında graflar birtakım optimizasyon tarzı problemleri çözmek için kullanılmaktadır. Yani graflar aslında yalnızca veri yapısıdır. Önemli olan bu veri yapısı üzerinde yararlı işlemler yapabilen algoritmaların çalıştırılmasıdır. İşte networkx kütüphanesinde de graflar üzerinde işlemler yapabilen pek çok hazır fonksiyon vardır.

Yukarıda da belirtildiği gibi Graph sınıfı yönsüz (yani çift yönlü) graf oluşturmaktadır. Halbuki DiGraph sınıfı yönlü graf oluşturur. Örneğin aşağıdaki yönlü grafi oluşturmak isteyelim:



```
import networkx as nx

g = nx.DiGraph(title='Road Graph')

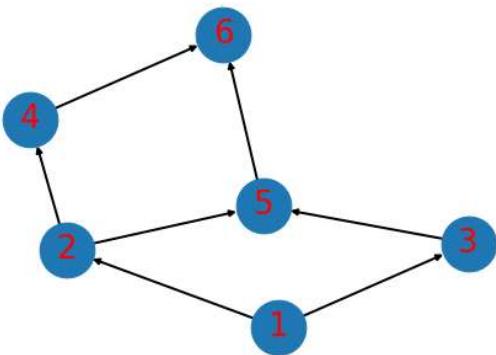
g.add_edge(1, 2, length=4)
g.add_edge(1, 3, length=3)
g.add_edge(3, 5, length=3)
g.add_edge(5, 6, length=2)
```

```

g.add_edge(2, 4, length=3)
g.add_edge(2, 5, length=2)
g.add_edge(4, 6, length=2)

nx.draw(g, with_labels=True, font_size=24, font_color='white', node_size=1000)

```



Aslında graf bilgileri bazı uygulamalarda komşuluk matrisi biçiminde de ifade edilebilmektedir. Örneğin yukarıdaki grafın komşuluk matrisi şöyledir:

```

0 4 3 0 0 0
0 0 0 3 2 0
0 0 0 0 3 0
0 0 0 0 0 2
0 0 0 0 0 2
0 0 0 0 0 0

```

Bu komşuluk matrisinden yönlü graf elde eden fonksiyon basit biçimde şöyle yazılabilir:

```

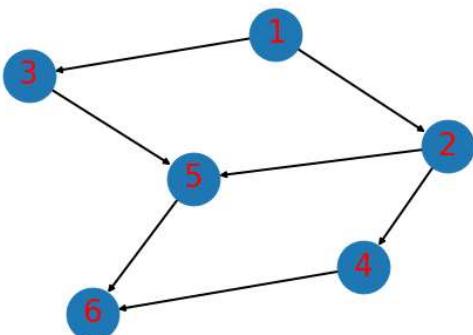
import numpy as np
import networkx as nx

def adjacency_matrix_to_graph(path):
    g = nx.DiGraph()
    data = np.loadtxt(path, dtype=np.float32)
    for i in range(len(data)):
        for k in range(len(data)):
            if data[i, k] != 0:
                g.add_edge(i + 1, k + 1, length=data[i, k])

    return g

g = adjacency_matrix_to_graph('graph.txt')
nx.draw(g, with_labels=True, font_size=26, node_size=2000, font_color='red', width=2)

```



Aslında bu işi yapan networkx kütüphanesinde from_numpy_matrix isimli bir fonksiyon da vardır. Örneğin:

```

data = np.loadtxt('graph.txt', dtype=np.float32)
g = nx.from_numpy_matrix(data)
nx.draw(g, with_labels=True, font_size=26, node_size=2000, font_color='red', width=2)

```

Tabii bunun tersini yapan adjacency_matrix isimli bir fonksiyon da vardır:

```

data2 = nx.adjacency_matrix(g)
print(data2)
print(data2.toarray())

```

Graflar üzerinde çeşitli optimizasyon işlemleri için networkx.algorithms modülündeki fonksiyonlar kullanılmaktadır. Networkx kütüphanesi bu bakımdan çok zengindir. Burada bazı graf problemleri örnek olarak verilecektir.

Graflar üzerindeki en klasik problem "en kısa yol (shortest path)" problemidir. Bu problemde bir düğümden bir düğüme gidebilmek için gereken en kısa yol bulunmaya çalışılır. En kısa yol problemi için algorithms.shortest_paths.generic.shortest_path fonksiyonu kullanılmaktadır. Bu fonksiyona biz başlangıç düğümünü, bitiş düğümünü ve neye göre uzunluk belirleneceğine belirten kenar özelliğini veriririz. O da bize en kısa yolu düğümlerde oluşan bir liste olarak verir. Örneğin:

```

import networkx as nx

g = nx.DiGraph(title='Road Graph')

g.add_edge(1, 2, length=4)
g.add_edge(1, 3, length=3)
g.add_edge(1, 2, length=4)
g.add_edge(2, 4, length=3)
g.add_edge(2, 5, length=2)
g.add_edge(3, 5, length=3)
g.add_edge(4, 6, length=2)
g.add_edge(5, 6, length=4)

print(g.number_of_edges())
print(g.number_of_nodes())

nx.draw(g, with_labels=True, font_size=26, node_size=2000, font_color='red', width=2)

from networkx.algorithms.shortest_paths.generic import shortest_path
path = shortest_path(g, 1, 6, weight='length')
print(path)

```

Programın çıktısı şöyle olacaktır:

```
[1, 3, 5, 6]
```

Graflar üzerinde turlama (cycling) işlemleri en çok kullanılan işlemleridir. Belli bir düğümden başlanarak tüm düğümlerin ya da kenarların elde edilmesi gerekebilmiştir. Örneğin simple_cycles isimli fonksiyon bize graf içerisindeki kısa ya da uzun bütün turları vermektedir:

```

import networkx as nx

g = nx.DiGraph(title='Road Graph')

g.add_edge(1, 2, length=4)
g.add_edge(1, 3, length=3)
g.add_edge(1, 2, length=4)
g.add_edge(2, 4, length=3)
g.add_edge(2, 5, length=2)
g.add_edge(3, 5, length=3)
g.add_edge(4, 6, length=2)

```

```

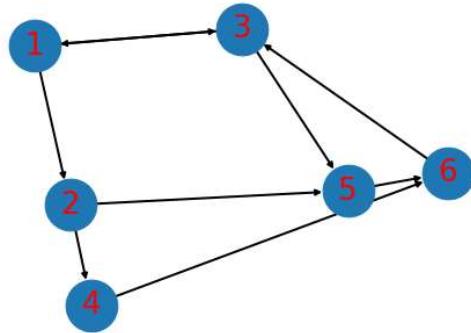
g.add_edge(5, 6, length=4)
g.add_edge(6, 3, length=7)
g.add_edge(3, 1, length=3)

print(g.number_of_edges())
print(g.number_of_nodes())

nx.draw(g, with_labels=True, font_size=26, node_size=2000, font_color='red', width=2)

cycles = nx.simple_cycles(g)
print(list(cycles))

```



```
[[1, 3], [1, 2, 5, 6, 3], [1, 2, 4, 6, 3], [3, 5, 6]]
```

Yukarıda da belirtildiği gibi graflarda pek çok algoritmik problem vardır. networkx kütüphanesi bu problemlerin çoğunu çözecek fonksiyonlara sahiptir. Örneğin "en küçük örten ağaç (minimum spanning tree)" yönsüz bir graftaki bütün düğümleri içeren en kısa ağacın oluşturulma problemidir. Su boruları ya da elektrik telleri gibi alt yapı hizmetlerinde önemli kullanımı vardır. (Örneğin tüm evlere su götürecek en kısa uzunluklu boru hattının oluşturulması örneği gibi.) Bu algoritma networkx.algorithms.tree.mst modülündeki minimum_spanning_edges fonksiyonuyla çözülmektedir. Örneğin:

```

import networkx as nx

g = nx.Graph(title='Road Graph')

g.add_edge(1, 2, length=4)
g.add_edge(1, 3, length=3)
g.add_edge(1, 2, length=4)
g.add_edge(2, 4, length=3)
g.add_edge(2, 5, length=2)
g.add_edge(3, 5, length=3)
g.add_edge(4, 6, length=2)
g.add_edge(5, 6, length=4)
g.add_edge(6, 3, length=7)

print(g.number_of_edges())
print(g.number_of_nodes())

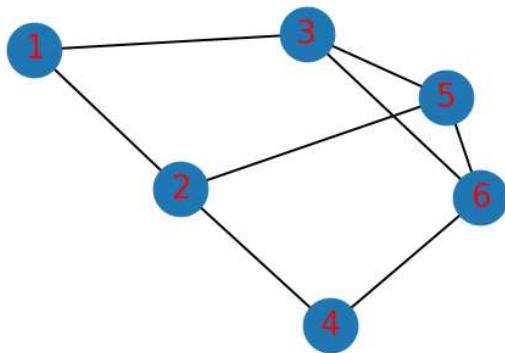
nx.draw(g, with_labels=True, font_size=26, node_size=2000, font_color='red', width=2)

from networkx.algorithms.tree.mst import minimum_spanning_edges
se = minimum_spanning_edges(g)
print(list(se))

```

Programın çıktısı şöyle olacaktır:

```
[(1, 2, {'length': 4}), (1, 3, {'length': 3}), (2, 4, {'length': 3}), (2, 5, {'length': 2}), (3, 6, {'length': 7})]
```



Diğer klasik problemlerden biri de "maksimum akış (maximum flow)" problemidir. Bu problemde belli bir düğümden belli bir düğüme maksimum kapasite aktarımı yapmak istenmektedir. Tipik durumda bu kapasite aktarımı borulardan suların aktarılması biçiminde düşünülebilir. Problemden amaç çeşitli yollar kullanarak maksimum akışın elde edilmesidir. Şüphesiz iki düğüm arasındaki akış o düğümlerdeki yollarda bulunan boruların en küçük kapasitelisi ile ilgilidir. Örnek bir problem şöyle verilebilir:

```
import networkx as nx

g = nx.DiGraph()
g.add_edge('x','a', capacity=3.0)
g.add_edge('x','b', capacity=1.0)
g.add_edge('a','c', capacity=3.0)
g.add_edge('b','c', capacity=5.0)
g.add_edge('b','d', capacity=4.0)
g.add_edge('d','e', capacity=2.0)
g.add_edge('c','y', capacity=2.0)
g.add_edge('e','y', capacity=3.0)

nx.draw(g, with_labels=True, font_size=26, node_size=2000, font_color='red', width=2)

from networkx.algorithms.flow import maximum_flow

flow_value, flow_dict = maximum_flow(g, 'x', 'y')
print(flow_value)
print(flow_dict)
```

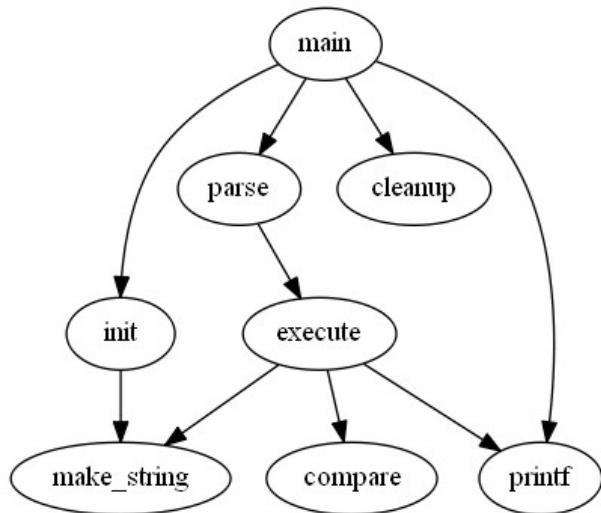
Graf Çizme İçin Graphviz Kütüphanesinin Kullanımı

Graphviz aslında genel amaçlı bir graf çizim kütüphanesidir. Bu kütüphane komut satırından ya da pek çok dilden kullanılabilir. Tipik kullanımında kullanıcı uzantısı .dot ya da .gv olacak biçimde bir text osya içerisinde Graphviz dilini kullanarak grafını yazışal biçimde oluşturur. Sonra dot isimli programı çalıştırır. Bu program Graphviz kaynak dosyasını okuyarak buradan hareketle bir çizim dosyası oluşturmaktadır. Örneğin aşağıdaki gibi bir sample.gv dosyası oluşturmuş olalım:

```
digraph G {
    main -> parse -> execute;
    main -> init;
    main -> cleanup;
    execute -> make_string;
    execute -> printf;
    init -> make_string;
    main -> printf;
    execute -> compare;
}
```

Aşağıdaki gibi bir komutla bir png dosyası elde edebiliriz:

```
dot -Tpng sample.gv -o test.png
```



Graphviz kütüphanesinin dokümantasyonuna aşağıdaki bağlantıdan erişilebilir:

<https://graphviz.gitlab.io/documentation/>

Graphviz Kütüphanesi aslında pek çok dilden kullanılabilmektedir. Biz burada Python'daki kullanımı üzerinde duracağız. Kütüphanenin Python için genel dokümantasyonuna aşağıdaki bağlantıdan erişilebilir:

<https://graphviz.readthedocs.io/en/stable/manual.html>

Graphviz kütüphanesi Python'dan kullanımı tipik olarak şöyle kullanılmaktadır:

1) Önce graph ilgili sınıf kullanılarak (yönsüz için Graph, yönlü için DiGraph) yaratılır. Örneğin:

```
import graphviz as gv
```

```
dot = gv.Digraph('My Graph')
```

2) Graf için düğümler yaratılır. Bu işlem Graph sınıflarının node isimli metodlarıyla yapılmaktadır. Bu metodlar bizden düğümün ismini ve etiketini parametre olarak alırlar. Etiket verilmek zorunda değildir. Örneğin:

```
import graphviz as gv
```

```
dot = gv.Digraph('My Graph')
```

```
dot.node('A', 'Adana')
dot.node('E', 'Eskişehir')
dot.node('K', 'Kastamonu')
dot.node('O', 'Ordu')
dot.node('İ', 'İstanbul')
```

3) Bundan sonra kenarlar edge metoduyla eklenir. Örneğin:

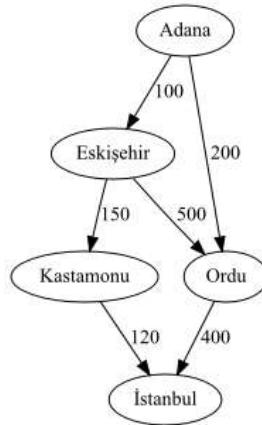
```
dot.edge('A', 'E', label='100')
dot.edge('A', 'O', label='200')
dot.edge('E', 'K', label='150')
dot.edge('O', 'İ', label='400')
```

```
dot.edge('K', 'İ', label='120')
dot.edge('E', 'O', label='500')
```

Sınıfın source isimli örnek özniteliği bize çizilecek grafin script dosya içeriğini verir. (Yani biz bu script'i bir dosyaya yazıp dot programıyla da görüntü dosyası oluşturabiliriz.) Komut satırında grafi çizdirmek için tek yapılacak şey nesne ismini yazarak ENTER tuşuna basmaktır. Örneğin:

In [2]: dot

Out[2]:



Sınıfın render isimli metodu grafik dosyasını oluşturmakta kullanılabilir. render metoduyla default durumda bu grafik dosyası hem oluşturulmakta hem de çizdirilmektedir. Örneğin:

```
dot.render('test.gv', format='png', view=True)
```

Elimizde dot diliyle yazılmış bir script yazısı varsa biz graphviz içerisindeki Source fonksiyonuyla bir Graph ya da Digraph nesnesi elde edebiliriz. Örneğin:

```
g = gv.Source(text)
```

Aslında Source bir sınıfıtır. Bu sınıfın from_file metoduyla da biz doğrudan dosyanın yol ifadesini vererek graf nesnesini elde edebiliriz.

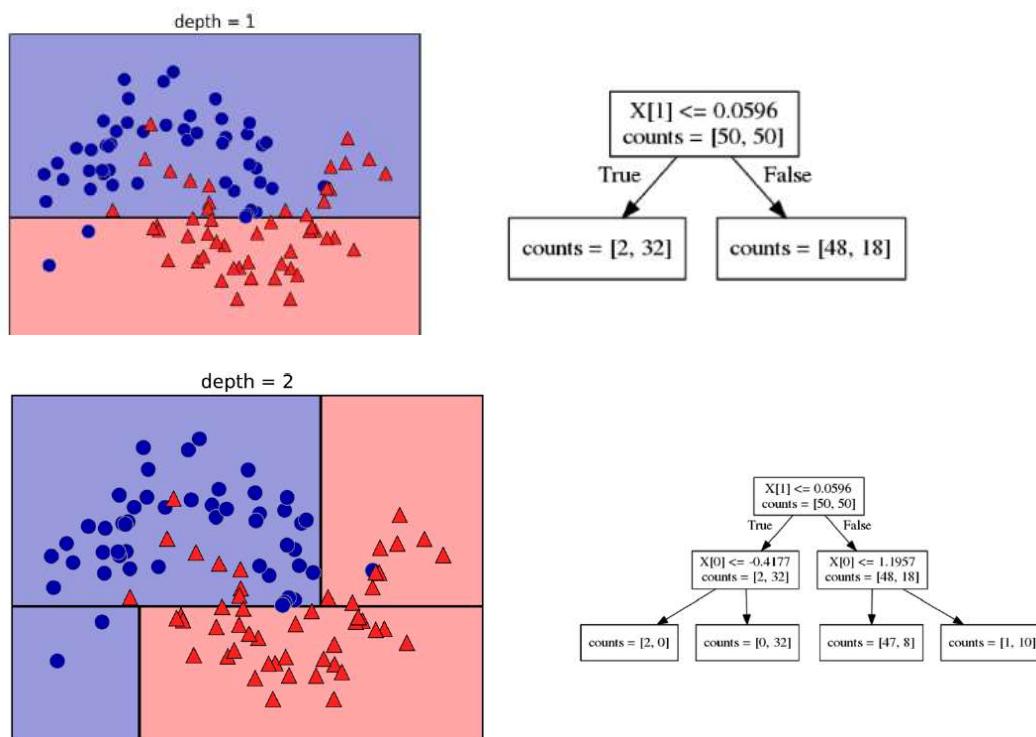
```
g = gv.Source.from_file(path)
```

KARAR AĞAÇLARI (DECISION TREES)

Karar ağaçları sınıflandırma ve regresyon tarzı problemlerde kullanılan alternatif yöntemlerden biridir. Karar ağaçlarının çalışma mekanizması şöyle bir oyunla anlatılabilir: Oyunda oyunculardan biri aklından bir nesne tutar. Diğerini yanıtı Doğru-Yanlış olarak beklenen sorular sorarak bu nesneyi bulmaya çalışır. Örnek sorular şöyle olabilir:

- Canlı mı cansız mı?
- Hafif mi ağır mı?
- Hacim olarak büyük mü küçük mü?
- Hareketli mi sabit mi?
-

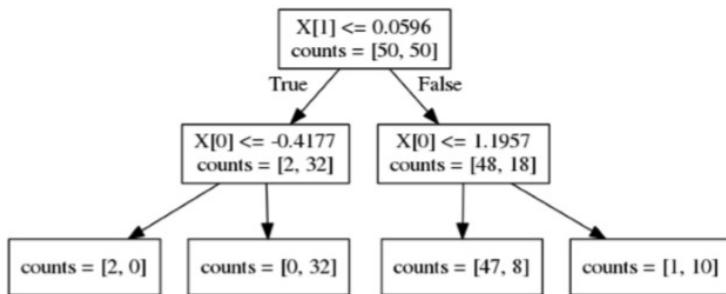
Bu soruların her birinin yanıtının iki seçenek içeriğine dikkat ediniz. İşte bu soruların her birinde aslında biz gitgide alanı daraltarak sonuca yaklaşmış oluruz. Daha önce biz istatistiksel lojistik regresyonla veri kümesini -eğer doğrusal olarak ayırtırılabilir ise- uygun bir doğruyla (ya da özellik sayısı ikiden fazla ise hyperplane ile) ayırtırmaya çalıştık. İşte karar ağaçları yöntemi de aslında yine doğrularla ayırtırma yapar fakat bu yöntemde ayırtırma için tek bir doğru kullanılmamaktadır. Ayırtırma birden fazla doğruyla yapılmaya çalışılmaktadır. Aşağıdaki şekilde iki sütunlu ($X[0]$ ve $X[1]$) bir veri kümesinde bölge yöntemiyle sınıflar ayırtırılmaya çalışılmaktadır (burada $X[0]$ düşey ekseni, $X[1]$ yatay ekseni belirtmektedir):



Alıntı Notu Çizimler ve karar ağaçları resimleri "Introduction To Machine Learning With Python (Muller & Guido)" kitabından alınmıştır.

Burada görüldüğü gibi önce yatay eksene paralel bir doğru oluşturulup iki bölge elde edilmiştir. Sonra bu iki bölge düşey eksene paralel iki doğru ile kendi aralarında yeniden iki bölgeye ayrılmıştır.

Yukarıdaki örnekte iki kademe bölge sonucunda elde edilen ikili ağaç (binary tree) inceleyiniz:



Bu ağaçta kök düğümde sorulan soru $X[1] \leq 0.0596$ 'dır. Bu soruya göre bu koşula uyan ve uymayan değerler elde edilmiştir. Ağaçtaki counts bilgisi ilgili bölgede kaç tane A sınıfından (yuvarlak mavi) kaç tane B sınıfından (üçgen kırmızı) nokta olduğunu belirtmektedir. Örneğin counts = [2, 32] o bölgede 2 tane A sınıfından 32 tane de B sınıfından nokta olduğunu anlatmaktadır. Bizim karar ağaçları yönteminde amacımız bölmelere devam etmek ve en sonunda homojen bölgeler elde etmektir. Bölgelerin homojen olması demek yalnızca tek gruptan nokta bulunması demektir. Yukarıdaki şekilde en soldaki yapraktaki counts değerinin [2, 0] biçiminde olduğunu dikkat ediniz. Yani o bölgede 2 tane A sınıfından nokta vardır fakat hiç B sınıfından hiç nokta yoktur. İşte bu homojen (pure) bir durumdur.

Karar ağaçları denetimli (supervised) bir öğrenme teknigini kullanmaktadır. Çünkü bölme işlemleri ilgili noktaların sınıflarına göre yapılmaktadır. Peki eğitimden sonra kestirim nasıl yapılacaktır? Aslında kestirim oldukça kolaydır. Kestirilecek değerlere ağacın tepesinden itibaren daha önce oluşturulmuş sorular sorulur. Soruların yanıtlarına göre sola ya da sağa sapılarak bir yaprağa varılır. İşte o yaprağın durumu da bize sınıflandırmanın sonucunu verecektir.

Peki karar ağıacı oluştururken hangi sorular hangi sırayla sorulacaktır? İşte bu noktada bilgi teorisi (information theory) konuları devreye girmektedir. Önce hangi sorunun sorulması gereği ve bu sorunun ne olması gerektiği çeşitli matematiksel yöntemlerle belirlenebilmektedir. Tabii burada kullanılan tek bir algoritmik yöntem yoktur. Shannon etropisi ve "Gini impurity" yönetimi en çok kullanılan yöntemlerdir.

Scikit-learn Kütüphanesinde Karar Ağaçlarıyla Sınıflandırma

Scikit-learn kütüphanesinde karar ağaçları ile sınıflandırma için DecisionTreeClassifier isimli bir sınıf bulundurulmuştur. Bu sınıfın kullanımı aslında daha önce gördüğümüz sınıfların kullanımına çok benzerdir. Önce DecisionTreeClassifier türünden bir nesne yaratılır. Sonra fit işlemi uygulanır. Kestirim için yine sınıfın predict metodu kullanılmaktadır. Sınıflandırmanın başarısı diğer sınıflarda olduğu gibi sınıfın score metoduyla elde edilmektedir.

Şimdi bu sınıfı daha önce çalıştığımız meme kanseri veri tablosu ile kullanalım.

```

from sklearn.datasets import load_breast_cancer
bc = load_breast_cancer()

print(f'Sütun isimleri: {bc.feature_names}')
print(f'Sınıf Isimleri: {bc.target_names}')

dataset_x = bc.data
dataset_y = bc.target

from sklearn.model_selection import train_test_split

training_dataset_x, test_dataset_x, training_dataset_y, test_dataset_y =
train_test_split(dataset_x, dataset_y, test_size=0.2)

from sklearn.tree import DecisionTreeClassifier

dtc = DecisionTreeClassifier()
dtc.fit(training_dataset_x, training_dataset_y)
score = dtc.score(test_dataset_x, test_dataset_y)

```

```
print(f'Score: {score}')
```

Burada default değerlerle DecisionTreeClassifier nesnesi yaratılmıştır. Daha sonra fit işlemi yapılmıştır. Ağacın oluşturulması fit işlemi sırasında gerçekleştirilmektedir. score metodu bir çeşit test metodudur. Biz de burada test veri kümemizle işlemin başarısını tespit etmiş olduk. score işlemi sırasında her test verisi ağaç'a sokularak ağaçtan bulunan değer gerçek sonuçla karşılaştırılmış ve sınıflama için bir başarı yüzdesi hesaplanmıştır. Programın her çalıştırılmasında farklı bir skor elde edilebilmektedir. Aşağıda programı beş kez çalıştırarak elde ettiğimiz skorları görüyoruz:

```
Score: 0.9385964912280702
Score: 0.9298245614035088
Score: 0.9385964912280702
Score: 0.9473684210526315
Score: 0.9122807017543859
```

Anımsayacağınız gibi destek vektör makineleri ile aynı veri kümelerinden %95'lik bir başarı elde etmiştir. Şimdi de yapay sinir ağlarının aynı veri kümelerindeki başarısına bakalım. Burada auto-keras kullanacağız:

```
from sklearn.datasets import load_breast_cancer
bc = load_breast_cancer()

dataset_x = bc.data
dataset_y = bc.target

from sklearn.model_selection import train_test_split

training_dataset_x, test_dataset_x, training_dataset_y, test_dataset_y =
train_test_split(dataset_x, dataset_y, test_size=0.2)

import autokeras as ak

sdc = ak.StructuredDataClassifier(max_trials=5)
sdc.fit(training_dataset_x, training_dataset_y, epochs=50)
model = sdc.export_model()

predict_result = sdc.evaluate(test_dataset_x, test_dataset_y)
eval_result = model.evaluate(test_dataset_x, test_dataset_y)
for i in range(len(eval_result)):
    print(f'{model.metrics_names[i]} ---> {eval_result[i]}')
```

Buradan şu sonuç elde edilmiştir:

```
loss ---> 0.20057329535484314
accuracy ---> 0.9649122953414917
```

Gördüğü gibi elde edilen sonuç alternatif yöntemlere göre biraz daha iyi gibi gözükmektedir.

DecisionTreeClassifier sınıfının predict metodu kestirim yapmakta kullanılmaktadır. Yani biz ağaç oluşturdukdan sonra kestirimde bulunabiliriz. Örneğin test_dataset_x içerisindeki rastgele 5 nokta için predict işlemi yapalım:

```
import numpy as np

r = np.random.randint(0, len(test_dataset_x) - 1, 5)
predict_data = test_dataset_x[r]
predict_result = dtc.predict(predict_data)

print(f'predicted result: {bc.target_names[predict_result]}')
print(f'real result: {bc.target_names[test_dataset_y[r]]}'')
```

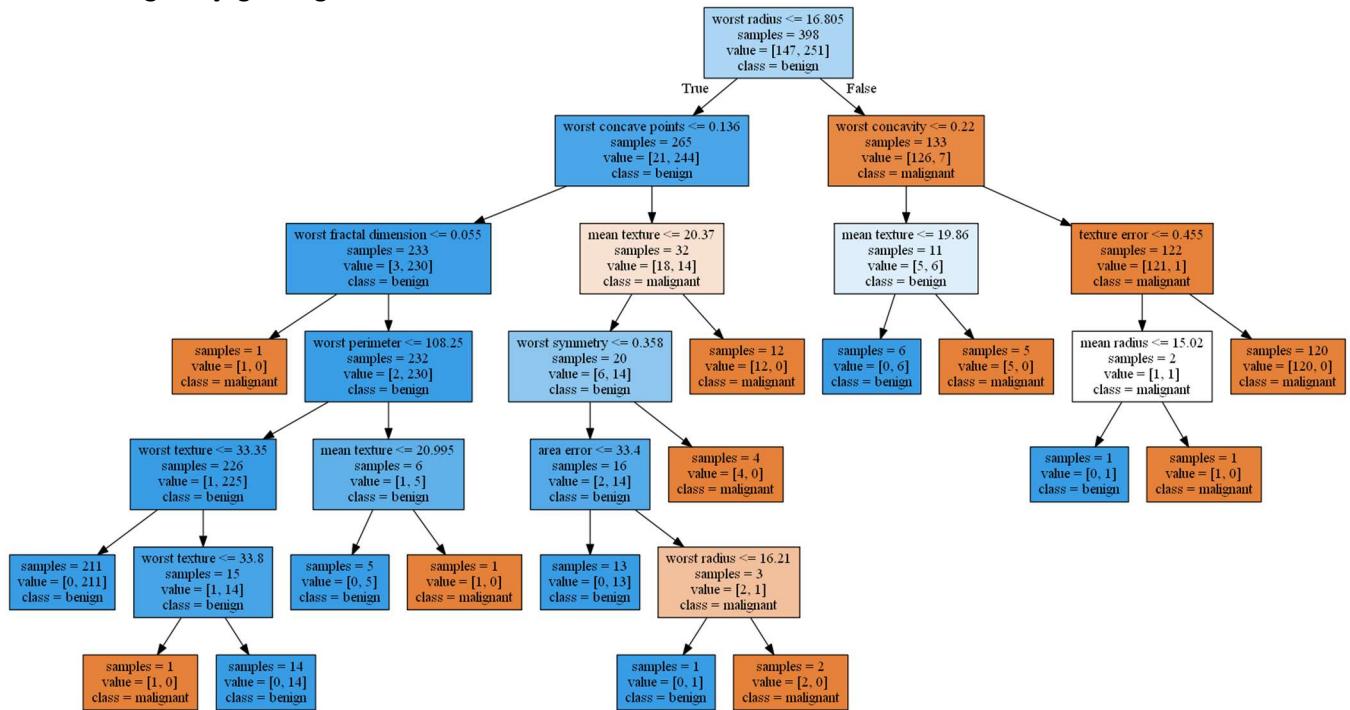
DecisionTreeClassifier sınıfı ile oluşturulan ağacın graphiz yardımıyla grafi çizdirilebilir. Bunun için sklearn.tree modülündeki export_graphviz metodu kullanılmaktadır. Bu metot çizimi yapmaz fakat çizim bilgilerinin bulunduğu graphviz script dosyasını oluşturur. Örneğin:

```
from sklearn.tree import export_graphviz
import graphviz

export_graphviz(dtc, out_file='dt.dot', class_names=['malignant', 'benign'],
feature_names=bc.feature_names, impurity=False, filled=True)

gv = graphviz.Source.from_file('dt.dot')
gv.render(view=True, format='png')
```

Elde edilen graf aşağıdaki gibidir:



Burada yaprakların homojen (pure) durumda olduğuna dikkat ediniz. Toplam özellik sayısı 30 olduğu halde eğitimde 6 derinlikte sonuca ulaşılmıştır. Biz DecisionTreeClassifier sınıfının `__init__` metodunda ağacın oluşturulması ile ilgili çeşitli belirlemeler yapabilmekteyiz. DecisionTreeClassifier sınıfının `__init__` metodunun parametrik yapısı şöyledir:

```
sklearn.tree.DecisionTreeClassifier(criterion='gini', splitter='best', max_depth=None, min_samples_split=2, min_samples_leaf=1, min_weight_fraction_leaf=0.0, max_features=None, random_state=None, max_leaf_nodes=None, min_impurity_decrease=0.0, min_impurity_split=None, class_weight=None, presort='deprecated', ccp_alpha=0.0)
```

Buradaki "criterion" parametresi 'gini' ya da 'entropy' biçiminde girilebilmektedir. `min_samples_split` parametresi ilgili ağaç düğümünün bölünmesi için gerekli olan minimum eleman sayısını belirtmektedir. `max_depth` parametresi ise ağacın maksimum derinliğini belirlemekte kullanılır. Örneğin bu parametreyi 4 yaparak kodu yeniden çalışıralım:

```
from sklearn.tree import DecisionTreeClassifier

dtc = DecisionTreeClassifier(max_depth=4)
dtc.fit(training_dataset_x, training_dataset_y)
score = dtc.score(test_dataset_x, test_dataset_y)

print(f'Score: {score}')

from sklearn.tree import export_graphviz
```

```

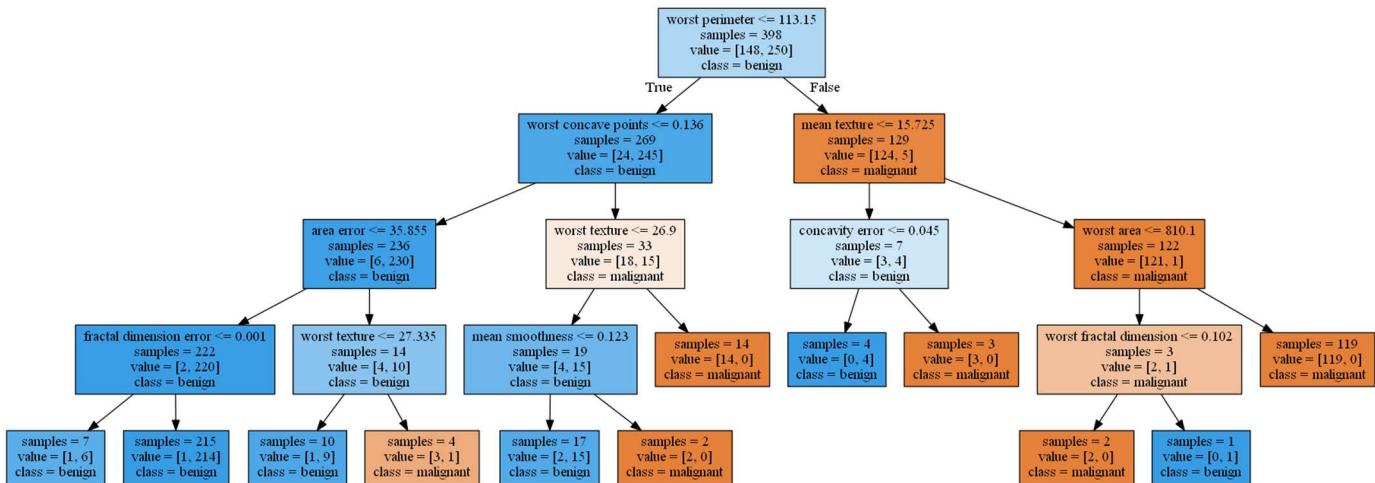
import graphviz

export_graphviz(dt, out_file='dt.dot', class_names=['malignant', 'benign'],
feature_names=bc.feature_names, impurity=False, filled=True)

gv = graphviz.Source.from_file('dt.dot')
gv.render(view=True, format='png')

```

Şu sonuç elde edilmiştir:



Burada ağaçın 4 derinlikli olduğu (okların sayısına bakınız) görülmektedir. Yaprakların "pure" olmadığına dikkat ediniz.

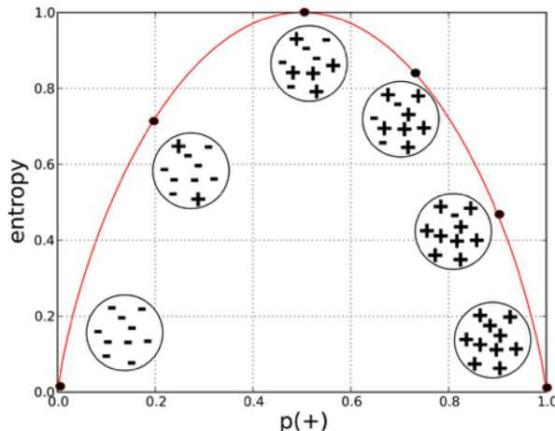
Şimdi bölme işlemini daha iyi anlayabilmek için iki özellikli bir veri seti üzerinde işlemlerimizi yapalım.

Karar Ağaçlarının Algoritmik Temeli

Karar ağaçlarının algoritmik temeli entropy kavramına dayanmaktadır. Entropy sistemdeki düzensizliğin bir ölçüsüdür. Eğer veriler rastgele ise yüksek bir entropy, düzenli ise düşük bir entropy söz konusudur. Karar ağaçlarında entropi hesaplamak için en çok kullanılan yöntem "Shannon entropisi" denilen yöntemdir. Shannon entropisi şöyle hesaplanmaktadır:

$$E(S) = \sum_{i=1}^c -p_i \log_2 p_i$$

Buradaki p_i ilgili özellik değerinin veri kümesinde ortaya çıkma olasılığıdır. Bu olasılık ilgili özelliğin adet toplamının veri kümesindeki satır sayısına bölümü ile elde edilebilir. Yukarıda da belirttiğimiz gibi entropi düzensizliğin yanı heterojenliğin bir ölçüsüdür. Homojenlik arttıkça entropi azalır, homojenlik azaldıkça entropi artar. Örneğin + ve - karakterlerinin veri kümesi içerisindeki durumlarına göre örnek bir entropi diyagramı şöyle çizilebilir:



Akıntı Notu: Görsel <https://towardsdatascience.com/entropy-how-decision-trees-make-decisions-2946b9c18c8> adresinden elde edilmiştir.

Burada görüldüğü gibi homojenlik arttıkça entropi düşmüş, heterojenlik arttıkça entropi artmıştır. Düşey eksende entropi miktarı gösterilmektedir. Entropi miktarı genel olarak $[0, 1]$ aralığında bir gerçek sayı biçiminde ifade edilmektedir. Şekildeki yatay eksende + şekillerinin olasılıklarının bulunduğuuna dikkat ediniz.

Karar ağaçlarında bölünecek en iyi sütunun ve noktanın tespit edilmesi "entropi" kavramı ile ilgilidir. Bu süreç kabaca şöyle yürütülmektedir: Her sütun için bazı noktalardan bölmeye yapılarak elde bir grup olası bölmelerin durumları elde edilir. Sonra bu bölmeye durumlarının kazançları hesaplanır. Hangi bölmeyenin alternatif bölmelere göre kazancı yüksekse o bölmeyi tercih edilmektedir. Bölmeyenin kazancı üst düğümün entropisinden alt düğümlerin entropilerinin toplamı çıkartılarak elde edilmektedir.

Bölmeyen Kazanı = Üst Düğümün Entropisi – Alt Düğümlerin Entropileri Toplamı

Kazancı en yüksek bölmeyen diğer alternatif bölmelere göre üst düğümü daha iyi ayırtır. Yani bir bölmeyenin kazancının diğer bölmenden yüksek olması aslında o bölmeyi uygulandığında diğerine göre düzensizlikten daha yüksek bir düzenlilik durumuna geçileceği anlamına gelmektedir. Tabii her bölmenden sonra işlemler yine diğer özellikler temel alınarak devam ettirilir. Tabii bu işlemin sonucunda aynı sütundan da birden fazla kez bölmeye yapılmış olabilir.

Karar ağaçlarında sütunlara göre bölmeye noktalarına nasıl karar verildiği de ayrı bir sorundur. Bölmeye noktalarını kategorik sütunlarla sayısal sütunlar için farklı biçimlerde belirlenebilmektedir. Eğer sütun kategorikse ve kategoriler de çok fazla değilse bölmeler kategorilere göre yapılmaktadır. Eğer sütunlardaki bilgi kategorik değerlerin %10, %20, %30, ... %90 gibi belli percentil'leri tek tek denenebilmektedir. Aslında yaygın kütüphaneler kategorik değerleri ayrı tamsayı değerler olarak ele alıp bölmeye işlemi yine sayısal düzeyde de yapabilmektedir.

Şimdi hiç NumPy kullanmadan karar ağıacı işlemlerini yapan program parçalarını yazmaya çalışalım. Veri kümemiz şöyle olsun:

```
dataset = [['a', 'x', 'yes'], ['b', 'x', 'yes'], ['a', 'y', 'yes'], ['a', 'x', 'no'], ['a', 'y', 'yes']]
```

Burada veri kümemizin iki sütundan olduğunu görüyoruz. Birinci sütun "a" ve "b" kategorik değerlerindendir, ikinci sütun ise "x" ve "y" kategorik değerlerinden oluşmaktadır. Üçüncü sütun ise "yes" ve "no" değerlerinden oluşan sonuç sütunudur.

Öncelikle entropy hesabı yapan örnek bir fonksiyon yazalım. Bu fonksiyonun girdisi yukarıdaki gibi çok boyutlu bir dizi olsun. Girdi olarak kullanılacak listenin son sütun elemanlarının sınıf belirten bir bilgi içerdigini varsayıyalım. Örneğin:

```
import math

def calc_shannon_entropy(dataset):
    nrows = len(dataset)
    label_dict = {}
```

```

for row in dataset:
    label = row[-1]
    if label not in label_dict:
        label_dict[label] = 0
    label_dict[label] += 1
entropy = 0
for key in label_dict:
    prob = label_dict[key] / nrows
    entropy += - prob * math.log(prob, 2)

return entropy

```

Yazdığımız fonksiyon yukarıdaki örnek liste için çalıştıralım:

```

dataset = [['a', 'x', 'yes'], ['b', 'x', 'yes'], ['a', 'y', 'yes'], ['a', 'x', 'no'], ['a', 'y', 'yes']]
result = calc_shannon_entropy(dataset)
print(result)

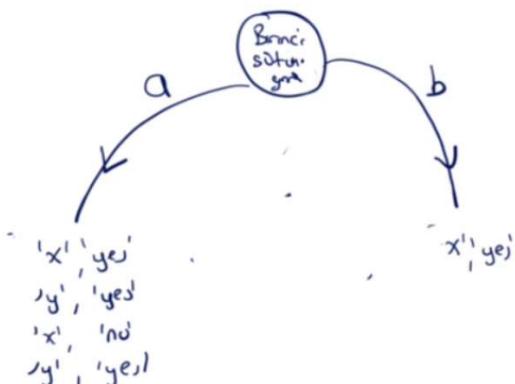
```

Buradan şöyle bir sonuç elde edilmiştir:

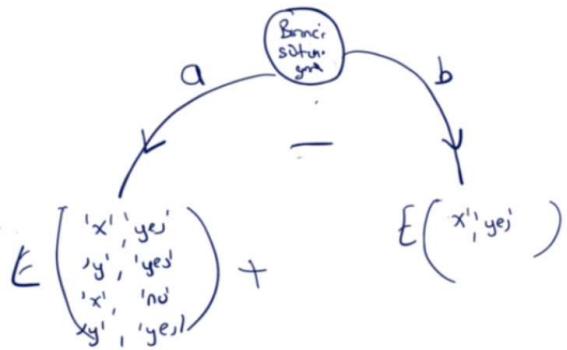
0.7219280948873623

Gördüğünüz gibi ['yes', 'yes', 'yes', 'no', 'yes'] için elde edilen entropi değeri 0.72 civarındadır. Buradaki bütün değerler "yes" ya da "no" olsaydı entropi 0, değerlerin yarısı "yes" yarısı "no" olsaydı entropi değeri 1 çıkacaktı. Aslında Shannon entropi değeri SciPy kütüphanesi içerisindeki `scipy.stats` modülünde bulunan `entropy` fonksiyonuyla hesaplanabilmektedir. Ancak bu fonksiyona değer olasılıklarının bir NumPy dizisi olarak girilmesi gerekmektedir.

Şimdi bizim hangi sütuna ve hangi noktalara göre ikiye ayırmayı belirleyip alternatif bölmeleri oluşturmamız gereklidir. Bu örneğimizde iki sütun vardır ve bu iki sütun zaten iki kategorik değerden oluşmaktadır. Bu durumda zaten olası bölgeleri toplamda iki tane olacaktır. Burada biz birinci sütundaki, "x" ve "y" değerlerine göre bölgeler yaparsak sol ve sağ düğümler şöyle olur:



Biz burada kazancı şöyle hesaplarız:



Şimdi bu işlemi programlama yoluyla yapalım:

```

parent_entropy = calc_shannon_entropy(dataset)

first_left = [['x', 'yes'], ['y', 'yes'], ['x', 'no'], ['y', 'yes']]
first_right = [['x', 'yes']]

prob_left = len(first_left) / len(dataset)
first_left_result = prob_left * calc_shannon_entropy(first_left)

prob_right = len(first_right) / len(dataset)
first_right_result = prob_right * calc_shannon_entropy(first_right)

first_gain = parent_entropy - (first_left_result + first_right_result)

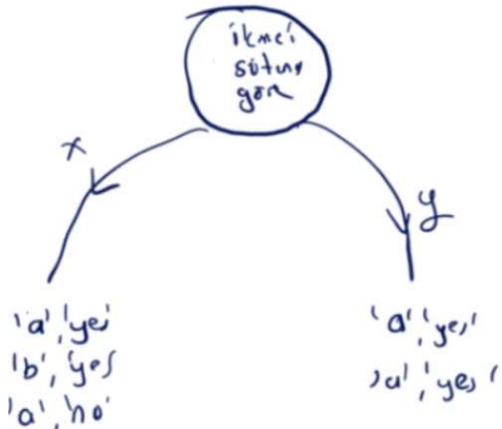
print(first_gain)

```

Buradan şu sonuç elde edilmiştir:

0.7219280948873623

Şimdi ikinci sütundaki "a" ve "b" değerlerine göre bölme yaptığımızı düşünelim:



Şimdi aynı şeyleri bu bölme için de yapalım:

```

second_left = [['a', 'yes'], ['b', 'yes'], ['a', 'no']]
second_right = [['a', 'yes'], ['a', 'yes']]

prob_left = len(second_left) / len(dataset)
second_left_result = prob_left * calc_shannon_entropy(second_left)

prob_right = len(second_right) / len(dataset)
second_right_result = prob_right * calc_shannon_entropy(second_right)

```

```

second_gain = parent_entropy - (second_left_result + second_right_result)

print(second_gain)

```

Buradan 0.170 sonucu elde edilmiştir. Görüldüğü gibi $0.072 < 0.170$ biçimindedir. Bu durumda bölme ikinci sütuna göre yapılacaktır.

İşte algoritmada alt düğümler de benzer biçimde bölünerek ilerlenir. Eğer bir düğüm tamamen homojen (pure) biçimde gelirse (yani entropisi 0 olursa) artık o düğüm bir yaprak durumundadır ve daha fazla bölme yapılmaz.

Aslında bölme işlemini yapan bir fonksiyon da benzer biçimde yazılabilir. Örneğin:

```

def split_dataset(dataset, column, value):
    result = []
    for row in dataset:
        if row[column] == value:
            result.append(row[:column] + row[column + 1:])

    return result

```

Şimdi de en iyi sütunun seçilmesini yapan fonksiyonu yazalım:

```

def find_best_feature(dataset):
    nfeatures = len(dataset[0]) - 1
    parent_entropy = calc_shannon_entropy(dataset)
    max_gain = float('-inf')
    max_feature = -1
    for i in range(nfeatures):
        feature_list = [row[i] for row in dataset]
        uniques = set(feature_list)
        sub_entropy = 0
        for value in uniques:
            sub_dataset = split_dataset(dataset, i, value)
            sub_entropy += calc_shannon_entropy(sub_dataset)
        gain = parent_entropy - sub_entropy
        if gain > max_gain:
            max_gain = gain
            max_feature = i

    return max_feature, max_gain

```

```

dataset = [['a', 'x', 'yes'], ['b', 'x', 'yes'], ['a', 'y', 'yes'], ['a', 'x', 'no'], ['a', 'y', 'yes']]

result = find_best_feature(dataset)
print(result)

```

Şimdi de yukarıdaki örneği Scikit-learn kütüphanesindeki DecisionTreeClassifier sınıfı ile çözelim. DecisionTreeClassifier sınıfı isminde "classifier" geçse de verileri kategorik değil sayısal olarak almaktadır. Bu nedenle bizim verileri kategorik biçimden sayısal biçimde dönüştürülmesi gerekmektedir. Bu işlemi sklearn.preprocessing modülü içerisindeki LabelEncoder sınıfı ile yapabiliriz:

```

import numpy as np

dataset = np.array([['a', 'x', 'yes'], ['b', 'x', 'yes'], ['a', 'y', 'yes'], ['a', 'x', 'no'], ['a', 'y', 'yes']])
transformed_dataset = np.zeros(dataset.shape)

le = LabelEncoder()
for i in range(dataset.shape[1]):

```

```

transformed_dataset[:, i] = le.fit_transform(dataset[:, i])

training_dataset_x = transformed_dataset[:, :-1]
training_dataset_y = transformed_dataset[:, -1]

```

Şimdi DecisionTreeClasifier sınıfını kullanarak işlemlerimizi yapalım:

```

from sklearn.tree import DecisionTreeClassifier

dt = DecisionTreeClassifier(criterion='entropy')
dt.fit(training_dataset_x, training_dataset_y)

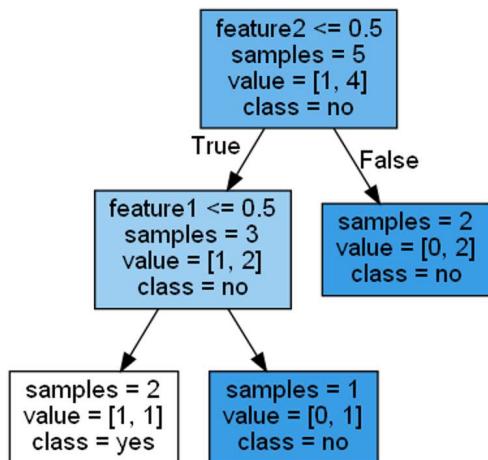
from sklearn.tree import export_graphviz
import graphviz

export_graphviz(dt, out_file='dt.dot', class_names=['yes', 'no'], feature_names=['feature1', 'feature2'], impurity=False, filled=True)

g = graphviz.Source.from_file('dt.dot')
gv.render(view=True, format='png')

```

Elde edilen grafik şöyledir:



Biz burada DecisionTreeClassifier sınıfı için criterion parametresini 'entropy' olarak kullandık. Bu criterion parametresi entropinin yukarıdaki örneklerde yaptığı gibi "Shannon entropisi" biçiminde hesaplanacağını belirtmektedir. Bu parametre 'gini' olarak da girilebilmektedir. Bu düzensizlik hesaplama yöntemi "Corrado Gini" tarafından önerildiği için ismine "Gini impurity" denilmektedir. Gini impurity de Shannon entropisine alternatif bir düzensizlik hesaplama yöntemidir. Hesaplama şöyle yapılmaktadır:

$$GiniIndex = 1 - \sum_j p_j^2$$

Sınıflandırma İşlemlerinde İstatistiksel Lojistik Regresyon İle Karar Ağaçlarının Karşılaştırılması

Istatistiksel lojistik regresyon ile karar ağaçları bazı veri kümeleri için birbirine benzer performans gösterse de bazı veri kümeleri için farklı performanslar gösterebilmektedir. Aralarındaki belirgin farklılıklar şöyle özetlenebilir:

- Karar ağaçları insan düşüncesine daha yakındır. Dolayısıyla verilen kararın izlediği yol sözcüklerle daha iyi açıklanabilmektedir.
- Bilgilerin aşama aşama elde edildiği durumlarda (doktor muayenesini düşününüz) olayın akışı itibarı ile karar ağaçları daha uygun bir yöntem olabilmektedir.

- İstatistiksel lojistik regresyon parametrik, karar ağaçları ise parametrik olmayan bir modele sahiptir.
- İstatistiksel lojistik regresyonun iyi sonuç vermesi için verilerin doğrusal olarak ayırtılabilir olması gerekmektedir. Halbuki karar ağaçlarında veriler doğrusal olarak ayırtılabilir olmasa da iyi bir sonuç elde edilebilmektedir.
- İstatistiksel lojistik regresyon üç değerlerden karar ağaçlarına göre daha olumsuz etkilemektedir.
- İstatistiksel lojistik regresyon özellikle sürekli değişkenler üzerinde uygulanmaktadır. Değişkenler kesikli ise karar ağaçları daha iyi performans göstermektedir.
- Genel olarak karar ağaçlarının overfit durumuna yatkınlığı istatistiksel lojistik regresyondan fazla olma eğilimindedir. Yani karar ağaçlarının eğitimde uygulanan kümeye bağlı olarak sınıflandırmayı yanlış öğrenme potansiyeli istatistiksel lojistik regresyona göre daha fazladır.

Karar Ağaçları ile Lojistik Olmayan Regresyon İşlemleri

Karar ağaçları yalnızca lojistik regresyon (sınıflandırma) amacıyla değil lojistik olmayan regresyon amacıyla da kullanılabilmektedir. Algoritmanın genel işleyişi çok benzerdir. Burada biz Scikit-learn ile lojistik olmayan karar ağaç regresyonlarının nasıl yapılacağı üzerinde duracağız. Karar ağaçlarının lojistik olmayan regresyon amaçlı kullanılması için Scikit-learn içerisindeki DecisionTreeRegressor sınıfı kullanılmaktadır. Sınıfın `__init__` metodunun parametrik yapısı şöyledir:

```
sklearn.tree.DecisionTreeRegressor(criterion='mse', splitter='best', max_depth=None,
min_samples_split=2, min_samples_leaf=1, min_weight_fraction_leaf=0.0, max_features=None,
random_state=None, max_leaf_nodes=None, min_impurity_decrease=0.0, min_impurity_split=None,
presort='deprecated', ccp_alpha=0.0)
```

Buradaki criterion 'mse', 'friedman_mse' ya da 'mae' olabilir. Yine max_depth parametresi ağacın maksimum derinliğini ayarlamakta kullanılır. DecisionTreeRegressor nesnesi yaratıldıkten sonra yine fit metoduyla eğitim yapılpredict metodu ile tahminleme yapılmaktadır. Aşağıda Boston ev fiyatlarıyla ilgili bir karar ağaç regresyonu görülmektedir:

```
import numpy as np

from sklearn.datasets import load_boston

boston = load_boston()
dataset_x = boston.data
dataset_y = boston.target

from sklearn.tree import DecisionTreeRegressor

dtr = DecisionTreeRegressor()
dtr.fit(dataset_x, dataset_y)

predict_x = np.array([[3.2370e-02, 0.0000e+00, 2.1800e+00, 0.0000e+00, 5.8800e-01,
6.9980e+00, 5.5800e+01, 6.0622e+00, 3.0000e+00, 2.2200e+02,
1.8700e+01, 3.9463e+02, 2.9400e+00]])

result = dtr.predict(predict_x)
print(result)

from sklearn.tree import export_graphviz
import graphviz

export_graphviz(dtr, out_file='dtr.gv', impurity=False, filled=True)

g = graphviz.Source.from_file('dtr.gv')
```

Karar ağaçlarıyla regresyon işlemi aslında sınıflandırma işlemine çok benzemektedir. Ağaçtan elde edilen yapraklar eğitim veri kümesindeki değerler olmaktadır. Tabii birden fazla aynı değere ilişkin yaprak karar ağacında bulunabilmektedir. Şüphesiz bu yöntemde fazla sayıda veri ile eğitim uygulamak kestirimini iyileştirecektir. Mademki bu yöntemde yapraklar aslında gerçek sonuç gözlem değerleridir o halde bu değerlerin dışında bir sonuç elde edilmesi beklenmemelidir. Yani eğitim veri kümesinde olmayan sonuçların tahminlemesi bu yöntemde mümkün değildir. Karar ağaçlarıyla lojistik olmayan regresyonu n eğitimdeki veri kümeleri kadar sınıfı sahip lojistik regresyon gibi düşünebilirsiniz.

Karar Ağaçlarında Paketleme (Bagging)

Yukarıda da belirtildiği gibi karar ağaçlarının en önemli sorunu "overfit" durumuna yatkınlıktır. Overfit aslında yüksek varyansla kendini göstermektedir. Örneğin biz eğitim veri kümesini iki yarıya bölüp iki karar ağaçları oluşturursak bu ağaçlar bu iki kümenin o andaki durumuna bağlı olarak farklı olabilecektir. Bu durum yüksek varyansı anlatmaktadır. Oysa lojistik regresyonlarda karar ağaçlarına göre varyans düşüktür. Ancak lojistik regresyonlar da uç değerlerden kötü bir biçimde etkilenme eğilimindedir. O halde karar ağaçlarını iyileştirmek için yapılacak şey varyansı düşürmektir. Varyansı düşürmenin ilk akla gelen makul yöntemi ise tek bir ağaç değil birden fazla ağaç kullanmaktır. (Birden fazla ağaç bu terminolojide "orman (forest)" da denilmektedir.)

Paketleme işleminde eğitim veri kümesi içerisindeki belli miktarda satırlardan ağaçlar oluşturulmaktadır. Örneğin eğitim veri kümesinde 100 tane satır olsun. Biz 30'ar satırdan oluşan 500 tane örnek elde edip 500 tane karar ağaçları oluşturabiliriz. Tabii örnekler (samples) rastgele bir biçimde seçilmelidir. Örneklerde genellikle iadelî seçim uygulanmaktadır. (Yani böylece bir örneklem aynı elemanlara sahip olabilmektedir.) Paketleme yönteminde satırlardan örnekler oluşturulmakla birlikte sütunların (yani değişkenlerin) hepsi alınmaktadır.

Paketleme işlemi sonucunda toplam n tane karar ağaçları elde edilmektedir. Peki bu ağaçlardan nasıl faydalanaçaktır? İşte varyansı düşürebilmek amacıyla buradan bir ortalama değer hesaplanır. Ortalama değer sınıflandırma problemleri için en yüksek sınıf temelinde yapılmaktadır. Lojistik olmayan regresyon problemlerinde ise gerçekten bir aritmetik ortalama hesaplanabilmektedir. Böylece lojistik olmayan regresyon problemlerinde eğitim veri kümesinde olmayan değerler de elde edilebilmektedir.

Örneğin sınıflandırma problemi için 500 tane karar ağaçının oluşturulduğunu düşünelim. Sonra da kestirim (prediction) işlemi yapmak isteyelim. İşte yöntemde bu kestirilecek veri tüm bu 500 ağaçla da sokulmaktadır. Bu 500 ağaçın sonucunda elde edilen değerlere bakılarak en yaygın sınıf kestiriminin sonucu olarak belirlenmektedir. Yine lojistik olmayan bir regresyon problemi için 500 karar ağaçının oluşturulduğunu düşünelim. Kestirim yapılırken kestirilecek değer bu 500 karar ağaçına da sokulacak ve elde edilen değerlerin aritmetik ortalaması regresyon sonucu olarak belirlenecektir.

Şüphesiz paketleme yöntemi normal karar ağaç yöntemi göre çok daha fazla bilgisayar zamanının kullanılmasına yol açmaktadır. Ancak bu yöntemin performansı normal karar ağaç yöntemi göre daha iyidir.

Peki bu yöntemde eğitim veri kümesindeki toplam satır sayısı n olmak üzere kaç ağaç (yani alt veri kümesi) oluşturulmalıdır? Şüphesiz ağaç sayısı ne kadar fazla olursa o kadar iyidir. Ancak belirli sayıda ağaçtan sonra bilgisayar zamanı artmasına karşın iyileşme oranı da azalmaktadır. Örneğin ağaç sayısı için 100, 200, 300 gibi değerler kullanılabilir. Örneklem için kullanılacak satır sayıları eğitim veri kümesinin miktarına da bağlı olarak belirlenebilmektedir. Yüksek miktardaki eğitim veri kümesi için örneklem veri miktarı sınıflandırma problemlerinde \sqrt{n} , regresyon problemlerinde $n / 2$ ya da $n / 3$ gibi değerde tutulabilir. Fakat düşük miktarda eğitim veri kümesinde örneklem büyülüğu daha yüksek olabilir.

Scikit-learn kütüphanesinde `sklearn.ensemble` modülündeki `BaggingClassifier` sınıfı paketleme yöntemi ile karar ağaçları sınıflandırması yapmakta kullanılır. Benzer biçimde aynı modüldeki `BaggingRegressor` sınıfı da paketleme yöntemiyle lojistik olmayan karar ağaç regresyonu için kullanılmaktadır. `BaggingClassifier` sınıfının `__init__` metodunun parametrik yapısı şöyledir:

```
class sklearn.ensemble.BaggingClassifier(base_estimator=None, n_estimators=10, max_samples=1.0, max_features=1.0, bootstrap=True, bootstrap_features=False, oob_score=False, warm_start=False, n_jobs=None, random_state=None, verbose=0)
```

Fonksiyonun birinci parametresi olan base_estimator kullanılacak yöntemi belirtmektedir. Bu parametre için argüman girilmezse default durum karar ağaçlarının kullanılmasıdır. Fonksiyonun n_estimators parametresi toplamda oluşturulacak karar ağaçlarının sayısını belirtir. Fonksiyonun max_samples parametresi tamsayı olarak girilirse örnekleم büyüküğünü float olarak girilse örnekleم oranını belirtmektedir. bootstrap parametresi ise örnekleم iadelı mi iadesiz mi yapılacağı belirtmektedir. Default durum iadelı örneklemedir.

BaggingClassifier sınıfının fit ve predict metodları diğer sınıflarda olduğu gibidir. Şimdi BaggingClassifier sınıfını meme kanseri veri kümesine uygulayalım:

```
from sklearn.datasets import load_breast_cancer

bc = load_breast_cancer()
print('Sütun isimleri: {}'.format(bc.feature_names))
print('Sınıf Isimleri: {}'.format(bc.target_names))

dataset_x = bc.data
dataset_y = bc.target

from sklearn.model_selection import train_test_split

training_dataset_x, test_dataset_x, training_dataset_y, test_dataset_y =
train_test_split(dataset_x, dataset_y, test_size=0.3)

from sklearn.ensemble import BaggingClassifier

dt = BaggingClassifier(n_estimators=300, max_samples=0.4)
dt.fit(training_dataset_x, training_dataset_y)
score = dt.score(test_dataset_x, test_dataset_y)
print(score)
```

Buradaki sonuçlar önceki normal karar ağacından elde ettiğimiz sonuçlardan genel olarak %3 civarında daha iyidir.

Paketleme ile lojistik olmayan regresyon işlemi de yapılabilmektedir. Bunun için ise BaggingRegressor sınıfı kullanılmaktadır. Aşağıda Boston verileriyle böyle bir lojistik olmayan regresyon örneği görüyorsunuz:

```
import numpy as np

from sklearn.datasets import load_boston
from sklearn.ensemble import BaggingRegressor

boston = load_boston()
dtr = BaggingRegressor(n_estimators=300, max_samples=0.4)
dtr.fit(boston.data, boston.target)

predict_x = np.array([[3.2370e-02, 0.0000e+00, 2.1800e+00, 0.0000e+00, 5.8800e-01,
6.9980e+00, 5.5800e+01, 6.0622e+00, 3.0000e+00, 2.2200e+02,
1.8700e+01, 3.9463e+02, 2.9400e+00]])
```

```
result = dtr.predict(predict_x)
print(result)
```

Karar Ağaçları ve Rassal Ormanlar

Rassal orman denilen yöntem paketleme (bagging) yönteminin bir ileri aşamasıdır. Anımsanacağı gibi paketleme yönteminde rastgele seçilen belki miktarda satırlardan karar ağaçları oluşturuluyordu. Ancak bu ağaçlarda sütunların hepsi kullanılıyordu. İşte paketleme yönteminde tüm sütunların (yani değişkenlerin) ağaçca dahil edilmesi oluşturulan

farklı ağaçların birbirlerine benzemesine yol açabilmektedir. Bu da varyansı yükselen bir faktör durumuna gelebilmektedir. Ayrıca paketleme yönteminde tüm sütunların işleme sokulması ağırlığı yüksek sütunların tüm ağaçlarda etkili olmasına yol açmaktadır. İşte rassal ormanlar yönteminde yalnızca eğitim veri kümelerindeki satırlar değil aynı zamanda sütunlar da örneklenmektedir. Bu nedenle rassal ormanlar yöntemi paketleme yöntemine göre daha üstün kabul edilmektedir.

Rassal ormanlar yöntemi için Scikit-learn kütüphanesindeki ensemble paketindeki RandomForestClassifier ve RandomForestRegressor isimli sınıflar bulunmaktadır. RandomForestClassifier sınıfının `__init__` metodunun parametrik yapısı şöyledir:

```
class sklearn.ensemble.RandomForestClassifier(n_estimators=100, criterion='gini', max_depth=None, min_samples_split=2, min_samples_leaf=1, min_weight_fraction_leaf=0.0, max_features='auto', max_leaf_nodes=None, min_impurity_decrease=0.0, min_impurity_split=None, bootstrap=True, oob_score=False, n_jobs=None, random_state=None, verbose=0, warm_start=False, class_weight=None, ccp_alpha=0.0, max_samples=None)
```

Yine metodun `n_estimators` parametresi toplam ağaç sayısını belirtir. `criterion` parametresi karar ağaçları için kullanılacak yöntemi belirtmektedir. Bu parametre 'gini', ya da 'entropy' biçiminde girilebilmektedir. Fonksiyonun pek çok parametresi ağaçın üretiminin durdurulması ile ilgilidir. Metodun `max_features` parametresi int, float ya da str türünden değer alabilmektedir. int değer doğrudan rastgele alınacak sütun sayısını belirtir. Float değer yine oran belirtmektedir. Eğer bu parametre yazışal biçimde 'sqrt' olarak girilirse sütun sayısı toplam sütunların karekökü kadar alınmaktadır. Zaten bu parametre için argüman girilmezse default olarak 'auto' alındığına dikkat ediniz. 'auto' tamamen 'sqrt' ile aynı anlama gelmektedir. `max_samples` parametresi yine her ağaç için rastgele alınacak örnek sayısını (satır sayısını) belirtmektedir. Bu değer int ya da float biçimde girilebilir. Bu parametre için değer girilmezse tüm veri kümesi işleme sokulmaktadır.

RandomForestClassifier kullanımına şöyle bir örnek verebiliriz:

```
from sklearn.datasets import load_breast_cancer

bc = load_breast_cancer()
print('Sütun isimleri: {}'.format(bc.feature_names))
print('Sınıf Isimleri: {}'.format(bc.target_names))

dataset_x = bc.data
dataset_y = bc.target

from sklearn.model_selection import train_test_split

training_dataset_x, test_dataset_x, training_dataset_y, test_dataset_y =
train_test_split(dataset_x, dataset_y, test_size=0.3)

from sklearn.ensemble import RandomForestClassifier

dt = RandomForestClassifier(n_estimators=300, max_features=0.6)
dt.fit(training_dataset_x, training_dataset_y)
score = dt.score(test_dataset_x, test_dataset_y)
print(score)
```

Benzer biçimde rassal ormanlarla regresyon uygulaması da yapılabilmektedir. Genel prensip sınıflandırma problemleriyle aynıdır. Bunun için `sklearn.ensemble` modülündeki `RandomForestRegressor` sınıfı kullanılmaktadır. `RandomForestRegressor` sınıfının `__init__` metodunun parametrik yapısı şöyledir:

```
class sklearn.ensemble.RandomForestRegressor(n_estimators=100, criterion='mse', max_depth=None, min_samples_split=2, min_samples_leaf=1, min_weight_fraction_leaf=0.0, max_features='auto', max_leaf_nodes=None, min_impurity_decrease=0.0, min_impurity_split=None, bootstrap=True, oob_score=False, n_jobs=None, random_state=None, verbose=0, warm_start=False, ccp_alpha=0.0, max_samples=None)
```

Aşağıda RandomForestRegressor sınıfı ile Boston örneği verilmiştir:

```
import numpy as np

from sklearn.datasets import load_boston
from sklearn.ensemble import RandomForestRegressor

boston = load_boston()
rfr = RandomForestRegressor(n_estimators=300, max_features=0.6)
rfr.fit(boston.data, boston.target)

predict_x = np.array([[3.2370e-02, 0.0000e+00, 2.1800e+00, 0.0000e+00, 5.8800e-01,
                      6.9980e+00, 5.5800e+01, 6.0622e+00, 3.0000e+00, 2.2200e+02,
                      1.8700e+01, 3.9463e+02, 2.9400e+00]]))

result = rfr.predict(predict_x)
print(result)
```

MAKİNE ÖĞRENMESİNDE BİR GRUP YÖNTEMİN BİRLİKTE KULLANILMASI (ENSEMBLE LEARNING)

Biz bu bölüme kadar pek çok kestirim yöntemini ele alarak inceledik. Bu kestirim yöntemlerini bazı bakımlardan birbirleriyle de karşılaştırdık. Ancak çok defalar belirttiğimiz gibi makine öğrenmesinde bir yöntemin diğerine üstünlüğü hakkında genel geçer şeyler söylemek çoğu kez mümkün olamamaktadır. Çünkü yöntemlerin etkinliği üzerinde çalışılan veri kümelerinin dağılımına ve o veri kümelerinin özel durumuna göre değişebilmektedir. Örneğin X veri kümesi için A yöntemi B yönteminden daha iyi sonuçlar verirken, Y veri kümlesi için B yöntemi A yönteminden daha iyi sonuçlar verebilmektedir. Bu nedenle -bazı tipik durumların dışında- belli bir veri kümlesi için işin başında hangi yöntemin daha iyi sonuç vereceğini belirlemek çoğu kez mümkün olamamaktadır.

Makine öğrenmesinde daha iyi bir kestirim yapabilmek için bir grup yöntemin bir arada kullanılmasına İngilizce "ensemble learning" denilmektedir. (Ensemble sözcüğü İngilizcede "bir grup öğrenen belli bir amaç için koordineli bir biçimde bir araya getirilmesi" anlamına gelmektedir. Bu bağlamın dışında "ensemble" sözcüğü "topluluk" anlamında, "müzik topluluğu" anlamında da kullanılmaktadır. Aslında makine öğrenmesinin bu kadar popüler olmadığı zamanlarda sonuçları iyileştirmek için bir grup istatistiksel yöntem de benzer amaçlarla kullanılıbiliyordu. İstatistik bağlamında bu etkinliğine de "topluluksal yöntemler (ensemble methods)" deniyordu.) Ensemble yöntemlerin bir kısmı farklı yöntemlerin bir arada daha iyi bir kestirim için kullanılmasıyla ilgiliyken bir kısmı ise aynı yöntemin farklı eğitim kümeleri ile birlikte kullanılması ile ilgilidir. Bazı ensemble yöntemler ise belli bir yöntemin bazı parametrelerini (bunlara "İngilizce hyper parameters" denilmektedir) daha iyi ayarlamak için kullanılmaktadır. Biz de kursumuzun bu bölümünde çeşitli başlıklar halinde çeşitli ensemble yöntemler üzerinde duracağız.

Lojistik Regresyon (Sınıflandırma) Problemlerinde Oylama Yöntemleri

Sınıflandırma problemleri için en yaygın kullanılan topluluk yöntemlerinden birisi "oylama (voting)" yöntemleridir. Oylama yöntemlerinde kestirim problemi değişik sınıflandırma yöntemleriyle çözülür. Sonra kestirim bu yöntemlerin her biri ile ayrı ayrı yapılır. Yapılan kestirimler sonucunda en çok bulunan değer nihai kestirim değeri olarak alınır. Örneğin bir kestirim probleminde hedefin A ve B biçiminde iki sınıfın birinin belirlenmesi olduğunu düşünelim. Biz de bu kestirim problemini LogisticRegression, SVC ve DecisionTreeClassifier sınıflarını kullanarak değişik yöntemlerle çözümüş olalım. Sonra kestirim yapmak istediğimizde kestirmi bu üç yöntemle de yapalım. Örneğin kestirim işleminde ilk yöntem A sınıfını, ikinci yöntem B sınıfını ve üçüncü yöntem de A sınıfını kestirmiştir olsun. Bu durumda A sınıfı daha fazla yöntem tarafından kestirildiği için biz bu kestirimin nihai sonucunun A olduğuna karar verebiliriz.

Şimdi oylama yöntemine bir örnek verelim. Örneğimizde "cryotherapy.csv" veri kümесini kullanacağız. Kriyoterapi özellikle dermatolojide ve jinekolojide uygulanan, cerrahiye gerek kalmadan derideki lezyonları tedavi etmek için kullanılan soğuk ortam tedavisine verilen bir ismidir. Bu tedavi yönteminde hasta -190 derece gibi çok düşük bir sıcaklığa maruz bırakılarak ek ajanların takviyesiyle tedavi uygulanmaktadır. Kriyoterapi veri kümесini aşağıdaki adresten .xlsx Excel formatı biçiminde indirebilirsiniz:

<https://archive.ics.uci.edu/ml/datasets/Cryotherapy+Dataset+>

Excel veri dosyasını "Save As (Farklı Kaydet)" işlemi ile CSV olarak biçimine dönüştürebilirsiniz. Veri kümelerinin baş kısmının CSV görünümü aşağıdaki gibidir:

```

sex,age,Time,Number_of_Warts,Type,Area,Result_of_Treatment
1,35,12,5,1,100,0
1,29,7,5,1,96,1
1,50,8,1,3,132,0
1,32,11.75,7,3,750,0
1,67,9.25,1,1,42,0
1,41,8,2,2,20,1
1,36,11,2,1,8,0
1,59,3.5,3,3,20,0
1,20,4.5,12,1,6,1
2,34,11.25,3,3,150,0
2,21,10.75,5,1,35,0
2,15,6,2,1,30,1
2,15,2,3,1,4,1
2,15,3.75,2,3,70,1
2,17,11,2,1,10,0
2,17,5.25,3,1,63,1
2,23,11.75,12,3,72,0
2,27,8.75,2,1,6,0
2,15,4.25,1,1,6,1
2,18,5.75,1,1,80,1
1,22,5.5,2,1,70,1
2,16,8.5,1,2,60,1
1,28,4.75,3,1,100,1
2,40,9.75,1,2,80,0
1,30,2.5,2,1,115,1
2,34,12,3,3,95,0
1,20,0.5,2,1,75,1
2,35,12,5,3,100,0

```

Veri tablosunda çeşitli özelliklere sahip olan olguların kriyoterapi elde ettikleri sonuçlar bulunmaktadır. Son sütun verileri eğer 0 ise tedavi başarısız 1 ise tedavi başarılı demektir.

Şimdi bu ikili sınıflandırma problemini oylama yöntemiyle çözelim. Problemi lojistik regresyon, destek vektör makineleri ('linear' kernel ile) ve karar ağaçları kullanarak oylama yöntemiyle çözelim. Önce veri kümesini Pandas kullanarak okuyarak dataset_x ve dataset_y değerlerin ayırtılalım:

```

import pandas as pd

df = pd.read_csv('cryotherapy.csv')
dataset_y = df.iloc[:, -1].to_numpy()
dataset_x = df.iloc[:, :-1].to_numpy()

```

Daha sonra train_test_split fonksiyonu ile verileri eğitim ve test biçiminde iki gruba ayıralım:

```

from sklearn.model_selection import train_test_split

training_dataset_x, test_dataset_x, training_dataset_y, test_dataset_y =
train_test_split(dataset_x, dataset_y, test_size=0.3)

```

Problemi çözmek için kullanılan nesnelere genel olarak "tahminleyici (estimator)" denilmektedir. Şimdi tahminleyicilerimizi bir listede toplayıp hepsine çokbiçimli (polymorphic) teknikle fit ve predict işlemlerini uygulayalım:

```

estimators = [LogisticRegression(max_iter=1000), SVC(kernel='linear'),
DecisionTreeClassifier()]

```

```

for estimator in estimators:
    estimator.fit(training_dataset_x, training_dataset_y)

predict_list = []
for estimator in estimators:
    result = estimator.predict(test_dataset_x)
    predict_list.append(result)

```

Burada predict_list içerisinde üç farklı yöntemden elde edilen kestirim sonuçları ndarray listesinde toplanmıştır. predict_list listesinin genel görünümü şöyledir:

```

In [3]: predict_list
Out[3]:
[array([1, 0, 1, 0, 0, 1, 0, 0, 0, 0, 0, 1, 0, 0, 1, 0, 0, 1, 1, 1, 1,
       0, 1, 1, 1, 0], dtype=int64),
 array([1, 1, 1, 1, 1, 0, 0, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,
       1, 1, 1, 1, 1], dtype=int64),
 array([1, 0, 1, 1, 0, 1, 0, 1, 0, 1, 0, 1, 1, 1, 1, 0, 1, 1, 1, 1, 1,
       0, 1, 0, 1, 0], dtype=int64)]

```

Artık nihai sonuç için oylama yapabiliriz. Kestirilecek her değer için hangi kestirim sınıfı fazlaysa biz o sınıfı kestirimin nihai sonucu olarak belirleyeceğiz. Bu işlemin de aslında istatistiksel olarak mod alma işlemi anlamına geldiğine dikkat ediniz. O halde biz bu değerleri bir NumPy matrisinde toplayıp tek hamlede eksen belirterek mod işlemi uygulayabiliriz. mod işlemi için NumPy'da hazır bir fonksiyon bulunmaktadır. Bunun için SciPy içerisindeki mode fonksiyonunu kullanacağız. Bu fonksiyonun bize mod değerini ve bunların yinelenme sayılarını bir demet olarak verdiğiğini anımsayınız. Biz burada yalnızca mod değerleri ile ilgileniyoruz.

```

import numpy as np

predict_array = np.vstack(predict_list)

from scipy.stats import mode

predict_result, _ = mode(predict_array, axis=0)

```

Şimdi modelimizin başarısını ölçelim:

```

from sklearn.metrics import accuracy_score

score = accuracy_score(predict_result.flatten(), test_dataset_y)
print(f'Ensemble Voting Accuracy Score: {score}')

```

Şu sonuç elde edilmiştir:

```
Ensemble Voting Accuracy Score: 0.8888888888888888
```

Tabii burada programın her çalıştırılmasında farklı bir sonuç elde edilebileceğini de göz önünde bulundurmamalısınız. Şimdi de yöntemleri tek tek uygulayarak elde edilen sonuçlara bakalım:

```

estimator_names = ['LogisticRegression', 'SVC', 'DecisionTreeClassifier']

for name, estimator in zip(estimator_names, estimators):
    score = accuracy_score(predict_data, test_dataset_y)
    print(f'{name} Accuracy Score: {score}')

```

Şu sonuçlar elde edilmiştir:

```
LogisticRegression Accuracy Score: 0.8518518518518519
SVC Accuracy Score: 0.8518518518518519
```

```
DecisionTreeClassifier Accuracy Score: 0.7037037037037037
```

Yukarıdaki kodların tamamını aşağıda bir bütün olarak veriyoruz:

```
import pandas as pd

df = pd.read_csv('cryotherapy.csv')
dataset_y = df.iloc[:, -1].to_numpy()
dataset_x = df.iloc[:, :-1].to_numpy()

from sklearn.model_selection import train_test_split

training_dataset_x, test_dataset_x, training_dataset_y, test_dataset_y =
train_test_split(dataset_x, dataset_y, test_size=0.3)

from sklearn.linear_model import LogisticRegression
from sklearn.svm import SVC
from sklearn.tree import DecisionTreeClassifier

estimators = [LogisticRegression(max_iter=1000), SVC(kernel='linear'),
DecisionTreeClassifier()]

for estimator in estimators:
    estimator.fit(training_dataset_x, training_dataset_y)

predict_list = []
for estimator in estimators:
    result = estimator.predict(test_dataset_x)
    predict_list.append(result)

import numpy as np

predict_array = np.vstack(predict_list)

from scipy.stats import mode

predict_result, _ = mode(predict_array, axis=0)

from sklearn.metrics import accuracy_score

score = accuracy_score(predict_result.flatten(), test_dataset_y)
print(f'Ensemble Voting Accuracy Score: {score}')

estimator_names = ['LogisticRegression', 'SVC', 'DecisionTreeClassifier']

for name, estimator in zip(estimator_names, estimators):
    score = accuracy_score(predict_data, test_dataset_y)
    print(f'{name} Accuracy Score: {score}'')
```

Sınıflandırma problemlerinde oylama yöntemi için sklearn.ensemble modülünde VotingClassifier isimli sınıf bulundurulmuştur. Sınıfın `__init__` metodunun parametrik yapısı şöyledir:

```
class sklearn.ensemble.VotingClassifier(estimators, *, voting='hard', weights=None,
n_jobs=None, flatten_transform=True, verbose=False)
```

Metodun `estimators` parametresi problemi çözmek için kullanılacak nesneleri ve onlara verilen isimleri almaktadır. Bu nesneler ve isimleri önce isim sonra nesne biçiminde ikili demet listeleri olarak girilir. Buradaki isimleri istediğimiz gibi belirleyebiliriz. Metodun `voting` parametresi 'hard' ya da 'soft' olarak girilebilmektedir. Bu parametre 'hard' olarak girilirse (default durum) oylama yukarıdaki örnekte olduğu gibi hangi sınıf fazla ise onun seçilmesi biçiminde gerçekleştirilir. Bu parametre 'soft' olarak girilirse oylama olasılık hesabına göre yapılmaktadır. Ancak oylamanın olasılık tabanlı yapılması için birinci parametreyle girilen tahminleyici nesnelerine ilişkin sınıfların `predict_proba` isimli

metotlarının bulunuyor olması gereklidir. Metodun weights parametresi 'hard' oylamada sıklık değerlerinin çarpılacağı ağırlıkları 'soft' oylamada ise olasılık değerlerinin çarpılacağı ağırlıkları belirtmektedir. Metodun diğer parametreleri için dokümanlara başvurabilirsiniz. Şimdi yukarıdaki örneği VotingClassifier sınıfını kullanarak gerçekleştirelim:

```
import pandas as pd

df = pd.read_csv('cryotherapy.csv')
dataset_y = df.iloc[:, -1].to_numpy()
dataset_x = df.iloc[:, :-1].to_numpy()

from sklearn.model_selection import train_test_split

training_dataset_x, test_dataset_x, training_dataset_y, test_dataset_y =
train_test_split(dataset_x, dataset_y, test_size=0.3)

from sklearn.linear_model import LogisticRegression
from sklearn.svm import SVC
from sklearn.tree import DecisionTreeClassifier

from sklearn.ensemble import VotingClassifier

estimators = [('logisticRegression', LogisticRegression(max_iter=1000)), ('SVC',
SVC(kernel='linear')), ('DecisionTreeClassifier', DecisionTreeClassifier())]

vc = VotingClassifier(estimators, voting='hard')
vc.fit(training_dataset_x, training_dataset_y)

predict_result = vc.predict(test_dataset_x)
score = vc.score(test_dataset_x, test_dataset_y)

print(f'VotingClassifier Accuracy score: {score}')
```

Şu sonuç elde edilmiştir:

VotingClassifier Accuracy score: 0.8518518518518519

Oylamanın 'soft' biçimde yapılabilmesi için tahminleyici sınıflarda predict_proba metodunu bulunuyor olması gerekmektedir. SVC sınıfında bu metodun işlevini yerine getirebilmesi için probability parametresinin True geçilmesi gereklidir. Örneğin:

```
from sklearn.ensemble import VotingClassifier

estimators = [('logisticRegression', LogisticRegression(max_iter=1000)), ('SVC',
SVC(kernel='linear', probability=True)), ('DecisionTreeClassifier', DecisionTreeClassifier())]

vc = VotingClassifier(estimators, voting='soft')
vc.fit(training_dataset_x, training_dataset_y)

predict_result = vc.predict(test_dataset_x)
score = vc.score(test_dataset_x, test_dataset_y)

print(f'VotingClassifier Accuracy score: {score}')
```

Buradan şu sonuç elde edilmiştir:

VotingClassifier Accuracy score: 0.8148148148148148

Lojistik Olmayan Regresyon Problemlerinde Oylama Yöntemi

Lojistik olmayan regresyon problemlerinde de sınıflandırma problemlerinde olduğu gibi oylama yapılmaktadır. Ancak oylama sonucunda bir ortalama değer elde edilir. Örneğin lojistik olmayan regresyon problemini biz LinearRegression, SVCRegressor ve DecisionTreeRegressor biçiminde üç yöntemle çözüp kestirimde bulunmak isteyelim. Kestirim sonucunda bu üç tahminleyiciden sırasıyla 82, 78 ve 89 değerleri elde edilmiş olsun. İşte biz bu değerlerin ortalamasını alarak nihai kestirim değerinin $(82 + 78 + 89) / 3 = 83$ olduğunu söyleyebiliriz.

Şimdi lojistik olmayan regresyon problemi için oylama yöntemi için somut bir örnek verelim. Örneğimizde "winequality-white.csv" veri kümesini kullanacağız. Bu veri kümesi beyaz şarapların birtakım özelliğinden hareketle onların kalitelerinin tahmin edilmesi için oluşturulmuştur. Veri kümesini aşağıdaki bağlantından indirebilirsiniz:

<https://www.kaggle.com/piyushagni5/white-wine-quality?select=winequality-white.csv>

Veri kümesinin görünümü aşağıdaki gibidir:

```
"fixed acidity";"volatile acidity";"citric acid";"residual sugar";"chlorides";"free sulfur dioxide";"total sulfur dioxide";
"density";"pH";"sulphates";"alcohol";"quality"
7;0.27;0.36;20.7;0.045;45;170;1.001;3;0.45;8.8;6
6.3;0.3;0.34;1.6;0.049;14;132;0.994;3.3;0.49;9.5;6
8.1;0.28;0.4;6.9;0.05;30;97;0.9951;3.26;0.44;10.1;6
7.2;0.23;0.32;8.5;0.058;47;186;0.9956;3.19;0.4;9.9;6
7.2;0.23;0.32;8.5;0.058;47;186;0.9956;3.19;0.4;9.9;6
8.1;0.28;0.4;6.9;0.05;30;97;0.9951;3.26;0.44;10.1;6
6.2;0.32;0.16;7;0.045;30;136;0.9949;3.18;0.47;9.6;6
7;0.27;0.36;20.7;0.045;45;170;1.001;3;0.45;8.8;6
6.3;0.3;0.34;1.6;0.049;14;132;0.994;3.3;0.49;9.5;6
8.1;0.22;0.43;1.5;0.044;28;129;0.9938;3.22;0.45;11;6
8.1;0.27;0.41;1.45;0.033;11;63;0.9908;2.99;0.56;12;5
8.6;0.23;0.4;4.2;0.035;17;109;0.9947;3.14;0.53;9.7;5
7.9;0.18;0.37;1.2;0.04;16;75;0.992;3.18;0.63;10.8;5
6.6;0.16;0.4;1.5;0.044;48;143;0.9912;3.54;0.52;12.4;7
8.3;0.42;0.62;19.25;0.04;41;172;1.0002;2.98;0.67;9.7;5
```

Veri kümemizi pandas.read_csv ile okuyup kullanıma hazır hale getirelim:

```
import pandas as pd

df = pd.read_csv('winequality-white.csv')

dataset_y = df.iloc[:, -1].to_numpy()
dataset_x = df.iloc[:, :-1].to_numpy()
```

Veri kümесini eğitim ve test biçiminde ikiye ayıralım:

```
from sklearn.model_selection import train_test_split

training_dataset_x, test_dataset_x, training_dataset_y, test_dataset_y =
train_test_split(dataset_x, dataset_y, test_size=0.2)
```

Problemi çözmek için Lasso, SVR ve DecisionTreeRegressor nesnelerini kullanarak modellerimizi eğitelim:

```
from sklearn.linear_model import Lasso
from sklearn.svm import SVR
from sklearn.tree import DecisionTreeRegressor

estimators = [Lasso(), SVR(), DecisionTreeRegressor()]

for estimator in estimators:
    estimator.fit(training_dataset_x, training_dataset_y)
```

Şimdi de kestirim yapıp ortalama mutlak hatayı hesaplayalım:

```

predict_list = []
for estimator in estimators:
    predict_result = estimator.predict(test_dataset_x)
    predict_list.append(predict_result)

import numpy as np

predict_array = np.array(predict_list)
predict_result = np.mean(predict_array, axis=0)

from sklearn.metrics import mean_absolute_error

mae = mean_absolute_error(predict_result, test_dataset_y)
print(f'Voting Mean Absolute error: {mae}')

```

Şöyledir bir sonuç elde edilmiştir:

Voting Mean Absolute error: 0.5705915169725315

Şimdi de bu regresyon nesnelerinin başarılarını tek başlarına hesaplayalım:

```

estimator_names = ['Lasso', 'SVR', 'DecisionTreeRegressor']

for name, estimator in zip(estimator_names, estimators):
    predict_result = estimator.predict(test_dataset_x)
    mae = mean_absolute_error(predict_result, test_dataset_y)
    print(f'{name} Mean Absolute error: {mae}')

```

Şu sonuçlar elde edilmiştir:

```

Lasso Mean Absolute error: 0.6734271477541998
SVR Mean Absolute error: 0.6409087535366707
DecisionTreeRegressor Mean Absolute error: 0.4826530612244898

```

Scikit-learn içerisinde sklearn.ensemble paketinde lojistik olmayan regresyon modelleri için oylama yöntemini uygulayan VotingRegressor isimli bir sınıf da bulunmaktadır. Sınıfın `__init__` metodunun parametrik yapısı şöyledir:

```
class sklearn.ensemble.VotingRegressor(estimators, *, weights=None, n_jobs=None, verbose=False)
```

Burada yine estimators parametresi tahminleyicilerin isimlerini ve tahminleyici nesnelerini bir demet listesi biçiminde alır. `n_jobs` parametresi paralel bir biçimde kaç çekirdeğin kullanılacağını belirtirmektedir. Diğer parametreler için dokümanlara başvurabilirsiniz. Sınıfın kullanımı tamamen VotingClassifier sınıfında olduğu gibidir.

Şimdi aynı problemi bu hazır sınıfı kullanarak çözelim:

```

from sklearn.ensemble import VotingRegressor

vr = VotingRegressor([('Lasso', Lasso()), ('SVR', SVR()), ('DecisionTreeRegressor',
DecisionTreeRegressor())])

vr.fit(training_dataset_x, training_dataset_y)
predict_result = vr.predict(test_dataset_x)

from sklearn.metrics import mean_absolute_error

mae = mean_absolute_error(predict_result, test_dataset_y)

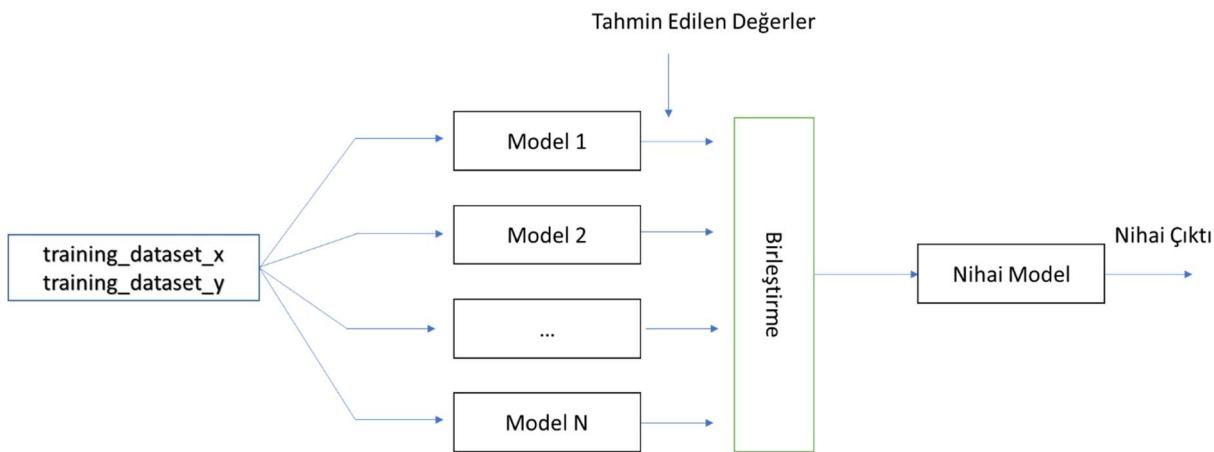
print(f'VotingRegressor Mean Absolute error: {mae}')

```

Şu sonuç elde edilmiştir:

Stacking Yöntemleri

Stacking yöntemlerinde problem bir grup farklı yöntemle çözülür. Çözüm sonucunda elde edilen sonuçlar birleştirilerek bu birleştirilmiş veriler başka nihai bir yönteme girdi olarak verilir. Bu nihai yöntemin çıktısı nihai çıktı olarak belirlenir.



Örneğin lojistik olmayan bir regresyon problemini stacking ensemble yöntemle çözmek isteyelim. Bunun için önce problemi ayrı ayrı birkaç yöntemle çözeriz. Örneğin bunun için Lasso regresyonu, destek vektör makinelерini ve karar ağaçlarını kullanmış olalım. Daha sonra buradan elde edilen üç farklı sonucu birleştirerek bunları başka bir yönteme girdi olarak veririz. Buradaki nihai model de örneğin doğrusal regresyon olsun. İşte bizim elde edeceğimiz nihai sonuç bu nihai lojistik regresyonun yönteminin verdiği sonuç olacaktır.

Stacking yöntemi için tipik olarak veri kümemizi üç parçaya ayırmamız gereklidir. Biz bu üç parçayı aşağıdaki biçimde isimlendireceğiz:

- training_dataset_x, training_dataset_y
- validation_dataset_x, validation_dataset_y
- test_dataset_x, test_dataset_y

training_dataset_x ve training_dataset_y farklı modellerin eğitilmesinde kullanılacak veri kümesidir. Bu farklı modeller bu veri kümesi ile eğitildikten sonra validation_dataset_x ile kestirim işlemine sokulduktan sonra elde edilen değerler birleştirilirler. Bu birleştirilmiş değerlere final_dataset_x diyelidir. İşte nihai model bu final_dataset_x ve validation_dataset_y verileri kullanılarak eğitilmektedir. test_dataset_x ve test_dataset_y tüm modelin test edilmesi için kullanılan veri kümesidir.

Şimdi stacking yöntemi ile bir lojistik regresyon problemini adım adım çözelim. Örneğimizde meme kanseri için hazırlanmış veri kümесini kullanacağımız. Anımsayacağınız gibi bu veri kümescini daha önce de kullanmıştık. Önce veri kümescini yükleyip kullanıma hazır hale getirelim:

```

from sklearn.datasets import load_breast_cancer

bc = load_breast_cancer()

dataset_x = bc.data
dataset_y = bc.target
  
```

Şimdi verilerimizi üç kümeye ayıralım. Bunun için iki kez train_test_split fonksiyonunu çağıracağız:

```

from sklearn.model_selection import train_test_split

temp_x, test_dataset_x, temp_y, test_dataset_y = train_test_split(dataset_x, dataset_y,
  
```

```
test_size=0.1)

training_dataset_x, validation_dataset_x, training_dataset_y, validation_dataset_y =
train_test_split(temp_x, temp_y, test_size=0.1)
```

Şimdi problemi destek vektör makineleri, karar ağaçları ve istatistiksel lojistik regresyon modelleri ile çözelim. Bunun için SVC, DecisionTreeClassifier ve LogisticRegression nesneleri yaratıp modelin eğitimini training_dataset_x ve training_dataset_y veri kümesi yoluyla yapacağız:

```
import numpy as np
from sklearn.svm import SVC
from sklearn.tree import DecisionTreeClassifier
from sklearn.linear_model import LogisticRegression

estimators = [SVC(), DecisionTreeClassifier(), LogisticRegression(max_iter=10000)]

for estimator in estimators:
    estimator.fit(training_dataset_x, training_dataset_y)
```

Şimdi eğitilmiş bu üç model için validation_dataset_x verilerini kullanarak kestirimde bulunalım ve kestirilen değerleri bir listede toplayalım:

```
validation_results = []
for estimator in estimators:
    validation_result = estimator.predict(validation_dataset_x)
    validation_results.append(validation_result)

final_dataset_x = np.column_stack(validation_results)
```

Artık nihai modelimizi oluşturup onu eğitebiliriz. Nihai modelimizi LogisticRegression nesnesi ile oluşturalım. Bu nihai modelin eğitimini önceki modellerin kestiriminden elde edilen verilerle yapacağız:

```
meta_estimator = LogisticRegression(max_iter=10000)
meta_estimator.fit(final_dataset_x, validation_dataset_y)
```

Burada önceki modellerin kestiriminden elde edilen final_dataset_x ve validation_dataset_y ile eğitim yapılmıştır. Artık nihai modelimizi test edebiliriz. Bu test işlemini yaparken tüm adımları baştan sona yineleyeceğiz:

```
predict_results = []
for estimator in estimators:
    predict_result = estimator.predict(test_dataset_x)
    predict_results.append(predict_result)

predict_results_dataset_x = np.column_stack(predict_results)

final_predict_result = meta_estimator.predict(predict_results_dataset_x)
```

Şimdi stacking yöntemi için kestirimin sonucunu elde edebiliriz:

```
from sklearn.metrics import accuracy_score

score = accuracy_score(final_predict_result, test_dataset_y)
print(f'Stacking Accuracy Score: {score}')
```

Şöyle bir sonuç elde edilmiştir:

```
Stacking Accuracy Score: 0.9473684210526315
```

Şimdi de bu yöntemleri ayrı ayrı kullanarak sonuçlarına bakıp bir karşılaştırma yapalım:

```
SVC Accuracy Score: 0.8771929824561403
DecisionTreeClassifier Accuracy Score: 0.8947368421052632
LogisticRegression Accuracy Score: 0.9298245614035088
```

Gördüğünüz gibi stacking işlemi burada daha iyi bir sonucun bulunmasına yol açmıştır. Burada programı her çalıştırduğımızda farklı değerlerin elde edilebileceğini bir kez daha vurgulamak istiyoruz.

Yukarıdaki programı bir bütün olarak aşağıda yeniden veriyoruz:

```
from sklearn.datasets import load_breast_cancer

bc = load_breast_cancer()

dataset_x = bc.data
dataset_y = bc.target

from sklearn.model_selection import train_test_split

temp_x, test_dataset_x, temp_y, test_dataset_y = train_test_split(dataset_x, dataset_y,
test_size=0.1)

training_dataset_x, validation_dataset_x, training_dataset_y, validation_dataset_y =
train_test_split(temp_x, temp_y,

test_size=0.1)

import numpy as np
from sklearn.svm import SVC
from sklearn.tree import DecisionTreeClassifier
from sklearn.linear_model import LogisticRegression

estimators = [SVC(), DecisionTreeClassifier(), LogisticRegression(max_iter=10000)]

for estimator in estimators:
    estimator.fit(training_dataset_x, training_dataset_y)

validation_results = []
for estimator in estimators:
    validation_result = estimator.predict(validation_dataset_x)
    validation_results.append(validation_result)

final_dataset_x = np.column_stack(validation_results)

meta_estimator = LogisticRegression(max_iter=10000)
meta_estimator.fit(final_dataset_x, validation_dataset_y)

predict_results = []
for estimator in estimators:
    predict_result = estimator.predict(test_dataset_x)
    predict_results.append(predict_result)

predict_results_dataset_x = np.column_stack(predict_results)

final_predict_result = meta_estimator.predict(predict_results_dataset_x)

from sklearn.metrics import accuracy_score

score = accuracy_score(final_predict_result, test_dataset_y)
print(f'Stacking Accuracy Score: {score}')

estimator_names = ['SVC', 'DecisionTreeClassifier', 'LogisticRegression']
for name, estimator in zip(estimator_names, estimators):
    predict_result = estimator.predict(test_dataset_x)
```

```

score = accuracy_score(predict_result, test_dataset_y)
print(f'{name} Accuracy Score: {score}')

```

Aslında sklearn.ensemble paketinde yukarıdaki stacking işlemini yapan StackingClassifier isimli bir sınıf zaten hazır bir biçimde bulunmaktadır. Sınıfın `__init__` metodunun parametrik yapısı şöyledir:

```

class sklearn.ensemble.StackingClassifier(estimators, final_estimator=None, *, cv=None,
stack_method='auto', n_jobs=None, passthrough=False, verbose=0)

```

Metodun birinci parametresi tahminleyici nesnelerinin ve isimlerinin bulunduğu listeyi alır. Yine bu listenin ilk elemanı tahminleyici isminden ikinci elemanı tahminleyici nesnesinden oluşan bir demet listesi biçiminde girilmesi gerekmektedir. Metodun ikinci parametresi nihai tahminleyici nesnesini belirtmektedir. Metodun `stacked_method` parametresi

İyileştirme (Boosting) Yöntemleri

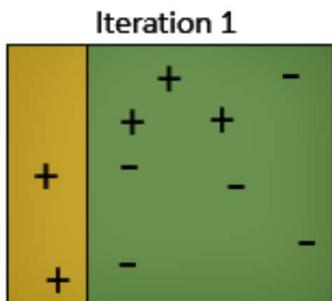
Bir grup topluluk öğrenmesi yöntemine "iyileştirme (boosting)" yöntemleri denilmektedir. Bu yöntemlerde tahminleyici modellerin başarısız olduğu veriler belirlenerek modellerin o veriler dikkate alınarak yeniden eğitilmesi sağlanmaktadır. Bu süreci şöyle bir benzetmeyle açıklayabiliriz: Bir sınavda kişiye çeşitli sorular soruluyor olsun. Kişi de bazı soruları bildiği için yapıp bazlarını bilmediği için yapamamış olsun. İşte kişi yapamadığı sorulara yoğunlaşıp o sorulardaki bilgisini güçlendirmeye çalışırsa sonraki sınavdan daha yüksek puan elde edebilir. Bu haliyle iyileştirme yöntemleri aslında yanılığı azaltıp varyansı düşürmeyi hedeflemektedir.

İyileştirme yöntemleri bir grup yöntemden oluşmaktadır. Biz bu bölümde en çok kullanılan birkaç iyileştirme yöntemini örneklerle açıklayacağız.

Adaboost Yöntemi

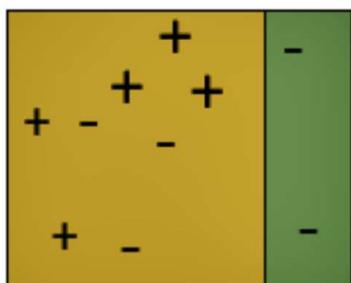
Adaboost (Adaptive Boosting) yöntemi en çok kullanılan iyileştirme yöntemlerinden biridir. Bu yöntemde belli bir tahminleyici model ile problem çözülür. Sonra modelin başarısız olduğu veriler için modelin ağırlık değerleri değiştirilerek problem aynı modelin başarısız olduğu verilerle yeniden çözülür ve işlemler böyle devam ettirilir. Böylece başlangıçta düşük performans gösteren model başarısız olan verilerdeki ağırlık değerleri değiştirilerek iyileştirilir. Bu işlemlerin sonunda belli sayıda farklı ağırlık değerlerine sahip model elde edilecektir. En sonunda bu modeller oylama işlemine sokularak nihai kestirim değerleri elde edilmektedir.

Adaboost yönteminin çalışma mekanizmasını söyle bir örnekle açıklayabiliriz. Biz + ve - ile temsil edilen değerleri sınıflandıracak olalım. Sarı renk + yeşil renk - değerlerin sınıflarını belirtiyor olsun. Biz bu modele `max_depth = 1` parametresiyle karar ağacı modelini uyguladığımızda söyle bir sınıflandırma elde etmiş olalım:



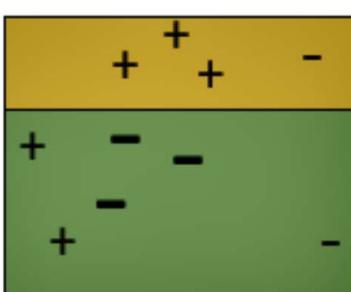
Burada görüldüğü gibi sınıflandırma tam yapılamamıştır. Sarı renklerin hepsi + olmasına karşın yeşil renklerin hepsi - değildir. Yani - değerlerin sınıflandırılmasında başarısızlık söz konusudur. Şimdi biz bu yeşil alanındaki ağırlıkları değiştirerek yani bu yeşil alanındaki değerleri ön plana çıkararak bir yineleme daha yapalım. Aşağıdaki gibi bir sınıflandırma elde edebiliriz:

Iteration 2



Burada da bu kez yeşil taraftaki eksiler daha iyi sınıflandırılırken sarı taraftaki + değerlerin sınıflandırılmasında başarısızlık oluşmuştur. Şimdi biz bu kez sarı kısmındaki ağırlıkları artırarak sarı kısmın sınıflandırmadaki önemini artırarak problemi yeniden çözelim:

Iteration 3



Buradan max_depth = 1 olan üç farklı karar ağacı elde etmiş olduk. Şimdi nihai tahminde oylama yöntemini kullanarak daha isabetli bir tahminde bulunabiliriz. Örneğin sağ üst köşedeki – değerine bakınız. Burada oylama yapıldığında 2 tane yeşil bir tane sarı elde edilecektir. O halde bu – değer yeşil taraftadır.

Akıntı Notu: Yukarıdaki şekiller "Ensemble Machine Learning Cookbook (Sarkar & Natarajan)" kitabından alınmıştır.

Adaboost yöntemi yalnızca lojistik regresyon problemlerinde değil aynı zamanda lojistik olmayan regresyon problemlerinde de kullanılabilmektedir. Adaboost yöntemi değişik tahminleyici modeller için kullanılabilir veya da bu yöntem en çok karar ağaçları ile birlikte kullanılmaktadır.

Adaboost yöntemi ile lojistik regresyon problemlerinin çözümü için Scikit-learn kütüphanesinde sklearn.ensemble modülü içerisindeki AdaBoostClassifier sınıfı kullanılmaktadır. Sınıfın __init__ metodunun parametrik yapısı şöyledir:

MAKİNE ÖĞRENMESİ SÜRECİNİ OTOMATİK HALE GETİREN KÜTÜPHANELER ve ARAÇLAR

Makine öğrenmesinde hangi durumlarda hangi modelin uygulanması gerektiği kesin ve açık olarak belli değildir. Çünkü uygulanması gereken modeller verilerin miktarına, özelliklerine ve dağılımına göre değişebilmektedir. Bu nedenle belli bir veri kümesi en iyi sonuç verecek modelin hiç deneme yapılmadan belirlenmesi çoğu kez mümkün olamamaktadır. Uygulamacılar için model belirlemenin dışında diğer önemli bir sorun da yöntemdeki "üst düzey parametrelerin (hyper parameters)" uygun biçimde ayarlanmasıdır. Çünkü pek çok modelin aynı zamanda üst düzey parametreler yoluyla uygun bir biçimde ayarlanması da gerekmektedir. İşte eldeki veri kümesi için çeşitli modellerin denenmesi yoluyla iyi bir modelin bulunmasını ve o model için üst düzey parametrelerin ayarlanması sağlayan çeşitli yazılımsal araçlar geliştirilmiştir. Bunlara "otomatik makine öğrenmesi araçları (automated machine learning tools)" denilmektedir.

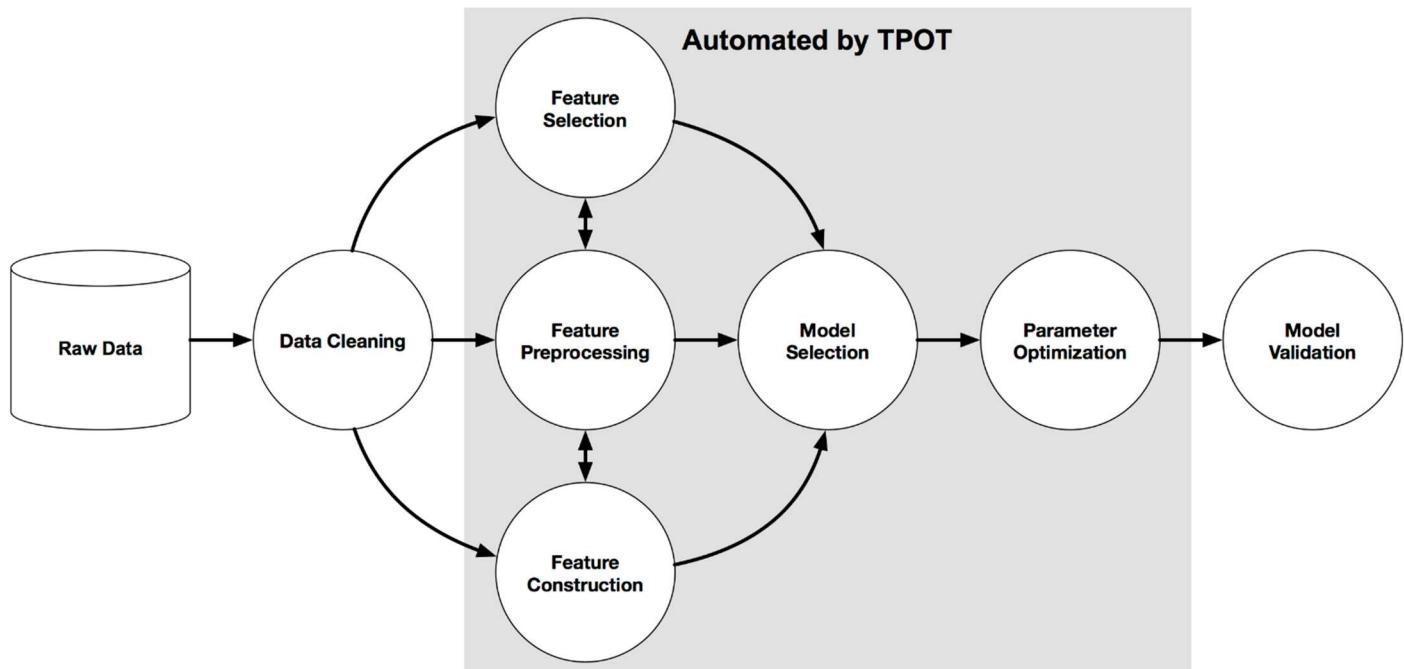
Çeşitli kişiler ve kurumlar tarafından süreci otomatik hale getirmeyi hedefleyen pek çok kütüphane ve araç geliştirilmiş durumdadır ve bu araçların sayıları da gün geçtikçe artmaktadır. Bu araçların bazıları yalnızca yapay sinir ağlarına ilişkin modelleri bazıları yapay sinir ağlarının dışındaki modelleri bazıları ise her iki grup modelleri de kapsamaktadır. Pek çok bulut tabanlı makine öğrenmesi platformlarında da onların içine entegre edilmiş otomatik makine öğrenmesi araçları bulunmaktadır. Biz de kursumuzun bu bölümünde en yaygın kullanılan kütüphaneleri ve araçları tanıtacağız. Pekşitmeli öğrenme yöntemleri için kullanılan kütüphaneler ve araçlar pekiştirmeli öğrenmenin ele alındığı bölümde açıklanmaktadır.

TPOT KÜTÜPHANESİNİN KULLANIMI

TPOT (The Tree-Based Pipeline Optimization Tool) ilk otomatik makine öğrenmesi araçlarından biridir. TPOT Randal Olson ve Jason H. Moore tarafından geliştirilmiştir. TPOT kütüphanesi Scikit-Learn kütüphanesi kullanılarak yazılmıştır. TPOT kendi içerisinde binlerce deneme yaparak en iyi yöntemi ve üst düzey parametreleri belirlemeye çalışmaktadır. TPOT kütüphanesinin resmi dokümantasyonuna aşağıdaki bağlantıdan erişebilirsiniz:

<http://epistasislab.github.io/tpot/>

TPOT kütüphanesinin çalışma biçimini kütüphaneyi geliştirenler tarafından aşağıdaki şekilde özetlenmiştir:



Alıntı Notu: Görsel <http://epistasislab.github.io/tpot/> adresinden elde edilmiştir.

Bu şekilden de görüldüğü gibi TPOT verilerin temizlenmesi işlemini yapmamaktadır ancak özellik seçimi, özellik indirmeleri, özellik ölçeklendirmesi gibi birtakım önişlemleri kendisi yapmaktadır. Bu işlemlerden sonra belirlenmektedir. Model belirlendikten sonra da modelin üst parametreleri ayarlamaktadır. TPOT kendi içerisinde pek çok ensemble yöntemleri de kullanmaktadır.

TPOT genel olarak istatistiksel yöntemleri kullanan bir kütüphanedir. Ancak son yıllarda TPOT kütüphanesi yapay sinir ağlarını da kullanacak biçimde genişletilmeye başlanmıştır. TPOT'un yapay sinir ağı modeline ilişkin paketine TPOT NN denilmektedir. TPOT NN paketi PyTorch kütüphanesi kullanılarak yazılmıştır.

TPOT yüksek seviyeli bir kütüphane olduğu için kullanımı oldukça kolaydır. Kütüphanede sınıflandırma problemleri (yani lojistik regresyon problemleri) için TPOTClassifier, lojistik olmayan regresyon problemleri için TPOTRegressor sınıfları bulundurulmuştur. Biz burada önce TPOTClassifier sonra da TPOTRegressor sınıflarını ele alacağız.

TPOT ile Sınıflandırma (Lojistik Regresyon) Problemlerinin Çözümü

TPOT ile sınıflandırma işlemi tipik olarak şu adımlarla gerçekleştirilmektedir:

1) Önce TPOTClassifier sınıfı türünden bir nesne yaratılır. TPOTClassifier sınıfının `__init__` metodunun parametrik yapısı şöyledir:

```
class tpot.TPOTClassifier(  
    generations=100,
```

```
population_size=100,  
offspring_size=None,  
mutation_rate=0.  
crossover_rate=0.1,  
scoring='accuracy',  
cv=5,  
subsample=1.0,  
n_jobs=1,  
max_time_mins=None,  
max_eval_time_mins=5,  
random_state=None,  
config_dict=None,  
template=None,  
warm_start=False,  
memory=None,  
use_dask=False,  
periodic_checkpoint_folder=None,  
early_stop=None,  
verbosity=0,  
disable_update_check=False,  
log_file=None)
```

Metodun bütün parametrelerinin birtakım default değerler aldığılığını görüyorsunuz. Metodun generation parametresi optimizasyon işleminde kullanılacak yineleme sayısını belirtmektedir. Bu sayı büyütüldükçe daha iyi bir sonucun elde edileceği söylenebilir. Metodun population_size parametresi her bir kuşakta (generation) tutulacak elemanların sayısını belirtmektedir. Bu parametrenin default değerinin 100 olduğunu görüyorsunuz. Bu değer de yükseltildikçe daha iyi bir sonucun elde edilmesi beklenmektedir. Metodun offspring_size parametresi oluşturulacak yavru sayısını belirtir. Bu parametre için değer girilmemezse offspring_size değeri population_size değeri kadar alınmaktadır. Metodun mutation_rate parametresi ise oluşturulacak mutasyonların oranını belirtmektedir. Bu oran 0 ile 1 arasında bir değer olabilir. Metodun max_time_mins parametresi algoritmanın en fazla kaç dakika sonra sonlandırılacağını belirtmektedir. Metodun max_eval_time_mins parametresi ise bir tek model için en fazla kaç dakika harcanacağını belirtmektedir. Bu parametrenin default değerinin 5 olduğunu görüyorsunuz. Metodun diğer parametreleri için TPOT dokümanlarına başvurabilirsiniz.

2) Yaratılan TPOTClassifier nesnesi ile sınıfın fit metodu çağrılır. fit metodu eğitim veri kümесinin x ve y değerlerini parametre olarak almaktadır.

3) Kestirim için sınıfın predict metodu kullanılmaktadır.

4) Test işlemi sınıfın score isimli metoduyla yapılmaktadır. score test veri kümесinin x ve y değerlerini parametre olarak almaktadır.

Şimdi TPOT ile sınıflandırma işlemi için bir örnek verelim. Örneğimizde Titanik kazasında yolcuların bazı özelliklerine göre onların hayatı kalıp kalamayacağını kestirmeye çalışacağız.

PEKİŞTİRMELİ ÖĞRENME (REINFORCEMENT LEARNING)

Yapay zekadaki pekiştirmeli öğrenme (reinforcement learning) psikolojideki edimsel koşullanma (operant conditioning) kuramı temel alınarak oluşturulmuştur. Psikolojide edimsel koşullanma "ödül getiren davranışların tekrarlandığı" fikrine dayanmaktadır. Bu konudaki ilk çalışmalar Edward Thorndike tarafından yapılmıştır. Thorndike kedileri belli bir alana kapatıp belli bir düğmeye bastıklarında onların çıkışmasına olanak sağlayan bir düzenek oluşturmuştur. Sonra kediler bu düğmeye tesadüfen bastıklarında ödül olarak dışarı çıkmışlardır. Thorndike bu deneyi aynı kediler üzerinde tekrarladıkça kediler düğmeye basma işini çok daha hızlı yapmaya başlamıştır. Thorndike buna "etki yasası (law of effect)" demiştir. Fakat edimsel koşullanmanın kuramsallaştırılması büyük ölçüde B.F. Skinner tarafından yapılmıştır. Skinner Thorndike'in deneylerini genişleterek bu alanı çok daha kapsamlı hale getirmiştir. Zaten "pekiştirme (reinforcement)" terimi de Skinner tarafından uydurulmuştur. Skinner organizmada hız uyandıran edimlerin (eylemlerin) yinelendiğini pek çok deneye göstermiştir. Buna göre organizma birtakım faaliyetlerde bulunur. Bazı faaliyetleronda hız uyandırmaktadır. Başka bir deyişle organizma bazı faaliyetlerden bazı ödüller (rewards) elde etmektedir. Yapılan faaliyetler sonucunda ödül elde edilmesine yol açarak edimin yinelenmesini sağlayan süreçlere "pekiştirme (reinforcement)", burada verilen ödülü de "pekiştireç (reinforcer)" denilmektedir. Edimsel koşullanma davranış değişirmede ve davranışın şekillendirilmesinde en etkili yöntemlerden biri olarak kabul edilmektedir.

Edimsel koşullanmada davranışının yinelenmesi için verilen uyarınlara "pekiştireç (reinforcer)" dendögünü belirtmiştir. Pekiştireçler de "pozitif" ve "negatif" olmak üzere ikiye ayrılmaktadır. Organizmaya doğrudan hız veren pekiştireçlere pozitif pekiştireçler denir. (Örneğin bir çocuğa ödül olarak verilen şeker gibi, bir çalışانا ödül olarak verilen para gibi.) Ortamda olumsuz bir uyarani (yani organizmada gerginlik yaratan bir uyarani) ortadan kaldırarak organizmanın yine hız elde etmesi sağlanabilir. İşte bu biçimde ortamdan acı verici bir uyarının kaldırılması durumunda bu uyarınlara da "negatif pekiştireçler" denilmektedir. Hem pozitif hem de negatif pekiştireçler sonuç olarak organizmada hız uyandırmaktadır. Edimsel koşullanmada önemli bir olgu da cezadır. Organizmada hoşa gitmeyen bir etki oluşturan uyarınlara bu bağlamda "ceza (punishment)" denilmektedir. Ceza da bir pekiştireçtir. Ancak araştırmalar davranış değişirmede ve davranışın kalıcılığını sağlamada cezaların çok iyi iş görmediğini göstermektedir. Ceza çabuk etki göstermesi bakımından pratik bir yöntem olsa da genellikle kalıcı bir davranış değişikliğine yol açmaz ve saldırganlığı artırmak gibi dolaylı yan etkilere sahiptir. Cezalar da "birincil" ve "ikincil" olmak üzere ikiye ayrılmaktadır. Organizamaya doğrudan acı veren uyarının uygulanmasına birincil ceza, organizmada hız uyandıran bir uyarının ortadan kaldırılması biçiminde verilen cezaya da ikincil ceza denilmektedir. Ceza verilecekse daha çok ikincil cezalar tercih edilmelidir.

Pekiştirme sürecinin diğer bir türü de "dolaylı pekiştirme (vicarious reinforcement)" denilen biçimdir. Dolaylı pekiştirme başkalarını izleyerek ve başkalarının ödül aldığına ya da ceza aldığına görerek bundan bir sonuç çıkartma sürecidir. Tabii burada bazı akıl yürütme faaliyetleri de deveye girdiği için sürecin bilişsel tarafı da vardır. Bu nedenle bu öğrenme modeline "sosyal öğrenme" ya da "sosyal bilişsel öğrenme" denilmektedir.

Pekiştirmeli Makine Öğrenmesinin Ana Fikri ve Temelleri

Pekiştirmeli öğrenmede ana fikir belli bir edimin (action) çevre (environment) ile etkileşime sokulması bunun sonucunda bir ödül ceza sisteminin uygulanması ve gitgide bu ödüllerin maksimize edilmeye çalışılmasıdır. Pekiştirmeli makine öğrenmesi sürecinde bazı terimler sıkça kullanılmaktadır. Önce bunları açıklamak istiyoruz:

Yazılımsal Etmen (Software Agent): Pekiştirmeli öğrenmeyi gerçekleştiren yazılım ve algoritmalar "yazılımsal etmen" denilmektedir. Genellikle "yazılımsal etmen" yerine yalnızca "etmen (agent)" terimi kullanılmaktadır. Biz de burada "yazılımsal etmen" yerine "etmen" terimini kullanacağız.

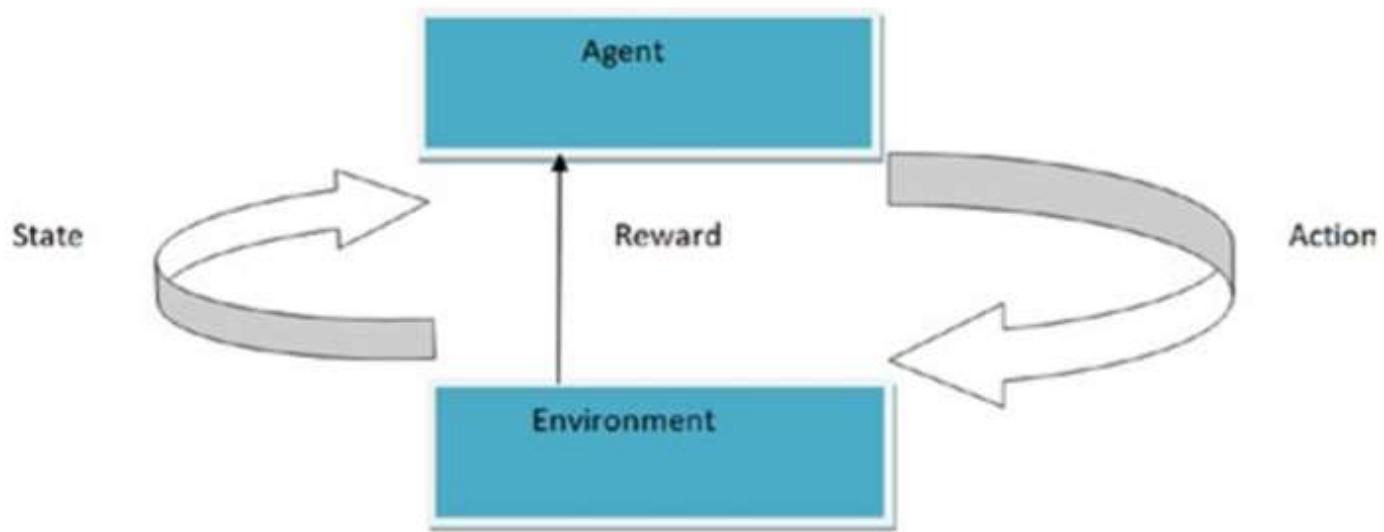
Çevre (Environment): Etmenin faaliyette bulunduğu ortama çevre denilmektedir. Pekiştirmeli öğrenmede çevreyi oluşturmak başka bir deyişle çevreyi simüle etmek önemli bir problemdir. Bu nedenle çevreyi simüle etmek için hazır birtakım platformlar oluşturulmuştur.

Faaliyet (Action) Yazılımsal etmenin yaptığı edimlere faaliyet (action) denilmektedir.

Durum (Status): Durum yazılımsal etmenin belli bir andaki verisel özellikleridir. Yazılımsal etmen bir faaliyette bulunduğu zaman durum değişikliği oluşur. İşte yazılımsal etmenin bir durumdan diğerine geçmesi söz konusudur. Bu haliyle konu "automata" teorisile ve durum makineleriyle (state machines) ilgili olmaktadır.

Ödül / Ceza (Reward /Punishment): Yazılımsal etmen bir faaliyette bulunduğuanda algoritmik olarak ona bir ödül ya da ceza verilir. Şüphesiz bu kavram pekiştirmeli öğrenmenin en önemli prensibini oluşturmaktadır.

Bu durumda yukarıdaki kavamlarla tipik bir pekiştirmeli öğrenme modeli aşağıdaki gibi bir şekilde betimlenebilir:



Alıntı Notu: Görsel "Reinforcement Learning With Open AI, TensorFlow and Keras Using Python (Nandy & Biswas)" kitabından alınmıştır.

Bu görselde anlatılmak istenen şey "etmenin çevre ile etkileşiminde bir faaliyette bulunduğu, bu faaliyet sonucunda bir durum değişikliğinin olduğu ve yeni durum için bir ödül/ceza sisteminin devreye sokulduğu"udur.

Etmenin içinde bulunduğu çevrenin özellikleri aşağıdakilere ilişkin olabilir:

Deterministik Olan ya da Deterministik Olmayan Çevreler: Eğer bir durumda gidilebilecek tek bir durumsal seçenek varsa ya da birden fazla durumsal seçeneklerin hangisinin seçileceği eldeki bilgilerle belirlenebiliyorsa bu tür çevrelerle deterministik çevre denilmektedir. Deterministik çevrelerde yazılımsal etmen aynı durumdaysa buradan aynı aynı sonuçlar elde edilmektedir.

Ayrık (Discrete) ya da Sürekli (Continuous) Çevreler: Ayrık çevreden kastedilen belli bir durumda oluşabilecek seçeneklerin sınırlı sayıda olmasıdır. Yani etmen belli bir durumda sınırlı sayıda faaliyette (action) bulunabilir. Bu istatistikteki "ayırık değişken" kavramına benzetilebilir. Sürekli çevrede ise bir durumda sonsuz miktarda olası faaliyet (action) söz konusu olmaktadır. Örneğin bir labirentte belli bir noktada sapılacak yolların sayısı sınırlıdır. Bu labirent ayrık bir çevre oluşturmaktadır.

Gözlemlenebilir (Observable) Olan, Gözlemlenebilir Olmayan (Unobservable) ve Kısmen Gözlemlenebilir Olan (Partially Observable) Çevreler: Gözlemlenebilir çevre demekle çevrenin bütünsel durumunun bilebilmesi anlatılmak istenmektedir. Yani biz çevredeki tüm öğelerin yerlerini, değerlerini vs. biliyorsak bu gözlemlenebilir bir çevredir. Eğer biz çevreyi oluşturan öğelerin durumlarını tam olarak bilmiyorsak bu çevre gözlemlenebilir değildir. Tabii bir çevrede bazı öğeler gözlemlenebilirken bazıları gözlemlenebilir olmayıabilir. Böyle çevrelerde kısmen gözlemlenebilir çevreler denilmektedir.

Pekiştirmeli Öğrenmenin Uygulama Alanları

Pekiştirmeli öğrenmenin en önemli uygulama alanları şunlardır:

Otomatik Kontrol Sistemleri: Otomatik kontrol sistemleri çevredeki değişimlere göre uygun konum alabilen sistemlerdir. Pekiştirmeli öğrenmenin tipik uygulama alanlarından birini oluşturmaktadır. Örneğin adaptif trafik kontrollerinde kırmızı ışığın ne süreyle yanıp söndürüleceği pekiştirmel öğrenme yoluya sisteme öğretilebilir. Benzer biçimde havadaki nem, basınc gibi faktörlere bağlı olarak birtakım dengeleme işlemlerinin yapılması da otomatik kontrol sistemlerine örnek olarak verilebilir.

Finansal Problemler: Finansal süreçler tipik olarak birtakım alternatifler arasında uygun bir alternatifin belirlenmesi ile ilgilidir. Burada pekiştirmeli öğrenme "öğrenilecek şeyin net olarak bilinmediği" durumlarda kullanılmaktadır.

Üretim Problemleri: Üretimdeki bazı problemler faaliyet ve durum değişikliği ile ilişkilidir. Bu tür durumlarda pekiştirmeli öğrenmelerden faydalanailmaktadır.

Stok Yönetimi Problemleri: Optimal stok miktarlarının belirlenmesi üretimde önemli bir sorundur. Bu tür sistemler pek çok faktörü olan bu sorun için iyi bir seçenek sunabilmektedir.

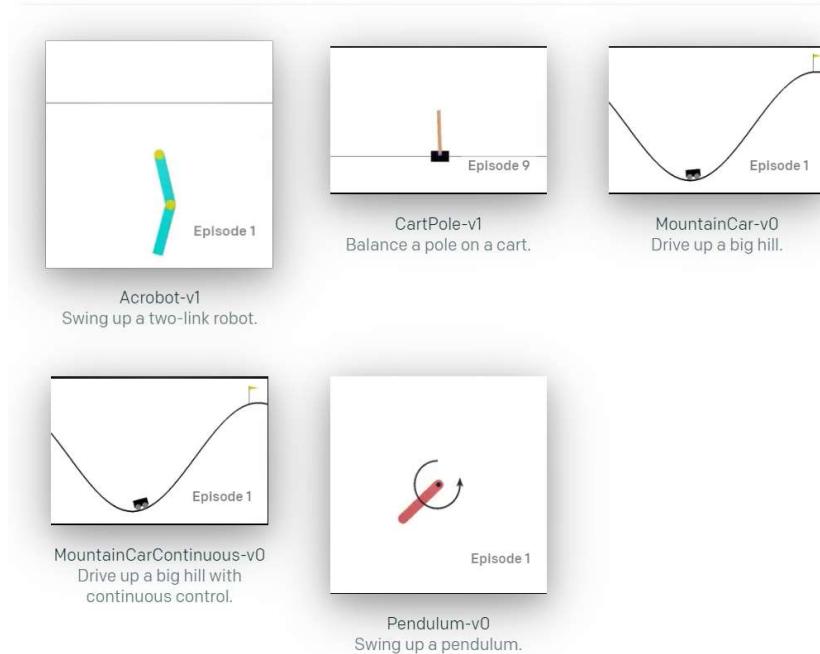
Dağıtım Problemleri: Genel olarak bir grup ürünün ne zaman ve hangi rotayla dağıtılacagini ilişkin problemlerde de pekiştirmeli öğrenme sıkça kullanılmaktadır.

OpenAI GYM Ortamı

OpenAI yapay zeka konusunda faaliyet gösteren bir kurumdur. OpenAI'ın gym denilen ortamı (gym.openai.com) pekiştirmeli öğrenme için iyi bir simülasyon ortamı sunmaktadır. Tabii gym dışında başka ortamlar da mevcuttur. Örneğin benzer özellikler Google'in DeepMind (<https://deepmind.com/>) ortamında da bulunmaktadır. Biz kursumuzda OpenAI'ın Gym ortamını kullanacağımız.

OpenAI Gym kullanıcıların algoritma geliştirmek amacıyla hazırlamış olduğu ortamında çeşitli konulara yönelik çeşitli simülatörler vardır. Bu simülatörlerde pek çok şey hazırlıdır. GYM ortamındaki simülatörler çeşitli kategorilere ayrılmıştır. Örneğin "Klasik Kontroller (Classical Control)" kategorisindeki simülatörler şunlardır:

Classic control
Control theory problems from the classic RL literature.

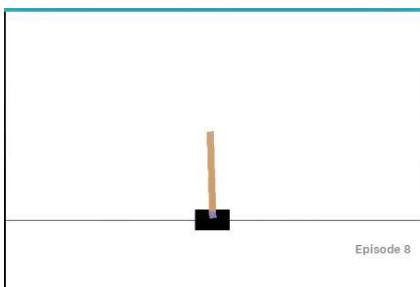


Gym ortamını pip programı şöyle kurabilirsiniz:

```
pip install gym  
Şimdi Gym simülatörlerinden birkaçını açıklayalım.
```

Gym CartPole Simülatörü

Cartpole ("Cart" araba, "pole" ise direk anlamına gelmektedir) simülatöründe bir küçük arabanın tepesine bir direk yerleştirilmiştir. Bu direk arabaya katı biçimde monte edilmemiştir ve mafsallardan oynayabilmektedir. Araba hareket ederse bu direk sola ya da sağa düşer.



Bu simülatörde kullanıcı arabaya soldan ya da sağdan bir kuvvet uygulayarak arabayı hareket ettirir. (Kullanıcı arabanın hızını doğrudan belirlemez. Yalnızca kuvvet uygular.) Uygulanan kuvvet sabittir. Eğer bu kuvvet aynı biçimde uygulanmaya devam ederse şüphesiz araba ivmeli bir biçimde -yani gittikçe hızlanarak- hareket edecektir. Simülatörde hedeflenen arabaya monte edilmiş direğin devrilmeden $+15$, -15 derece arasında dik tutulmasıdır. Aynı zamanda arabanın merkezden 2.4 birim uzaklaşmaması da gerekmektedir. Yani burada başarısızlığın iki nedeni vardır: Direğin $+15$, -15 'lik dereceden aşağıda olması ve arabanın merkezden 2.4 birim uzaklaşmış olmasıdır. Özette modelin parametrik bilgileri şöyledir:

- Simülatörde iki faaliyet tanımlıdır:

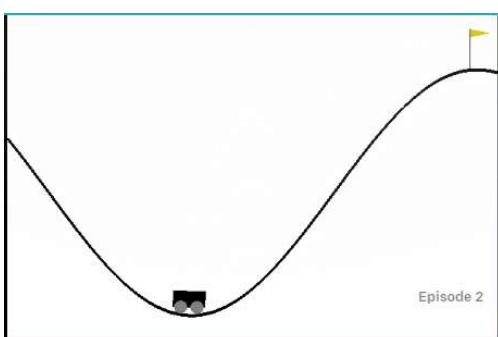
- 0 --> Sola kuvvet uygula
- 1 --> Sağa kuvvet uygula

- Arabanın içinde bulunduğu durumla (observation space) ilgili bilgiler şunlardır:

- Arabanın konumu (merkez 0 olmak üzere)
 - Arabanın o andaki hızı
 - Direğin açısı
 - Direğin açısal hızı
- Eğer direk -15 , $+15$ açısı arasında ise $+1$ olarak değilse 0 ödül puanı verilmektedir.
- Eğer direk açısı -15 , $+15$ derece sınırlarını aşarsa ya da arabanın pozisyonu $[-2.4, 2.4]$ sınırlarının dışına çıkarsa işlem başarısızlığıyla sonlandırılmaktadır. Eğer araba 500 adım başarısız olmazsa işlem başarıyla sonlandırılmışmaktadır.

Gym MountainCar Simülatörü

MountainCar simülatöründe bir araba bir tepeyi aşmaya çalışmaktadır. Arabayı idare edenin yapabileceği üç şey vardır (faaliyet uzayı): İleri doğru gaz vermek, geriye doğru gaz vermek ve hiç gaz vermemek.



Araba ileri doğru gaz verildiğinde yokuştan dolayı tepeyi aşamamaktadır. Tepenin aşılması için hızının artırılması gerekmektedir. Burada insanların (makinelerin değil) aklına gelen en uygun strateji önce ileri doğru gaz verip arabanın çıkabildiği kadar çıkışmasını sağlamak sonra geriye gaz verip ters yönde potansiyel enerji kazanmak ve böyle devam ederek tepeyi aşmasını sağlamaktır. Simülatör bize gözlem değeri olarak (observation space) arabanın konumunu ve hızını vermektedir. MountainCar simülatöründe her adımda araba bayraklı yere erişirse ödül olarak 0 verilmekte erişemezse -1 ceza puanı verilmektedir. Arabanın tepeyi aşması için bayrak ile belirtilen noktaya gelmesi gerekmektedir. Eğer 200 adımda araba tepeyi aşamazsa girişim başarısız olmaktadır. MountainCar simülatörle ilgili bilgileri şöyle özetleyebiliriz:

- Araba için üç faaliyet söz konusudur.

- 0 --> Motoru sola çalıştırma

- 1 --> Motoru durdurma

- 2 --> Motoru sağa çalıştırma

- Çevre durumu o anda arabanın bulunduğu yer ve arabanın hızıdır. Arabanın bulunduğu yer [-1.2, 0.6] arasında hız ise [-0.07, 0.07] arasında değişmektedir.

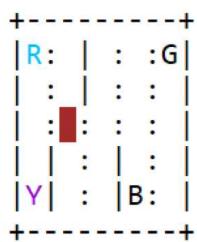
- Tepe (yani bayrağın bulunduğu yer) 0.5 pozisyonundadır.

- Araba başlangıçta [-0.6, -0.4] arasında rastgele bir konumdan başlatılmaktadır.

- Eğer araba tepeyi aşarsa yani arabanın konumu 0.5'ten büyük olursa işlem başarıyla sonuçlanmaktadır. Eğer 200 adımda araba tepeyi aşamazsa işlem başarısızlıkla sonuçlanmaktadır.

Gym Taxi Simülatörü

Bu simülasyonda 5 X 5'lik bir alanda bir taksi bulunmaktadır. Her biri ayrı bir renkle gösterilen 4 ayrı indirme-bindirme durağı vardır. Burada öğrenilecek iş taksinin yolcuya belirlenen bir duraktan alıp başka bir belirlenen durağa bırakmasıdır. Durakların yerleri hep sabit olmakla birlikte yolcu bu duraklardan herhangi birinde bulunuyor olabilir ve bu duraklardan herhangi birine gitmek istiyor olabilir. Alan içerisindeki matriste duvarlar da vardır. Dolayısıyla duvara çarptığında diğer tarafa geçilememektedir. Çizdirilen şekilde mavi renk her zaman yolcunun alınacağı durağı, mor renk ise yolcunun bırakılacağı durağı belirtmektedir. Arabanın içerisinde yolcu yoksa araba kırmızı, yolcu varsa yeşil olarak gösterilmektedir. Örneğin:



Burada yolcu sol üst duraktan alınacak, sol alt duraga bırakılacaktır.

Simülasyonda toplam 6 tane eylem (action) vardır:

- 0 --> Aşağıya gitme

- 1 --> Yukarıya gitme

- 2 --> Sağa gitme

- 3 --> Sola gitme

- 4 --> Yolcu alma

- 5 --> Yolcu bırakma

Bu eylemler taksinin yukarı, sola, sağa, aşağıya gitmesi, yolcu alma ve yolcu bırakma eylemleridir. Toplam durum sayısı (observation space) 500 tanedir. Taksi 5 X 5'lik alanda 25 farklı yerden birinde olabilir. Yolcu da 5 farklı yerde bulunabilir. (4 tane durak ve taksinin içi). Nihayetinde yolcunun bırakılacağı 4 farklı yer bulunmaktadır. Bunların çarpımı 500'dür. 5X5'lik matristeki hücre numaralandırmaları ekran koordinat sisteminde olduğu gibi yapılmıştır. Yani Sol-Üst köşe (0, 0) koordinatını belirtmektedir. Durum bilgisi tek bir sayı ile şu biçimde elde edilmektedir:

Arabanın satır numarası * 100 + arabanın sütun numarası * 20 + yolcunun konumu * 4 + yolcunun bırakılacağı yer

Burada Arabanın satır ve sütun numaraları 0'dan başlatılmaktadır. Yolcunun konumu şöyle kodlanmıştır:

R --> 0
G --> 1
Y --> 2
B --> 3
Taksinin içinde --> 4

Yolcunun bırakılacağı yer de şöyle kodlanmıştır:

R --> 0
G --> 1
Y --> 2
B --> 3

FrozenLake8x8 Simülatörü

Bu simülatör FrozenLake isimli 4x4'lük simülatörün 8x8'lik biçimidir. Bu simülatörde donmuş bir gölde bir kişi bir noktadan (S noktası) başka bir noktaya (G noktası) gitmeye çalışmaktadır. Ancak yolu üzerinde delikler (yani çatlaklar) vardır (H noktaları). Kişi de ancak donmuş yüzeylerden (F noktaları) yürüyebilmektedir.



Simülatörde etmenin yapabileceği eylemler şunlardır:

Sola gitme --> 0
Aşağıya gitme --> 1
Sağa gitme --> 2
Yukarıya gitme --> 3

Ancak simülatörde varsayılan durumda zemin kaygandır. Kaygan (slippery) zeminde kişi bir yöne gitmek istediginde ancak 1/3 olasılıkla istediği yöne, 2/3 olasılıkla ise istediği yönün dik yönlerinden birine gidebilmektedir. Örneğin kişi sağa gitmek istesin. Bu durumda aslında kişi 1/3 olasılıkla sağa, 1/3 olasılıkla yukarıya ve 1/3 olasılıkla aşağıya gidecektir. Benzer biçimde örneğin kişi aşağıya gitmek istese yine 1/3 olasılıkla aşağıya, 1/3 olasılıkla sola 1/3 olasılıkla sağa gidecektir. Aslında zeminin kayganlığı nesne yaratılırken is_slippery parametresiyle ayarlanabilmektedir. Bu parametre False geçilirse (default durum True) zemin kayganlığı ortadan kalkar. Dolayısıyla kişi istediği yöne gider. Örneğin:

```
env = gym.make('FrozenLake8x8-v1', is_slippery=False)
```

Durum bilgisi etmenin içinde bulunduğu satır ve sütunu belirten tek bir sayıdan oluşmaktadır. Bu sayı şöyle elde edilmektedir:

```
etmenin satır numarası * 8 + etmenin sütun numarası
```

Hedef noktaya (G noktası) varan eylemler 1 puan varmayan eylemler 0 puan ödül almaktadır.

MsPacman Simülörü

Bu simülatör geçmişin en popüler Atari oyunlarından biri olan Pac-Man oyununun simülasyonunu yapmaktadır. Bu oyunda oyuncu küçük topakları yiyecek puan kazanır. Ancak oyuncuyu dört hayalet izlemektedir. Oyuncu aynı zamanda bu dört hayalet tarafından yakalanmamaya da çalışır. Oyuncuyu hayalete yakalanırsa can kaybetmektedir. Oyuncu bir güç topağını yerse hayaletlerin maviye dönmesine neden olarak, onların ekstra puanlar için yenebilmelerine de yol açar. Artan puan değerleri için her turda iki kez bonus meyveler yenebilir. Turlar arttıkça hız artar ve enerji verici topaklar genellikle hayaletlerin savunmasızlık süresini de azaltır. Oyunda oyuncunun 4 canı vardır. Oyuncu bu canların hepsini kaybederse oyun bitmektedir.



Breakout Simülasyonu

Bu simülator kişisel bilgisayarların ilk zamanlarında oldukça popüler olmuş olan "tuğla kirmaca" oyununun simülasyonunu yapmaktadır. Oyunda kça yansyan bir top, yukarıda tuğlalar ve aşağıda yatay eksende hareket ettirilebilir bir raket vardır. Top yere düşerse oyun oturum biter. Oyuncunun bu biçimde 5 hakkı bulunmaktadır. Oyuncu raketin hareket ettirerek topun yere düşmesini engeller. Tuğlalar kırıldıkça oyuncu puan kazanmaktadır. Aşağıda oyundan bir kar göründürünüz:



Simülatörün durum bilgisi 210x160x3 boyutlarında RGB bir resimdir. Simülatörde dört eylem tanımlıdır:

- 0 --> Hareket Yok
- 1 --> Ateşleme
- 2 --> Sağa Gitme
- 3 --> Sola Gitme

Ateşleme her defasında yeni bir top ile oyunu başlatmak için kullanılmaktadır. Yani top aşağıya düşerse yeni bir topla devam edebilmek için bir kez ateşlemenin yapılması gerekmektedir. Oyunda bir tuğla kırıldığında 1 puan ödül verilmektedir. Tuğlanın kırılmasına yol açmayan eylemlerden 0 puan elde edilmektedirç

Gym Simülatörlerinin Çalıştırılması

Gym simülatörleri modüldeki global make isimli fonksiyonun simülatör ismiyle çağrılmalarıyla yaratılmaktadır. Örneğin:

```
import gym  
  
env = gym.make('CartPole-v1')
```

Bundan sonra simülatör nesnenin reset metoduyla başlangıç konumuna ayarlanır. Simülatör nesnesinin kullanımı bittiğinde close metodu ile boşaltım sağlanmalıdır. Örneğin:

```
import gym  
  
env = gym.make('CartPole-v1')  
obs = env.reset()  
...  
env.close()
```

Örneğin reset işlemi ile CartPole-v1 simülatöründeki araba ve direk rastgele bir konumdan başlatılmaktadır. reset metodu bize geri dönüş değeri olarak "gözlem nesnesini (observation object)" vermektedir. Gözlem nesnesi ortamdaki gözlemlenebilir tüm öğelerin (observation space) oluşturduğu bir NumPy dizisidir. Bu dizinin elemanları "CartPole-v1" için sırasıyla arabanın konumu, arabanın hızı, direğin açısı ve direğin açısal hızıdır. Örneğin:

```
In [22]: obs  
Out[22]: array([-0.04124306, -0.0085189 ,  0.01014184, -0.01133194])
```

reset işleminden sonra artık durumlar arasında geçiş oluşturmak gereklidir. Bunun için de faaliyette (action) bulunmak gereklidir. İşte faaliyette bulunma işlemi simülör nesnelerinin step metodlarıyla yapılmaktadır. Simülör sınıflarının step metodları faaliyet alanındaki (action space) bir faaliyeti argüman olarak alıp yeni oluşan çevre durumuna ilişkin bazı değerleri bize vermektedir. CartPole simülöründe step metodu 0 ve 1 olmak üzere iki değeri argüman olarak almaktadır. 0 sola, 1 sağa kuvvet uygulanacağı anlamına gelir. step metodu dörtlü bir demetle geri dönmektedir. Bu dörtlü demetin ilk elemanı o faaliyet uygulandıktan sonraki çevrenin gözlem değerleridir. Bu değerler yine CartPole örneğinde bize 4'lü NumPy dizisi biçiminde verilmektedir. Demetin ikinci elemanı verilen ödül miktarıdır. Üçüncü eleman oyunun bitip bitmediğini belirten bir flag niteliğindedir. Örneğin CartPole simülöründe bitiş koşulları iki tanedir. Son parametre bir sözlük nesnesidir. Bize başka bazı bilgileri vermektedir.

Gym simülörleri oluşan değerleri bize vermenin yanı sıra ortamı da görüntüleyebilmektedir. Bunun için ilgili simülör nesnesinin render metodunu kullanılır. Şimdi örnek olarak arabayı bir sağa bir sola hareket ettirelim:

Örneğin:

```
import gym

import gym
import time

env = gym.make('CartPole-v1')
obs = env.reset()

while True:
    obs, reward, done, info = env.step(0)
    if done:
        break
    env.render()
    time.sleep(0.2)
    obs, reward, done, info = env.step(1)
    if done:
        break
    env.render()
    time.sleep(0.2)

env.close()

print(i)
```

Burada araba bir sağa bir sola hareket ettirilmiştir. Bitiş koşulları sağlandığında döngüden çıkıştır. render işlemlerinden sonra time.sleep fonksiyonu ile arabanın davranışını görebilmek için küçük bir bekleme koyduk.

Genel olarak gym nesnelerinin action_space elemanından elde edilen nesnenin sample metodunu bize faaliyet uzayındaki rastgele bir değeri vermektedir. Örneğin arabayı rasgele biçimde söyle ilerletebiliriz:

```
import gym
import time

env = gym.make('CartPole-v1')
obs = env.reset()

while True:
    action = env.action_space.sample()
    obs, reward, done, info = env.step(action)
    if done:
        break
    env.render()
    time.sleep(0.2)

env.close()
```

Pekiyi pekiştirmeli öğrenmede bu simülatörle programcı ne yapacaktır? İşte bu tür OpenAI simülatörlerinde programcı aslında gözlem değerlerini alıp faaliyeti (action) belirleyecek algoritmik yapıyı kurmaya çalışır. Bu simülatörlerin temel amacı bu çalışmaların yapılabilmesi için ortam oluşturmaktır. Biz de bu simülatörleri aslında pekiştirmeli öğrenme algoritmalarını gerçekleştirmek ve denemek için kullanacağız. Örneğin aşağıda yalnızca direğin açısına göre faaliyeti ayarlayan bir strateji uygulanmıştır. Bu stratejinin başarısız olacağı açıklıdır:

```
import gym
import time

def get_action(obs, reward):
    return 1 if obs[2] > 0 else 0

env = gym.make('CartPole-v1')
obs = env.reset()

reward = 0
while True:
    action = get_action(obs, reward)
    obs, reward, done, info = env.step(action)
    if done:
        break
    env.render()
    time.sleep(0.5)

env.close()
```

Simülatör sınıflarının `action_space` örnek öznitelikleri faaliyet kümesi hakkında bize bilgi vermektedir. Bu örnek özniteligiden Discrete türünden bir nesne elde edilmişse bu nesne bize faaliyet elemanlarının ayrık değerlerden oluştuğunu söylemektedir. Discrete sınıfının "n" isimli örnek özniteliği bu değerlerin kaç tane olduğunu verir. Benzer biçimde simülatör sınıflarının `observation_space` örnek özniteliği de gözlemlerin özelliklerini bize vermektedir.

Şimdi de MountainCar simülatörünü çalıştıralım. Örneğin bu simülatörde doğrudan arabaya ileriye doğru gaz verelim:

```
import gym
import time

env = gym.make('MountainCar-v0')
obs = env.reset()
print(obs)
while True:
    obs, reward, done, info = env.step(2)
    if done:
        break
    env.render()
    time.sleep(0.5)

print(obs)

env.close()
```

Göründüğü gibi arabaya sürekli gaz vermek tepeyi aşması için yeterli olmamaktadır. Burada izlenecek en uygun strateji arabanın hızı sıfıra düşene kadar tepe yönünde gaz vermek, hız sıfıra düşünce ters yönde gaz vermek, böylece hız her sıfıra düştüğünde ters yönde gaz vererek tepeyi aşmasını sağlamaktır:

```
import gym

env = gym.make('MountainCar-v0')
obs = env.reset()
```

```

print(obs)
while True:
    if obs[1] > 0:
        action = 2
    else:
        action = 0
    obs, reward, done, info = env.step(action)
    if done:
        break
    env.render()
    print(obs)

env.close()

```

Tabii biz problemi burada insan zekası ile çözdük. Ancak pekiştirmeli öğrenmede biz problemin çözümünün makine tarafından bulunmasını sağlamaya çalışacağız.

Şimdi de Taksi simülatöründe taksiye rastgele işlemler yaptıralım:

```

import gym

env = gym.make('Taxi-v3')
obs = env.reset()
print(obs)
env.render()

while True:
    action = env.action_space.sample()
    obs, reward, done, info = env.step(action)
    if done:
        break
    env.render()

env.close()

```

Şimdi de Taxt simülörü ile çalışalım. Yine simülasyonu başlatmak için gym.make fonksiyonu ile simülör ismi verilerek simülör nesnesi elde edilir. Nesne reset edilerek başlangıç konumu oluşturulur. Örneğin:

```

import gym

env = gym.make('Taxi-v3')
obs = env.reset()
env.render()

```

```

+-----+
|R: | : :G|
| : | : : |
| : | : : |
| : | : : |
|Y| :B: |
+-----+

```

Örneğin yukarıdaki reset durumunun observation değeri şöyledir:

```

In [8]: obs
Out[8]: 453

```

Buradaki 453 değeri şöyle elde edilmiştir:

$4 \text{ (arabanın satır numarası)} * 100 + 2 \text{ (arabanın sütun numarası)} * 20 + 3 \text{ (yolcunun konumu)} * 4 + 1 \text{ (yolcunun bırakılacağı yer)} = 453$

Simülör nesnesinin encode isimli metodu sırasıyla satır no, sütun no, yolcunun konumu ve yolcunun bırakılacağı koordinatları parametre olarak alıp bize simülasyonun konumunu tek bir değer olarak verir. Örneğin:

```
In [23]: env.encode(4, 2, 3, 1)
Out[23]: 453
```

Bunun tersini yapan decode isimli metot da vardır. decode metodu dolaşılabilir bir nesne vermektedir. Örneğin:

```
In [26]: list(env.decode(453))
Out[26]: [4, 2, 3, 1]
```

Her step işleminde simülör tarafından verilen ödül şöyledir:

- Yolcu uygun yere bırakılırsa +20 ödül alınmaktadır.
- Her adımda -1 ceza verilmektedir.
- Yolcunun olmadığı yerden yolcu almak ya da hedef olmayan durağa yere yolcu bırakmak -10 ceza puanına yol açmaktadır.
- Yolcunun doğru yerden alımında herhangi bir puan verilmediği gibi yine -1 ceza verilmektedir.

Bir eylem yine step metoduya gerçekleştirilmektedir. Bu metot yine bize 4'lü bir demet verir. reset ve step metodlarından elde ettiğimiz observation nesnesi o andaki ortamın durumunu vermektedir. Örneğin:

```
In [27]: obs, reward, done, info = env.step(1)
```

```
In [28]: obs
Out[28]: 353
```

Burada araba yukarı yönlü hareket ettirilmiştir. Yeni konumu 353'tür. Bu değeri decode edip yeni çizimi yapalım:

```
In [30]: list(env.decode(obs))
Out[30]: [3, 2, 3, 1]
```

```
In [31]: env.render()
+-----+
|R: | : :G| |
| : | : : |
| : | : : |
| : | :B: |
|Y| : |B: |
+-----+
(North)
```

Şimdi arabaya rastgele 10 hareket yaptıran örnek bir program oluşturalım:

```
import gym

env = gym.make('Taxi-v3')
obs = env.reset()
env.render()

total_rewards = 0
for i in range(10):
    action = env.action_space.sample()
    obs, reward, done, _ = env.step(action)
    total_rewards += reward
    env.render()
```

```
print(total_rewards)
```

render işlemlerinden şu durumlar elde edilmişdir:

```
+-----+
| R: | : : G | |
| : | : : : |
| : | : : : |
| : | : : : |
| Y | : | B: |
+-----+
```

```
+-----+
| R: | : : G | |
| : | : : : |
| : | : : : |
| : | : | B: |
| Y | : | B: |
+-----+
```

(East)

```
+-----+
| R: | : : G | |
| : | : : : |
| : | : : : |
| : | : | B: |
| Y | : | B: |
+-----+
```

(Pickup)

```
+-----+
| R: | : : G | |
| : | : : : |
| : | : : : |
| : | : | B: |
| Y | : | B: |
+-----+
```

(Pickup)

```
+-----+
| R: | : : G | |
| : | : : : |
| : | : : : |
| : | : | B: |
| Y | : | B: |
+-----+
```

(South)

```
+-----+
| R: | : : G | |
| : | : : : |
| : | : : : |
| : | : | B: |
| Y | : | B: |
+-----+
```

(Pickup)

```
+-----+
| R: | : : G | |
| : | : : : |
| : | : : : |
| : | : | B: |
| Y | : | B: |
+-----+
```

(West)

```
+-----+
| R: | : : G | |
| : | : : : |
| : | : : : |
| : | : | B: |
| Y | : | B: |
+-----+
```

(West)

```

+-----+
|R: | : :G| |
| : | : : |
| : | : : |
| : | : : |
|Y|B: |B: |
+-----+
(South)
+-----+
|R: | : :G| |
| : | : : |
| : | : : |
| : | : : |
|Y|B: |B: |
+-----+
(Dropoff)
+-----+
|R: | : :G| |
| : | : : |
| : | : : |
| : | : : |
|B: | : : |
|Y| : |B: |
+-----+
(North)
-46

```

Bu işlemin hareketli bir biçimde görüntülenmesi için şöyle bir yol izlenebilir:

```

import gym
import time

env = gym.make('Taxi-v3')
obs = env.reset()
print( '\x1b[1J' + env.render(mode='ansi'))

total_rewards = 0
for i in range(20):
    action = env.action_space.sample()
    obs, reward, done, _ = env.step(action)
    total_rewards += reward
    time.sleep(0.5)
    print( '\x1b[1J' + env.render(mode='ansi'))

env.close()

print(total_rewards)

```

render metodunun mode parametresinin 'ansi' biçiminde girildiğine dikkat ediniz. Bu parametre sayesinde render metodу çıktıyı ekrana basılmaz. ANSI terminal sürücüsünün anlayabilecegi terminal ESC dizimleri biçiminde bize verir. Ekranın silinmesi için '\x1b[1J' özel yazısının yazdırılması yeterli olmaktadır.

Şimdi de benzer biçimde FrozenLake8x8 simülatörü ile çalışalım. Bu simülatör de benzer biçimde kullanılmaktadır. Simülatörün render metodu eskiden default durumda terminale karakter tabanlı basıyordu. Ancak daha sonra bu durum değiştirildi. Şimdi render metodu default durumda ortamı GUI olarak göstermektedir. Eğer render metodunun eskiden olduğu gibi çıktıyı karakter tabanlı göstermesi istenirse mode='ansi' girilmelidir. Örneğin:

```

import gym

env = gym.make('FrozenLake8x8-v1')
obs = env.reset()
print(env.render(mode='ansi'))

env.close()

```

Şöyledir bir görüntü elde edilmiştir:

```
FFFFFFFFFF  
FFFFFFFFFF  
FFFHFFFFFF  
FFFFFHFFF  
FFFHFFFFFF  
FHHFFFHF  
FHFFFHFHF  
FFFHFFFFG
```

Şimdi simülatöre rastgele 3 eylem yapkıralım:

```
SFFFFFFF  
FFFHFFFFFF  
FFFHFFFFFF  
FFFFFHFFF  
FFFHFFFFFF  
FHHFFFHF  
FHFFFHFHF  
FFFHFFFFG,
```

```
SFFFFFFF  
FFFHFFFFFF  
FFFHFFFFFF  
FFFFFHFFF  
FFFHFFFFFF  
FHHFFFHF  
FHFFFHFHF  
FFFHFFFFG,
```

```
SFFFFFFF  
FFFHFFFFFF  
FFFHFFFFFF  
FFFFFHFFF  
FFFHFFFFFF  
FHHFFFHF  
FHFFFHFHF  
FFFHFFFFG,
```

Yine hareketli biçimde görüntüyü şöyle oluşturabiliriz:

```
import gym
import time

env = gym.make('Taxi-v3')
obs = env.reset()
print('\x1b[1J' + env.render(mode='ansi'))

total_rewards = 0
for i in range(20):
    action = env.action_space.sample()
    obs, reward, done, _ = env.step(action)
    total_rewards += reward
    time.sleep(0.5)
    print(' \x1b[1J' + env.render(mode='ansi'))

env.close()

print(total_rewards)
```

Simülatörün GUI arayüzü aşağıdaki gibidir:



Şimdi de MsPacman oyununda etmene rastgele hareketler yaptıralım: Aşağıda oyuncunun rastgele hareketlerle oynadığı örnek bir oyun görüyorsunuz:

```
import gym
import time

env = gym.make('MsPacman-v0')

obs = env.reset()
while True:
    action = env.action_space.sample()
    obs, reward, done, _ = env.step(action)
    if done:
        break
    env.render()
    time.sleep(0.1)

env.close()
```

Breakout oyunu için de rastgele oyun hareketler yapan bir program şöyle oluşturulabilir:

```
import gym
import time

env = gym.make('Breakout-v4')

obs = env.reset()

while True:
    action = env.action_space.sample()
    obs, reward, done, _ = env.step(action)
    if done:
        break
    env.render()
    time.sleep(0.1)

env.close()
```

Pekiştirmeli Öğrenmede Kullanılan Algoritmalar

Pekiştirmeli öğrenmede çeşitli algoritmik yöntemlerden ve tekniklerden faydalanylabilmektedir. Örneğin yapay sinir ağları da başka tekniklerle birlikte pekiştirmeli öğrenmede kullanılabilmektedir. Biz kursumuzun bu bölümünde en yaygın kullanılan algoritmik yöntemler üzerinde duracağız.

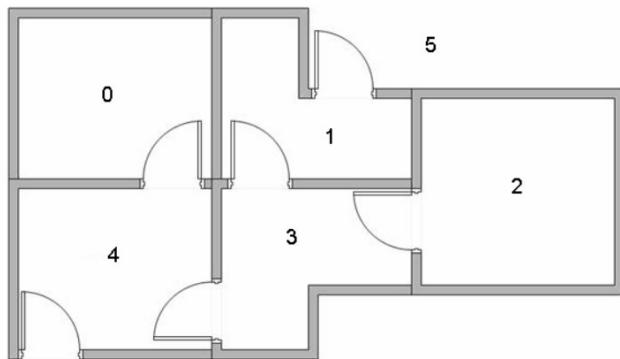
Q-Learning Algoritması

Q-Learning pekiştirmeli öğrenmede en fazla kullanılan algoritmik yöntem ve yaklaşımındır. Bu yaklaşımın sinir ağı versiyonu da vardır. Buna da "Deep Q Learning (DQN)" denilmektedir.

Q Learning algoritması aslında "Markov Zincirleri" denilen algoritmik modelle yakından ilişkilidir. Gerek Markov zincirlerinde gerekse Q-Learning algoritmasında en önemli unsur belli bir noktadaki kararın daha önceki veriler ve durumlar dikkate alınarak verilmesidir.

Q-Learning algoritmasında üç önemli olgu vardır: Durum (State), Eylem (Action) ve Ödül (Reward). Yöntemde öncelikle karşılaşılan problemden durumlar (states) oluşturulmaktadır. Yani içinde bulunulan koşullar durumlara ayırtılmalıdır. Durumlar ayrık olgularıdır. Dolayısıyla sürekli olguların ayrık hale getirilmesi gereklidir. Örneğin MountainCar simülasyonunda arabanın içinde bulunduğu durum konum ve hızla belirlenmektedir. Fakat konum da hız da ayrık olgular değildir. O halde bizim bu konum ve hızı aralık temelli bir biçimde ayrık hale getirmemiz gereklidir. Sürekli olguların ayrık hale getirilmesiyle elde edilen durumların sayısı çok yüksek olabilmektedir. Uygulamacı durum sayılarını kendi olanaklarına göre makul bir biçimde belirlemelidir. (Pekiştirmeli öğrenmede oluşturulan durumların sayısı fazla olabileceğinden dolayı bu biçimdeki yapay öğrenme yöntemleri de yüksek bir bilgisayar zamanı ve bellek kaynağının kullanılmasına yol açmaktadır.) Tabii bazen durumlar zaten ayrıktır. Bu durumda onların ayrık hale getirilmesine gerek kalmaz. Örneğin Taxi simülatöründe ya da FrozenLake simülatöründe durum zaten ayrıktır.

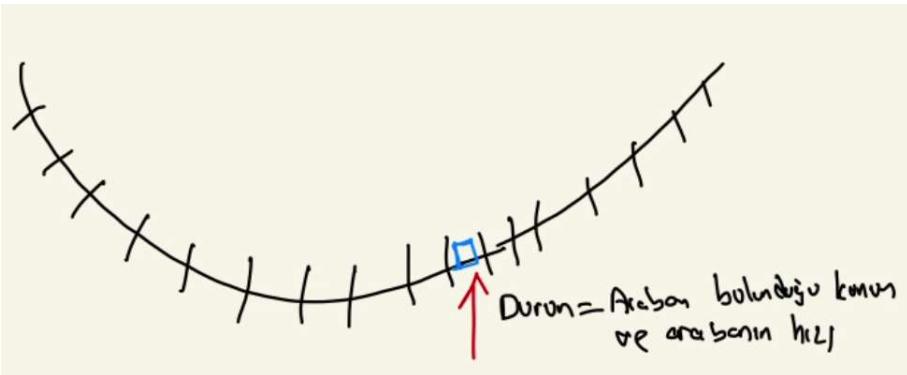
Örneğin bir labirentte odaların her biri bir durum olarak modellenebilir. Böylece labirentte kişinin bulunduğu yer zaten ayrık bir durum oluşturur.



(Görsel <http://mnemstudio.org/path-finding-q-learning-tutorial.htm> sitesinden alınmıştır.)

Burada durumlar 0, 1, 2, 3, 4, 5'ten oluşmaktadır. Bu labirentten amaç 5 noktasına ulaşmaktır.

Süphesiz durum (state) tek değişkenli bir bilgi olmak zorunda değildir. Çünkü belli bir durumu ifade etmek için birden fazla değişkene ihtiyaç duyulabilmektedir. Örneğin MountainCar simülasyonunda durum yalnızca arabanın x eksenindeki yeri değildir. Arabanın o andaki hızı da durumun bir parçasıdır. Bu örnekte x eksenini 20 parçanı 20x20'lük bir durum matrisi elde ederiz.

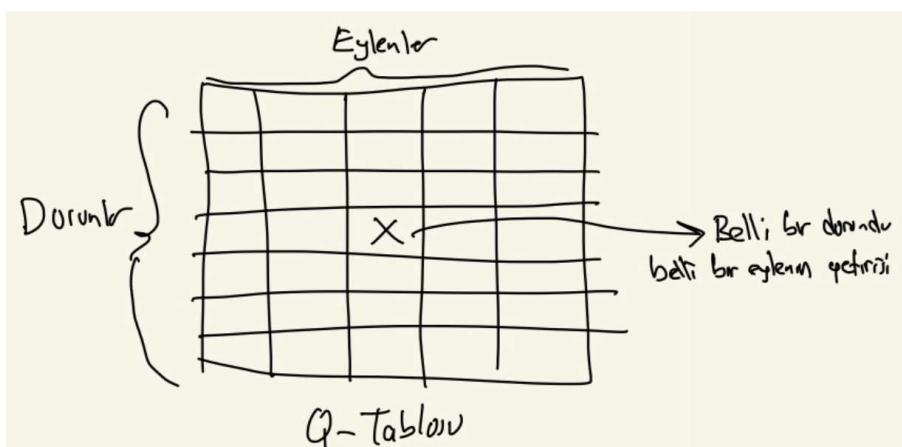


Göründüğü gibi MountainCar simülasyonunda arabanın belli bir konumda olması durum bilgisi için yetmemektedir. Araba aynı konumda bulunduğu halde o sırada farklı hızlarda olabilir. O halde buradaki durumlar konum ve hızı barındırmalıdır. Biz konum ve hızı 20 parçaya bölgerek ayrık hale getirdiğimizde toplam 20×20 'lik bir durum matrisi elde ederiz. Tabii eğer problemde durumsal bilgi 2 değişkenli değil 3 değişkenli olsaydı bizim durum matrisimiz de 3 boyutlu olacaktı. O halde genel olarak n değişkenli bir durumsal problemde durum matrisi de n boyutlu olacaktır.

Q-Learning algoritmada ikinci önemli nokta belli bir durumdaki eylemlerin (actions) neler olduğunu söylemektedir. Yani belli bir durumda olan etmen (agent) o durumu değiştirmek için hangi geçerli eylemleri yapabilecektir? Eylemlerin sayısı ve genel olarak listesi çok fazla olabilir. Üstelik de eylemler içinde bulunulan duruma göre farklılaşabilir. Bu durumda programcının eylemleri uygun ve makul bir veri yapısıyla ifade etmesi gereklidir. Yukarıdaki labirent örneğinde eylem bir odadan (yani durumdan) diğerine geçmektir. Ancak her odadan diğerine bir geçişin olmadığı görülmektedir. Tabii bu tür gerçek problemlerde hangi odalardan hangi odalara geçişin olduğu başlangıçta biliniyor olabilir ya da süreç sırasında öğreniliyor olabilir. Yukarıdaki problemde labirentin durumunun önceden bilindiğini varsayırsak hangi durumlarda hangi eylemlerin yapılabileceğini bir sözlük nesnesiyle ya da matrisle temsil edebiliriz.

Pekiştirmeli öğrenmede bir ödül mekanizmasının olması gerekiğinden bahsetmiştim. Çünkü öğrenme aslında toplam ödülü maksimize etmeye çalışmakla gerçekleşmektedir. Ödül mekanizması ortamı iyi bilenler tarafından makul bir biçimde oluşturulabilir. Ancak bazen ortam problem çözümü tarafından da tam olarak bilinmeyecek bir durumda programcı yalnızca açık birtakım durumlar için ödül koyabilir. Örneğin yukarıdaki labirentte ödül yalnızca labirentten çıkış için veriliyor olabilir. Yani örneğin herhangi iki oda arasındaki geçiş eyleminden 0 ödül verilirken bir odadan dışarıya çıkış için 100'lük ödül verilebilir.

Q Learning algoritmasında ismine "Q-Tablosu (Q-Table)" denilen bir tablo oluşturulmaktadır. Bu tabloda satırlar durumları (states) sütunlar ise eylemleri (actions) belirtir. Q tabloları sözlükler ya da matrisler biçiminde oluşturulabilmektedir. Çünkü tablodan amaç belli durumda iken hangi eylemlerin uygun olacağına ilişkin bir puanlama oluşturmaktır. Yani algoritmada etmen (agent) belli bir durumdayken tabloya başvurarak o durumda hangi eylemin yapılması gerekiğine karar verir. Q-Tablosu başlangıçta 0'larla doldurulur.



Tabii Q-Tablosunu oluşturan durumların da aslında değişken sayısına bağlı olarak matrisel bir biçimde olabileceğine dikkat ediniz. Örneğin MountainCar simülasyonunda durum aslında 20×20 'lik bir matristir. Bu durumda MountainCar

simülasyonundaki eylemler de 3 tane olduğuna göre bu simülasyon için oluşturulacak Q-Tablosu aslında 20X20X3'lük bir matris durumunda olacaktır. Tabii yukarıda da belirttiğimiz gibi Q-Tablosu bir matris biçiminde değil bir sözlük biçiminde de oluşturulabilir. Örneğin yukarıdaki labirent için Q-Tablosu aşağıdaki gibi bir sözlük biçiminde oluşturulabilir:

```
maze = {0: {4: 0}, 1: {3: 0, 5: 0}, 2: {3: 0}, 3: {1: 0, 2: 0, 4: 0}, 4: {0: 0, 3: 0, 5: 0}, 5: {5: 0}}
```

Burada bir sözlüğün her elemanı sözlük yapılmıştır. Bu tür problemlerde matris yerine sözlüklerin tercih edilmesinin en önemli nedeni her durumda yapılacak eylemlerin farklı olmasıdır.

Aynı labirent için Q tablosu aşağıdaki gibi bir matrisle de oluşturulabilirdi:

```
maze = np.zeros((6, 6))
```

		Eylemler					
		0	1	2	3	4	5
Durumlar	0	0	0	0	0	0	0
	1	0	0	0	0	0	0
	2	0	0	0	0	0	0
	3	0	0	0	0	0	0
	4	0	0	0	0	0	0
	5	0	0	0	0	0	0
	6	0	0	0	0	0	0

Q Tablosu

Q tablosu öğrenme süreci sırasında her eylemden sonra güncellenen bir tablodur. Öğrenme gerçekleştikçe tablo gitgide güncellenir. Öğrenme süreci bittiğinde tablo hangi durumlarda hangi eylemlerin en yararlı olduğunu belirten bir yapıya kavuşur.

Q-Learning algoritmasının incelikleri yavaş yavaş ele alınacaktır. Ancak algoritma baştan rastgele bir durumdan başlatılır. İşin başında mademki etmen (agent) hiçbir şey bilmemektedir. O halde rastgele bir eylemde bulunur. İşte etmen belli s durumunda belli bir a hareketini yaptığından matrisin [s, a] elemanı bir formülle güncellenmektedir. Böylece bir durumda bir eylem yapıldığında gittikçe tablo elemanları güncellenmiş olacaktır. Bu eylemler arttıkça tablo elemanları daha uygun değerlerle doldurulur. En sonunda Q-Tablosu tatminkar değerlerle doldurulduğunda artık etmen belli bir durumda bırakıldığından ödülü en büyüklemek için ne yapması gerektiğini öğrenmiş olacaktır. Burada şüphesiz iki nokta önemlidir:

1) Tablo elemanı hangi formüle göre güncellenmektedir?

2) Belli bir durumda etmen hangi eylemi gerçekleştirecektir?

Tablo elemanlarının güncellenmesi aşağıdaki formüle göre yapılmaktadır:

$$Q(s_t, a_t) \leftarrow \underbrace{Q(s_t, a_t)}_{\text{old value}} + \underbrace{\alpha}_{\text{learning rate}} \cdot \left(\underbrace{r_{t+1} + \gamma \max_a Q(s_{t+1}, a)}_{\substack{\text{learned value} \\ \text{reward} \\ \text{discount factor} \\ \text{estimate of optimal future value}}} - \underbrace{Q(s_t, a_t)}_{\text{old value}} \right)$$

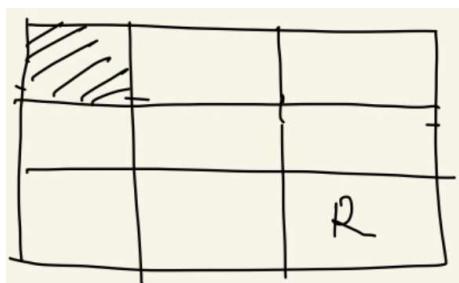
Bu formülde iki önemli sabit vardır: Alfa (learning rate) ve gama (discount). Bu faktörler 0 ile 1 arasında bir değer olarak alınabilmektedir ve daha sonra bunların etkisinden bahsedilecektir. Buradaki t+1 alt indisleri "sonraki" anlamına gelmektedir. Örneğin formüldeki r_{t+1} yeni duruma geçildiğindeki yani eski durumdan yeni duruma geçiş için (s_t 'den s_{t+1} 'e geçiş için) verilecek ödülü belirtmektedir. Formülün max ile ilgili kısmı şu anlamda gelmektedir: s_t durumundan s_{t+1} durumuna geçiş planlandığı zaman kendimizin s_{t+1} durumunda olduğumuzu varsayırsak oradan başka bir duruma geçiş için elde edilecek maksimum kalite (ya da memnuniyet diyebiliriz) bulunmak istenmektedir.

Çünkü Q matrisi aslında nihayetinde her durumdan mümkün her eylemin amaç doğrultusundaki kalitesini (quality) belirtir. Yani Q matrisinde $[s, a]$ elemanı s durumdayken a eylemi gerçekleştirildiğinde bundan ne kadar memnuniyet duyulacağını belirtmektedir.

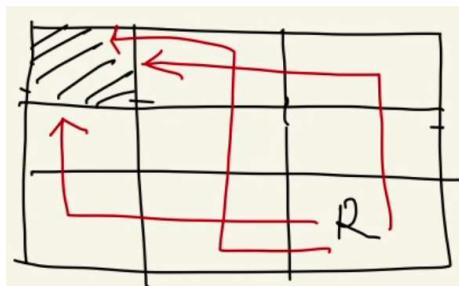
Peki de her eylemden sonra Q-Tablosu güncelleneceğine göre öğrenme süreci toplamda nasıl olacaktır? İşte öğrenme süreci kabaca şöyle bir algoritmayla gerçekleştirilebilir:

- 1) Öğrenme süreci bölüm bölüm (episode'larla) yapılmaktadır. Her bölüm rastgele bir durumdan başlatılır.
- 2) Her durumda en iyi eylem gerçekleştirilmeye çalışılır. Bunun için alternatifler arasındaki en iyi Q değeri seçilir. Tabii bu Q değeri yalnızca tablodan değil yine yukarıdaki formülden elde edilmelidir.
- 3) İşin başında Q tablosu tamamen boş olduğuna göre rastgele bir eylem seçilebilir. Tabloda duruma ilişkin satırın tüm elemanları 0 ise rastgele bir eylemin seçilmesi uygun olacaktır. Bazen alternatif Q değerleri aynı da olabilmektedir. Bu durumda yine rastgele bir eylem seçilebilir.

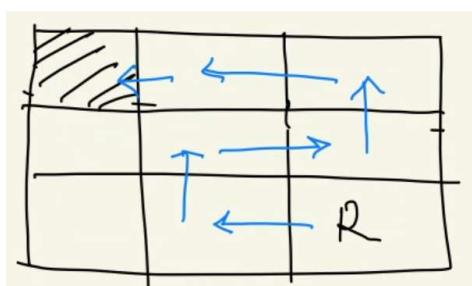
Şimdi çok basit bir problem üzerinde düşünelim. Etmeniz bir robot olsun. Bu robot 3X3'lük bir matriste sola, sağa, yukarı aşağı gidebilsin. Ama çapraz olarak gidemesin. Burada robotun amacı belli bir hücreye hızlı (en az yol kat edecek biçimde) varmak olsun:



Burada taralı hücre hedefi belirtiyor olsun. Görüldüğü gibi hedefe varmanın en kısa yolu 4 adımdır. Bu yol farklı biçimlerde oluşturulabilmektedir. Örneğin:



Ancak aşağıdaki gibi bir rota hedefe daha yavaş varmaktadır:



Böyle bir problemi rastgele hareketlerle çözmeye çalışabiliriz. Her hedefe varlığında yolu hesaplayabiliriz. Ancak bu bir öğrenmeye yol açmaz. Yani robot her defasında rastgele hareketler yapar. Halbuki istediğimiz şey robotu eğitmek ondan sonra onu herhangi bir hücreye koyduğumuzda en kısa yolu bulmasını sağlamaktır. Psikoloji de öğrenmenin

"davranışta -göreli olarak- kalıcı bir değişiklik oluşturan süreçler" biçiminde tanımladığını anımsayınız. Rastgele hareketler daha sonra kullanılabilecek bir davranış değişikliğine yol açmamaktadır.

Burada öğretici olarak robota yaptığı hareketlerden ödül (ya da ceza) vermemiz gereklidir. Peki nasıl bir ödül mekanizması oluşturulabilir? Akla gelen makul ödül mekanizması hedefe yaklaştıkça artan, uzaklaştıkça azalan ya da negatif hale gelen bir mekanizma olabilir. Tabii bunun için bizim robotun durumuyla hedef arasındaki ilişkiyi biliyor olmamız gereklidir. Ancak her uygulamada buna benzer bir bilgiyi öğretici bilmiyor olabilir. Bu nedenle ödül sistemi genellikle daha basit bir biçimde oluşturulmaktadır. Örneğin burada en basit bir ödül mekanizması "hedefe varan hareketin 1, hedefe varmayan hareketin 0" olarak ödüllendirilmesidir. (Tabii 0 ödül aslında ödül vermemek negatif ödül ise ceza vermek anlamındadır.)

Bu problemi Q-Learning algoritmasıyla çözebilme için yukarıda da belirtildiği gibi bir Q-Tablosunun oluşturulması gereklidir. Yukarıda da belirttiğimiz gibi Q-Tablosu satırlarda durumların sütunlarda eylemlerin (actions) olduğu bir tablodur. Tipik olarak matrisel bir biçimde oluşturulabildiği gibi sözlük gibi veri yapılarıyla da oluşturulabilmektedir. Q-Tablosunu oluşturabilmek için ise şüphesiz bizim önce problemi durumlar (states) ve eylemler (actions) biçiminde tanımlamamız gereklidir. Bu problemdeki durumlar robotun içinde bulunduğu hücredir. Eylemler ise robotun hareketleridir. Biz her hücreyi bir durumla temsil edebiliriz:

S_0	S_1	S_2
S_3	S_4	S_5
S_6	S_7	R S_8

Robotun bir durumdayken başka bir duruma geçmesi biçiminde tanımlanan eylemleri de dört tane dir: Yukarı, Sağ, Aşağı, Sola gitmek. Tabii bu problemde robotun her durumda her eylemi yapamayacağı da görülmektedir. Örneğin robot S_8 durumunda sağa ve aşağı gidememektedir. Bu gidememe durumu programlamada bir biçimde oluşturulmalıdır. Bazen mümkün hareketler sanki mümkünmiş gibi düşünülüp ona yüksek cezalar da verilebilmektedir. Bu durumda Q-Tablosu aşağıdaki gibi ifade edilebilir:

	Yukarı	Sağ	Aşağı	Sola
S_0				
S_1				
S_2				
S_3				
S_4				
S_5				
S_6				
S_7				
S_8				

(Q - Tablosu)

Q-Learning algoritmasında tablodaki hücreleri güncellerken kullanılan iki parametrik değerini olduğunu görüyoruz. Bunlar alfa ve gama değerleridir. Alfa değerine "öğrenme hızı (learning rate)" gama değerine ise "indirim (discount)" denilmektedir. Bu iki parametre de 0 ile 1 arasında bir değer almaktadır. Biz bu örneğimizde alfa değerini 1, gama değerini 0.90 olarak alalım:

$$Q(s_t, a_t) \leftarrow \underbrace{Q(s_t, a_t)}_{\text{old value}} + \underbrace{\alpha}_{\text{learning rate}} \cdot \left(\underbrace{r_{t+1} + \gamma \cdot \max_a Q(s_{t+1}, a)}_{\substack{\text{learned value} \\ \text{reward} \\ \text{discount factor} \\ \text{estimate of optimal future value}}} - \underbrace{Q(s_t, a_t)}_{\text{old value}} \right)$$

Q-Learning algoritmasında oluşturulan Q tablosu baştan 0'larla doldurulmuştur. Q-Tablosu yukarıda da belirtildiği gibi aslında hangi durumdayken hangi eylemlerin daha iyi (kaliteli) olduğunu göstermektedir. İşin başında biz hangi eylemlerin hangi iyilikte olduğunu bilememekteyiz. Bu nedenle Q-Tablosu da 0'larla doldurulmaktadır.

Şimdi robotumuzun S1'de olduğunu ve S0'a gitmek istedğini düşünelim. Eğer robot S1'de ise ve S0'a gitmek istiyorsa bu eylem sonucunda bizim tablonun S1-Sola hücresini güncellememiz gereklidir. Bu güncelleme yukarıdaki formüle göre yapılacaktır. Alfa için 1, gama için 0.90 değerlerini uygun görmüştük. Formüldeki r_{t+1} S1'den Sola gidildiğinde elde edilecek ödülü belirtmektedir. Bu ödülü 1 olduğunu belirlemiştik. Formüldeki $\max_a Q(s_{t+1}, a)$ bulunulan durumdan belli durumlara gidildiğindeki o durumlara özgü en yüksek tablo değerini belirtir. Yani örneğin biz S1'deyken sağa gitmek istediğimizde kendimizi bu yeni S2'de olduğumuzu düşünerek burada yapabileceğimiz en iyi eylemi bulmak istemekteyiz.

Biz S1'deydik ve S0'a gitmek istiyorduk. Bu durumda tabloda güncelleyeceğimiz hücre $Q(s_1, \text{sola})$ hücresi olacaktır. Yukarıdaki formüle göre güncellememizi yapalım:

$$Q(s_1, \text{sola}) = Q(s_1, \text{sola}) + 1 * (1 + 0.90 * 0 - Q(s_1, \text{sola}))$$

Buradan 1 değeri elde edilecektir. S1'den sola gidildiğinde varılacak yer hedef olduğu için formülün max elemanından 0 elde edildiğini varsayıyoruz. Bu durumda Q-Tablosu şu hale gelecektir:

	Yukarı	Sağ	Aşağı	Sola
S0	0	0	0	0
S1	0	0	0	1
S2	0	0	0	0
S3	0	0	0	0
S4	0	0	0	0
S5	0	0	0	0
S6	0	0	0	0
S7	0	0	0	0
S8	0	0	0	0

Q - Tablosu

Şimdi robotumuzun S2'de olduğunu varsayıyalım. S2'den sola gitmek isteyelim. Bu durumda biz tablomuzun $Q(s_2, \text{sola})$ hücresini güncelleriz. Formülü uygulayalım:

$$Q(s_2, \text{sola}) = Q(s_2, \text{sola}) + 1 * (0 + 0.90 * 1 - Q(s_1, \text{saga}))$$

Buradan 0.90 değeri elde edilmektedir. Algoritmada kritik nokta formüldeki max değерidir. Biz S2'den sola gitmek istedik. Hedef olarak varacağımız yer S1'dir. İşte bu max değeri robotun S1'de olduğu fikriyle oradaki eylemlere ilişkin en büyük tablo değerini belirtir. Bu da 1'dir.

	Yukarı	Sağ	Aşağı	Sola
S0	0	0	0	0
S1	0	0	0	1
S2	0	0	0	0
S3	0	0	0	0
S4	0	0	0	0
S5	0	0	0	0
S6	0	0	0	0
S7	0	0	0	0
S8	0	0	0	0

Q - Tablosu

güncellenen hücre
S1'den S2'ye gitmek istedigind
S1'deki Tablo degerleri en
buyuk

Q-Tablosunun yeni durumu şöyledir:

	Yukarı	Sağ	Aşağı	Sola
S0	0	0	0	0
S1	0	0	0	1
S2	0	0	0	0.90
S3	0	0	0	0
S4	0	0	0	0
S5	0	0	0	0
S6	0	0	0	0
S7	0	0	0	0
S8	0	0	0	0

Q - Tablosu

Şimdi robotun S1'de olduğunu ve S2'ye gitmek istediğini düşünelim. Şüphesiz bu iyi bir hareket değildir. Fakat Q(s1, sağa) hücresini formüle göre güncelleyelim:

$$Q(s1, \text{sağ}) = 0 + 1 * (0 + 0.90 * 0.90 - 0)$$

Buradan 0.81 değeri elde edilir. Buradaki max elemanın 0.90 değerinde olduğuna dikkat ediniz. Çünkü robot s1'den s2'ye girmek istediğiinde s2'de olduğu fikriyle oradaki eylemlerin en yüksek tablo değeri 0.90'dır:

	Yukarı	Sağ	Aşağı	Sola
S0	0	0	0	0
S1	0	0	0	1
S2	0	0	0	0.90
S3	0	0	0	0
S4	0	0	0	0
S5	0	0	0	0
S6	0	0	0	0
S7	0	0	0	0
S8	0	0	0	0

Q - Tablosu

güncellenen hücre
Robotun S2'de 0.90'yu
fikriyle orada yapabilecegi,
eylenen en yakin degere

Q-Tablosunun yeni hali şöyledir:

	Yukarı	Sağ	Aşağı	Sola
S0	0	0	0	0
S1	0	0.81	0	1
S2	0	0	0	0.90
S3	0	0	0	0
S4	0	0	0	0
S5	0	0	0	0
S6	0	0	0	0
S7	0	0	0	0
S8	0	0	0	0

Q - Tablosu

Şimdi robotumuzun S5'te olduğunu varsayıyalım ve robotumuz yukarıya gitmek istesin. Bu durumda Q-Tablosundaki Q(s5, yukarıya) hücresi güncellenecektir. Formülü uygulayalım:

$$Q(s5, \text{ yukarıya}) = 0 + 1 * (0 + 0.90 * 0.90 - 0)$$

Buradan elde edilecek değer 0.81'dir. Çünkü S5'ten yukarıya gittiğimizde S2 durumuna geçeriz. Robotumuzun S2'de olduğu fikriyle oradan elde edebileceğimiz yerin en yüksek değeri (s2 satırından) 0.90'dır. O halde tablomuzun yeni durumu şöyle olacaktır:

	Yukarı	Sağ	Aşağı	Sola
S0	0	0	0	0
S1	0	0.81	0	1
S2	0	0	0	0.90
S3	0	0	0	0
S4	0	0	0	0
S5	0.81	0	0	0
S6	0	0	0	0
S7	0	0	0	0
S8	0	0	0	0

Q - Tablosu

Şimdi de robotumuzun S8'de olduğunu varsayıyalım ve yukarıya gitmek istediğini düşünelim. Bu durumda Q-Tablosunun Q(s8, yukarıya) elemanı güncellenecektir. Formülü uygulayalım:

$$Q(s8, \text{ yukarıya}) = 0 + 1 * (0 + 0.90 * 0.81 - 0)$$

Buradan elde edilecek değer 0.729'dur. Tablomuzun yeni hali şöyledir:

	Yukarı	Sağ	Aşağı	Sola
s0	0	0	0	0
s1	0	0.81	0	1
s2	0	0	0	0.90
s3	0	0	0	0
s4	0	0	0	0
s5	0.81	0	0	0
s6	0	0	0	0
s7	0	0	0	0
s8	0.729	0	0	0

Q - Tablosu

Şimdi tablomuzu biraz daha doldurmaya çalışalım. Örneğin robotumuzun S8'de olduğunu ve sola gitmek istediğini varsayıyalım:

$$Q(s8, sola) = 0 + 1 * (0 + 0.90 * 0 - 0)$$

Buradan 0 değeri elde edilecektir. Aslında S8'den sola gitmek izlenebilecek bir yoldur. Ancak tablo henüz boş olduğu için bu değer 0 olarak elde edilir. Burada biz başlangıçta boş olan tablonun ödül almadıkça anlamlı değerlerle doldurulamadığını görüyoruz. Tablonun doldurulma stratejisi Q-Learning algoritmasında önemli bir konudur.

Şimdi robotumuzun S3'te olduğunu varsayıyalım ve yukarıya gitmek isteyelim:

$$Q(s3, yukarıya) = 0 + 1 * (1 + 0.90 * 0 - 0)$$

Burada 1 değeri elde edilecektir. Tablomuzun hali şöyledir:

	Yukarı	Sağ	Aşağı	Sola
s0	0	0	0	0
s1	0	0.81	0	1
s2	0	0	0	0.90
s3	1	0	0	0
s4	0	0	0	0
s5	0.81	0	0	0
s6	0	0	0	0
s7	0	0	0	0
s8	0.729	0	0	0

Q - Tablosu

Şimdi sırasıyla birkaç elemanı güncelleylelim:

$$Q(s4, yukarıya) = 0 + 1 * (0 + 0.90 * 1 - 0) = 0.90$$

$$Q(s6, yukarıya) = 0 + 1 * (0 + 0.90 * 1 - 0) = 0.90$$

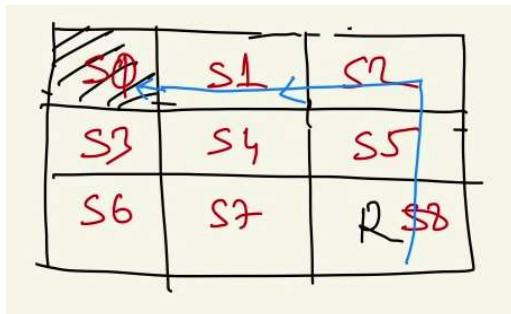
$$Q(s7, sağa) = 0 + 1 * (0 + 0.90 * 0.729 - 0) = 0.656$$

$$Q(s7, yukarıya) = 0 + 1 * (0 + 0.90 * 0.90 - 0) = 0.81$$

	Yukarı	Sağ	Aşağı	Sola
S0	0	0	0	0
S1	0	0.81	0	1
S2	0	0	0	0.90
S3	1	0	0	0
S4	0.90	0	0	0
S5	0.81	0	0	0
S6	0.90	0	0	0
S7	0.81	0.656	0	0
S8	0.729	0	0	0

Q - Tablosu

Böylesi işlemlerle tablonun doldurulduğunu ve hücrelerin de güncellendiğini düşünelim. En son varacağımız nokta ne olacaktır? İşte en sonunda biz robotumuzu herhangi bir hücreye bıraktığımızda robotumuz bu tabloya bakarak hedefe (yani S0 hücresine) en kısa sürede ulaşacaktır. Doldurulmuş ve güncellenmiş bir Q-Tablosunda etmenin hedefe gitmesi şöyle gerçekleşir: Etmen hangi konumdaysa her zaman o konumdaki en yüksek tablo değerine ilişkin eylemi gerçekleştirir. Sonra yeni durumda da aynı işlemleri yapar. Örneğin yukarıda zayıf doldurulmuş tabloda robotun S8'de olduğunu düşünelim. S8 satırındaki en yüksek puanlı eylem yukarıya gitmektir. Robot yukarı gidince S5 durumuna gelmiş olur. S5 satırındaki en yüksek puanlı eylem yukarı gitmektir. Böylece robot S2'ye gelir. S2 satırındaki en yüksek puanlı eylem ise sola gitmektir. Böylece robot S1'ye gelmiş olur. S1 satırındaki en yüksek puanlı eylem ise sola gitmektir. Böylece robot hedefe ulaşmış olur.



Formüldeki indirim (discount) parametresinin ne anlama ifade ettiğine yönelik bir ip ucu elde etmiş olabilirsiniz. Bu indirim parametresi hedeften uzaklaştıkça puan düşürmektedir. Bu değer 1'den ne kadar küçük olursa puan o kadar çabuk düşürülür.

Q-Learning Algoritmasında Keşif-İşletme Stratejileri

Q-Learning yönteminde tabloyu doldurmak için Q-Tablosundaki en iyi eylemlerin yanı sıra rastgele birtakım eylemlerin de yapılması gerekmektedir. Arada rastgele eylemlerin yapılmasına "keşif" (exploration), tabloya bakarak en iyi Q değerine ilişkin eylemi uygulamaya ise "işletme (exploitation)" denilmektedir. İşte ne zaman keşif (exploration) ne zaman işletme (exploitation) uygulanacağına yönelik "keşif-işletme stratejileri (exploration - exploitation strategies)" vardır. En basit keşif-işletme stratejilerinden biri "epsilon greedy" denilen yöntemdir.

Epsilon greedy keşif-işletme stratejisinde belli bir olasılık dahilinde keşif belli bir olasılık dahilinde işletme uygulanır. Bu yöntem kendi içerisinde çeşitli varyasyonlarla kullanılmaktadır. En basit biçimde bir rassal sayı üretılır. O sayı belli bir epsilon değerinden küçükse keşif, değilse işletme uygulanır. Örneğin:

```

if np.random.uniform(0, 1) < EPSILON:
    # keşif
else:
    # işletme

```

np.random.uniform fonksiyonunun belli aralıkta düzgün dağılmış rastgele değer ürettiğini anımsayınız (fonksiyon default durumda zaten [0, 1) aralığını kullanmaktadır). Örneğin yukarıdaki kodda EPSILON değerinin 0.2 olduğunu varsayıyalım. Bu durumda %20 olasılıkla keşif %80 olasılıkla işletme yapılacaktır. Ancak epsilon greedy yönteminin bu biçimde kullanılması aslında çok uygun değildir. Çünkü başlangıçta Q-Tablosu boştur ve boş tabloya başvurmak anlamlı değildir. Bu nedenle başlangıçta çok daha yüksek olasılıkla keşif yapılması ve tablo doldukça keşif olasılığının azaltılması uygun olur. Epsilon değerinin bu biçimde düşürülmesine İngilizce "epsilon decay" denilmektedir. Yüksek bir keşif olasılığının giderek düşürülmesi için en çok kullanılan birkaç teknik açıklamak istiyoruz.

Akla gelen basit yöntem EPOCHS miktarı kadar eğitimde değerin eğitim ilerledikçe oransal olarak düşürülmesidir. Örneğin:

```

for i in range(EPOCHS):
    epsilon = 1 - i / EPOCHS
    if np.random.uniform(0, 1) < epsilon:
        # keşif
    else:
        # işletme

```

Burada keşif olasılığı 1'den itibaren düzenli bir biçimde 0'a kadar düşürülmüştür. Tabii keşfin 0'a kadar düşürülmesi de pek çok durumda uygun olmayabilir. Keşif için epsilon değerinin düşürüleceği bir alt limit de belirlenebilir:

```

for i in range(EPOCHS):
    epsilon = max(1 - i / EPOCHS, EPSILON_MIN)
    if np.random.uniform(0, 1) < epsilon:
        # keşif
    else:
        # işletme

```

Epsilon değerini düşürmede kullanılan diğer bir teknik de çarpma tekniğidir. Burada epsilon değeri her defasında 1'den küçük bir değerle çarpılarak küçültülür. Örneğin:

```

EPOCHS = 200
EPSILON_DECAY = 0.99
EPSILON_MIN = 0.20

epsilon = 1
for i in range(EPOCHS):
    if np.random.uniform(0, 1) < epsilon:
        # keşif
    else:
        # işletme
    epsilon = max(epsilon * EPSILON_DECAY, EPSILON_MIN)

```

Epsilon küçültme işlemi için diğer bir yöntem de üstel küçültmedir. Bu yöntemde epsilon değeri e^{-M^*i} gibi bir değerle çarpılır. Buradaki M sabit bir değerdir. i ise her epoch işleminde artırılan sayaç değeridir.

Taxi Simülatöründe Q-Learning Algoritmasının Uygulanması

Şimdi de biz Q-Learning algoritmasını kullanarak Taxi simülatöründe taksinin yolcuya alıp bırakma işini öğrenmesini sağlayalım. Anımsanacağı gibi bu problemdeki toplam durum sayısı 500, toplam eylemlerin sayısı da 6 idi. Bu durumda bizim Q tablomuz 500 X 6'lık bir matris olmalıdır. Eğitim işlemi aşağıdaki gibi yapılabilir:

```

import numpy as np
import gym

NEPOCHS = 10000

```

```

MAX_ITER = 1000
EPSILON = 0.1
DISCOUNT = 0.6
LEARNING_RATE = 0.1

def train(env, nepochs=NEPOCHS, max_iter=MAX_ITER, epsilon=EPSILON,
learning_rate=LEARNING_RATE, discount=DISCOUNT):
    qtable = np.zeros((env.observation_space.n, env.action_space.n))

    for i in range(nepochs):
        obs = env.reset()
        for j in range(max_iter):
            if np.random.uniform(0, 1) < epsilon:
                action = np.random.choice(env.action_space.n)
            else:
                action = np.argmax(qtable[obs])

            next_obs, reward, done, _ = env.step(action)
            if done:
                break
            qtable[obs, action] = qtable[obs, action] + learning_rate * (reward + discount *
np.max(qtable[next_obs]) - qtable[obs, action])
            obs = next_obs

    return qtable

```

Buradaki train fonksiyonu Q-Tablosunu oluşturarak oluşturulmuş olan tabloyla geri dönmektedir. Fonksiyonda her biri en fazla MAX_ITER (1000) kadar hareket yapan NEPOCHS (1000000) kadar deneme yapılmıştır. Yani bir deneme ortam reset edilerek rastgele bir yerden başlatılır, işlem bitene kadar ya da en fazla MAX_ITER kadar devam ettilir. Bu denemeler de toplamda NEPOCHS kadar yinelenmektedir.

Biz de örneğimizde keşif stratejisi olarak "epsilon greedy" yöntemini kullandık:

```

if np.random.uniform(0, 1) < epsilon:
    action = np.random.choice(env.action_space.n)
else:
    action = np.argmax(qtable[obs])

```

Burada np.random.uniform fonksiyonu 0 ile 1 arasında rastgele noktalı bir değer üretmektedir. Bu değer epsilon değerinden küçükse rastgele bir eylem seçilmiştir. Epsilon için default değerin 0.1 olduğunu dikkat ediniz. O halde eğitim sırasında her 10 eylemin ortalama 1 tanesi rastgele alınmaktadır.

train fonksiyonunda Q-Tablosunun yukarı da vermiş olduğumuz formüle göre güncellendiğini görüyorsunuz:

```

qtable[obs, action] = qtable[obs, action] + learning_rate * (reward + discount *
np.max(qtable[next_obs]) - qtable[obs, action])

```

Burada obs ve next_obs önceki sonraki durumları belirtmektedir. Yani eylem uygulanıp yeni bir durum elde edilip eski değer güncellenmiştir. Eğitimi bu fonksiyonu kullanarak yapabiliriz:

```

env = gym.make('Taxi-v3')
qtable = train(env)

```

Aşağıda oluşturulmuş olan Q-Tablosunu kullanarak problemi çözen fonksiyonu görüyorsunuz:

```

def execute(env, qtable):
    count = 0
    obs = env.reset()
    env.render()

```

```

done = False
while not done:
    action = np.argmax(qtable[obs])
    obs, reward, done, _ = env.step(action)
    env.render()
    count += 1

return count

```

Göründüğü gibi bu fonksiyon doldurulmuş Q-Tablosundaki en yüksek değerler eşliğinde belli bir durumdaki en iyi eylemlerini belirlemektedir. Fonksiyon çözüm için gereken adım sayısına geri dönmektedir. Fonksiyonu şöyle çağırabiliriz:

```

result = execute(env, qtable)
print(result)

```

Çıkan sonuç aşağıdaki gibidir:

```

+-----+
|R: | : :G|
|B: | : : |
| : : : : |
| : : | : |
|Y| : |B: |
+-----+
+-----+
|R: | : :G|
| : | : : |
| : : : : |
| : | : : |
|Y| : |B: |
+-----+
(North)
+-----+
|B: | : :G|
| : | : : |
| : : : : |
| : | : : |
|Y| : |B: |
+-----+
(Pickup)
+-----+
|R: | : :G|
|B: | : : |
| : : : : |
| : | : : |
|Y| : |B: |
+-----+
(South)

```

```

+-----+
|R: | : :G| |
| : | : : |
| : | : : |
| : | : : |
|Y| : |B:|
+-----+
(South)

+-----+
|R: | : :G| |
| : | : : |
| : | : : |
| : | : : |
|Y| : |B:|
+-----+
(East)

+-----+
|R: | : :G| |
| : | : : |
| : | : : |
| : | : : |
|Y| : |B:|
+-----+
(East)

+-----+
|R: | : :G| |
| : | : : |
| : | : : |
| : | : : |
|Y| : |B:|
+-----+
(East)
(East)

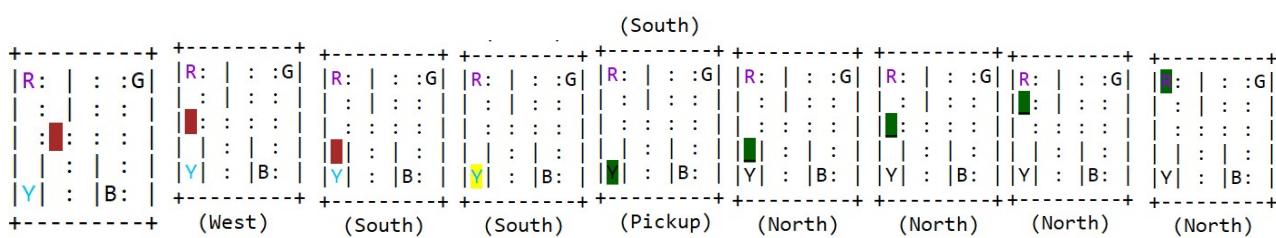
+-----+
|R: | : :G| |
| : | : : |
| : | : : |
| : | : : |
|Y| : |B:|
+-----+
(South)

+-----+
|R: | : :G| |
| : | : : |
| : | : : |
| : | : : |
|Y| : |B:|
+-----+
(South)

+-----+
|R: | : :G| |
| : | : : |
| : | : : |
| : | : : |
|Y| : |B:|
+-----+
(Dropoff)
10

```

Burada araç önce maviye gidip müşteriyi alıp sonra mora gidip müşteriyi bırakıyor. Bu işlemi toplam 10 adımda bitirebilmektedir. Siz de gözle bilişsel yeteneklerinizi kullanarak bu işlemin kaç adımda yapılabileceğini hesaplayınız. Şimdi execute fonksiyonunu yeniden çalıştırıp oluşan durumları yan yana görüntüleyelim:



Bu işlemin hareketli bir biçimde görüntülenmesini şöyle yapabiliriz:

```

import time

def execute(env, qtable):
    count = 0
    obs = env.reset()

```

```

env.render()

done = False
while not done:
    action = np.argmax(qtable[obs])
    obs, reward, done, _ = env.step(action)
    print('\x1b[1J' + env.render(mode='ansi'))
    time.sleep(0.5)
    count += 1

return count

result = execute(env, qtable)
print(result)

```

FrozenLake8x8 Simülöründe Q-Learning Algoritmasının Uygulanması

Anımsanacağı gibi FrozenLake8x8 simülöründe kişi belli bir noktadan belli bir hedefe deliklere düşmeden gitmeye çalışıyordu. Ancak kaygan modda (default durum) bir yönde gitmek isterken kayarak ona dik bir yönde de gidebiliyordu. Bu simülörde ödül mekanizması hedefe varan hareketler için 1 puan, hedefe varmayan hareketler için 0 puandı.

Şimdi FrtozenLake8x8 simülörünü Q-Learning algoritmasıyla çözelim:

```

import gym
import numpy as np

NEPOCHS = 5000
MAX_ITER = 100
DISCOUNT = 0.9
LEARNING_RATE = 0.6

def train(env, nepochs=NEPOCHS, max_iter=MAX_ITER, learning_rate=LEARNING_RATE,
discount=DISCOUNT):
    qtable = np.zeros((env.observation_space.n, env.action_space.n))

    for i in range(nepochs):
        obs = env.reset()
        for j in range(max_iter):
            action = np.argmax(qtable[obs] + np.random.randn(1, env.action_space.n) * (1. / (i + 1)))
            next_obs, reward, done, _ = env.step(action)

            qtable[obs, action] = qtable[obs, action] + learning_rate * (
                reward + discount * np.max(qtable[next_obs]) - qtable[obs, action])
            obs = next_obs
            if done:
                break

    return qtable

```

Eğitimde keşif stratejisi olarak normal dağılım yöntemi kullanılmıştır. Bu yöntemde Q-Tablosunun ilgili satırındaki eylemlerin Q değerlerine normal dağılıma uygun rastgele değerler toplanmıştır. Bu toplamın en yüksek Q değeri eylem olarak seçilmiştir:

```
action = np.argmax(qtable[obs] + np.random.randn(1, env.action_space.n) * (1. / (i + 1)))
```

Aynı zamanda her yinelemede bu rastgele normal dağılım değerlerinin etkisinin $1 / (i + 1)$ çarpanı ile düşürüldüğünü görüyorsunuz. Şimdi modelimizi eğitelim:

```
env = gym.make('FrozenLake8x8-v1')
qtable = train(env)
```

Şimdi de hedefi bulan fonksiyonu yazıp çalıştırıralım. Aslında bu fonksiyon yukarıda yazdığımız fonksiyonun aynısıdır. Çünkü tablonun kullanımı aynı biçimdedir:

```
import time

def execute(env, qtable):
    count = 0
    obs = env.reset()
    env.render()

    done = False
    while not done:
        action = np.argmax(qtable[obs])
        obs, reward, done, _ = env.step(action)
        print('\x1b[1J' + env.render(mode='ansi'))
        time.sleep(0.5)
        count += 1

    return count

result = execute(env, qtable)
print(result)
```

Simülatör reset edildiğinde her zaman başlangıç S pozisyonu (sol-üst köşe) olduğuna dikkat ediniz. Kişinin başlangıç pozisyonunun değiştirilmesine yönelik bir dokümantasyon yoktur. Ancak sınıfların yapısı incelediğinde pozisyon bilgisinin env.env.env.s değişkeninde tutulduğu görülmektedir. Yani biz bu değişkendeki değeri değiştirek simülatörün S dışında başka bir yerden çalışmaya başlamasını sağlayabiliriz.

```
import time

def execute(env, qtable, start_pos = 0):
    count = 0
    obs = env.reset()
    env.env.env.s = start_pos
    env.render(mode='ansi')

    done = False
    while not done:
        action = np.argmax(qtable[obs])
        obs, reward, done, _ = env.step(action)
        print('\x1b[1J' + env.render(mode='ansi'))
        time.sleep(0.5)
        count += 1

    return count

result = execute(env, qtable, 12)
print(result)
```

Eğitimi yaparken hep S noktasından eğitimi başlattığımız için buradaki başarı biraz düşebilir. Eğitimi de rastgele yerlerden başlatarak yapabiliriz.

Aşağıdaki örnekte eğitim sırasında her defasında rastgele bir başlangıç noktası seçilmiştir:

```
def train(env, nepochs=NEPOCHS, max_iter=MAX_ITER, learning_rate=LEARNING_RATE,
discount=DISCOUNT):
    qtable = np.zeros((env.observation_space.n, env.action_space.n))
```

```

for i in range(nepochs):
    obs = env.reset()
    env.env.env.s = np.random.randint(env.observation_space.n)
    for j in range(max_iter):
        action = np.argmax(qtable[obs] + np.random.randn(1, env.action_space.n) * (1. / (i
+ 1)))
        next_obs, reward, done, _ = env.step(action)

        qtable[obs, action] = qtable[obs, action] + learning_rate * (
            reward + discount * np.max(qtable[next_obs]) - qtable[obs, action])
        obs = next_obs
        if done:
            break

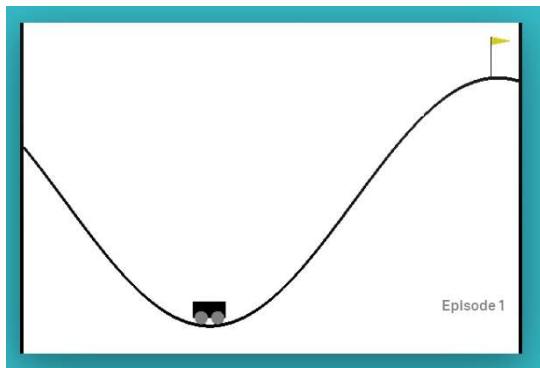
return qtable

```

MountainCar Örneğinin Q Learning Algoritmasıyla Çözümü

Anımsanacağı gibi OpenAI Gym içerisindeki MountainCar simülöründe bir araba motorunu ileri ya da geri çalıştırabiliyor ya da durdurabiliyordu. ve belli bir ve bu hareketlerden yalnızca birini yapabiliyordu. Amaç ise onun tepeyi aşmasıydı. Daha önceden de gördüğümüz gibi araba sürekli ileri gitmeye çalışırsa tepeyi aşmaya gücü yetmemektedir.

Biz MountainCar problemini daha önce bu problemi sezgisel biçimde çözmüştük. Arabayı hız 0'a düşene kadar ileri, daha sonra yine hız sıfıra düşene kadar geri yönde hareket ettirerek tepeyi aşırtmıştık. Burada ise arabanın tepeyi aşması için yapması gereken şeyleler Q-Learning algoritmasıyla pekiştirmeli bir biçimde arabaya öğretilecektir.



Anımsanacağı gibi bu problemdeki mevcut eylemler (action space) 0, 1 ve 2'dir. 0 "geri git", 1 "gaz verme (motoru durdur)", 2 ise "ileri git" anlamına gelmektedir. Yine anımsanacağı gibi problemdeki gözlem değerleri (observation_space) ise iki elemanlı bir NumPy dizisi olarak bize verilmektedir. Dizinin 0'inci indisli elemanı arabanın x eksenindeki konumunu, 1'inci indisli elemanı ise arabanın o andaki hızını belirtmektedir. Burada işlemin başarısını belirten done koşulu iki duruma bağlıdır: Birincisi arabanın tepeyi aşması, ikincisi ise maksimum deneme sayısı olan 200 denemenin bitmesidir.

Bu problemin Q-Learning algoritmasıyla çözümünde ilk yapılacak şey durumların (states) oluşturulmasıdır. Çünkü gözlemlerdeki konum ve hız değerleri sürekli değerlerdir. Bizim bu değerleri ayrı hale getirip durumsallaştırmamız gereklidir. Sürekli gözlem değerlerini ayrı biçimde durumsallaştırırken bir bölme değerini önceden belirleyebiliriz. Tabii aslında her gözlemin diğer gözlemlerle aynı sayıda parçaya ayrılması gerekmektedir. Fakat uygulamada tüm gözlemlerin aynı sayıda parçaya ayrılması kolay bir tasarımdır. Örneğin MountainCar simülöründe parça sayısını 20 olarak belirlediğimizi düşünelim. Bu durumda gözlem değerlerinden biri olan konum maksimum ve minimum değerler dikkate alınarak 20 parçaya bölünecektir. Benzer biçimde arabanın hızı da maksimum ve minimum değerler dikkate alınarak yine 20 parçaya bölünebilir. Arabanın içinde bulunduğu durum (state) böylece aslında 20×20 durumdan bir tanesi olacaktır. Matrisel biçimde düşünüldüğünde bunun için 20×20 'lik iki boyutlu bir matris oluşturulabilir. Arabanın içinde bulunduğu durum konum ve hız biçiminde iki ayrı özellik ile temsil ediliyor olsa da biz bu durumu matrisel bir biçimde iki boyutla temsil edebiliriz. (Tabii bu tür örneklerde observation_space daha fazla

elemana sahipse bu durumda matris de daha fazla boyuttan oluşacaktır. Bizim durumsal indekslerimiz de daha fazla bileşene sahip olacaktır. Örneğin CartPole simülasyonundaki gözlem değişkenleri 4 tanedir.) Aşağıda MountainCar simülasyonu için bir gözlemi indekslerden oluşan durumsal bir bilgiye dönüştüren fonksiyon örneği verilmiştir:

```
import gym

env = gym.make('MountainCar-v0')

DISCRETE_STATES = 20

state_intervals = (env.observation_space.high - env.observation_space.low) / DISCRETE_STATES

def obs_to_state(env, obs):
    return ((obs - env.observation_space.low) / state_intervals).astype(int)
```

Şimdi Q-Tablosunu oluşturmaya çalışalım. MountainCar örneğindeki eylemlerin sayısı 3 olduğuna göre oluşturacağımız Q-Tablosu da $20 \times 20 \times 3$ boyutlarında olacaktır. Q-Tablosu istenilen boyutta şöyle oluşturulabilir:

```
q_table = np.zeros([20, 20, 3])
```

Fakat biz Q-Tablosunun durumsal boyutunu Buradaki boyutu ileride ele alacağımız bir neden dolayı bir fazla olarak oluşturacağız. Bu durumda Q-Tablosu env nesnesinden hareketle daha parametrik bir biçimde şöyle de oluşturulabilirdik:

```
import numpy as np

index_list = [DISCRETE_STATES + 1] * env.observation_space.shape[0] + [env.action_space.n]
q_table = np.zeros(index_list)
```

Buradan elde edilen tablonun $(21, 21, 3)$ boyutunda olduğuna dikkat ediniz.

Şimdi çeşitli denemeler yaptıracak sistemi öğrenme sürecine sokmaya çalışalım. Burada yaptırlan denemeler Q-Tablosunun uygun biçimde doldurulmasına yol açacaktır. Bu örnekte keşif stratejisi (exploration strategy) olarak "epsilon greedy" yönteminin bir varyasyonunu kullanacağız. Kullanacağımız yöntemde epsilon olasılıkla tamamen rastgele bir eylem seçimi yapacağız. Ancak diğer durumlarda birbirlerine benzer Q değerlerinin arasında biraz rassallık da oluşturacağız.

```
import gym

NEPOCHS = 500
MAX_ITER = 1000
LEARNING_RATE = 0.01
EPSILON = 0.2
DISCOUNT = 0.90
DISCRETE_STATES = 15

def obs_to_state(env, obs):
    state_intervals = (env.observation_space.high - env.observation_space.low) /
DISCRETE_STATES
    return ((obs - env.observation_space.low) / state_intervals).astype(int)

import numpy as np

def train(env):
    print('Training starts...')

    index_list = [DISCRETE_STATES + 1] * env.observation_space.shape[0] + [env.action_space.n]
    q_table = np.zeros(index_list)
    for i in range(NEPOCHS):
        obs = env.reset()
        for k in range(MAX_ITER):
```

```

a, b = obs_to_state(env, obs)
if np.random.uniform(0, 1) < EPSILON:
    action = np.random.choice(env.action_space.n)
else:
    logits = q_table[a, b]
    logits_exp = np.exp(logits)
    probs = logits_exp / np.sum(logits_exp)
    action = np.random.choice(env.action_space.n, p=probs)

next_obs, reward, done, _ = env.step(action)
a_next, b_next = obs_to_state(env, next_obs)
q_table[a, b, action] = q_table[a, b, action] + LEARNING_RATE * (
    reward + DISCOUNT * np.max(q_table[a_next, b_next]) - q_table[a, b,
action])
obs = next_obs
print(i, end=' ')
print()

return q_table

```

Buradaki train fonksiyonu hakkında bazı açıklamalar yapmak istiyoruz:

- Fonksiyonda iç içe iki döngü vardır. Dış döngü NEPOCHS kadar dönmektedir. NEPOCHS toplam yapılan denemelerin sayısını belirtir. İç döngü ise MAX_ITER kadar dönmektedir. MAX_ITER de bir denemede en fazla kaç hareket yapılacağını belirtir. Teorik olarak NEPOCHS ve MAX_ITER sayıları ne kadar fazla olursa öğrenmenin de o kadar iyi olacaktır.

- Denemeler sırasında seçilecek eylem (action) aşağıdaki gibi bir koşulla belirlenmiştir:

```

if np.random.uniform(0, 1) < EPSILON:
    action = np.random.choice(env.action_space.n)
else:
    logits = q_table[a, b]
    logits_exp = np.exp(logits)
    probs = logits_exp / np.sum(logits_exp)
    action = np.random.choice(env.action_space.n, p=probs)

```

Yukarıdaki if deyiminde eğer rastgele üretilen değer EPSILON değerinden (%2) küçükse bu durumda rastgele bir eylem seçilmektedir. Eğer bu rastgele değer EPSILON değerinden küçük değilse Q-Tablosundaki en iyi eylemler arasında belli oranlarda rastgelelik ile eylem seçimi yapılmıştır. (Yani örneğin Q tablosundaki eylemlerin puanları farklısa yüksek puanın olasılığı yüksek olacak biçimde bir rastgelelik oluşturulmuştur.) Bu sayede Q değerleri birbirlerine yakın olan eylemler arasında her zaman en yüksek Q değerine sahip olan değil alternatifler de değerlendirilmektedir.

- Döгüdeki Q-Tablo değerlerinin güncellemesi şöyle yapılmıştır:

```

next_obs, reward, done, _ = env.step(action)
a_next, b_next = obs_to_state(env, next_obs, state_intervals)
q_table[a, b, action] = q_table[a, b, action] + learning_rate * (
    reward + GAMMA * np.max(q_table[a_next, b_next]) - q_table[a, b, action])

```

Burada konuya girişte açıkladığımız Q değerinin hesaplanma işlemi ve tablo elemanın güncelleme işlemi yapılmaktadır.

- train fonksiyonun oluşturulan Q tablosuna geri döndüğüne dikkat ediniz.

train fonksiyonu yalnızca Q tablosunu doldurarak öğrenme işlemini gerçekleştirmektedir. Yani bu öğrenme sürecinin sonunda artık biz hangi durumdan (state) başlarsak başlayalım Q tablosundaki en iyi değerlerden hareketle eylemler peşisira yapılacaktır. İşin bu kısmını run fonksiyonu yapmaktadır:

```

def run(env, q_table):
    count = 0
    obs = env.reset()
    while True:
        env.render()
        a, b = obs_to_state(env, obs)
        action = np.argmax(q_table[a, b])
        obs, reward, done, _ = env.step(action)
        count += 1
        if done:
            break

    env.close()

    return count

```

Fonksiyonun yaptığı tek şey aslında Q tablosundan hareketler durum geçişleri yapmaktadır. Q tablosunda bir duruma ilişkin en iyi eylem şu ifadeyle bulunmuştur:

```
action = np.argmax(q_table[a, b])
```

`np.argmax` fonksiyonunun NumPy dizisi içerisinde en yüksek değerin indeksini verdigini anımsayınız. O halde yukarıdaki ifade aslında bize o durum için en yüksek Q değerli eylemi vermektedir.

Nihayet oyunu şöyle çalıştırabiliriz:

```

env = gym.make('MountainCar-v0')
q_table = train(env)

count = run(env, q_table)
print(count)

```

CartPole Simülasyonunun Q Learning Algoritmasıyla Çözümü

Cartpole Simülasyonu aşağıdaki gibi bir Q Learning algoritması kullanılabilir:

```

import numpy as np
import gym

NEPOCH = 2000
MAX_ITER = 1000
EPSILON = 0.02
GAMMA = 1.5
LEARNING_RATE = 0.001
DISCRETE_STATES = 70

def obs_to_state(env, obs, state_intervals):
    states = ((obs - env.observation_space.low) / state_intervals).astype(int)
    states[states > DISCRETE_STATES] = DISCRETE_STATES
    states[states < 0] = 0

    return states

def train(env):
    index_list = [DISCRETE_STATES + 1] * env.observation_space.shape[0] + [env.action_space.n]
    q_table = np.zeros(index_list)
    state_intervals = (env.observation_space.high - env.observation_space.low) /
DISCRETE_STATES
    for i in range(NEPOCH):
        obs = env.reset()

```

```

learning_rate = LEARNING_RATE
for j in range(MAX_ITER):
    a, b, c, d = obs_to_state(env, obs, state_intervals)
    if np.random.uniform(0, 1) < EPSILON:
        action = np.random.choice(env.action_space.n)
    else:
        logits = q_table[a, b, c, d]
        logits_exp = np.exp(logits)
        probs = logits_exp / np.sum(logits_exp)
        action = np.random.choice(env.action_space.n, p=probs)
    obs, reward, done, _ = env.step(action)
    a_next, b_next, c_next, d_next = obs_to_state(env, obs, state_intervals)
    q_table[a, b, c, d, action] = q_table[a, b, c, d, action] + learning_rate * (
        reward + GAMMA * np.max(q_table[a_next, b_next, c_next, d_next]) - 
q_table[a, b, c, d, action])
    print('.', end='')

print()
return q_table

def run_episode(env, q_table, render=True, rnd=False):
    state_intervals = (env.observation_space.high - env.observation_space.low) /
DISCRETE_STATES
    obs = env.reset()
    for step in range(MAX_ITER):
        a, b, c, d = obs_to_state(env, obs, state_intervals)
        if not rnd:
            action = np.argmax(q_table[a, b, c, d])

        else:
            action = env.action_space.sample()

        obs, reward, done, _ = env.step(action)
        if render:
            env.render()
        if done:
            break
    return step + 1

env = gym.make('CartPole-v0')

env.observation_space.low[1] = -10
env.observation_space.high[1] = 10

env.observation_space.low[3] = -10
env.observation_space.high[3] = 10

q_table = train(env)

total_step = run_episode(env, q_table, render=False, rnd=False)
print(total_step)

env.close()

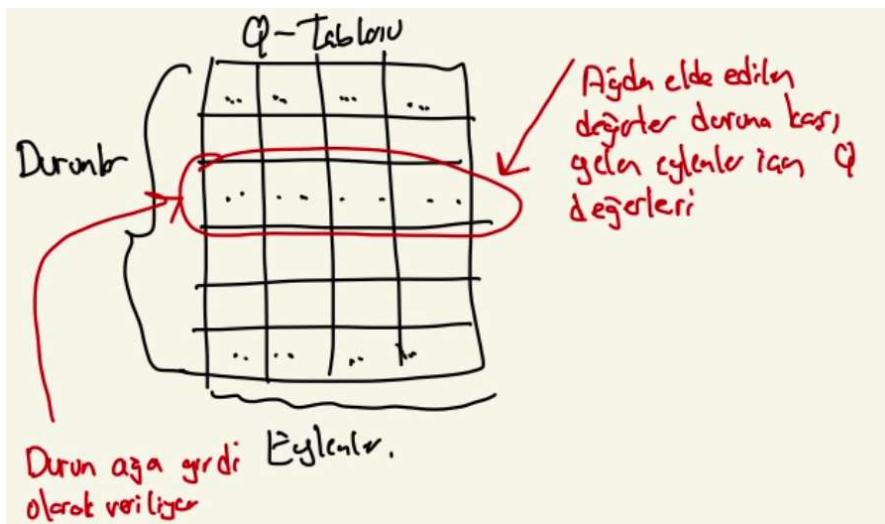
```

Pekiştirmeli Öğrenmede Deep Q-Learning (DQN) Yöntemi

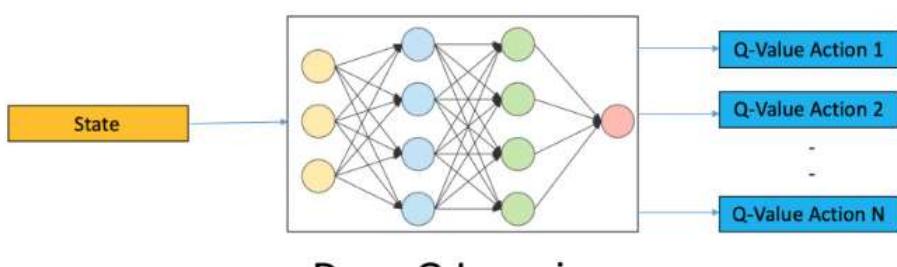
Q Learning en çok tercih edilen pekiştirmeli öğrenme algoritmasıdır. Ancak bu algoritma durum sayısının (yani observation space'in) çok fazla olduğu özellikle de sürekli (continuous) gözlem değerlerinin söz konusu olduğu durumlarda bazı sorunlar oluşturmaktadır. Bu sorunlardan en önemli oluşturulacak Q-Tablosunun büyülüğu dolayısıyla kaplayacağı alandır. Aynı zamanda bu yöntemde Q-Tablosunun doldurulması için iyi bir eğitimin sağlanması gerekmektedir. Maalesef bu yöntemde çok fazla durum söz konusu olduğunda yetersiz bir eğitimde Q-

Tablosunun önemli bir kısmı boş kalabilmektedir. Bu da çözümde bazı durumlarda etmenin (agent) ne yapacağını bilememesine yol açmaktadır. İşte Deep Q-Learning (DQN) yöntemi aslında yapay sinir ağları ile Q-Learning algoritmasının hibrit bir biçimidir.

Anımsanacağı gibi Q-Learning algoritmasında önce bir eğitim süreci gerçekleştirilip durumlar için en iyi eylemlerin ne olacağını belirten bir Q-Tablosu oluşturuluyordu. Sonra da bu Q-Tablosuna bakılarak bir rota izleniyordu. İşte Deep Q-Learning yönteminde bir Q-Tablosu oluşturulup ona başvurulmak yerine belli durumda en iyi eylemin ne olacağı yapay sinir ağından elde edilmektedir. Deep Q-Learning yönteminde oluşturulacak yapay sinir ağının girdilerini durum bilgisi oluşturmaktadır. Bu yapay sinir ağının çıktıları ise belli bir durumdaki Q değerleridir.



Deep Q-Learning yönteminde kullanılan yapay sinir ağının ilgili durum bilgisini alır, çıktı olarak da her eylem için kestirilen Q değerlerini vermektedir. Biz de çıktı Q değerlerinin en büyüğünü bulup ona karşı gelen eylemin en iyi olduğu sonucunu elde ederiz. Bu durumda buradaki ağın girdi katmanında `len(env.observation_space)` kadar nöron, çıktı katmanında da `env.action_space.n` kadar nöron olacaktır.



Sekil <https://www.analyticsvidhya.com/blog/2019/04/introduction-deep-q-learning-python/> sitesinden alınmıştır.

Deep Q-Learning yönteminde sinir ağının bir regresyon modeli oluşturduğu için bizim sürekli durum değerlerini ayrıksa hale getirmememize de gerek kalmamaktadır. Bu sürekli durum değerleri doğrudan ağa girdi olarak verilebilir.

Örneğin CartPole simülasyonunda bu ağın girdi katmanında 4 tane nöron olacaktır. (Arabanın x koordinatı, arabanın hızı, direğin açısı ve direğin açısal hızı). Çıktı katmanında da 2 nöron bulunacaktır. (Araba sola mı sağa mı gidecek?) Bu kestirim ağı bir lojistik regresyon değil normal çok değişkenli (multivariate) bir regresyondur. Dolayısıyla tipik olarak ağı oluştururken gizli katmanların aktivasyon fonksiyonları "relu", loss fonksiyonu "mean_squared_error" ya da "mean_absolute_error", optimizasyon algoritması ise "adam" ya da "rmsprop" ya da "sgd" alınabilir. Çıktı katmanının aktivasyon fonksiyonu da "linear" olmalıdır.

Bilindiği gibi regresyon modellerindeki sinir ağları "denetimli (supervised)" bir öğrenme teknigi kullanmaktadır. O halde Deep Q-Learning yöntemindeki sinir ağı da bir eğitim sürecine sahip olmak zorundadır. Pekiyi biz işin başında sistem hakkında bir şey bilmemiğimize göre eğitimi nasıl uygulayacağız? İşte tipik olarak bu yöntemde eğitimle

kestirim çoğu kez bir arada yürütülmektedir. Programcı önce bazı gözlem kümesi için Q değerlerini bulur, bunları eğitimde kullanır. Sonra da kestirim için sinir ağından faydalananır.

Deep Q-Learning Yöntemi kabaca şöyle gerçekleştirilmektedir:

- 1) Gözlemlere karşılık eylemler için Q değerlerini verecek bir yapay sinir ağı modeli oluşturulur.
- 2) Q-Learning algoritması uygulanarak belli sayıda gözle ve q değerleri elde edilir. Bu Q değerleriyle ağ eğitilir. Genellikle ağın eğitilmesi için bu Q değerlerinin belli bir sayıya (batch) erişmesi beklenir. Bunun için Q değerleri bir bellek alanında saklanabilmektedir. Bu Q değerleri belli sayıya eriştiğten sonra artık iadelî seçimlerle ağıtım başlatılmaktadır. Tabii aslında eğitim hiç biriktirme yapmadan hemen de başlatılabilir.
- 3) Q-Learning algoritması işletilirken Q formülü yine uygulanır. Ancak bu formüldeki tablonun en yüksek elemanları yapay sinir ağından tahminleme yoluyla elde edilmektedir.

Deep Q-Learning Yönteminin CartPole Simülasyonunda Kullanılması

CartPole simülasyonunda Deep Q-Learning yöntemini kullanırken önce yapay sinir ağını oluştururuz. Sonra da bir keşif stratejisi ile ağı eğitiriz. Ağ yeterince eğitildikten sonra da en iyi Q değerlerinden hareketle eylemleri uygularız. Biz burada ağın eğitirken her zaman belirleyeceğimiz bir BATCH miktarı kadar veriyi fit işlemeye sokacağız. Bu BATCH miktarı oluşturma kadar beklenenek sonra eğitime başlanacaktır. Bir kez biriktirdiğimiz değerler bu BATCH miktarına erişince artık her defasında biriktirilen değerler içerisinde BATCH miktarı kadarı rastgele seçilerek eğitime devam edilecektir.

```
import numpy as np
import gym
import random

DISCOUNT = 0.95
LEARNING_RATE = 0.001
BATCH_SIZE = 32
EPSILON_MAX = 1.0
EPSILON_MIN = 0.01
EPSILON_DECAY = 0.995

env = gym.make('CartPole-v1')
exploration_rate = EPSILON_MAX

observation_space = env.observation_space.shape[0]
action_space = env.action_space.n

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense
from tensorflow.keras.optimizers import Adam

def train(env, epoch):
    model = Sequential()
    model.add(Dense(64, input_dim=observation_space, activation='relu', name='Hidden-1'))
    model.add(Dense(64, activation='relu', name='Hidden-2'))
    model.add(Dense(action_space, activation='linear', name='Output'))
    model.compile(optimizer=Adam(lr=LEARNING_RATE), loss='mse')

    epsilon = EPSILON_MAX
    memory = []

    for i in range(epoch):
        obs = env.reset()
        obs = obs.reshape((1, -1))

        count = 0
```

```

while True:
    if np.random.rand() < epsilon:
        action = np.random.choice(action_space)
    else:
        q_values = model.predict(obs)
        action = np.argmax(q_values[0])

    obs_next, reward, done, _ = env.step(action)

    env.render()

    reward = reward if not done else -reward

    obs_next = obs_next.reshape((1, -1))
    memory.append((obs, action, reward, obs_next, done))

    if len(memory) >= BATCH_SIZE:
        batch = random.sample(memory, BATCH_SIZE)
        for obs_mem, action_mem, reward_mem, obs_next_mem, done_mem in batch:
            q_update = reward_mem
            if not done_mem:
                q_update = (reward_mem + DISCOUNT *
np.amax(model.predict(obs_next_mem)[0]))
            q_values = model.predict(obs_mem)
            q_values[0, action_mem] = q_update
            model.fit(obs_mem, q_values, verbose=0)
        epsilon *= EPSILON_DECAY
        epsilon = max(EPSILON_MIN, exploration_rate)

    obs = obs_next
    count += 1

    if done:
        break

print(f'{i} => {count}')

return model

def run_episode(env, model):
    obs = env.reset()
    count = 0
    while True:
        obs = obs.reshape(1, -1)
        action = np.argmax(model.predict(obs))
        obs, reward, done, info = env.step(action)
        if done:
            break
        env.render()
        count += 1

    return count

env = gym.make('CartPole-v1')
model = train(env, 300)
print('training ends...')

result = run_episode(env, model)
print(result)
env.close()

```

Burada kabaca şunlar yapılmıştır:

- Regresyon temelli bir sinir ağı modeli kurulmuştur. Bu sinir ağına CartPole gözlemleri girdi olarak verilip eylemlerin (actions) Q değerleri çıktı olarak alınmaktadır. Dolayısıyla ağı eğitildikten sonra qgün çıktısından elde edilen Q değerlerinin en yüksek olanı eylem olarak tercih edilecektir. Programda ayrık hale getirme gibi bir işlem yapılmamıştır. Çünkü buna gerek yoktur. Zaten sinir ağı sürekli değerler için bir tahmin yapabilmektedir.

- Programda keşif stratejisi olarak "epsilon greedy" yöntemi kullanılmıştır. Ancak rassallık gitgide azaltılmıştır. Rassallık önce EPSILON_MAX değerinden başlatılır. Her yinelemede EPSILON_DECAY kadar azaltılmaktadır. Ancak rassal en fazla EPSILON_MIN değerine kadar azaltılmış olmaktadır.

- Ağın eğitilmesi şöyle sağlanmaktadır: Önce BATCH_SIZE kadar veri toplanana kadar hiç eğitim uygulanmaz. İlk eğitim BATCH_SIZE bilgi toplandığında başlatılır. Bundan sonra da artık her yeni bilgi oluştuğunda yeniden rastgele bir BATCH_SIZE kadar bilgi çekilerek eğitim devam ettirilmektedir. Örneğimizde BATCH_SIZE 32 olarak alınmıştır. Bu durumda ilk 32 değer için hiçbir eğitim yapılmamakta sonra hep rasgele 32 değer seçilerek fit işlemi yapılmaktadır.

Bu biçimdeki modelin başarısı neye bağlıdır? Seçilen bazı parametrik değerlerin, sinir ağının genel yapısının ve diğer parametrelerin öğrenme hızında ve verilen kararlarda etkisinin olduğu açıklıdır. Programcı bu tür durumlarda deneme yanılma yöntemlerine de başvurabilir. Ancak ağın eğitilmesi için çok denemenin yapılması gerekebilir.

Pekiştirmeli Öğrenmede Kullanılabilecek Yüksek Seviyeli Kütüphaneler

Pekiştirmeli öğrenme problemleri genellikle probleme özgü bir biçimde tasarlanıp eğitilmektedir. Bu da model geliştirme zamanını artırmaktadır. İşte bu tür problemlerdeki geliştirme zamanını azaltmak için son birkaç yıldır yüksek seviyeli kütüphaneler oluşturulmaya başlanmıştır. Henüz bu kütüphaneler çok olsa bir noktada değildir. Ancak zaman içerisinde bunlar da daha iyi hale getirilecektir. Bu tür kütüphaneler arasında uygun olanını seçmek de henüz kolay bir karar değildir. Çünkü hangi kütüphanelerin ne kadar süre içerisinde olgunlaşacağını tahmin etmek zordur. Böyle bir seçimde göz önüne alınması gereken ölçütlerden bazıları şunlar olmalıdır:

- Kütüphanenin genel yeteneği (örneğin kaç algoritma destekleniyor gibi)
- Kütüphanenin dokümantasyonu
- Kütüphanenin genel tasarıtı. Bazı kütüphaneler daha esnek tasarıma sahiptir.
- Kütüphaneyi oluşturan proje grubunun büyülüğu.
- Kütüphaneyi oluşturan proje grubunun destek aldığı sponsorlar.
- Kütüphanenin kolay kullanılabilir olması
- Projenin güncellenme aralığı

Kursun yapıldığı zaman aralığındaki belli başlı kütüphaneler şunlardır:

- KerasRL
- Tensorforce
- OpenAI-Baselines
- Stable Baselines
- ChainerRL
- Coach
- RLLib

Stable-Baselines Kütüphanesinin Kullanımı

Stable-Baselines Kütüphanesi aslında OpenAI kurumunun Baselines kütüphanesinin çatallanmış (fork edilmiş) bir versiyonudur. Ancak bu versiyonda orijinal BaseLines kütüphanesi pek çok bakımdan iyileştirilmiştir. Kütüphanenin dokümantasyonu <https://stable-baselines.readthedocs.io/en/master/> adresinde bulunmaktadır.

Stable-Baselines kütüphanesinin en önemli sorunu maalesef bu kütüphanenin Tensorflow kütüphanesinin 2'den önceki versiyonlarıyla yazılmış olmasıdır. Tensorflow kütüphanesinin 1'li versiyonları Python yorumlayıcısının yeni versiyonlarıyla yüklenememektedir. gym kütüphanesinin son versiyonları ise Python yorumlayıcısının daha ileri

versiyonlarına gereksinim duymaktadır. Bizim önerimiz Python 3.6.13 versiyonuna ilişkin bir "virtual environment" oluşturup Tensorflow ve gym kütüphanelerinin şu versiyonlarının yüklenmesidir:

```
pip install tensorflow==1.15.5
pip install gym==0.16.0
```

Ayrıca stable-baselines kütüphanesinin "stable-baselines3" ismi ile Pytorch kullanılarak yazılmış yeni bir fork versiyonu da yazılmaktadır. Bu versiyonda Pytorch kullandığı için tensorflow ile ilgili sorunlar söz konusu değildir. Bu version şöyle yüklenebilir:

```
pip install stable-baselines3
```

Stable-Baselines3 kütüphanesinin dokümantasyonu için aşağıdaki bağlantıya başvurabiliriniz:

<https://stable-baselines3.readthedocs.io/en/master/>

Stable-Baselines kütüphanesinin kullanımı oldukça basittir. Tipik çalışma şöyle yapılmaktadır:

- 1) Önce bir ortam (environment) nesnesi yaratılır. Ortam nesneleri için gym kütüphanesi referans alınmıştır. Yani programcı ortam nesnesini doğrudan gym.make fonksiyonu ile oluşturulabilmektedir. Tabii programcı isterse kendi problemi için kendi ortam nesnelerini de (custom environment) oluşturabilir. Bu konu izleyen böümlerde ele alınacaktır.
- 2) Uygulanacak algoritma belirlenir. Algoritmaların çoğu geneldir. Yani pek çok ortam için kullanılabilmektedir. En çok kullanılan algoritmalar DQN (Deep Q-Learning), PPO1 ve PPO2 (Proximal Policy Optimization), TRPO (Trust Region Policy Optimization), ACKTR (Actor Critic using Kronecker-Factored Trust Region), DDPG (Deep Deterministic Policy Gradient) algoritmalarıdır. Her algoritma aynı isimli sınıflarla temsil edilmiştir. Bu sınıf nesnelerinde genel olarak model nesneleri denilmektedir. Algoritma sınıflarına ilişkin __init__ metodlarının pek çok parametresi vardır. Parametrelerin çoğu default değerler almaktadır. Zorunlu parametrelerin birisi kullanılacak politikadır. Tipik bazı politikalar şunlardır: MlpPolicy, LnMlpPolicy, CnnPolicy, LnCnnPolicy. En çok kullanılan politikalar MlpPolicy (Multi Layer Perceptron, 64 nörondan oluşan iki katmanlı ağ) ve CnnPolicy (Convolutional Neural Network, 64 nörondan oluşan iki katmanlı ağ).

3) model nesnelerinin learn isimli metodları ile eğitim gerçekleştirilir. Artık eğitilmiş bir model elde edilmiş olur.

4) Eğitilmiş model gerçek durumlara uygulanır. Bunun için model sınıflarının predict metodları kullanılır. Bu metodlar parametre olarak bizden durumu (observation) alırlar ve bize uygulanacak eylemi verirler. Biz de bu işlemleri bir döngü içerisinde yaparak etmeni uygun biçimde çalıştırılmış oluruz.

Örneğin:

```
import gym
from stable_baselines import DQN

env = gym.make('CartPole-v1')

model = DQN('MlpPolicy', env)
model.learn(total_timesteps=100_000)

obs = env.reset()
while True:
    action, _ = model.predict(obs)
    obs, reward, done, _ = env.step(action)
    if done:
        break
    env.render()

env.close()
```

Burada algoritma olarak DQN (Deep Q-Learning) uygulanmıştır. Kullanılan politika MlpPolicy biçimindedir. Bu politika iki katmanlı her biri 64 nörondan oluşan bir yapay sinir ağı kullanmaktadır. learn fonksiyonunda eğitim için toplam 1000000 yinelemenin yapıldığını görürorsunuz. Modelin parametreleri (epsilon, gamma vs.) default biçimde seçilmiştir. Eğitimden sonra örnek bir deneme yapılmıştır.

Şimdi de MountainCar örneğini uygulayalım. MountainCar için de yukarıdaki programın neredeyse aynısı kullanılabilir. Örneğin:

```
import gym

from stable_baselines.deepq.policies import MlpPolicy
from stable_baselines import DQN

env = gym.make('MountainCar-v0')

model = DQN(MlpPolicy, env, verbose=0)
model.learn(total_timesteps=100000)

obs = env.reset()
i = 0
while True:
    action, _states = model.predict(obs)
    obs, reward, done, info = env.step(action)
    if done:
        break
    env.render()
    print(i, end=' ')
    i += 1

env.close()
```

Model eğitildikten sonra saklanıp geri yüklenebilir. Modeli saklamak için model sınıfının save isimli metodu kullanılır. Örneğin:

```
model.save('mountaincar')
```

Bu metot modeli bir .zip dosyası içerisinde saklamaktadır. Modeli geri yüklemek için ise algoritma sınıflarının statik load metodları kullanılmaktadır. Örneğin:

```
model = DQN.load('mountaincar')
```

Örneğin yukarıdaki MountainCar simülasyonunda eğitim sonrası değerleri saklayıp geri yükleyelim:

```
import gym

from stable_baselines.deepq.policies import MlpPolicy
from stable_baselines import DQN

env = gym.make('MountainCar-v0')

model = DQN(MlpPolicy, env, verbose=0)
model.learn(total_timesteps=100000)

model.save('mountaincar')

del model # model nesnesi kasti olarak siliniyor.

model = DQN.load('mountaincar')

obs = env.reset()
```

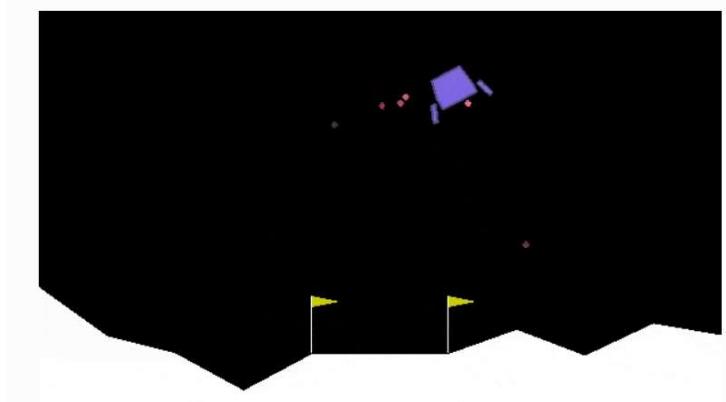
```

i = 0
while True:
    action, _states = model.predict(obs)
    obs, reward, done, info = env.step(action)
    if done:
        break
    env.render()
    print(i, end=' ')
    i += 1

env.close()

```

Stable-Baselines dokğanlarında içerisinde çeşitli örnekler vardır. Örneğin LunarLanding simülatörü ayda inmeye çalışan örümceği takit eder. Bu simülörde amaç örümceğin iki bayrak arasına indirilmesidir. Örümcek sağa sola hareket ettirilebilmektedir.



Modelin eğitimi ve örnek uygulaması şöyle yapılabilmektedir:

```

import gym
from stable_baselines import DQN
from stable_baselines.common.evaluation import evaluate_policy

# Create environment
env = gym.make('LunarLander-v2')

# Instantiate the agent
model = DQN('MlpPolicy', env, learning_rate=1e-3, prioritized_replay=True, verbose=1)
# Train the agent
model.learn(total_timesteps=int(2e5))

# Evaluate the agent
mean_reward, std_reward = evaluate_policy(model, model.get_env(), n_eval_episodes=10)
print(mean_reward, std_reward)

# Enjoy trained agent
obs = env.reset()
for i in range(1000):
    action, _states = model.predict(obs)
    obs, rewards, dones, info = env.step(action)
    env.render()

env.close()

```

Stable-Baselines İçin Ortam Oluşturulması

Örneklerden de görüldüğü gibi stable-baselines OpenAI gym ortamını temel almaktadır. Gerçekten de model sınıfının learn metodu bizden bir ortam nesnesi istemektedir. Pekiyi biz kendi problemlerimizi bu kütüphaneyle nasıl çözebiliriz? İşte bunun için bizim gym uyumlu ortam nesnesi oluşturmamız gereklidir. Kendimize özel ortam sınıfı oluşturma eylemine İngilizce "custom environment" denilmektedir.

Gym uyumlu ortam nesnesi oluşturabilmek için öncelikle gym.Env sınıfından türetme yapılarak bir ortam sınıfının tanımlanması gereklidir. Örneğin:

```
import gym

class MyEnv(gym.Env):
    pass
```

Daha sonra oluşturduğumuz bu ortam sınıfı için action_space ve observation_space isimli örnek özniteliklerini ve reset, step ve render isimli metodları yazmamız gereklidir. Örneğin:

```
import gym

class MyEnv(gym.Env):
    def __init__(self):
        super().__init__()
        # .....
        self.action_space = < actions >
        self.observation_space = < observations >

    def reset(self):
        pass

    def step(self):
        pass

    def render(self):
        pass
```

Şimdi sarma bir sınıf üzerinde bu arayüzün çalıştığını göstermek istiyoruz. Aşağıda Cartpole simülatörünü sarmalayan örnek bir ortam sınıfı veriyoruz:

```
import gym
from stable_baselines import DQN

class MyEnv(gym.Env):
    def __init__(self):
        super().__init__()

        self.env = gym.make('CartPole-v1')
        self.observation_space = self.env.observation_space
        self.action_space = self.env.action_space

    def reset(self):
        return self.env.reset()

    def step(self, action):
        obs, reward, done, _ = self.env.step(action)
        return obs, reward, done, _

    def render(self):
        return self.env.render()

    def close(self):
        return self.env.close()

env = MyEnv()
```

```

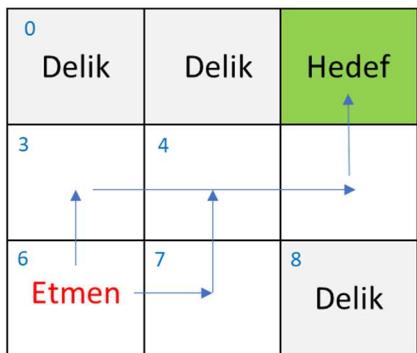
model = DQN('MlpPolicy', env)
model.learn(total_timesteps=100000)

obs = env.reset()
while True:
    action, _ = model.predict(obs)
    obs, reward, done, _ = env.step(action)
    if done:
        break
    env.render()

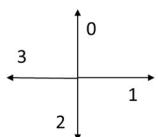
env.close()

```

Şimdi de basit bir simülatör tasarlayarak onun için ortam sınıfı yazalım. Simülatörümüzde bir etmen (agent) belli bir noktadan deliğe düşmeden hedefe varmaya çalışın:



Burada ortam yalnızca etmenin konumuna ilişkin ayırik değerlerden oluşmaktadır. Burada etmenin yapacağı dört tür hareket vardır: Yukarıya gitmek, sağa gitmek, aşağıya gitmek ve sola gitmek. Bu ayırik faaliyetleri sayılarla söyle ifade edebiliriz:



Etmen için ödül/ceza mekanizmasını da söyle oluşturabiliriz:

Deliğe düşme: -10 puan

Hedefe varma: 20 puan

Deliğe düşmeden başka bir duruma geçme: 0 puan

Pekürtmeli öğrenmede hedefe varmakta katkı sağlamayan eylemleri ödüllendirmemelisiniz. Eğer etmeninize gereksiz ödüller verirseniz etmeniniz arzu ettiğiniz şeyi değil başka şeyler öğrenebilir. Bu durumda psikolojideki edimsel koşullanmada da benzerdir. Bir çocuğa işlevsiz eylemlerinde ödül veren bir ebeveyn çocuğun bu işlevsiz hareketleri yinelemesini sağlayabilmektedir.

Kendi ortamınızı (custom environment) oluştururken sınıfın `observation_space` örnek özniteligi'ne eğer ortam ayırik durumlardan oluşuyorsa `gym.spaces` modülündeki `Discrete` sınıfı türünden bir nesne, ortam sürekli ise `Box` türünden bir nesne atanmalıdır. Benzer biçimde sınıfın `action_space` isimli örnek özniteligi'ne de eğer etmen ayırik faaliyet yapıyorsa `Discrete` türünden, sürekli faaliyet yapıyorsa `Box` sınıfı türünden nesnenin atanması gereklidir. Bizim yukarıdaki simülatörümüzde ortam 0 ile 8 arasında, eylem ise 0 ile 3 arasında tamsayılar biçiminde ayırik değerle ifade edilmektedir. Bu nedenle `observation_space` örnek özniteligi'ne `Discrete(8)`, `action_space` örnek özniteligi'ne ise `Discrete(3)` biçimde yaratılan nesneler atanmıştır.

Ortam sınıfının reset metodu etmenin ilk durumunu oluşturarak ortam bilgisyle (observation) geri döner. step metodu ise etmenin yapacağı eylemi (action) parametre olarak alarak etmeni hareket ettirir ve etmenin yeni durumuna ilişkin dörtlü bir demetle geri döner. Bu demetin ilk elemanı etmenin bulunduğu yeni duruma ilişkin ortam bilgisi (observation), ikinci elemanı etmenin yaptığı eylemden elde ettiği ödül/ceza puanını, üçüncü elemanı simülasyonun bitip bitmediğine ilişkin bilgiyi içerir. Demetin son elemanı ise simülatörlarındaki diğer bilgileri içeren bir sözlük nesnesidir. Eğer simülatör ek bir bilgi vermeyecekse demetin bu elemanı boş bir sözlük nesnesi olarak oluşturulmalıdır.

Ortam sınıfının render metodu simülatörün durumunu betimlemek için kullanılmaktadır. render metodu text tabanlı ya da GUI tabanlı bir görüntü eşliğinde bu betimlemeyi yapabilir. Bizim örneğimizde render yalnızca etmenin yeni konumunu ekrana yazdırmaktadır. Nihayet ortam sınıfının close metodu __init__ metodunda yapılan birtakım ilk işlemleri sonlandırmak için kullanılmaktadır.

Yukarıda belirttiğimiz simülatöre ilişkin ortam nesnesinin gerçekleştirimini aşağıda veriyoruz:

```
import gym
from stable_baselines import DQN

class MyEnv(gym.Env):
    def __init__(self):
        super().__init__()

        self.env = gym.make('CartPole-v1')
        self.observation_space = self.env.observation_space
        self.action_space = self.env.action_space

    def reset(self):
        return self.env.reset()

    def step(self, action):
        obs, reward, done, _ = self.env.step(action)
        return obs, reward, done, _

    def render(self):
        return self.env.render()

    def close(self):
        return self.env.close()

env = MyEnv()

model = DQN('MlpPolicy', env)
model.learn(total_timesteps=100000)

obs = env.reset()
while True:
    action, _ = model.predict(obs)
    obs, reward, done, _ = env.step(action)
    if done:
        break
    env.render()

env.close()
```

Şimdi de Pac-Man isimli klasik bir Atari oyununu pekiştirmeli öğrenme yöntemiyle Stable Baselines kullanarak çözmeye çalışalım.

Keras-RL Kütüphanesinin Kullanımı

Tensorforce Kütüphanesinin Kullanımı

Tensorforce kütüphanesinin kullanımı da ana hatlarıyla Stable Baselines